Statistica Pieței Financiare

Date și indicatori statistici

Daniel Traian PELE
Stefan Gaman

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Obiective de învățare

La sfârșitul acestui capitol, veți fi capabili să:

1. **Distingeți** între date de preț OHLC, prețuri ajustate și spread-uri bid-ask
2. **Calculați** randamente simple și logaritmice și explicați pierderea din variență
3. **Identificați** faptele stilizate ale randamentelor (cozi groase, clustering, efect levier)
4. **Aplicați** estimatori de volatilitate bazați pe range (Parkinson, GK, RS, Yang-Zhang)
5. **Comparați** eficiența estimatorilor și volatilitatea condițională vs. necondițională
6. **Calculați** măsuri de performanță ajustate la risc (Sharpe, Sortino, Calmar)
7. **Construiți** frontiera eficientă și derivați portofoliul cu variență minimă

Cuprins

1. Motivație
2. Date de preț
3. Randamente
4. Fapte stilizate
5. Estimatori de volatilitate
6. Comparație de eficiență
7. Randamente ajustate la risc
8. Caz de utilizare AI
9. Rezumat
10. Quiz
11. Bibliografie

De ce avem nevoie de date?

Înțelegerea trecutului

- Identificarea modelelor, tendințelor și anomaliilor.
- Validarea teoriilor: EMH, CAPM, APT.
- Măsurarea profilurilor de risc și randament.

Predicția viitorului

- Prognoza prețurilor, volatilității, corelațiilor.
- Construirea de strategii cantitative.
- Analiză de scenarii și stress testing.

Managementul riscului

- Cuantificarea expunerii: VaR, CVaR, ES.
- Diversificarea portofoliului și hedging.
- Conformitate regulatorie (Basel III, Solvency II).

Evaluare & tranzacționare

- Evaluarea derivatelor (opțiuni, futures, swap-uri).
- Contabilizare mark-to-market.
- Tranzacționare algoritmică și de înaltă frecvență.

Exemple de utilizare a datelor

Analiză tehnică

- Utilizează date istorice de preț și volum.
- Modele grafice, medii mobile, RSI, MACD.
- Presupune că istoria prețurilor se repetă.

Analiză fundamentală

- Situații financiare, câștiguri, indicatori macro.
- Modele de fluxuri de numerar actualizate (DCF).
- Raportul P/E, book-to-market, randamentul dividendelor.

Finanțe cantitative

- Modele statistice: GARCH, vol. stochastică, copule.
- Învățare automată: random forests, LSTM-uri.
- Modele factoriale: Fama-French, Carhart, Barra.

Tranzacționare algoritmică

- Date tick-by-tick, registrul de ordine, date TAQ.
- Algoritmi de execuție sensibili la latență.
- Microstructura pieței și execuția optimă.

Surse de date

Sursă	Tip	Cost	Acoperire
Bloomberg Terminal	OHLCV, fundamentale, știri	$$$$	Global, toate clasele de active
Refinitiv Eikon	OHLCV, date tick, știri	$$$	Global, instituțional
Yahoo Finance	OHLCV zilnic, dividende	Gratuit	Acțiuni, ETF-uri, FX
WRDS / CRSP	Prețuri ajustate, randamente	$$ (academic)	Acțiuni SUA, 1926–prezent
CoinGecko / CoinMarketCap	OHLCV, date on-chain	Gratuit/$	Criptomonede

Surse gratuite

- Yahoo Finance, Alpha Vantage, Quandl (NASDAQ Data Link).
- Suficiente pentru cercetare academică și backtesting.
- Întârzieri: 15–20 minute pentru cotații în timp real.

Surse plătite / instituționale

- Bloomberg, Refinitiv: date tick la nivel de milisecundă.
- WRDS/CRSP: date curate de acțiuni SUA, fără survivorship bias.
- Esențiale pentru managementul profesional al riscului.

Frecvența datelor

Tick → 1 min → 5 min → Hourly → Daily → Weekly → Monthly

HFT — Standard — Macro

- **Frecvență mai mare** ⇒ mai multe observații, mai mult zgomot de microstructură.
- **Zilnic** este frecvența standard pentru cercetarea academică și practică.
- **Efectul Epps** (1979): corelațiile perechi între active *scad* pe măsură ce frecvența de eșantionare crește către nivelul de tick.
  - Cauzat de tranzacționarea asincronă: activele nu se tranzacționează simultan.
  - Corelațiile măsurate la frecvență zilnică sunt semnificativ mai mari decât la 1 minut.
- **Datele intrazilnice** sunt esențiale pentru estimarea volatilității realizate (Secțiunea 5).

Provocări ale datelor în finanțe

- **Calitatea datelor**: Valori lipsă, tick-uri eronate, erori la acțiuni corporative.
  - Chiar și datele Bloomberg conțin erori; validați mereu.
- **Survivorship bias**: Studierea doar a firmelor listate curent inflează randamentele estimate.
  - CRSP include firmele delistate; Yahoo Finance nu.
- **Look-ahead bias**: Utilizarea informațiilor indisponibile la momentul deciziei.
  - Ex., utilizarea compoziției actuale a indicelui pentru a backtesta o strategie de 10 ani.
- **Volumul datelor**: HFT generează $\sim$1 TB/zi per bursă; stocarea și curățarea sunt netriviale.
- **Testare multiplă**: Harvey, Liu & Zhu (2016) argumentează că majoritatea factorilor publicați sunt descoperiri false.
  - p-hacking și căutarea excesivă în date inflează erorile de tip I.
  - Prag recomandat: t-statistic > 3.0 pentru factori noi.
- **Interpretarea datelor**: Corelație $\neq$ cauzalitate; semnificație statistică $\neq$ economică.

Cuprins

1. Motivație ✓
2. **Date de preț**
3. Randamente
4. Fapte stilizate ale randamentelor financiare
5. Estimatori de volatilitate
6. Comparație de eficiență
7. Randamente ajustate la risc
8. Caz AI / Rezumat / Quiz
9. Bibliografie

Date OHLC

Symbol	Denumire	Descriere
O_t	Deschidere	Primul preț din perioada t
H_t	Maxim	Prețul maxim din perioada t
L_t	Minim	Prețul minim din perioada t
C_t	Închidere	Ultimul preț din perioada t
V_t	Volum	Acțiuni tranzacționate

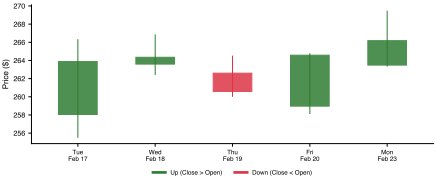

- Prin construcție: $L_t \leq O_t$, $C_t \leq H_t$.
- Range $H_t - L_t$: proxy pentru volatilitatea intra-perioadă.
- Volum mare $\Rightarrow$ descoperire a prețului mai eficientă.

SFM_ch1_ohlc_orderbook

OHLC: Exemplu numeric

- Cinci zile de tranzacționare cu date simulate tip AAPL (prețuri în USD):

Date	Open	High	Low	Close	Volume
2024-01-02	185.20	188.45	184.10	187.90	52,300,000
2024-01-03	187.90	189.30	183.60	184.20	61,800,000
2024-01-04	184.20	186.80	181.50	186.10	48,500,000
2024-01-05	186.10	191.20	185.70	190.40	55,200,000
2024-01-08	190.40	193.50	188.90	192.30	47,900,000

- Ziua 2 (3 Ian): lumânare bearish — Close $<$ Open; spread $= 189.30 - 183.60 = \$5.70$.
- Ziua 4 (5 Ian): lumânare bullish puternică — Close $-$ Open $= \$4.30$; volum mare.
- Randamentul logaritmic zilnic, 2 Ian: $r = \ln(187.90/185.20) = 0.01449 \approx 1.45\%$.

SFM_ch1_ohlc_orderbook

Prețul ajustat de închidere

- Prețurile de închidere brute **nu sunt direct comparabile** în timp din cauza acțiunilor corporative.
- **Prețul ajustat de închidere** ține cont retroactiv de toate acțiunile corporative:

$$P_t^{\text{adj}} = P_t \times \prod_{k:\, t_k > t} A_{t_k}^{-1}$$

- $A_{t_k} \succ$ factorul de ajustare la data acțiunii corporative t_k

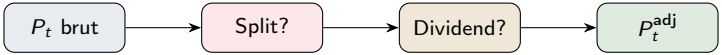

Important

Folosiți mereu prețuri ajustate la calculul randamentelor — prețurile brute prezintă salturi false la datele acțiunilor corporative care ar apărea ca randamente artificiale mari.

Factori individuali de ajustare

- **Splituri de acțiuni** (m-for-n): fiecare acționar primește m acțiuni pentru fiecare n deținute.

$$A_t^{\text{split}} = \frac{n}{m}, \qquad \text{de ex. split 2-la-1: } A_t = \tfrac{1}{2}.$$

- **Dividende în acțiuni**: compania emite acțiuni noi ca dividend (de ex. 10% dividend în acțiuni).

$$A_t^{\text{stock div}} = \frac{1}{1+d}, \qquad d = \text{rata dividendului.}$$

- **Dividende în numerar**: plată directă în numerar D_t pe acțiune.

$$A_t^{\text{cash div}} = \frac{P_{t-1} - D_t}{P_{t-1}} = 1 - \frac{D_t}{P_{t-1}}.$$

- **Oferte de drepturi**: acționarii existenți cumpără acțiuni noi la un preț redus.

$$A_t^{\text{rights}} = \frac{P_{t-1} + r \cdot P_{\text{sub}}}{P_{t-1}(1+r)},$$

unde r = raportul de acțiuni noi per acțiune existentă, P_{sub} = prețul de subscriere.

Exemplu numeric: Prețuri ajustate

Example 1

Acțiune la \$100. Ziua 5: dividend în numerar \$2. Ziua 10: split 2-la-1.

- **Factori de ajustare:** $A_5 = 98/100 = 0.98; \quad A_{10} = 1/2 = 0.50$
- **Prețuri ajustate:**

Perioada	**Ajustări**	**Formulă**
$t < 5$	ambele	$P_t^{\text{adj}} = P_t \times 0.49$
$5 \leq t < 10$	doar split	$P_t^{\text{adj}} = P_t \times 0.50$
$t \geq 10$	niciuna	$P_t^{\text{adj}} = P_t$

- \$100 din Ziua 1 se ajustează la $100 \times 0.49 = \$49$ retroactiv — nu e o pierdere, ci doar o ajustare contabilă.
- Seria de randamente calculată din prețuri ajustate este continuă pe parcursul acțiunilor corporative.

Spread Bid-Ask și registrul de ordine

- **Ask** P^a: cel mai mic preț de vânzare.
- **Bid** P^b: cel mai mare preț de cumpărare.
- **Spread**: $s = P^a - P^b > 0$.
- **Mid-price**: $P^m = (P^a + P^b)/2$.
- **Effective spread**: $2|P_{\text{trade}} - P^m|$.
- Spread-uri mai mici $\Rightarrow$ piață mai lichidă.

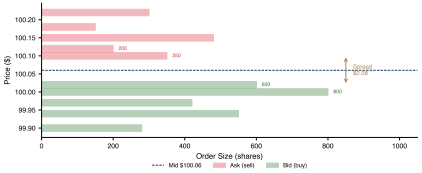

SFM_ch1_ohlc_orderbook

Microstructura pieței

- **Microstructura pieței** studiază modul în care se formează prețurile la nivel de tranzacție.
- **Descoperirea prețului**: procesul prin care informațiile noi sunt încorporate în prețuri.
  - Roll (1984): saltul bid-ask induce autocorrelație *negativă* de ordinul întâi în randamentele tranzacțiilor.
  - Prețul tranzacției observat = prețul real + componentă de zgomot.
- **Asimetria informațională**: unii traderi au informații private (traderi informați).
  - Formatorii de piață lărgesc spread-urile când riscul de selecție adversă este mare.
  - Glosten-Milgrom (1985) model: spread-ul de echilibru depinde de fracția de traderi informați.
- **Market makers**: furnizează lichiditate cotând simultan bid și ask.
  - Profită din spread; suportă risc de inventar și selecție adversă.
- **Tick size**: incrementul minim de preț (de ex., $0.01 pentru acțiunile SUA de la decimalizarea din 2001).
  - Tick mai mic $\Rightarrow$ spread-uri mai mici dar potențial mai puțină adâncime.

Cuprins

1. Motivație ✓
2. Date de preț ✓
3. **Randamente**
4. Fapte stilizate ale randamentelor financiare
5. Estimatori de volatilitate
6. Comparație de eficiență
7. Randamente ajustate la risc
8. Caz AI / Rezumat / Quiz
9. Bibliografie

De ce randamente? Staționaritate

Definiție 1 (Staționaritate slabă (în covarianță))

O serie temporală $\{X_t\}$ este **slab staționară** dacă:

1. $\mathbb{E}[X_t] = \mu$ (medie constantă, $\forall\, t$),
2. $\mathrm{Var}(X_t) = \sigma^2 < \infty$ (varianță constantă și finită, $\forall\, t$),
3. $\mathrm{Cov}(X_t, X_{t-k}) = \gamma(k)$ (autocovarianța depinde doar de lag-ul k, nu de t).

- **Prețurile** P_t sunt în general **nestaționare**: au trend, rădăcini unitare și varianță variabilă în timp.
- **Randamentele** $r_t = \ln(P_t/P_{t-1})$ sunt aproximativ staționare: medie și varianță relativ constante.
- Majoritatea metodelor statistice (OLS, MLE, teste de ipoteză) necesită staționaritate sau variante ale acesteia.
- **Test formal**: testul Augmented Dickey-Fuller (ADF) respinge ipoteza nulă de rădăcină unitară pentru randamente, dar nu pentru prețuri.

Staționaritate: Preț vs. Randamente

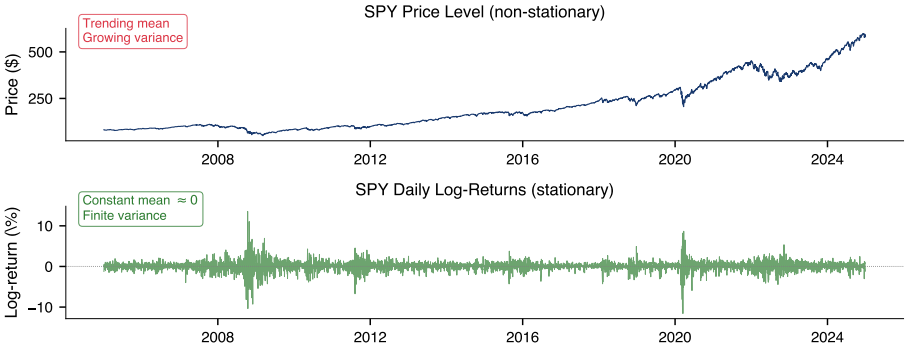

- **Sus**: Prețul SPY are medie cu trend și varianță crescătoare ⇒ nestațională.
- **Jos**: Randamentele log fluctuează în jurul zero-ului cu varianță aprox. constantă ⇒ stațională.

SFM_ch1_stationarity

Randamente simple (aritmetice)

Definiție 2 (Randament simplu)

Randamentul net simplu pe o perioadă:

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}} = \frac{P_t}{P_{t-1}} - 1.$$

Randamentul brut este $1 + R_t = P_t/P_{t-1}$.

- **Aditivitate pe active**: randamentul portofoliului $R_P = \sum_{i=1}^{n} w_i R_i$ (exact, o perioadă).
- **Nu este aditiv în timp**: randamentul brut multi-perioadă $= \prod_s (1 + R_s)$, nu o sumă.
- **Mărginit inferior** de -1 (răspundere limitată; prețurile nu pot fi negative).
- Randamentul brut pe k perioade: $1 + R_t(k) = \prod_{j=0}^{k-1}(1 + R_{t-j})$.
- Exemplu: $P_0 = 100$, $P_1 = 110 \Rightarrow R_1 = 10\%$.

Observație 1

Randamentele simple sunt preferate pentru analiza **cross-secțională** (construcția portofoliului).

Randamente logaritmice (compuse continuu)

Definiție 3 (Randament logaritmic)

Randamentul logaritmic (randament compus continuu):

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln(1 + R_t).$$

- **Aditive în timp**: $r_t(k) = \sum_{j=0}^{k-1} r_{t-j} = \ln(P_t/P_{t-k})$.
- **Non-aditive pe active**: $r_P \neq \sum_i w_i r_i$ în general.
- **Simetrice**: câștig de $+x$ și pierdere de $-x$ tratate simetric.
- **Nemărginite**: $r_t \in (-\infty, +\infty)$, compatibil cu distribuția normală.
- Exemplu: $P_0 = 100$, $P_1 = 110 \Rightarrow r_1 = \ln(1.10) = 9.531\%$.

Observație 2

Randamentele logaritmice sunt preferate pentru analiza **seriilor de timp** (staționaritate, agregare).

Randamente simple vs. logaritmice: Expansiunea Taylor

Propoziție 1

Pentru randamente mici: $r_t = \ln(1 + R_t) = R_t - \frac{R_t^2}{2} + \frac{R_t^3}{3} - \cdots$

La ordinul doi: $r_t \approx R_t - \frac{R_t^2}{2}$, deci $r_t < R_t$ pentru orice $R_t \neq 0$.

Demonstrație. Deoarece ln este strict concavă, $\ln(1 + x) < x$ pentru orice $x > -1$, $x \neq 0$ (inegalitatea lui Jensen aplicată identității $\ln(1 + x) \leq x$ cu egalitate iff $x = 0$). Substituind $x = R_t$ obținem $r_t = \ln(1 + R_t) < R_t$. □

- Pentru randamente zilnice ($|R_t| \approx 1\%$), aproximarea $r_t \approx R_t$ este excelentă.
- Diferența $R_t - r_t \approx R_t^2/2$ crește cu volatilitatea și pe orizonturi mai lungi.
- Aceasta este sursa **pierderii din variantă** în performanța pe termen lung.

Pierderea din variantă (Inegalitatea lui Jensen)

$\mathbb{E}[r_t] = \mathbb{E}[\ln(1 + R_t)] < \ln(1 + \mathbb{E}[R_t])$. Practic: $\mathbb{E}[r_t] \approx \mathbb{E}[R_t] - \frac{1}{2}\mathrm{Var}(R_t)$.

Randamente simple vs. logaritmice: Comparație vizuală

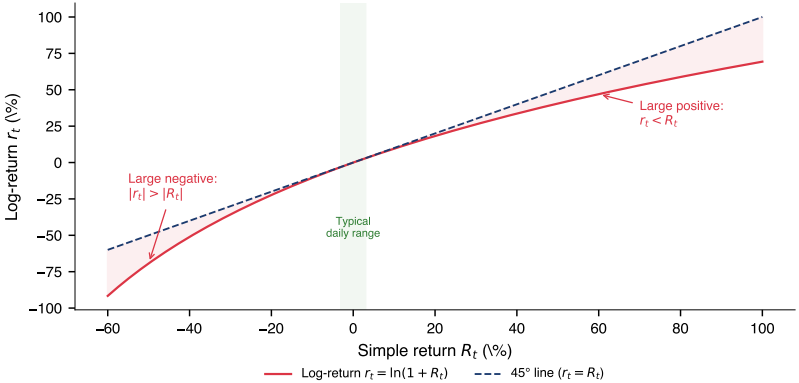

- Pentru randamente zilnice tipice ($\pm 3\%$), simple $\approx$ log; pentru mișcări mari, divergența e semnificativă.
- Randamentul log este mereu **mai mic** decât cel simplu: $r_t < R_t$ pentru $R_t > 0$.

SFM_ch1_stationarity

Exemplu numeric: Randamente simple vs. logaritmice

Example 2

$P_0 = \$100$: crește $+10\%$ apoi scade -10% (randamente simple).

Randamente simple:

- $P_1 = 100 \times 1.10 = \$110$
- $P_2 = 110 \times 0.90 = \$99$
- Net: -1%. Suma $+10\% - 10\% = 0$ este *înșelătoare*!

Randamente logaritmice:

- $r_1 = \ln(1.10) = +9.531\%$
- $r_2 = \ln(0.90) = -10.536\%$
- Sumă: $-1.005\% = \ln(99/100)$ ✓

	Per. 1	Per. 2	**Total**
R_t	$+10.00\%$	-10.00%	-1.00%
r_t	$+9.53\%$	-10.54%	-1.01%

- Randamentele logaritmice se *însumează* corect.
- Randamentele simple trebuie compuse: $(1.10)(0.90) - 1 = -1\%$.

De ce contează diferența

- Diferența dintre $\mathbb{E}[R]$ și $\mathbb{E}[r]$ este **pierderea din varianță**:

$$\mathbb{E}[r] \approx \mathbb{E}[R] - \frac{\sigma^2}{2}.$$

- Crește cu volatilitatea și orizontul de timp; semnificativă pentru activele cu volatilitate mare.

Asset	$\mathbb{E}[R]$/day	σ/day	$\mathbb{E}[r]$/day	Pierdere anuală
S&P 500	0.040%	1.0%	0.035%	$\approx$ 1.3%
AAPL	0.060%	1.8%	0.044%	$\approx$ 4.1%
Bitcoin	0.200%	4.0%	0.120%	$\approx$ 29%

- BTC: variance drag $= 4^2/(2 \times 100) = 0.08\%$/zi; pe 365 zile $\approx 29\%$ pe an.
- **Convenții zile de tranzacționare**: acțiunile folosesc 252 zile/an (NYSE), crypto folosește 365 zile calendaristice. Specificați mereu convenția folosită la anualizare.
- Pentru proiecții de avuție pe termen lung, folosiți mereu randamente geometrice (log).

Pierderea din varianță: Vizualizare

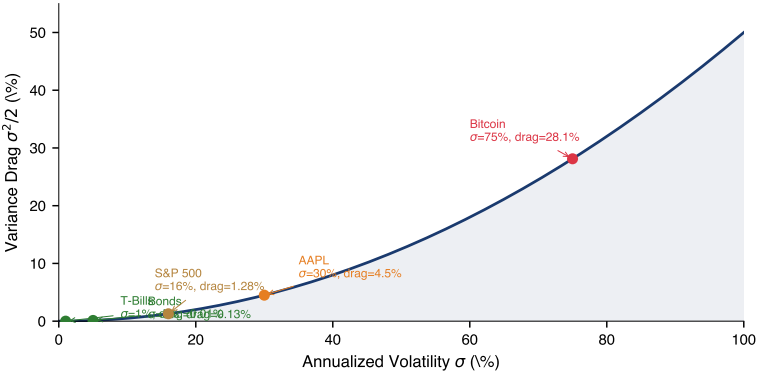

- Curba drag $\sigma^2/2$ este **cvadratică**: dublarea volatilității cvaduplează pierderea.
- Pentru S&P 500 ($\sigma \approx 16\%$): drag $\approx 1.3\%$/an — moderat.
- Pentru Bitcoin ($\sigma \approx 75\%$): drag $\approx 28\%$/an — domină randamentele așteptate.

Randamente multi-perioadă și procesul de avuție

Definiție 4 (Procesul de avuție)

Investind W_0 la momentul 0, avuția după T perioade:

$$W_T = W_0 \prod_{t=1}^{T}(1 + R_t) = W_0 \exp\left(\sum_{t=1}^{T} r_t\right).$$

- **Log-wealth** este o sumă: $\ln W_T = \ln W_0 + \sum_{t=1}^{T} r_t$.
- Prin TLC, $\ln W_T$ este aproximativ normal pentru T mare (dacă r_t sunt i.i.d.).
- Prin urmare W_T este aproximativ **log-normal**.
- Randamentul logaritmic pe k perioade: $r_t(k) = \sum_{j=0}^{k-1} r_{t-j}$ (sumă, simplu).
- Randamentul simplu pe k perioade: $R_t(k) = \prod_{j=0}^{k-1}(1 + R_{t-j}) - 1$ (produs, mai dificil).

Implicație practică

Pentru backtesting: sumați randamentele logaritmice, apoi convertiți la avuția finală prin $W_T = W_0 \cdot e^{\mathrm{CLR}_T}$.

Randamente cumulate

Definiție 5 (Randamente cumulate)

CSR (Randament simplu cumulat) de la 0 la T:

$$\mathrm{CSR}_T = \prod_{t=1}^{T}(1 + R_t) - 1.$$

CLR (Randament logaritmic cumulat) de la 0 la T:

$$\mathrm{CLR}_T = \sum_{t=1}^{T} r_t = \ln \frac{P_T}{P_0}.$$

Relație: $\mathrm{CSR}_T = e^{\mathrm{CLR}_T} - 1$.

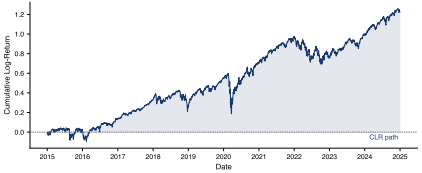

- CLR: sumă simplă, ușor de calculat.
- CSR: necesită compunere (înmulțire).

Randamente anualizate

- Pentru a compara strategiile pe diferite orizonturi, randamentele sunt **anualizate**.
- **Anualizare geometrică** (preferată; ține cont de compunere):

$$\bar{R}^{\text{geo}}_{\text{annual}} = \left(\prod_{t=1}^{T}(1+R_t)\right)^{252/T} - 1 = e^{\frac{252}{T}\cdot \text{CLR}_T} - 1.$$

- **Anualizare aritmetică** (aproximare simplă):

$$\bar{R}^{\text{arith}}_{\text{annual}} = \frac{252}{T}\sum_{t=1}^{T} r_t.$$

Orizont	**Factor geo.**	**Example: 0.05%/day mean**
Daily $\to$ Annual (252 days)	$(1+\bar{R})^{252} - 1$	$(1.0005)^{252} - 1 = 13.3\%$
Monthly $\to$ Annual (12 months)	$(1+\bar{R})^{12} - 1$	$(1.0105)^{12} - 1 = 13.4\%$
Quarterly $\to$ Annual (4 quarters)	$(1+\bar{R})^{4} - 1$	$(1.0327)^{4} - 1 = 13.8\%$

- Arithmetic $>$ Geometric by approximately $\sigma^2/2$ per perioadă (din nou pierderea din varianță).

Momentele randamentelor

- **Mean** (primul moment) — randamentul așteptat:

$$\mu = \mathbb{E}[r_t], \qquad \hat{\mu} = \frac{1}{n}\sum_{t=1}^{n} r_t.$$

- **Variance** (al doilea moment central) — risc total:

$$\sigma^2 = \mathrm{Var}(r_t) = \mathbb{E}[(r_t - \mu)^2], \qquad \hat{\sigma}^2 = \frac{1}{n-1}\sum_{t=1}^{n}(r_t - \hat{\mu})^2.$$

- **Skewness** (al treilea moment standardizat) — asimetrie:

$$S = \frac{\mathbb{E}[(r_t - \mu)^3]}{\sigma^3}. \quad S < 0 \Rightarrow \text{coadă stângă mai grea (mai multe pierderi mari).}$$

- **Kurtosis** (al patrulea moment standardizat) — greutatea cozilor:

$$K = \frac{\mathbb{E}[(r_t - \mu)^4]}{\sigma^4}. \quad K > 3 \Rightarrow \text{leptokurtic (mai groase decât Normala).}$$

- **Excess kurtosis**: $\kappa = K - 3$; Normal $\Rightarrow \kappa = 0$.

Asimetrie și kurtosis: Interpretare

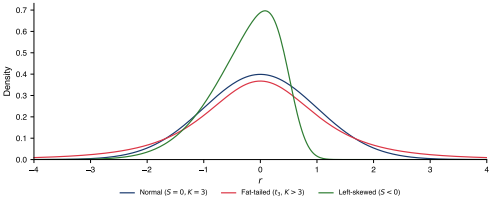

- **Normal**: $S = 0$, $K = 3$.
- **Left-skewed** ($S < 0$): câștiguri mici frecvente, pierderi mari rare; tipic pentru *indici bursieri*.
- **Fat-tailed** ($K > 3$): evenimente extreme mult mai probabile decât Normala; universal în datele financiare.
- **Right-skewed** ($S > 0$): câștiguri mari ocazionale; tipic pentru opțiuni call OTM.
- **Jarque-Bera test**: $JB = \frac{n}{6}(S^2 + \frac{\kappa^2}{4}) \sim \chi^2_2$.

SFM_ch1_returns_analysis

Momente empirice: Exemplu

- Statistici eșantion pentru randamente logaritmice zilnice (aprox. 2015–2024):

Asset	Mean	Std	Skew	Kurt	Min	Max
S&P 500	+0.040%	1.00%	−0.72	12.1	−12.8%	+9.4%
AAPL	+0.058%	1.80%	−0.31	8.6	−13.0%	+11.9%
Bitcoin	+0.195%	3.90%	−0.15	7.4	−46.5%	+22.5%
EUR/USD	+0.000%	0.45%	+0.08	5.2	−2.7%	+3.1%

- Toate activele: kurtosis în exces $\gg 0$ (cozi groase confirmate).
- Acțiuni: asimetrie negativă (riscul de crash domină).
- BTC: volatilitate maximă; asimetrie negativă în ciuda narativului de asimetrie pozitivă.
- EUR/USD: medie aproape zero, aproape simetrică, dar cu cozi groase.

SFM_ch1_returns

Drawdown-uri

Definiție 6 (Drawdown și MDD)

Drawdown la momentul t:
$$DD_t = \frac{P_t - \max_{s \le t} P_s}{\max_{s \le t} P_s} \le 0.$$
MDD: $\text{MDD} = \min_{t \in [0,T]} DD_t$.

- MDD: cel mai mare declin de la maxim la minim din istorie.
- Metric de risc cheie pentru strategiile de urmărire a tendinței.
- S&P 500 MDD: -56.8% (Mar 2007–Mar 2009).
- BTC MDD: -83% (Dec 2017–Dec 2018).
- Calmar ratio: $\bar{R}_{\text{annual}}/|\text{MDD}|$.

SFM_ch1_returns_analysis

Cuprins

1. Motivație ✓
2. Date de preț ✓
3. Randamente ✓
4. **Fapte stilizate ale randamentelor financiare**
5. Estimatori de volatilitate
6. Comparație de eficiență
7. Randamente ajustate la risc
8. Caz AI / Rezumat / Quiz
9. Bibliografie

Ipoteza pieței eficiente (EMH)

Definiție 7 (Ipoteza pieței eficiente (Fama, 1970))

O piață este **eficientă informațional** dacă prețurile *reflectă complet* toată informația disponibilă. Trei forme:

1. **Forma slabă**: prețurile reflectă toate *datele istorice de preț și volum*.
   $\Rightarrow$ Analiza tehnică nu poate genera randamente excesive; $\mathrm{Corr}(r_t, r_{t-k}) = 0$.
2. **Forma semi-puternică**: prețurile reflectă toată *informația publică disponibilă*.
   $\Rightarrow$ Analiza fundamentală nu poate genera randamente excesive; studiile de evenimente arată ajustare rapidă.
3. **Forma puternică**: prețurile reflectă *toată* informația (inclusiv privată/insider).
   $\Rightarrow$ Nici insiderii nu pot genera randamente excesive (încălcată empiric).

⊡ Faptele stilizate de mai jos arată **unde EMH eșuează**: absența autocorelației liniare susține eficiența slabă, dar gruparea volatilității și efectul de levier sugerează momente de ordin doi predictibile.

Fapte stilizate ale randamentelor financiare

- Cont (2001) și Mandelbrot (1963) au identificat **regularități statistice universale** observate pe diferite piețe, instrumente și perioade de timp.

1. **Absența autocorrelației liniare**: $\mathrm{Corr}(r_t, r_{t-k}) \approx 0$ pentru $k \geq 1$.
2. **Cozi groase**: kurtosis în exces $K > 3$ în distribuțiile randamentelor.
3. **Asimetrie**: asimetrie negativă pentru randamentele acțiunilor.
4. **Gruparea volatilității**: valorile mari ale $|r_t|$ tind să fie urmate de valori mari ale $|r_{t+1}|$.
5. **Efectul de levier**: randamentele negative cresc volatilitatea viitoare mai mult decât randamentele pozitive de aceeași magnitudine (Black, 1976).
6. **Gaussianitate agregațională**: randamentele se apropie de normalitate pe măsură ce scala temporală crește.
7. **Corelația volum-volatilitate**: volumul de tranzacționare și volatilitatea sunt corelate pozitiv.

Cozi groase și non-normalitate

- Sub $\mathcal{N}(\mu, \sigma^2)$, un eveniment de 5σ are probabilitatea $\approx 2.87 \times 10^{-7}$.
- **Black Monday** (Oct 19, 1987): S&P 500 a scăzut cu -22.6% într-o singură zi.
  - Cu $\sigma_{\text{daily}} \approx 1\%$, aceasta este o mișcare de $> 20\sigma$ deviații standard.
  - Probabilitate sub normalitate: $\approx 10^{-89}$ — practic imposibil.

Magnitudinea evenimentului	**Probabilitate Normală**	**Frecvență observată**
$> 3\sigma$ move	0.27% (1 in 370 days)	~1 in 50–100 days
$> 4\sigma$ move	0.0063% (1 in 16,000 days)	~1 in 500–1000 days
$> 5\sigma$ move	1 in 3.5 million days	~1 in 5000–10,000 days

Concluzie

Randamentele financiare sunt **leptokurtice**: modelul Normal subestimează dramatic riscul de coadă. Distribuțiile Student-t, Pareto-stabile sau NIG oferă o potrivire mult mai bună.

Cozi groase: Ilustrație QQ-Plot

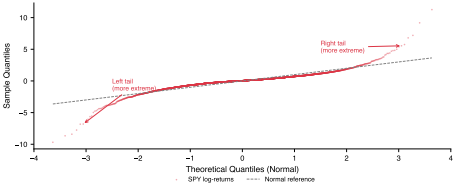

- A QQ-plot: cuantile eșantion vs. cuantile Normale.
- Dacă Normală: punctele pe linia de 45° grade exact.
- **Formă de S**: coada stângă sub linie (pierderi mai extreme), coada dreaptă deasupra (câștiguri mai extreme).
- **Cozi groase**: ambele capete deviază în sus/jos față de linie.
- Testul Jarque-Bera: $JB = \frac{n}{6}(S^2 + \frac{\kappa^2}{4}) \sim \chi^2_2$ sub H_0.
- Testele Kolmogorov-Smirnov și Anderson-Darling sunt de asemenea folosite.

SFM_ch1_stylized_facts

Gruparea volatilității

- Mandelbrot (1963): "*Schimbările mari tind să fie urmate de schimbări mari — de orice semn — iar schimbările mici tind să fie urmate de schimbări mici.*"
- Formal: $\mathrm{Corr}(r_t, r_{t-k}) \approx 0$ dar $\mathrm{Corr}(|r_t|, |r_{t-k}|) > 0$ pentru $k = 1, 2, \ldots$

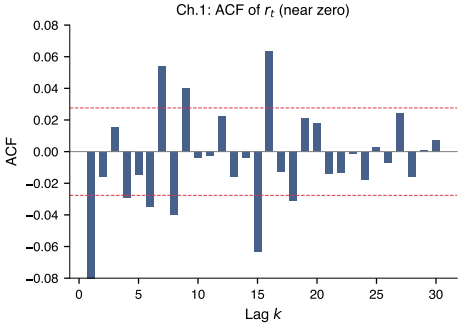

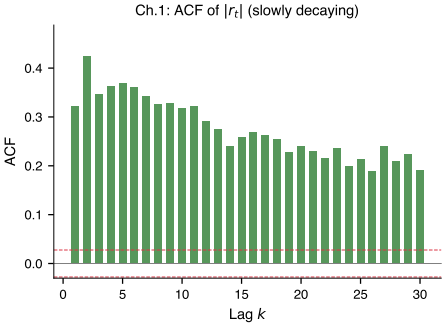

- ACF of $|r_t|$: descreștere lentă (memorie lungă) $\Rightarrow$ motivează modelele ARCH/GARCH (Engle 1982, Bollerslev 1986).

Efectul de levier

- Black (1976): un randament *negativ* crește volatilitatea viitoare *mai mult* decât unul pozitiv de aceeași magnitudine.
- **Explicație levier**: când prețul scade, datoria/capitalul propriu crește ⇒ capitalul devine mai riscant.
- Formal: $\mathrm{Corr}(r_t, \sigma^2_{t+1}) < 0$.

GJR-GARCH(1,1)

$$\sigma_t^2 = \omega + (\alpha + \gamma\, 1_{r_{t-1}<0})\, r_{t-1}^2 + \beta\, \sigma_{t-1}^2$$

- $\gamma > 0$: șocuri negative → pondere $\alpha+\gamma$; pozitive → doar α.
- EGARCH (Nelson, 1991): $\sigma_t^2 > 0$ prin spec. logaritmică.

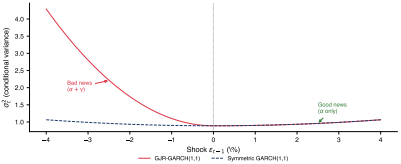

SFM_ch1_leverage_effect

Gaussianitate agregațională

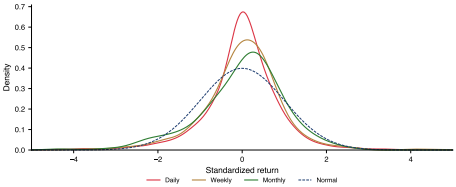

- **Daily**: cozi foarte groase, kurtosis în exces $\approx$ 5–20.
- **Weekly**: kurtosis redus, mai puține valori aberante extreme.
- **Monthly**: aproximativ normală prin TLC.
- CLT: $r_t^{(k)} = \sum_{j=0}^{k-1} r_{t-j} \to \mathcal{N}$ as $k \to \infty$ sub condiții slabe.
- **Caveat**: convergența este *lentă* pentru distribuțiile Pareto-stabile; distribuțiile cu varianță infinită nu converg niciodată la Normal.

SFM_ch1_stylized_facts

Corelația volum-volatilitate

- **Fapt empiric**: volumul V_t și $|r_t|$ sunt corelate pozitiv.
- **MDH** (Clark 1973; Tauchen & Pitts 1983): ambele determinate de fluxul informațional latent.
- **Sosire secvențială** (Copeland 1976): traderii învață secvențial.
- Modelele GARCH augmentate cu volum depășesc GARCH standard.

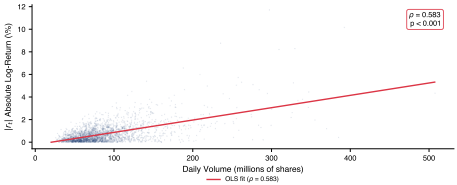

SFM_ch1_volume_volatility

Cuprins

1. Motivație ✓
2. Date de preț ✓
3. Randamente ✓
4. Fapte stilizate ale randamentelor financiare ✓
5. **Estimatori de volatilitate**
6. Comparație de eficiență
7. Randamente ajustate la risc
8. Caz AI / Rezumat / Quiz
9. Bibliografie

Volatilitatea: Conceptul central

Definiție 8 (Volatilitate)

Volatilitatea este gradul de variație al unei serii de prețuri de tranzacționare în timp, măsurată prin abaterea standard (sau varianța) randamentelor. Este o **variabilă latentă**: neobservabilă direct, doar estimabilă.

Estimator	Date utilizate	RE vs CC	Referință cheie
Close-to-Close (CC)	doar C_t	1.0	Statistică clasică
Parkinson (P)	H_t, L_t	5.2	Parkinson (1980)
Garman-Klass (GK)	O_t, H_t, L_t, C_t	7.4	Garman & Klass (1980)
Rogers-Satchell (RS)	O_t, H_t, L_t, C_t	8.0	Rogers & Satchell (1991)
Yang-Zhang (YZ)	O_t, H_t, L_t, C_t	14.0	Yang & Zhang (2000)
Realized Vol (RV)	Tick-uri intra-zilnice	$\gg$14	Andersen & Bollerslev (1998)

Volatilitate istorică (Estimatorul Close-to-Close)

Definiție 9 (Volatilitate istorică)

Estimatorul standard bazat pe n randamente logaritmice:

$$\hat{\sigma}_{\text{CC}} = \sqrt{\frac{1}{n-1}\sum_{t=1}^{n}(r_t - \bar{r})^2}, \qquad \bar{r} = \frac{1}{n}\sum_{t=1}^{n} r_t.$$

- Aceasta este pur și simplu abaterea standard eșantion a randamentelor logaritmice.
- **Anualizare**: $\hat{\sigma}_{\text{annual}} = \hat{\sigma}_{\text{daily}} \times \sqrt{252}$.
- **Avantaje**: simplu, intuitiv, necesită doar prețuri de închidere.
- **Limitări**: ignoră informațiile intra-zilnice (O, H, L); ponderează egal toate observațiile; sensibil la lungimea ferestrei n; întârzie schimbările de regim.

SFM_ch1_volatility_estimators

Volatilitate istorică: Estimare rulantă

- O **fereastră glisantă** de n zile oferă o estimare a volatilității variabilă în timp.
- Alegeri uzuale: $n = 20$ zile (termen scurt), $n = 60$ zile (termen mediu).

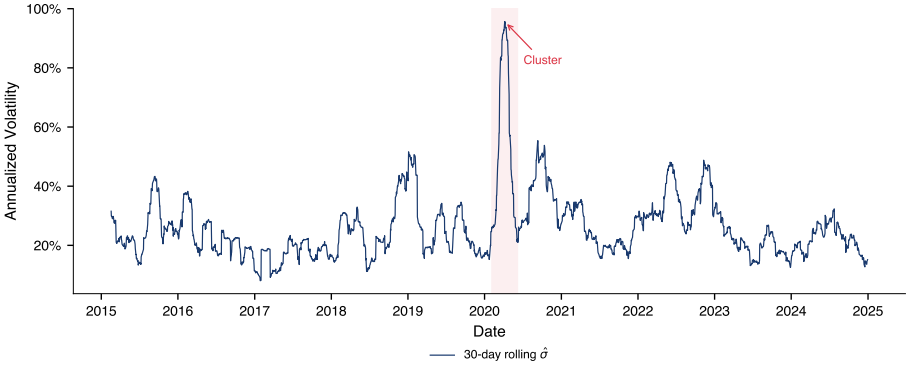

- Clusterele de volatilitate sunt clar vizibile în estimările rulante.
- Lungimea ferestrei: scurtă $\rightarrow$ zgomotoasă; lungă $\rightarrow$ depășită.

Regula rădăcinii pătrate a timpului

Teoremă 1 (Square Root of Time Rule)

Dacă randamentele logaritmice $r_1, r_2, \ldots$ sunt i.i.d. cu $\mathrm{Var}(r_t) = \sigma_1^2$, atunci abaterea standard pe T perioade satisface

$$\sigma_T = \sigma_1 \sqrt{T}.$$

Demonstrație. Fie $R_T = \sum_{t=1}^{T} r_t$. Deoarece r_t sunt i.i.d.: $\mathrm{Var}(R_T) = \sum_{t=1}^{T} \mathrm{Var}(r_t) = T\sigma_1^2$, deci $\mathrm{SD}(R_T) = \sigma_1\sqrt{T}$. □

- **Exemple de scalare**: $\sigma_{\text{annual}} = \sigma_{\text{daily}} \times \sqrt{252}$; $\sigma_{\text{monthly}} = \sigma_{\text{daily}} \times \sqrt{22}$; $\sigma_{\text{weekly}} = \sigma_{\text{daily}} \times \sqrt{5}$.

Când eșuează regula?

Regula presupune randamente i.i.d. Aceasta eșuează când:

- Randamentele sunt **autocorelate** (AC pozitivă $\Rightarrow$ vol reală $>$ estimarea regulii)
- Volatilitatea este **variabilă în timp** (efecte GARCH)
- Randamentele au **varianță infinită** (stable Paretian)

Rădăcina pătrată a timpului: Exemplu numeric

Example 3

Volatilitatea zilnică $\hat{\sigma}_{\text{daily}} = 1.2\%$.

Orizont	$\sqrt{T}$	Vol
1 zi	1.0	1.2%
1 săpt.	2.2	2.7%
1 lună	4.7	5.6%
1 trim.	7.9	9.5%
1 an	15.9	19.1%

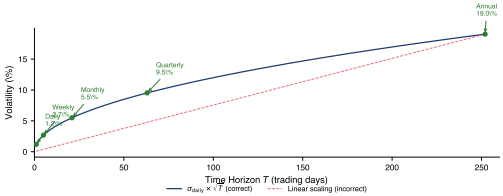

- Cu autocorelație AR(1) $\rho > 0$: $\sigma_T^2 = T\sigma_1^2\left[1 + 2\sum_{k=1}^{T-1}(1 - k/T)\rho^k\right] > T\sigma_1^2$.

SFM_ch1_vol_comparison

Estimatorul Parkinson (1980)

Definiție 10 (Estimatorul Parkinson)

Utilizând doar prețurile maxim și minim:

$$\hat{\sigma}_{\mathrm{P}}^2 = \frac{1}{4n\ln 2}\sum_{t=1}^{n}\left(\ln\frac{H_t}{L_t}\right)^2.$$

Derivation sketch. Sub Geometric Brownian Motion (GBM), adică $dS = \mu S\,dt + \sigma S\,dW$, cu $\mu = 0$, intervalul unui pod Brownian pe $[0,1]$ satisface $\mathbb{E}[(\ln H/L)^2] = 4\sigma^2\ln 2$, obținând $1/(4\ln 2) \approx 0.361$.

Avantaje

- 5,2× mai eficient decât CC
- Utilizează informația de range intraday
- Formulă simplă, ușor de calculat

Limitări

- Presupune GBM cu drift zero
- Presupune tranzacționare continuă (fără salturi)
- Biasată în jos dacă H/L reale nu sunt observate

Estimatorul Garman-Klass (1980)

Definiție 11 (Estimatorul Garman-Klass)

Utilizând toate cele patru prețuri OHLC (GBM cu drift zero):

$$\hat{\sigma}^2_{\mathrm{GK}} = \frac{1}{n}\sum_{t=1}^{n}\left[0.5\left(\ln\frac{H_t}{L_t}\right)^2 - (2\ln 2 - 1)\left(\ln\frac{C_t}{O_t}\right)^2\right].$$

- **Derivație**: descompune varianța totală în componentele range + close-to-open; minimizează varianța.
- **Eficiență**: $\approx 7.4\times$ mai eficient decât CC.
- **Limitare**: presupune $\mu = 0$; biasată pe piețe în trend.

Avantaje

- Cea mai bună eficiență cu drift zero
- Utilizează informația de range și O-to-C

Limitări

- Biasată pe piețe cu trend
- Gap-urile overnight introduc bias

Estimatorul Rogers-Satchell (1991)

Definiție 12 (Estimatorul Rogers-Satchell)

Estimatorul RS **permite drift nenul**:

$$\hat{\sigma}^2_{\text{RS}} = \frac{1}{n}\sum_{t=1}^{n}\left[\ln\frac{H_t}{C_t}\cdot\ln\frac{H_t}{O_t} + \ln\frac{L_t}{C_t}\cdot\ln\frac{L_t}{O_t}\right].$$

Proprietăți cheie

- **Independent de drift**: nebiasată cu $\mu \neq 0$
- Performanță bună pe piețe cu trend
- $\approx 8\times$ mai eficient decât CC

Aplicații

- Piețe emergente (Öztürk et al., 2016)
- Criptomonede (Cadenas-Morales, 2022)
- **Presupune**: tranzacționare continuă, fără salturi

Estimatorul Yang-Zhang (2000)

Definiție 13 (Estimatorul Yang-Zhang)

Combină componentele overnight, deschidere-la-închidere și Rogers-Satchell:

$$\hat{\sigma}_{\mathrm{YZ}} = \sqrt{\hat{\sigma}_O^2 + k\,\hat{\sigma}_C^2 + (1-k)\,\hat{\sigma}_{\mathrm{RS}}^2}\,,$$

unde $\alpha = 1.34$ este constanta optimală (Yang & Zhang, 2000) și
$k = (\alpha - 1)/\big(\alpha + (T+1)/(T-1)\big) \approx 0.34$ pentru T tipic.

- $\hat{\sigma}_O^2$: **overnight variance** $= \frac{1}{T-1}\sum_{t=1}^{T}\left(\ln\frac{O_t}{C_{t-1}} - \overline{\ln\frac{O_t}{C_{t-1}}}\right)^2$.
- $\hat{\sigma}_C^2$: **open-to-close variance** $= \frac{1}{T-1}\sum_{t=1}^{T}\left(\ln\frac{C_t}{O_t} - \overline{\ln\frac{C_t}{O_t}}\right)^2$.
- $\hat{\sigma}_{\mathrm{RS}}^2$: Rogers-Satchell component.
- $14\times$ **mai eficient** decât CC; gestionează drift și salturi overnight.
- Cel mai bun estimator general pentru date OHLC zilnice.

Estimatori de volatilitate: Comparație vizuală (AAPL 2018–2024)

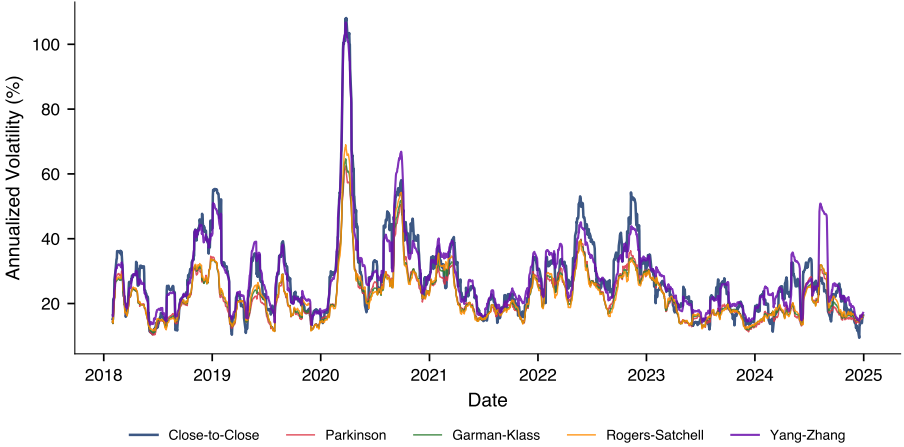

- Estimatorii bazați pe range (P, GK, RS) sunt mai netezi decât CC datorită eficienței mai mari.
- Yang-Zhang urmărește CC, dar cu mai puțin zgomot — combină informația overnight + intraday.
- În perioadele de criză (2020), toate estimatoarele captează vârful, dar cu magnitudini diferite.

Estimatori de volatilitate: Comparație numerică (AAPL 2020–2024)

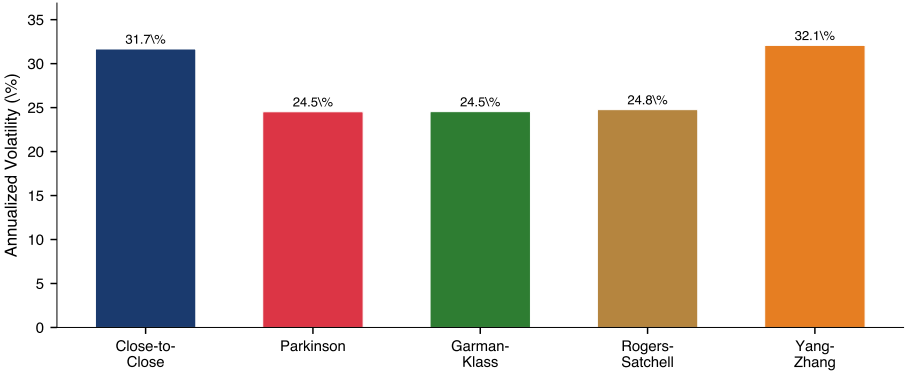

- Estimatorii bazați pe range (P, GK, RS) produc volatilitate anualizată **mai mică** decât CC deoarece extrag mai multă informație per observație.
- Yang-Zhang combină informația overnight și intraday, oferind o estimare completă.
- Diferențele sunt cele mai pronunțate pe piețele volatile cu gap-uri overnight mari.

Volatilitatea EWMA

$$\hat{\sigma}_t^2 = \lambda\, \hat{\sigma}_{t-1}^2 + (1-\lambda)\, r_{t-1}^2, \qquad \lambda = 0.94.$$

- Ponderea la lag-ul k: $(1-\lambda)\lambda^k$ (descreștere exponențială).
- $\lambda = 0.94$: fereastră efectivă $\approx 16{,}7$ zile.
- **Avantaje**: reacționează rapid; fără fereastră fixă; ușor de actualizat.
- **Dezavantaje**: fără revenire la medie; λ stabilit extern.

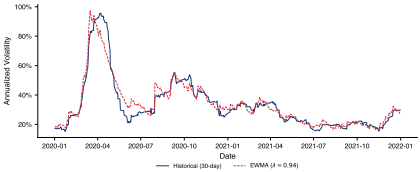

SFM_ch1_volatility_charts

Volatilitatea realizată

Definiție 14 (Volatilitate realizată)

Date fiind m randamente logaritmice intrazilnice la frecvența $\Delta = 1/m$:

$$\mathrm{RV}_t = \sum_{j=1}^{m} r_{t,j}^2, \qquad r_{t,j} = \ln P_{t,j} - \ln P_{t,j-1}.$$

- **Consistență**: $\mathrm{RV}_t \xrightarrow{p} \int_0^1 \sigma_t^2(s)\, ds$ când $m \to \infty$ (Andersen & Bollerslev, 1998).
- În practică: eșantionare la fiecare 5 minute ($m \approx 78$ pentru acțiuni SUA).
- **Abaterea standard realizată**: $\mathrm{RSD}_t = \sqrt{\mathrm{RV}_t}$.
- **Zgomot de microstructură**: saltul bid-ask contaminează estimările la frecvențe foarte înalte.

Graficul semnăturii volatilității

Trasați RV vs. frecvența de eșantionare Δ. La frecvențe foarte înalte, RV diverge din cauza zgomotului de microstructură. Frecvența optimă echilibrează precizia și biasul de zgomot.

Graficul semnăturii volatilității

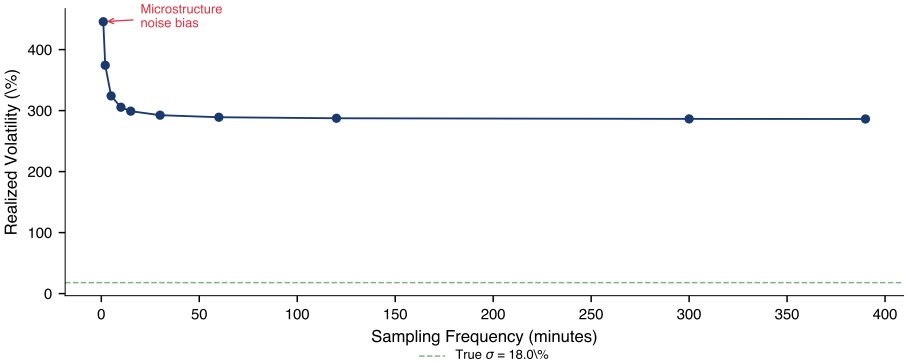

- La frecvențe înalte ($\Delta < 5$ min), bid-ask bounce umflă RV.
- La frecvențe joase, RV este nebiasată dar imprecisă (puține observații).
- Eșantionare optimală: ≈ 5 minute echilibrează biasul și varianța (Bandi & Russell, 2008).

SFM_ch1_vol_comparison

Estimatori de volatilitate: Graficul comparației de eficiență

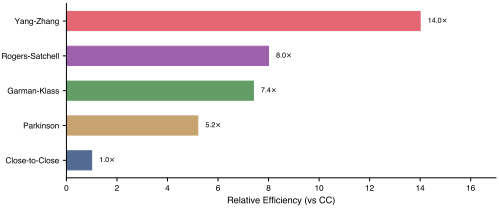

- **RE** (Eficiență relativă) $= \mathrm{Var}(\hat{\sigma}^2_{\mathrm{CC}})/\mathrm{Var}(\hat{\sigma}^2)$.
- RE > 1: variantă mai mică decât benchmark-ul CC.
- Utilizarea OHLC vs. doar C: până la $14\times$ mai multă informație.
- YZ este cel mai bun estimator utilizând doar date OHLC zilnice.
- Intrazilic (RV): eficiență teoretic nelimitată când $\Delta \to 0$ (dacă microstructura permite).

SFM_ch1_volatility_charts

Volatilitate condițională vs. necondițională

Volatilitate necondițională

- Volatilitatea medie pe termen lung:

$$\sigma^2 = \mathrm{Var}(r_t).$$

- Estimată prin estimatorul CC istoric pe o fereastră lungă.
- Constantă în timp: presupune staționaritate.
- Utilă pentru: evaluarea opțiunilor (termen lung), capital regulatoriu (Basel).

Volatilitate condițională

- Variabilă în timp, dată informația până la $t-1$:

$$\sigma_t^2 = \mathrm{Var}(r_t \mid \mathcal{F}_{t-1}).$$

- Modelată prin ARCH/GARCH, volatilitate stochastică.
- Captează gruparea volatilității.
- Utilă pentru: riscul pe termen scurt, hedging opțiuni (delta), VaR.

- **GARCH(1,1)** (Bollerslev 1986): $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta\sigma_{t-1}^2$. Varianța pe termen lung (necondițională): $\bar{\sigma}^2 = \omega/(1-\alpha-\beta)$.
- Capitolul 5 acoperă modelele GARCH în detaliu.

Volatilitate condițională vs. necondițională: Exemplu AAPL

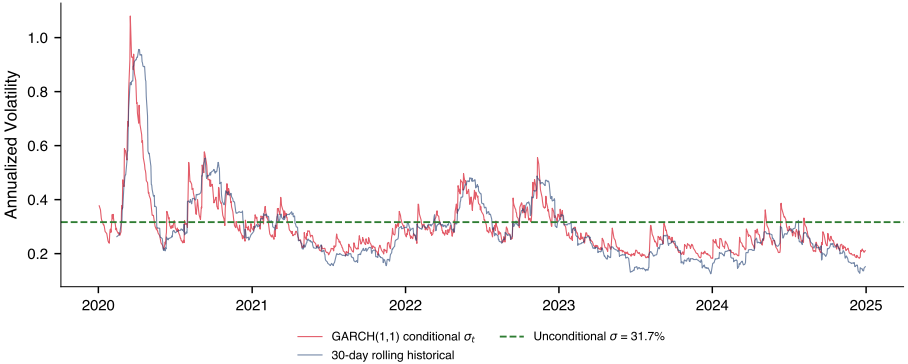

- Volatilitatea condițională **GARCH(1,1)** urmărește clustering-ul volatilității în timp real.
- Estimarea rolling pe 30 de zile este mai netedă dar rămâne în urmă față de schimbările bruște.
- Nivelul necondițional reprezintă media pe termen lung în jurul căreia σ_t fluctuează.

SFM_ch1_vol_comparison

Cuprins

1. Motivație ✓
2. Date de preț ✓
3. Randamente ✓
4. Fapte stilizate ale randamentelor financiare ✓
5. Estimatori de volatilitate ✓
6. **Comparație de eficiență**
7. Randamente ajustate la risc
8. Caz AI / Rezumat / Quiz
9. Bibliografie

Eficiența estimatorilor de volatilitate

- **Eficiență relativă**: $\text{RE} = \text{Var}(\hat{\sigma}^2_{\text{CC}})/\text{Var}(\hat{\sigma}^2)$. $\text{RE} > 1$ înseamnă varianță mai mică decât CC.

Estimator	RE vs CC	Drift-free?	Jump-robust?	Data
Close-to-Close	1.0	Nu	Nu	C
Parkinson	5.2	Da ($\mu = 0$)	Nu	H, L
Garman-Klass	7.4	Da ($\mu = 0$)	Nu	O, H, L, C
Rogers-Satchell	8.0	Permite drift	Nu	O, H, L, C
Yang-Zhang	14.0	Permite drift	Parțial	O, H, L, C
Realized Vol	$\gg$14	Da	Extensii	Intraday

- Toți estimatorii bazați pe interval presupun **tranzacționare continuă** și **fără salturi de preț**.
- În practică, sunt disponibile extensii robuste la salturi (bipower variation, Christensen & Podolskij 2007).
- Gap-urile overnight încalcă ipoteza de tranzacționare continuă pentru GK, Parkinson.

Considerații practice

Când folosim care?

- **CC**: doar prețuri de închidere disponibile.
- **Parkinson**: estimare rapidă de interval; piețe fără drift.
- **GK**: cea mai bună eficiență când drift ≈ 0.
- **RS**: piețe în trend, drift semnificativ.
- **YZ**: cel mai bun estimator general pentru OHLC zilnic.
- **RV**: date intra-zilnice; standardul de aur.

Capcane frecvente

- GK/Parkinson pe date în trend $\Rightarrow$ biased în jos.
- Ignorarea gap-urilor overnight $\Rightarrow$ subestimează vol totală.
- Fereastră prea scurtă $\Rightarrow$ zgomotoasă; prea lungă $\Rightarrow$ depășită.
- Prețuri neajustate $\Rightarrow$ salturi false la datele dividendelor.

Regulă practică

20–30z: termen scurt; 60–90z: termen mediu; 252z: anual.

Cuprins

1. Motivație ✓
2. Date de preț ✓
3. Randamente ✓
4. Fapte stilizate ale randamentelor financiare ✓
5. Estimatori de volatilitate ✓
6. Comparație de eficiență ✓
7. **Randamente ajustate la risc**
8. Caz AI / Rezumat / Quiz
9. Bibliografie

Indicatorul Sharpe

Definiție 15 (Indicatorul Sharpe)

Randament excesiv pe unitate de risc total:

$$SR = \frac{\bar{R}_p - R_f}{\sigma_p}.$$

- S&P 500: $SR \approx 0.4$–0.5 (anual).
- SR mai mare $\not\Rightarrow$ performanță viitoare superioară.
- Presupune normalitate; eșuează pentru randamente asimetrice.

Valoare SR	Interpretare
$SR < 0$	Sub rata fără risc
$0 \leq SR < 1$	Acceptabil
$1 \leq SR < 2$	Bun
$SR \geq 2$	Excelent (rar)

SFM_ch1_sharpe_ratio

Indicatorul Sharpe: Exemplu numeric

Example 4

Două fonduri, $R_f = 2\%$ pe an. Care oferă un randament ajustat la risc mai bun?

Fund	$\bar{R}_p$	σ_p	$\bar{R}_p - R_f$	SR
Fund A	12%	18%	10%	$10/18 = 0.556$
Fund B	8%	9%	6%	$6/9 = 0.667$

- Fondul B: randament absolut mai mic dar indicator Sharpe mai mare.
- Investitorul avers la risc preferă Fondul B (recompensă mai bună per unitate de risc).
- Fondul A necesită $18 \times 0.667 + 2 = 14\%$ randament pentru a egala SR-ul Fondului B.

Anualizarea SR

Din date zilnice: $SR_{\text{annual}} = SR_{\text{daily}} \times \sqrt{252}$.

Alte măsuri ajustate la risc

- **Sortino Ratio**: utilizează deviația descendentă σ_D sub un prag τ (de obicei R_f sau 0):

$$\text{Sortino} = \frac{\bar{R}_p - \tau}{\sigma_D}, \qquad \sigma_D = \sqrt{\frac{1}{n}\sum_{t=1}^{n}\big[\min(R_t - \tau,\ 0)\big]^2}.$$

  Preferat când distribuția randamentelor este asimetrică (opțiuni long, fonduri speculative).
- **Raportul informațional** (IR): randament activ vs. eroare de urmărire față de benchmark B:

$$\text{IR} = \frac{\bar{R}_p - \bar{R}_B}{\text{TE}}, \qquad \text{TE} = \text{std}(R_p - R_B).$$

- **Calmar Ratio**: randament raportat la drawdown-ul maxim:

$$\text{Calmar} = \frac{\bar{R}_{\text{annual}}}{|\text{MDD}|}.$$

- **Treynor Ratio**: randament excesiv pe unitate de risc *sistematic*:

$$\text{Treynor} = \frac{\bar{R}_p - R_f}{\beta_p}, \qquad \beta_p = \text{Cov}(R_p, R_m)/\text{Var}(R_m).$$

Volatilitatea portofoliului

- Pentru un portofoliu cu două active cu ponderile $w_X + w_Y = 1$:

$$\sigma_P^2 = w_X^2\sigma_X^2 + w_Y^2\sigma_Y^2 + 2w_X w_Y\, \rho_{XY}\, \sigma_X\sigma_Y.$$

- **Beneficiul diversificării**: când $\rho_{XY} < 1$, varianța portofoliului $<$ varianța medie ponderată.
- Beneficiu maxim când $\rho_{XY} = -1$ (corelație negativă perfectă).

Example 5

$w_X = 0.6$, $w_Y = 0.4$; $\sigma_X = 20\%$, $\sigma_Y = 30\%$; $\rho = 0.3$.

$$\sigma_P^2 = (0.6)^2(0.20)^2 + (0.4)^2(0.30)^2 + 2(0.6)(0.4)(0.3)(0.20)(0.30)$$

$$= 0.0144 + 0.0144 + 0.00864 = 0.03744. \quad \sigma_P = 19.35\%.$$

Medie ponderată: $0.6 \times 20\% + 0.4 \times 30\% = 24\%$. Diversificarea economisește $\approx 4.65\%$ din volatilitate.

Frontiera eficientă

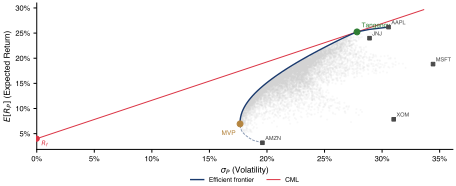

- **Efficient frontier**: mulțimea portofoliilor cu randament așteptat maxim pentru o volatilitate dată (Markowitz 1952).
- **MVP**: portofoliul cu variență minimă — cel mai mic σ_P.
- **Tangency portfolio**: portofoliul de pe frontieră cu cel mai mare indicator Sharpe.
- **Capital Market Line** (CML): combinații de R_f și portofoliul tangent.
- Toți investitorii raționali dețin o combinație de R_f și portofoliul tangent (Teorema separației, Tobin 1958).

SFM_ch1_volatility_charts

Portofoliul cu varianță minimă (MVP)

- **Problema de optimizare medie-varianță** (Markowitz, 1952):

$$\min_{\mathbf{w}} \quad \mathbf{w}'\boldsymbol{\Sigma}\mathbf{w} \qquad \text{s.t.} \quad \mathbf{w}'\boldsymbol{\mu} = \mu_{\text{target}}, \quad \mathbf{w}'1 = 1.$$

- **MVP global** (fără constrângere de randament țintă):

$$\mathbf{w}_{\text{MVP}} = \frac{\boldsymbol{\Sigma}^{-1}1}{1'\boldsymbol{\Sigma}^{-1}1}, \qquad \sigma^2_{\text{MVP}} = \frac{1}{1'\boldsymbol{\Sigma}^{-1}1}.$$

- MVP depinde *doar* de matricea de covarianță $\boldsymbol{\Sigma}$, nu de randamentele așteptate $\boldsymbol{\mu}$.
- Acest lucru îl face mai robust în practică, deoarece $\boldsymbol{\mu}$ este notoriu greu de estimat (Merton, 1980).
- Frontiera eficientă este ramura superioară a "glonțului" trasată variind μ_{target} de la μ_{MVP} la $\max(\boldsymbol{\mu})$.

Teorema separației cu două fonduri

Teoremă 2 (Teorema separației cu două fonduri (Tobin, 1958))

Orice portofoliu de pe frontiera eficientă poate fi scris ca o combinație liniară a oricăror două portofolii distincte de pe frontieră.

- **Fără activ fără risc**: investitorii aleg un punct pe frontiera eficientă conform aversiunii la risc. Toate portofoliile eficiente sunt combinații a două "fonduri mutuale."
- **Cu activ fără risc** R_f: mulțimea eficientă devine **Capital Market Line** (CML):

$$E[R_P] = R_f + \frac{E[R_T] - R_f}{\sigma_T}\sigma_P,$$

  unde T este **portofoliul tangent** (Sharpe maxim).
- Toți investitorii dețin *același* portofoliu riscant T, diferind doar prin fracțiunea alocată lui R_f (levier sau de-levier).
- Aceasta este fundamentul teoretic al **investiției în indici**: portofoliul de piață aproximează T.

Cuprins

1. Motivație ✓
2. Date de preț ✓
3. Randamente ✓
4. Fapte stilizate ale randamentelor financiare ✓
5. Estimatori de volatilitate ✓
6. Comparație de eficiență ✓
7. Randamente ajustate la risc ✓
8. **Caz de utilizare AI**
9. Rezumat
10. Quiz
11. Bibliografie

Exercițiu AI: Gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

"Descarcă datele zilnice OHLC pentru AAPL 2020–2024 folosind Python (`yfinance`). Calculează toți cei cinci estimatori de volatilitate (CC, Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang) folosind o fereastră rolling de 30 de zile. Reprezintă-i pe același grafic și calculează estimările anualizate pe întregul eșantion. De asemenea, estimează un model GARCH(1,1) și suprapune volatilitatea condițională. Discută care estimator este cel mai fiabil."

Exercițiu:

1. AI-ul folosește formula corectă pentru fiecare estimator? Verifică cu notele de curs.
2. Sunt clasamentele de eficiență (rapoartele RE) consistente cu teoria?
3. Volatilitatea condițională GARCH urmărește clustering-ul mai bine decât estimările rolling?
4. Întreabă AI-ul: "Ce se întâmplă dacă acțiunea are gap-uri overnight?" Menționează Yang-Zhang?
5. Re-rulează cu date BTC-USD. Se schimbă clasamentul estimatorilor? De ce?

Atenție: AI-ul confundă adesea formula Rogers-Satchell. Verificați mereu cu $\ln(H/C) \cdot \ln(H/O) + \ln(L/C) \cdot \ln(L/O)$.

Cuprins

1. Motivație ✓
2. Date de preț ✓
3. Randamente ✓
4. Fapte stilizate ✓
5. Estimatori de volatilitate ✓
6. Comparație de eficiență ✓
7. Randamente ajustate la risc ✓
8. Caz de utilizare AI ✓
9. **Rezumat**
10. Quiz
11. Bibliografie

Concluzii cheie

Rezumat

- **Randamentele** sunt metrica principală:
  - Randamente simple pentru analiză cross-secțională; randamente logaritmice pentru serii de timp
  - Pierderea din varianță: $\mathbb{E}[r] \approx \mathbb{E}[R] - \sigma^2/2$; critică pentru active volatile
- **Fapte stilizate** universale: cozi groase, clustering volatilitate, efect levier, gaussianitate agregațională
- **Volatilitatea** este latentă; estimatorii bazați pe range (P, GK, RS, YZ) sunt mai eficienți decât CC
- **Măsuri ajustate la risc**: Sharpe ratio este standard; Sortino, Calmar abordează limitările
- **Diversificare**: frontiera eficientă formalizează compromisul risc-randament (Markowitz 1952)

Formule importante

Randamente

- **Simple**: $R_t = P_t/P_{t-1} - 1$
- **Log**: $r_t = \ln(P_t/P_{t-1})$
- **Drag**: $\mathbb{E}[r] \approx \mathbb{E}[R] - \sigma^2/2$
- **Scalare**: $\sigma_T = \sigma_1\sqrt{T}$

Estimatori de volatilitate

- **CC**: $\hat{\sigma}^2 = \frac{1}{n-1}\sum r_t^2$
- **Parkinson**: folosește $\ln(H/L)$
- **YZ**: combină overnight + RS

Randamente ajustate la risc

- **Sharpe**: $SR = (\bar{R} - R_f)/\sigma$
- **Sortino**: folosește σ_D downside
- **Portofoliu**: $\sigma_P^2 = \mathrm{w}'\Sigma\mathrm{w}$

GARCH(1,1)

- $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta\sigma_{t-1}^2$
- **Necond**: $\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}$
- **EWMA**: $\lambda = 0.94$

Previzualizare capitolul următor

Capitolul 2: Distribuții de probabilitate pentru piețele financiare

- **Distribuția Normală**: proprietăți, limitări pentru date financiare
- **Student-t**: cozi groase, grade de libertate
- **Distribuții stabile**: Pareto-stabile, legi de putere
- **Amestecuri**: Normal Inverse Gaussian (NIG), mixture models

Ce vom învăța

- **Compara** distribuții pe date reale (QQ-plot, KS test)
- **Estima** parametrii prin MLE
- **Modela** cozile groase și asimetria
- **Aplica** distribuții la VaR și Expected Shortfall

Concluzii

- **Randamente** sunt metrica principală pentru evaluarea performanței activelor:
  - Randamente simple: analiza cross-secțională (portofoliu).
  - Randamente logaritmice: analiza seriilor de timp și agregare.
  - Pierderea din varianță: $\mathbb{E}[r] \approx \mathbb{E}[R] - \sigma^2/2$; contează pe orizonturi lungi.
- Randamentele financiare prezintă **fapte stilizate**: cozi groase, gruparea volatilității, efect de levier, gaussianitate agregațională.
- **Volatility** este latentă; există estimatori multipli, fiecare cu compromisuri:
  - Mai multe date (OHLC vs. doar C) $\Rightarrow$ eficiență mai mare.
  - Independență de drift (RS, YZ) vs. ipoteză de drift zero (P, GK).
- **Randamente ajustate la risc** permit comparație echitabilă între strategii:
  - Sharpe ratio: cel mai utilizat; presupune normalitate.
  - Sortino, Calmar, Treynor: adresează limitări specifice ale indicatorului Sharpe.
- **Diversificarea**: varianța portofoliului $<$ media ponderată când $\rho < 1$; frontiera eficientă formalizează aceasta (Markowitz 1952).

Tema 1: Calculul randamentelor

- Prețul unei acțiuni la momentul t este $P_t = \$100$.
  - Randamentele compuse continuu (log) pe următoarele trei perioade sunt: $r_{t+1} = 0.10$, $r_{t+2} = -0.05$, $r_{t+3} = 0.02$.
  - Calculați P_{t+1}, P_{t+2}, P_{t+3}. Arătați toate calculele.
- Acum presupuneți că randamentele **simple** sunt $R_{t+1} = 0.10$, $R_{t+2} = -0.05$, $R_{t+3} = 0.02$.
  - Calculați P_{t+1}, P_{t+2}, P_{t+3}. Arătați toate calculele.
- Comparați prețurile finale:
  - Sunt identice? De ce da sau de ce nu?
  - Care este mai mare și cu cât?
  - Explicați implicațiile practice, în special pentru orizonturi mai lungi.

Tema 1 (cont.): Aditivitatea temporală

- Vi se dă o serie temporală de prețuri ale acțiunilor $P_0, P_1, \ldots, P_n$.
  - Derivați o formulă generală pentru randamentul total compus continuu de la momentul 0 la momentul n.
  - Exprimați aceasta în funcție de randamentele logaritmice individuale pe perioadă $r_1, r_2, \ldots, r_n$.
  - Explicați cum se aplică **aditivitatea temporală** la randamentele logaritmice.
  - De ce este această proprietate dezirabilă în modelarea financiară (ex., pentru scalarea varianței)?
- Derivați acum formula analogă pentru **randamentul simplu** total pe n perioade.
  - Arătați că randamentele simple **nu** sunt aditive temporal.
  - Oferiți un exemplu numeric cu $n = 3$ perioade pentru a ilustra diferența.

Tema 2: Volatilitate și risc

- Definiți volatilitatea în contextul piețelor financiare.
  - Raportați definiția la conceptul de risc din notele de curs.
  - Distingeți între volatilitatea **necondiționată** și **condiționată**.
- De ce este volatilitatea considerată o măsură a riscului? Ce tip de risc captează?
  - Ce tip de risc *nu* captează? (Indiciu: gândiți-vă la riscul de coadă și asimetrie.)
- Discutați cel puțin **trei** metode diferite de estimare a volatilității.
  - Pentru fiecare: specificați datele necesare, avantajul principal și limitarea principală.
- Vi se dau două active A și B:
  - Asset A: $\bar{R} = 12\%$, $\sigma = 20\%$, $R_f = 3\%$.
  - Asset B: $\bar{R} = 8\%$, $\sigma = 10\%$, $R_f = 3\%$.
  - Calculați indicatorul Sharpe pentru fiecare. Pe care l-ar prefera un investitor avers la risc?
  - Explicați conceptul de **aversiune la risc** și cum se raportează la această alegere.

Tema 2 (cont.): Volatilitatea portofoliului

- Un portofoliu constă din două active X și Y cu ponderile $w_X + w_Y = 1$.
  - Activul X: $\sigma_X = 15\%$. Activul Y: $\sigma_Y = 25\%$. Corelație $\rho_{XY} = 0.4$.
  - **(a)** Derivați formula pentru varianța portofoliului σ_P^2 din principii de bază.
  - **(b)** Calculați σ_P pentru $w_X = 0.5$, $w_Y = 0.5$.
  - **(c)** Calculați σ_P pentru $w_X = 0.5$, $w_Y = 0.5$ când $\rho_{XY} = 0$.
  - **(d)** Calculați σ_P pentru $w_X = 0.5$, $w_Y = 0.5$ când $\rho_{XY} = -1$.
- Explicați cum **diversificarea** reduce volatilitatea portofoliului.
  - Pentru ce valoare a corelației este beneficiul maxim?
  - Care este varianța minimă posibilă a portofoliului (indiferent de ponderi)?

Tema 3: Regula rădăcinii pătrate a timpului

- Enunțați și demonstrați regula rădăcinii pătrate a timpului.
  - Enunțați clar toate ipotezele care stau la baza regulii.
  - Furnizați demonstrația pas cu pas.
- O acțiune are o volatilitate zilnică de $\hat{\sigma}_{\text{daily}} = 1.2\%$.
  - Estimați volatilitățile săptămânală (5 zile), lunară (22 zile) și anuală (252 zile).
  - Arătați toate calculele.
  - Valoarea anualizată: este consecventă cu intuiția dvs. pentru o acțiune tipică?
- Presupuneți acum că randamentele zilnice au **autocorrelație pozitivă** $\rho_1 = 0.1$ la lag 1.
  - Volatilitatea anuală reală ar fi mai mare sau mai mică decât estimarea i.i.d.? De ce?
  - Scrieți formula corectată a varianței pentru randamente pe k-perioade cu autocorrelație AR(1).
  - Calculați varianța anuală corectată pentru acțiunea de mai sus cu $\rho_1 = 0.1$.

Cuprins

1. Motivație ✓
2. Date de preț ✓
3. Randamente ✓
4. Fapte stilizate ale randamentelor financiare ✓
5. Estimatori de volatilitate ✓
6. Comparație de eficiență ✓
7. Randamente ajustate la risc ✓
8. Caz de utilizare AI ✓
9. Caz de utilizare AI ✓
10. Rezumat ✓
11. **Quiz**
12. Bibliografie

Întrebarea 1

Întrebare

⊡ O acțiune merge de la \$100 la \$110 la \$99. Care este **log-randamentul** pe două perioade?

Variante de răspuns

(A) $r_{0\to 2} = \ln(99/100) = -1.005\%$

(B) $r_{0\to 2} = (110 - 100)/100 + (99 - 110)/110 = 0\%$

(C) $r_{0\to 2} = \ln(110/100) + \ln(99/110) = 9.531\% + (-10.536\%) = -1.005\%$

(D) $r_{0\to 2} = (99 - 100)/100 = -1\%$

Întrebarea 1: Răspuns

Răspuns: (C)

- Log-randamentele sunt **aditive temporal**: $r_{0\to 2} = r_1 + r_2 = \ln(110/100) + \ln(99/110)$.
- Aceasta este egală cu $\ln(99/100) = -1.005\%$, care coincide cu (A), dar (C) arată metoda corectă.
- (B) calculează randamente simple și le adună — randamentele simple NU sunt aditive temporal.
- (D) este randamentul simplu pe două perioade, nu log-randamentul.

Întrebarea 2

Întrebare

⊡ Care dintre următoarele **NU** este un fapt stilizat al randamentelor financiare?

Variante de răspuns

(A) Cozi groase (exces de curtoză)

(B) Gruparea volatilității (volatility clustering)

(C) Randamentele sunt autocorelate pozitiv la frecvența zilnică

(D) Gaussianitate agregațională

Întrebarea 2: Răspuns

Răspuns: (C)

- Randamentele zilnice au autocorelație **aproape de zero** (consistent cu EMH formă slabă).
- Ceea ce ESTE autocorelat este $|r_t|$ și r_t^2 (clustering volatilitate), nu r_t în sine.
- (A), (B), (D) sunt toate fapte stilizate bine documentate (Cont, 2001).
- Efectul de levier (corelație negativă randament-volatilitate) este un alt fapt stilizat cheie.

Întrebarea 3

Întrebare

⊡ Estimatorul Parkinson are eficiență relativă RE $= 5.2$ vs. close-to-close. Ce înseamnă?

Variante de răspuns

(A) Are nevoie de $5.2\times$ mai multe date pentru aceeași precizie

(B) Atinge aceeași precizie cu $1/5.2$ din date

(C) Varianța sa este $5.2\times$ mai mare decât estimatorul CC

(D) Converge de $5.2\times$ mai lent decât CC

Întrebarea 3: Răspuns

Răspuns: (B)

- $\mathrm{RE} = \mathrm{Var}(\hat{\sigma}^2_{\mathrm{CC}})/\mathrm{Var}(\hat{\sigma}^2_{\mathrm{P}}) = 5.2$.
- Varianța estimatorului Parkinson este $5.2\times$ **mai mică**, deci are nevoie de doar $1/5.2 \approx 19\%$ din date pentru aceeași precizie.
- Câștigul de eficiență vine din folosirea informației high-low (întregul range zilnic).
- Yang-Zhang atinge $\mathrm{RE} \approx 14$, cel mai mare dintre estimatorii OHLC.

Întrebarea 4

Întrebare

⊡ Bitcoin are σ zilnică $\approx 4\%$. Pierderea din varianță $\sigma^2/2$ pe 365 de zile este aproximativ:

Variante de răspuns

(A) 0.08% pe zi $\times$ 365 $\approx 29\%$ pe an

(B) $4\%/2 = 2\%$ pe an

(C) $4^2/2 = 8\%$ pe an

(D) Neglijabilă — variance drag contează doar pentru active cu volatilitate scăzută

Întrebarea 4: Răspuns

Răspuns: (A)

- Drag zilnic $= \sigma^2/2 = 4^2/(2 \times 100) = 0.08\%$ pe zi.
- Drag anual $= 0.08\% \times 365 = 29.2\%$ pe an.
- Aceasta înseamnă că randamentul geometric Bitcoin este $\approx 29\%$ **mai mic** decât cel aritmetic anual.
- (B) și (C) confundă σ cu σ^2. (D) este invers — drag crește cvadratic cu σ.

Întrebarea 5

Întrebare

- Fond A: $\bar{R} = 12\%$, $\sigma = 20\%$, $R_f = 3\%$. Fond B: $\bar{R} = 8\%$, $\sigma = 10\%$, $R_f = 3\%$. Care are Sharpe ratio mai mare?

Variante de răspuns

(A) Fondul A: $SR_A = 0.45$ vs. $SR_B = 0.50$, deci Fondul A

(B) Fondul B: $SR_B = (8 - 3)/10 = 0.50 > SR_A = (12 - 3)/20 = 0.45$

(C) Sunt egale: ambele au SR $= 0.50$

(D) Fondul A, deoarece are randament absolut mai mare

Întrebarea 5: Răspuns

Răspuns: (B)

- $SR_A = (12\% - 3\%)/20\% = 0.45$.
- $SR_B = (8\% - 3\%)/10\% = 0.50$.
- Fondul B livrează mai mult **randament per unitate de risc**, deși are randament absolut mai mic.
- (D) este greșeala frecventă: randament mai mare $\neq$ performanță ajustată la risc mai bună.

Întrebarea 6

Întrebare

Două active cu $\sigma_X = 15\%$, $\sigma_Y = 25\%$, $\rho_{XY} = 0.3$. Un portofoliu cu ponderi egale are volatilitatea:

Variante de răspuns

(A) $\sigma_P = (15\% + 25\%)/2 = 20\%$ (media)

(B) $\sigma_P = \sqrt{0.25 \times 0.0225 + 0.25 \times 0.0625 + 2 \times 0.25 \times 0.3 \times 0.15 \times 0.25} \approx 16.6\%$

(C) $\sigma_P = \sqrt{0.5^2 \times 15^2 + 0.5^2 \times 25^2} = 14.6\%$

(D) Nu se poate calcula fără randamentele așteptate individuale

Întrebarea 6: Răspuns

Răspuns: (B)

- $\sigma_P^2 = w_X^2\sigma_X^2 + w_Y^2\sigma_Y^2 + 2w_X w_Y \rho\sigma_X\sigma_Y$
- $= 0.25(0.0225) + 0.25(0.0625) + 2(0.25)(0.3)(0.15)(0.25)$
- $= 0.005625 + 0.015625 + 0.005625 = 0.026875$, deci $\sigma_P = 16.4\%$.
- Aceasta este **mai mică** decât media ponderată (20%) $\Rightarrow$ beneficiul diversificării.
- (C) uită termenul încrucișat (presupune $\rho = 0$). (D) este greșit: σ_P nu depinde de randamente așteptate.

Cuprins

1. Motivație ✓
2. Date de preț ✓
3. Randamente ✓
4. Fapte stilizate ✓
5. Estimatori de volatilitate ✓
6. Comparație de eficiență ✓
7. Randamente ajustate la risc ✓
8. Caz de utilizare AI ✓
9. Rezumat ✓
10. Quiz ✓
11. **Bibliografie**

Bibliografie I

Manuale de referință

- Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*. 4th Ed., Springer.
- Tsay, R.S. (2010). *Analysis of Financial Time Series*. 3rd Ed., Wiley.
- Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). *The Econometrics of Financial Markets*. Princeton University Press.

Articole fundamentale

- Mandelbrot, B. (1963). The Variation of Certain Speculative Prices. *Journal of Business*, 36(4), 394–419.
- Cont, R. (2001). Empirical Properties of Asset Returns: Stylized Facts and Statistical Issues. *Quantitative Finance*, 1(2), 223–236.
- Fama, E.F. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *Journal of Finance*, 25(2), 383–417.

Bibliografie II

Modele GARCH și de volatilitate

- Engle, R.F. (1982). Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of UK Inflation. *Econometrica*, 50(4), 987–1007.
- Bollerslev, T. (1986). Generalized Autoregressive Conditional Heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Nelson, D.B. (1991). Conditional Heteroskedasticity in Asset Returns: A New Approach. *Econometrica*, 59(2), 347–370.
- Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the Relation between the Expected Value and the Volatility of the Nominal Excess Return on Stocks. *Journal of Finance*, 48(5), 1779–1801.
- Black, F. (1976). Studies of Stock Price Volatility Changes. *Proceedings of the 1976 ASA Meetings*, 177–181.

Previziunea volatilității

- Andersen, T.G., Bollerslev, T. (1998). Answering the Skeptics: Yes, Standard Volatility Models Do Provide Accurate Forecasts. *Int. Economic Review*, 39(4), 885–905.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). . . . and the Cross-Section of Expected Returns. *Review of Financial Studies*, 29(1), 5–68.

Bibliografie III

Estimatori de volatilitate bazați pe interval

- Parkinson, M. (1980). The Extreme Value Method for Estimating the Variance of the Rate of Return. *Journal of Business*, 53(1), 61–65.
- Garman, M.B., Klass, M.J. (1980). On the Estimation of Security Price Volatilities from Historical Data. *Journal of Business*, 53(1), 67–78.
- Rogers, L.C.G., Satchell, S.E. (1991). Estimating Variance from High, Low and Closing Prices. *Annals of Applied Probability*, 1(4), 504–512.
- Yang, D., Zhang, Q. (2000). Drift-independent volatility estimation based on high, low, open, and close prices. *Journal of Business*, 73(3), 477–492.

Studii comparative

- Molnár, P. (2012). Properties of range-based volatility estimators. *Int. Review of Financial Analysis*, 25, 1–12.
- Lapinova, S., Saichev, A. (2017). Comparative statistics of GK, Parkinson, RS and bridge estimators. *Cogent Physics*, 4(1), 1303931.
- Fałdziński, M., Osińska, M. (2016). Volatility estimators in econometric analysis of risk transfer. *Dynamic Econometric Models*, 16(1), 1–20.
- Öztürk, H., Erol, U., Yuksel, A. (2016). Extreme value volatility estimators and realized volatility of ISE. *Int. J. of Economics and Finance*, 8(8), 73.
- Cadenas-Morales, E. (2022). Bitcoin volatility estimate applying Rogers and Satchell range model. *IJFIRM*, 12(1), 49–79.

Bibliografie IV

Volatilitate realizată și microstructură

- Barndorff-Nielsen, O.E., Shephard, N. (2002). Econometric Analysis of Realized Volatility. *JRSS B*, 64(2), 253–280.
- Christensen, K., Podolskij, M. (2007). Realized range-based estimation of integrated variance. *Journal of Econometrics*, 141(2), 323–349.
- Epps, T.W. (1979). Comovements in Stock Prices in the Very Short Run. *JASA*, 74(366), 291–298.
- Glosten, L.R., Milgrom, P.R. (1985). Bid, Ask and Transaction Prices in a Specialist Market. *Journal of Financial Economics*, 14(1), 71–100.
- Roll, R. (1984). A Simple Implicit Measure of the Effective Bid-Ask Spread. *Journal of Finance*, 39(4), 1127–1139.

Relația volum-volatilitate

- Clark, P.K. (1973). A Subordinated Stochastic Process Model with Finite Variance for Speculative Prices. *Econometrica*, 41(1), 135–155.
- Copeland, T.E. (1976). A Model of Asset Trading under Sequential Information Arrival. *Journal of Finance*, 31(4), 1149–1168.
- Tauchen, G.E., Pitts, M. (1983). The Price Variability-Volume Relationship on Speculative Markets. *Econometrica*, 51(2), 485–505.

Bibliografie V

Teoria portofoliului

- Markowitz, H. (1952). Portfolio Selection. *Journal of Finance*, 7(1), 77–91.
- Sharpe, W.F. (1966). Mutual Fund Performance. *Journal of Business*, 39(1), 119–138.
- Tobin, J. (1958). Liquidity Preference as Behavior Towards Risk. *Review of Economic Studies*, 25(2), 65–86.

Resurse online și cod

- **Quantlet**: `https://quantlet.com` ≻ Platformă de cod pentru metode cantitative
- **Quantinar**: `https://quantinar.com` ≻ Platformă de învățare pentru metode cantitative
- **GitHub SFM**: `https://github.com/QuantLet/Stat_fin_markets/tree/main/SFM_ch1` ≻ Cod Python pentru acest capitol

Vă mulțumesc!

Întrebări?

Materialele cursului disponibile la: https://danpele.github.io/SFM/

Quantlet Quantinar