



Statistica Piețelor Financiare

Capitolul 1: Date și indicatori statistici



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Obiective de învățare

La sfârșitul acestui capitol, veți fi capabili să:

1. **Distingeți** între date de preț OHLC, prețuri ajustate și spread-uri bid-ask
2. **Calculați** randamente simple și logaritmice și explicați pierderea din varianță
3. **Identificați** faptele stilizate ale randamentelor (cozi groase, gruparea volatilității, efect levier)
4. **Aplicați** estimatori de volatilitate bazați pe range (Parkinson, GK, RS, Yang-Zhang)
5. **Comparați** eficiența estimatorilor și volatilitatea condițională vs. necondițională
6. **Calculați** măsuri de performanță ajustate la risc (Sharpe, Sortino, Calmar)
7. **Construiți** frontiera eficientă și derivați portofoliul cu varianță minimă

Ghid de studiu — Cum să folosiți materialele

Înainte de curs (*pre-reading*)

- ▣ Franke et al. (2019), Cap. 1 (20 pag.)
- ▣ Campbell et al. (1997), Cap. 1.1–1.3
- ▣ Opțional: Cont (2001), Secțiunile 1–2

După curs (*review*)

- ▣ Refaceți exercițiile din slide-uri **fără** a privi rezolvările
- ▣ Rulați cel puțin 2 notebook-uri Quantlet
- ▣ Completați quiz-ul ca auto-evaluare

Resurse digitale

- ▣ **Slide-uri + cod:** <https://danpele.github.io/SFM/>
- ▣ **Quantlet-uri interactive:** https://github.com/QuantLet/Stat_fin_markets/tree/master/Ch_01
- ▣ **Forum de discuții:** Platforma e-learning ASE

Cuprins

- ▣ Motivație
- ▣ Date de preț
- ▣ Randamente
- ▣ Fapte stilizate
- ▣ Estimatori de volatilitate
- ▣ Comparație de eficiență
- ▣ Randamente ajustate la risc
- ▣ Caz de utilizare AI
- ▣ Rezumat
- ▣ Quiz & Exerciții de examen
- ▣ Bibliografie

Harta capitolului



Parcursul logic

- ▣ Colectăm **date de preț** (OHLC)
- ▣ Le transformăm în **randamente**
- ▣ Studiem **faptele stilizate**
- ▣ Estimăm **riscul** (volatilitate, drawdown)
- ▣ Luăm **decizii** (Sharpe, frontieră eficientă)

Ideea centrală

- ▣ Prețurile sunt **nestaționare** — nu le putem modela direct
- ▣ Randamentele sunt **staționare** — le putem analiza statistic
- ▣ Volatilitatea este o **variabilă latentă** — trebuie estimată
- ▣ Riscul nu este doar volatilitate — include cozi groase, drawdown, asimetrie

Partea I

Date, Randamente și Fapte Stilizate

— Secțiunile 1–4 —

De ce avem nevoie de date?



"Data! Data! Data! I can't make bricks without clay." — Sherlock Holmes

Înțelegerea trecutului

- Identificarea modelelor, tendințelor și anomaliilor.
- Validarea teoriilor: EMH (*Efficient Market Hypothesis*), CAPM (*Capital Asset Pricing Model*), APT (*Arbitrage Pricing Theory*).
- Măsurarea profilurilor de risc și randament.

Predicția viitorului

- Prognoza prețurilor, volatilității, corelațiilor.
- Construirea de strategii cantitative.
- Analiză de scenarii și stress testing.

Managementul riscului

- Cuantificarea expunerii: VaR (*Value at Risk*), CVaR (*Conditional VaR*), ES (*Expected Shortfall*).
- Diversificarea portofoliului și hedging.
- Conformitate regulatorie (Basel III, Solvency II).

Evaluare & tranzacționare

- Evaluarea derivatelor (opțiuni, futures, swap-uri).
- Contabilizare mark-to-market.
- Tranzacționare algoritmică și de înaltă frecvență.

Exemple de utilizare a datelor

Analiză tehnică

- ▣ Utilizează date istorice de preț și volum.
- ▣ Modele grafice, medii mobile, RSI, MACD.
- ▣ Presupune că istoria prețurilor se repetă.

Analiză fundamentală

- ▣ Situații financiare, câștiguri, indicatori macro.
- ▣ Modele de fluxuri de numerar actualizate (DCF).
- ▣ Raportul P/E, book-to-market, randamentul dividendelor.

Finanțe cantitative

- ▣ Modele statistice: GARCH, vol. stochastică, copule.
- ▣ Învățare automată: random forests, LSTM-uri.
- ▣ Modele factoriale: Fama-French, Carhart, Barra.

Tranzacționare algoritmică

- ▣ Date tick-by-tick, registrul de ordine (*order book*), date TAQ.
- ▣ Algoritmi de execuție sensibili la latență.
- ▣ Microstructura pieței și execuția optimă.

Surse de date

Sursă	Tip	Cost	Acoperire
Bloomberg Terminal	OHLCV, fundamentale, știri	\$\$\$\$	Global, toate clasele de active
Refinitiv Eikon	OHLCV, date tick, știri	\$\$\$	Global, instituțional
Yahoo Finance	OHLCV zilnic, dividende	Gratuit	Ațiuni, ETF-uri, FX
WRDS / CRSP	Prețuri ajustate, randamente	\$\$ (academic)	Ațiuni SUA, 1926–prezent
CoinGecko / CoinMarketCap	OHLCV, date on-chain	Gratuit/\$	Criptomonedă

Surse gratuite

- Yahoo Finance, Alpha Vantage, Quandl (NASDAQ Data Link).
- Suficiente pentru cercetare academică și backtesting.
- Întârzieri: 15–20 minute pentru cotații în timp real.

Surse plătite / instituționale

- Bloomberg, Refinitiv: date tick la nivel de milisecundă.
- WRDS/CRSP: date curate de acțiuni SUA, fără survivorship bias.
- Esențiale pentru managementul profesional al riscului.

Frecvența datelor



- ▣ **Frecvență mai mare** $\Rightarrow$ mai multe observații, mai mult zgomot de microstructură.
- ▣ **Zilnic** este frecvența standard pentru cercetarea academică și practică.
- ▣ **Efectul Epps** (1979): corelațiile perechi între active *scad* pe măsură ce frecvența de eșantionare crește către nivelul de tick.
 - ▶ Căuzat de tranzacționarea asincronă: activele nu se tranzacționează simultan.
 - ▶ Corelațiile măsurate la frecvență zilnică sunt semnificativ mai mari decât la 1 minut.
- ▣ **Datele intrazilnice** sunt esențiale pentru estimarea volatilității realizate (Secțiunea 5).

Provocări ale datelor în finanțe

- ▣ **Calitatea datelor:** Valori lipsă, tick-uri eronate, erori la acțiuni corporative.
 - ▶ Chiar și datele Bloomberg conțin erori; validați mereu.
- ▣ **Survivorship bias:** Studierea doar a firmelor listate curent inflează randamentele estimate.
 - ▶ CRSP include firmele delistate; Yahoo Finance nu.
- ▣ **Look-ahead bias:** Utilizarea informațiilor indisponibile la momentul deciziei.
 - ▶ Ex., utilizarea compoziției actuale a indicelui pentru a backtesta o strategie de 10 ani.
- ▣ **Volumul datelor:** HFT generează ~ 1 TB/zi per bursă; stocarea și curățarea sunt netriviale.
- ▣ **Testare multiplă:** Harvey, Liu & Zhu (2016) argumentează că majoritatea factorilor publicați sunt descoperiri false.
 - ▶ p -hacking și căutarea excesivă în date inflează erorile de tip I.
 - ▶ Prag recomandat: t -statistic > 3.0 pentru factori noi.
- ▣ **Interpretarea datelor:** Corelație $\neq$ cauzalitate; semnificație statistică $\neq$ economică.


Cuprins

- ▣ Motivație ✓
- ▣ **Date de preț**
- ▣ Randamente
- ▣ Fapte stilizate ale randamentelor financiare
- ▣ Estimatori de volatilitate
- ▣ Comparație de eficiență
- ▣ Randamente ajustate la risc
- ▣ Caz AI / Rezumat / Quiz
- ▣ Bibliografie

Date OHLC

Symbol	Denumire	Descriere
O_t	Deschidere	Primul preț din perioada t
H_t	Maxim	Prețul maxim din perioada t
L_t	Minim	Prețul minim din perioada t
C_t	Închidere	Ultimul preț din perioada t
V_t	Volum	Acțiuni tranzacționate

- Prin construcție: $L_t \leq O_t, C_t \leq H_t$.
- Range $H_t - L_t$: proxy pentru volatilitatea intra-perioadă.
- Volum mare $\Rightarrow$ descoperire a prețului mai eficientă.



OHLC: Exemplu numeric

- Cinci zile de tranzacționare cu date simulate tip AAPL (prețuri în USD):

Date	Open	High	Low	Close	Volume
2024-01-02	185.20	188.45	184.10	187.90	52,300,000
2024-01-03	187.90	189.30	183.60	184.20	61,800,000
2024-01-04	184.20	186.80	181.50	186.10	48,500,000
2024-01-05	186.10	191.20	185.70	190.40	55,200,000
2024-01-08	190.40	193.50	188.90	192.30	47,900,000

- Ziua 2 (3 Ian): **lumânare bearish** — $\text{Close} < \text{Open}$; spread = $189.30 - 183.60 = \$5.70$.
- Ziua 4 (5 Ian): **lumânare bullish puternică** — $\text{Close} - \text{Open} = \4.30 ; volum mare.
- Randamentul logaritm zilnic, 2 Ian: $r = \ln(187.90/185.20) = 0.01449 \approx 1.45\%$.

 SFM_ch1_ohlc_orderbook

Prețul ajustat de închidere

- Prețurile de închidere brute **nu sunt direct comparabile** în timp din cauza acțiunilor corporative.
- Prețul ajustat de închidere** ține cont retroactiv de toate acțiunile corporative:

$$P_t^{\text{adj}} = P_t \times \prod_{k: t_k > t} A_{t_k}^{-1}$$

- A_{t_k} $\succ$ factorul de ajustare la data acțiunii corporative t_k



Important

- Folosiți mereu prețuri ajustate la calculul randamentelor — prețurile brute prezintă salturi false la datele acțiunilor corporative care ar apărea ca randamente artificiale mari.

Factori individuali de ajustare

- **Splituri de acțiuni** (m -for- n): fiecare acționar primește m acțiuni pentru fiecare n deținute.

$$A_t^{\text{split}} = \frac{n}{m}, \quad \text{de ex. split 2-la-1: } A_t = \frac{1}{2}.$$

- **Dividende în acțiuni**: compania emite acțiuni noi ca dividend (de ex. 10% dividend în acțiuni).

$$A_t^{\text{stock div}} = \frac{1}{1+d}, \quad d = \text{rata dividendului.}$$

- **Dividende în numerar**: plată directă în numerar D_t pe acțiune.

$$A_t^{\text{cash div}} = \frac{P_{t-1} - D_t}{P_{t-1}} = 1 - \frac{D_t}{P_{t-1}}.$$

- **Oferte de drepturi**: acționarii existenți cumpără acțiuni noi la un preț redus.

$$A_t^{\text{rights}} = \frac{P_{t-1} + r \cdot P_{\text{sub}}}{P_{t-1}(1+r)},$$

unde r = raportul de acțiuni noi per acțiune existentă, P_{sub} = prețul de subscriere.

Exemplu numeric: Prețuri ajustate

Example 1

Acțiune la \$100. Ziua 5: dividend în numerar \$2. Ziua 10: split 2-la-1.

▣ **Factori de ajustare:** $A_5 = 98/100 = 0.98$; $A_{10} = 1/2 = 0.50$


▣ **Prețuri ajustate:**

Perioada	Ajustări	Formulă
$t < 5$	ambele	$P_t^{\text{adj}} = P_t \times 0.49$
$5 \leq t < 10$	doar split	$P_t^{\text{adj}} = P_t \times 0.50$
$t \geq 10$	niciuna	$P_t^{\text{adj}} = P_t$

- ▣ \$100 din Ziua 1 se ajustează la $100 \times 0.49 = \$49$ retroactiv — nu e o pierdere, ci doar o ajustare contabilă.
- ▣ Seria de randamente calculată din prețuri ajustate este continuă pe parcursul acțiunilor corporative.

Spread Bid-Ask și registrul de ordine (*order book*)

- ▣ **Ask P^a :** cel mai mic preț de vânzare.
- ▣ **Bid P^b :** cel mai mare preț de cumpărare.
- ▣ **Spread:** $s = P^a - P^b > 0$.
- ▣ **Mid-price:** $P^m = (P^a + P^b)/2$.
- ▣ **Effective spread:** $2|P_{\text{trade}} - P^m|$.
- ▣ Spread-uri mai mici $\Rightarrow$ piață mai lichidă.



Microstructura pieței

- ▣ **Microstructura pieței** studiază modul în care se formează prețurile la nivel de tranzacție.
- ▣ **Descoperirea prețului:** procesul prin care informațiile noi sunt încorporate în prețuri.
 - ▶ Roll (1984): saltul bid-ask induce autocorelație *negativă* de ordinul întâi în randamentele tranzacțiilor.
 - ▶ Prețul tranzacției observat = prețul real + componentă de zgomot.
- ▣ **Asimetria informațională:** unii traderi au informații private (traderi informați).
 - ▶ Formatorii de piață (*market makers*) largesc spread-urile când riscul de selecție adversă este mare.
 - ▶ Glosten-Milgrom (1985) model: spread-ul de echilibru depinde de fracția de traderi informați.
- ▣ **Market makers:** furnizează lichiditate cotând simultan bid și ask.
 - ▶ Profită din spread; suportă risc de inventar și selecție adversă.
- ▣ **Tick size:** incrementul minim de preț (de ex., \$0,01 pentru acțiunile SUA de la decimalizarea din 2001).
 - ▶ Tick mai mic $\Rightarrow$ spread-uri mai mici dar potențial mai puțină adâncime.

Estimarea spreadului efectiv: Exemplu

Tranzacția	Preț (\$)	Midpoint (\$)	Direcție	Spread efectiv
1	50.10	50.05	Cumpărare	$2 \times 50.10 - 50.05 = 0.10$
2	49.95	50.00	Vânzare	$2 \times 49.95 - 50.00 = 0.10$
3	50.15	50.08	Cumpărare	$2 \times 50.15 - 50.08 = 0.14$
4	49.90	49.95	Vânzare	$2 \times 49.90 - 49.95 = 0.10$
5	50.20	50.10	Cumpărare	$2 \times 50.20 - 50.10 = 0.20$

- **Spread efectiv mediu:** $\bar{S}_{\text{eff}} = \frac{1}{5}(0.10 + 0.10 + 0.14 + 0.10 + 0.20) = \0.128 .
- **Estimatorul Roll (1984):** $\hat{S} = 2\sqrt{-\widehat{\text{Cov}}(\Delta P_t, \Delta P_{t-1})}$ — estimează spreadul doar din autocovarianța randamentelor, fără date de cotații.
- Aplicabil când datele bid/ask nu sunt disponibile (serii istorice lungi).

Impactul de piață și conținutul informațional

- **Impactul de piață** (*market impact*): deplasarea prețului cauzată de o tranzacție mare.
 - ▶ Impact temporar (revenire) + impact permanent (informație nouă).
 - ▶ Modelul Almgren-Chriss (2001): cost total $\propto \sigma \sqrt{V/ADV}$.
- **Lambda Kyle** (λ): sensibilitatea prețului la fluxul net de ordine (*order flow*):

$$\Delta P_t = \lambda \cdot OF_t + \varepsilon_t, \quad \lambda = \text{măsura ilichidității informaționale.}$$

- **Descompunerea spreadului** (Huang & Stoll, 1997):
 - ▶ Componenta de *selecție adversă* (informație) — compensează pierderea față de traderii informați
 - ▶ Componenta de *inventar* — risc de deținere a unei poziții dezechilibrate
 - ▶ Componenta de *procesare ordine* — costuri fixe operaționale
- **Legătura cu MDH**: lichiditatea scăzută $\Rightarrow$ volatilitate mai mare, consistentă cu ipoteza mixturii de distribuții.

Cuprins

- ▣ Motivație ✓
- ▣ Date de preț ✓
- ▣ **Randamente**
- ▣ Fapte stilizate ale randamentelor financiare
- ▣ Estimatori de volatilitate
- ▣ Comparație de eficiență
- ▣ Randamente ajustate la risc
- ▣ Caz AI / Rezumat / Quiz
- ▣ Bibliografie

De ce randamente? Staționaritate


Definiție 1 (Staționaritate slabă (în covarianță))

□ O serie temporală $\{X_t\}$ este **slab staționară** dacă:

1. $\mathbb{E}[X_t] = \mu$ (medie constantă, $\forall t$),
2. $\text{Var}(X_t) = \sigma^2 < \infty$ (varianță constantă și finită, $\forall t$),
3. $\text{Cov}(X_t, X_{t-k}) = \gamma(k)$ (autocovarianța depinde doar de lag-ul k , nu de t).

- **Prețurile** P_t sunt în general **nestaționare**: au trend, rădăcini unitare și varianță variabilă în timp.
- **Randamentele** $r_t = \ln(P_t/P_{t-1})$ sunt aproximativ staționare: medie și varianță relativ constante.
- **Notatie formală**: $P_t \sim I(1)$ (nestaționară, rădăcină unitară), $r_t = \Delta \ln P_t \sim I(0)$ (staționară).
- **Intuiție**: „Prețurile cresc, randamentele oscilează.” Analizăm randamente deoarece metodele statistice cer staționaritate.
- **Test formal**: testul ADF respinge ipoteza nulă de rădăcină unitară pentru randamente, dar nu pentru prețuri.


Staționaritate: Preț vs. Randamente



- ▣ **Sus:** Prețul S&P 500 are medie cu trend și varianță crescătoare $\Rightarrow$ nestaționară.
- ▣ **Jos:** Randamentele log fluctuează în jurul zero-ului cu varianță aprox. constantă $\Rightarrow$ staționară.

Testul Augmented Dickey-Fuller (ADF)

- ▣ ADF testează H_0 : rădăcină unitară (nestaționară) vs. H_1 : staționară.
- ▣ Model: $\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{j=1}^p \delta_j \Delta y_{t-j} + \varepsilon_t$. Respingem H_0 dacă $\hat{\tau} = \hat{\gamma}/SE(\hat{\gamma}) < \tau_{critic}$.



- ▣ Log-prețurile: H_0 nu se respinge ($p = 0.98$) $\Rightarrow$ rădăcină unitară, $I(1)$.
- ▣ Log-randamentele: H_0 se respinge la 1% ($p \approx 0$) $\Rightarrow$ staționare, $I(0)$.

Randamente simple (aritmetice)

Convenție de notație

- În notația OHLC, prețul de închidere este C_t . Însă, de aici înainte, P_t denotă **prețul de închidere** (*closing price*) sau **prețul de închidere ajustat** (*adjusted closing price*), în funcție de context.
- Folosiți mereu prețuri ajustate pentru calculul randamentelor, pentru a ține cont de dividende și split-uri.

Definiție 2 (Randament simplu)

- Randamentul net simplu** pe o perioadă: $R_t = \frac{P_t - P_{t-1}}{P_{t-1}} = \frac{P_t}{P_{t-1}} - 1$.
- Randamentul brut**: $1 + R_t = P_t / P_{t-1}$.
- Aditivitate pe active**: randamentul portofoliului $R_P = \sum_{i=1}^n w_i R_i$ (exact, o perioadă).
- Nu este aditiv în timp**: randamentul brut multi-perioadă $= \prod_s (1 + R_s)$, nu o sumă.
- Mărginit inferior** de -1 (răspundere limitată; prețurile nu pot fi negative).
- Randamentul brut pe k perioade: $1 + R_t(k) = \prod_{j=0}^{k-1} (1 + R_{t-j})$.
- Exemplu: $P_0 = 100, P_1 = 110 \Rightarrow R_1 = 10\%$.
- Observație**: Randamentele simple sunt preferate pentru analiza **cross-secțională** (construcția portofoliului).

Când folosim fiecare tip de randament?

Context	Tip preferat	Motivare
Analiză cross-sectiională	Simplu (R_t)	Aditivitate pe active: $R_P = \sum w_i R_i$
Serie temporală	Logaritmico (r_t)	Aditivitate temporală: $r_{0 \rightarrow T} = \sum r_t$
Construcție portofoliu	Simplu	Ponderile sunt semnificative
Backtesting pe termen lung	Logaritmico	$\ln W_T = \ln W_0 + \sum r_t$
Raportare către investitori	Simplu	Interpretare directă: “+10%”
Modelare statistică	Logaritmico	$r_t \in (-\infty, +\infty)$, compatibil cu Distribuția Normală

Mini-exercițiu

- O acțiune are $P_0 = 50$, $P_1 = 55$, $P_2 = 48$. Calculați randamentele simple și logaritmice pentru fiecare perioadă. Verificați: suma log-randamentelor = log-randamentul total?

Randamente logaritmice (compuse continuu)

Definiție 3 (Randament logaritmice)

- ▣ **Randamentul logaritmice** (randament compus continuu): $r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln(1 + R_t)$.
- ▣ **Aditive în timp**: $r_t(k) = \sum_{j=0}^{k-1} r_{t-j} = \ln(P_t/P_{t-k})$.
- ▣ **Non-aditive pe active**: $r_P \neq \sum_i w_i r_i$ în general.
- ▣ **Simetrice**: câștig de $+x$ și pierdere de $-x$ tratate simetric.
- ▣ **Nemărginite**: $r_t \in (-\infty, +\infty)$, compatibil cu distribuția normală.
- ▣ Exemplu: $P_0 = 100$, $P_1 = 110 \Rightarrow r_1 = \ln(1.10) = 9.531\%$.
- ▣ **Observație**: Randamentele logaritmice sunt preferate pentru analiza **seriilor de timp** (staționaritate, agregare).

Randamente simple vs. logaritmice: Expansiunea Taylor

Propoziție 1

Pentru randamente mici: $r_t = \ln(1 + R_t) = R_t - \frac{R_t^2}{2} + \frac{R_t^3}{3} - \dots$

La ordinul doi: $r_t \approx R_t - \frac{R_t^2}{2}$, deci $r_t < R_t$ pentru orice $R_t \neq 0$.


▣ **Demonstrație.** Deoarece $\ln$ este strict concavă, $\ln(1 + x) < x$ pentru orice $x > -1$, $x \neq 0$. Substituind $x = R_t$ obținem $r_t = \ln(1 + R_t) < R_t$. □

- ▣ Pentru randamente zilnice ($|R_t| \approx 1\%$), aproximarea $r_t \approx R_t$ este excelentă.
- ▣ Diferența $R_t - r_t \approx R_t^2/2$ crește cu volatilitatea și pe orizonturi mai lungi.
- ▣ Aceasta este sursa **pierderii din varianță** în performanța pe termen lung.

Pierdere din varianță (*variance drag*, Inegalitatea lui Jensen)

- ▣ $\mathbb{E}[r_t] = \mathbb{E}[\ln(1 + R_t)] < \ln(1 + \mathbb{E}[R_t])$. Practic: $\mathbb{E}[r_t] \approx \mathbb{E}[R_t] - \frac{1}{2}\text{Var}(R_t)$.

Randamente simple vs. logaritmice: Comparație vizuală



- Pentru randamente zilnice tipice ($\pm 3\%$), simple $\approx$ log; pentru mișcări mari, divergența e semnificativă.
- Randamentul log este mereu **mai mic** decât cel simplu: $r_t < R_t$ pentru $R_t > 0$.

Exemplu numeric: Randamente simple vs. logaritmice

Example 2

$P_0 = \$100$: crește +10% apoi scade -10% (randamente simple).

□ **Randamente simple:**

- ▶ $P_1 = 100 \times 1.10 = \110
- ▶ $P_2 = 110 \times 0.90 = \99
- ▶ Net: -1%. Suma +10% - 10% = 0 este înșelătoare!

□ **Randamente logaritmice:**

- ▶ $r_1 = \ln(1.10) = +9.531\%$
- ▶ $r_2 = \ln(0.90) = -10.536\%$
- ▶ Sumă: -1.005% = $\ln(99/100)$ ✓

	Per. 1	Per. 2	Total
R_t	+10.00%	-10.00%	-1.00%
r_t	+9.53%	-10.54%	-1.01%

- Randamentele logaritmice se *însurează* corect.
- Randamentele simple trebuie compuse:
 $(1.10)(0.90) - 1 = -1\%$.

De ce contează diferența

- Diferența dintre $\mathbb{E}[R]$ și $\mathbb{E}[r]$ este **pierdere din varianță** (*variance drag*): $\mathbb{E}[r] \approx \mathbb{E}[R] - \sigma^2/2$.
- Crește cu volatilitatea și orizontul de timp. **Intuiție:** volatilitatea acționează ca o «taxă» asupra creșterii compuse.

Mini-scenariu: Care activ produce mai multă avere pe termen lung?


- **Activ A:** $\mathbb{E}[R] = 10\%$, $\sigma = 5\%$
Pierdere: $0,05^2/2 = 0,125\% \Rightarrow \mathbb{E}[r] \approx 9,875\%$
- **Activ B:** $\mathbb{E}[R] = 10\%$, $\sigma = 30\%$
Pierdere: $0,30^2/2 = 4,5\% \Rightarrow \mathbb{E}[r] \approx 5,5\%$
- Același $\mathbb{E}[R]$, dar **averea pe 10 ani:**
- A: $W_{10} = e^{10 \times 0.09875} \approx 2,68 \times W_0$
- B: $W_{10} = e^{10 \times 0.055} \approx 1,73 \times W_0$
- **Volatilitatea mare distruge averea!**

Activ	$\mathbb{E}[R]/\text{zi}$	σ/zi	$\mathbb{E}[r]/\text{zi}$	Pierdere anuală
S&P 500	0,040%	1,0%	0,035%	$\approx 1,3\%$
AAPL	0,060%	1,8%	0,044%	$\approx 4,1\%$
Bitcoin	0,200%	4,0%	0,120%	$\approx 29\%$

De ce contează diferența (cont.)

- ▣ BTC: pierderea din varianță $= 4^2 / (2 \times 100) = 0,08\%/zi$; pe 365 zile $\approx 29\%/an$.
- ▣ **Convenții:** acțiunile folosesc 252 zile/an (NYSE), crypto folosește 365 zile calendaristice.
- ▣ Pentru proiecții de avuție pe termen lung, folosiți mereu randamente geometrice (log).

Pierdere din varianță: Vizualizare



- Curba pierderii $\sigma^2/2$ este **cvadratică**: dublarea volatilității cvadrupează pierderea.
- S&P 500 ($\sigma \approx 16\%$): pierdere $\approx 1,3\%/an$; Bitcoin ($\sigma \approx 75\%$): $\approx 28\%/an$.

Randamente multi-perioadă și procesul de avere

Definiție 4 (Procesul de avere)

- Investind W_0 la momentul 0, averea după T perioade: $W_T = W_0 \prod_{t=1}^T (1 + R_t) = W_0 \exp(\sum_{t=1}^T r_t)$.
- Log-wealth** este o sumă: $\ln W_T = \ln W_0 + \sum_{t=1}^T r_t$.
- Prin **Teorema Limită Centrală (TLC)**, $\ln W_T \approx$ normal pentru T mare (dacă r_t i.i.d.) $\Rightarrow W_T$ este **log-normal**.
- Randamentul log pe k perioade: $r_t(k) = \sum_{j=0}^{k-1} r_{t-j}$ (sumă, simplu).
- Randamentul simplu pe k perioade: $R_t(k) = \prod_{j=0}^{k-1} (1 + R_{t-j}) - 1$ (produs, mai dificil).

Implicație practică

- Pentru backtesting: sumați randamentele logaritmice, apoi convertiți la averea finală prin $W_T = W_0 \cdot e^{\text{CLR}_T}$.

Mișcarea browniană geometrică și proprietatea log-normală


Definiție 5 (GBM — Geometric Brownian Motion)

Modelul clasic Black-Scholes presupune că prețul urmează: $dP_t = \mu P_t dt + \sigma P_t dW_t$, cu soluția:

$$P_T = P_0 \exp\left[\left(\mu - \frac{\sigma^2}{2}\right)T + \sigma W_T\right], \quad W_T \sim \mathcal{N}(0, T).$$

$\ln P_T \sim \mathcal{N}(\ln P_0 + (\mu - \sigma^2/2)T, \sigma^2 T) \Rightarrow P_T$ este **log-normal**.

Termenul $-\sigma^2/2$ este **pierderea din varianță** (*variance drag*): randamentul median < randamentul mediu.



Limitări ale GBM

GBM presupune volatilitate **constantă** și randamente **normal distribuite** — ignoră cozi groase, gruparea volatilității și efectul de levier.

Randamente cumulate

Definiție 6 (Randamente cumulate)

- **CSR** (Randament simplu cumulat) de la 0 la T : $CSR_T = \prod_{t=1}^T (1 + R_t) - 1$.
 - **CLR** (Randament logaritmic cumulat) de la 0 la T : $CLR_T = \sum_{t=1}^T r_t = \ln \frac{P_T}{P_0}$.
 - Relație: $CSR_T = e^{CLR_T} - 1$.
-
- CLR: sumă simplă, ușor de calculat.
 - CSR: necesită compunere (înmulțire).



Randamente anualizate

- Pentru a compara strategiile pe diferite orizonturi, randamentele sunt **anualizate**.
- **Anualizare geometrică** (preferată; ține cont de compunere):

$$\bar{R}_{\text{annual}}^{\text{geo}} = \left(\prod_{t=1}^T (1 + R_t) \right)^{252/T} - 1 = e^{\frac{252}{T} \cdot \text{CLR}_T} - 1.$$

- **Anualizare aritmetică** (aproximare simplă): $\bar{R}_{\text{annual}}^{\text{arith}} = \frac{252}{T} \sum_{t=1}^T r_t$.

Orizont	Factor geo.	Exemplu: medie 0,05%/zi
Zilnic → Anual (252 zile)	$(1 + \bar{R})^{252} - 1$	$(1.0005)^{252} - 1 = 13.3\%$
Lunar → Anual (12 luni)	$(1 + \bar{R})^{12} - 1$	$(1.0105)^{12} - 1 = 13.4\%$
Trim. → Anual (4 trim.)	$(1 + \bar{R})^4 - 1$	$(1.0327)^4 - 1 = 13.8\%$

- Randamentul aritmetic $>$ geometric cu aproximativ $\sigma^2/2$ per perioadă (pierderea din varianță).

Momentele randamentelor

- **Media** (primul moment) — randamentul așteptat:

$$\mu = \mathbb{E}[r_t], \quad \hat{\mu} = \frac{1}{n} \sum_{t=1}^n r_t.$$

- **Varianța** (al doilea moment central) — risc total:

$$\sigma^2 = \text{Var}(r_t) = \mathbb{E}[(r_t - \mu)^2], \quad \hat{\sigma}^2 = \frac{1}{n-1} \sum_{t=1}^n (r_t - \hat{\mu})^2.$$

- **Asimetria** (al treilea moment standardizat, *skewness*):

$$S = \frac{\mathbb{E}[(r_t - \mu)^3]}{\sigma^3}. \quad S < 0 \Rightarrow \text{coadă stângă mai grea (mai multe pierderi mari)}.$$


- **Kurtosis** (al patrulea moment standardizat):

$$K = \frac{\mathbb{E}[(r_t - \mu)^4]}{\sigma^4}. \quad K > 3 \Rightarrow \text{leptokurtic (cozi mai groase decât Distribuția Normală)}.$$

- **Excess kurtosis:** $\kappa = K - 3$; Normal $\Rightarrow \kappa = 0$.

Asimetrie și kurtosis: Interpretare

- ▣ **Normal:** $S = 0$, $K = 3$.
- ▣ **Asimetrie stângă** ($S < 0$): câștiguri mici frecvente, pierderi mari rare; tipic pentru *indici bursieri*.
- ▣ **Cozi groase** ($K > 3$): evenimente extreme mult mai probabile decât Distribuția Normală; universal în datele financiare.
- ▣ **Asimetrie dreaptă** ($S > 0$): câștiguri mari ocazionale; tipic pentru opțiuni call OTM (*out-of-the-money*).



Momente empirice: Exemplu

- Statistici eșantion pentru randamente logaritmice zilnice (aprox. 2015–2024):

Activ	Medie	Std	Asimetrie	Kurtosis	Min	Max
S&P 500	+0.040%	1.00%	−0.72	12.1	−12.8%	+9.4%
AAPL	+0.058%	1.80%	−0.31	8.6	−13.0%	+11.9%
Bitcoin	+0.195%	3.90%	−0.15	7.4	−46.5%	+22.5%
EUR/USD	+0.000%	0.45%	+0.08	5.2	−2.7%	+3.1%


- Toate activele: excess kurtosis $\gg 0$ (cozi groase confirmate).
- Acțiuni: asimetrie negativă (riscul de crah domină).
- BTC: volatilitate maximă; asimetrie negativă în ciuda narativului de asimetrie pozitivă.
- EUR/USD: medie aproape zero, aproape simetrică, dar cu cozi groase.

Drawdown-uri

Definiție 7 (Drawdown și MDD)

Drawdown la momentul t : $DD_t = \frac{P_t - \max_{s \leq t} P_s}{\max_{s \leq t} P_s} \leq 0$. MDD: $MDD = \min_{t \in [0, T]} DD_t$.

- ▣ MDD: cel mai mare declin de la maxim la minim din istorie.
- ▣ Metrică de risc cheie pentru strategiile de urmărire a tendinței.
- ▣ S&P 500 MDD: -56.8% (Oct 2007–Mar 2009).
- ▣ BTC MDD: -83% (Dec 2017–Dec 2018).
- ▣ Calmar ratio: $\bar{R}_{\text{annual}}/|MDD|$.



Cuprins

- ▣ Motivație ✓
- ▣ Date de preț ✓
- ▣ Randamente ✓
- ▣ **Fapte stilizate ale randamentelor financiare**
- ▣ Estimatori de volatilitate
- ▣ Comparație de eficiență
- ▣ Randamente ajustate la risc
- ▣ Caz AI / Rezumat / Quiz
- ▣ Bibliografie

Opriti-vă și gândiți-vă

(auto-evaluare)

Verificare rapidă — Randamente

1. Un activ crește cu 20% și apoi scade cu 20%. Randamentul total simplu este 0%? Dar cel logaritmic?
2. De ce log-randamentele sunt preferate în modelarea statistică?
3. Ce este „pierderea din varianță” (*variance drag*) și de ce contează pentru investitorii pe termen lung?

Răspunsuri

1. Nu! $100 \rightarrow 120 \rightarrow 96$, pierdere -4% . Log: $\ln(1,2) + \ln(0,8) = \ln(0,96) = -4,1\%$ ✓
2. Sunt **aditive în timp** ($r_{[0,T]} = \sum r_t$), simetrice, și nemărginite inferior.
3. $\mathbb{E}[\text{geom}] \approx \mathbb{E}[\text{aritm}] - \sigma^2/2$; volatilitate mare erodează randamentul compus.

Ipoteza pieței eficiente (EMH)

Definiție 8 (Ipoteza pieței eficiente (Fama, 1970))

- O piață este **eficientă informațional** dacă prețurile *reflectă complet* toată informația disponibilă.
- Trei forme:
 1. **Forma slabă**: prețurile reflectă toate *datele istorice de preț și volum*.
⇒ Analiza tehnică nu poate genera randamente excesive; $\text{Corr}(r_t, r_{t-k}) = 0$.
 2. **Forma semi-puternică**: prețurile reflectă toată *informația publică disponibilă*.
⇒ Analiza fundamentală nu poate genera randamente excesive; studiile de evenimente arată ajustare rapidă.
 3. **Forma puternică**: prețurile reflectă *toată* informația (inclusiv privată/insider).
⇒ Nici insiderii nu pot genera randamente excesive (încălcăată empiric).
- Faptele stilizate de mai jos arată **unde EMH eșuează**: absența autocorelației liniare susține eficiența slabă, dar gruparea volatilității și efectul de levier sugerează momente de ordin doi predictibile.

Fapte stilizate ale randamentelor financiare (*stylized facts*)

- Cont (2001) și Mandelbrot (1963) au identificat **regularități statistice universale** observate pe diferite piețe, instrumente și perioade de timp.
- 1. **Absența autocorelației liniare:** $\text{Corr}(r_t, r_{t-k}) \approx 0$ pentru $k \geq 1$.
- 2. **Cozi groase (*fat tails*):** excess kurtosis $K > 3$ în distribuțiile randamentelor.
- 3. **Asimetrie:** asimetrie negativă pentru randamentele acțiunilor.
- 4. **Gruparea volatilității (*volatility clustering*):** valorile mari ale $|r_t|$ tind să fie urmate de valori mari ale $|r_{t+1}|$.
- 5. **Efectul de levier (*leverage effect*):** randamentele negative cresc volatilitatea viitoare mai mult decât cele pozitive de aceeași magnitudine (Black, 1976).
- 6. **Normalitate prin agregare** (aggregational Gaussianity): randamentele se apropie de normalitate pe măsură ce scala temporală crește.
- 7. **Corelația volum-volatilitate:** volumul de tranzacționare și volatilitatea sunt corelate pozitiv.

Cozi groase și non-normalitate

- Sub $\mathcal{N}(\mu, \sigma^2)$, un eveniment de 5σ are prob. $\approx 2.87 \times 10^{-7}$.
- Black Monday** (19 Oct 1987): S&P 500 -20.5% într-o zi ($\approx 20\sigma$, prob. $\approx 10^{-89}$).

Magnitudinea evenimentului	Prob. Normală	Frecvență observată
Mișcare $> 3\sigma$	0,27% (1 la 370 zile)	~ 1 la 50–100 zile
Mișcare $> 4\sigma$	0,0063% (1 la 16 000 zile)	~ 1 la 500–1000 zile
Mișcare $> 5\sigma$	1 la 3,5 mil. zile	~ 1 la 5000–10 000 zile

Concluzie


- Randamentele sunt **leptokurtice**: Distribuția Normală subestimează dramatic riscul de coadă. Empiric $\approx$ Student- t cu $\nu \in [4, 8]$.

Implicație practică

- VaR-ul sub normalitate **subestimează** pierderile extreme. Un model Normal ar fi spus că Black Monday nu se poate întâmpla niciodată.

Cozi groase: Ilustrație QQ-Plot


- Un QQ-plot: cuantilele eșantionului vs. cuantilele distribuției normale.
- Dacă distribuția este Normală: punctele cad pe linia de 45° exact.
- **Formă de S:** coada stângă sub linie (pierderi mai extreme), coada dreaptă deasupra (câștiguri mai extreme).
- **Cozi groase:** ambele capete deviază în sus/jos față de linie.
- Testul Jarque-Bera: $JB = \frac{n}{6}(S^2 + \frac{\kappa^2}{4}) \sim \chi^2_2$ sub H_0 .
- Testele Kolmogorov-Smirnov și Anderson-Darling sunt de asemenea folosite.



SFM_ch1_stylized_facts

Gruparea volatilității (Volatility Clustering)

- Mandelbrot (1963): “Schimbările mari tind să fie urmate de schimbări mari — de orice semn — iar schimbările mici tind să fie urmate de schimbări mici.”
- Formal: $\text{Corr}(r_t, r_{t-k}) \approx 0$ dar $\text{Corr}(|r_t|, |r_{t-k}|) > 0$ pentru $k = 1, 2, \dots$




- ACF a $|r_t|$: descreștere lentă (memorie lungă) $\Rightarrow$ motivează ARCH/GARCH.
- Implicație: „Volatilitatea este predictibilă, randamentele nu.”

Efectul de levier (*leverage effect*)

- Black (1976): un randament *negativ* crește volatilitatea viitoare *mai mult* decât unul pozitiv de aceeași magnitudine.
- Când prețul scade, datoria/capital propriu $\uparrow \Rightarrow$ risc mai mare.
- Formal: $\text{Corr}(r_t, \sigma_{t+1}^2) < 0$.

GJR-GARCH(1,1)

$$\sigma_t^2 = \omega + (\alpha + \gamma 1_{r_{t-1} < 0}) r_{t-1}^2 + \beta \sigma_{t-1}^2$$



Teorema Limită Centrală (TLC)


Teoremă 1 (Teorema Limită Centrală)

Fie $X_1, X_2, \dots, X_n$ variabile aleatoare i.i.d. cu $\mathbb{E}[X_i] = \mu$ și $\text{Var}(X_i) = \sigma^2 < \infty$. Atunci:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{când } n \rightarrow \infty.$$

- ▣ **Intuiție:** suma (sau media) unui număr mare de variabile aleatoare independente tinde spre Distribuția Normală, *indiferent* de distribuția originală.
- ▣ **Condiție cheie:** varianța finită ($\sigma^2 < \infty$). Eșuează pentru distribuții Pareto-stabile ($\alpha < 2$).
- ▣ **Viteză de convergență** (Berry-Esseen): $\sup_x |F_n(x) - \Phi(x)| \leq \frac{C \mathbb{E}[|X_1 - \mu|^3]}{\sigma^3 \sqrt{n}}$, cu $C \leq 0.4748$.
- ▣ **Relevanță financiară:** randamentele pe k zile = $\sum_{j=1}^k r_j$ — TLC justifică aproximarea normală pentru orizonturi mai lungi.


TLC: Convergența vizuală



- Pe măsură ce n crește, distribuția sumelor standardizate se apropie de curba normală (linia roșie), indiferent de distribuția inițială.


Normalitate prin agregare (aggregational Gaussianity)

- ▣ **Zilnic:** cozi foarte groase, excess kurtosis $\approx 5-20$.
- ▣ **Săptămânal:** kurtosis redus, mai puține valori aberante extreme.
- ▣ **Lunar:** aproximativ normală prin Teorema Limită Centrală (TLC).
- ▣ TLC: $r_t^{(k)} = \sum_{j=0}^{k-1} r_{t-j} \xrightarrow{d} \mathcal{N}$ când $k \rightarrow \infty$, sub condiții slabe ($\sigma^2 < \infty$).
- ▣ **Caveat:**
 - ▶ Convergența este *lentă* pentru distribuțiile Pareto-stabile
 - ▶ Distribuțiile cu varianță infinită nu converg niciodată la Distribuția Normală



Corelația volum-volatilitate

- ▣ **Fapt empiric:** volumul V_t și $|r_t|$ sunt corelate pozitiv.
- ▣ **MDH** (*Mixture of Distributions Hypothesis*, Clark 1973; Tauchen & Pitts 1983): ambele determinate de fluxul informațional latent.
- ▣ **Sosire secvențială** (Copeland 1976): traderii învață secvențial.
- ▣ Modelele GARCH augmentate cu volum depășesc GARCH standard.



De la fapte stilizate la modele

Fapt stilizat	Implicație pentru modelare	Capitol
Cozi groase (fat tails)	Distribuția Student- t , Pareto-stabile	Cap. 2
Gruparea volatilității	GARCH, EGARCH	Cap. 5
Efect de levier	GJR-GARCH, EGARCH asimetric	Cap. 5
Absența autocorelației în r_t	EMH forma slabă; randamente $\approx$ MDS	Cap. 3
Autocorelație în r_t și r_t^2	Memorie lungă, FIGARCH	Cap. 5
Normalitate prin agregare	TLC; modele cu varianță finită	Cap. 2
Corelație volum-volatilitate	MDH, modele GARCH cu volum	Cap. 5

Concluzie

- Faptele stilizate nu sunt doar curiozități empirice — ele **ghidează** alegerea modelului statistic. Un model bun trebuie să reproducă aceste regularități.

Cuprins

- ▣ Motivație ✓
- ▣ Date de preț ✓
- ▣ Randamente ✓
- ▣ Fapte stilizate ale randamentelor financiare ✓
- ▣ **Estimatori de volatilitate**
- ▣ Comparație de eficiență
- ▣ Randamente ajustate la risc
- ▣ Caz AI / Rezumat / Quiz
- ▣ Bibliografie

Partea II

Estimatori de Volatilitate, Eficiență și Performanță

— Secțiunile 5–8 —

Volatilitatea: Conceptul central

Definiție 9 (Volatilitate)

- ▣ Gradul de variație al unei serii de prețuri de tranzacționare în timp
- ▣ Măsurată prin **abaterea standard** (sau varianța) randamentelor
- ▣ Este o **variabilă latentă**: neobservabilă direct, doar estimabilă

Estimator	Date utilizate	RE vs. CC	Referință cheie
Close-to-Close (CC)	doar C_t	1.0	Statistică clasică
Parkinson (P)	H_t, L_t	5.2	Parkinson (1980)
Garman-Klass (GK)	O_t, H_t, L_t, C_t	7.4	Garman & Klass (1980)
Rogers-Satchell (RS)	O_t, H_t, L_t, C_t	8.0	Rogers & Satchell (1991)
Yang-Zhang (YZ)	O_t, H_t, L_t, C_t	14.0	Yang & Zhang (2000)
Realized Vol (RV)	Tick-uri intra-zilnice	$\gg 14$	Andersen & Bollerslev (1998)

Tipuri de volatilitate: Taxonomie

Tip	Sursa datelor	Ce măsoară	Când folosim	Exemplu
Istorică (necondițională)	Prețuri trecute (C_t sau OHLC)	Vol. medie pe termen lung	Evaluare pe termen lung	CC, rolling 252 zile
Condițională	Randamente + model	Vol. variabilă în timp	Risc pe termen scurt	GARCH, EWMA
Realizată	Randamente intrazilnice	Vol. zilnică reală	Benchmark de aur	RV cu date la 5 min
Implicită	Prețuri de opțiuni	Așteptarea pieței	Tranzacționare opțiuni	VIX, IV surface

De reținut

- Volatilitatea istorică privește **în trecut**, cea condițională estimează **azi**, cea implicită estimează **viitorul**. Fiecare răspunde la o altă întrebare.

Volatilitate istorică (Estimatorul Close-to-Close)

Definiție 10 (Volatilitate istorică)


- Estimatorul standard bazat pe n randamente logaritmice:

$$\hat{\sigma}_{CC} = \sqrt{\frac{1}{n-1} \sum_{t=1}^n (r_t - \bar{r})^2}, \quad \bar{r} = \frac{1}{n} \sum_{t=1}^n r_t.$$

- Aceasta este pur și simplu abaterea standard eșantion a randamentelor logaritmice.
- Anualizare:** $\hat{\sigma}_{\text{annual}} = \hat{\sigma}_{\text{daily}} \times \sqrt{252}$.
- Avantaje:** simplu, intuitiv, necesită doar prețuri de închidere.
- Limitări:** ignoră informațiile intra-zilnice (O, H, L); ponderează egal toate observațiile; sensibil la lungimea ferestrei n ; întârzie schimbările de regim.

Volatilitate istorică: Estimare rolling

- O fereastră glisantă de n zile oferă o estimare a volatilității variabilă în timp.
- Alegeri uzuale: $n = 20$ zile (termen scurt), $n = 60$ zile (termen mediu).



- Clusterele de volatilitate sunt clar vizibile în estimările rolling.
- Lungimea ferestrei: scurtă → zgomotoasă; lungă → depășită.

Regula rădăcinii pătrate a timpului (*Square Root of Time Rule*)

Teoremă 2

Dacă $r_1, r_2, \dots$ sunt i.i.d. cu $\text{Var}(r_t) = \sigma_1^2$, atunci $\sigma_T = \sigma_1 \sqrt{T}$.

▣ **Dem.** $\text{Var}(\sum_{t=1}^T r_t) = T\sigma_1^2 \Rightarrow \text{SD} = \sigma_1 \sqrt{T}$. □

▣ **Scalare:** $\sigma_{\text{annual}} = \sigma_{\text{daily}} \times \sqrt{252}$; $\sigma_{\text{monthly}} = \sigma_{\text{daily}} \times \sqrt{22}$; $\sigma_{\text{weekly}} = \sigma_{\text{daily}} \times \sqrt{5}$.

Când eșuează regula?

Presupune randamente necorelate cu varianță finită. Eșuează când:

- ▣ Randamente **autocorelate** ($\rho > 0 \Rightarrow \text{vol reală} > \text{estimare}$)
- ▣ Volatilitate **variabilă în timp** (efecte GARCH)
- ▣ **Varianță infinită** (Pareto-stabile)


Rădăcina pătrată a timpului: Exemplu numeric

Example 3

Volatilitatea zilnică $\hat{\sigma}_{\text{daily}} = 1.2\%$.

Orizont	$\sqrt{T}$	Vol
1 zi	1.0	1.2%
1 săpt.	2.2	2.7%
1 lună	4.7	5.6%
1 trim.	7.9	9.5%
1 an	15.9	19.1%

□ Cu autocorelație AR(1) $\rho > 0$: $\sigma_T^2 = T\sigma_1^2 \left[1 + 2 \sum_{k=1}^{T-1} (1 - k/T)\rho^k \right] > T\sigma_1^2$.



Mini-exercițiu: Anualizarea volatilității

Exercițiu pe slide

Dacă $\sigma_{\text{daily}} = 1.5\%$, calculați:

1. σ_{weekly} (5 zile) =?
2. σ_{monthly} (22 zile) =?
3. σ_{annual} (252 zile) =?

Rezolvare

1. $\sigma_{\text{weekly}} = 1.5\% \times \sqrt{5} = 1.5\% \times 2.236 = 3.35\%$
2. $\sigma_{\text{monthly}} = 1.5\% \times \sqrt{22} = 1.5\% \times 4.690 = 7.04\%$
3. $\sigma_{\text{annual}} = 1.5\% \times \sqrt{252} = 1.5\% \times 15.875 = 23.81\%$

Atenție

- ☐ Aceste calcule presupun randamente i.i.d. — validați mereu ipoteza înainte de a aplica regula $\sqrt{T}$.

Estimatorul Parkinson (1980)

Definiție 11 (Estimatorul Parkinson)

- Utilizând doar prețurile maxim și minim:

$$\hat{\sigma}_P^2 = \frac{1}{4n \ln 2} \sum_{t=1}^n \left(\ln \frac{H_t}{L_t} \right)^2.$$

- Derivare.** Sub GBM (*Geometric Brownian Motion*) cu $\mu = 0$: $\mathbb{E}[(\ln H/L)^2] = 4\sigma^2 \ln 2$, deci $1/(4 \ln 2) \approx 0.361$.

Avantaje

- 5,2× mai eficient decât CC
- Utilizează informația de range intraday
- Formulă simplă, ușor de calculat

Limitări

- Presupune GBM cu drift zero
- Presupune tranzacționare continuă (fără salturi)
- Distorsionată în jos dacă H/L reale nu sunt observate

Estimatorul Garman-Klass (1980)

Definiție 12 (Estimatorul Garman-Klass)

- Utilizând toate cele patru prețuri OHLC (GBM cu drift zero):

$$\hat{\sigma}_{\text{GK}}^2 = \frac{1}{n} \sum_{t=1}^n \left[0.5 \left(\ln \frac{H_t}{L_t} \right)^2 - (2 \ln 2 - 1) \left(\ln \frac{C_t}{O_t} \right)^2 \right].$$

- Derivare:** descompune varianța totală în componentele interval (*range*) + închidere-deschidere; minimizează varianța estimatorului.
- Eficiență:** $\approx 7.4 \times$ mai eficient decât CC.
- Limitare:** presupune $\mu = 0$; distorsionată pe piețe în trend.

Avantaje

- Cea mai bună eficiență cu drift zero
- Utilizează informația de range și O-to-C

Limitări

- Distorsionată pe piețe cu trend
- Gap-urile overnight introduc bias

Estimatorul Rogers-Satchell (1991)

Definiție 13 (Estimatorul Rogers-Satchell)

- Estimatorul RS **permite drift nenul**:

$$\hat{\sigma}_{\text{RS}}^2 = \frac{1}{n} \sum_{t=1}^n \left[\ln \frac{H_t}{C_t} \cdot \ln \frac{H_t}{O_t} + \ln \frac{L_t}{C_t} \cdot \ln \frac{L_t}{O_t} \right].$$

Proprietăți cheie

- Independent de drift**: nedeplasată cu $\mu \neq 0$
- Performanță bună pe piețe cu trend
- $\approx 8 \times$ mai eficient decât CC

Aplicații


- Piețe emergente (Öztürk et al., 2016)
- Criptomonedă (Cadenas-Morales, 2022)
- Presupune**: tranzacționare continuă, fără salturi

Estimatorul Yang-Zhang (2000)

Definiție 14 (Estimatorul Yang-Zhang)


- ▣ Combină componentele overnight, open-to-close și Rogers-Satchell: $\hat{\sigma}_{YZ} = \sqrt{\hat{\sigma}_O^2 + k \hat{\sigma}_C^2 + (1 - k) \hat{\sigma}_{RS}^2}$
- ▣ $\alpha = 1.34$ constanta optimală (Yang & Zhang, 2000)
- ▣ $k = (\alpha - 1) / (\alpha + (T + 1) / (T - 1)) \approx 0.14$ pentru T tipic
- ▣ $\hat{\sigma}_O^2$: **overnight variance** $= \frac{1}{T-1} \sum_{t=1}^T \left(\ln \frac{O_t}{C_{t-1}} - \overline{\ln \frac{O_t}{C_{t-1}}} \right)^2$.
- ▣ $\hat{\sigma}_C^2$: **open-to-close variance** $= \frac{1}{T-1} \sum_{t=1}^T \left(\ln \frac{C_t}{O_t} - \overline{\ln \frac{C_t}{O_t}} \right)^2$.
- ▣ $\hat{\sigma}_{RS}^2$: componenta Rogers-Satchell.
- ▣ $14 \times$ **mai eficient** decât CC; gestionează drift și salturi overnight.
- ▣ Cel mai bun estimator general pentru date OHLC zilnice.

Estimatori de volatilitate: Comparație vizuală (AAPL 2018–2024)



- Range-based (P, GK, RS) sunt mai netezi decât CC; YZ combină overnight + intraday.
- În criză (2020) toate captează vârful, dar cu magnitudini diferite.

Estimatori de volatilitate: Comparație numerică (AAPL 2020–2024)



- Range-based (P, GK, RS) produc volatilitate **mai mică** decât CC — extrag mai multă informație.
- YZ combină overnight + intraday; diferențele cresc pe piețe volatile cu gap-uri mari.

SFM_ch1_vol_comparison

Volatilitatea EWMA

- ▣ $\hat{\sigma}_t^2 = \lambda \hat{\sigma}_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, $\lambda = 0.94$.
- ▣ Ponderea la lag-ul k : $(1 - \lambda)\lambda^k$ (descreștere exponențială).
- ▣ $\lambda = 0.94$: fereastră efectivă $\approx 16,7$ zile.
- ▣ **Avantaje**: reacționează rapid; fără fereastră fixă; ușor de actualizat.
- ▣ **Dezavantaje**: fără revenire la medie; λ stabilit extern.



Volatilitatea realizată

Definiție 15 (Volatilitate realizată)

- ▣ Date fiind m randamente logaritmice intrazilnice la frecvența $\Delta = 1/m$:


$$RV_t = \sum_{j=1}^m r_{t,j}^2, \quad r_{t,j} = \ln P_{t,j} - \ln P_{t,j-1}.$$

- ▣ **Consistență:** $RV_t \xrightarrow{P} \int_0^1 \sigma_t^2(s) ds$ când $m \rightarrow \infty$ (Andersen & Bollerslev, 1998).
- ▣ În practică: eşantionare la fiecare 5 minute ($m \approx 78$ pentru acțiuni SUA).
- ▣ **Abaterea standard realizată:** $RSD_t = \sqrt{RV_t}$.
- ▣ **Zgomot de microstructură:** saltul bid-ask contaminează estimările la frecvențe foarte înalte.

Graficul semnăturii volatilității

- ▣ Trasați RV vs. frecvența de eşantionare Δ . La frecvențe foarte înalte, RV diverge din cauza zgomotului de microstructură. Frecvența optimă echilibrează precizia și biasul de zgomot.


Graficul semnăturii volatilității



- La frecvențe înalte ($\Delta < 5$ min), bid-ask bounce umflă RV.
- La frecvențe joase, RV este nedepășată dar imprecisă (puține observații).
- Eșantionare optimă: ≈ 5 min echilibrează biasul și varianța (Bandi & Russell, 2008).

Estimatori de volatilitate: Graficul comparației de eficiență

- RE (Eficiență relativă) = $\text{Var}(\hat{\sigma}_{CC}^2) / \text{Var}(\hat{\sigma}^2)$.
- RE > 1: varianță mai mică decât benchmark-ul CC.
- Utilizarea OHLC vs. doar C: până la 14× mai multă informație.
- YZ este cel mai bun estimator utilizând doar date OHLC zilnice.
- Intrazilic (RV): eficiență teoretic nelimitată când $\Delta \rightarrow 0$ (dacă microstructura permite).



Volatilitate condițională vs. necondițională

Volatilitate necondițională

- Volatilitatea medie pe termen lung:

$$\sigma^2 = \text{Var}(r_t).$$

- Estimată prin estimatorul CC istoric pe o fereastră lungă.
- Constantă în timp: presupune staționaritate.
- Utilă pentru: evaluarea opțiunilor (termen lung), capital regulatoriu (Basel).

- GARCH(1,1)** (Bollerslev 1986): $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$. Varianța pe termen lung (necondițională): $\bar{\sigma}^2 = \omega / (1 - \alpha - \beta)$.
- Capitolul 5 acoperă modelele GARCH în detaliu.

Volatilitate condițională

- Variabilă în timp, dată informația până la $t - 1$:

$$\sigma_t^2 = \text{Var}(r_t | \mathcal{F}_{t-1}).$$

- Modelată prin ARCH/GARCH, volatilitate stochastică.
- Captează gruparea volatilității.
- Utilă pentru: riscul pe termen scurt, hedging opțiuni (delta), VaR.

De ce volatilitatea nu este risc complet

Ce captează volatilitatea:

- ▣ Variabilitatea medie a randamentelor
- ▣ Dimensiunea fluctuațiilor tipice
- ▣ Baza pentru Sharpe ratio și VaR parametric

Ce NU captează:

- ▣ **Crash risk:** pierderi catastrofale
- ▣ **Tail risk:** evenimente extreme ($> 3\sigma$)
- ▣ **Skewness:** asimetria distribuției
- ▣ **Drawdown:** cât poți pierde de la maxim


Exemplu ilustrativ: Două active cu $\sigma = 20\%$:

- ▣ **X:** Skewness = 0, $K = 3$ (Normală) — mișcări $> 3\sigma$: 1/370 zile
- ▣ **Y:** Skewness = -1.5 , $K = 10$ — mișcări $> 3\sigma$: 1/50 zile
- ▣ Aceeași σ , **risc real complet diferit!**

Concluzie

- ▣ Volatilitatea este *necesară dar insuficientă*. Completați cu skewness, kurtosis, MDD și VaR/CVaR.

Volatilitate condițională vs. necondițională: Exemplu AAPL



- **GARCH(1,1)** urmărește gruparea volatilității în timp real.
- Estimarea rolling pe 30 de zile este mai netedă dar rămâne în urmă față de schimbările bruște.
- Nivelul necondițional = media pe termen lung în jurul căreia σ_t fluctuează.

Cuprins

- ▣ Motivație ✓
- ▣ Date de preț ✓
- ▣ Randamente ✓
- ▣ Fapte stilizate ale randamentelor financiare ✓
- ▣ Estimatori de volatilitate ✓
- ▣ **Comparație de eficiență**
- ▣ Randamente ajustate la risc
- ▣ Caz AI / Rezumat / Quiz
- ▣ Bibliografie

Opriti-vă și gândiți-vă

(auto-evaluare)

Verificare rapidă — Estimatori de volatilitate

1. Estimatorul Parkinson folosește doar H_t și L_t . De ce este mai eficient decât close-to-close?
2. Estimatorul Yang-Zhang combină overnight + open-to-close + range. Când este cel mai avantajos?
3. Regula $\sigma_T = \sigma_1 \sqrt{T}$ presupune randamente i.i.d. Ce se întâmplă dacă există autocorelație pozitivă?

Răspunsuri

1. Range-ul ($H - L$) conține informație despre traiectoria intra-zilnică, nu doar punctul final.
2. Când există **salt overnight** semnificativ (e.g. earnings, macro news).
3. Volatilitatea anuală este **mai mare** decât $\sigma\sqrt{252}$: $\sigma_T^2 = T\sigma^2(1 + 2\sum \rho_k)$.

Eficiența estimatorilor de volatilitate

- ▣ **Eficiență relativă:** $RE = \text{Var}(\hat{\sigma}_{CC}^2) / \text{Var}(\hat{\sigma}^2)$. $RE > 1$ înseamnă varianță mai mică decât CC.
- ▣ **Interpretare intuitivă:** „Dacă $RE = 5$, înseamnă că avem nevoie de $5 \times$ mai puține date pentru aceeași precizie.” Sau echivalent: cu aceeași cantitate de date, estimarea este de $5 \times$ mai precisă.

Estimator	RE vs. CC	Ind. de drift?	Robust salturi?	Date
Close-to-Close	1.0	Nu	Nu	C
Parkinson	5.2	Da ($\mu = 0$)	Nu	H, L
Garman-Klass	7.4	Da ($\mu = 0$)	Nu	O, H, L, C
Rogers-Satchell	8.0	Permite drift	Nu	O, H, L, C
Yang-Zhang	14.0	Permite drift	Parțial	O, H, L, C
Realized Vol	$\gg 14$	Da	Extensii	Intrazilnice

- ▣ Toți estimatorii bazați pe interval presupun **tranzacționare continuă și fără salturi de preț**.
- ▣ În practică, sunt disponibile extensii robuste la salturi (bipower variation, Christensen & Podolskij 2007).
- ▣ Gap-urile overnight încalcă ipoteza de tranzacționare continuă pentru GK, Parkinson.

Considerații practice

Când folosim care?

- ▣ **CC**: doar prețuri de închidere disponibile.
- ▣ **Parkinson**: estimare rapidă de interval; piețe fără drift.
- ▣ **GK**: cea mai bună eficiență când drift ≈ 0 .
- ▣ **RS**: piețe în trend, drift semnificativ.
- ▣ **YZ**: cel mai bun estimator general pentru OHLC zilnic.
- ▣ **RV**: date intra-zilnice; standardul de aur.

Capcane frecvente

- ▣ GK/Parkinson pe date în trend $\Rightarrow$ distorsionat în jos.
- ▣ Ignorarea gap-urilor overnight $\Rightarrow$ subestimează vol totală.
- ▣ Fereastră prea scurtă $\Rightarrow$ zgomotoasă; prea lungă $\Rightarrow$ depășită.
- ▣ Prețuri neajustate $\Rightarrow$ salturi false la datele dividendelor.

Regulă practică

- ▣ 20–30z: termen scurt; 60–90z: termen mediu; 252z: anual.

Cuprins

- ▣ Motivație ✓
- ▣ Date de preț ✓
- ▣ Randamente ✓
- ▣ Fapte stilizate ale randamentelor financiare ✓
- ▣ Estimatori de volatilitate ✓
- ▣ Comparație de eficiență ✓
- ▣ **Randamente ajustate la risc**
- ▣ Caz AI / Rezumat / Quiz
- ▣ Bibliografie

Indicatorul Sharpe

Definiție 16 (Indicatorul Sharpe)

- Randament excesiv pe unitate de risc total:

$$SR = \frac{\bar{R}_p - R_f}{\sigma_p}.$$

- S&P 500: $SR \approx 0.4-0.5$ (anual).
- SR mai mare $\nrightarrow$ performanță viitoare superioară.
- Presupune normalitate; eșuează pentru randamente asimetrice.

Valoare SR	Interpretare
$SR < 0$	Sub rata fără risc
$0 \leq SR < 1$	Acceptabil
$1 \leq SR < 2$	Bun
$SR \geq 2$	Excelent (rar)

 SFM_ch1_sharpe_ratio

Limitări ale indicatorului Sharpe

Limitări

- ▣ **Penalizează și volatilitatea pozitivă** — nu diferențiază câștiguri de pierderi
- ▣ **Nu capturează asimetria (skew)** — pierderi rare dar catastrofale $\Rightarrow$ SR bun
- ▣ **Ignoră drawdown-ul** — nu spune nimic despre cel mai rău scenariu
- ▣ **Nu capturează riscul de coadă** — SR ridicat nu înseamnă lipsă de tail risk
- ▣ **Eroare de estimare mare** — Lo (2002): $SE(\widehat{SR}) \approx \sqrt{(1 + SR^2/2)/n}$. Ex.: cu $SR = 0.5$ și $n = 60$ luni, $SE \approx 0.13$, deci intervalul de încredere 95% este $[0.24, 0.76]$ — foarte larg!

Indicatorul Sharpe: Exemplu numeric

Example 4

Două fonduri, $R_f = 2\%$ pe an. Care oferă un randament ajustat la risc mai bun?

Fond	$\bar{R}_p$	σ_p	$\bar{R}_p - R_f$	SR
Fond A	12%	18%	10%	$10/18 = 0,556$
Fond B	8%	9%	6%	$6/9 = 0,667$

- Fondul B: randament absolut mai mic dar indicator Sharpe mai mare.
- Investitorul avers la risc preferă Fondul B (recompensă mai bună per unitate de risc).
- Fondul A necesită $18 \times 0.667 + 2 = 14\%$ randament pentru a egala SR-ul Fondului B.

Anualizarea SR

- Din date zilnice: $SR_{\text{annual}} = SR_{\text{daily}} \times \sqrt{252}$.

Alte măsuri ajustate la risc (I)

- **Sortino Ratio:** utilizează deviația descendentă σ_D sub un prag τ (de obicei R_f sau 0):

$$\text{Sortino} = \frac{\bar{R}_p - \tau}{\sigma_D}, \quad \sigma_D = \sqrt{\frac{1}{n} \sum_{t=1}^n [\min(R_t - \tau, 0)]^2}.$$

Preferat când distribuția randamentelor este asimetrică (opțiuni long, fonduri speculative).

Notă: unii autori utilizează $1/n_-$ (doar observațiile negative) în loc de $1/n$ la numitor, ceea ce produce valori mai mari ale σ_D .

- **Raportul informațional (IR):** randament activ vs. eroare de urmărire față de benchmark B :

$$\text{IR} = \frac{\bar{R}_p - \bar{R}_B}{\text{TE}}, \quad \text{TE} = \text{std}(R_p - R_B).$$

- **Calmar Ratio:** randament raportat la drawdown-ul maxim:

$$\text{Calmar} = \frac{\bar{R}_{\text{annual}}}{|\text{MDD}|}.$$

Alte măsuri ajustate la risc (II)

- ▣ **Treynor Ratio**: randament excesiv pe unitate de risc *sistematic*:

$$\text{Treynor} = \frac{\bar{R}_p - R_f}{\beta_p}, \quad \beta_p = \text{Cov}(R_p, R_m) / \text{Var}(R_m).$$

- ▣ **Omega Ratio** (Keating & Shadwick, 2002): raportul câștigurilor ponderate deasupra pragului τ la pierderile de sub τ :

$$\Omega(\tau) = \frac{\int_{\tau}^{\infty} [1 - F(r)] dr}{\int_{-\infty}^{\tau} F(r) dr}, \quad F = \text{CDF a randamentelor}.$$

Interpretare: $\Omega > 1$ distribuție favorabilă; $\Omega < 1$ nefavorabilă. Captează *întreaga* distribuție, nu doar primele momente.

Volatilitatea portofoliului

- Pentru un portofoliu cu două active cu ponderile $w_X + w_Y = 1$:

$$\sigma_P^2 = w_X^2 \sigma_X^2 + w_Y^2 \sigma_Y^2 + 2w_X w_Y \rho_{XY} \sigma_X \sigma_Y.$$

- **Beneficiul diversificării:** când $\rho_{XY} < 1$, varianța portofoliului $<$ varianța medie ponderată.
- Beneficiu maxim când $\rho_{XY} = -1$ (corelație negativă perfectă).

Example 5

$w_X = 0.6$, $w_Y = 0.4$; $\sigma_X = 20\%$, $\sigma_Y = 30\%$; $\rho = 0.3$.

$$\begin{aligned}\sigma_P^2 &= (0.6)^2 (0.20)^2 + (0.4)^2 (0.30)^2 + 2(0.6)(0.4)(0.3)(0.20)(0.30) \\ &= 0.0144 + 0.0144 + 0.00864 = 0.03744. \quad \sigma_P = 19.35\%.\end{aligned}$$

Medie ponderată: $0.6 \times 20\% + 0.4 \times 30\% = 24\%$. Diversificarea economisește $\approx 4.65\%$ din volatilitate.

Exemplu: Portofoliu cu 3 active

Example 6

Trei active cu $\sigma_1 = 20\%$, $\sigma_2 = 25\%$, $\sigma_3 = 15\%$ și matricea de corelație:

$$\rho = \begin{pmatrix} 1 & 0.3 & 0.1 \\ 0.3 & 1 & 0.25 \\ 0.1 & 0.25 & 1 \end{pmatrix}, \quad w = \left(\frac{1}{3}, \frac{1}{3}, \frac{1}{3}\right).$$

▣ Formula generală: $\sigma_P^2 = w' \Sigma w = \sum_i \sum_j w_i w_j \rho_{ij} \sigma_i \sigma_j$.

▣ Calculul:

$$\begin{aligned} \sigma_P^2 &= \frac{1}{9} [\sigma_1^2 + \sigma_2^2 + \sigma_3^2 + 2\rho_{12}\sigma_1\sigma_2 + 2\rho_{13}\sigma_1\sigma_3 + 2\rho_{23}\sigma_2\sigma_3] \\ &= \frac{1}{9} [0.04 + 0.0625 + 0.0225 + 2(0.3)(0.05) + 2(0.1)(0.03) + 2(0.25)(0.0375)] \\ &= \frac{1}{9} [0.125 + 0.03 + 0.006 + 0.01875] = \frac{0.17975}{9} = 0.01997. \end{aligned}$$


▣ $\sigma_P = \sqrt{0.01997} = 14.13\%$.

▣ Media ponderată: $\frac{1}{3}(20\% + 25\% + 15\%) = 20\%$.

▣ **Beneficiu diversificării:** $20\% - 14.13\% \approx 5.87\%$ economie de volatilitate.

Frontiera eficientă

- **Frontiera eficientă** (*efficient frontier*): mulțimea portofoliilor cu randament așteptat maxim pentru o volatilitate dată (Markowitz 1952).
- **MVP**: portofoliul cu varianță minimă — cel mai mic σ_P .
- **Portofoliul tangent** (*tangency portfolio*): portofoliul de pe frontieră cu cel mai mare indicator Sharpe.
- **Linia pieței de capital** (CML): combinații de R_f și portofoliul tangent.
- Toți investitorii raționali dețin o combinație de R_f și portofoliul tangent (Teorema separației, Tobin 1958).



Markowitz vs. Linia Pieței de Capital

Fără activ fără risc (Markowitz)

- ▣ Mulțimea fezabilă: **curba tip glonț** (*bullet curve*) în planul $(\sigma, \mathbb{E}[R])$
- ▣ Frontiera eficientă: porțiunea superioară a curbei, deasupra MVP
- ▣ Fiecare investitor alege un portofoliu **diferit** pe frontieră, în funcție de aversiunea la risc
- ▣ Nu există un portofoliu *universal* optim

Cu activ fără risc (Tobin)

- ▣ CML: linie dreaptă de la R_f tangentă la frontieră
- ▣ Portofoliul tangent T este **unic** și optim pentru toți investitorii
- ▣ Teorema separării în două fonduri: orice portofoliu eficient = combinație de R_f și T
- ▣ Aversiunea la risc determină doar **ponderea** în T , nu compoziția

Concluzie

- ▣ Introducerea activului fără risc **simplifică radical** alegerea: de la o curbă (infinitate de portofolii eficiente) la un singur punct (portofoliul tangent) plus o decizie de levier.

Portofoliul cu varianță minimă (MVP)

- ▣ **Problema de optimizare medie-varianță** (Markowitz, 1952):

$$\min_w w' \Sigma w \quad \text{s.t.} \quad w' \mu = \mu_{\text{target}}, \quad w' \mathbf{1} = 1.$$

- ▣ **MVP global** (fără constrângere de randament țintă):

$$w_{\text{MVP}} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}' \Sigma^{-1} \mathbf{1}}, \quad \sigma_{\text{MVP}}^2 = \frac{1}{\mathbf{1}' \Sigma^{-1} \mathbf{1}}.$$

- ▣ MVP depinde *doar* de matricea de covarianță Σ , nu de randamentele așteptate μ .
- ▣ Acest lucru îl face mai robust în practică, deoarece μ este notoriu greu de estimat (Merton, 1980).
- ▣ Frontiera eficientă este ramura superioară a “glonțului” trasată variind μ_{target} de la μ_{MVP} la $\max(\mu)$.

Teorema separării cu două fonduri (Two-Fund Separation)

Teoremă 3 (Tobin, 1958)

Orice portofoliu eficient poate fi exprimat ca o combinație liniară a doar două portofolii de pe frontiera eficientă.

- ▣ **Fără activ fără risc:** fiecare investitor alege pe frontieră în funcție de toleranța sa la risc. Toate alegerile eficiente sunt amestecuri ale acelorași două “fonduri mutuale.”
- ▣ **Cu activ fără risc R_f :** frontiera se reduce la **Capital Market Line (CML)**:

$$E[R_P] = R_f + \frac{E[R_T] - R_f}{\sigma_T} \sigma_P,$$

unde T = **portofoliul tangent** (cel cu Sharpe maxim).

- ▣ **Consecință:** toți investitorii dețin *același* portofoliu riscant T ; diferă doar proporția investită în R_f (levier sau de-levier).
- ▣ **Implicație practică:** portofoliul de piață $\approx T \Rightarrow$ baza teoretică a **investiției pasive în indici**.

Cuprins

- ▣ Motivație ✓
- ▣ Date de preț ✓
- ▣ Randamente ✓
- ▣ Fapte stilizate ale randamentelor financiare ✓
- ▣ Estimatori de volatilitate ✓
- ▣ Comparație de eficiență ✓
- ▣ Randamente ajustate la risc ✓
- ▣ **Caz de utilizare AI**
- ▣ Rezumat
- ▣ Quiz
- ▣ Bibliografie

Opriți-vă și gândiți-vă

(auto-evaluare)

Verificare rapidă — Performanță ajustată la risc

1. Fond A: $\bar{R} = 20\%$, $\sigma = 30\%$. Fond B: $\bar{R} = 10\%$, $\sigma = 8\%$. Cu $R_f = 3\%$, care are Sharpe mai bun?
2. De ce Sortino este adesea preferat Sharpe pentru fonduri cu randamente asimetrice?
3. Maximum Drawdown = -45% . Ce informație aduce aceasta pe care σ nu o oferă?

Răspunsuri

1. $SR_A = 17/30 = 0,57$; $SR_B = 7/8 = 0,88$. Fondul B, deși cu randament mai mic!
2. Sortino penalizează doar volatilitatea descendentă (σ_{down}), nu și pe cea ascendentă.
3. MDD arată **cel mai rău scenariu real** trăit de investitor — σ nu surprinde persistența pierderilor.

Exercițiu AI: Gândire critică

Prompt de testat în ChatGPT / Claude / Copilot

“Descarcă datele zilnice OHLC pentru AAPL 2020–2024 folosind Python (yfinance). Calculează toți cei cinci estimatori de volatilitate (CC, Parkinson, Garman-Klass, Rogers-Satchell, Yang-Zhang) folosind o fereastră rolling de 30 de zile. Reprezintă-i pe același grafic și calculează estimările anualizate pe întregul eșantion. De asemenea, estimează un model GARCH(1,1) și suprapune volatilitatea condițională. Discută care estimator este cel mai fiabil.”

Exercițiu:

1. AI-ul folosește formula corectă pentru fiecare estimator? Verifică cu notele de curs.
2. Sunt clasamentele de eficiență (rapoartele RE) consistente cu teoria?
3. Volatilitatea condițională GARCH urmărește gruparea volatilității mai bine decât estimările rolling?
4. Întreabă AI-ul: “Ce se întâmplă dacă acțiunea are gap-uri overnight?” Menționează Yang-Zhang?
5. Re-rulează cu date BTC-USD. Se schimbă clasamentul estimatorilor? De ce?

☐ **Atenție:** AI-ul confundă adesea formula Rogers-Satchell. Verificați mereu cu $\ln(H/C) \cdot \ln(H/O) + \ln(L/C) \cdot \ln(L/O)$.

Exercițiu AI: Analiza randamentelor

Prompt de testat în ChatGPT / Claude / Copilot

“Descarcă datele zilnice pentru AAPL și MSFT din 2020 până în 2024 folosind Python (yfinance). Calculează randamentele simple R_t și logaritmice r_t pentru ambele acțiuni. Compară grafic cele două serii de randamente (overlay pe același grafic). Verifică numeric relația $\bar{R} - \bar{r} \approx \sigma^2/2$ (variance drag).”

Exercițiu de verificare:

1. AI-ul folosește formula corectă? $R_t = P_t/P_{t-1} - 1$ vs. $r_t = \ln(P_t/P_{t-1})$?
2. Diferența $\bar{R} - \bar{r}$ este aproximativ $\sigma^2/2$? Verifică numeric.
3. Re-rulează cu date BTC-USD. Variance drag-ul este mai mare? De ce?
4. Construiește un portofoliu 60/40 (AAPL/MSFT). Se păstrează relația $\sigma^2/2$?

☐ **Atenție:** AI-ul confundă adesea randamentul aritmetic cu cel geometric. Verificați mereu dacă $r_t = \ln(1 + R_t)$.

Exercițiu AI: Optimizare de portofoliu

Prompt de testat în ChatGPT / Claude / Copilot

“Folosind Python, descarcă datele zilnice pentru 5 acțiuni (AAPL, MSFT, GOOGL, AMZN, JPM) din 2020–2024. Construiește frontiera eficientă Markowitz cu 10 000 portofolii aleatorii. Identifică portofoliul cu varianță minimă (MVP) și portofoliul tangent cu $R_f = 4\%$. Trasează frontiera cu MVP, portofoliul tangent și Capital Market Line.”

Exercițiu de verificare:

1. AI-ul impune constrângerea $\sum w_i = 1$? Permite ponderi negative (short)?
2. Sharpe-ul portofoliului tangent este mai mare decât al oricărui activ individual?
3. Aduă BTC în universul de active. Cum se schimbă frontiera?
4. Cere AI-ului un backtest out-of-sample (2024). Portofoliul optim rezistă?

☐ **Atenție:** Optimizarea Markowitz este sensibilă la erorile de estimare a lui μ și Σ . Rezultatele in-sample nu garantează performanță out-of-sample.

Cuprins

- ▣ Motivație ✓
- ▣ Date de preț ✓
- ▣ Randamente ✓
- ▣ Fapte stilizate ✓
- ▣ Estimatori de volatilitate ✓
- ▣ Comparație de eficiență ✓
- ▣ Randamente ajustate la risc ✓
- ▣ Caz de utilizare AI ✓
- ▣ **Rezumat**
- ▣ Quiz
- ▣ Bibliografie

Concluzii cheie

Rezumat

- ▣ **Randamentele** sunt metrica principală:
 - ▶ Randamente simple pentru analiză cross-secțională; randamente logaritmice pentru serii de timp
 - ▶ Pierderea din varianță: $\mathbb{E}[r] \approx \mathbb{E}[R] - \sigma^2/2$; critică pentru active volatile
- ▣ **Fapte stilizate** universale: cozi groase, gruparea volatilității, efect levier, normalitate prin agregare
- ▣ **Volatilitatea** este o variabilă latentă; estimatorii bazați pe range (P, GK, RS, YZ) sunt mai eficienți decât CC
- ▣ **Măsuri ajustate la risc**: Sharpe ratio este standard; Sortino, Calmar abordează limitările
- ▣ **Diversificare**: frontiera eficientă formalizează compromisul risc-randament (Markowitz 1952)

Formule importante

Randamente

- ▣ **Simple:** $R_t = P_t/P_{t-1} - 1$
- ▣ **Log:** $r_t = \ln(P_t/P_{t-1})$
- ▣ **Pierdere:** $\mathbb{E}[r] \approx \mathbb{E}[R] - \sigma^2/2$
- ▣ **Scalare:** $\sigma_T = \sigma_1\sqrt{T}$

Estimatori de volatilitate

- ▣ **CC:** $\hat{\sigma}^2 = \frac{1}{n-1} \sum (r_t - \bar{r})^2$
- ▣ **Parkinson:** folosește $\ln(H/L)$
- ▣ **YZ:** combină overnight + RS

Randamente ajustate la risc

- ▣ **Sharpe:** $SR = (\bar{R} - R_f)/\sigma$
- ▣ **Sortino:** folosește σ_D descendentă
- ▣ **Portofoliu:** $\sigma_P^2 = w'\Sigma w$

GARCH(1,1)

- ▣ $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$
- ▣ **Necond.:** $\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}$
- ▣ **EWMA:** $\lambda = 0,94$

Capcane frecvente

Erori de date

- Folosirea **prețurilor neajustate** la dividende/splituri
- Ignorarea **survivorship bias** (doar firme active)
- Confuzia între preț și randament

Erori de calcul

- **Anualizare greșită:** $\sigma_{\text{annual}} = \sigma_{\text{daily}} \times 252$ în loc de $\times \sqrt{252}$
- Aplicarea regulii $\sqrt{T}$ **fără verificarea i.i.d.**
- Adunarea randamentelor simple pe timp (sunt multiplicative!)

Erori de interpretare

- Interpretarea Sharpe **fără risc sistematic**: SR mare $\neq$ risc mic
- Ignorarea **asimetriei/kurtosis-ului**: SR nu captează riscul de coadă
- Presupunerea de **normalitate** la VaR: subestimează pierderile extreme
- Confuzia dintre **corelație și cauzalitate**

Erori de estimare

- Fereastră prea **scurtă** $\Rightarrow$ zgomot; prea **lungă** $\Rightarrow$ depășită
- GK/Parkinson pe piețe **în trend** $\Rightarrow$ distorsionat
- Ignorarea **gap-urilor overnight**

Ce trebuie să știți perfect

Checklist de competențe — Capitolul 1

- ✓ **Calculați** randamente simple și logaritmice din prețuri
- ✓ **Explicați** diferența simplă vs. log și când se folosește fiecare
- ✓ **Calculați** și interpretați pierderea din varianță (variance drag)
- ✓ **Anualizați** corect volatilitatea ($\times \sqrt{252}$, nu $\times 252$)
- ✓ **Aplicați** regula $\sqrt{T}$ și cunoașteți limitările ei
- ✓ **Distingeți** între estimatorii CC, Parkinson, GK, RS, Yang-Zhang
- ✓ **Interpretați** asimetria: $S < 0 \Rightarrow$ pierderi mari mai frecvente
- ✓ **Interpretați** kurtosis: $K > 3 \Rightarrow$ cozi groase, distribuția normală inadecvată
- ✓ **Calculați** indicatorul Sharpe și cunoașteți limitările
- ✓ **Calculați** drawdown și MDD
- ✓ **Explicați** faptele stilizate: gruparea volatilității, efect levier, cozi groase
- ✓ **Distingeți** volatilitate istorică, condițională, realizată, implicită

Test rapid de autoevaluare

- ☐ Dacă puteți răspunde la toate cele 12 puncte **fără note**, sunteți pregătiți pentru examen pe acest capitol.

Previzualizare capitolul următor

Capitolul 2: Distribuții de probabilitate pentru piețele financiare

- ▣ **Distribuția Normală:** proprietăți, limitări pentru date financiare
- ▣ **Student- t :** cozi groase, grade de libertate
- ▣ **Distribuții stabile:** Pareto-stabile, legi de putere
- ▣ **Amestecuri:** Normal Inverse Gaussian (NIG), modele de amestec

Ce vom învăța

- ▣ **Comparați** distribuții pe date reale (QQ-plot, testul KS)
- ▣ **Estimați** parametrii prin MLE
- ▣ **Modelați** cozile groase și asimetria
- ▣ **Aplicați** distribuții în context financiar

Tema 1: Calculul randamentelor

Anul 3

- Prețul unei acțiuni la momentul t este $P_t = \$100$.
 - ▶ Randamentele compuse continuu (log) pe următoarele trei perioade sunt: $r_{t+1} = 0.10$, $r_{t+2} = -0.05$, $r_{t+3} = 0.02$.
 - ▶ Calculați P_{t+1} , P_{t+2} , P_{t+3} . Arătați toate calculele.
- Acum presupuneți că randamentele **simple** sunt $R_{t+1} = 0.10$, $R_{t+2} = -0.05$, $R_{t+3} = 0.02$.
 - ▶ Calculați P_{t+1} , P_{t+2} , P_{t+3} . Arătați toate calculele.
- Comparați prețurile finale:
 - ▶ Sunt identice? De ce da sau de ce nu?
 - ▶ Care este mai mare și cu cât?
 - ▶ Explicați implicațiile practice, în special pentru orizonturi mai lungi.

Tema 1 (cont.): Aditivitatea temporală

Anul 3

- Vi se dă o serie temporală de prețuri ale acțiunilor $P_0, P_1, \dots, P_n$.
 - ▶ Derivați o formulă generală pentru randamentul total compus continuu de la momentul 0 la momentul n .
 - ▶ Exprimați aceasta în funcție de randamentele logaritmice individuale pe perioadă $r_1, r_2, \dots, r_n$.
 - ▶ Explicați cum se aplică **aditivitatea temporală** la randamentele logaritmice.
 - ▶ De ce este această proprietate dezirabilă în modelarea financiară (ex., pentru scalarea varianței)?
- Derivați acum formula analogă pentru **randamentul simplu** total pe n perioade.
 - ▶ Arătați că randamentele simple **nu** sunt aditive temporal.
 - ▶ Oferiți un exemplu numeric cu $n = 3$ perioade pentru a ilustra diferența.

Tema 2: Volatilitate și risc

Anul 3

- Definiți volatilitatea în contextul piețelor financiare.
 - ▶ Raportați definiția la conceptul de risc din notele de curs.
 - ▶ Distingeți între volatilitatea **necondiționată** și **condiționată**.
- De ce este volatilitatea considerată o măsură a riscului? Ce tip de risc captează?
 - ▶ Ce tip de risc *nu* captează? (Indiciu: gândiți-vă la riscul de coadă și asimetrie.)
- Discutați cel puțin **trei** metode diferite de estimare a volatilității.
 - ▶ Pentru fiecare: specificați datele necesare, avantajul principal și limitarea principală.
- Vi se dau două active A și B:
 - ▶ Activul A: $\bar{R} = 12\%$, $\sigma = 20\%$, $R_f = 3\%$.
 - ▶ Activul B: $\bar{R} = 8\%$, $\sigma = 10\%$, $R_f = 3\%$.
 - ▶ Calculați indicatorul Sharpe pentru fiecare. Pe care l-ar prefera un investitor avers la risc?
 - ▶ Explicați conceptul de **aversiune la risc** și cum se raportează la această alegere.

Tema 2 (cont.): Volatilitatea portofoliului

Anul 3

- Un portofoliu constă din două active X și Y cu ponderile $w_X + w_Y = 1$.
 - ▶ Activul X: $\sigma_X = 15\%$. Activul Y: $\sigma_Y = 25\%$. Corelație $\rho_{XY} = 0.4$.
 - ▶ (a) Derivați formula pentru varianța portofoliului σ_P^2 din principii de bază.
 - ▶ (b) Calculați σ_P pentru $w_X = 0.5$, $w_Y = 0.5$.
 - ▶ (c) Calculați σ_P pentru $w_X = 0.5$, $w_Y = 0.5$ când $\rho_{XY} = 0$.
 - ▶ (d) Calculați σ_P pentru $w_X = 0.5$, $w_Y = 0.5$ când $\rho_{XY} = -1$.
- Explicați cum **diversificarea** reduce volatilitatea portofoliului.
 - ▶ Pentru ce valoare a corelației este beneficiul maxim?
 - ▶ Care este varianța minimă posibilă a portofoliului (indiferent de ponderi)?

Tema 3: Regula rădăcinii pătrate a timpului

Master

- Enunțați și demonstrați regula rădăcinii pătrate a timpului.
 - ▶ Enunțați clar toate ipotezele care stau la baza regulii.
 - ▶ Furnizați demonstrația pas cu pas.
- O acțiune are o volatilitate zilnică de $\hat{\sigma}_{\text{daily}} = 1.2\%$.
 - ▶ Estimați volatilitățile săptămânală (5 zile), lunară (22 zile) și anuală (252 zile).
 - ▶ Arătați toate calculele.
 - ▶ Valoarea anualizată: este consecventă cu intuiția dvs. pentru o acțiune tipică?
- Presupuneți acum că randamentele zilnice au **autocorelație pozitivă** $\rho_1 = 0.1$ la lag 1.
 - ▶ Volatilitatea anuală reală ar fi mai mare sau mai mică decât estimarea i.i.d.? De ce?
 - ▶ Scrieți formula corectată a varianței pentru randamente pe k -perioade cu autocorelație AR(1).
 - ▶ Calculați varianța anuală corectată pentru acțiunea de mai sus cu $\rho_1 = 0.1$.

Mini-proiect obligatoriu: Analiza unei acțiuni BVB

Descriere

- Fiecare student alege o acțiune listată la **Bursa de Valori București (BVB)** și realizează o analiză statistică completă pe minimum 3 ani de date zilnice.

Raportul trebuie să includă

1. Randamente logaritmice zilnice (grafic + statistici descriptive)
2. Volatilitate rolling pe 30 de zile (grafic)
3. Asimetrie și kurtosis (+ testul Jarque-Bera)
4. Maximum Drawdown (grafic + interpretare)
5. Indicatorul Sharpe (R_f = rata dobânzii BNR)
6. **Interpretare de risc:** profilul complet al activului

Cerințe tehnice

- Cod **Python** sau **R** (reproducibil)
- Sursa datelor: Yahoo Finance, BVB, sau altă sursă documentată
- Raport de maximum **5 pagini** (fără cod, cu grafice)
- Codul se predă separat (notebook Jupyter sau script .py)

Termen de predare

- Săptămâna 5 a semestrului.

Cuprins

- ▣ Motivație ✓
- ▣ Date de preț ✓
- ▣ Randamente ✓
- ▣ Fapte stilizate ale randamentelor financiare ✓
- ▣ Estimatori de volatilitate ✓
- ▣ Comparație de eficiență ✓
- ▣ Randamente ajustate la risc ✓
- ▣ Caz de utilizare AI ✓
- ▣ Rezumat ✓
- ▣ **Quiz**
- ▣ Bibliografie

Întrebarea 1

Întrebare

□ O acțiune merge de la \$100 la \$110 la \$99. Care este **log-randamentul** pe două perioade?

Variante de răspuns

(A) $r_{0 \rightarrow 2} = \ln(99/100) = -1.005\%$

(B) $r_{0 \rightarrow 2} = (110 - 100)/100 + (99 - 110)/110 = 0\%$

(C) $r_{0 \rightarrow 2} = \ln(110/100) + \ln(99/110) = 9.531\% + (-10.536\%) = -1.005\%$

(D) $r_{0 \rightarrow 2} = (99 - 100)/100 = -1\%$

Întrebarea 1: Răspuns

Răspuns: (C)

- ▣ Log-randamentele sunt **aditive temporal**: $r_{0 \rightarrow 2} = r_1 + r_2 = \ln(110/100) + \ln(99/110)$.
- ▣ Aceasta este egală cu $\ln(99/100) = -1.005\%$, care coincide cu (A), dar (C) arată metoda corectă.
- ▣ (B) calculează randamente simple și le adună — randamentele simple NU sunt aditive temporal.
- ▣ (D) este randamentul simplu pe două perioade, nu log-randamentul.

Întrebarea 2

Întrebare

☐ Care dintre următoarele **NU** este un fapt stilizat al randamentelor financiare?

Variante de răspuns

- (A) Cozi groase (excess kurtosis)
- (B) Gruparea volatilității (volatility clustering)
- (C) Randamentele sunt autocorelate pozitiv la frecvența zilnică
- (D) Normalitate prin agregare

Întrebarea 2: Răspuns

Răspuns: (C)

- ▣ Randamentele zilnice au autocorelație **aproape de zero** (consistent cu EMH formă slabă).
- ▣ Ceea ce ESTE autocorelat este $|r_t|$ și r_t^2 (gruparea volatilității), nu r_t în sine.
- ▣ (A), (B), (D) sunt toate fapte stilizate bine documentate (Cont, 2001).
- ▣ Efectul de levier (corelație negativă randament-volatilitate) este un alt fapt stilizat cheie.

Întrebarea 3

Întrebare

□ Estimatorul Parkinson are eficiență relativă $RE = 5.2$ vs. close-to-close. Ce înseamnă?

Variante de răspuns

- (A) Are nevoie de $5.2 \times$ mai multe date pentru aceeași precizie
- (B) Atinge aceeași precizie cu $1/5.2$ din date
- (C) Varianța sa este $5.2 \times$ mai mare decât estimatorul CC
- (D) Converge de $5.2 \times$ mai lent decât CC

Întrebarea 3: Răspuns

Răspuns: (B)

- ▣ $RE = \text{Var}(\hat{\sigma}_{CC}^2) / \text{Var}(\hat{\sigma}_P^2) = 5.2$.
- ▣ Varianța estimatorului Parkinson este $5.2 \times$ **mai mică**, deci are nevoie de doar $1/5.2 \approx 19\%$ din date pentru aceeași precizie.
- ▣ Câștigul de eficiență vine din folosirea informației high-low (întregul range zilnic).
- ▣ Yang-Zhang atinge $RE \approx 14$, cel mai mare dintre estimatorii OHLC.

Întrebarea 4

Întrebare

□ Bitcoin are σ zilnică $\approx 4\%$. Pierderea din varianță $\sigma^2/2$ pe 365 de zile este aproximativ:

Variante de răspuns

- (A) $0.08\% \text{ pe zi} \times 365 \approx 29\% \text{ pe an}$
- (B) $4\%/2 = 2\% \text{ pe an}$
- (C) $4^2/2 = 8\% \text{ pe an}$
- (D) Neglijabilă — pierderea din varianță contează doar pentru active cu volatilitate scăzută

Întrebarea 4: Răspuns

Răspuns: (A)

- ▣ Pierdere zilnică $= \sigma^2/2 = 4^2/(2 \times 100) = 0,08\%$ pe zi.
- ▣ Pierdere anuală $= 0,08\% \times 365 = 29,2\%$ pe an.
- ▣ Aceasta înseamnă că randamentul geometric Bitcoin este $\approx 29\%$ **mai mic** decât cel aritmetic anual.
- ▣ (B) și (C) confundă σ cu σ^2 . (D) este invers — pierderea crește cvadratic cu σ .

Întrebarea 5

Întrebare

□ Fond A: $\bar{R} = 12\%$, $\sigma = 20\%$, $R_f = 3\%$. Fond B: $\bar{R} = 8\%$, $\sigma = 10\%$, $R_f = 3\%$. Care are Sharpe ratio mai mare?

Variante de răspuns

- (A) Fondul A: $SR_A = 0.45$ vs. $SR_B = 0.50$, deci Fondul A
- (B) Fondul B: $SR_B = (8 - 3)/10 = 0.50 > SR_A = (12 - 3)/20 = 0.45$
- (C) Sunt egale: ambele au $SR = 0.50$
- (D) Fondul A, deoarece are randament absolut mai mare

Întrebarea 5: Răspuns

Răspuns: (B)

- ▣ $SR_A = (12\% - 3\%)/20\% = 0.45$.
- ▣ $SR_B = (8\% - 3\%)/10\% = 0.50$.
- ▣ Fondul B livrează mai mult **randament per unitate de risc**, deși are randament absolut mai mic.
- ▣ (D) este greșeala frecventă: randament mai mare $\neq$ performanță ajustată la risc mai bună.

Întrebarea 6

Întrebare

□ Două active cu $\sigma_X = 15\%$, $\sigma_Y = 25\%$, $\rho_{XY} = 0.3$. Un portofoliu cu ponderi egale are volatilitatea:

Variante de răspuns

(A) $\sigma_P = (15\% + 25\%)/2 = 20\%$ (media)

(B) $\sigma_P = \sqrt{0.25 \times 0.0225 + 0.25 \times 0.0625 + 2 \times 0.25 \times 0.3 \times 0.15 \times 0.25} \approx 16.4\%$

(C) $\sigma_P = \sqrt{0.5^2 \times 15^2 + 0.5^2 \times 25^2} = 14.6\%$

(D) Nu se poate calcula fără randamentele așteptate individuale

Întrebarea 6: Răspuns

Răspuns: (B)

- ▣ $\sigma_P^2 = w_X^2 \sigma_X^2 + w_Y^2 \sigma_Y^2 + 2w_X w_Y \rho \sigma_X \sigma_Y$
- ▣ $= 0.25(0.0225) + 0.25(0.0625) + 2(0.25)(0.3)(0.15)(0.25)$
- ▣ $= 0.005625 + 0.015625 + 0.005625 = 0.026875$, deci $\sigma_P = 16.4\%$.
- ▣ Aceasta este **mai mică** decât media ponderată (20%) $\Rightarrow$ beneficiul diversificării.
- ▣ (C) uită termenul încrucișat (presupune $\rho = 0$). (D) este greșit: σ_P nu depinde de randamente așteptate.

Întrebarea 7: Variance drag

Întrebare

Un activ are randament aritmetic așteptat $\bar{R} = 12\%$ și volatilitate anuală $\sigma = 30\%$. Care este **aproximarea** randamentului geometric (compus continuu) așteptat?

- (A) $E[r] \approx 12\%$ (identic cu randamentul aritmetic)
- (B) $E[r] \approx 12\% - (30\%)^2/2 = 7,5\%$
- (C) $E[r] \approx 12\% - 30\%/2 = -3\%$
- (D) $E[r] \approx 12\% \times (1 - 30\%) = 8,4\%$

Întrebarea 7: Răspuns

Răspuns: (B)

- ▣ Relația fundamentală: $E[r] \approx \bar{R} - \sigma^2/2$ (variance drag).
- ▣ $E[r] \approx 12\% - (30\%)^2/2 = 12\% - 4,5\% = 7,5\%$.
- ▣ **Variance drag** $= \sigma^2/2 = 4,5\%/an$ — aceasta este “taxa” pe care volatilitatea o impune randamentului compus.
- ▣ Cu cât volatilitatea este mai mare, cu atât diferența $\bar{R} - E[r]$ crește. Exemplu: $\sigma = 50\% \Rightarrow \text{drag} = 12,5\%$!
- ▣ (A) ignoră complet efectul. (C) confundă σ cu σ^2 . (D) folosește o formulă inventată.

Întrebarea 8: EWMA vs. volatilitate rolling

Întrebare

Care dintre următoarele afirmații descrie **corect** diferența principală dintre estimatorul EWMA și volatilitatea rolling cu fereastră fixă?

- (A) EWMA folosește mai multe observații decât fereastra rolling
- (B) Fereastra rolling atribuie ponderi descrescătoare observațiilor mai vechi
- (C) EWMA atribuie ponderi exponențial descrescătoare observațiilor mai vechi
- (D) Ambele metode dau rezultate identice pentru orice serie temporală

Întrebarea 8: Răspuns

Răspuns: (C)

- ▣ EWMA: $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, cu $\lambda \in (0, 1)$ (tipic $\lambda = 0,94$).
- ▣ Ponderile scad geometric: $(1 - \lambda)$, $\lambda(1 - \lambda)$, $\lambda^2(1 - \lambda)$, ...
- ▣ Fereastra rolling atribuie ponderi **egale** tuturor observațiilor din fereastră și zero în afara ei.
- ▣ EWMA reacționează mai rapid la șocuri recente (nu are “ghost effect” al ferestrei fixe).
- ▣ (A) este incorect: EWMA folosește teoretic toate observațiile, dar diferența nu e în număr, ci în ponderare. (B) descrie EWMA, nu rolling. (D) este fals.

Întrebarea 9: Sortino vs. Sharpe

Întrebare

Care este diferența principală între indicatorul Sharpe și indicatorul Sortino?

- (A) Sortino folosește randamentul median, nu media
- (B) Sortino folosește doar deviația descendentă (downside deviation) în loc de deviația standard totală
- (C) Sortino nu necesită o rată fără risc
- (D) Sharpe și Sortino sunt echivalente pentru distribuții simetrice

Întrebarea 9: Răspuns

Răspuns: (B)

- ▣ Sharpe: $SR = \frac{\bar{R} - R_f}{\sigma}$, unde σ = deviația standard totală.
- ▣ Sortino: $\text{Sortino} = \frac{\bar{R} - R_f}{\sigma_{\text{down}}}$, unde $\sigma_{\text{down}} = \sqrt{\frac{1}{n} \sum_{r_t < R_f} (r_t - R_f)^2}$.
- ▣ Sortino penalizează **doar** volatilitatea descendentă — nu penalizează randamentele pozitive mari.
- ▣ Aceasta este importantă pentru distribuții asimetrice (skewness < 0): Sharpe subestimează riscul real.
- ▣ (A) este incorect: ambele folosesc media. (C) fals: Sortino necesită R_f (sau un prag). (D) aproximativ adevărat, dar nu exact.

Întrebarea 10: Efectul diversificării

Întrebare

Două active au fiecare $\sigma = 20\%$. Corelația dintre ele este $\rho = -0,5$. Un portofoliu egal ponderat ($w_1 = w_2 = 0,5$) are volatilitatea:

- (A) $\sigma_P = 20\%$ (media ponderată)
- (B) $\sigma_P = 10\%$ (jumătate din σ individuală)
- (C) $\sigma_P = 14,1\%$ ($= 20\%/\sqrt{2}$)
- (D) $\sigma_P = 0\%$ (riscul se elimină complet)

Întrebarea 10: Răspuns

Răspuns: (B)

- ▣ $\sigma_P^2 = w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 + 2w_1 w_2 \rho \sigma_1 \sigma_2$
- ▣ $= 0,25 \times 0,04 + 0,25 \times 0,04 + 2(0,25)(-0,5)(0,04)$
- ▣ $= 0,01 + 0,01 - 0,01 = 0,01$, deci $\sigma_P = \sqrt{0,01} = 10\%$.
- ▣ Diversificarea reduce volatilitatea de la 20% la 10% — o reducere de 50%!
- ▣ (A) ignoră corelația. (C) presupune $\rho = 0$. (D) necesită $\rho = -1$ pentru eliminare completă.

Exercițiul 1: Randamente simple vs. logaritmice

Enunț

Se dau prețurile:

t	0	1	2	3
P_t	100	105	98	110

1. Calculați randamentele **simple** R_1, R_2, R_3 .
2. Calculați randamentele **logaritmice** r_1, r_2, r_3 .
3. Calculați randamentul total pe 3 perioade:
 - ▶ folosind compunere simplă: $\prod_{t=1}^3 (1 + R_t) - 1$
 - ▶ folosind suma log-urilor: $\sum_{t=1}^3 r_t$
4. Verificați relația: $e^{\sum r_t} - 1 = \prod (1 + R_t) - 1$.

Exercițiul 2: Pierderea din varianță (Variance Drag)

Enunț

Un activ are randamentul aritmetic așteptat $\mathbb{E}[R] = 12\%$ și volatilitatea $\sigma = 20\%$.

1. Aproximați randamentul **geometric** anual folosind $\mathbb{E}[r] \approx \mathbb{E}[R] - \sigma^2/2$.
2. Ce se întâmplă dacă volatilitatea crește la $\sigma = 40\%$? Recalculați.
3. Calculați averea după 10 ani ($W_0 = 1$) pentru ambele scenarii.
4. Interpretați economic: de ce activul mai volatil produce mai puțină avere?

Indiciu

$W_{10} = W_0 \cdot e^{10 \times \mathbb{E}[r]}$. Comparați $\mathbb{E}[r]$ în cele două scenarii.

Exercițiul 3: Staționaritate

Enunț

Răspundeți la următoarele întrebări conceptuale:

1. Explicați de ce prețurile financiare sunt în general $I(1)$ (nestaționare).
 - ▶ Ce proprietăți ale staționarității slabe sunt încălcate?
2. De ce randamentele logaritmice sunt aproximativ $I(0)$ (staționare)?
 - ▶ Ce test formal putem folosi pentru a verifica?
3. De ce este problematic să aplicăm regresie OLS direct pe prețuri?
 - ▶ Ce fenomen statistic poate apărea? (Indiciu: regresie falsă)

Intuiție cheie

- „*Prețurile cresc, randamentele oscilează.*” Metodele statistice cer staționaritate — de aceea analizăm randamente, nu prețuri.

Exercițiul 4: Volatilitate Close-to-Close

Enunț

Se dau randamentele logaritmice zilnice (%): 2.0, -1.0, 3.0, -2.0, 1.0

1. Calculați media eșantion $\bar{r}$.
2. Calculați volatilitatea zilnică $\hat{\sigma}_{\text{daily}} = \sqrt{\frac{1}{n-1} \sum_{t=1}^n (r_t - \bar{r})^2}$.
3. Anualizați volatilitatea (252 zile de tranzacționare).
4. Ce se schimbă dacă folosim n în loc de $n - 1$ la numitor?

Verificare

$\bar{r} = 0.6\%$. Volatilitatea zilnică $\approx 2.07\%$. Verificați calculele pas cu pas.

Exercițiul 5: Regula $\sqrt{T}$

Enunț

Volatilitatea zilnică a unei acțiuni este $\hat{\sigma}_{\text{daily}} = 1.5\%$.

1. Calculați volatilitatea **lunară** (22 zile de tranzacționare).
2. Calculați volatilitatea **anuală** (252 zile).
3. În ce condiții este formula $\sigma_T = \sigma_1\sqrt{T}$ validă?
4. Dacă randamentele au autocorelație pozitivă $\rho_1 = 0.15$, volatilitatea anuală reală este mai mare sau mai mică decât estimarea i.i.d.? Justificați.

Exercițiul 6: Indicatorul Sharpe

Enunț

Două fonduri de investiții, rata fără risc $R_f = 2\%$ pe an:

	$\bar{R}_{\text{annual}}$	σ_{annual}
Fond A	14%	18%
Fond B	10%	9%

1. Calculați indicatorul Sharpe pentru ambele fonduri.
2. Care fond este preferabil din perspectiva randamentului ajustat la risc?
3. Enumerați cel puțin 3 limitări ale indicatorului Sharpe.
4. Ce randament ar trebui să aibă Fondul A pentru a egala indicatorul Sharpe al Fondului B?

Exercițiul 7: Drawdown

Enunț

Se dau prețurile zilnice: 100, 120, 110, 130, 90, 95

1. Calculați running maximum-ul la fiecare moment t .
2. Calculați drawdown-ul $DD_t = (P_t - \max_{s \leq t} P_s) / \max_{s \leq t} P_s$ la fiecare moment.
3. Determinați **MDD** (Maximum Drawdown).
4. Interpretați: ce semnifică MDD pentru un investitor?
5. Dacă randamentul anual este 8%, calculați raportul **Calmar**.

Indiciu

Running max: 100, 120, 120, 130, 130, 130. Drawdown la $t = 5$: $(90 - 130)/130$.

Exercițiul 8: Asimetrie și kurtosis

Enunț

Un activ are următoarele statistici empirice pe randamente zilnice:

$$\text{Asimetrie} = -1,2, \quad \text{Kurtosis} = 9,0$$

1. Ce semnifică o asimetrie negativă ($S < 0$) economic?
2. Ce semnifică un excess kurtosis $\kappa = K - 3 = 6 > 0$?
3. Este distribuția normală adecvată pentru a modela acest activ? Justificați.
4. Ce distribuții alternative ați putea folosi? (Menționați cel puțin două.)
5. Cum afectează cozile groase calculul VaR?

De reținut

- ☐ Distribuția normală subestimează dramatic riscul de coadă. Un eveniment 5σ apare mult mai frecvent decât prevede distribuția normală.

Exercițiul 9: Volatilitate Rolling — Compromisuri

Enunț

Explicați compromisurile în alegerea ferestrei de estimare pentru volatilitatea rolling:

1. De ce o fereastră de **10 zile** produce o estimare instabilă (zgomotoasă)?
2. De ce o fereastră de **250 zile** reacționează lent la schimbările de regim?
3. Care este compromisul optim? (Indiciu: bias vs. varianță)
4. Cum rezolvă EWMA ($\lambda = 0.94$) acest compromis?
5. Ce avantaj principal are volatilitatea **realizată** (intra-zilnică) față de estimările rolling?

Exercițiul 10: Interpretare integrată

Enunț

Un activ financiar prezintă următorul profil de risc:

Indicator	Valoare
Volatilitate anuală	35%
Sharpe ratio	0.4
MDD (Maximum Drawdown)	−60%
Asimetrie	−1,5
Excess kurtosis	6,0

1. Descrieți profilul de risc al activului în 3–4 propoziții.
2. Ați investi? Justificați, luând în considerare **toți** indicatorii.
3. Ce informație aduce MDD care nu se vede din Sharpe?
4. Ce semnifică asimetria = $-1,5$ combinată cu kurtosis = 9?

Exercițiul 1: Rezolvare

Rezolvare

1. Randamente simple: $R_1 = 105/100 - 1 = 5\%$, $R_2 = 98/105 - 1 = -6,67\%$, $R_3 = 110/98 - 1 = 12,24\%$.
2. Randamente logaritmice: $r_1 = \ln(105/100) = 4,88\%$, $r_2 = \ln(98/105) = -6,90\%$, $r_3 = \ln(110/98) = 11,57\%$.
3. Verificare aditivitate:
 - ▣ Log: $r_{0:3} = r_1 + r_2 + r_3 = 4,88 - 6,90 + 11,57 = 9,53\% = \ln(110/100) \checkmark$
 - ▣ Simplu: $\prod_{i=1}^3 (1 + R_i) - 1 = 1,05 \times 0,9333 \times 1,1224 - 1 = 10\% \checkmark$
 - ▣ Relația: $e^{\sum r_i} - 1 = e^{0,0953} - 1 = 10\% = \prod (1 + R_i) - 1 \checkmark$

Exercițiul 2: Rezolvare

Rezolvare

1. Variance drag: $E[r] \approx \bar{R} - \sigma^2/2$.
2. Scenariul 1 ($\sigma = 20\%$):
 - ▣ $E[r] \approx 12\% - (20\%)^2/2 = 12\% - 2\% = 10\%$
 - ▣ $W_{10} = e^{10 \times 0,10} = e^{1,0} = 2,72$ (investiția se triplează aproape)
3. Scenariul 2 ($\sigma = 40\%$):
 - ▣ $E[r] \approx 12\% - (40\%)^2/2 = 12\% - 8\% = 4\%$
 - ▣ $W_{10} = e^{10 \times 0,04} = e^{0,4} = 1,49$ (creștere modestă de 49%)
4. Concluzie: la același $\bar{R} = 12\%$, volatilitatea mai mare reduce dramatic averea finală (2,72 vs. 1,49). Variance drag-ul este “taxa” invizibilă a volatilității.

Exercițiul 3: Rezolvare

Rezolvare

1. Prețurile sunt **I(1)** (integrate de ordinul 1):

- ▣ Au trend stocastic, varianța crește cu t : $\text{Var}(P_t) \rightarrow \infty$.
- ▣ Testul ADF pe prețuri: nu respingem H_0 (rădăcină unitară).

2. Randamentele sunt **I(0)** (staționare):

- ▣ $r_t = \ln(P_t/P_{t-1}) = \Delta \ln P_t$ — diferențierea elimină trendul.
- ▣ Testul ADF pe randamente: respingem $H_0 \Rightarrow$ serie staționară.

3. OLS pe prețuri $\Rightarrow$ **regresie falsă** (Granger & Newbold, 1974):

- ▣ R^2 artificial ridicat, statistici t invalide.
- ▣ Soluție: folosiți randamente (staționare) sau cointegration (Engle-Granger).

Exercițiul 4: Rezolvare

Rezolvare

1. Date: $n = 5$ randamente, $\bar{r} = 0,6\%$.
2. $\sum_{t=1}^5 (r_t - \bar{r})^2 = 17,20\%^2$ (din tabelul enunțului).
3. Cu $n - 1$ (corecția Bessel): $\hat{\sigma}^2 = \frac{17,20}{4} = 4,30\%^2$, deci $\hat{\sigma} = 2,074\%$ zilnic.
4. Anualizare: $\hat{\sigma}_{\text{anual}} = 2,074\% \times \sqrt{252} = 32,9\%$.
5. Cu n (fără corecție): $\hat{\sigma}^2 = 17,20/5 = 3,44\%^2$, $\hat{\sigma} = 1,855\%$, $\hat{\sigma}_{\text{anual}} = 29,4\%$.
6. **Corecția Bessel** ($n - 1$): estimator nedeplasat al varianței populației. Cu eșantioane mici ($n = 5$), diferența este semnificativă: 32,9% vs. 29,4%.

Exercițiul 5: Rezolvare

Rezolvare

1. Regula $\sqrt{T}$: $\sigma_{\text{anual}} = \sigma_{\text{lunar}} \times \sqrt{12}$.

$$\sigma_{\text{anual}} = 7,04\% \times \sqrt{12} = 7,04\% \times 3,464 = 24,4\%.$$

2. Condiții necesare: randamentele trebuie să fie **i.i.d.** (independente și identic distribuite).

□ Independență: $\text{Cov}(r_t, r_{t-k}) = 0$ pentru orice $k \neq 0$.

□ Varianță constantă (homoscedasticitate).

3. Cu autocorelație $\rho_1 = 0,15$:

$$\square \text{Var}(r_{1:T}) = T\sigma^2 \left(1 + 2 \sum_{k=1}^{T-1} \frac{T-k}{T} \rho_k \right)$$

$$\square \text{Aproximare: } \sigma_{\text{anual}}^2 \approx 12\sigma_{\text{lunar}}^2(1 + 2 \times 0,15) = 12 \times 0,0704^2 \times 1,3$$

$$\square \sigma_{\text{anual}} \approx 24,4\% \times \sqrt{1,3} = 27,8\% \text{ — mai mare decât estimarea i.i.d.!}$$

Exercițiul 6: Rezolvare

Rezolvare

1. Sharpe Ratio: $SR = \frac{\bar{R} - R_f}{\sigma}$, cu $R_f = 2\%$.

▣ Fond A: $SR_A = \frac{14\% - 2\%}{18\%} = \frac{12\%}{18\%} = 0,667$

▣ Fond B: $SR_B = \frac{10\% - 2\%}{9\%} = \frac{8\%}{9\%} = 0,889$

2. Fondul B este preferabil ($SR_B > SR_A$): randament mai bun per unitate de risc.

3. Trei limitări ale lui Sharpe:

▣ Presupune distribuție normală (nu captează skewness/kurtosis).

▣ Penalizează volatilitatea ascendentă și descendentă egal.

▣ Sensibil la alegerea lui R_f și la orizontul de timp.

4. Pentru $SR_A = SR_B$: $\frac{\bar{R}_A - 2\%}{18\%} = 0,889 \Rightarrow \bar{R}_A = 2\% + 0,889 \times 18\% = 18,0\%$.

Exercițiul 7: Rezolvare

Rezolvare

1. Running maximum: $M_0 = 100$, $M_1 = 120$, $M_2 = 120$, $M_3 = 130$, $M_4 = 130$, $M_5 = 130$.
2. Drawdown la fiecare moment: $DD_t = (P_t - M_t)/M_t$.
 - ▣ $DD_0 = 0\%$, $DD_1 = 0\%$, $DD_2 = (110 - 120)/120 = -8,33\%$
 - ▣ $DD_3 = 0\%$, $DD_4 = (90 - 130)/130 = -30,77\%$, $DD_5 = (95 - 130)/130 = -26,92\%$
3. **Maximum Drawdown:** $MDD = -30,77\%$ (la $t = 4$).
4. Calmar Ratio: $\text{Calmar} = \frac{\bar{R}_{\text{annual}}}{|MDD|}$.
 - ▣ $\bar{R}_{\text{annual}} = 8\% \Rightarrow \text{Calmar} = 8\%/30,77\% = 0,260$.
 - ▣ $\text{Calmar} < 1$ indică un randament insuficient raportat la drawdown-ul maxim.

Exercițiul 8: Rezolvare

Rezolvare

1. $S < 0$ (skewness negativă): coada stângă este mai grea $\Rightarrow$ pierderi extreme mai frecvente decât câștiguri extreme (“crash risk”).
2. $\kappa = 6$ (excess kurtosis): cozi groase, evenimente $> 3\sigma$ mult mai probabile decât sub distribuția normală.
3. Testul Jarque-Bera: $JB = \frac{n}{6} \left(S^2 + \frac{(\kappa)^2}{4} \right) \gg 5,99 \Rightarrow$ **respingem** normalitatea.
4. Alternative: Student- t (cozi groase, simetrică), skew- t (cozi groase + asimetrie), distribuții stabile (teorie generalizatoare).
5. VaR sub distribuția normală subestimează riscul cu 30–50% deoarece distribuția normală alocă probabilitate insuficientă în cozi.

Exercițiul 9: Rezolvare

Rezolvare

1. Ferestre rolling:

- ▣ 10 zile: prea zgomotoasă (mult noise, puțin semnal).
- ▣ 250 zile: prea netedă (“outdated”, nu captează schimbări recente).
- ▣ **Optim: 30–60 zile** — compromis între noise și lag.

2. EWMA ($\lambda = 0,94$): $\sigma_t^2 = 0,94 \sigma_{t-1}^2 + 0,06 r_{t-1}^2$.

- ▣ Ponderi exponențial descrescătoare: observația de ieri contează cel mai mult.
- ▣ Fără “ghost effect” (nu cade brusc o observație mare din fereastră).

3. Volatilitate realizată (RV): $RV_t = \sum_{i=1}^M r_{t,i}^2$ (date intrazilnice, M observații/zi).

- ▣ Efficiency Ratio $RE \gg 1$ față de estimatorul CC (informație mai bogată).
- ▣ Necesită date de înaltă frecvență (tick/1-min).

Exercițiul 10: Rezolvare

Rezolvare

1. Profil: $\sigma = 35\%$, $SR = 0,4$, $MDD = -60\%$, $S = -1,5$, $\kappa = 6$.

Activ **foarte riscant**: volatilitate ridicată, drawdown sever, distribuție asimetrică cu cozi groase.

2. Variance drag: $\sigma^2/2 = (35\%)^2/2 = 6,1\%/an$. La $\bar{R} = SR \times \sigma + R_f \approx 0,4 \times 35\% + 4\% = 18\%$, randamentul geometric este doar $\approx 11,9\%$.

3. $MDD = -60\%$ captează riscul **path-dependent** pe care Sharpe nu-l vede:

- ☐ Sharpe măsoară dispersia randamentelor (moment de ordinul 2).
- ☐ MDD arată cea mai mare pierdere cumulată de la vârf — relevant pentru toleranța psihologică a investitorului.

4. $S = -1,5 + \kappa = 6$: pierderi extreme **asimetrice** și frecvente.

- ☐ Distribuția normală subestimează VaR cu 30–50%.
- ☐ Recomandare: modelați cu Student- t asimetrică sau distribuții stabile.

Cuprins

- ▣ Motivație ✓
- ▣ Date de preț ✓
- ▣ Randamente ✓
- ▣ Fapte stilizate ✓
- ▣ Estimatori de volatilitate ✓
- ▣ Comparație de eficiență ✓
- ▣ Randamente ajustate la risc ✓
- ▣ Caz de utilizare AI ✓
- ▣ Rezumat ✓
- ▣ Quiz ✓
- ▣ Exerciții de examen ✓
- ▣ Rezolvări exerciții ✓
- ▣ **Bibliografie**

Bibliografie I

Manuale de referință

- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*. 4th Ed., Springer.
- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*. 3rd Ed., Wiley.
- ▣ Campbell, J.Y., Lo, A.W., MacKinlay, A.C. (1997). *The Econometrics of Financial Markets*. Princeton University Press.

Articole fundamentale

- ▣ Mandelbrot, B. (1963). The Variation of Certain Speculative Prices. *Journal of Business*, 36(4), 394–419.
- ▣ Cont, R. (2001). Empirical Properties of Asset Returns. *Quantitative Finance*, 1(2), 223–236.
- ▣ Fama, E.F. (1970). Efficient Capital Markets. *Journal of Finance*, 25(2), 383–417.

Bibliografie II

Modele GARCH și de volatilitate

- Engle, R.F. (1982). Autoregressive Conditional Heteroscedasticity. *Econometrica*, 50(4), 987–1007.
- Bollerslev, T. (1986). Generalized Autoregressive Conditional Heteroskedasticity. *J. of Econometrics*, 31(3), 307–327.
- Nelson, D.B. (1991). Conditional Heteroskedasticity in Asset Returns. *Econometrica*, 59(2), 347–370.

Efect levier și previziune

- Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the Relation between Expected Value and Volatility of Nominal Excess Return on Stocks. *J. of Finance*, 48(5), 1779–1801.
- Black, F. (1976). Studies of Stock Price Volatility Changes. *Proc. ASA Meetings*, 177–181.
- Andersen, T.G., Bollerslev, T. (1998). Answering the Skeptics: Standard Volatility Models Do Provide Accurate Forecasts. *Int. Econ. Rev.*, 39(4), 885–905.

Bibliografie III

Estimatori de volatilitate bazați pe interval

- ▣ Parkinson, M. (1980). The Extreme Value Method for Estimating the Variance of the Rate of Return. *J. of Business*, 53(1), 61–65.
- ▣ Garman, M.B., Klass, M.J. (1980). On the Estimation of Security Price Volatilities from Historical Data. *J. of Business*, 53(1), 67–78.
- ▣ Rogers, L.C.G., Satchell, S.E. (1991). Estimating Variance from High, Low and Closing Prices. *Annals of Applied Probability*, 1(4), 504–512.

Estimatori de interval (continuare)

- ▣ Yang, D., Zhang, Q. (2000). Drift-independent volatility estimation based on high, low, open, and close prices. *J. of Business*, 73(3), 477–492.
- ▣ Molnár, P. (2012). Properties of range-based volatility estimators. *Int. Review of Financial Analysis*, 25, 1–12.
- ▣ Lapinova, S., Saichev, A. (2017). Comparative statistics of GK, Parkinson, RS and bridge estimators. *Cogent Physics*, 4(1), 1303931.

Bibliografie IV

Studii comparative

- Fałdziński, M., Osińska, M. (2016). Volatility estimators in econometric analysis of risk transfer. *Dyn. Econom. Models*, 16(1), 1–20.
- Öztürk, H. et al. (2016). Extreme value volatility estimators and realized volatility of ISE. *Int. J. Econ. Fin.*, 8(8), 73.
- Cadenas-Morales, E. (2022). Bitcoin volatility estimate applying RS range model. *IJFIRM*, 12(1), 49–79.

Volatilitate realizată

- Barndorff-Nielsen, O.E., Shephard, N. (2002). Econometric Analysis of Realized Volatility. *JRSS B*, 64(2), 253–280.
- Bandi, F.M., Russell, J.R. (2008). Microstructure Noise, Realized Variance, and Optimal Sampling. *Rev. Econ. Stud.*, 75(2), 339–369.
- Christensen, K., Podolskij, M. (2007). Realized range-based estimation of integrated variance. *J. Econometrics*, 141(2), 323–349.
- Harvey, C.R., Liu, Y., Zhu, H. (2016). ... and the Cross-Section of Expected Returns. *Rev. Fin. Stud.*, 29(1), 5–68.

Bibliografie V

Microstructură și spread

- Epps, T.W. (1979). Comovements in Stock Prices in the Very Short Run. *JASA*, 74(366), 291–298.
- Glosten, L.R., Milgrom, P.R. (1985). Bid, Ask and Transaction Prices in a Specialist Market. *J. of Financial Economics*, 14(1), 71–100.
- Roll, R. (1984). A Simple Implicit Measure of the Effective Bid-Ask Spread. *J. of Finance*, 39(4), 1127–1139.

Relația volum-volatilitate

- Clark, P.K. (1973). A Subordinated Stochastic Process Model with Finite Variance for Speculative Prices. *Econometrica*, 41(1), 135–155.
- Copeland, T.E. (1976). A Model of Asset Trading under Sequential Information Arrival. *J. of Finance*, 31(4), 1149–1168.
- Tauchen, G.E., Pitts, M. (1983). The Price Variability-Volume Relationship on Speculative Markets. *Econometrica*, 51(2), 485–505.

Bibliografie VI

Teoria portofoliului

- ▣ Markowitz, H. (1952). Portfolio Selection. *J. of Finance*, 7(1), 77–91.
- ▣ Sharpe, W.F. (1966). Mutual Fund Performance. *J. of Business*, 39(1), 119–138.
- ▣ Tobin, J. (1958). Liquidity Preference as Behavior Towards Risk. *Review of Economic Studies*, 25(2), 65–86.
- ▣ Lo, A.W. (2002). The Statistics of Sharpe Ratios. *Financial Analysts Journal*, 58(4), 36–52.

Resurse online și cod

- ▣ **Quantlet:** <https://quantlet.com> > Platformă de cod pentru metode cantitative
- ▣ **Quantinar:** <https://quantinar.com> > Platformă de învățare pentru metode cantitative
- ▣ **GitHub SFM:** https://github.com/QuantLet/Stat_fin_markets/tree/master/Ch_01 > Cod Python capitol 1

Criterii de evaluare — Exerciții și proiect

Grila de notare (aplicabilă la examen și proiect)

Nivel	Calcul	Interpretare
9–10	Formule + calcule corecte, complete	Leagă de decizia de business
7–8	Formule corecte, erori minore	Interpretare corectă, superficială
5–6	Formula corectă, greșeli de aplicare	Repetă definiția fără context
<5	Formula greșită sau lipsă	Fără interpretare

Pondere evaluare

□ Examen scris: 70% Proiect individual: 20% Participare activă: 10%

Lectură recomandată pe nivele

Y3 — Lectură minimă

- ▣ Franke et al. (2019), Cap. 1; Cont (2001), §1–3; exercițiile 1–5 din curs

— Lectură suplimentară

- ▣ + Tsay (2010), Cap. 1–2; Campbell et al. (1997); exercițiile 6–10 și studiul de caz

PhD — Lectură avansată

- ▣ + Yang & Zhang (2000); Barndorff-Nielsen & Shephard (2002); slide-urile despre volatilitatea realizată

Frontiere: Machine Learning și volatilitatea

Estimarea modernă a volatilității

- ▣ **LSTM / GRU** pentru predicția volatilității: captează dependențe pe termen lung mai bine decât GARCH (Kim & Won, 2018)
- ▣ **Random Forests** pentru selecția estimatorului optim: alegerea automată între CC, Parkinson, GK, YZ în funcție de regim
- ▣ **HAR-RV + ML**: combinarea volatilității realizate cu *gradient boosting* pentru previziuni superioare

Conexiune cu acest capitol

- ▣ Estimatorii clasici (CC, Parkinson, GK, YZ) rămân **benchmark-uri** indispensabile
- ▣ ML nu le înlocuiește — le **combină**: un model ML folosește CC + range + volum ca *features*
- ▣ **Provocare**: explicabilitate — un Sharpe Ratio este mai transparent decât un model black-box

Bilet de ieșire (*Exit Ticket*)

(1 minut)

Completați înainte de a pleca (anonim, pe hârtie sau online)

1. **Un lucru clar:** Ce concept din cursul de azi ați înțeles cel mai bine?
2. **Un lucru neclar:** Ce concept necesită mai multă clarificare?
3. **O întrebare:** Ce întrebare ați dori să explorați mai departe?

De ce facem acest exercițiu?

- ☐ Răspunsurile anonime ajustează conținutul **următorului curs**
- ☐ Cercetările arată că reflecția imediat după curs crește retenția cu 20–40% (Roediger & Butler, 2011)

Vă Mulțumim!

Întrebări?

Materialele cursului sunt disponibile la: <https://danpele.github.io/SFM/>



Quantlet



Quantinar