



# Statistica Piețelor Financiare

## Capitolul 2: Distribuții clasice și fapte stilizate



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance

## Obiective de învățare

La sfârșitul acestui curs, veți fi capabili să:

1. **Explicați** de ce alegerea distribuției afectează estimarea riscului financiar
2. **Calculați** log-randamente și interpretați proprietățile lor statistice
3. **Aplicați** teste de normalitate și interpretați rezultatele
4. **Identificați** faptele stilizate ale randamentelor financiare
5. **Ajustați** distribuția Student- $t$  și comparați cu distribuția normală
6. **Aplicați** distribuția Pareto și estimatorul Hill pentru analiza cozilor grele

## Ghid de studiu — Cum să folosiți materialele

### Înainte de curs (*pre-reading*)

- ▣ McNeil et al. (2015), Cap. 2.1–2.2 (20 pag.)
- ▣ Cont (2001), Secțiunile 1–3 (8 pag.)
- ▣ Opțional: Mandelbrot (1963), primele 10 pag.

### După curs (*review*)

- ▣ Refaceți exercițiile din slide-uri **fără** a privi rezolvările
- ▣ Rulați cel puțin 2 notebook-uri Quantlet
- ▣ Completați testele grilă din seminar ca auto-evaluare

### Resurse digitale

- ▣ **Slide-uri + cod:** <https://danpele.github.io/SFM/>
- ▣ **Quantlet-uri interactive:** [https://github.com/QuantLet/Stat\\_fin\\_markets/tree/master/Ch\\_02](https://github.com/QuantLet/Stat_fin_markets/tree/master/Ch_02)
- ▣ **Forum de discuții:** Platforma e-learning ASE

## Cuprins

- ▣ Introducere — De ce contează distribuțiile
- ▣ De la prețuri la log-randamente
- ▣ Distribuția normală
- ▣ Fapte stilizate ale randamentelor financiare
- ▣ Distribuția Student- $t$
- ▣ Distribuția Pareto
- ▣ Studiu de caz
- ▣ Quiz & Exerciții de examen



## De ce contează alegerea distribuției?

(ext. Cap. 1)

- ▣ Dacă presupunem o distribuție greșită, **subestimăm** probabilitatea pierderilor extreme
- ▣ **Exemplu:** 19 octombrie 1987 — S&P 500 a scăzut cu 20,5% într-o singură zi
  - ▶ Sub ipoteza normală ( $\sigma \approx 1\%$ ): un eveniment de  $\sim 20\sigma$  cu probabilitate  $\approx 10^{-89}$
  - ▶ Și totuși s-a întâmplat — distribuția normală este inadecvată pentru evenimente extreme
- ▣ Băncile și autoritățile de reglementare trebuie să cuantifice „cât de rău poate fi?”
- ▣ Acest lucru necesită **modele distribuționale precise**

### Idee cheie

- ▣ Alegerea distribuției de probabilitate determină direct cât capital trebuie să dețină o bancă pentru acoperirea pierderilor potențiale

## Problema alegerii distribuției

- **Anticipare:** Mai târziu vom defini formal **Value-at-Risk (VaR)**, o măsură cheie de risc care depinde complet de ipoteza distribuțională
- Candații pe care îi vom studia:
  - ▶ **Normală** — referința clasică (cozi subțiri)
  - ▶ **Student- $t$**  — cozi mai groase, momente superioare finite
  - ▶ **Stabilă** — cele mai groase cozi, varianță infinită (*infinite variance*) posibilă
  - ▶ **EVT** — modelează doar cozile, agnostică față de centru
- Fiecare model implică un răspuns diferit la „cât de rău poate fi?”

| Model        | Tip coadă    | Kurtosis | Parametri |
|--------------|--------------|----------|-----------|
| Normal       | Exponențială | 3        | 2         |
| Student- $t$ | Lege putere  | $> 3$    | 3         |
| Stabilă      | Lege putere  | $\infty$ | 4         |
| GPD (EVT)    | Flexibilă    | —        | 2         |

## Structura capitolului

### Fundamente

1. De la prețuri la log-randamente
2. Distribuția normală (referință)
3. Fapte stilizate ale randamentelor
4. Distribuția Student- $t$

### Modele de coadă și aplicații

5. Distribuția Pareto (legea de putere)
6. **Studiu de caz** (S&P 500, BRD, Bitcoin)
7. Quiz & Exerciții de examen


## Alegerea distribuției și evaluarea instrumentelor financiare derivate

- ▣ Black–Scholes presupune log-normalitate  $\Rightarrow$  volatilitate implicită constantă
- ▣ Deviațiile empirice produc **zâmbetul/asimetria volatilității** (*volatility smile/skew*)
- ▣ Optimizarea portofoliului sub randamente non-Gaussiene: medie-varianță este suboptimală
- ▣ Context de reglementare: Basel II  $\rightarrow$  Basel III/IV
  - ▶ Basel II: VaR 1% cu ipoteză normală
  - ▶ Basel III/IV (FRTB, 2023): trecerea de la VaR 1% la ES 2,5%

### Observație 1

- ▣ Întregul cadru Basel de capital de reglementare se bazează pe ipoteze distribuționale
- ▣ Subestimarea riscului de coadă  $\Rightarrow$  capital insuficient  $\Rightarrow$  fragilitate sistemică

## S&P 500: cum arată lumea reală



- ▣ Crahurile ( $|r_t| > 3\sigma$ ) apar mult mai frecvent decât prevede distribuția normală
- ▣ Randamentele extreme se **clusterizează**; avem nevoie de modele cu cozi groase (*heavy tails*)

 SFM\_ch2\_stylized\_facts

## Distribuția normală vs. realitate — Vizualizare și exemplu

(ext. Cap. 1)

### Black Monday — 19 oct. 1987

S&P 500 a scăzut cu 20,5% într-o singură zi.


- ▣ Sub ipoteza normală ( $\sigma \approx 1\%$ ): un eveniment de  $\sim 20\sigma$  cu  $P \approx 10^{-89}$
- ▣ Sub Student- $t$  ( $\nu=4$ ):  $P \approx 10^{-5}$  — de  $10^{84} \times$  mai plauzibil

### Timpul de revenire

- ▣  $T = \frac{1}{252 \times 10^{-89}} \approx 4 \times 10^{86}$  ani; vârsta universului:  $\approx 1,4 \times 10^{10}$  ani
- ▣  $\Rightarrow \sim 10^{76}$  **vârste ale universului!**
- ▣ Alegerea distribuției nu este un detaliu tehnic — este o **decizie de business**

 SFM\_ch2\_normal\_distribution

## Distribuția normală vs. realitate — Grafic



SFM\_ch2\_normal\_distribution

## Recapitulare din Cap. 1: Log-randamente

### Definiție (v. Cap. 1)

- ▣  $r_t = \ln(P_t/P_{t-1})$  — aditive în timp, simetrice, nemărginite inferior
- ▣ Randament simplu:  $R_t = (P_t - P_{t-1})/P_{t-1}$ ; relație:  $r_t = \ln(1 + R_t)$


### De ce contează pentru acest capitol?

- ▣ Aditivitatea  $r_{[0,T]} = \sum r_t$  permite aplicarea **TLC** și a teoriei distribuțiilor
- ▣ Întrebarea centrală: **ce distribuție** urmează  $r_t$ ? Normală? Student- $t$ ? Pareto?
- ▣ Convenție:  $r_t$  denotă **log-randamentul** pe tot parcursul capitolului



## Limita în timp continuu

- ▣ Mișcarea Browniană geometrică:  $dS/S = \mu dt + \sigma dW$
- ▣ Prin lema lui Itô:  $d \ln S = (\mu - \sigma^2/2) dt + \sigma dW$
- ▣ Inegalitatea lui Jensen:  $\mathbb{E}[\ln(P_T/P_0)] \neq \ln(\mathbb{E}[P_T/P_0])$ 
  - ▶ Randamentul mediu aritmetic depășește randamentul mediu geometric
  - ▶ Diferența  $\approx \sigma^2/2$  („pierdere din volatilitate (*volatility drag*)”)
- ▣ Log-randamente: aditive în *timp*; randamente simple: aditive pe *active*



## Pierderea din volatilitate (*Volatility Drag*) — Demonstrație

### Exercițiu mental

- ▣ Portofoliul tău crește cu 50% azi și scade cu 50% mâine
- ▣ Randamentul mediu aritmetic:  $(+50\% - 50\%)/2 = 0\%$ . Dar banii reali?
- ▣  $100\$ \rightarrow 150\$ \rightarrow 75\$$ . Ai pierdut **25%**!

### De ce log-randamentele spun adevărul

- ▣  $r_1 = \ln(1,5) = +40,5\%$ ,  $r_2 = \ln(0,5) = -69,3\%$
- ▣ Suma:  $r_1 + r_2 = -28,8\% = \ln(0,75)$  ✓ (aditivitatea funcționează!)
- ▣ Randamentul simplu **nu** este aditiv:  $(+50\%) + (-50\%) \neq \ln(0,75)$
- ▣ **Regula:**  $\mathbb{E}[\text{rand. geometric}] \approx \mathbb{E}[\text{rand. aritmetic}] - \sigma^2/2$ ; volatilitate mare  $\Rightarrow$  pierdere reală mai severă

## Reprezentarea semimartingală

(optional)

- ▣ Procesele de preț modelate ca **semimartingale**:  $S_t = S_0 + A_t + M_t$
- ▣ Lema lui Itô pentru semimartingale cu salturi:

$$d \ln S_t = \frac{dS_t}{S_{t-}} - \frac{1}{2} \frac{d[S, S]_t^c}{S_{t-}^2} + \sum_{s \leq t} \left( \ln \frac{S_s}{S_{s-}} - \frac{\Delta S_s}{S_{s-}} \right)$$

- ▣ Variația quadratică și volatilitatea realizată:

$$[X, X]_t = \lim_{\|\Pi\| \rightarrow 0} \sum_i (X_{t_{i+1}} - X_{t_i})^2$$

- ▣ Procese de preț discontinue: salturi și descompunerea Lévy-Itô

## Exemplu numeric: Calculul log-randamentelor

## Exercițiu

Prețuri:  $P_0=100$ ,  $P_1=103$ ,  $P_2=101$ ,  $P_3=105$ ,  $P_4=102$ . Calculați log-randamentele, media și varianța.

## Rezolvare

| $t$                 | $P_t$ | $R_t$  | $r_t$                                               | $r_t - \bar{r}$ | $(r_t - \bar{r})^2$ |
|---------------------|-------|--------|-----------------------------------------------------|-----------------|---------------------|
| 1                   | 103   | +3,00% | +2,96%                                              | 2,46%           | 0,0605%             |
| 2                   | 101   | -1,94% | -1,96%                                              | -2,46%          | 0,0605%             |
| 3                   | 105   | +3,96% | +3,88%                                              | 3,38%           | 0,1143%             |
| 4                   | 102   | -2,86% | -2,90%                                              | -3,40%          | 0,1153%             |
| $\bar{r} = 0,495\%$ |       |        | $s^2 = \frac{\sum (r_t - \bar{r})^2}{3} = 0,1169\%$ |                 |                     |

▣ **Aditivitate:**  $r_{[0,4]} = \ln(102/100) = 1,98\% = \sum_{t=1}^4 r_t$  ✓

## „Prințul matematicienilor”



Carl Friedrich Gauss  
(1777–1855)

### De la stele la Wall Street

- ▣ A derivat curba normală în 1809 pentru **erorile astronomice**
- ▣ Ideea: erorile sunt suma multor perturbații mici și independente
- ▣ Apare pe **bancnota de 10 DM** — singura distribuție de pe o bancnotă!

### Avertismentul

- ▣ Gauss a demonstrat-o pentru erori de măsurare, **nu** pentru piețe financiare
- ▣ Wall Street a adoptat-o oricum — consecințele le vom vedea în acest capitol

## Singura distribuție de pe o bancnotă



- 10 Deutsche Mark (seria IV, 1993–2001): Gauss + curba normală cu formula  $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$
- Pe verso: sextantul lui Gauss și rețeaua de triangulație geodezică a Germaniei

## Distribuția normală — Definiție și proprietăți

### Definiție 1 (Distribuția normală)

$X \sim N(\mu, \sigma^2)$  dacă:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$


### Momente

- ▣  $\mathbb{E}[X] = \mu, \quad \text{Var}(X) = \sigma^2$
- ▣ Asimetrie = 0
- ▣ Kurtosis = 3 (exces de kurtosis = 0)

### Proprietăți cheie

- ▣ Simetrică față de  $\mu$
- ▣ Regula 68–95–99,7
- ▣ Cozile scad ca  $e^{-x^2/2}$

## Distribuția normală — Graficul densității

 SFM\_ch2\_normal\_distribution

- **Clopotul lui Gauss:** formă simetrică, unimodală, maximă în  $x = \mu$
- Parametrii  $\mu$  și  $\sigma^2$  controlează **poziția** și **dispersia**
- Cozile scad **exponențial**:  $f(x) \sim e^{-x^2/2}$  — subestimează evenimentele extreme



## Cuantile normale și conexiunea cu VaR

- ▣ **Cuantile:** Cuantila de ordin  $\alpha$  a  $N(\mu, \sigma^2)$  este:


$$q_\alpha = \mu + \sigma \Phi^{-1}(\alpha)$$

- ▣ Aceasta va fi utilizată pentru a defini Value-at-Risk
- ▣ **Cuantile cheie:**  $\Phi^{-1}(0,01) = -2,326$ ,  $\Phi^{-1}(0,05) = -1,645$

### Observație 2

- ▣ **TLC** (v. Cap. 1):  $(\bar{X}_n - \mu)/(\sigma/\sqrt{n}) \xrightarrow{d} N(0, 1)$  dacă  $\sigma^2 < \infty$
- ▣ **Stabilitate:**  $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$
- ▣ **Întrebarea cheie:** ce se întâmplă dacă  $\sigma^2 = \infty$ ?  $\Rightarrow$  limite *stabile*, nu normale


## Ilustrarea TLC



SFM\_ch2\_normal\_distribution

- Pe măsură ce  $n$  crește,  $\bar{X}_n$  se apropie de normalitate
- Limitare:** TLC necesită varianță finită — ce se întâmplă dacă  $\sigma^2 = \infty$ ?

## Ajustarea normală pe randamentele S&P 500



 SFM\_ch2\_normal\_distribution

- PDF-ul distribuției normale se potrivește rezonabil în centru, dar **ratează cozile**
- Histograma are mai multă masă în cozi decât prevede distribuția normală

## Testul Jarque–Bera

- ▣ **Entropie maximă:** Dintre toate distribuțiile cu  $(\mu, \sigma^2)$  date, distribuția normală maximizează entropia Shannon  $H = -\int f \ln f \, dx$

### Ipoteze

$H_0: S = 0$  și  $K = 3$  (datele provin dintr-o distribuție normală)

$H_1: S \neq 0$  sau  $K \neq 3$  (abatere de la normalitate)

### Statistica de test

$$JB = \frac{n}{6} \left( S^2 + \frac{(K - 3)^2}{4} \right) \xrightarrow{d} \chi^2(2)$$

- ▣  $S = \frac{1}{n} \sum \left( \frac{x_i - \bar{x}}{s} \right)^3$  (asimetrie),  $K = \frac{1}{n} \sum \left( \frac{x_i - \bar{x}}{s} \right)^4$  (kurtosis)
- ▣ Respingem  $H_0$  dacă  $JB > \chi^2_{2; 1-\alpha}$ . Pentru  $\alpha = 5\%$ :  $\chi^2_{2; 0,95} = 5,99$

## Testul Shapiro–Wilk

### Testul Shapiro–Wilk (1965)

$H_0$ : datele provin dintr-o distribuție normală vs.  $H_1$ : non-normalitate

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad W \in (0, 1]$$

- ▣  $x_{(i)}$  = statisticile de ordine (*order statistics*) ale eșantionului
- ▣  $a_i$  = coeficienți tabelați, depind de  $n$
- ▣ Respingem  $H_0$  dacă  $W$  este prea mic (aproape de 0)
- ▣ Cel mai puternic test pentru eșantioane mici ( $n < 50$ )

## Testele Anderson–Darling și Kolmogorov–Smirnov

### Testul Anderson–Darling (1954)

$$H_0: F = F_0 \quad \text{vs.} \quad H_1: F \neq F_0$$

$$A^2 = -n - \frac{1}{n} \sum_{i=1}^n (2i-1) [\ln F_0(x_{(i)}) + \ln(1 - F_0(x_{(n+1-i)}))]$$

- ▣ Ponderat pe cozi: mai sensibil la devieri în extremele distribuției decât KS


### Testul Kolmogorov–Smirnov (1933)

- ▣  $H_0: F = F_0 \quad \text{vs.} \quad H_1: F \neq F_0$

$$D_n = \sup_x |F_n(x) - F_0(x)|$$

- ▣ Non-parametric; mai puțin sensibil la cozi decât AD

## Teste de normalitate — Vizualizare



B. Normality Test Results

| Test             | Statistic | p-value / Critical | Reject H <sub>0</sub> (5%) |
|------------------|-----------|--------------------|----------------------------|
| Jarque-Bera      | 30876.71  | p = 0.00e+00       | Yes                        |
| Shapiro-Wilk     | 0.909685  | p = 1.64e-47       | Yes                        |
| Anderson-Darling | 126.2996  | cv(5%) = 0.7520    | Yes                        |

Sample size: n = 6,537  
Skewness: -0.3450 | Excess kurtosis: 10.6242  
H<sub>0</sub>: Data follows a Normal distribution

 SFM\_ch2\_normal\_distribution

- Rezultatele testelor pe randamentele S&P 500 resping **masiv** ipoteza de normalitate
- Testul JB:  $p$ -value  $\approx 0$  (asimetrie și kurtosis diferite de valorile normale)

## Teste de normalitate — Rezultate empirice (S&amp;P 500)

| Test               | Statistica | $p$ -value | Decizia         |
|--------------------|------------|------------|-----------------|
| Jarque–Bera        | $> 1000$   | $< 0,001$  | Respingem $H_0$ |
| Shapiro–Wilk       | $< 0,99$   | $< 0,001$  | Respingem $H_0$ |
| Anderson–Darling   | $> 10$     | $< 0,001$  | Respingem $H_0$ |
| Kolmogorov–Smirnov | $> 0,05$   | $< 0,001$  | Respingem $H_0$ |

## Concluzie

- ▣ Normalitatea este respinsă **covârșitor** pentru randamentele financiare zilnice
- ▣ Distribuția normală subestimează sistematic riscul de coadă



## Marginile Berry–Esseen și ratele de convergență

(ext. Cap. 1)

## Teoremă 1 (Berry–Esseen)

Dacă  $X_1, X_2, \dots$  sunt i.i.d. cu  $\mathbb{E}[X_i] = 0$ ,  $\mathbb{E}[X_i^2] = \sigma^2$ ,  $\mathbb{E}[|X_i|^3] = \rho < \infty$ , atunci:

$$\sup_x |F_n(x) - \Phi(x)| \leq \frac{C \rho}{\sigma^3 \sqrt{n}}$$

unde  $C \leq 0,4748$  (Shevtsova, 2011).

- ▣ Rata de convergență:  $O(n^{-1/2})$  — lentă pentru date cu cozi groase
- ▣ Expansiunile Edgeworth rafinează aproximarea TLC pentru  $n$  finit
- ▣ **Distribuția normală ca distribuție stabilă:**  $N(\mu, \sigma^2) = S(2, 0, \sigma/\sqrt{2}, \mu)$  — membrul  $\alpha = 2$  al familiei stabile
- ▣ Când  $\mathbb{E}[X_i^2] = \infty$ : TLC eșuează, dar **TLC Generalizată** dă limite stabile

## Regimul pre-asimptotic — De ce TLC nu ne salvează

### Conexiunea Berry-Esseen $\leftrightarrow$ Gaussianitate agregată

- TLC ne **promite** convergența spre normalitate pe măsură ce agregăm
- Dar Berry-Esseen arată că viteza depinde de  $\rho/\sigma^3$  (momentul de ordin 3)
- Randamentele financiare au  $\rho/\sigma^3$  **foarte mare** (cozi groase)  $\Rightarrow$  convergența este **dureros de lentă**

### Implicație practică

- Dacă randamentele ar avea cozi subțiri, 22 de zile (o lună) ar fi suficiente pentru normalitate perfectă
- Din cauza cozilor groase, nici măcar agregatele **anuale** nu sunt perfect Gaussiene
- **Concluzie** (Taleb): în finanțe, trăim permanent în *regimul pre-asimptotic* — TLC este o promisiune pe care datele noastre nu o pot onora

## Exemplu: Probabilitatea unei pierderi mari sub distribuția normală

### Exercițiu

Un portofoliu are  $\sigma = 1,5\%$  zilnic. Sub ipoteza normală cu  $\mu = 0$ , calculați  $P(\text{pierdere} > 3\sigma)$ . Câte zile pe an se așteaptă o astfel de pierdere? Comparați cu frecvența empirică.

### Rezolvare

$P(r < -3\sigma) = \Phi(-3) = 0,00135$  (0,135%). Cu 252 zile/an:  $252 \times 0,00135 = 0,34$  zile/an (o dată la  $\sim 3$  ani).

### Realitatea empirică

- S&P 500 (1990–2023): pierderi  $> 4,5\%$  apar  $\approx 0,7$  ori/an — **2× mai frecvent** decât sub distribuția normală
- Pierderi  $> 5\sigma$ : distribuția normală prevede 1 eveniment la 13.932 ani; empiric, apare la decenii
- **Concluzie:** Distribuția normală subestimează dramatic riscul de coadă

## Opriti-vă și gândiți-vă

(auto-evaluare)

## Verificare rapidă — Distribuția normală

1. Testul Jarque–Bera respinge normalitatea pe S&P 500. Ce anume măsoară: media și varianța, sau asimetria și kurtosis-ul?
2. Un portofoliu cu  $\sigma = 1,5\%$  suferă o pierdere de  $-6\%$  într-o zi. Sub distribuția normală, câte abateri standard reprezintă? Este plauzibil?
3. Dacă TLC ne spune că sumele converg la normală, de ce randamentele lunare **tot** nu sunt perfect Gaussiene?

## Răspunsuri

1. JB testează  $S = 0$  și  $K = 3$ ; nu depinde de  $\mu$  sau  $\sigma$ .
2.  $-6\%/1,5\% = 4\sigma$ ; sub normală:  $P \approx 0,003\%$  (1 zi/31.574). Empiric, apare la câțiva ani.
3. Convergența TLC este **lentă** când cozile sunt groase (Berry–Esseen:  $O(n^{-1/2})$  cu constantă mare).

## De la distribuția normală la realitate — Ce urmează?

Am stabilit: distribuția normală este inadecvată

- ▣ Testele (JB, SW, AD, KS) **resping covârșitor** normalitatea pe S&P 500
- ▣ Pierderi  $> 3\sigma$  apar de  $\sim 4\times$  mai frecvent decât prevede normala
- ▣ Dar **cum arată** abaterile? Sunt sistematice sau idiosincratice?

Următorul pas: faptele stilizate

- ▣ Vom documenta **regularitățile universale** ale randamentelor financiare
- ▣ Aceste fapte stilizate sunt **criteriile** pe care orice model alternativ trebuie să le îndeplinească
- ▣ Taxonomia Cont (2001): 11 fapte stilizate observate pe sute de active, piețe și perioade

## Omul care a spart curba clopoțelului



Benoît Mandelbrot  
(1924–2010)

### De la bumbac la fractali

- ▣ **1963**: prețurile bumbacului au variații *mult* prea mari pentru normală
- ▣ Propune distribuțiile **stabile Lévy** ( $\alpha < 2$ ) — cozi groase, varianță infinită
- ▣ Inventatorul **geometriei fractale**; auto-similaritate la orice scară
- ▣ „*Piețele sunt mai riscante decât cred oamenii*”

### Moștenirea

- ▣ Ignorat 40 de ani de Wall Street, care a preferat modelul Gaussian
- ▣ Criza din 2008 i-a dat dreptate — modelele cu cozi subțiri au eșuat spectaculos

## Cozi groase și exces de kurtosis

(ext. Cap. 1)

- ▣ **Kurtosis:**  $\kappa = \mathbb{E}[(X - \mu)^4]/\sigma^4$ ;    exces de kurtosis:  $\kappa_e = \kappa - 3$
- ▣ Distribuția normală:  $\kappa_e = 0$
- ▣ Kurtosis tipică pentru acțiuni zilnice:  $\kappa \in [5, 50]$ , deci  $\kappa_e \gg 0$
- ▣ **Interpretare:** Randamentele extreme apar mult mai frecvent decât prevede distribuția normală

| Activ             | Asimetrie | Exces de kurtosis |
|-------------------|-----------|-------------------|
| S&P 500 (zilnic)  | -0,3      | $\approx 10$      |
| FTSE 100 (zilnic) | -0,2      | $\approx 8$       |
| USD/EUR (zilnic)  | -0,1      | $\approx 5$       |
| Bitcoin (zilnic)  | -0,5      | $\approx 15$      |

## Asimetrie negativă și clusterizarea volatilității

### Asimetrie negativă

- ▣ Coada stângă mai grea decât cea dreaptă
- ▣ Mai pronunțată pentru indici de acțiuni
- ▣ Prăbușirile sunt mai abrupte decât raliul
- ▣ Asimetrie  $S = \mathbb{E}[(X - \mu)^3]/\sigma^3 < 0$

### Clusterizarea volatilității

- ▣ „Variații mari urmate de variații mari” (Mandelbrot, 1963)
- ▣  $\text{Corr}(|r_t|, |r_{t+k}|) > 0$  pentru  $k$  mare
- ▣ Randamentele sunt necorelate dar **nu independente**
- ▣  $\text{Corr}(r_t, r_{t+k}) \approx 0$  dar  $\text{Corr}(r_t^2, r_{t+k}^2) > 0$

### Implicație

- ▣ O singură distribuție i.i.d. nu poate surprinde clusterizarea volatilității
- ▣ Avem nevoie de modele cu varianță variabilă în timp (GARCH, v. capitolele următoare)



## Gaussianitate agregată

- ▣ **Observație cheie:** Pe măsură ce orizontul de deținere crește, distribuția randamentelor devine *mai Gaussiană*
- ▣ Randamente zilnice: kurtosis ridicată, cozi groase
- ▣ Randamente săptămânale: kurtosis moderată
- ▣ Randamente lunare: mai aproape de distribuția normală
- ▣ **Mecanism:** Efect similar TLC — randamentul lunar =  $\sum$  din  $\sim 22$  randamente zilnice

| Frecvență    | Exces de kurtosis | JB $p$ -value  |
|--------------|-------------------|----------------|
| Zilnică      | $\approx 10$      | $< 0,001$      |
| Săptămânală  | $\approx 4$       | $< 0,001$      |
| Lunară       | $\approx 1,5$     | $\approx 0,05$ |
| Trimestrială | $\approx 0,5$     | $\approx 0,3$  |

## Rezumatul faptelor stilizate

1. **Cozi groase:**  $\kappa_e \gg 0$  — evenimente extreme mai frecvente decât sub normală
2. **Asimetrie negativă:** Coadă stângă mai grea (acțiuni)
3. **Clusterizarea volatilității:** Perioade de volatilitate mare/mică persistă
4. **Gaussianitate agregată:** Kurtosis scade cu orizontul
5. **Absența autocorelației randamentelor:**  $\text{Corr}(r_t, r_{t+k}) \approx 0$  pentru  $k \geq 1$
6. **Autocorelația randamentelor pătrate:**  $\text{Corr}(r_t^2, r_{t+k}^2) > 0$

### Provocarea

- Orice model adecvat pentru randamentele financiare trebuie să reproducă aceste fapte stilizate
- Distribuția normală eșuează la punctele 1, 2 și 3

## Efectul de levier și memoria lungă

### Efectul de levier

- ▣ Randamentele negative cresc volatilitatea viitoare *mai mult* decât randamentele pozitive de aceeași magnitudine
- ▣ Răspuns asimetric:  $\text{Corr}(r_t, \sigma_{t+1}^2) < 0$
- ▣ Denumit după Black (1976): scăderea prețului  $\Rightarrow$  levier mai mare  $\Rightarrow$  risc mai mare
- ▣ Capturat de GJR-GARCH, EGARCH

### Memoria lungă în volatilitate

- ▣  $\text{Corr}(|r_t|, |r_{t+k}|)$  scade *lent* (hiperbolic, nu exponențial)
- ▣ Exponentul Hurst  $H > 0,5$  pentru  $|r_t|$
- ▣ GARCH standard: descreștere exponențială
- ▣ Modelele FIGARCH, HAR surprind memoria lungă

## Asimetria câștig/pierdere

- ▣ **Asimetria câștig/pierdere:** Prețurile acțiunilor scad mai repede decât cresc
- ▣ Scăderile mari au loc în zile; recuperarea durează luni sau ani
- ▣ Această asimetrie este distinctă de asimetria distribuției — privește *dinamica*, nu distribuția marginală
- ▣ **Efect volumetric:** Volumul de tranzacționare crește în episoadele de volatilitate mare
  - ▶ Corelație pozitivă între  $|r_t|$  și volumul zilnic
  - ▶ Amplificată de *margin calls* și vânzări forțate

## Taxonomia Cont (2001) — Fapte stilizate 1–6

(ext. Cap. 1)

1. **Absența autocorelației:**  $\text{Corr}(r_t, r_{t+\tau}) \approx 0, \tau \geq 1$ 
  - ▶ Eficiență informațională; excepție: intra-zilnic (*bid-ask bounce*)
2. **Cozi groase:**  $\kappa_e \gg 0$ ; evenimente  $> 3\sigma$  mult mai frecvente decât sub normală
  - ▶ Stabil între piețe:  $\kappa_e \in [5, 50]$  pentru acțiuni zilnice
3. **Gaussianitate agregată:** kurtosis scade cu orizontul temporal
  - ▶ Randamente lunare mai apropiate de normală; mecanism: efect TLC
4. **Clusterizarea volatilității:**  $\text{Corr}(|r_t|, |r_{t+\tau}|) > 0$  persistent
  - ▶ „Variații mari urmate de variații mari” (Mandelbrot, 1963)
  - ▶ Modele: GARCH, volatilitate stochastică
5. **Efectul de levier:**  $\text{Corr}(r_t, \sigma_{t+1}^2) < 0$  (Black, 1976)
  - ▶ Scăderi  $\Rightarrow$  levier  $\uparrow \Rightarrow$  volatilitate  $\uparrow$ ; modele: GJR-GARCH, EGARCH
6. **Corelație volum-volatilitate:**  $\text{Corr}(V_t, |r_t|) > 0$ 
  - ▶ Zilele volatile au volume mai mari; amplificat de *margin calls*

## Taxonomia Cont (2001) — Fapte stilizate 7–11

(ext. Cap. 1)

7. **Asimetrie:** randamente negative mai extreme decât cele pozitive
    - ▶ Specific acțiunilor ( $S \in [-0,5, -0,1]$ ); FX poate fi simetric
  8. **Asimetrie câștig/pierdere:** scăderile mari — rapide; recuperările — lente
    - ▶ Privește *dinamica*, nu forma statică a distribuției
  9. **Invariantă de scară:** pattern-uri similare la scale temporale diferite
    - ▶ Graficele la 5 min, 1 oră, 1 zi au aceeași „textură” (structură fractală)
  10. **Memoria lungă a volatilității:**  $\text{Corr}(|r_t|, |r_{t+\tau}|) \propto \tau^{2H-2}$ ,  $H > 0,5$ 
    - ▶ Descreștere *hiperbolică*, nu exponențială
    - ▶ Modele: FIGARCH, HAR (Corsi, 2009)
  11. **Descreștere lentă a autocorelației  $|r_t|$** 
    - ▶ GARCH standard prezice descreștere exponențială — insuficientă
    - ▶ Necesită modele cu memorie lungă sau componente multiple
- **Modele multifractale** (Mandelbrot et al., 1997):  $\mathbb{E}[|r_t|^q] \propto \Delta t^{\zeta(q)}$  cu  $\zeta(q)$  concav

## De ce apar faptele stilizate? — Microstructura pieței

### Cozile groase — mecanisme de feedback pozitiv

- ▣ Într-o criză, scăderea prețului declanșează **apeluri în marjă** (*margin calls*)
- ▣ Investitorii sunt forțați să vândă  $\Rightarrow$  prețul scade mai mult  $\Rightarrow$  noi margin calls
- ▣ Ordinele automate *stop-loss* amplifică mișcarea: vânzare automată sub un prag
- ▣ Rezultat: pierderi mult mai mari decât prevede distribuția normală

### Clusterizarea volatilității — fragmentarea informației


- ▣ Ordinele instituționale mari sunt fragmentate și executate pe parcursul mai multor zile
- ▣ Informația se integrează *gradual* în preț, nu instantaneu (piețe imperfect eficiente)
- ▣ **Consecință:** perioade prelungite de volatilitate mare (sau mică)
- ▣ Efectul de levier (Black, 1976): scăderea  $\Rightarrow$  levier mai mare  $\Rightarrow$  risc perceput mai mare  $\Rightarrow$  volatilitate crește

## Structura fractală și legile putere

- ▣ **Cozi tip lege putere (*power law*):**  $P(|r| > x) \sim x^{-\alpha}$  cu  $\alpha \in [2, 5]$  pentru majoritatea activelor financiare
- ▣ Exponentul de coadă  $\alpha$  este remarcabil de stabil între active și perioade
- ▣ **Auto-similaritate:** Distribuțiile randamentelor la scale temporale diferite sunt legate prin scalare
- ▣ Conexiunea cu distribuțiile stabile: dacă  $\alpha < 2$ , TLC Generalizată implică limite stabile
- ▣ „Legea cubului invers” (Gopikrishnan et al., 1999):  $\alpha \approx 3$  pentru acțiunile americane
- ▣ Dezbattere: lege putere reală vs. cozi cu variație lentă



## Vizualizarea clusterizării volatilității



SFM\_ch2\_stylized\_facts

- „Variații mari urmate de variații mari” (Mandelbrot, 1963) — crizele 2001, 2008, 2020
- $\text{Corr}(r_t, r_{t+k}) \approx 0$  dar  $\text{Corr}(|r_t|, |r_{t+k}|) > 0$  — necorelate, dar **nu independente**

## Ecuatiile faptelor stilizate — Kurtosis și autocorelația

### Kurtosis

$$\kappa = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4}$$

- ▣ **Exces de kurtosis:**  $\kappa_e = \kappa - 3$
- ▣  $\kappa_e = 0$ : normală;  $\kappa_e > 0$ : **leptocurtică**

### Autocorelația $r_t^2$

$$\rho_k = \text{Corr}(r_t^2, r_{t+k}^2) > 0, \quad k \text{ mare}$$

### Exemplu numeric

|          | $\kappa$     | $\kappa_e$   |
|----------|--------------|--------------|
| Normal   | 3            | 0            |
| S&P 500  | $\approx 10$ | $\approx 7$  |
| FTSE 100 | $\approx 8$  | $\approx 5$  |
| Bitcoin  | $\approx 15$ | $\approx 12$ |

- ▣  $\kappa_e = 7$  pentru S&P 500  $\Rightarrow$  cozi **substanțial mai groase** decât normala

## Previzualizare: Măsuri de risc — VaR și ES

### Definiție 2 (Value-at-Risk — definiție de lucru)

**Value-at-Risk** la nivelul  $\alpha$ : pierderea maximă care **nu** este depășită cu probabilitatea  $(1 - \alpha)$ :

$$\text{VaR}_\alpha = -F^{-1}(\alpha), \quad \text{unde } F^{-1} \text{ este cuantila randamentelor.}$$


### Definiție 3 (Expected Shortfall — definiție de lucru)

**Expected Shortfall** (ES) la nivelul  $\alpha$ : pierderea **medie** în cele mai grave  $\alpha\%$  scenarii:

$$\text{ES}_\alpha = -\frac{1}{\alpha} \int_0^\alpha F^{-1}(p) dp.$$

- ▣ **Exemplu:** VaR 1% normală,  $\sigma = 1,5\%$ , \$1M:  $\text{VaR} = 2,326 \times 0,015 \times 10^6 = \$34.890$
- ▣ Proprietăți formale, coerența Artzner, backtesting — **capitolele următoare**

## VaR și ES — Ilustrare grafică



SFM\_ch2\_risk\_management

- ▣ **VaR<sub>α</sub>**: cuantila — „nu vom pierde mai mult de  $X$  cu prob.  $1 - \alpha$ ”
- ▣ **ES<sub>α</sub>**: media cozii — „dacă depășim VaR, cât pierdem *în medie*?”
- ▣  $ES \geq VaR$  întotdeauna; diferența crește cu grosimea cozilor

## Opriti-vă și gândiți-vă

(auto-evaluare)

### Verificare rapidă — Fapte stilizate

1. Randamentele zilnice au  $\text{Corr}(r_t, r_{t+1}) \approx 0$ , dar  $\text{Corr}(r_t^2, r_{t+1}^2) > 0$ . Ce înseamnă acest lucru pentru dependența temporală?
2. Un model i.i.d. poate reproduce clusterizarea volatilității? De ce?
3. Dacă kurtosis-ul scade de la 10 (zilnic) la 1,5 (lunar), ce mecanism explică acest fenomen?

### Răspunsuri

1. Randamentele sunt **necorelate** (nu putem prezice direcția), dar **nu independente** (putem prezice magnitudinea).
2. Nu — i.i.d. implică independență completă; clusterizarea necesită modele condiționale (GARCH).
3. **Gaussianitate agregată**: efect TLC; suma a  $\sim 22$  randamente zilnice converge spre normală.

## Cine este „Student”?



William Sealy Gosset  
(1876–1937)

### Povestea din spatele pseudonimului

- Chimist la fabrica de bere **Guinness**, Dublin
- Problema: cum testezi calitatea berii din eșantioane **foarte mici**? ( $n = 3-4$ )
- Guinness **interzicea** publicarea — secret comercial!
- Soluția: publică sub pseudonimul „**Student**” (1908)

### De ce contează pentru finanțe?

- Normala cu  $\sigma$  *estimat* nu mai este normală — este Student- $t$ !
- Ironia: inventată pentru bere, acum modelează crahuri bursiere


## Distribuția Student- $t$ — Definiție

### Definiție 4 (Distribuția Student- $t$ )

$X \sim t_\nu$  dacă:

$$f(x; \nu) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi} \Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu}\right)^{-(\nu+1)/2}, \quad x \in \mathbb{R}.$$


- Un singur parametru  $\nu > 0$  (**grade de libertate**) controlează grosimea cozilor
- $\mathbb{E}[X] = 0$  ( $\nu > 1$ );  $\text{Var}(X) = \frac{\nu}{\nu-2}$  ( $\nu > 2$ )
- Exces de kurtosis:  $\kappa_e = \frac{6}{\nu-4}$  ( $\nu > 4$ )
- $\nu \rightarrow \infty$ : converge la  $N(0, 1)$ ;  $\nu = 1$ : distribuția Cauchy
- Cozi:  $f(x) \sim |x|^{-(\nu+1)}$  (**lege putere**)

PDF-uri Student- $t$  — Efectul lui  $\nu$ 

SFM\_ch2\_student\_t

- $\nu$  mai mic  $\Rightarrow$  cozi mai groase, vârf mai ascuțit
- Randamente financiare: de regulă  $\hat{\nu} \in [3, 8]$  pentru date zilnice de acțiuni



Ajustarea Student- $t$  pe S&P 500

SFM\_ch2\_student\_t

- Student- $t$  surprinde cozile groase mult mai bine decât distribuția normală
- $\hat{\nu} \approx 4-5$  pentru S&P 500 (depinde de perioada de estimare); centrul și cozile bine ajustate

De ce Student- $t$  pentru finanțe?

| Proprietate        | Normal                        | Student- $t$                        |
|--------------------|-------------------------------|-------------------------------------|
| Descreșterea cozii | Exponențială ( $e^{-x^2/2}$ ) | Lege putere ( $ x ^{-\nu-1}$ )      |
| Exces de kurtosis  | 0                             | $6/(\nu - 4)$                       |
| Parametri          | 2 ( $\mu, \sigma$ )           | 3 ( $\mu, \sigma, \nu$ )            |
| Evenimente extreme | Foarte rare                   | Mai frecvente                       |
| Limită             | —                             | Normal ( $\nu \rightarrow \infty$ ) |

## Avantaj cheie

- Student- $t$  **include** distribuția normală ca un caz special ( $\nu \rightarrow \infty$ ) permițând în același timp cozi mai groase
- Este cea mai simplă alternativă cu cozi groase

## Forma locație-scală și MLE

▣ **Forma locație-scală:**  $X = \mu + \sigma T$ , unde  $T \sim t_\nu$

▣ Estimare MLE a  $(\mu, \sigma, \nu)$ : maximizăm

$$\ell(\mu, \sigma, \nu) = \sum_{t=1}^n \ln f\left(\frac{r_t - \mu}{\sigma}; \nu\right) - n \ln \sigma$$


▣ Criterii informaționale pentru selecția modelului:

▶  $AIC = -2\ell + 2k$  (penalizează ușor complexitatea)

▶  $BIC = -2\ell + k \ln n$  (penalizează mai puternic complexitatea)

▣ Student- $t$  ca distribuție a inovațiilor în modele GARCH:  $\epsilon_t = \sigma_t z_t$ ,  $z_t \sim t_\nu$

▣ Diagnostic QQ-plot: abaterile de la linia de  $45^\circ$  indică specificare greșită

Normală vs. Student- $t$  — Suprapunere pe S&P 500

SFM\_ch2\_distribution\_comparison

- Student- $t$  surprinde cozile groase; normala le subestimează sistematic

## Compararea modelelor: AIC/BIC

| Model                             | Log-verosim.      | AIC            | BIC                  |
|-----------------------------------|-------------------|----------------|----------------------|
| Normal $(\mu, \sigma)$            | $\ell_1$          | $-2\ell_1 + 4$ | $-2\ell_1 + 2 \ln n$ |
| Student- $t$ $(\mu, \sigma, \nu)$ | $\ell_2 > \ell_1$ | $-2\ell_2 + 6$ | $-2\ell_2 + 3 \ln n$ |

- ▣ Student- $t$  obține AIC/BIC substanțial mai bun în ciuda unui parametru suplimentar
- ▣ Câștigul în log-verosimilitudine provine din ajustarea superioară a cozilor

## Reprezentarea ca mixtură și interpretarea Bayesiană

- **Reprezentare ca mixtură:**  $X | V \sim N(0, V)$ ,  $V \sim \text{Inv-Gamma}(\nu/2, \nu/2)$ 
  - ▶ Student- $t$  = Normală cu varianță aleatoare (mixtură de scale a normalelor)
  - ▶ Interpretare:  $V$  surprinde volatilitatea variabilă în timp
  - ▶ **Vizual:**  $t_\nu = \int_0^\infty N(0, v) \cdot \text{InvGamma}(v) dv$  — medierea peste  $v$  „îngroașă” cozile
- **Interpretare Bayesiană:** Student- $t$  ca distribuție marginală a posteriori sub priori conjugate normal-inverse-gamma
- **Student- $t$  multivariată:**  $f(x) \propto \left(1 + \frac{(x-\mu)' \Sigma^{-1} (x-\mu)}{\nu}\right)^{-(\nu+p)/2}$
- **Compararea cozilor:** indicele de coadă (*tail index*)  $t_\nu = \nu$  vs. indicele de stabilitate  $= \alpha$
- Student- $t$  **nu** este închisă la convoluție; distribuțiile stabile **sunt**

## Exemplu: Probabilitatea unei pierderi extreme

### Exercițiu

Randamentele zilnice au  $\sigma = 1,5\%$ . Calculați  $P(r < -3\sigma) = P(r < -4,5\%)$  sub distribuția normală vs. Student- $t$  cu  $\nu = 5$ .

### Rezolvare

- ▣ **Sub distribuția normală:**  $P(r < -3\sigma) = \Phi(-3) = 0,00135 = 0,135\%$  (1 zi din 741)
- ▣ **Sub Student- $t$  ( $\nu = 5$ ):** scală ajustată  $s = \sigma\sqrt{(\nu - 2)/\nu} = 0,01162$ 
  - ▶  $t_{\text{stat}} = -0,045/0,01162 = -3,874 \Rightarrow P(T_5 < -3,874) = 0,00584 = 0,584\%$  (1 zi din 171)

### Concluzie

- ▣ Student- $t$  prevede pierderi  $> 3\sigma$  de  **$4,3\times$  mai frecvent** decât distribuția normală (0,584% vs. 0,135%)

## Incertitudinea modelului și măsuri robuste de risc

- ▣ **Incertitudinea modelului:** Care distribuție este „corectă”? Poate niciuna — orice model este o *aproximare*.
- ▣ **Aversiune față de ambiguitate** (paradoxul Ellsberg): decidentul nu cunoaște distribuția exactă și adoptă o atitudine conservatoare.
- ▣ Măsuri robuste de risc sub incertitudine distribuțională:

$$\rho_{\text{robust}}(X) = \sup_{Q \in \mathcal{Q}} \rho_Q(X)$$

- ▣ **Mulțimea de ambiguitate**  $\mathcal{Q}$  = o mulțime de distribuții de probabilitate considerate plauzibile. Se calculează riscul sub *cea mai defavorabilă* distribuție din  $\mathcal{Q}$  (*worst-case*).
- ▣ Exemple clasice de  $\mathcal{Q}$ :
  - ▶ **Bazată pe momente:** toate distribuțiile cu  $(\mu, \sigma^2)$  date:  $\mathcal{Q} = \{Q : \mathbb{E}_Q[X] = \mu, \text{Var}_Q(X) = \sigma^2\}$
  - ▶ **Wasserstein:** vecinătate de rază  $\varepsilon$  în jurul distribuției empirice:  $\mathcal{Q} = \{Q : W_p(Q, \hat{P}_n) \leq \varepsilon\}$
  - ▶ **KL-divergență:**  $\mathcal{Q} = \{Q : D_{\text{KL}}(Q \| P_0) \leq \eta\}$
- ▣ **Cuantificarea riscului de model:** intervalul VaR/ES între modele plauzibile furnizează o „primă de risc de model”



## Distanțe între distribuții — Intuiție

- ▣ **Problema:** Cum măsurăm cât de „aproape” sunt două distribuții  $P$  și  $Q$ ?
- ▣ **Distanța Wasserstein  $W_p(P, Q)$ :**
  - ▶ Cunoscută și ca *Earth Mover's Distance* (distanța mutării de pământ)
  - ▶ Intuiție: costul minim de „transport” al masei de probabilitate din  $P$  în  $Q$
  - ▶ Dacă  $P$  și  $Q$  sunt distribuții pe  $\mathbb{R}$  cu CDF-uri  $F_P, F_Q$ :

$$W_1(P, Q) = \int_{-\infty}^{+\infty} |F_P(x) - F_Q(x)| dx$$

- ▶ Avantaj: ține cont de *geometria* spațiului (nu doar de suprapunerea densităților)
- ▣ **Divergența Kullback–Leibler  $D_{KL}(Q||P_0)$ :**
  - ▶ Măsoară „pierderea de informație” dacă aproximăm  $Q$  prin  $P_0$
  - ▶  $D_{KL}(Q||P_0) = \int q(x) \ln \frac{q(x)}{p_0(x)} dx \geq 0$ , cu egalitate iff  $Q = P_0$
  - ▶ **Nu** este o distanță propriu-zisă (nu este simetrică:  $D_{KL}(Q||P) \neq D_{KL}(P||Q)$ )
- ▣ **Aplicație:**  $\varepsilon$  mare  $\Rightarrow \mathcal{Q}$  mai largă  $\Rightarrow$  VaR robust mai mare.    **Rezumat:**  $W_1$  = cost de transport (simetrică); KL = pierdere de informație (asimetrică)

## Wasserstein în practică — Stress-testing bancar

### Scenariul: Criza din 2008 / Pandemia 2020

- ▣ Distribuția *istorică* a randamentelor devine brusc irelevantă (non-staționaritate)
- ▣ VaR estimat pe date din 2005–2007 subestimează masiv pierderile din 2008
- ▣ **Problema:** cum ne protejăm când modelul pe care l-am estimat poate fi greșit?

### Soluția: optimizare robustă cu vecinătate Wasserstein

- ▣ În loc de a calcula VaR sub o *singură* distribuție  $\hat{P}$ , calculăm sub **cea mai defavorabilă** distribuție dintr-o vecinătate:  $\rho_{\text{robust}} = \sup_{Q: w_1(Q, \hat{P}) \leq \varepsilon} \text{VaR}_Q$
- ▣ Raza  $\varepsilon$  = bugetul de incertitudine al băncii (cât de mult poate devia realitatea)
- ▣  $\varepsilon$  mic: optimism („criza nu se va repeta”);  $\varepsilon$  mare: conservatorism (supraviețuire)
- ▣ **Basel III+**: autoritățile impun *stressed VaR* — exact această filozofie

## Opriti-vă și gândiți-vă

*(auto-evaluare)*Verificare rapidă — Distribuția Student- $t$ 

1. Student- $t$  cu  $\nu = 3$  are varianță finită? Dar kurtosis?
2. De ce Student- $t$  cu  $\nu = 5$  prevede pierderi  $> 3\sigma$  de  $\sim 4\times$  mai frecvent decât normala?
3. Dacă  $\hat{\nu} \rightarrow \infty$ , ce distribuție obținem? Ce implică aceasta pentru selecția modelului?

## Răspunsuri

1. Varianță: da ( $\nu > 2$ ,  $\text{Var} = 3/(3 - 2) = 3$ ). Kurtosis: **nu** ( $\nu > 4$  necesar;  $6/(3 - 4) < 0$  — nu există).
2. Cozile Student- $t$  scad ca  $|x|^{-(\nu+1)}$  (lege putere) vs.  $e^{-x^2/2}$  (exponențial) — mult mai multă masă în cozi.
3. Se obține  $N(0, 1)$ . Aceasta înseamnă că Student- $t$  **include** normala; AIC/BIC vor selecta normala dacă cozile nu sunt groase.

## De la Student- $t$ la Pareto — De ce avem nevoie de ambele?

### Student- $t$ : modelul **complet**

- ▣ Modelează **întregul set de date** (centru + cozi)
- ▣ Compromis: dacă fitezi bine centrul, poți rata coada extremă
- ▣ Parametru global:  $\nu$  controlează simultan vârful și cozile


### Pareto: modelul **cozii extreme**

- ▣ Modelează **doar valorile extreme** ( $x > x_m$ )
- ▣ Nu face compromisuri: se concentrează exclusiv pe coada dreaptă
- ▣ Pregătește mental Teoria Valorilor Extreme (EVT)

### Legătura matematică

- ▣ Student- $t$  cu  $\nu$  g.l. are **cozi Pareto**:  $P(X > x) \sim C \cdot x^{-\nu}$  pentru  $x \rightarrow \infty$
- ▣ Indicele de coadă Pareto  $\alpha =$  gradele de libertate  $\nu$  ale Student- $t$
- ▣ Pareto nu este o alternativă la Student- $t$ , ci o **unealtă complementară** de diagnostic

## Regula 80/20 — Omul din spatele legii



Vilfredo Pareto  
(1848–1923)

### De la grădinărit la inegalitate

- ▣ Inginer italo-elvețian: **80% din pământul Italiei** era deținut de **20% din populație** (1896)
- ▣ Legenda: 20% din plante produceau 80% din mazăre
- ▣ Aceeași lege apare **peste tot**: avere, orașe, cutremure, vânzări, trafic web

### De ce contează pentru finanțe?

- ▣ Puține zile catastrofale generează cea mai mare parte a riscului
- ▣ Mandelbrot (1963): cozile randamentelor sunt Pareto —  
$$P(X > x) \propto x^{-\alpha}$$

## Distribuția Pareto — Legea de putere

### Definiție (Pareto, 1896)

O variabilă aleatoare  $X$  urmează o **distribuție Pareto** cu parametri  $x_m > 0$  (scală) și  $\alpha > 0$  (formă / indice de coadă) dacă:

$$f(x) = \frac{\alpha x_m^\alpha}{x^{\alpha+1}}, \quad x \geq x_m$$

▣ **CDF:**  $F(x) = 1 - \left(\frac{x_m}{x}\right)^\alpha$

▣ **Funcția de supraviețuire:**

$$\bar{F}(x) = P(X > x) = \left(\frac{x_m}{x}\right)^\alpha$$

▣ Comportament **lege de putere** (*power law*):  
 $P(X > x) \propto x^{-\alpha}$


▣ **Medie:**  $\mathbb{E}[X] = \frac{\alpha x_m}{\alpha-1}$  (există doar dacă  $\alpha > 1$ )

▣ **Varianță:**  $\text{Var}(X) = \frac{\alpha x_m^2}{(\alpha-1)^2(\alpha-2)}$  (există doar dacă  $\alpha > 2$ )

▣  $\alpha \leq 2$ : **varianță infinită**

▣  $\alpha \leq 1$ : **medie infinită**

## Distribuția Pareto — Grafic PDF și CDF



- $\alpha$  mic  $\Rightarrow$  coadă groasă, densitate scade lent
- $\alpha$  mare  $\Rightarrow$  masa se concentrează lângă  $x_m$ , coada scade rapid

## Distribuția Pareto — Semnătura legii de putere

 SFM\_ch2\_pareto\_analysis

### Testul grafic log-log


- Pe graficul log-log, funcția de supraviețuire Pareto este o **dreaptă**:

$$\log P(X > x) = -\alpha \log x + \alpha \log x_m$$

- Panta** =  $-\alpha$  (indicele de coadă)
- Aliniere pe dreaptă  $\Rightarrow$  comportament Pareto; abaterea pentru  $x$  mici: *trunchiere*
- Verificare practică: desenăm  $\log \hat{S}(x)$  vs.  $\log x$  pe datele empirice — liniaritate confirmă coada Pareto



## Distribuția Pareto — Log-log survival



## Distribuția Pareto — De ce contează în finanțe?

### Principiul lui Pareto (regula 80/20)

- ▣ **Vilfredo Pareto** (1896): 80% din averea Italiei era deținută de 20% din populație
- ▣ Aceeași lege apare în finanțe: pierderile extreme urmează o lege de putere
- ▣ **Mandelbrot** (1963): randamentele piețelor au cozi de tip Pareto

### Proprietatea cheie: cozile groase


- ▣ Normală:  $P(X > x) \sim e^{-x^2/2}$  (**exponențial**); Pareto:  $P(X > x) \sim x^{-\alpha}$  (**polinomial**)
- ▣ Evenimentele *Black Swan* sunt **mult mai probabile** sub Pareto
- ▣ **Exemplu**:  $\alpha = 3$ ,  $P(X > 10x_m) = 10^{-3}$ ; sub normală:  $\approx 10^{-23}$

## Distribuția Pareto — Estimarea parametrilor (MLE)

### Estimatorul de verosimilitate maximă (MLE)



- ▣ Fie  $x_1, \dots, x_n$  un eșantion i.i.d. din  $\text{Pareto}(\alpha, x_m)$
- ▣ **Pasul 1:**  $\hat{x}_m = \min(x_1, \dots, x_n)$  (scala = valoarea minimă)
- ▣ **Pasul 2:**  $\hat{\alpha}_{\text{MLE}} = \frac{n}{\sum_{i=1}^n \ln(x_i / \hat{x}_m)}$
- ▣ **Proprietăți:** consistent, eficient asimptotic,  $\sqrt{n}$ -convergent

## Distribuția Pareto — MLE: Demonstrație




□ **Stânga:** histogram + fit MLE ( $\alpha = 3$ ,  $n = 1000$ ). **Dreapta:** convergența MLE ( $n = 50 \rightarrow 5000$ ) — [SFM\\_ch2\\_pareto\\_analysis](#)

## Distribuția Pareto — Estimatorul Hill pe S&amp;P 500

 SFM\_ch2\_pareto\_analysis

- ▣ **Hill plot:** zona stabilă  $\hat{\alpha} \approx 2,9$ ; **Tail fit:** Pareto  $\hat{\alpha} \approx 2,5$
- ▣  $\alpha < 3 \Rightarrow$  momente de ordin  $\geq 3$  nu există; confirmare: **cozi groase**

## Distribuția Pareto — Tail fitting (S&amp;P 500)



- **QQ-plot:** aliniere pe diagonală  $\Rightarrow$  coada este Pareto
- **Sensibilitate prag:** zona stabilă  $\approx 3-8\%$ ;  $\hat{\alpha} \approx 2,5-3,0$

## Distribuția Pareto — Interpretarea tail fitting

### Procedura de tail fitting

- ▣ **Pasul 1:** Selectăm pragul  $u$  (sau fracția de coadă, e.g. top 5%)
- ▣ **Pasul 2:** Estimăm  $\hat{\alpha}$  pe datele  $\{x_i : x_i > u\}$  via MLE sau Hill
- ▣ **Pasul 3:** Verificăm sensibilitatea: variază  $u$  și observăm stabilitatea lui  $\hat{\alpha}$
- ▣ **Pasul 4:** Validăm cu QQ-plot și CDF fit

### Rezultate empirice (S&P 500, 2000–2025)

- ▣  $\hat{\alpha} \approx 2,5-3,0 \Rightarrow$  momente finite doar până la ordinul 2
- ▣ Varianța există, dar kurtosis-ul **nu** — distribuția normală este inadecvată
- ▣ CDF-ul Pareto se potrivește bine pe coada dreaptă a pierderilor

## Distribuția Pareto — Aplicații

 SFM\_ch2\_pareto\_analysis

### Legea lui Zipf (capitalizare de piață)



- ▣ Capitalizarea firmelor urmează o **lege de putere**:  $P(\text{cap} > x) \propto x^{-\alpha}$
- ▣ Top 10 firme  $\approx$  30% din piață; panta Zipf  $\approx -1$  (lege empirică universală)

### Alte aplicații ale distribuției Pareto

- ▣ **Pierderi din asigurări**: sumele asigurate extreme  $\Rightarrow$  Pareto
- ▣ **Riscul operațional** (Basel II): pierderile operaționale au coada Pareto
- ▣ **Distribuția averii**: Top 1% deține 40–50% din avere (Piketty, 2014)
- ▣ **Volumul tranzacțiilor**: câteva tranzacții mari domină volumul total
- ▣ **Cyber risk**: severitatea atacurilor cibernetice este Pareto-distribuită



## Legea lui Zipf — Capitalizare de piață



 SFM\_ch2\_pareto\_analysis

## Distribuția Pareto — Conexiuni teoretice

### Legătura cu EVT și estimatorul Hill

- ▣ **Teorema Pickands–Balkema–de Haan:** excedentele peste un prag suficient de mare urmează aproximativ o **distribuție Pareto generalizată** (GPD)
- ▣ Distribuția Pareto clasică = caz particular al GPD cu  $\xi > 0$
- ▣ **Estimatorul Hill:** estimează  $\alpha$  din statisticile de ordine  $X_{(1)} \leq \dots \leq X_{(n)}$ :

$$\hat{\alpha}_{\text{Hill}} = \left( \frac{1}{k} \sum_{i=1}^k \ln \frac{X_{(n-i+1)}}{X_{(n-k)}} \right)^{-1}$$

### Legătura cu distribuțiile stabile și Student- $t$

- ▣ Distribuțiile  $\alpha$ -stabile cu  $\alpha < 2$  au cozi Pareto:  $P(X > x) \sim C_{\alpha} x^{-\alpha}$
- ▣ Student- $t$  cu  $\nu$  grade de libertate: cozi Pareto cu indice  $\alpha = \nu$
- ▣ Indicele de coadă Pareto unifică teoria: mai mic  $\alpha \Rightarrow$  cozi mai groase

## Opriti-vă și gândiți-vă

*(auto-evaluare)*

## Verificare rapidă — Distribuția Pareto

1. Pierderile au  $\hat{\alpha} = 2,5$ . Varianța există? Dar kurtosis-ul?
2. Pe graficul log-log, funcția de supraviețuire este o dreaptă cu pantă  $-3$ . Ce indice de coadă  $\alpha$  aveți?
3. VaR Pareto la 1% cu  $x_m = 2\%$ ,  $\alpha = 3$ :  $q = x_m \cdot (0,01)^{-1/\alpha}$ . Calculați rapid.

## Răspunsuri

1. Varianță: da ( $\alpha > 2$ ). Kurtosis: **nu** ( $\alpha < 4$ , momentul de ordin 4 nu există).
2.  $\alpha = 3$  (panta cu semn schimbat).
3.  $q = 2\% \times 100^{1/3} = 2\% \times 4,64 = 9,28\%$ .

## Cuprins

- ▣ Introducere ✓
- ▣ De la prețuri la log-randamente ✓
- ▣ Distribuția normală ✓
- ▣ Fapte stilizate ✓
- ▣ Distribuția Student- $t$  ✓
- ▣ Distribuția Pareto ✓
- ▣ **Studiu de caz**
- ▣ Quiz & Exerciții de examen

## Studiu de caz: Datele


SFM\_ch2\_case\_study\_2a

### Prețuri și log-randamente

- **S&P 500** — piață dezvoltată, lichiditate mare
- **BRD** — acțiune românească, piață emergentă
- **Bitcoin** — activ digital, volatilitate extremă
- Perioadă: 2015–2025, date zilnice

| Activ   | N      | Media (%) | Std (%) | Skew  | Kurt |
|---------|--------|-----------|---------|-------|------|
| S&P 500 | ~2 500 | 0.05      | 1.15    | −0.60 | 13.5 |
| BRD     | ~2 500 | 0.04      | 1.10    | −0.80 | 12.0 |
| Bitcoin | ~3 600 | 0.12      | 3.80    | −0.30 | 8.5  |

## Studiu de caz: Prețuri și log-randamente



SFM\_ch2\_case\_study\_2a

## Studiu de caz: Fapte stilizate

 SFM\_ch2\_case\_study\_2a


### Volatilitate clusterizată

- ▣ ACF a  $|r_t|$  confirmă dependența pe termen lung
- ▣ Toate cele 3 active prezintă autocorelație semnificativă a  $|r_t|$  până la lag-ul 60
- ▣ **Kurtosis**  $\gg 3$  pe toate piețele  $\Rightarrow$  cozi groase
- ▣ **Asimetrie negativă** pentru S&P 500 și BRD (*leverage effect*)
- ▣ Bitcoin: asimetrie mai redusă, dar volatilitate de  $3\times$

### Observație 3

- ▣ Clusterizarea volatilității invalidează ipoteza i.i.d. necesară modelului Black–Scholes

## Studiu de caz: Fapte stilizate — Grafic



SFM\_ch2\_case\_study\_2a



## Studiu de caz: Normal vs Student-t

 SFM\_ch2\_case\_study\_2a


### Histogramă log-scale cu overlay

- ▣ Comparăm cele două modele pe scara logaritmică
- ▣ **Normal** subestimează sistematic cozile
- ▣ **Student-t** se adaptează bine cu  $\nu$  estimat:
  - ▶ S&P 500:  $\hat{\nu} \approx 4-5$ ; BRD:  $\hat{\nu} \approx 3-5$ ; Bitcoin:  $\hat{\nu} \approx 3-4$
- ▣ Diferența crește exponențial în cozi

### Implicație


- ▣ Pe scara logaritmică, subestimarea normală devine vizibilă: cozile empirice sunt cu ordine de mărime mai groase

## Studiu de caz: Normal vs Student-t — Grafic



SFM\_ch2\_case\_study\_2a

## Studiu de caz: QQ-plots



SFM\_ch2\_case\_study\_2a

- **Normal QQ:** deviații sistematice în cozi      **Student-t QQ:** aliniere mult mai bună
- **Bitcoin:** cele mai mari deviații, confirmând cozi mai groase

## Studiu de caz: Teste de normalitate

Testarea ipotezei  $H_0: \text{randamentele} \sim \mathcal{N}(\mu, \sigma^2)$

| Activ   | Jarque–Bera | Shapiro–Wilk | Anderson–Darling | Kolmogorov–Smirnov |
|---------|-------------|--------------|------------------|--------------------|
| S&P 500 | > 10 000*** | < 0.99***    | > 20***          | > 0.05***          |
| BRD     | > 8 000***  | < 0.99***    | > 15***          | > 0.04***          |
| Bitcoin | > 5 000***  | < 0.98***    | > 30***          | > 0.06***          |

- \*\*\* respingere la nivel  $\alpha = 0.001$  pentru toate testele și toate activele

### Concluzie

- Normalitatea este **respinsă decisiv** pe toate cele trei piețe
- Cele patru teste converg: JB (momente), SW (ordine), AD (cozi), KS (distribuție completă)

## Studiu de caz: VaR și ES — Normal vs Student- $t$

Aplicarea formulelor de risc (portofoliu 1M EUR,  $\mu \approx 0$ )

$$\square \text{ VaR}_{1\%}^N = 2,326 \sigma; \quad \text{VaR}_{1\%}^t = \sqrt{\frac{\nu-2}{\nu}} |t_{\nu}^{-1}(0,01)| \sigma; \quad \text{ES: media cozii stângi sub VaR}$$

| Activ ( $\sigma, \hat{\nu}$ ) | VaR Normal | VaR Student- $t$ | ES Normal | ES Student- $t$ |
|-------------------------------|------------|------------------|-----------|-----------------|
| S&P 500 (1,15%, 4,5)          | 26 750     | 30 400           | 30 500    | 40 200          |
| BRD (1,10%, 3,8)              | 25 590     | 29 600           | 29 300    | 40 200          |
| Bitcoin (3,80%, 3,2)          | 88 390     | 102 000          | 100 900   | 148 700         |

ES Normal subestimează cu 30–50%

$$\square P(r < -3\sigma): \text{Normal} = \Phi(-3) = 0,135\% \text{ (1 zi/741); } \text{Student-}t (\hat{\nu}=4,5) \approx 0,58\% \text{ (1 zi/172)} \text{ — de } 4,3\times \text{ mai frecvent}$$

## Studiu de caz: Selecția modelului — AIC/BIC

Criterii informaționale ( $AIC = -2\ell + 2k$ ;  $BIC = -2\ell + k \ln n$ )

| Activ   | $\Delta AIC$ (Normal – Student- $t$ ) | $\Delta BIC$ | Câștigător   |
|---------|---------------------------------------|--------------|--------------|
| S&P 500 | > 200                                 | > 190        | Student- $t$ |
| BRD     | > 150                                 | > 140        | Student- $t$ |
| Bitcoin | > 300                                 | > 290        | Student- $t$ |

### Observație 4

- ▣  $\Delta AIC > 10 \Rightarrow$  evidență puternică împotriva modelului Normal (Burnham & Anderson)
- ▣ Student- $t$  câștigă decisiv pe toate piețele, deși are un parametru suplimentar ( $\nu$ )

## Studiu de caz: Concluzii

### Lecții din analiza datelor reale

1. **Kurtosis**  $\gg 3$  pe toate piețele  $\Rightarrow$  modelul Normal este inadecvat
2. **Student-t** oferă o primă aproximare, dar are *cozi simetrice*
3. **Asimetria** (mai ales pe S&P 500 și BRD) necesită modele asimetrice
4. **Volatilitatea clusterizată** cere modele condiționale (GARCH)

### Implicații pentru managementul riscului

- ES Normal la 1% subestimează pierderea medie din coadă cu **30–50%** față de Student- $t$
- VaR Normal subestimează cu  $\sim 15\%$ , dar evenimentele de  $3\sigma$  apar de  $4\times$  mai des

## Opriți-vă și gândiți-vă

(auto-evaluare)

### Verificare rapidă — Studiu de caz

1. Dintre cele 3 active (S&P 500, BRD, Bitcoin), care are cel mai mic  $\hat{\nu}$ ? Ce implicație are pentru VaR?
2. ES Normal subestimează cu 30–50%. Puteți explica **de ce** într-o propoziție?
3. Un manager vă întreabă: „De ce să nu folosim pur și simplu VaR empiric?” Ce argument aveți?

### Răspunsuri

1. Bitcoin ( $\hat{\nu} \approx 3,2$ ); VaR Student- $t$  este cu  $\sim 45\%$  mai mare decât VaR Normal.
2. Normala subestimează masa din coada stângă; ES mediază pierderile extreme, unde diferența este maximă.
3. Cu  $n = 2500$ , cuantila 0,1% folosește doar 2–3 observații — prea puțin pentru estimare fiabilă.



## Exercițiu AI: Distribuții și risc de coadă

Prompt de testat în ChatGPT / Claude / Copilot

“Descarcă datele zilnice pentru S&P 500 și Bitcoin din 2015 până în 2025 folosind Python (yfinance). Calculează log-randamentele. Ajustează pe fiecare serie o distribuție normală și o distribuție Student- $t$  prin MLE. Compară modelele folosind AIC/BIC, QQ-plot și histogramă pe scară logaritmică. Calculează VaR la 1% și Expected Shortfall sub ambele modele. Estimează indicele de coadă Pareto cu estimatorul Hill.”

### Exercițiu:

1. AI-ul calculează corect log-randamentele? Verifică:  $r_t = \ln(P_t/P_{t-1})$ , nu  $(P_t - P_{t-1})/P_{t-1}$
2. Gradele de libertate  $\hat{\nu}$  estimate sunt plauzibile ( $\hat{\nu} \in [3, 8]$  pentru date zilnice)?
3. Formulele VaR și ES sunt corecte? Verifică:  $\text{VaR}_{1\%}^t$  folosește scală ajustată  $s = \sigma\sqrt{(\nu - 2)/\nu}$ ?
4. Întreabă AI-ul: “Ce se întâmplă cu VaR dacă  $\nu \leq 2$ ?” Menționează varianța infinită?
5. Hill plot-ul arată o zonă stabilă? Ce valoare  $\hat{\alpha}$  obține? Compară cu  $\hat{\nu}$  din Student- $t$

☐ **Atenție:** AI-ul confundă adesea *excess kurtosis* ( $\kappa - 3$ ) cu kurtosis-ul total ( $\kappa$ ). Verificați mereu definiția folosită.

## Întrebarea 1

### Întrebare

- ▣ Evenimentul din 19 octombrie 1987 (S&P 500  $-20,5\%$ ) corespunde unui eveniment de  $\sim 20\sigma$  sub ipoteza normală ( $\sigma \approx 1\%$ ). Care este probabilitatea unui astfel de eveniment?

### Variante de răspuns

- ▣ (A)  $\approx 10^{-2}$  (1 la 100)
- ▣ (B)  $\approx 10^{-30}$  (practic imposibil pe orizontul uman)
- ▣ (C)  $\approx 10^{-89}$  (imposibil în durata de viață a universului)
- ▣ (D)  $\approx 10^{-6}$  (o dată la un milion de zile)

## Întrebarea 1: Răspuns

### Răspuns: (C)

- ▣ **Normal:**  $\sigma \approx 1\%$ , deci  $-20,5\% = 20,5\sigma$ .  $P = 2\Phi(-20,5) \approx 10^{-89}$ .
- ▣ **Student- $t$  ( $\nu = 5$ ):** scală ajustată  $s = \sigma\sqrt{3/5} = 0,775\%$ ;  $t_{\text{stat}} = 20,5/0,775 = 26,5$ ;  $P(|T_5| > 26,5) \approx 10^{-8}$  — tot extrem, dar  $10^{81} \times$  **mai probabil** decât sub normală!
- ▣ Și totuși s-a întâmplat — demonstrează **inadecvarea distribuției normale**.
- ▣ Sub distribuții stabile ( $\alpha \approx 1,7$ ), probabilitatea crește la  $\sim 10^{-3}$ .

## Întrebarea 2

### Întrebare

- O distribuție Student- $t$  cu  $\nu = 4$  grade de libertate are:

### Variante de răspuns

- **(A)** Medie finită, varianță finită, kurtosis finită
- **(B)** Medie finită, varianță finită, kurtosis infinită
- **(C)** Medie finită, varianță infinită, kurtosis infinită
- **(D)** Medie infinită, varianță infinită, kurtosis infinită

## Întrebarea 2: Răspuns

### Răspuns: (B)

- ▣ Pentru Student- $t$ : media există dacă  $\nu > 1$ , varianța dacă  $\nu > 2$ , kurtosis dacă  $\nu > 4$ .
- ▣ Cu  $\nu = 4$ : media finită ( $\checkmark$ ), varianță finită ( $= \nu/(\nu - 2) = 2$ ,  $\checkmark$ ), dar kurtosis-ul **nu există** (formula  $6/(\nu - 4)$  are un pol la  $\nu = 4$ ; momentul de ordin 4 este infinit).
- ▣ (A) este greșit: momentul de ordin 4 nu există la  $\nu = 4$  exact.
- ▣ Aceasta arată că și distribuțiile cu varianță finită pot avea cozi **foarte groase**.

### Întrebarea 3: Raționament — Basel III și alegerea distribuției

#### Întrebare

- O bancă calculează capitalul de reglementare folosind ES la 2,5% sub distribuția normală. Autoritățile de supraveghere descoperă că randamentele portofoliului au  $\hat{\nu} = 4$  (Student- $t$ ). Ce consecință are acest lucru?

#### Variante de răspuns

- **(A)** Capitalul este suficient — ES nu depinde de forma distribuției
- **(B)** Capitalul este subestimat cu 30–50%, banca trebuie să majoreze rezervele
- **(C)** Capitalul este supraestimat — Student- $t$  prevede riscuri mai mici
- **(D)** Nu se poate decide fără a cunoaște volatilitatea

### Întrebarea 3: Răspuns

Răspuns: (B)

- ▣ Student- $t$  cu  $\nu = 4$  are cozi mult mai groase decât normala:  $P(r < -3\sigma)$  este de  $\sim 4\times$  mai mare.
- ▣ ES sub Student- $t$  este cu **30–50% mai mare** decât sub normală (am demonstrat în studiul de caz).
- ▣ (A) este greșit: ES depinde critic de forma cozilor, nu doar de  $\sigma$ .
- ▣ (D) este greșit: chiar și cu aceeași  $\sigma$ , Student- $t$  dă ES mai mare datorită cozilor.
- ▣ **Lecția:** Alegerea distribuției nu este academică — **determină direct capitalul bancar.**

## Exercițiul 1: Log-randamente și momente

### Enunț

□ Se dau prețurile zilnice de închidere:

| $t$   | 0   | 1   | 2  | 3  | 4   |
|-------|-----|-----|----|----|-----|
| $P_t$ | 100 | 103 | 98 | 95 | 102 |

1. Calculați log-randamentele  $r_t = \ln(P_t/P_{t-1})$  pentru  $t = 1, \dots, 4$ .
2. Calculați media, varianța, asimetria și kurtosis eșantionului.
3. Aplicați testul Jarque–Bera:  $JB = \frac{n}{6} \left( S^2 + \frac{(K-3)^2}{4} \right)$ . Se respinge normalitatea la 5%?
4. Calculați log-randamentul total pe 4 perioade. Verificați aditivitatea temporală.



## Exercițiul 2: Distribuția normală și VaR

### Enunț

□ Un portofoliu de \$5M are randamente zilnice  $\sim N(\mu, \sigma^2)$  cu  $\hat{\mu} = 0,04\%$  și  $\hat{\sigma} = 1,2\%$

1. Calculați VaR zilnic la nivelurile 5%, 1% și 0,1%.
2. Calculați Expected Shortfall la nivelul 1%.
3. Un eveniment de  $-4\%$  a avut loc. Ce probabilitate are sub ipoteza normală?
4. Argumentați de ce VaR normal poate subestima riscul real.

### Indiciu

$\text{VaR}_\alpha = -(\mu + z_\alpha \cdot \sigma)$ , unde  $z_{0,05} = -1,645$ ,  $z_{0,01} = -2,326$ ,  $z_{0,001} = -3,090$ .

## Exercițiul 3: Student- $t$ — Ajustare și comparație

### Enunț

- Pe datele de la Exercițiul 1, presupuneți că MLE produce: distribuția normală  $\ell = 12,5$ , Student- $t$  ( $\nu = 5$ )  $\ell = 14,8$
1. Calculați AIC și BIC pentru ambele modele ( $k_N = 2$ ,  $k_t = 3$ ,  $n = 4$ ).
  2. Care model este preferat de AIC? Dar de BIC?
  3. Calculați excesul de kurtosis (*excess kurtosis*) al distribuției Student- $t$  cu  $\nu = 5$ .
  4. Explicați de ce Student- $t$  captează mai bine cozile groase decât distribuția normală.

### Formule

- $\text{AIC} = -2\ell + 2k$ ,  $\text{BIC} = -2\ell + k \ln n$ ,  $\kappa = 6/(\nu - 4)$  pentru  $\nu > 4$

## Exercițiul 4: Compararea VaR/ES — Normal, Student- $t$ , Pareto

### Enunț

□ Un portofoliu de \$10M are randamente zilnice cu  $\hat{\sigma} = 1,5\%$ ,  $\mu \approx 0$ . Estimatorul Hill pe coada stângă dă  $\hat{\alpha} = 3,5$

1. Calculați VaR 1% sub: (a) Normal; (b) Student- $t$  cu  $\nu = 5$ ; (c) Pareto cu  $\alpha = 3,5$ ,  $x_m = 0,01$
2. Calculați ES 1% sub fiecare model. *Indiciu:*  $ES_{\alpha}^{\text{Pareto}} = \frac{\alpha}{\alpha-1} \text{VaR}_{\alpha}$  pentru  $\alpha > 1$
3. Completați tabelul și comentați diferențele:

|        | Normal | Student- $t$ ( $\nu=5$ ) | Pareto ( $\alpha=3,5$ ) |
|--------|--------|--------------------------|-------------------------|
| VaR 1% | ?      | ?                        | ?                       |
| ES 1%  | ?      | ?                        | ?                       |
| ES/VaR | ?      | ?                        | ?                       |

## Exercițiul 4: Rezolvare

### Rezolvare

1. VaR 1% ( $\sigma = 1,5\%$ ,  $W = \$10\text{M}$ ):
  - ▶ **Normal**:  $\text{VaR} = 2,326 \times 0,015 \times 10\text{M} = \$348.900$
  - ▶ **Student- $t$**  ( $\nu=5$ ):  $s = \sigma\sqrt{3/5} = 1,162\%$ ;  $|t_5^{-1}(0,01)| = 3,365$ ;  
 $\text{VaR} = 3,365 \times 0,01162 \times 10\text{M} = \$390.800$
  - ▶ **Pareto** ( $\alpha=3,5$ ):  $\text{VaR} = x_m \cdot \alpha^{1/\alpha} = 0,01 \times 0,01^{-1/3,5} = \$461.600$
2. ES 1%:
  - ▶ **Normal**:  $\text{ES} = \sigma \phi(2,326)/0,01 \times W = \$401.200$
  - ▶ **Student- $t$** :  $\text{ES} \approx 1,28 \times \text{VaR} = \$500.200$  (formula exactă via funcția  $g_\nu$ )
  - ▶ **Pareto**:  $\text{ES} = \frac{\alpha}{\alpha-1} \text{VaR} = \frac{3,5}{2,5} \times 461.600 = \$646.200$
3. Raportul ES/VaR: Normal = 1,15; Student- $t$  = 1,28; Pareto = 1,40. Cozi mai groase  $\Rightarrow$  ES depășește VaR cu un procent mai mare — Pareto avertizează cel mai sever

## Criterii de evaluare — Exerciții și proiect

### Grila de notare (aplicabilă la examen și proiect)

| Nivel | Calcul                               | Interpretare                       |
|-------|--------------------------------------|------------------------------------|
| 9–10  | Formule + calcule corecte, complete  | Leagă de decizia de business       |
| 7–8   | Formule corecte, erori minore        | Interpretare corectă, superficială |
| 5–6   | Formula corectă, greșeli de aplicare | Repetă definiția fără context      |
| <5    | Formula greșită sau lipsă            | Fără interpretare                  |

### Pondere evaluare

▣ Examen scris: 70%    Proiect individual: 20%    Participare activă: 10%

## Laborator Python — Exerciții interactive

### Lab 1: Ajustarea distribuțiilor (Y3)

1. Deschideți `SFM_ch2_normal_distribution.ipynb`
2. Descărcați date S&P 500 (2015–2025); calculați log-randamentele
3. Histogramă + suprapunere normală; testul Jarque–Bera
4. Ajustați Student- $t$  (MLE). Comparați AIC cu modelul normal

 `SFM_ch2_normal_distribution`

## Exercițiul 1: Rezolvare

### Rezolvare

1. Log-randamente:  $r_1 = \ln(103/100) = 0,0296$ ,  $r_2 = \ln(98/103) = -0,0498$ ,  $r_3 = \ln(95/98) = -0,0311$ ,  $r_4 = \ln(102/95) = 0,0713$
2.  $\bar{r} = (0,0296 - 0,0498 - 0,0311 + 0,0713)/4 = 0,0050$ ;  $s^2 = \frac{1}{3} \sum (r_i - \bar{r})^2 = 0,00253$ ;  $s = 0,0503$ .  
Asimetrie:  $S \approx 0,56$ ; Kurtosis:  $K \approx 1,72$
3.  $JB = \frac{4}{6}(0,56^2 + (1,72 - 3)^2/4) = 0,48$ . Cu  $\chi_2^2(0,05) = 5,99$ :  $0,48 < 5,99 \Rightarrow$  **nu respingem** normalitatea (eșantion prea mic!)
4.  $r_{0.4} = \ln(102/100) = 0,0198 = r_1 + r_2 + r_3 + r_4 = 0,0198 \checkmark$

## Exercițiul 2: Rezolvare

### Rezolvare

1.  $\text{VaR}_\alpha = -(\mu + z_\alpha \sigma) \times W$ , cu  $\mu = 0,0004$ ,  $\sigma = 0,012$ ,  $W = \$5\text{M}$ :  
►  $\text{VaR } 5\%: 0,01934 \times 5\text{M} = \$96.680$ ;  $\text{VaR } 1\%: \$137.560$ ;  $\text{VaR } 0,1\%: \$183.400$
2.  $\text{ES}_{1\%} = \sigma \cdot \phi(-2,326)/0,01 = 0,03198 \Rightarrow \$159.900$
3.  $P(r < -0,04) = \Phi(-3,37) \approx 0,038\%$  (1 zi în  $\sim 2.600$ )
4. Empiric, evenimentele  $> 3\sigma$  apar mult mai frecvent  $\Rightarrow \text{VaR normal subestimează riscul}$



## Exercițiul 3: Rezolvare

### Rezolvare

1. Cu  $\ell_N = 12,5$ ,  $\ell_t = 14,8$ ,  $k_N = 2$ ,  $k_t = 3$ ,  $n = 4$ :  
► Normal:  $AIC = -21,0$ ;  $BIC = -22,23$ . Student- $t$ :  $AIC = -23,6$ ;  $BIC = -25,44$
2. Student- $t$  câștigă pe ambele criterii ( $AIC: -23,6 < -21,0$ ;  $BIC: -25,44 < -22,23$ ). *Notă*: cu  $n = 4$ ,  $\ln 4 = 1,39 < 2$ , deci BIC penalizează mai puțin ca AIC — situație atipică, specifică eșantioanelor foarte mici
3. Exces de kurtosis:  $\kappa = 6/(\nu - 4) = 6/(5 - 4) = 6$ . Kurtosis totală:  $3 + 6 = 9$
4. PDF-ul Student- $t$  scade ca  $|x|^{-(\nu+1)}$  (lege putere) vs.  $e^{-x^2/2}$  pentru normală. Decăderea mai lentă alocă mai multă probabilitate în cozi

## Bibliografie I

### Manuale de referință

- ▣ McNeil, A., Frey, R. & Embrechts, P. (2015). *Quantitative Risk Management*. Princeton University Press.
- ▣ Nolan, J. P. (2020). *Stable Distributions — Models for Heavy Tailed Data*. Birkhäuser.
- ▣ Rachev, S. T. (2003). *Handbook of Heavy Tailed Distributions in Finance*. Elsevier.

### Articole fundamentale

- ▣ Mandelbrot, B. (1963). The Variation of Certain Speculative Prices. *Journal of Business*, 36(4), 394–419.
- ▣ Fama, E. (1965). The Behavior of Stock-Market Prices. *Journal of Business*, 38(1), 34–105.
- ▣ Cont, R. (2001). Empirical Properties of Asset Returns. *Quantitative Finance*, 1(2), 223–236.

## Bibliografie II

### Distribuții și estimare

- Hansen, B. (1994). Autoregressive Conditional Density Estimation. *International Economic Review*, 35(3), 705–730.
- Nolan, J. P. (1997). Numerical Calculation of Stable Densities and Distribution Functions. *Stochastic Models*, 13(4), 759–774.
- Barndorff-Nielsen, O. (1977). Exponentially Decreasing Distributions for the Logarithm of Particle Size. *Proc. Royal Society A*, 353, 401–419.

### Modele dinamice

- Hamilton, J. D. (1989). A New Approach to the Economic Analysis of Nonstationary Time Series. *Econometrica*, 57(2), 357–384.
- Merton, R. (1976). Option Pricing When Underlying Stock Returns Are Discontinuous. *J. of Financial Economics*, 3, 125–144.
- Barndorff-Nielsen, O. & Shephard, N. (2001). Non-Gaussian Ornstein–Uhlenbeck-Based Models. *JRSS B*, 63(2), 167–241.

## Bibliografie III

### Testare și selecție de modele

- ▣ Vuong, Q. H. (1989). Likelihood Ratio Tests for Model Selection and Non-Nested Hypotheses. *Econometrica*, 57(2), 307–333.
- ▣ Fissler, T. & Ziegel, J. F. (2016). Higher Order Elicitability and Osband's Principle. *Annals of Statistics*, 44(4), 1680–1707.

### Resurse online și cod

- ▣ **Quantlet:** <https://quantlet.com> > Platformă de cod pentru metode cantitative
- ▣ **Quantinar:** <https://quantinar.com> > Platformă de învățare pentru metode cantitative
- ▣ **GitHub SFM:** [https://github.com/QuantLet/Stat\\_fin\\_markets/tree/master/Ch\\_02](https://github.com/QuantLet/Stat_fin_markets/tree/master/Ch_02) > Cod Python capitol 2

## Bibliografie IV

### Referințe recente (2020–2025)

- Kelly, B., Jiang, H. & Pruitt, S. (2022). Tail Risk and Asset Prices. *Rev. Fin. Studies*, 35(5), 2254–2295.
- Bollerslev, T. & Todorov, V. (2023). The Jump Tails of Asset Returns. *Econometrica* (forthcoming).
- Aas, K. et al. (2009). Pair-Copula Constructions of Multiple Dependence. *IME*, 44(2), 182–198.
- Taylor, J.W. (2019). Forecasting VaR and ES Using the Asymmetric Laplace Distribution. *JBES*, 37(1), 121–133.

### Evenimente recente relevante

- **Covid-19 (mar. 2020)**: S&P 500 –12% într-o zi; al 3-lea cel mai grav eveniment din istorie
- **FTX/crypto (nov. 2022)**: Prăbușire de –65% în 48h; cozi groase extreme
- **SVB (mar. 2023)**: Contagiune bancară; risc de coadă în sectorul financiar
- **Lecția**: Modelele cu cozi groase sunt **esențiale**, nu opționale

## Idei esențiale — Ce trebuie să rețineți din acest capitol

### 5 lecții fundamentale

1. Distribuția normală **subestimează sistematic** riscul de coadă
2. Student- $t$  ( $\hat{\nu} \in [3, 8]$ ) captează cozile groase cu un singur parametru suplimentar; câștigă decisiv pe AIC/BIC
3. Pareto și legile de putere unifică teoria cozelor:  $\alpha$  conectează Student- $t$ , distribuțiile stabile și EVT
4. ES este mai informativ decât VaR — Normal subestimează ES cu 30–50%
5. **Alegerea distribuției determină direct capitalul de reglementare**: Basel III FRTB (2023) impune ES 2,5%

### Pregătire pentru capitolele următoare

- ▣ **Cap. 3:** Distribuții stabile, skew- $t$ , GED — asimetrie și cozi mai groase
- ▣ **Cap. 4:** Teoria Valorilor Extreme (EVT) — Pareto generalizată, praguri

## Lectură recomandată pe nivele

### Y3 — Lectură minimă

- ▣ McNeil et al. (2015), Cap. 2.1–2.2; Cont (2001), §1–3; exercițiile 1–3 din curs

### — Lectură suplimentară

- ▣ + McNeil et al. (2015), Cap. 2.3–2.4 (MLE, selecția modelului); Fama (1965); exercițiul 4 și studiul de caz complet

### PhD — Lectură avansată

- ▣ + Nolan (2020), Cap. 1; Mandelbrot (1963); Kelly et al. (2022); slide-urile Wasserstein și măsuri robuste

## Frontiere: Machine Learning și distribuțiile financiare

### Rețele neuronale pentru estimarea densității

- ▣ **Normalizing Flows** (Rezende & Mohamed, 2015): transformări invertibile  $f_\theta$  care mapează  $N(0,1)$  într-o distribuție complexă; captează asimetrie și cozi groase
- ▣ **Mixture Density Networks** (Bishop, 1994): rețeaua produce parametrii  $(\mu_k, \sigma_k, \pi_k)$  unei mixturi condiționale — generalizare a Student- $t$
- ▣ **DeepVaR / DeepES**: estimarea cuantilelor condiționale via *quantile regression* neuronală (Taylor, 2019)

### Conexiune cu acest capitol

- ▣ Distribuțiile clasice rămân **benchmark-uri** indispensabile; ML le **generalizează**
- ▣ Un Normalizing Flow antrenat pe date financiare redescoperă automat cozile groase
- ▣ **Provocare**: interpretabilitate —  $\hat{\nu} = 4,5$  e mai ușor de explicat unui regulator decât 50 de straturi neuronale



## Bilet de ieșire (*Exit Ticket*)

(1 minut)

Completați înainte de a pleca (anonim, pe hârtie sau online)

1. **Un lucru clar:** Ce concept din cursul de azi ați înțeles cel mai bine?
2. **Un lucru neclar:** Ce concept necesită mai multă clarificare?
3. **O întrebare:** Ce întrebare ați dori să explorați mai departe?

De ce facem acest exercițiu?

- ☐ Răspunsurile anonime ajustează conținutul **următorului curs**
- ☐ Cercetările arată că reflecția imediat după curs crește retenția cu 20–40% (Roediger & Butler, 2011)

# Vă Mulțumim!

## Întrebări?

Materialele cursului sunt disponibile la: <https://danpele.github.io/SFM/>



Quantlet



Quantinar