Statistica Pieței Financiare

Capitolul 2: Distribuții clasice și fapte stilizate

Daniel Traian PELE
Antoaneta Amza

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Obiective de învățare

La sfârșitul acestui curs, veți fi capabili să:

1. **Explicați** de ce alegerea distribuției afectează estimarea riscului financiar
2. **Calculați** log-randamente și interpretați proprietățile lor statistice
3. **Aplicați** teste de normalitate și interpretați rezultatele
4. **Identificați** faptele stilizate ale randamentelor financiare
5. **Ajustați** distribuția Student-t și comparați cu distribuția normală

Cuprins

- Introducere — De ce contează distribuțiile
- De la prețuri la log-randamente
- Distribuția normală
- Fapte stilizate ale randamentelor financiare
- Distribuția Student-t
- Distribuția Pareto

De ce contează alegerea distribuției?

- Dacă presupunem o distribuție greșită, **subestimăm** probabilitatea pierderilor extreme
- **Exemplu**: 19 octombrie 1987 — S&P 500 a scăzut cu 20,5% într-o singură zi
  - Sub ipoteza normală ($\sigma \approx 1\%$): un eveniment de $\sim 20\sigma$ cu probabilitate $\approx 10^{-89}$
  - Și totuși s-a întâmplat — distribuția normală este inadecvată pentru evenimente extreme
- Băncile și autoritățile de reglementare trebuie să cuantifice „cât de rău poate fi?”
- Acest lucru necesită **modele distribuționale precise**

Idee cheie

- Alegerea distribuției de probabilitate determină direct cât capital trebuie să dețină o bancă pentru acoperirea pierderilor potențiale

Problema alegerii distribuției

- **Anticipare**: Mai târziu vom defini formal **Value-at-Risk (VaR)**, o măsură cheie de risc care depinde complet de ipoteza distribuțională
- Candidații pe care îi vom studia:
  - **Normală** — referința clasică (cozi subțiri)
  - **Student-t** — cozi mai groase, momente superioare finite
  - **Stabilă** — cele mai groase cozi, variantă infinită (*infinite variance*) posibilă
  - **EVT** — modelează doar cozile, agnostică față de centru
- Fiecare model implică un răspuns diferit la „cât de rău poate fi?"

Model	Tip coadă	Kurtosis	Parametri
Normal	Exponențială	3	2
Student-t	Lege putere	> 3	3
Stabilă	Lege putere	∞	4
GPD (EVT)	Flexibilă	—	2

Structura capitolului

Fundamente

1. De la prețuri la log-randamente
2. Distribuția normală (referință)
3. Fapte stilizate ale randamentelor
4. Distribuția Student-t
5. Distribuții asimetrice

Modele avansate și aplicații

6. Distribuții stabile
7. Teoria Valorilor Extreme
8. Compararea distribuțiilor
9. **Managementul riscului (VaR, ES)**
10. Extensii moderne (GARCH)

Alegerea distribuției și evaluarea instrumentelor financiare derivate

- Black–Scholes presupune log-normalitate $\Rightarrow$ volatilitate implicită constantă
- Deviațiile empirice produc **zâmbetul/asimetria volatilității (*volatility smile/skew*)**
- Optimizarea portofoliului sub randamente non-Gaussiene: medie-varianță este suboptimală
- Context de reglementare: Basel II $\rightarrow$ Basel III/IV
  - Basel II: VaR 1% cu ipoteză normală
  - Basel III/IV: trecerea de la VaR 1% la ES 2,5%

Observație 1

- Întregul cadru Basel de capital de reglementare se bazează pe ipoteze distribuționale
- Subestimarea riscului de coadă $\Rightarrow$ capital insuficient $\Rightarrow$ fragilitate sistemică

S&P 500: cum arată lumea reală

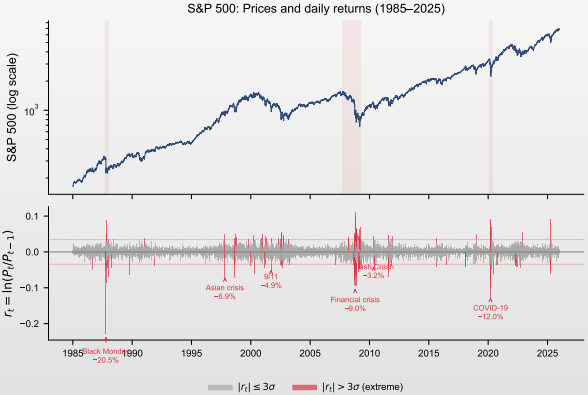

- Crahurile ($|r_t| > 3\sigma$) apar mult mai frecvent decât prevede distribuția normală
- Randamentele extreme se **clusterizează**; avem nevoie de modele cu cozi groase (*heavy tails*)

SFM_ch2_stylized_facts

Incertitudinea modelului și măsuri robuste de risc

- **Incertitudinea modelului**: Care distribuție este „corectă”? Poate niciuna — orice model este o *aproximare*.
- **Aversiune față de ambiguitate** (paradoxul Ellsberg): decidentul nu cunoaște distribuția exactă și adoptă o atitudine conservatoare.
- Măsuri robuste de risc sub incertitudine distribuțională:

$$\rho_{\text{robust}}(X) = \sup_{Q \in \mathcal{Q}} \rho_Q(X)$$

- **Mulțimea de ambiguitate** $\mathcal{Q}$ = o mulțime de distribuții de probabilitate considerate plauzibile. Se calculează riscul sub *cea mai defavorabilă* distribuție din $\mathcal{Q}$ (*worst-case*).
- Exemple clasice de $\mathcal{Q}$:
  - **Bazată pe momente**: toate distribuțiile cu (μ, σ^2) date: $\mathcal{Q} = \{Q : \mathbb{E}_Q[X] = \mu,\ \mathrm{Var}_Q(X) = \sigma^2\}$
  - **Wasserstein**: vecinătate de rază ε în jurul distribuției empirice: $\mathcal{Q} = \{Q : W_p(Q, \hat{P}_n) \leq \varepsilon\}$
  - **KL-divergență**: $\mathcal{Q} = \{Q : D_{\mathrm{KL}}(Q \| P_0) \leq \eta\}$
- **Cuantificarea riscului de model**: intervalul VaR/ES între modele plauzibile furnizează o „primă de risc de model”

Distanțe între distribuții — Intuiție

- **Problema**: Cum măsurăm cât de „aproape" sunt două distribuții P și Q?
- **Distanța Wasserstein** $W_p(P, Q)$:
  - Cunoscută și ca *Earth Mover's Distance* (distanța mutării de pământ)
  - Intuiție: costul minim de „transport" al masei de probabilitate din P în Q
  - Dacă P și Q sunt distribuții pe $\mathbb{R}$ cu CDF-uri F_P, F_Q:

$$W_1(P, Q) = \int_{-\infty}^{+\infty} |F_P(x) - F_Q(x)|\, dx$$

  - Avantaj: ține cont de *geometria* spațiului (nu doar de suprapunerea densităților)
- **Divergența Kullback–Leibler** $D_{\mathrm{KL}}(Q\|P_0)$:
  - Măsoară „pierderea de informație" dacă aproximăm Q prin P_0
  - $D_{\mathrm{KL}}(Q\|P_0) = \int q(x) \ln \frac{q(x)}{p_0(x)}\, dx \geq 0$, cu egalitate iff $Q = P_0$
  - **Nu** este o distanță propriu-zisă (nu este simetrică: $D_{\mathrm{KL}}(Q\|P) \neq D_{\mathrm{KL}}(P\|Q)$)
- **Aplicație**: Alegerea razei ε (Wasserstein) sau η (KL) controlează *gradul de conservatorism* al măsurii robuste de risc — ε mare $\Rightarrow$ mulțime $\mathcal{Q}$ mai largă $\Rightarrow$ VaR robust mai mare

Distribuția normală vs. realitate — Vizualizare și exemplu

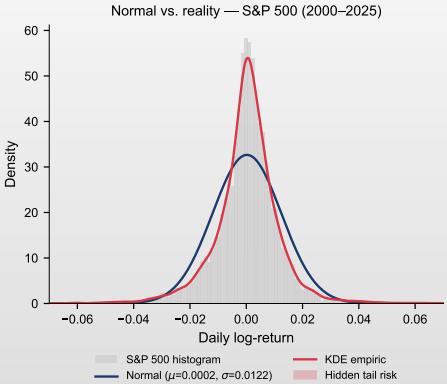

SFM_ch2_normal_distribution

Black Monday — 19 oct. 1987

S&P 500 a scăzut cu 20,5% într-o zi.

- Normală: $\sim 20\sigma$, $P \approx 10^{-89}$
- Student-t ($\nu = 4$): $P \approx 10^{-5}$

Timpul de revenire

- $T = \frac{1}{252 \times 10^{-89}} \approx 4 \times 10^{86}$ ani; vârsta universului: $\approx 1{,}4 \times 10^{10}$ ani
- $\Rightarrow \sim 10^{76}$ **vârste ale universului**!

Definiția log-randamentelor

Definiție 1 (Log-randament)

Log-randamentul (randamentul compus continuu) la momentul t este:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln P_t - \ln P_{t-1}$$

unde P_t este prețul activului la momentul t.

- **Aditivitate**: Randamentele multi-perioadă sunt sume: $r_{t:t+k} = \sum_{i=1}^{k} r_{t+i}$
- **Aproximare**: Pentru randamente mici, $r_t \approx (P_t - P_{t-1})/P_{t-1}$
- **Motivație statistică**: Structura aditivă permite teoria probabilităților standard (TLC, limite stabile)

Proprietățile log-randamentelor

De ce log-randamente?

- Aditive în timp: $r_{[0,T]} = \sum_{t=1}^{T} r_t$
- Simetrice: $+5\%$ și -5% sunt comparabile
- Nemărginite inferior: pot modela pierderi mari
- Permit inferență bazată pe TLC

Randamente simple vs. log-randamente

- Randament simplu: $R_t = \frac{P_t - P_{t-1}}{P_{t-1}}$
- Relație: $r_t = \ln(1 + R_t)$
- Randamentele simple *nu* sunt aditive în timp
- Dar *sunt* aditive pe activele din portofoliu

Convenție

- Pe parcursul acestui capitol, r_t denotă **log-randamentul**, dacă nu se specifică altfel

Limita în timp continuu

- Mișcarea Browniană geometrică: $dS/S = \mu\, dt + \sigma\, dW$
- Prin lema lui Itô: $d \ln S = (\mu - \sigma^2/2)\, dt + \sigma\, dW$
- Inegalitatea lui Jensen: $\mathbb{E}[\ln(P_T/P_0)] \neq \ln(\mathbb{E}[P_T/P_0])$
  - Randamentul mediu aritmetic depășește randamentul mediu geometric
  - Diferența $\approx \sigma^2/2$ („pierderea din volatilitate (*volatility drag*)")
- Log-randamente: aditive în *timp*; randamente simple: aditive pe *active*

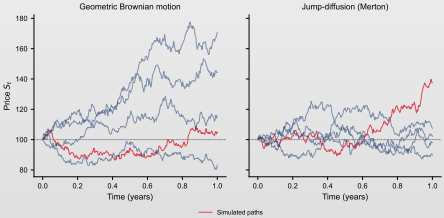

SFM_ch2_distribution_comparison

Reprezentarea semimartingală

- Procesele de preț modelate ca **semimartingale**: $S_t = S_0 + A_t + M_t$
- Lema lui Itô pentru semimartingale cu salturi:

$$d \ln S_t = \frac{dS_t}{S_{t^-}} - \frac{1}{2}\frac{d[S,S]_t^c}{S_{t^-}^2} + \sum_{s \le t}\left(\ln \frac{S_s}{S_{s^-}} - \frac{\Delta S_s}{S_{s^-}}\right)$$

- Variația cuadratică și volatilitatea realizată:

$$[X,X]_t = \lim_{\|\Pi\| \to 0} \sum_i (X_{t_{i+1}} - X_{t_i})^2$$

- Procese de preț discontinue: salturi și descompunerea Lévy–Itô

Exemplu numeric: Calculul log-randamentelor

Exercițiu

Prețuri: $P_0 = 100$, $P_1 = 103$, $P_2 = 101$, $P_3 = 105$, $P_4 = 102$. Calculați log-randamentele, media și varianța.

Rezolvare

t	P_t	R_t	r_t	$r_t - \bar{r}$	$(r_t - \bar{r})^2$
1	103	+3,00%	+2,96%	2,46%	0,0605%
2	101	−1,94%	−1,96%	−2,46%	0,0605%
3	105	+3,96%	+3,88%	3,38%	0,1143%
4	102	−2,86%	−2,90%	−3,40%	0,1153%
$\bar{r} = 0{,}495\%$			$s^2 = \frac{\sum (r_t - \bar{r})^2}{3} = 0{,}1169\%$		

- **Aditivitate**: $r_{[0,4]} = \ln(102/100) = 1{,}98\% = \sum_{t=1}^{4} r_t$ ✓

Distribuția normală — Definiție și proprietăți

Definiție 2 (Distribuția normală)

$X \sim N(\mu, \sigma^2)$ dacă:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$

Momente

- $\mathbb{E}[X] = \mu, \quad \mathrm{Var}(X) = \sigma^2$
- Asimetrie $= 0$
- Kurtosis $= 3$ (exces de kurtosis $= 0$)

Proprietăți cheie

- Simetrică față de μ
- Regula 68–95–99,7
- Cozile scad ca $e^{-x^2/2}$

Distribuția normală — Graficul densității

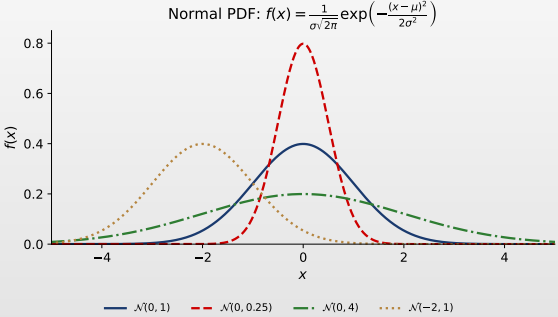

SFM_ch2_normal_distribution

- Forma de **clopot**: simetrică, unimodală, maximă în $x = \mu$
- Parametrii μ și σ^2 controlează **poziția** și **dispersia**
- Cozile scad **exponențial**: $f(x) \sim e^{-x^2/2}$ — subestimează evenimentele extreme

Cuantile și Teorema Limită Centrală

- **Cuantile**: Cuantila de ordin α a $N(\mu, \sigma^2)$ este:

$$q_\alpha = \mu + \sigma\, \Phi^{-1}(\alpha)$$

- Aceasta va fi utilizată pentru a defini Value-at-Risk
- **Cuantile cheie**: $\Phi^{-1}(0{,}01) = -2{,}326, \quad \Phi^{-1}(0{,}05) = -1{,}645$

Teoremă 1 (Teorema Limită Centrală)

Dacă $X_1, X_2, \ldots$ sunt i.i.d. cu $\mathbb{E}[X_i] = \mu$ și $\mathrm{Var}(X_i) = \sigma^2 < \infty$, atunci:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1).$$

- **Stabilitate**: Suma unor v.a. independente distribuite normal este normală: $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$

Ilustrarea TLC

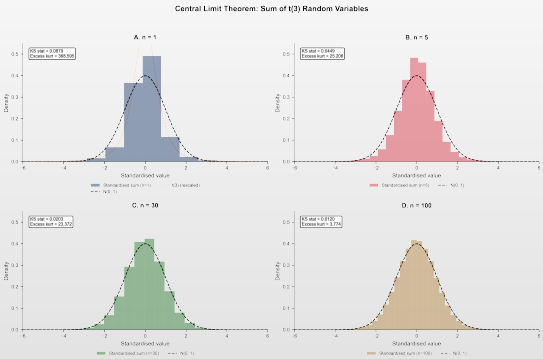

SFM_ch2_normal_distribution

- Pe măsură ce n crește, $\bar{X}_n$ se apropie de normalitate
- **Limitare**: TLC necesită varianță finită — ce se întâmplă dacă $\sigma^2 = \infty$?

Ajustarea normală pe randamentele S&P 500

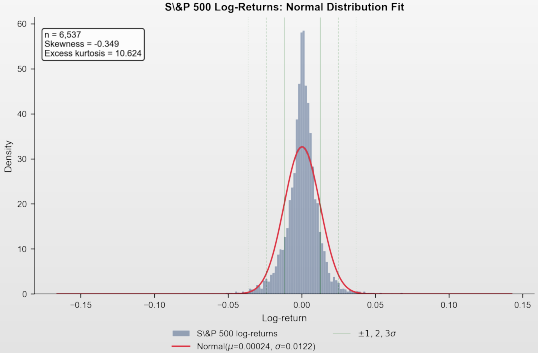

SFM_ch2_normal_distribution

- PDF-ul distribuției normale se potrivește rezonabil în centru, dar **ratează cozile**
- Histograma are mai multă masă în cozi decât prevede distribuția normală

Testul Jarque–Bera

- **Entropie maximă**: Dintre toate distribuțiile cu (μ, σ^2) date, distribuția normală maximizează entropia Shannon $H = -\int f \ln f \, dx$

Ipoteze

H_0: $S = 0$ și $K = 3$ (datele provin dintr-o distribuție normală)
H_1: $S \neq 0$ sau $K \neq 3$ (abatere de la normalitate)

Statistica de test

$$\boxed{JB = \frac{n}{6}\left(S^2 + \frac{(K-3)^2}{4}\right) \xrightarrow{d} \chi^2(2)}$$

- $S = \frac{1}{n}\sum\left(\frac{x_i - \bar{x}}{s}\right)^3$ (asimetrie), $K = \frac{1}{n}\sum\left(\frac{x_i - \bar{x}}{s}\right)^4$ (kurtosis)
- Respingem H_0 dacă $JB > \chi^2_{2;\,1-\alpha}$. Pentru $\alpha = 5\%$: $\chi^2_{2;\,0{,}95} = 5{,}99$

Testul Shapiro–Wilk

Testul Shapiro–Wilk (1965)

H_0: datele provin dintr-o distribuție normală vs. H_1: non-normalitate

$$\boxed{W = \frac{\left(\sum_{i=1}^{n} a_i\, x_{(i)}\right)^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}, \quad W \in (0, 1]}$$

- $x_{(i)}$ = statisticile de ordine (*order statistics*) ale eșantionului
- a_i = coeficienți tabelați, depind de n
- Respingem H_0 dacă W este prea mic (aproape de 0)
- Cel mai puternic test pentru eșantioane mici ($n < 50$)

Testele Anderson–Darling și Kolmogorov–Smirnov

Testul Anderson–Darling (1954)

H_0: $F = F_0$ vs. H_1: $F \neq F_0$

$$\boxed{A^2 = -n - \frac{1}{n}\sum_{i=1}^{n}(2i-1)\left[\ln F_0(x_{(i)}) + \ln(1 - F_0(x_{(n+1-i)}))\right]}$$

- Ponderat pe cozi: mai sensibil la devieri în extremele distribuției decât KS

Testul Kolmogorov–Smirnov (1933)

- H_0: $F = F_0$ vs. H_1: $F \neq F_0$ $\boxed{D_n = \sup_x |F_n(x) - F_0(x)|}$
- Non-parametric; mai puțin sensibil la cozi decât AD

Teste de normalitate — Vizualizare

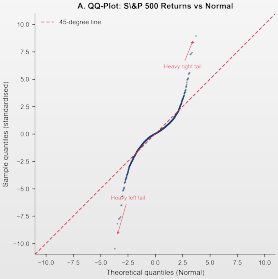

B. Normality Test Results

Test	Statistic	p-value / Critical	Reject H₀ (5%)
Jarque-Bera	30876.71	p = 0.00e+00	Yes
Shapiro-Wilk	0.909685	p = 1.64e-47	Yes
Anderson-Darling	126.2996	cv(5%) = 0.7520	Yes

Sample size: n = 6,537
Skewness: −0.3489 | Excess kurtosis: 10.6242
H₀: Data follows a Normal distribution

SFM_ch2_normal_distribution

- Rezultatele testelor pe randamentele S&P 500 resping **masiv** ipoteza de normalitate
- Testul JB: p-value ≈ 0 (asimetrie și kurtosis diferite de valorile normale)

Teste de normalitate — Rezultate empirice (S&P 500)

Test	Statistica	p-value	Decizia
Jarque–Bera	> 1000	$< 0{,}001$	**Respingem** H_0
Shapiro–Wilk	$< 0{,}99$	$< 0{,}001$	**Respingem** H_0
Anderson–Darling	> 10	$< 0{,}001$	**Respingem** H_0
Kolmogorov–Smirnov	$> 0{,}05$	$< 0{,}001$	**Respingem** H_0

Concluzie

- Normalitatea este respinsă **covârșitor** pentru randamentele financiare zilnice
- Distribuția normală subestimează sistematic riscul de coadă

Marginile Berry–Esseen și ratele de convergență

Teoremă 2 (Berry–Esseen)

Dacă $X_1, X_2, \ldots$ sunt i.i.d. cu $\mathbb{E}[X_i] = 0$, $\mathbb{E}[X_i^2] = \sigma^2$, $\mathbb{E}[|X_i|^3] = \rho < \infty$, atunci:

$$\sup_x |F_n(x) - \Phi(x)| \leq \frac{C\,\rho}{\sigma^3\sqrt{n}}$$

unde $C \leq 0{,}4748$ (Shevtsova, 2011).

- Rata de convergență: $O(n^{-1/2})$ — lentă pentru date cu cozi groase
- Expansiunile Edgeworth rafinează aproximarea TLC pentru n finit
- **Distribuția normală ca distribuție stabilă**: $N(\mu, \sigma^2) = S(2, 0, \sigma/\sqrt{2}, \mu)$ — membrul $\alpha = 2$ al familiei stabile
- Când $\mathbb{E}[X_i^2] = \infty$: TLC eșuează, dar **TLC Generalizată** dă limite stabile

Exemplu: Probabilitatea unei pierderi mari sub distribuția normală

Exercițiu

Un portofoliu are $\sigma = 1{,}5\%$ zilnic. Sub ipoteza normală cu $\mu = 0$, calculați $P(\text{pierdere} > 3\sigma)$. Câte zile pe an se așteaptă o astfel de pierdere? Comparați cu frecvența empirică.

Rezolvare

$P(r < -3\sigma) = \Phi(-3) = 0{,}00135$ (0,135%). Cu 252 zile/an: $252 \times 0{,}00135 = 0{,}34$ zile/an (o dată la $\sim$3 ani).

Realitatea empirică

- S&P 500 (1990–2023): pierderi $> 4{,}5\%$ apar $\approx 0{,}7$ ori/an — **2×** **mai frecvent** decât sub distribuția normală
- Pierderi $> 5\sigma$: distribuția normală prevede 1 eveniment la 13.932 ani; empiric, apare la decenii
- **Concluzie**: Distribuția normală subestimează dramatic riscul de coadă

Cozi groase și exces de kurtosis

- **Kurtosis**: $\kappa = \mathbb{E}[(X-\mu)^4]/\sigma^4$; exces de kurtosis: $\kappa_e = \kappa - 3$
- Distribuția normală: $\kappa_e = 0$
- Kurtosis tipică pentru acțiuni zilnice: $\kappa \in [5, 50]$, deci $\kappa_e \gg 0$
- **Interpretare**: Randamentele extreme apar mult mai frecvent decât prevede distribuția normală

Activ	**Asimetrie**	**Exces de kurtosis**
S&P 500 (zilnic)	$-0{,}3$	≈ 10
FTSE 100 (zilnic)	$-0{,}2$	≈ 8
USD/EUR (zilnic)	$-0{,}1$	≈ 5
Bitcoin (zilnic)	$-0{,}5$	≈ 15

Asimetrie negativă și clusterizarea volatilității

Asimetrie negativă

- Coada stângă mai grea decât cea dreaptă
- Mai pronunțată pentru indici de acțiuni
- Prăbușirile sunt mai abrupte decât raliul
- Asimetrie $S = \mathbb{E}[(X-\mu)^3]/\sigma^3 < 0$

Clusterizarea volatilității

- „Variații mari urmate de variații mari" (Mandelbrot, 1963)
- $\mathrm{Corr}(|r_t|, |r_{t+k}|) > 0$ pentru k mare
- Randamentele sunt necorelate dar **nu independente**
- $\mathrm{Corr}(r_t, r_{t+k}) \approx 0$ dar $\mathrm{Corr}(r_t^2, r_{t+k}^2) > 0$

Implicație

- O singură distribuție i.i.d. nu poate surprinde clusterizarea volatilității
- Avem nevoie de modele cu varianță variabilă în timp (GARCH, Secțiunea 2.10)

Gaussianitate agregată

- **Observație cheie**: Pe măsură ce orizontul de deținere crește, distribuția randamentelor devine *mai Gaussiană*
- Randamente zilnice: kurtosis ridicată, cozi groase
- Randamente săptămânale: kurtosis moderată
- Randamente lunare: mai aproape de distribuția normală
- **Mecanism**: Efect similar TLC — randamentul lunar $= \sum$ din $\sim$22 randamente zilnice

Frecvență	**Exces de kurtosis**	**JB *p*-value**
Zilnică	≈ 10	$< 0{,}001$
Săptămânală	≈ 4	$< 0{,}001$
Lunară	$\approx 1{,}5$	$\approx 0{,}05$
Trimestrială	$\approx 0{,}5$	$\approx 0{,}3$

Rezumatul faptelor stilizate

1. **Cozi groase**: $\kappa_e \gg 0$ — evenimente extreme mai frecvente decât sub normală
2. **Asimetrie negativă**: Coada stângă mai grea (acțiuni)
3. **Clusterizarea volatilității**: Perioade de volatilitate mare/mică persistă
4. **Gaussianitate agregată**: Kurtosis scade cu orizontul
5. **Absența autocorelației randamentelor**: $\mathrm{Corr}(r_t, r_{t+k}) \approx 0$ pentru $k \geq 1$
6. **Autocorelația randamentelor pătrate**: $\mathrm{Corr}(r_t^2, r_{t+k}^2) > 0$

Provocarea

- Orice model adecvat pentru randamentele financiare trebuie să reproducă aceste fapte stilizate
- Distribuția normală eșuează la punctele 1, 2 și 3

Efectul de levier și memoria lungă

Efectul de levier

- Randamentele negative cresc volatilitatea viitoare *mai mult* decât randamentele pozitive de aceeași magnitudine
- Răspuns asimetric: $\mathrm{Corr}(r_t, \sigma^2_{t+1}) < 0$
- Denumit după Black (1976): scăderea prețului $\Rightarrow$ levier mai mare $\Rightarrow$ risc mai mare
- Capturat de GJR-GARCH, EGARCH

Memoria lungă în volatilitate

- $\mathrm{Corr}(|r_t|, |r_{t+k}|)$ scade *lent* (hiperbolic, nu exponențial)
- Exponentul Hurst $H > 0{,}5$ pentru $|r_t|$
- GARCH standard: descreștere exponențială
- Modelele FIGARCH, HAR surprind memoria lungă

Asimetria câștig/pierdere

- **Asimetria câștig/pierdere**: Prețurile acțiunilor scad mai repede decât cresc
- Scăderile mari au loc în zile; recuperarea durează luni sau ani
- Această asimetrie este distinctă de asimetria distribuției — privește *dinamica*, nu distribuția marginală
- **Efect volumetric**: Volumul de tranzacționare crește în episoadele de volatilitate mare
  - Corelație pozitivă între $|r_t|$ și volumul zilnic
  - Amplificată de *margin calls* și vânzări forțate

Taxonomia Cont (2001) și modele multifractale

- Cont (2001): taxonomie sistematică a 11 fapte stilizate pentru randamentele activelor
- **Modele multifractale** (Mandelbrot, Fisher & Calvet, 1997):
  - $\mathbb{E}[|r_t|^q] \propto \Delta t^{\zeta(q)}$ cu $\zeta(q)$ *neliniar* (multiscaling)
  - Unifractal: $\zeta(q) = qH$ (liniar); multifractal: $\zeta(q)$ concav
- Structura corelațiilor încrucișate și fapte stilizate multivariate
- Fapte stilizate intra-zilnice: zgomot de microstructură, săritura bid-ask, efectul Epps

Structura fractală și legile putere

- **Cozi tip lege putere (*power law*)**: $P(|r| > x) \sim x^{-\alpha}$ cu $\alpha \in [2, 5]$ pentru majoritatea activelor financiare
- Exponentul de coadă α este remarcabil de stabil între active și perioade
- **Auto-similaritate**: Distribuțiile randamentelor la scale temporale diferite sunt legate prin scalare
- Conexiunea cu distribuțiile stabile: dacă $\alpha < 2$, TLC Generalizată implică limite stabile
- „Legea cubului invers" (Gopikrishnan et al., 1999): $\alpha \approx 3$ pentru acțiunile americane
- Dezbatere: lege putere reală vs. cozi cu variație lentă

Vizualizarea clusterizării volatilității

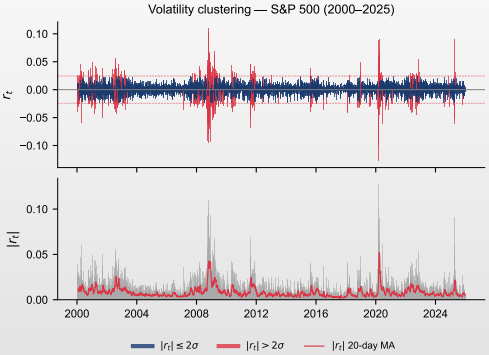

SFM_ch2_stylized_facts

- „Variații mari urmate de variații mari” (Mandelbrot, 1963) — crizele 2001, 2008, 2020
- $\mathrm{Corr}(r_t, r_{t+k}) \approx 0$ dar $\mathrm{Corr}(|r_t|, |r_{t+k}|) > 0$ — necorelate, dar **nu independente**

Ecuațiile faptelor stilizate — Kurtosis și autocorelația

Kurtosis

$$\kappa = \frac{\mathbb{E}[(X-\mu)^4]}{\sigma^4}$$

- **Exces de kurtosis**: $\kappa_e = \kappa - 3$
- $\kappa_e = 0$: distribuția normală (referință)
- $\kappa_e > 0$: **leptocurtică** (cozi groase — *fat tails*)

Autocorelația r_t^2

$$\rho_k = \mathrm{Corr}(r_t^2, r_{t+k}^2) > 0, \quad k \text{ mare}$$

Exemplu numeric

	κ	κ_e
Normal	3	0
S&P 500	$\approx$10	$\approx$7
FTSE 100	$\approx$8	$\approx$5
Bitcoin	$\approx$15	$\approx$12

- $\kappa_e = 7$ pentru S&P 500 $\Rightarrow$ cozi **substanțial mai groase** decât distribuția normală

Previzualizare: Măsuri de risc — VaR și ES

Definiție 3 (Value-at-Risk — definiție de lucru)

Value-at-Risk la nivelul α: pierderea maximă care **nu** este depășită cu probabilitatea $(1-\alpha)$:

$$\mathrm{VaR}_\alpha = -F^{-1}(\alpha), \quad \text{unde } F^{-1} \text{ este cuantila randamentelor.}$$

Definiție 4 (Expected Shortfall — definiție de lucru)

Expected Shortfall (ES) la nivelul α: pierderea **medie** în cele mai rele $\alpha\%$ scenarii:

$$\mathrm{ES}_\alpha = -\frac{1}{\alpha}\int_0^\alpha F^{-1}(p)\,dp.$$

- **Exemplu**: VaR 1% normală, $\sigma = 1{,}5\%$, \$1M: $\mathrm{VaR} = 2{,}326 \times 0{,}015 \times 10^6 = \$34.890$
- Proprietăți formale, coerența Artzner, backtesting — **Secțiunea 10**

VaR și ES — Ilustrare grafică

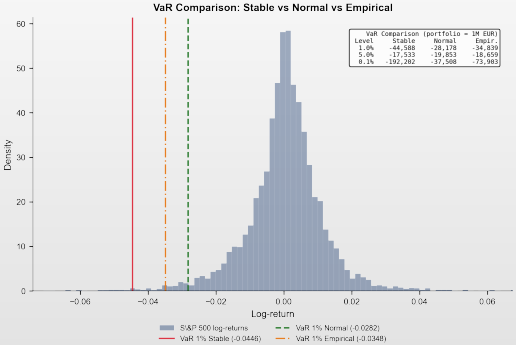

SFM_ch2_risk_management

- **VaR**$_\alpha$: cuantila — „nu vom pierde mai mult de X cu prob. $1-\alpha$"
- **ES**$_\alpha$: media cozii — „dacă depășim VaR, cât pierdem *în medie*?"
- ES $\geq$ VaR întotdeauna; diferența crește cu grosimea cozilor

Distribuția Student-t — Definiție

Definiție 5 (Distribuția Student-t)

$X \sim t_\nu$ dacă:

$$f(x;\nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\,\Gamma\left(\frac{\nu}{2}\right)} \left(1 + \frac{x^2}{\nu}\right)^{-(\nu+1)/2}, \quad x \in \mathbb{R}.$$

- Un singur parametru $\nu > 0$ (**grade de libertate**) controlează grosimea cozilor
- $\mathbb{E}[X] = 0$ $(\nu > 1)$; $\quad \mathrm{Var}(X) = \frac{\nu}{\nu-2}$ $(\nu > 2)$
- Exces de kurtosis: $\kappa_e = \frac{6}{\nu-4}$ $(\nu > 4)$
- $\nu \to \infty$: converge la $N(0,1)$; $\quad \nu = 1$: distribuția Cauchy
- Cozi: $f(x) \sim |x|^{-(\nu+1)}$ **(lege putere)**

PDF-uri Student-t — Efectul lui ν

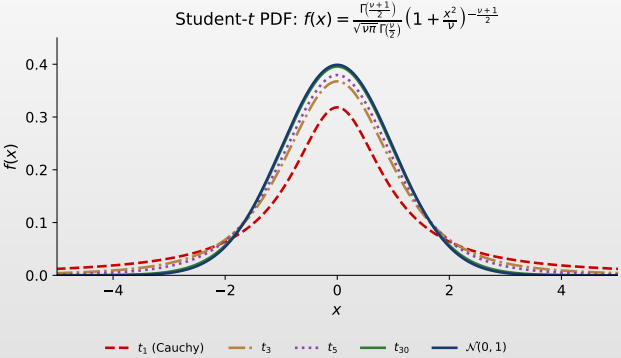

SFM_ch2_student_t

- ν mai mic $\Rightarrow$ cozi mai groase, vârf mai ascuțit
- Randamente financiare: de regulă $\hat{\nu} \in [3, 8]$ pentru date zilnice de acțiuni

Ajustarea Student-t pe S&P 500

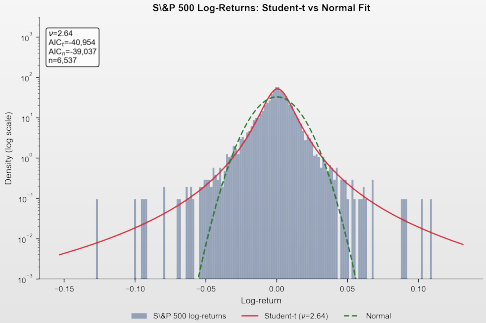

SFM_ch2_student_t

- Student-t surprinde cozile groase mult mai bine decât distribuția normală
- $\hat{\nu} \approx 4$–5 pentru S&P 500; centrul și cozile bine ajustate

De ce Student-t pentru finanțe?

Proprietate	**Normal**	**Student-t**
Descreșterea cozii	Exponențială ($e^{-x^2/2}$)	Lege putere ($\lvert x\rvert^{-\nu-1}$)
Exces de kurtosis	0	$6/(\nu-4)$
Parametri	2 (μ,σ)	3 (μ,σ,ν)
Evenimente extreme	Foarte rare	Mai frecvente
Limită	—	Normal ($\nu\to\infty$)

Avantaj cheie

- Student-t **include** distribuția normală ca un caz special ($\nu\to\infty$) permițând în același timp cozi mai groase
- Este cea mai simplă alternativă cu cozi groase

Forma locație-scală și MLE

- **Forma locație-scală**: $X = \mu + \sigma T$, unde $T \sim t_\nu$
- Estimare MLE a (μ, σ, ν): maximizăm

$$\ell(\mu, \sigma, \nu) = \sum_{t=1}^{n} \ln f\left(\frac{r_t - \mu}{\sigma}; \nu\right) - n \ln \sigma$$

- Criterii informaționale pentru selecția modelului:
  - AIC $= -2\ell + 2k$ (penalizează ușor complexitatea)
  - BIC $= -2\ell + k \ln n$ (penalizează mai puternic complexitatea)
- Student-t ca distribuție a inovațiilor în modele GARCH: $\epsilon_t = \sigma_t z_t$, $z_t \sim t_\nu$
- Diagnostice QQ-plot: abaterile de la linia de 45° indică specificare greșită

Compararea modelelor: normală vs. Student-t

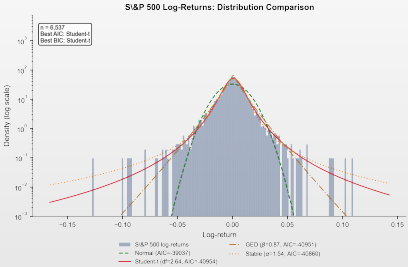

SFM_ch2_distribution_comparison

Model	Log-verosim.	AIC	BIC
Normal (μ, σ)	ℓ_1	$-2\ell_1 + 4$	$-2\ell_1 + 2\ln n$
Student-t (μ, σ, ν)	$\ell_2 > \ell_1$	$-2\ell_2 + 6$	$-2\ell_2 + 3\ln n$

- Student-t obține AIC/BIC substanțial mai bun în ciuda unui parametru suplimentar

Reprezentarea ca mixtură și interpretarea Bayesiană

- **Reprezentare ca mixtură**: $X \mid V \sim N(0, V), \quad V \sim \text{Inv-Gamma}(\nu/2, \nu/2)$
  - Student-t = Normală cu varianță aleatoare (mixtură de scale a normalelor)
  - Interpretare: V surprinde volatilitatea variabilă în timp
- **Interpretare Bayesiană**: Student-t ca distribuție marginală a posteriori sub priori conjugate normal–inverse-gamma
- **Student-t multivariată**: $f(x) \propto \left(1 + \frac{(x-\mu)'\Sigma^{-1}(x-\mu)}{\nu}\right)^{-(\nu+p)/2}$
- **Compararea cozilor**: indicele de coadă (*tail index*) $t_\nu = \nu$ vs. indicele de stabilitate $= \alpha$
- Student-t **nu** este închisă la convoluție; distribuțiile stabile **sunt**

Exemplu: Probabilitatea unei pierderi extreme

Exercițiu

Randamentele zilnice au $\sigma = 1{,}5\%$. Calculați $P(r < -3\sigma) = P(r < -4{,}5\%)$ sub distribuția normală vs. Student-t cu $\nu = 5$.

Rezolvare

- **Sub distribuția normală**: $P(r < -3\sigma) = \Phi(-3) = 0{,}00135 = 0{,}135\%$ (1 zi din 741)
- **Sub Student-t ($\nu = 5$)**: scală ajustată $s = \sigma\sqrt{(\nu-2)/\nu} = 0{,}01162$
  - $t_{\text{stat}} = -0{,}045/0{,}01162 = -3{,}874 \Rightarrow P(T_5 < -3{,}874) = 0{,}00584 = 0{,}584\%$ (1 zi din 171)

Concluzie

- Student-t prevede pierderi $> 3\sigma$ de **4,3× mai frecvent** decât distribuția normală (0,584% vs. 0,135%)

Distribuția Pareto — Legea de putere

Definiție (Pareto, 1896)

O variabilă aleatoare X urmează o **distribuție Pareto** cu parametri $x_m > 0$ (scală) și $\alpha > 0$ (formă / indice de coadă) dacă:

$$\boxed{f(x) = \frac{\alpha\, x_m^{\alpha}}{x^{\alpha+1}}, \quad x \geq x_m}$$

- **CDF**: $F(x) = 1 - \left(\frac{x_m}{x}\right)^{\alpha}$
- **Funcția de supraviețuire**:

$$\bar{F}(x) = P(X > x) = \left(\frac{x_m}{x}\right)^{\alpha}$$

- Comportament **lege de putere** (*power law*): $P(X > x) \propto x^{-\alpha}$
- **Medie**: $\mathbb{E}[X] = \frac{\alpha\, x_m}{\alpha - 1}$ (există doar dacă $\alpha > 1$)
- **Varianță**: $\mathrm{Var}(X) = \frac{\alpha\, x_m^2}{(\alpha-1)^2(\alpha-2)}$ (există doar dacă $\alpha > 2$)
- $\alpha \leq 2$: **varianță infinită**
- $\alpha \leq 1$: **medie infinită**

Distribuția Pareto — Grafic PDF și CDF

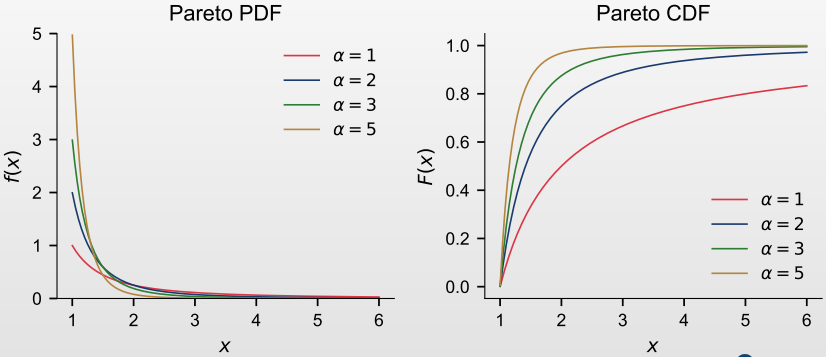

SFM_ch2_pareto_analysis

- α mic $\Rightarrow$ coadă groasă, densitate scade lent
- α mare $\Rightarrow$ masa se concentrează lângă x_m, coada scade rapid

Distribuția Pareto — Semnătura legii de putere

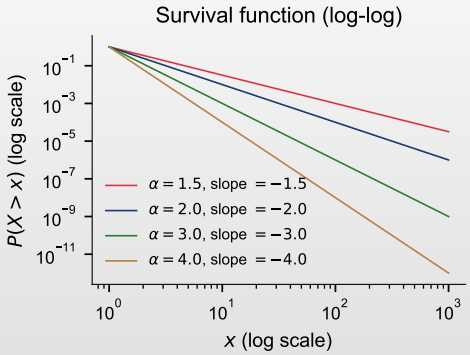

Testul grafic log-log

- Pe graficul log-log, funcția de supraviețuire Pareto este o **dreaptă**: $\log P(X > x) = -\alpha \log x + \alpha \log x_m$
- **Panta** $= -\alpha$ (indicele de coadă)
- Aliniere pe dreaptă $\Rightarrow$ comportament Pareto
- Abaterea pentru x mici: *trunchiere*

Distribuția Pareto — De ce contează în finanțe?

Principiul lui Pareto (regula 80/20)

- **Vilfredo Pareto** (1896): 80% din averea Italiei era deținută de 20% din populație
- Aceeași lege apare în finanțe: pierderile extreme urmează o lege de putere
- **Mandelbrot** (1963): randamentele piețelor au cozi de tip Pareto

Proprietatea cheie: cozile groase

- Normală: $P(X > x) \sim e^{-x^2/2}$ (**exponențial**); Pareto: $P(X > x) \sim x^{-\alpha}$ (**polinomial**)
- Evenimentele *Black Swan* sunt **mult mai probabile** sub Pareto
- **Exemplu**: $\alpha = 3$, $P(X > 10x_m) = 10^{-3}$; sub normală: $\approx 10^{-23}$

Distribuția Pareto — Estimarea parametrilor (MLE)

Estimatorul de verosimilitate maximă (MLE)

- Fie $x_1, \ldots, x_n$ un eșantion i.i.d. din Pareto(α, x_m)
- **Pasul 1**: $\hat{x}_m = \min(x_1, \ldots, x_n)$ (scala = valoarea minimă)
- **Pasul 2**: $\hat{\alpha}_{\text{MLE}} = \dfrac{n}{\sum_{i=1}^{n} \ln(x_i/\hat{x}_m)}$
- **Proprietăți**: consistent, eficient asimptotic, $\sqrt{n}$-convergent

Distribuția Pareto — MLE: Demonstrație

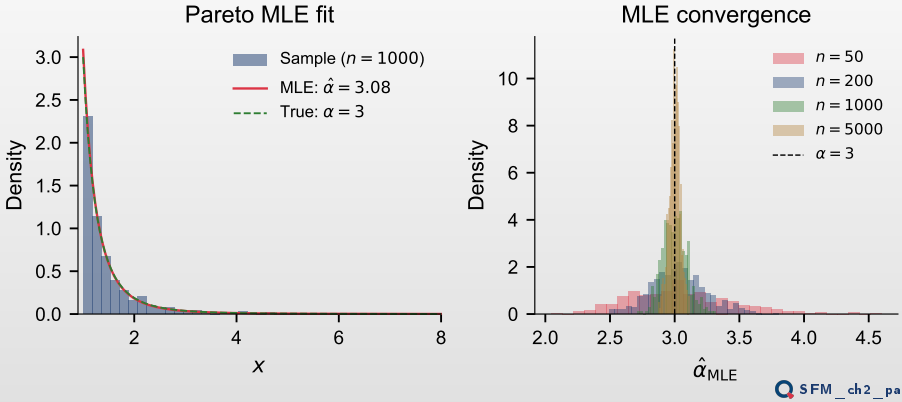

- **Stânga**: histogram + fit MLE vs. valoarea adevărată ($\alpha = 3$, $n = 1000$)
- **Dreapta**: convergența MLE pe măsură ce n crește ($n = 50 \to 5000$)

Distribuția Pareto — Estimatorul Hill pe S&P 500

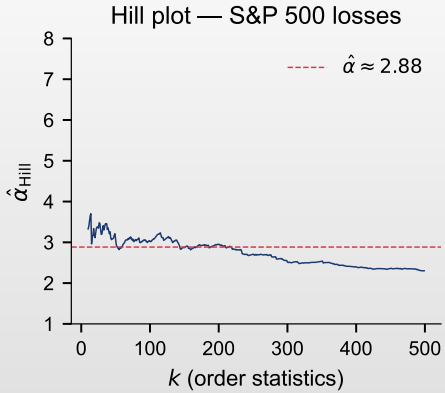

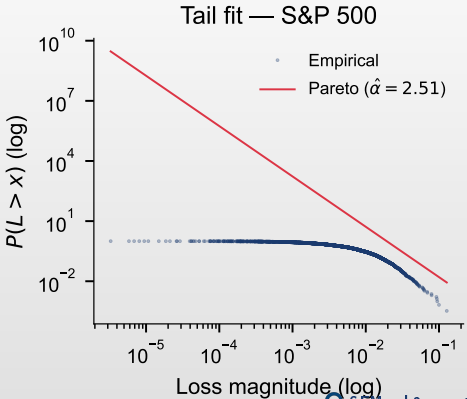

SFM_ch2_pareto_analysis

- **Hill plot**: zona stabilă $\hat{\alpha} \approx 2{,}9$; **Tail fit**: Pareto $\hat{\alpha} \approx 2{,}5$
- $\alpha < 3 \Rightarrow$ momente de ordin ≥ 3 nu există; confirmare: **cozi groase**

Distribuția Pareto — Tail fitting (S&P 500)

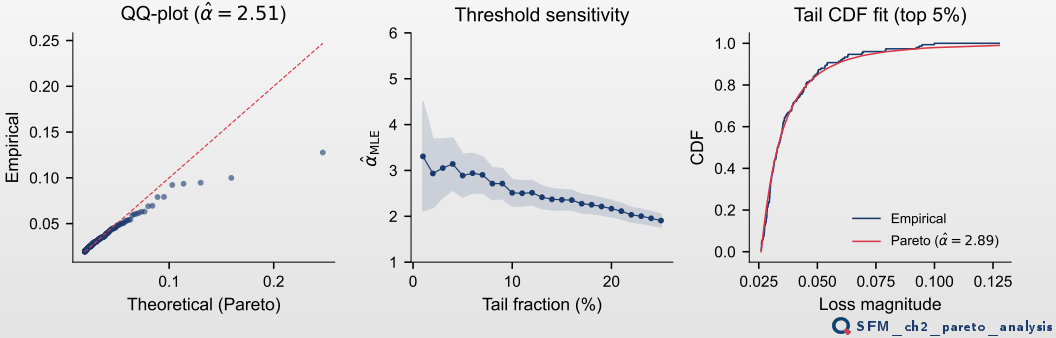

- **QQ-plot**: aliniere pe diagonală ⇒ coada este Pareto
- **Sensibilitate prag**: zona stabilă ≈ 3–8%; $\hat{\alpha} \approx 2{,}5$–$3{,}0$

Distribuția Pareto — Interpretarea tail fitting

Procedura de tail fitting

- **Pasul 1**: Selectăm pragul u (sau fracția de coadă, e.g. top 5%)
- **Pasul 2**: Estimăm $\hat{\alpha}$ pe datele $\{x_i : x_i > u\}$ via MLE sau Hill
- **Pasul 3**: Verificăm sensibilitatea: variază u și observăm stabilitatea lui $\hat{\alpha}$
- **Pasul 4**: Validăm cu QQ-plot și CDF fit

Rezultate empirice (S&P 500, 2000–2025)

- $\hat{\alpha} \approx 2{,}5$–$3{,}0 \Rightarrow$ momente finite doar până la ordinul 2
- Varianța există, dar kurtosis-ul **nu** — distribuția normală este inadecvată
- CDF-ul Pareto se potrivește bine pe coada dreaptă a pierderilor

Distribuția Pareto — Aplicații

Legea lui Zipf (capitalizare de piață)

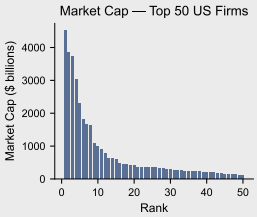

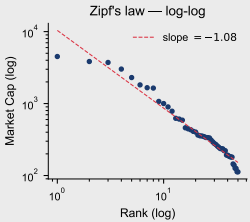

- Capitalizarea firmelor urmează o lege de putere
- Top 10 firme $\approx$ 30% din piață
- Panta Zipf ≈ -1 (lege empirică universală)

Alte aplicații ale distribuției Pareto

- **Pierderi din asigurări**: sumele asigurate extreme $\Rightarrow$ Pareto
- **Riscul operațional** (Basel II): pierderile operaționale au coada Pareto
- **Distribuția averii**: Top 1% deține 40–50% din avere (Piketty, 2014)
- **Volumul tranzacțiilor**: câteva tranzacții mari domină volumul total
- **Cyber risk**: severitatea atacurilor cibernetice este Pareto-distribuită

Distribuția Pareto — Conexiuni teoretice

Legătura cu EVT și estimatorul Hill

- **Teorema Pickands–Balkema–de Haan**: excedentele peste un prag suficient de mare urmează aproximativ o **distribuție Pareto generalizată** (GPD)
- Distribuția Pareto clasică = caz particular al GPD cu $\xi > 0$
- **Estimatorul Hill**: estimează α din statisticile de ordine $X_{(1)} \leq \cdots \leq X_{(n)}$:

$$\hat{\alpha}_{\text{Hill}} = \left(\frac{1}{k} \sum_{i=1}^{k} \ln \frac{X_{(n-i+1)}}{X_{(n-k)}} \right)^{-1}$$

Legătura cu distribuțiile stabile și Student-t

- Distribuțiile α-stabile cu $\alpha < 2$ au cozi Pareto: $P(X > x) \sim C_\alpha x^{-\alpha}$
- Student-t cu ν grade de libertate: cozi Pareto cu indice $\alpha = \nu$
- Indicele de coadă Pareto unifică teoria: mai mic $\alpha \Rightarrow$ cozi mai groase

Cuprins

- Introducere ✓
- De la prețuri la log-randamente ✓
- Distribuția normală ✓
- Fapte stilizate ✓
- Distribuția Student-t ✓
- Distribuția Pareto ✓
- **Distribuții asimetrice**
- Distribuții stabile
- Teoria valorilor extreme
- Comparația distribuțiilor
- Copule și dependența de coadă (*tail dependence*)
- Managementul riscului
- Extensii moderne / Rezumat

Studiu de caz: Datele

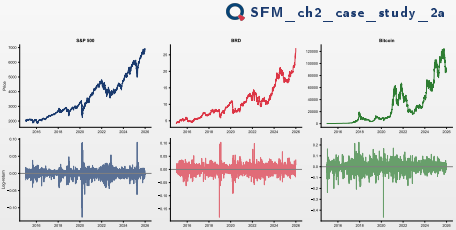

Prețuri și log-randamente

- **S&P 500** — piață dezvoltată, lichiditate mare
- **BRD** — acțiune românească, piață emergentă
- **Bitcoin** — activ digital, volatilitate extremă
- Perioadă: 2015–2025, date zilnice

Activ	N	Media (%)	Std (%)	Skew	Kurt
S&P 500	∼2 500	0.05	1.15	−0.60	13.5
BRD	∼2 500	0.04	1.10	−0.80	12.0
Bitcoin	∼3 600	0.12	3.80	−0.30	8.5

Studiu de caz: Fapte stilizate

Volatilitate clusterizată

- ACF a $|r_t|$ confirmă dependența pe termen lung:
- Toate cele 3 active prezintă autocorelație semnificativă a $|r_t|$ până la lag-ul 60
- **Kurtosis** $\gg 3$ pe toate piețele $\Rightarrow$ cozi groase
- **Asimetrie negativă** pentru S&P 500 și BRD (*leverage effect*)
- Bitcoin: asimetrie mai redusă, dar volatilitate de $3\times$

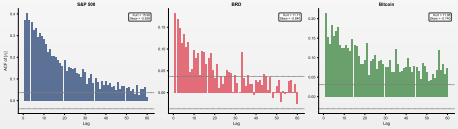

Observație 2

- Clusterizarea volatilității invalidează ipoteza i.i.d. necesară modelului Black–Scholes

Studiu de caz: Normal vs Student-t

SFM_ch2_case_study_2a

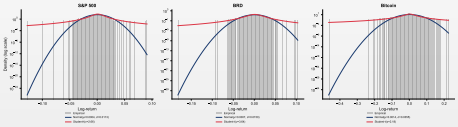

Histogramă log-scale cu overlay

- Comparăm cele două modele pe scara logaritmică:
- Normal subestimează sistematic cozile
- Student-t se adaptează bine cu ν estimat:
  - S&P 500: $\hat{\nu} \approx 4$–5
  - BRD: $\hat{\nu} \approx 3$–5
  - Bitcoin: $\hat{\nu} \approx 3$–4
- Diferența crește exponențial în cozi

Studiu de caz: QQ-plots

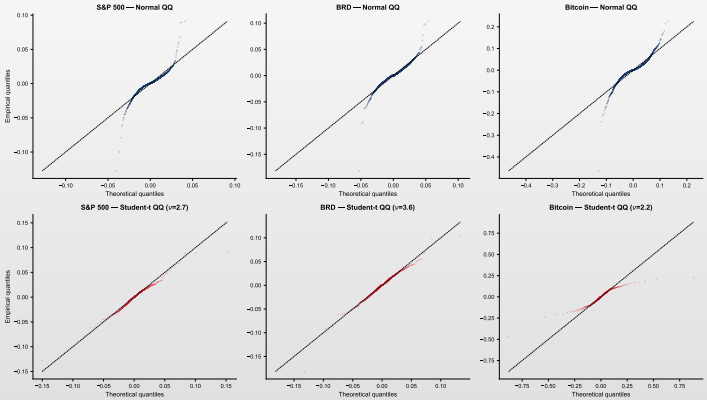

- **Normal QQ**: deviații sistematice în cozi **Student-t QQ**: aliniere mult mai bună
- Bitcoin: cele mai mari deviații, confirmând cozi mai groase

Studiu de caz: Teste de normalitate

Testarea ipotezei H_0: randamentele $\sim \mathcal{N}(\mu, \sigma^2)$

Activ	Jarque–Bera	Shapiro–Wilk	Anderson–Darling	Kolmogorov–Smirnov
S&P 500	$> 10\,000^{***}$	$< 0.99^{***}$	$> 20^{***}$	$> 0.05^{***}$
BRD	$> 8\,000^{***}$	$< 0.99^{***}$	$> 15^{***}$	$> 0.04^{***}$
Bitcoin	$> 5\,000^{***}$	$< 0.98^{***}$	$> 30^{***}$	$> 0.06^{***}$

- *** respingere la nivel $\alpha = 0.001$ pentru toate testele și toate activele

Concluzie

- Normalitatea este **respinsă decisiv** pe toate cele trei piețe
- Cele patru teste converg: JB (momente), SW (ordine), AD (cozi), KS (distribuție completă)

Studiu de caz: VaR și ES — Normal vs Student-t

Aplicarea formulelor de risc (portofoliu 1M EUR, $\mu \approx 0$)

- $\mathrm{VaR}^N_{1\%} = 2{,}326\,\sigma$; $\mathrm{VaR}^t_{1\%} = \sqrt{\frac{\nu-2}{\nu}}\,|t_\nu^{-1}(0{,}01)|\,\sigma$; ES: media cozii stângi sub VaR

Activ (σ, $\hat{\nu}$)	VaR Normal	VaR Student-t	ES Normal	ES Student-t
S&P 500 (1,15%, 4,5)	26 750	30 400	30 500	40 200
BRD (1,10%, 3,8)	25 590	29 600	29 300	40 200
Bitcoin (3,80%, 3,2)	88 390	102 000	100 900	148 700

ES Normal subestimează cu 30–50%

- $P(r < -3\sigma)$: Normal $= \Phi(-3) = 0{,}135\%$ (1 zi/741); Student-t ($\hat{\nu}=4{,}5$) $\approx 0{,}58\%$ (1 zi/172) — de $4{,}3\times$ mai frecvent

Studiu de caz: Selecția modelului — AIC/BIC

Criterii informaționale ($\text{AIC} = -2\ell + 2k$; $\text{BIC} = -2\ell + k \ln n$)

Activ	ΔAIC (Normal − Student-t)	ΔBIC	Câștigător
S&P 500	> 200	> 190	Student-t
BRD	> 150	> 140	Student-t
Bitcoin	> 300	> 290	Student-t

Observație 3

- $\Delta\text{AIC} > 10 \Rightarrow$ evidență puternică împotriva modelului Normal (Burnham & Anderson)
- Student-t câștigă decisiv pe toate piețele, deși are un parametru suplimentar (ν)

Studiu de caz: Concluzii

Lecții din analiza datelor reale

1. **Kurtosis** $\gg 3$ pe toate piețele $\Rightarrow$ modelul Normal este inadecvat
2. **Student-t** oferă o primă aproximare, dar are *cozi simetrice*
3. **Asimetria** (mai ales pe S&P 500 și BRD) necesită modele asimetrice
4. **Volatilitatea clusterizată** cere modele condiționale (GARCH)

Implicații pentru managementul riscului

- ES Normal la 1% subestimează pierderea medie din coadă cu **30–50%** față de Student-t
- VaR Normal subestimează cu $\sim$15%, dar evenimentele de 3σ apar de $4\times$ mai des

Întrebarea 1

Întrebare

- Evenimentul din 19 octombrie 1987 (S&P 500 $-20{,}5\%$) corespunde unui eveniment de $\sim 20\sigma$ sub ipoteza normală ($\sigma \approx 1\%$). Care este probabilitatea unui astfel de eveniment?

Variante de răspuns

- **(A)** $\approx 10^{-2}$ (1 la 100)
- **(B)** $\approx 10^{-30}$ (practic imposibil pe orizontul uman)
- **(C)** $\approx 10^{-89}$ (imposibil în durata de viață a universului)
- **(D)** $\approx 10^{-6}$ (o dată la un milion de zile)

Întrebarea 1: Răspuns

Răspuns: (C)

- Sub distribuția normală ($\sigma \approx 1\%$), un eveniment de $\sim 20\sigma$ are probabilitatea $\approx 10^{-89}$.
- Și totuși s-a întâmplat — aceasta demonstrează **inadecvarea distribuției normale** pentru evenimente extreme.
- Sub distribuții cu cozi groase (Student-t, stabilă), astfel de evenimente au probabilități mult mai mari.
- Aceasta este motivația principală pentru studierea distribuțiilor alternative.

Întrebarea 2

Întrebare

- O distribuție Student-t cu $\nu = 4$ grade de libertate are:

Variante de răspuns

- **(A)** Medie finită, varianță finită, kurtosis finită
- **(B)** Medie finită, varianță finită, kurtosis infinită
- **(C)** Medie finită, varianță infinită, kurtosis infinită
- **(D)** Medie infinită, varianță infinită, kurtosis infinită

Întrebarea 2: Răspuns

Răspuns: (B)

- Pentru Student-t: media există dacă $\nu > 1$, varianța dacă $\nu > 2$, kurtosis dacă $\nu > 4$.
- Cu $\nu = 4$: media finită (✓), varianță finită ($= \nu/(\nu - 2) = 2$, ✓), dar kurtosis-ul **nu există** (momentul de ordin 4 diverge: $6/(\nu - 4)$ cu $\nu = 4$).
- (A) este greșit: momentul de ordin 4 nu există la $\nu = 4$ exact.
- Aceasta arată că și distribuțiile cu varianță finită pot avea cozi **foarte groase**.

Exercițiul 1: Log-randamente și momente

Enunț

Se dau prețurile zilnice de închidere:

t	0	1	2	3	4
P_t	100	103	98	95	102

1. Calculați log-randamentele $r_t = \ln(P_t/P_{t-1})$ pentru $t = 1, \ldots, 4$.
2. Calculați media, varianța, asimetria și kurtosis eșantionului.
3. Aplicați testul Jarque–Bera: $JB = \frac{n}{6}\left(S^2 + \frac{(K-3)^2}{4}\right)$. Se respinge normalitatea la 5%?
4. Calculați log-randamentul total pe 4 perioade. Verificați aditivitatea temporală.

Exercițiul 2: Distribuția normală și VaR

Enunț

⊡ Un portofoliu de \$5M are randamente zilnice $\sim N(\mu, \sigma^2)$ cu $\hat{\mu} = 0{,}04\%$ și $\hat{\sigma} = 1{,}2\%$

1. Calculați VaR zilnic la nivelurile 5%, 1% și 0,1%.
2. Calculați Expected Shortfall la nivelul 1%.
3. Un eveniment de -4% a avut loc. Ce probabilitate are sub ipoteza normală?
4. Argumentați de ce VaR normal poate subestima riscul real.

Indiciu

$\text{VaR}_\alpha = -(\mu + z_\alpha \cdot \sigma)$, unde $z_{0,05} = -1{,}645$, $z_{0,01} = -2{,}326$, $z_{0,001} = -3{,}090$.

Exercițiul 3: Student-t — Ajustare și comparație

Enunț

- Pe datele de la Exercițiul 1, presupuneți că MLE produce: distribuția normală $\ell = 12{,}5$, Student-t ($\nu = 5$) $\ell = 14{,}8$

1. Calculați AIC și BIC pentru ambele modele ($k_N = 2$, $k_t = 3$, $n = 4$).
2. Care model este preferat de AIC? Dar de BIC?
3. Calculați excesul de kurtosis (*excess kurtosis*) al distribuției Student-t cu $\nu = 5$.
4. Explicați de ce Student-t captează mai bine cozile groase decât distribuția normală.

Formule

- $\text{AIC} = -2\ell + 2k, \quad \text{BIC} = -2\ell + k \ln n, \quad \kappa = 6/(\nu - 4)$ pentru $\nu > 4$

Laborator Python — Exerciții interactive

Lab 1: Ajustarea distribuțiilor (Y3)

1. Deschideți `SFM_ch2_normal_distribution.ipynb`
2. Descărcați date S&P 500 (2015–2025); calculați log-randamentele
3. Histogramă + suprapunere normală; testul Jarque–Bera
4. Ajustați Student-t (MLE). Comparați AIC cu modelul normal

SFM_ch2_normal_distribution

Exercițiu AI: Distribuții și risc de coadă

Prompt de testat în ChatGPT / Claude / Copilot

"Descarcă datele zilnice pentru S&P 500 și Bitcoin din 2015 până în 2025 folosind Python (`yfinance`). Calculează log-randamentele. Ajustează pe fiecare serie o distribuție normală și o distribuție Student-t prin MLE. Compară modelele folosind AIC/BIC, QQ-plot și histogramă pe scară logaritmică. Calculează VaR la 1% și Expected Shortfall sub ambele modele. Estimează indicele de coadă Pareto cu estimatorul Hill."

Exercițiu:

1. AI-ul calculează corect log-randamentele? Verifică: $r_t = \ln(P_t/P_{t-1})$, nu $(P_t - P_{t-1})/P_{t-1}$
2. Gradele de libertate $\hat{\nu}$ estimate sunt plauzibile ($\hat{\nu} \in [3, 8]$ pentru date zilnice)?
3. Formulele VaR și ES sunt corecte? Verifică: $\text{VaR}^t_{1\%}$ folosește scală ajustată $s = \sigma\sqrt{(\nu-2)/\nu}$?
4. Întreabă AI-ul: "Ce se întâmplă cu VaR dacă $\nu \leq 2$?" Menționează varianța infinită?
5. Hill plot-ul arată o zonă stabilă? Ce valoare $\hat{\alpha}$ obține? Compară cu $\hat{\nu}$ din Student-t

⊡ **Atenție**: AI-ul confundă adesea *excess kurtosis* ($\kappa - 3$) cu kurtosis-ul total (κ). Verificați mereu definiția folosită.

Exercițiul 1: Rezolvare

Rezolvare

1. Log-randamente: $r_1 = \ln(103/100) = 0{,}0296$, $r_2 = \ln(98/103) = -0{,}0498$, $r_3 = \ln(95/98) = -0{,}0311$, $r_4 = \ln(102/95) = 0{,}0713$
2. $\bar{r} = (0{,}0296 - 0{,}0498 - 0{,}0311 + 0{,}0713)/4 = 0{,}0050$; $s^2 = \frac{1}{3}\sum(r_i - \bar{r})^2 = 0{,}00253$; $s = 0{,}0503$. Asimetrie: $S \approx 0{,}56$; Kurtosis: $K \approx 1{,}72$
3. $JB = \frac{4}{6}(0{,}56^2 + (1{,}72 - 3)^2/4) = 0{,}48$. Cu $\chi^2_2(0{,}05) = 5{,}99$: $0{,}48 < 5{,}99 \Rightarrow$ **nu respingem** normalitatea (eșantion prea mic!)
4. $r_{0:4} = \ln(102/100) = 0{,}0198 = r_1 + r_2 + r_3 + r_4 = 0{,}0198$ ✓

Exercițiul 2: Rezolvare

Rezolvare

1. $\text{VaR}_\alpha = -(\mu + z_\alpha \sigma) \times W$, cu $\mu = 0{,}0004$, $\sigma = 0{,}012$, $W = \$5\text{M}$:
   - VaR 5%: $0{,}01934 \times 5\text{M} = \$96.680$; VaR 1%: \$137.560; VaR 0,1%: \$183.400
2. $\text{ES}_{1\%} = \sigma \cdot \phi(-2{,}326)/0{,}01 = 0{,}03198 \Rightarrow \$159.900$
3. $P(r < -0{,}04) = \Phi(-3{,}37) \approx 0{,}038\%$ (1 zi în $\sim$2.600)
4. Empiric, evenimentele $> 3\sigma$ apar mult mai frecvent $\Rightarrow$ VaR normal subestimează riscul

Exercițiul 3: Rezolvare

Rezolvare

1. Cu $\ell_N = 12{,}5$, $\ell_t = 14{,}8$, $k_N = 2$, $k_t = 3$, $n = 4$:
   - Normal: AIC $= -21{,}0$; BIC $= -22{,}23$. Student-t: AIC $= -23{,}6$; BIC $= -25{,}44$
2. Student-t câștigă pe ambele criterii (AIC: $-23{,}6 < -21{,}0$; BIC: $-25{,}44 < -22{,}23$)
3. Exces de kurtosis: $\kappa = 6/(\nu - 4) = 6/(5 - 4) = 6$. Kurtosis totală: $3 + 6 = 9$
4. PDF-ul Student-t scade ca $|x|^{-(\nu+1)}$ (lege putere) vs. $e^{-x^2/2}$ pentru normală. Decăderea mai lentă alocă mai multă probabilitate în cozi

Bibliografie I

Manuale de referință

- McNeil, A., Frey, R. & Embrechts, P. (2015). *Quantitative Risk Management*. Princeton University Press.
- Nolan, J. P. (2020). *Stable Distributions — Models for Heavy Tailed Data*. Birkhäuser.
- Rachev, S. T. (2003). *Handbook of Heavy Tailed Distributions in Finance*. Elsevier.

Articole fundamentale

- Mandelbrot, B. (1963). The Variation of Certain Speculative Prices. *Journal of Business*, 36(4), 394–419.
- Fama, E. (1965). The Behavior of Stock-Market Prices. *Journal of Business*, 38(1), 34–105.
- Cont, R. (2001). Empirical Properties of Asset Returns. *Quantitative Finance*, 1(2), 223–236.

Bibliografie II

Distribuții și estimare

- Hansen, B. (1994). Autoregressive Conditional Density Estimation. *International Economic Review*, 35(3), 705–730.
- Nolan, J. P. (1997). Numerical Calculation of Stable Densities and Distribution Functions. *Stochastic Models*, 13(4), 759–774.
- Barndorff-Nielsen, O. (1977). Exponentially Decreasing Distributions for the Logarithm of Particle Size. *Proc. Royal Society A*, 353, 401–419.

Modele dinamice

- Hamilton, J. D. (1989). A New Approach to the Economic Analysis of Nonstationary Time Series. *Econometrica*, 57(2), 357–384.
- Merton, R. (1976). Option Pricing When Underlying Stock Returns Are Discontinuous. *J. of Financial Economics*, 3, 125–144.
- Barndorff-Nielsen, O. & Shephard, N. (2001). Non-Gaussian Ornstein–Uhlenbeck-Based Models. *JRSS B*, 63(2), 167–241.

Bibliografie III

Testare și selecție de modele

- Vuong, Q. H. (1989). Likelihood Ratio Tests for Model Selection and Non-Nested Hypotheses. *Econometrica*, 57(2), 307–333.
- Fissler, T. & Ziegel, J. F. (2016). Higher Order Elicitability and Osband's Principle. *Annals of Statistics*, 44(4), 1680–1707.

Resurse online și cod

- **Quantlet**: `https://quantlet.com` ≻ Platformă de cod pentru metode cantitative
- **Quantinar**: `https://quantinar.com` ≻ Platformă de învățare pentru metode cantitative
- **GitHub SFM**: `https://github.com/QuantLet/Stat_fin_markets/tree/master/Ch_02` ≻ Cod Python capitol 2

Bibliografie IV

Referințe recente (2020–2025)

- Kelly, B., Jiang, H. & Pruitt, S. (2022). Tail Risk and Asset Prices. *Review of Financial Studies*, 35(5), 2254–2295.
- Bollerslev, T. & Todorov, V. (2023). The Jump Tails of Asset Returns. *Econometrica* (forthcoming).
- Aas, K., Czado, C., Frigessi, A. & Bakken, H. (2009). Pair-Copula Constructions of Multiple Dependence. *Insurance: Mathematics and Economics*, 44(2), 182–198.

Evenimente recente relevante

- **Covid-19 (mar. 2020)**: S&P 500 -12% într-o zi; al 3-lea cel mai rău eveniment din istorie
- **FTX/crypto (nov. 2022)**: Prăbușire de -65% în 48h; cozi groase extreme
- **SVB (mar. 2023)**: Contagiune bancară; risc de coadă în sectorul financiar
- **Lecția**: Modelele cu cozi groase sunt **esențiale**, nu opționale

Vă Mulțumim!

Întrebări?

Materialele cursului sunt disponibile la: https://danpele.github.io/SFM/

Quantlet Quantinar