



Statistica Piețelor Financiare

Capitolul 4: Ipoteza Pieței Eficiente (EMH)



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Obiective de învățare (Learning Objectives)

La finalul acestui capitol, veți fi capabili să:

1. **Definiți** eficiența informațională a pieței și cele trei forme (slabă, semi-tare, tare)
2. **Formalizați** EMH utilizând modelele martingal și mers aleator
3. **Implementați** teste statistice pentru eficiența în formă slabă (weak-form) (autocorelație, runs, variance ratio)
4. **Analizați** studii de eveniment pentru eficiența semi-tare
5. **Evaluați** anomaliile de piață și provocările comportamentale la adresa EMH
6. **Discutați** Ipoteza Pieței Adaptive ca sinteză modernă

Cuprins

1. Motivație
2. Ipoteza Pieței Eficiente
3. Cadrul matematic
4. Eficiența în formă slabă (Weak-Form)
5. Teste extinse de mers aleator
6. Eficiența semi-tare (Semi-Strong)
7. Eficiența în formă tare (Strong-Form)
8. Anomalii de piață
9. Finanțe comportamentale
10. Ipoteza Pieței Adaptive (AMH)
11. Studii de caz și Exerciții
12. Concluzii

Puteți bate piața? (Can You Beat the Market?)

▣ Întrebarea centrală din finanțe

- Poate un investitor să obțină constant randamente superioare indicelui de referință?

▣ Burton Malkiel (1973)


- „O maimuță legată la ochi, aruncând săgeți într-o pagină cu cotații bursiere, ar putea selecta un portofoliu la fel de bun ca cel ales cu grijă de experți.”

▣ Fapt empiric


- Peste 90% din fondurile active subperformează indicele pe 15 ani
- Sursa: SPIVA (*S&P Indices Versus Active*) Scorecard, 2024

▣ Implicație

- Dacă prețurile reflectă toată informația, nicio strategie nu poate genera sistematic **alpha**



Evidența SPIVA: Active vs Passive



- Faptul empiric dominant
 - ▶ > 90% din fondurile active subperformează pe 15 ani
 - ▶ Gap-ul cumulativ în favoarea indicelui
- Cauze principale
 - ▶ Comisioane de administrare ~ 1%/an
 - ▶ Cost de tranzacție și slippage
 - ▶ Concurență între manageri informați
- Consecință
 - ▶ Fondurile index pasive au crescut rapid
 - ▶ Argument puternic pentru EMH (Fama 1965)

Context istoric (Historical Context)

An	Autor	Contribuție
1900	Louis Bachelier	Teză: prețurile acțiunilor urmează un mers aleator
1953	Maurice Kendall	Prețurile acțiunilor britanice nu prezintă tipare
1965	Eugene Fama	„Random Walks in Stock Market Prices”
1965	Paul Samuelson	„Proof That Properly Anticipated Prices Fluctuate Randomly”
1970	Eugene Fama	Taxonomia formală EMH: slabă, semi-tare, tare
1991	Eugene Fama	EMH revizuită: predictibilitate, studii de eveniment
2004	Andrew Lo	Ipoteza Pieței Adaptive (AMH)
2013	Fama & Shiller	Premiul Nobel (viziuni opuse despre eficiență)

Definiția eficienței informaționale (Informational Efficiency)


Definiție 1 (Piață eficientă — Fama, 1970)

- ▣ **Piață eficientă informațional**
 - ▶ Prețurile reflectă pe deplin toată informația Ω_t
 - ▶ Formal: $P_t = \mathbb{E}[P_t \mid \Omega_t]$
- ▣ **Implicație**
 - ▶ Nicio strategie bazată pe Ω_t nu bate randamentul de echilibru
- ▣ **Impredictibilitate**
 - ▶ Prețurile răspund doar la informații **noi** (surprize)
- ▣ **Ipoteză compusă**
 - ▶ EMH = eficiență + model de echilibru al randamentelor

Joint Hypothesis Problem

- ▣ Eficiența nu se testează izolat
 - ▶ Orice test cere un model (CAPM, APT, etc.)
- ▣ Respingere = ineficiență *sau* model greșit

Cele trei forme ale EMH (Three Forms of EMH)



Cele trei forme: rezumat (Three Forms: Summary)

Forma	Mulțimea info	Implicație	Ce exclude
Slabă	Prețuri, volume, rand. istorice	An. tehnică nu poate genera α	Medii mobile, tipare grafice
Semi-tare	Toată informația publică	An. fundamentală nu poate genera α	Filtre P/E, tranzacț. pe știri
Tare	Toată informația (incl. insider)	Niciun investitor nu are avantaj	Insider trading, info private

- Fiecare formă este **inclusă**: tare $\Rightarrow$ semi-tare $\Rightarrow$ slabă
- Dacă forma tare este valabilă, ambele forme mai slabe sunt automat valabile
- Majoritatea cercetărilor empirice se concentrează pe eficiența slabă și semi-tare

Modelul jocului echitabil (Fair Game)

Definiție 2 (Joc echitabil)

Fie r_{t+1} randamentul unui activ. Piața este un **joc echitabil** în raport cu informația Ω_t dacă:

$$\mathbb{E}[r_{t+1} - \mathbb{E}[r_{t+1} \mid \Omega_t] \mid \Omega_t] = 0.$$

- ▣ Definim randamentul excesiv: $z_{t+1} = r_{t+1} - \mathbb{E}[r_{t+1} \mid \Omega_t]$
- ▣ Condiția de joc echitabil: $\mathbb{E}[z_{t+1} \mid \Omega_t] = 0$ — erorile de prognoză sunt nedeplasate
- ▣ Nicio regulă de tranzacționare $\delta(\Omega_t)$ nu poate produce profit excesiv așteptat pozitiv: $\mathbb{E}[\delta(\Omega_t) \cdot z_{t+1}] = 0$

Intuiție

- ▣ Jocul echitabil $\neq$ randamente zero
 - ▶ Doar randamentele **neasteptate** sunt zero în medie
- ▣ Investitorii câștigă prima de risc
 - ▶ Dar nu pot face sistematic mai bine decât echilibrul

Martingal și mers aleator (Martingale and Random Walk)

Martingal

- $\{P_t\}$ este martingal în raport cu Ω_t dacă:

$$\mathbb{E}[P_{t+1} \mid \Omega_t] = P_t$$

- Prețurile nu au trend predictibil
- Mai slabă decât mersul aleator: permite varianță variabilă în timp

Mers aleator (Random Walk)

- **RW1**: $P_t = P_{t-1} + \varepsilon_t$, $\varepsilon_t \stackrel{iid}{\sim} (0, \sigma^2)$
- **RW2**: incremente independente dar nu identic distribuite
- **RW3**: incremente necorelate (cea mai slabă)
- $\text{RW1} \Rightarrow \text{RW2} \Rightarrow \text{RW3}$

Distincție esențială

- EMH $\nRightarrow$ Mers aleator
 - ▶ EMH cere un **martingal** pentru prețurile ajustate la risc
 - ▶ Nu cere incremente iid
- Clusterizarea volatilității este compatibilă cu EMH

Cele trei tipuri de mers aleator (Three Types of Random Walk)

Definiție 3 (RW1 — Mers aleator cu incremente iid)

$P_t = \mu + P_{t-1} + \varepsilon_t$, unde $\varepsilon_t \stackrel{iid}{\sim} (0, \sigma^2)$. Incrementele sunt independente și identic distribuite. Cel mai restrictiv model.


RW2 — Incremente independente

- ▣ $P_t = \mu + P_{t-1} + \varepsilon_t$
- ▣ ε_t sunt independente dar **nu** identic distribuite
- ▣ Permite heteroscedasticitate necondiționată (de ex. volatilitatea se modifică între subperioade)
- ▣ Testabil prin: variance ratio, BDS test

RW3 — Incremente necorelate

- ▣ $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ pentru $t \neq s$
- ▣ Dar pot exista dependențe neliniare: $\text{Cov}(\varepsilon_t^2, \varepsilon_s^2) \neq 0$
- ▣ Compatibil cu modele GARCH (*Generalized AutoRegressive Conditional Heteroskedasticity*)
- ▣ Cel mai slab model — autocorelațiile randamentelor sunt zero, dar cele ale randamentelor pătratice nu

Simulare mers aleator vs S&P 500 (RW Simulation)



- Stânga: preț cumulat — RW simulat (verde) vs S&P 500 (albastru)
 - Ambele sunt $I(1)$ (trend stocastic, nestaționare)
- Dreapta: randamente $r_t = \varepsilon_t$ — staționare, $I(0)$

Mersul aleator logaritmic (Logarithmic Random Walk)

Modelul

- Prețurile financiare urmează un **mers aleator geometric**:

$$P_t = P_{t-1} \cdot e^{\mu + \sigma \varepsilon_t}, \quad \varepsilon_t \sim \mathcal{N}(0, 1)$$

- Echivalent, log-prețurile urmează un mers aleator aritmetic:

$$\ln P_t = \ln P_{t-1} + \mu + \sigma \varepsilon_t$$

- Log-randamentele sunt i.i.d.:

$$r_t = \ln \frac{P_t}{P_{t-1}} = \mu + \sigma \varepsilon_t \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$$


De ce logaritmic?

- Prețurile nu pot fi negative: $P_t > 0$ întotdeauna
- Log-randamentele sunt aditiv compuse
- Consistent cu capitalizarea continuă
- Log-normalitatea implică cozi mai groase decât normalul simplu

Proprietăți:

- $\mathbb{E}[\ln P_t] = \ln P_0 + \mu t$
- $\text{Var}(\ln P_t) = \sigma^2 t$ (crește liniar)
- $P_t \sim \text{LogNormal}(\ln P_0 + \mu t, \sigma^2 t)$
- Regula $\sqrt{T}$: $\sigma_T \text{ zile} = \sigma_1 \text{ zi} \cdot \sqrt{T}$

De la EMH la predicții testabile (Testable Predictions)



Testarea eficienței în formă slabă (Weak-Form)

- ▣ **Ipoteza nulă:** randamentele trecute nu conțin informație despre randamentele viitoare
- ▣ Dacă EMH în formă slabă (weak-form) este validă, randamentele ar trebui să fie serial necorelate:

$$\text{Corr}(r_t, r_{t-k}) = 0, \quad \forall k \geq 1$$

Principalele teste statistice

Test	Ipoteza nulă	Metoda
Autocorelație	$\rho_k = 0$ pentru orice k	Statistica Ljung–Box Q
Test runs	Randamentele sunt aleatorii	Test neparametric de semn
Variance ratio	$\text{Var}(r_t^{(q)}) = q \cdot \text{Var}(r_t)$	Lo–MacKinlay (1988)
Test ADF	Rădăcină unitară în prețuri	Augmented Dickey–Fuller

Testul de autocorelație (Autocorrelation Test)

Autocorelația eșantionului

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^T (r_t - \bar{r})(r_{t-k} - \bar{r})}{\sum_{t=1}^T (r_t - \bar{r})^2}$$

- ▣ Sub H_0 : $\hat{\rho}_k \sim \mathcal{N}(0, 1/T)$ aproximativ
- ▣ Se respinge dacă $|\hat{\rho}_k| > z_{\alpha/2}/\sqrt{T}$

Statistica Ljung–Box Q

$$Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k}$$


- ▣ Testează ipoteza nulă compusă:
 $\rho_1 = \rho_2 = \dots = \rho_m = 0$
- ▣ Sub H_0 : $Q(m) \sim \chi^2(m)$
- ▣ Alegere tipică: $m = 10$ sau $m = 20$

Rezultat empiric


- ▣ Randamente zilnice pe indici: $\hat{\rho}_1 \approx 0,05-0,10$
 - ▶ Mic dar statistic semnificativ (Lo & MacKinlay, 1988)
 - ▶ Economic ne semnificativ, dar contestă strict EMH slabă

Interpretarea graficului ACF (ACF Interpretation)

- ▣ Graficul ACF (*AutoCorrelation Function* — funcția de autocorelație) arată $\hat{\rho}_k$ pentru $k = 1, 2, \dots, m$
- ▣ **Banda de încredere 95%**: $\pm 1,96/\sqrt{T}$
- ▣ Bare care depășesc banda $\Rightarrow$ autocorelație semnificativă la lag-ul k
- ▣ **Piață eficientă**: toate barele ar trebui să fie în interiorul benzii (zgomot alb)
- ▣ **Randamente**: de regulă ACF aproape de zero — eficiență aproximativă
- ▣ **Randamente pătratice** (r_t^2): ACF semnificativ pozitivă pe multe lag-uri $\Rightarrow$ clusterizare a volatilității (compatibilă cu EMH!)



Funcția de autocorelație: rezultate empirice (ACF Empirical Results)



- Observații empirice pe S&P 500
 - ▶ Toate autocorelațiile $|\hat{\rho}_k| < 1,96/\sqrt{n}$
 - ▶ Pattern compatibil cu EMH slabă
- Randamente pătratice r_t^2
 - ▶ Autocorelații mari și persistente
 - ▶ Clustering de volatilitate (GARCH)
- Concluzie
 - ▶ Independență liniară; dependență neliniară
 - ▶ Compatibil cu EMH slabă

Testul runs (Runs Test)

Definiție 4 (Run)

Un **run** este o secvență maximală consecutivă de randamente cu același semn. Ex.: $(+, +, -, -, -, +)$ are 3 run-uri.

- Fie n_+ = nr. randamente pozitive, n_- = nr. randamente negative, R = nr. run-uri
- Sub independență:

$$\mathbb{E}[R] = \frac{2n_+n_-}{n_+ + n_-} + 1$$

$$\text{Var}(R) = \frac{2n_+n_-(2n_+n_- - n_+ - n_-)}{(n_+ + n_-)^2(n_+ + n_- - 1)}$$

- Statistica de test:

$$Z = \frac{R - \mathbb{E}[R]}{\sqrt{\text{Var}(R)}} \xrightarrow{d} \mathcal{N}(0, 1)$$

- **Prea puține run-uri** $\Rightarrow$ impuls (autocorelație pozitivă)
- **Prea multe run-uri** $\Rightarrow$ reversie la medie (autocorelație negativă)
- **Neparametric**: nu necesită ipoteze distribuționale

Testul variance ratio (Variance Ratio Test)

Ideea cheie

□ Dacă randamentele sunt iid, varianța randamentelor pe q perioade ar trebui să crească liniar: $\text{Var}(r_t(q)) = q \cdot \text{Var}(r_t)$

□ **Raportul de varianță:**

$$VR(q) = \frac{\text{Var}(r_t(q))}{q \cdot \text{Var}(r_t)} = 1 + 2 \sum_{k=1}^{q-1} \left(1 - \frac{k}{q}\right) \rho_k$$

- $VR(q) = 1$: mers aleator (fără autocorelație)
- $VR(q) > 1$: autocorelație pozitivă (impuls)
- $VR(q) < 1$: autocorelație negativă (reversie la medie)

□ **Lo-MacKinlay (1988):**

$$Z(q) = \frac{VR(q) - 1}{\sqrt{\phi(q)}} \xrightarrow{d} \mathcal{N}(0, 1)$$

unde $\phi(q)$ este varianța asimptotică

- Versiune robustă la heteroscedasticitate disponibilă
- Tipic: $q = 2, 5, 10, 20$

 SFM_ch3_variance_ratio

Testul ADF (Augmented Dickey–Fuller)

Modelul

- Se testează dacă seria de prețuri $\{P_t\}$ are rădăcină unitară (mers aleator):

$$\Delta P_t = \alpha + \beta t + \gamma P_{t-1} + \sum_{j=1}^p \delta_j \Delta P_{t-j} + \varepsilon_t$$

- $H_0: \gamma = 0$ (rădăcină unitară, serie nestăționară) vs. $H_1: \gamma < 0$ (staționaritate)

- Statistica ADF **nu** are distribuție normală sub H_0 — se folosesc tabele Dickey–Fuller
- Valori critice la 5%: $\approx -2,86$ (fără trend), $\approx -3,41$ (cu trend)
- Se respinge H_0 dacă $ADF < \text{valoarea critică}$
- Rezultat tipic:** prețurile sunt $I(1)$ (ADF nu respinge H_0), dar log-randamentele sunt $I(0)$ (ADF respinge H_0)
- Consistent cu modelul mersului aleator pentru prețuri
- Lag-urile p se aleg cu AIC sau BIC


Variance ratio: rezultate empirice (Empirical Results)

Piață	VR(2)	VR(5)	VR(10)	VR(20)	Interpretare
S&P 500	1,05	1,04	0,99	0,95	Impuls scurt, reversie lungă
FTSE 100	1,03	1,01	0,97	0,92	Reversie moderată
BTC-USD	1,02	0,98	0,94	0,88	Reversie pe orizonturi lungi
BET	1,12	1,18	1,10	1,01	Impuls puternic (ineficient)

- ▣ Piețe dezvoltate: $VR \approx 1$ la majoritatea orizonturilor $\Rightarrow$ aproximativ eficiente
- ▣ Piețe emergente (BET): deviații mai mari $\Rightarrow$ potențială ineficiență
- ▣ Crypto: eficiență ridicată pe termen scurt, reversie la medie pe termen lung
- ▣ **Tipar:** $VR > 1$ la orizonturi scurte, $VR < 1$ la orizonturi lungi — impuls pe termen scurt și reversie la medie pe termen lung (Poterba & Summers, 1988)


 SFM_ch4_vr_profile

Variance ratio: profil multi-piață (Multi-Market Profile)



- S&P 500 (dezvoltată)
 - ▶ $VR \approx 1$ pe toate orizonturile
 - ▶ Cvasi-eficientă forma slabă
- Bitcoin (crypto)
 - ▶ $VR > 1$ crescător $\Rightarrow$ momentum
 - ▶ Persistența randamentelor pe termen mediu
- BET/BVB (emergentă)
 - ▶ Momentum scurt, apoi mean reversion
 - ▶ Piață subțire, tranzacționare rară

Variance ratio mobil (Rolling VR: Time-Varying Efficiency)



- VR mobil: $VR(q)$ pe fereastră de 500 zile;
 $|VR - 1|$ = indice de eficiență
- În crize (2008, 2020), $|VR - 1|$ crește abrupt
- BET: nivel bazal mai ridicat $\Rightarrow$ mai puțin eficient
- Între crize, eficiența se restabilește (AMH)

Studiu de caz: Eficiența EMH pe S&P 500 (Case Study)

Date: S&P 500, randamente zilnice, 2000–2025 ($T \approx 6300$)

☐ Sursa: Yahoo Finance via yfinance

Test	Statistică	p -value	Decizie
Ljung–Box $Q(10)$	$Q = 18,7$	0,044	Respingere marginală la 5%
Ljung–Box $Q(20)$	$Q = 28,3$	0,102	Non-respingere la 5%
Test runs	$Z = -1,82$	0,069	Non-respingere marginală
VR(2) Lo–MacKinlay	$Z = 2,41$	0,016	Respingere la 5%
VR(5) Lo–MacKinlay	$Z = 1,34$	0,181	Non-respingere
ADF (prețuri)	$\tau = -1,23$	0,66	Rădăcină unitară (așteptat)
ADF (randamente)	$\tau = -56,1$	$< 0,001$	Staționare (așteptat)

Concluzie

☐ S&P 500 este **aproximativ eficient**: autocorelație statistică slabă la lag 1, dar economic ne semnificativă. Costurile de tranzacționare elimină orice profit potențial.

Eficiența pe piețe emergente: BET (*Bucharest Exchange Trading, BVB*)

Rezultate BET (2005–2025)

- ▣ $\hat{\rho}_1 = 0,11$ (semnificativ la 1%)
- ▣ Ljung–Box $Q(10) = 42,5$ ($p < 0,001$)
- ▣ $VR(2) = 1,12$, $VR(5) = 1,18$
- ▣ Test runs: $Z = -3,24$ ($p = 0,001$)
- ▣ Exponent Hurst: $H \approx 0,58$

- ▣ Autocorelație semnificativă $\Rightarrow$ eficiența slabă este respinsă
- ▣ Cauzele posibile: lichiditate redusă, costuri de tranzacționare mari, tranzacții nesincronizate

Comparație piețe emergente

Piață	$\hat{\rho}_1$	$VR(5)$	H
BET (România)	0,11	1,18	0,58
WIG (Polonia)	0,06	1,08	0,54
BUX (Ungaria)	0,05	1,05	0,53
BIST (Turcia)	0,04	1,03	0,52
S&P 500	0,02	1,04	0,52

- ▣ Piețele emergente din Europa Centrală și de Est sunt mai puțin eficiente decât piețele dezvoltate
- ▣ BET prezintă cea mai mare abatere de la eficiență

Python: Autocorelație și testul Ljung-Box

```
import yfinance as yf
import numpy as np
from statsmodels.stats.diagnostic import acorr_ljungbox
from statsmodels.tsa.stattools import acf

# Descarca date S&P 500
sp = yf.download("^GSPC", start="2000-01-01", end="2025-01-01")
ret = np.log(sp["Close"] / sp["Close"].shift(1)).dropna()

# Autocorelație esanțion
rho = acf(ret, nlags=20, fft=True)
print(f"rho_1={rho[1]:.4f}, rho_5={rho[5]:.4f}")

# Testul Ljung-Box
lb = acorr_ljungbox(ret, lags=[10, 20], return_df=True)
print(lb)
# Q(10)=18.7 (p=0.044), Q(20)=28.3 (p=0.102)
```

Python: Testul variance ratio pe S&P 500

```
import numpy as np

def variance_ratio(returns, q):
    """ Calculeaza VR(q) si statistica Z Lo-MacKinlay. """
    T = len(returns)
    mu = returns.mean()
    # Varianta pe 1 perioada
    var1 = np.sum((returns - mu)**2) / (T - 1)
    # Randamente pe q perioade
    ret_q = np.array([returns[i:i+q].sum()
                      for i in range(T - q + 1)])
    varq = np.sum((ret_q - q * mu)**2) / (T - q)
    vr = varq / (q * var1)
    # Varianta asimptotica (sub homoscedasticitate)
    phi = 2 * (2*q - 1) * (q - 1) / (3 * q * T)
    z = (vr - 1) / np.sqrt(phi)
    return vr, z

for q in [2, 5, 10, 20]:
    vr, z = variance_ratio(ret.values, q)
    print(f"VR({q:2d}) = {vr:.4f}, Z = {z:+.3f}")
```

Testul ADF: Formulare (Formulation)

Ecuția de regresie ADF

- ▣ Augmented Dickey–Fuller cu trend: $\Delta P_t = \alpha + \beta t + \gamma P_{t-1} + \sum_{j=1}^p \delta_j \Delta P_{t-j} + \varepsilon_t$
- ▣ $H_0: \gamma = 0$ (rădăcină unitară) vs. $H_1: \gamma < 0$ (staționaritate)

▣ Selecția lag-urilor p :

- ▣ AIC: $AIC(p) = \ln \hat{\sigma}_p^2 + \frac{2p}{T}$
- ▣ BIC: $BIC(p) = \ln \hat{\sigma}_p^2 + \frac{p \ln T}{T}$
- ▣ BIC preferă modele mai parsimonioase
- ▣ Alternativă: general-to-specific (de la $p_{\max}$, se elimină lag-uri ne semnificative)

▣ Valori critice MacKinnon (1996):

- ▣ 1%: -3,43; 5%: -2,86; 10%: -2,57 (fără trend)
- ▣ 1%: -3,96; 5%: -3,41; 10%: -3,13 (cu trend)
- ▣ Se respinge H_0 dacă $\tau_{ADF} < \text{valoarea critică}$
- ▣ **Interpretare EMH:** prețurile $I(1) \Rightarrow$ mers aleator; randamentele $I(0) \Rightarrow$ consistent

 SFM_ch3_emh_tests

Testele Phillips–Perron și KPSS

Phillips–Perron (PP)

- ▣ Corectează neparametric autocorelația reziduurilor
- ▣ Nu adaugă lag-uri ΔP_{t-j} ; în schimb, ajustează statistica t folosind estimatorul Newey–West
- ▣ H_0 : rădăcină unitară (ca ADF)
- ▣ Avantaj: robust la heteroscedasticitate și autocorelație de formă necunoscută

Kwiatkowski–Phillips–Schmidt–Shin, KPSS (1992)

- ▣ **Inversează ipotezele:**
- ▣ H_0 : seria este staționară
- ▣ H_1 : seria are rădăcină unitară
- ▣ Statistica: $\eta = T^{-2} \sum_{t=1}^T S_t^2 / \hat{\sigma}_{LR}^2$
- ▣ $\hat{\sigma}_{LR}^2$ = varianța pe termen lung (Bartlett kernel)

Test	H_0	H_1	Utilizare EMH
ADF	Rădăcină unitară	Staționaritate	Non-respingere $\Rightarrow$ mers aleator
PP	Rădăcină unitară	Staționaritate	Robust la heterosced.
KPSS	Staționaritate	Rădăcină unitară	Respingere $\Rightarrow$ mers aleator

Analiza spectrală pentru eficiența slabă (Spectral Analysis)

Densitatea spectrală a randamentelor

- ▣ Descompune varianța pe frecvențe: $f(\omega) = \frac{1}{2\pi} [\gamma_0 + 2 \sum_{k=1}^{\infty} \gamma_k \cos(\omega k)]$
- ▣ Zgomot alb: $f(\omega) = \sigma^2/(2\pi)$ — spectru **plat** (constant)
- ▣ **Testul Bartlett (1955):**
 - ▣ Compară periodograma cumulată cu distribuția uniformă
 - ▣ Statistica Kolmogorov–Smirnov pe spectrul cumulat
 - ▣ H_0 : spectru plat (zgomot alb)
 - ▣ Respingere $\Rightarrow$ dependență serial la anumite frecvențe
- ▣ **Interpretare EMH:**
 - ▣ Spectru plat $\Rightarrow$ nicio frecvență dominantă $\Rightarrow$ EMH consistent
 - ▣ Pic la frecvențe joase $\Rightarrow$ memorie lungă (anti-EMH)
 - ▣ Pic la frecvențe înalte $\Rightarrow$ microstructură / bouncing
 - ▣ Avantaj: detectează tipare periodice invizibile în ACF

Reguli de filtrare și tranzacționare tehnică (Filter Rules)

Regulile Alexander (1961)

- Cumpără dacă prețul crește cu $x\%$ de la un minim local
- Vinde dacă prețul scade cu $x\%$ de la un maxim local
- Filtre tipice: $x = 0,5\%, 1\%, 2\%, 5\%$
- Fama & Blume (1966): filtrele mici generează profit brut, dar **nu** după costuri de tranzacționare

Medie mobilă (*Moving Average*, MA) crossover


- **Definiție** $MA(k)$: $MA_t(k) = \frac{1}{k} \sum_{i=0}^{k-1} P_{t-i}$ — media aritmetică a ultimelor k prețuri
- Cumpără când MA scurtă (rapidă) > MA lungă (lentă)
- Vinde când MA scurtă < MA lungă
- Exemple: MA(50) vs MA(200) — „Golden Cross” / „Death Cross”
- Brock, Lakonishok & LeBaron (1992): profitabile pe date pre-1990
- Post-1990: profitabilitatea dispare $\Rightarrow$ piața se adaptează

Concluzie


- Strategiile tehnice **eșuează** după costuri
 - Costuri de tranzacționare, slippage, impact de piață
- Rezultat consistent cu EMH forma slabă (weak-form)

Exemplu: MA(50)/MA(200) pe S&P 500 (Concrete Example)

S\&P 500 cu MA(50) și MA(200) --- Golden/Death Cross



Performanța strategiei vs Buy \& Hold



SFM_ch4_ma_crossover

Exemplu MA: rezultate și interpretare (Results)

Backtest pe S&P 500 (2010–2024, $n = 3.774$ zile, 15 ani)

- ▣ **Buy & Hold**
 - ▶ CAGR = 11,65%; volatilitate anuală $\hat{\sigma} = 17,28\%$
 - ▶ Sharpe (cu $R_f = 2\%$): $(11,65 - 2)/17,28 = 0,56$
- ▣ **MA(50)/MA(200) crossover — brut (fără costuri)**
 - ▶ 13 tranzacții în 15 ani; timp în piață: $\sim 85\%$
 - ▶ CAGR = 7,86%; $\hat{\sigma} = 13,73\%$
 - ▶ Sharpe brut: $(7,86 - 2)/13,73 = 0,43$
- ▣ **MA(50)/MA(200) crossover — net de costuri (0,05%/tranzacție)**
 - ▶ CAGR = 7,81% (cu 0,05pp pierdere din costuri)
 - ▶ Sharpe net: 0,42

Concluzii practice

- ▣ MA reduce volatilitatea (σ scade de la 17,3% la 13,7%), dar **pierde** $\sim 3,8$ pp de randament anual
- ▣ Raportul Sharpe al B&H (0,56) depășește pe cel al MA (0,42) $\Rightarrow$ MA **nu** adaugă valoare ajustată la risc
- ▣ Rezultat consistent cu EMH slabă pe piețe dezvoltate post-1990
- ▣ **Excepție utilă:** MA ajută la reducerea Maximum Drawdown (MDD) în crize mari

Python: Teste de rădăcină unitară (Unit Root)

```
import yfinance as yf, numpy as np
from statsmodels.tsa.stattools import adfuller, kpss

sp = yf.download("^GSPC", start="2000-01-01", end="2025-01-01")
prices = sp["Close"].dropna()
ret = np.log(prices / prices.shift(1)).dropna()

# Test ADF pe preturi (asteptam non-respingere = radacina unitara)
adf_p = adfuller(prices, maxlag=20, autolag="BIC")
print(f"ADF_preturi: stat={adf_p[0]:.3f}, p={adf_p[1]:.4f}")

# Test ADF pe randamente (asteptam respingere = stationaritate)
adf_r = adfuller(ret, maxlag=20, autolag="BIC")
print(f"ADF_randamente: stat={adf_r[0]:.3f}, p={adf_r[1]:.6f}")


# Test KPSS pe randamente (H0: stationaritate)
kpss_r = kpss(ret, regression="c", nlags="auto")
print(f"KPSS_randamente: stat={kpss_r[0]:.4f}, p={kpss_r[1]:.4f}")
# ADF preturi: stat=-1.23, p=0.66 (radacina unitara)
# ADF randamente: stat=-56.1, p<0.001 (stationare)
# KPSS randamente: stat=0.12, p>0.10 (stationare)
```

Testarea eficienței semi-tare (Semi-Strong: Event Studies)

Metodologie

- ▣ Se măsoară reacția prețului la un eveniment informațional public (câștiguri, M&A, dividende)
 - ▣ Dacă EMH semi-tare este validă: prețul se ajustează **imediat** și **complet** la știre
-
- | | |
|---|--|
| <ul style="list-style-type: none"> ▣ Pasul 1: Estimarea rand. normale pe fereastra $[-250, -11]$: $R_{i,t} = \alpha_i + \beta_i R_{m,t} + \varepsilon_{i,t}$ ▣ Pasul 2: Randamentele anormale pe $[-10, +10]$:
 $AR_{i,t} = R_{i,t} - (\hat{\alpha}_i + \hat{\beta}_i R_{m,t})$ | <ul style="list-style-type: none"> ▣ Pasul 3: Randamentul anormal cumulat:
 $CAR_i(\tau_1, \tau_2) = \sum_{t=\tau_1}^{\tau_2} AR_{i,t}$ ▣ Pasul 4: Media pe N evenimente:
 $\overline{CAR}(\tau_1, \tau_2) = \frac{1}{N} \sum_{i=1}^N CAR_i$ ▣ Test: $t = \overline{CAR} / (\hat{\sigma}_{CAR} / \sqrt{N})$ |
|---|--|

Studiu de eveniment: trei scenarii (Event Study Scenarios)



- (a) Surpriză pură
 - ▶ Ajustare instantanee la $t = 0$
 - ▶ Compatibil cu EMH semi-tare
- (b) Leak (scurgere)
 - ▶ Drift pozitiv pre-eveniment
 - ▶ Posibilă scurgere insider
- (c) PEAD
 - ▶ Drift post-eveniment persistent
 - ▶ Anomalie contra EMH semi-tare

Deriva post-anunț de câștiguri (Post-Earnings Announcement Drift, PEAD)

- După surprize privind câștigurile, prețurile acțiunilor continuă să derive în direcția surprizei timp de 60–90 de zile
- Una dintre cele mai puternice și persistente anomalii, documentată din Ball & Brown (1968)
- **Surpriza de câștiguri** — Standardized Unexpected Earnings (SUE):

$$SUE_t = \frac{EPS_t - \mathbb{E}[EPS_t]}{\sigma_{EPS}}$$

- Acțiunile din decila superioară SUE depășesc decila inferioară cu ~4% pe trimestru
- Supraviețuiește costurilor de tranzacționare în multe studii

Provocare la adresa EMH semi-tare


- PEAD implică faptul că prețurile **nu** se ajustează complet la informația publică privind câștigurile
- Fama (1998): „bunicul evenimentelor de subreacție”
- Persistă pe diverse piețe, perioade și metodologii

Python: Simulare event study

```
import numpy as np
np.random.seed(42)
T_est, T_evt, N = 240, 21, 50 # estimare, eveniment, nr
alpha, beta = 0.0002, 1.1
car_all = []
for _ in range(N):
    r_m = np.random.normal(0.0003, 0.01, T_est + T_evt)
    eps = np.random.normal(0, 0.015, T_est + T_evt)
    r_i = alpha + beta * r_m + eps
    r_i[T_est] += 0.03 # surpriza de 3% la t=0
    rm_est, ri_est = r_m[:T_est], r_i[:T_est]
    b = np.cov(ri_est, rm_est)[0,1] / np.var(rm_est)
    a = ri_est.mean() - b * rm_est.mean()
    ar = r_i[T_est:] - (a + b * r_m[T_est:]) # AR
    car_all.append(np.cumsum(ar))

car_mean = np.mean(car_all, axis=0)
se = np.std([c[-1] for c in car_all]) / np.sqrt(N)
print(f"CAR (-10,+10) = {car_mean[-1]:.4f}, t = {car_mean[-1]/se:.2f}")
```

Studiu de eveniment: rezultate empirice (Empirical Results)



- Randamentul anormal cumulat (CAR) arată ajustarea prețului în jurul evenimentului ($t = 0$)
- Deriva post-anunț vizibilă: piața nu se ajustează complet și imediat

Testarea eficienței în formă tare (Strong-Form)

Întrebare


- ▣ Pot investitorii cu informații **private** să obțină randamente anormale?
- ▣ **Evidențe din insider trading:**
 - ▣ Insiderii corporativi obțin ~5–8% randamente anormale din tranzacțiile lor (Jeng et al., 2003)
 - ▣ Insiderii cumpără înainte de creșteri de preț, vând înainte de scăderi
 - ▣ Raportările SEC (*Securities and Exchange Commission*, Formularul 4) arată tipare sistematice
 - ▣ ⇒ EMH în formă tare (strong-form) este **respinsă**
- ▣ **Evidențe din performanța managerilor de fonduri:**
 - ▣ Jensen (1968): fondurile mutuale nu bat piața după comisioane
 - ▣ Carhart (1997): persistența randamentelor fondurilor se explică prin momentum, nu prin abilitate
 - ▣ SPIVA (2024): 92% din fondurile US large-cap subperformează S&P 500 pe 15 ani
 - ▣ ⇒ Managerii profesioniști ca grup **nu** au informații private

Paradoxul Grossman–Stiglitz (Grossman-Stiglitz Paradox)

Teoremă 1 (Grossman & Stiglitz, 1980)

Dacă piețele sunt perfect eficiente, niciun investitor nu are stimulente să cheltuiască resurse pentru achiziția de informații. Dar dacă nimeni nu achiziționează informații, prețurile nu le pot reflecta. Prin urmare, piețele perfect eficiente sunt o imposibilitate.

- ▣ **Rezolvare:** piețele trebuie să fie „eficient ineficiente”
- ▣ Prețurile sunt *aproape* eficiente
 - ▶ Suficient de apropiate încât majoritatea nu pot profita
 - ▶ Cu suficiente deviații pentru a recompensa traderii informați
- ▣ Gradul de eficiență depinde de:
 - ▶ Costul achiziției de informații
 - ▶ Numărul de traderi informați
 - ▶ Lichiditatea pieței



Anomalii calendaristice (Calendar Anomalies)

Anomalie	Descriere	Status actual
Efectul ianuarie	Acțiunile mici au randamente mai mari în ianuarie	Slăbit semnificativ de la descoperire
Efectul luni	Randamentele sunt mai mici luna	Dispărut în mare parte
Schimbarea de lună	Rand. mai mari în ultimele și primele 3 zile	Încă prezent, legat de fluxuri salariale
Efectul de sărbătoare	Randamentele înainte de sărbători sunt mai mari	Persistă slab
Halloween	„Vinde în mai și pleacă”	Evidență mixtă, dep. de regiune

Biasul publicării și declinul anomaliilor

- ▣ Multe anomalii slăbesc sau dispar după publicare
 - ▶ Consistent cu EMH (McLean & Pontiff, 2016)
 - ▶ Arbitrageurs elimină greșelile de preț după ce devin cunoscute

Anomalii transversale (Cross-sectional Anomalies)

Efectul de valoare

- ▣ Acțiuni cu B/M ridicat au randamente superioare (Fama & French, 1993)
- ▣ Factorul High Minus Low (HML): $\sim 4\%$ pe an istoric
- ▣ Primă de risc sau eroare de preț?

Efectul de dimensiune

- ▣ Acțiuni cu capitalizare mică au randamente superioare (Banz, 1981)
- ▣ Factorul Small Minus Big (SMB): $\sim 2\%$ pe an; slăbit de la descoperire

Momentum

- ▣ Câștigătorii continuă să câștige pe 3–12 luni (Jegadeesh & Titman, 1993)
- ▣ Factorul Winners Minus Losers (WML): $\sim 8\%$ pe an; prăbușiri ocazionale (2009)
- ▣ Cea mai dificilă anomalie de explicat rațional

Volatilitate scăzută

- ▣ Acțiuni cu vol. scăzută au rand. ajustate la risc superioare
- ▣ Contrazice relația risc-randament din CAPM
- ▣ Explicații: constrângeri de levier, preferințe loterie

Anomalii extinse: De ce persistă? (Why Anomalies Persist)

Limita arbitrajului (Shleifer & Vishny, 1997)

- ▣ Riscul de model: eroarea de preț se poate agrava
- ▣ Riscul de lichiditate: active greu de vândut rapid
- ▣ Costuri de tranzacționare: spread, comisioane, impact
- ▣ Riscul de finanțare: margin call forțează închiderea
- ▣ LTCM (1998): aveau dreptate pe termen lung, dar au dat faliment pe termen scurt

De ce dispar anomaliile?

- ▣ McLean & Pontiff (2016): randamentele anomaliilor scad cu 58% după publicare
- ▣ Capital-ul atras de anomalie elimină profitul
- ▣ Îmbunătățiri tehnologice (High-Frequency Trading, HFT) accelerează procesul
- ▣ Anomaliile care supraviețuiesc sunt cele greu de arbitrajat (iliciditate, costuri mari)

Implicație

- ▣ Declinul anomaliilor post-publicare este **în sine o dovadă** pentru EMH

Grădina zoologică a factorilor (Factor Zoo)

- Harvey, Liu & Zhu (2016): peste **300** de factori publicați care pretind că prezic randamentele
- Mulți sunt probabil descoperiri false din cauza data mining-ului și p -hacking-ului
- Hou, Xue & Zhang (2020): majoritatea anomaliilor nu supraviețuiesc replicării cu corecții adecvate

Factor	t -stat (original)	t -stat (replicat)	Status
Valoare (HML)	3,07	2,83	Robust
Momentum (WML)	4,71	3,92	Robust
Dimensiune (SMB)	2,28	1,31	Slăbit
Accruals	4,33	0,89	Non-robust
Creșterea activelor	5,07	1,61	Slăbit

Implicație

- Corecțiile de testare multiplă (Bonferroni, BH = Benjamini-Hochberg)
 - ▶ Elimină majoritatea „anomaliilor”
 - ▶ Piața posibil mai eficientă decât sugerează factor zoo

Provocări comportamentale (Behavioral Challenges to EMH)

Biasuri cognitive

- ▣ **Exces de încredere:** traderii supraestimează precizia informațiilor
- ▣ **Ancorare:** prețurile rămân legate de puncte de referință (max 52 săpt., IPO)
- ▣ **Aversiune la pierdere:** pierderile afectează $\sim 2\times$ mai mult decât câștigurile (Kahneman & Tversky, 1979)
- ▣ **Comportament de turmă:** investitorii urmează mulțimea, amplificând bulele


Fenomene la nivel de piață

- ▣ **Bule:** Tulip (1637), Dot-com (2000), Subprime (2008), Crypto (2017, 2021)
- ▣ **Volatilitate excesivă:** Shiller (1981) — prețurile mai volatile decât justifică fundamentele
- ▣ **Limite ale arbitrajului:** corectarea erorilor de preț e riscantă și costisitoare

Contra-argumentul lui Fama

- ▣ Suprareacția și subreacția apar la fel de des $\Rightarrow$ erorile sunt aleatoare. Anomaliile sunt consistente cu EMH + prime de risc raționale.

Bule și prăbușiri: cronologie (Bubbles and Crashes Timeline)



□ Perspectiva EMH

- ▶ Bulele pot fi identificate doar *ex post*
- ▶ *Ex ante*, prețurile reflectau așteptări raționale date informațiile


□ Perspectiva comportamentală

- ▶ Iraționalitatea sistematică (comportamentul de turmă, speculația)
- ▶ Creează tipare predictibile

□ Idee cheie

- ▶ Chiar dacă există bule, e greu să profiți de ele
- ▶ „Piața poate rămâne irațională mai mult decât poți rămâne solvent”

Bule: pattern-uri comparative (Comparative Patterns)



- Pattern tipic al bulelor
 - ▶ Creștere exponențială înainte de vârf
 - ▶ Vârf abrupt, urmat de scădere rapidă
 - ▶ Asimetric: urcăm lent, coborâm brusc
- Trei exemple
 - ▶ Dotcom (Nasdaq, 2000)
 - ▶ Subprime housing (2007–2008)
 - ▶ Bitcoin (2021)
- Lecția pentru EMH
 - ▶ Bulele persistă în ciuda testelor EMH
 - ▶ Arbitrajul este costisitor și riscant

Teoria prospectului (Prospect Theory) — Kahneman & Tversky (1979)

Funcția de valoare

- Definită relativ la un **punct de referință** (nu în termeni absoluți):

$$v(x) = \begin{cases} x^\alpha & \text{dacă } x \geq 0 \\ -\lambda(-x)^\beta & \text{dacă } x < 0 \end{cases}$$

- $\alpha \approx 0,88$, $\lambda \approx 2,25$
- Concavă** pentru câștiguri (aversiune la risc)
- Convexă** pentru pierderi (căutare de risc)
- Mai abruptă** pentru pierderi: $\lambda > 1$ (aversiunea la pierdere)

Ponderarea probabilităților

- Investitorii **supraponderează** evenimentele rare (cozi)
- Subponderează** probabilitățile moderate
- Explică: preferința pentru loterie, asigurare simultană
- Funcția de ponderare $w(p)$:

$$w(p) = \frac{p^\gamma}{(p^\gamma + (1-p)^\gamma)^{1/\gamma}}$$

- $\gamma \approx 0,61$ (Tversky & Kahneman, 1992)

Efectul de dispoziție (Disposition Effect)

Definiție

- Investitorii tind să **vândă câștigătorii prea devreme** și să **păstreze perdanții prea mult**
- Odean (1998): investitorii individuali vând acțiuni câștigătoare cu 50% mai frecvent decât cele perdante
- Cauza: aversiunea la pierdere din teoria prospectului — realizarea unei pierderi este dureroasă


Implicații pentru EMH

- Creează presiune de vânzare pe câștigători $\Rightarrow$ sub-reacție la știri pozitive
- Reduce presiunea de vânzare pe perdanți $\Rightarrow$ sub-reacție la știri negative
- Contribuie la **PEAD** și **momentum**
- Grinblatt & Han (2005): efectul de dispoziție explică $\sim 40\%$ din profitul strategiei momentum

Măsurare

- Proportion of Gains Realized (PGR) vs. Proportion of Losses Realized (PLR). Efectul de dispoziție: $PGR > PLR$.

Efectul de dispoziție: evidență (Disposition Effect Evidence)



- Pattern universal
 - ▶ PGR > PLR la toate categoriile
 - ▶ Retail: cel mai afectat
 - ▶ Instituționali: disciplină mai bună
- Interpretare comportamentală
 - ▶ Loss aversion (Kahneman-Tversky)
 - ▶ Mental accounting: preț cumpărare = referință
- Impact asupra performanței
 - ▶ Randament sub media pieței
 - ▶ Cost fiscal suplimentar

Limitele arbitrajului (Limits to Arbitrage)

De ce greșelile de preț persistă?

- ▣ **Riscul noise trader** (DeLong et al., 1990): traderii iraționali pot agrava eroarea de preț pe termen scurt
- ▣ **Riscul fundamental**: pot apărea știri negative despre activul subevaluat
- ▣ **Constrângeri de short-selling**: costuri de împrumut, recall risk, reglementări
- ▣ **Costuri de implementare**: spread, comisioane, impact de piață

Exemple celebre

- ▣ **Royal Dutch/Shell (1907–2005)**: acțiuni duale cu prețuri diferite, deviație persistentă 8–15% — arbitrajul limitat de risc
- ▣ **Palm/3Com (2000)**: IPO Palm $\Rightarrow$ 3Com subevaluat, dar short-selling imposibil
- ▣ **LTCM (1998)**: strategii de convergență corecte, dar margin calls au forțat lichidarea

Implicație

- ▣ Ineficiențele pot persista chiar dacă sunt **cunoscute**
 - ▶ Corectarea lor este riscantă și costisitoare
 - ▶ Arbitrajul nu este „free lunch”

Puzzle-ul volatilității excesive (Excess Volatility)

Shiller (1981): Prețurile fluctuează prea mult

- ▣ Modelul valorii prezente: $P_t^* = \sum_{k=1}^{\infty} \frac{\mathbb{E}[D_{t+k}]}{(1+r)^k}$, unde D_{t+k} sunt dividendele viitoare
- ▣ Dacă EMH este validă, $P_t = \mathbb{E}[P_t^* | \Omega_t]$, deci $\text{Var}(P_t) \leq \text{Var}(P_t^*)$
- ▣ **Rezultat empiric:** $\text{Var}(P_t) \gg \text{Var}(P_t^*)$ — prețurile sunt mult mai volatile decât justifică fluxurile de numerar viitoare
- ▣ **Contra-argumente (Fama, Marsh & Merton):**
 - ▣ Rata de actualizare r nu este constantă
 - ▣ Prime de risc variabile în timp
 - ▣ Probleme econometrice (serie nestaționară, eșantion finit)
- ▣ **Interpretarea comportamentală:**
 - ▣ Excesul de încredere amplifică reacțiile
 - ▣ Comportamentul de turmă generează feedback pozitiv
 - ▣ Modelul Campbell–Shiller: $\sim 1/3$ din varianța prețurilor explicată de dividende, $\sim 2/3$ de sentimentul investitorilor

Indicatori de sentiment (Sentiment Indicators)

Indicatori de piață

- ▣ **VIX** (CBOE Volatility Index, Fear Index): volatilitate implicită din opțiuni S&P 500
- ▣ $VIX > 30$: frică extremă; $VIX < 15$: complacență
- ▣ **Raportul Put/Call**: volum put / volum call
- ▣ Raport > 1 : sentiment bearish; $< 0,7$: bullish
- ▣ **Fluxuri în fonduri**: intrări nete = optimism; ieșiri = pesimism

Indexul Baker–Wurgler (2006)

- ▣ Indice compozit de sentiment bazat pe:
- ▣ Volumul IPO-urilor și randamentul primei zile
- ▣ Raportul dividende/fond propriu
- ▣ Closed-end fund discount
- ▣ Turnover (lichiditate)
- ▣ **Rezultat**: sentimentul ridicat prezice randamente scăzute viitoare (mai ales pentru acțiuni speculative)

Implicație pentru EMH

- ▣ Dacă sentimentul prezice randamente
 - ▶ Prețurile nu reflectă pe deplin informația $\Rightarrow$ contestare a EMH
- ▣ Contra-argument
 - ▶ Sentimentul poate fi o proxy pentru prime de risc variabile

Quiz: Finanțe comportamentale (Behavioral Finance)

Testați-vă cunoștințele

1. Un investitor refuză să vândă o acțiune care a scăzut cu 30%, spunând „nu am pierdut până nu vând”. Ce bias comportamental ilustrează?
R: Aversiunea la pierdere / efectul de dispoziție — realizarea pierderii este dureroasă, investitorul preferă să aștepte.
2. De ce arbitrajul nu elimină imediat toate greșelile de preț?
R: Limitele arbitrajului: risc noise trader, risc fundamental, constrângeri short-selling, costuri de tranzacționare. Greșeala se poate agrava pe termen scurt.
3. VIX-ul este la 45. Ce indică despre sentimentul pieței?
R: Frică extremă pe piață ($VIX > 30$). Istoric, niveluri extreme VIX au fost urmate de randamente pozitive pe termen mediu (contrarian signal).
4. Care este diferența dintre suprareacție și subreacție?
R: Suprareacție: prețul depășește valoarea justă, apoi revine (De Bondt & Thaler). Subreacție: prețul se ajustează prea lent, derivă continuă (PEAD).

Ipoteza Pieței Adaptive (Adaptive Markets Hypothesis, Lo 2004)

Ideea centrală

- Eficiența pieței nu este o proprietate statică, ci o **dinamică evolutivă** condusă de forțe evoluționiste: competiție, adaptare, selecție naturală.
- **Principii cheie:**
 - Investitorii nu sunt nici pe deplin raționali, nici pe deplin iraționali — ei se **adaptează**
 - Ecologia pieței: specii (fonduri hedge, retail, HFT) concurează pentru resurse (alpha)
 - Oportunitățile de profit apar și dispar pe măsură ce strategiile devin aglomerate
 - Primele de risc variază în timp cu condițiile pieței
- **Predictii:**
 - Eficiența variază între piețe și perioade de timp
 - Anomaliile apar, atrag capital, apoi scad
 - Crizele creează noi ineficiențe (frică, vânzări forțate)
 - Perioadele de recuperare restabilesc eficiența
 - EMH este un **caz limită** al AMH când ecologia pieței este stabilă

EMH vs. AMH: o comparație (A Comparison)

Dimensiune	EMH (Fama)	AMH (Lo)
Raționalitatea investitorului	Pe deplin rațional	Raționalitate limitată, adaptiv
Eficiența pieței	Constantă	Variabilă în timp, dinamică
Prime de risc	Constante sau variind lent	Fluctuează cu ecologia pieței
Anomalii	Artefacte statistice sau risc	Reale dar tranzitorii
Crize	Răspuns rațional la știri	Perturbări ecologice
Strategie de investiții	Pasivă (fonduri index)	Adaptivă, dependentă de regim
Bază teoretică	Economia neoclasică	Biologia evoluționistă

Implicație practică

- Sub AMH, strategia optimă este **adaptivă**: pasivă în perioade calme, activă în timpul crizelor când ineficiențele sunt cele mai mari.


Exponentul Hurst (Hurst Exponent as Efficiency Measure)

Analiza R/S (Rescaled Range)

- ▣ Pentru o subserie de lungime n , se calculează: $R(n) = \max_{1 \leq k \leq n} S_k - \min_{1 \leq k \leq n} S_k$, unde $S_k = \sum_{i=1}^k (r_i - \bar{r})$ sunt sumele parțiale centrate
 - ▣ Se normalizează: $(R/S)(n) = R(n)/\hat{\sigma}(n)$
 - ▣ Relația asimptotică: $(R/S)(n) \sim c \cdot n^H$ pe măsură ce $n \rightarrow \infty$
 - ▣ H se estimează din panta regresiei: $\log(R/S) = H \cdot \log(n) + \text{const.}$
-
- ▣ $H = 0,5$: mers aleator (eficient)
 - ▣ $H > 0,5$: persistență (trend, momentum)
 - ▣ $H < 0,5$: anti-persistență (reversie la medie)
-
- ▣ Valori tipice pentru randamente zilnice:
 - ▣ S&P 500: $H \approx 0,52$
 - ▣ BTC-USD: $H \approx 0,55$ (mai persistent)
 - ▣ BET: $H \approx 0,58$ (cel mai puțin eficient)

SFM_ch3_hurst_exponent

Exponentul Hurst rolling (Rolling Hurst: AMH Evidence)



- Observație cheie
 - ▶ $\hat{H}$ oscilează în jur de 0,5
 - ▶ Crește la 0,6–0,7 în crize
- Pattern temporal
 - ▶ Dotcom, GFC, COVID, 2022 inflație
 - ▶ Crizele $\Rightarrow$ ineficiență temporară
- Implicație AMH
 - ▶ Eficiența este dinamică
 - ▶ Se restabilește între crize
 - ▶ Lo (2004): “markets adapt”

Python: Estimarea exponentului Hurst (analiza R/S)

```
import numpy as np, yfinance as yf

def hurst_rs(returns, min_n=20, max_n=None):
    T = len(returns)
    max_n = max_n or T // 4
    ns, rs_vals = [], []
    for n in range(min_n, max_n + 1, 10):
        rs_list = []
        for start in range(0, T - n, n):
            chunk = returns[start:start+n]
            cumdev = np.cumsum(chunk - chunk.mean())
            R = cumdev.max() - cumdev.min()
            S = chunk.std(ddof=1)
            if S > 0: rs_list.append(R / S)
        if rs_list:
            ns.append(n); rs_vals.append(np.mean(rs_list))
    H = np.polyfit(np.log(ns), np.log(rs_vals), 1)[0]
    return H

sp = yf.download("^GSPC", start="2000-01-01", end="2025-01-01")
ret = np.log(sp["Close"] / sp["Close"].shift(1)).dropna().values
print(f"Hurst S&P 500: H = {hurst_rs(ret):.3f}")
```

AMH: Evidență empirică (Empirical Evidence)

Sharpe ratios variabile în timp

- ▣ Strategiile de momentum generează Sharpe ratio > 1 în 1990–2000, dar < 0 în 2007–2009
- ▣ Valoarea: subperformanță 2010–2020, revenire 2021–2023
- ▣ **Nicio strategie nu domină permanent** — consistent cu selecția naturală a strategiilor (AMH)
- ▣ Kim, Shamsuddin & Lim (2011): VR variabil demonstrează cicluri de eficiență pe 16 piețe

Strategii dependente de regim

- ▣ **Regim calm:** volatilitate scăzută, eficiență ridicată $\Rightarrow$ strategia pasivă domină
- ▣ **Regim de criză:** volatilitate ridicată, autocorelații mari $\Rightarrow$ strategii active pot genera alpha
- ▣ Keim & Madhavan (1998): costurile de implementare variază cu regimul
- ▣ Implementare: modele Markov-switching cu 2–3 stări (Hamilton, 1989)

AMH: Implicații pentru investiții (Investment Implications)

Strategie adaptivă pasiv/activ

- ▣ **Regim normal:** alocație pasivă (Exchange-Traded Fund, ETF, index, costuri minime)
- ▣ **Regim de stres:** rotire spre strategii active (momentum, carry, value) care exploatează ineficiențele temporare
- ▣ **Indicator de comutare:** $|VR(5) - 1|$ pe fereastră mobilă de 252 zile
- ▣ Dacă $|VR - 1| > 0,15$: activați strategiile de trading

Adaptare Risk Parity

- ▣ Risk Parity clasic: ponderile $\propto 1/\sigma_i$
- ▣ **Risk Parity adaptiv:** ajustează ponderile pe baza regimului de eficiență
- ▣ În crize: reduce expunerea la active ineficiente (risc de momentum crash)
- ▣ Post-criză: crește expunerea la active care revin la eficiență (oportunitate de convergență)
- ▣ Lo (2012): fondurile hedge performante se adaptează, nu urmează reguli fixe

AMH vs Ipoteza Pieței Fractale (Fractal Market Hypothesis)

Ipoteza Pieței Fractale (FMH)

- Mandelbrot (1963, 1997): piețele au structură **fractală** (auto-similară)
- Randamentele nu sunt i.i.d. — prezintă memorie lungă ($H \neq 0,5$)
- Lichiditatea asigurată de diversitatea orizonturilor investitorilor (zilnic, lunar, anual)
- Crize: orizonturile se aliniază $\Rightarrow$ lichiditate dispare $\Rightarrow$ crash

Modele multi-fractale (MMAR)

- Mandelbrot, Fisher & Calvet (1997): Multifractal Model of Asset Returns
- Exponentul Hurst variază cu scara temporală
- Spectrul multi-fractal $f(\alpha)$ descrie heterogenitatea scalării
- Avantaj: captează simultan cozi groase, clusterizare volatilitate, memorie lungă

Dimensiune	AMH (Lo)	FMH (Mandelbrot)
Bază	Biologie evoluționistă	Geometrie fractală
Mecanism	Adaptare, selecție	Auto-similaritate, scalare
Eficiența	Variabilă, ciclică	Aparentă (artefact al agregării)
Crize	Perturbări ecologice	Alinierea orizonturilor

Ecologia pieței (Market Ecology)

Analogia speciilor financiare (Lo, 2017)

- ▣ Piața financiară este un **ecosistem** cu specii (tipuri de investitori) care concurează pentru resurse (alpha)

Specie	Strategie
Investitori index	Pasivi, buy & hold
Value investors	Fundamentală, contrarian
Momentum traders	Trend-following
HFT	Microstructură, latență
Market makers	Bid-ask spread
Hedge funds	Arbitraj, multi-strategie
Retail	Sentiment, comportamental

- ▣ **Impactul HFT (High-Frequency Trading):**
- ▣ Cresc eficiența prețurilor pe milisecunde
- ▣ Reduc spread-urile bid-ask
- ▣ Dar: „Flash crashes” (6 mai 2010)
- ▣ **Dark pools:**
- ▣ Execuție anonimă, fragmentare lichiditate
- ▣ Pot întârzia descoperirea prețului ⇒ reduce eficiența temporar
- ▣ Reglementare: MiFID II, Reg NMS

Python: Backtest tranzacționare tehnică (Technical Trading)

```
import yfinance as yf, numpy as np, pandas as pd

sp = yf.download("^GSPC", start="2010-01-01", end="2025-01-01")
prices = sp["Close"]
ret = np.log(prices / prices.shift(1))

# Strategie MA crossover: MA(50) vs MA(200)
ma_short = prices.rolling(50).mean()
ma_long = prices.rolling(200).mean()
signal = (ma_short > ma_long).astype(int).shift(1) # 1=long

# Randamente strategie vs buy-and-hold
ret_strat = signal * ret
ret_bh = ret

# Performanta cumulata
cum_strat = np.exp(ret_strat.cumsum()).iloc[-1]
cum_bh = np.exp(ret_bh.cumsum()).iloc[-1]
sr_strat = ret_strat.mean() / ret_strat.std() * np.sqrt(252)
sr_bh = ret_bh.mean() / ret_bh.std() * np.sqrt(252)

print(f"Buy-and-Hold: cumul={cum_bh:.2f}, SR={sr_bh:.2f}")
print(f"MA Crossover: cumul={cum_strat:.2f}, SR={sr_strat:.2f}")
# Rezultat tipic: MA crossover subperformeaza dupa costuri
```

Python: Analiză sentiment (Sentiment Analysis)

```
import yfinance as yf, numpy as np, pandas as pd

# Descarca VIX si S&P 500
vix = yf.download("^VIX", start="2010-01-01", end="2025-01-01")["Close"]
sp = yf.download("^GSPC", start="2010-01-01", end="2025-01-01")["Close"]
ret = np.log(sp / sp.shift(1))

# Randament mediu viitor (20 zile) in functie de nivelul VIX
df = pd.DataFrame({"VIX": vix, "Ret_20d": ret.rolling(20).mean().shift(-20)})
df = df.dropna()

# Categorii VIX
df["Regim"] = pd.cut(df["VIX"], bins=[0, 15, 25, 40, 100],
                     labels=["Calm", "Normal", "Stres", "Criza"])
print(df.groupby("Regim")["Ret_20d"].agg(["mean", "std", "count"]))
# Rezultat: randamentele viitoare mai mari dupa VIX ridicat
# Calm: mean~0.03%, Normal: ~0.04%, Stres: ~0.06%, Criza: ~0.10%
# => VIX ridicat prezice randamente pozitive (contrarian)
```

Python: Eficiență mobilă cross-asset (Rolling Efficiency)


```
import yfinance as yf, numpy as np, pandas as pd

tickers = {"S&P_500": "^GSPC", "BTC": "BTC-USD",
           "Gold": "GC=F",      "BET": "^BETI"}
window = 500

def rolling_vr(ret, q=5, w=500):
    vr = []
    for i in range(w, len(ret)):
        r = ret.iloc[i-w:i].values
        var1 = np.var(r, ddof=1)
        rq = np.array([r[j:j+q].sum() for j in range(len(r)-q+1)])
        varq = np.var(rq, ddof=1)
        vr.append(varq / (q * var1) if var1 > 0 else np.nan)
    return pd.Series(vr, index=ret.index[w:])


for name, tk in tickers.items():
    data = yf.download(tk, start="2015-01-01", end="2025-01-01")
    ret = np.log(data["Close"] / data["Close"].shift(1)).dropna()
    vr = rolling_vr(ret)
    ineff = np.abs(vr - 1).mean()
    print(f"{name:10s}: |VR-1| mediu={ineff:.4f}")
```

Compararea eficienței pe piețe (Cross-Market Comparison)



- Indicatori de eficiență (VR, Hurst, autocorelație) comparați pentru S&P 500, FTSE 100, BET, BTC-USD
- Piețele dezvoltate sunt mai apropiate de eficiența în formă slabă (weak-form)
- Piețele emergente prezintă deviații semnificative, mai ales la orizonturi lungi

Studiu de caz: S&P 500 (Comprehensive Analysis)



Test	Statistică	p-value	Verdict
Ljung-Box Q(10)	18,7	0,044	Marginal semnificativ
Test runs	$Z = -1,82$	0,069	Non-respingere
VR(5) Lo-MacKinlay	$Z = 1,34$	0,181	Non-respingere
ADF (prețuri)	$\tau = -1,23$	0,660	Rădăcină unitară
KPSS (randamente)	$\eta = 0,12$	$> 0,10$	Staționare
Hurst	$H = 0,52$	—	Aproape eficient

□ **Concluzie:** S&P 500 este aproximativ eficient în formă slabă (weak-form). Deviații mici, economic nesemnificative.

Studiu de caz: Bitcoin (Bitcoin Efficiency)

Rezultate BTC-USD (2015–2025)

- ▣ $\hat{\rho}_1 = 0,01$ (nesemnificativ)
- ▣ Ljung–Box $Q(10) = 12,3$ ($p = 0,26$)
- ▣ $VR(2) = 1,02$, $VR(10) = 0,94$
- ▣ Hurst: $H \approx 0,55$
- ▣ ADF (prețuri): $\tau = -1,8$ (rădăcină unitară)

Evoluția eficienței 2015–2024

- ▣ **2015–2017**: piață tânără, $|VR - 1|$ mare, autocorelație semnificativă $\Rightarrow$ **ineficient**
- ▣ **2018–2020**: creșterea lichidității, futures CME $\Rightarrow$ eficiență crescândă
- ▣ **2021–2024**: ETF-uri BTC spot, instituționalizare $\Rightarrow$ **aproape eficient**
- ▣ Consistentă cu AMH: piața se maturizează

Idee cheie

- ▣ Bitcoin ilustrează **traectoria către eficiență**: pe măsură ce participanții cresc și lichiditatea se îmbunătățește, piața devine progresiv mai eficientă.

Studiu de caz: BVB/BET (Bucharest Stock Exchange)

Rezultate BET (2005–2025)

- ▣ $\hat{\rho}_1 = 0,11$ (semnificativ la 1%)
- ▣ $VR(5) = 1,18$ (impuls puternic)
- ▣ Hurst: $H \approx 0,58$ (persistență)
- ▣ Eficiența slabă este respinsă
- ▣ Cauze: lichiditate redusă (~ 10 mil EUR/zi vs. mld pe NYSE — *New York Stock Exchange*)

Comparație cu piețe dezvoltate

- ▣ BET: $|\hat{\rho}_1| \approx 5\times$ mai mare decât S&P 500
- ▣ Spread bid-ask: $\sim 1\text{--}2\%$ vs. $\sim 0,01\%$ pe piețe lichide
- ▣ Tranzacționare nesincronă: unele acțiuni BET nu se tranzacționează zilnic
- ▣ **Implicații pentru investitori români:**
- ▣ Strategii de momentum pot fi profitabile (după costuri ridicate)
- ▣ Diversificarea internațională este esențială

Studiu de caz: Aurul ca refugiu (Gold Safe Haven)

Proprietăți ale randamentelor aurului

- ▣ Randament mediu anual: $\sim 7\%$ (2000–2025)
- ▣ Volatilitate: $\sim 16\%$ (comparabilă cu acțiunile)
- ▣ Corelație cu S&P 500: $\sim 0,02$ (aproape zero)
- ▣ Corelație în crize: $\sim -0,15$ (refugiu)
- ▣ Distribuție: cozi moderate, ușoară asimetrie pozitivă

Teste de eficiență


- ▣ $\hat{\rho}_1 \approx -0,02$ (nesemnificativ)
- ▣ $VR(5) = 0,97$ (ușoară reversie)
- ▣ Hurst: $H \approx 0,50$ (aproape eficient)
- ▣ **Concluzie:** piața aurului este surprinzător de eficientă — consistent cu lichiditatea ridicată și participanții sofisticati
- ▣ Rolul de refugiu apare prin **corelația condiționată**, nu prin predictibilitate

Clasamentul eficienței cross-asset (Cross-Asset Ranking)

Piață	$ \hat{\rho}_1 $	$ VR(5) - 1 $	H	$Q(10) p$	Scor ef.	Clasament
S&P 500	0,02	0,04	0,52	0,044	0,92	1 (cel mai eficient)
FTSE 100	0,03	0,01	0,51	0,121	0,90	2
Aur (GC)	0,02	0,03	0,50	0,312	0,88	3
EUR/USD	0,01	0,02	0,51	0,405	0,87	4
BTC-USD	0,01	0,06	0,55	0,260	0,72	5
WIG (Polonia)	0,06	0,08	0,54	0,008	0,61	6
BET (România)	0,11	0,18	0,58	<0,001	0,38	7 (cel mai puțin eficient)

- ▣ **Scor de eficiență:** media normalizată a indicatorilor (1 = perfect eficient)
- ▣ **Tipar general:** eficiența crește cu lichiditatea, numărul de participanți și sofisticarea pieței
- ▣ Piețele FX și aur sunt surprinzător de eficiente datorită volumului enorm de tranzacționare

Studiu de eveniment: Rezultate AAPL (ticker Apple Inc., Event Study)



Eveniment

- ▶ Anunțuri trimestriale câștiguri Apple (2015–2024, $N = 40$)
- ▶ Model: $R_{AAPL,t} = \alpha + \beta R_{m,t} + \varepsilon_t$


Rezultate

- ▶ $\overline{CAR}(-1, +1) = 2,8\%$ ($t = 4,2$, semnificativ)
- ▶ $\overline{CAR}(+2, +10) = 0,4\%$ ($t = 0,9$, ne semn.)

Interpretare

- ▶ Ajustare rapidă, drift post-anunț neglijabil
- ▶ AAPL este eficient semi-tare

Eficiență variabilă în timp: Evidență (Time-Varying)



- **VR mobil** (500 zile, $q = 5$)
 - ▶ $|VR - 1|$ crește în crize (2008, 2020)
 - ▶ Scade în perioade calme
- **Hurst mobil** (500 zile)
 - ▶ H crește de la $\sim 0,50$ la $\sim 0,60$ în stres
- **Implicație**
 - ▶ Eficiența nu e constantă
 - ▶ Piața oscilează $\Rightarrow$ AMH

Eficiență și microstructura pieței (Market Microstructure)

Bid-ask bounce

- ▣ Prețurile oscilează între bid și ask $\Rightarrow$ autocorelație negativă artificială la frecvențe înalte
- ▣ Roll (1984): $\text{spread} = 2\sqrt{-\text{Cov}(r_t, r_{t-1})}$
- ▣ Aceasta nu este ineficiență, ci un artefact de microstructură

Tranzacționare nesincronă

- ▣ Activele dintr-un index nu se tranzacționează simultan
- ▣ Prețul de închidere reflectă ultima tranzacție (poate fi la 14:30)
- ▣ Creează autocorelație pozitivă artificială în indicele bursier (Lo & MacKinlay, 1990)

Efectul Epps (1979)

- ▣ Corelația între active **scade** cu frecvența datelor
- ▣ La 1 min: corelații mult mai mici decât la date zilnice
- ▣ Cauze: tranzacționare nesincronă, microstructură diferită

Lecție

- ▣ Înainte de a concluziona „ineficiență”, eliminați artefactele: bid-ask bounce, nonsynchronous trading, overnight gaps.

Exercițiu 1: Testul Ljung–Box (Exercise 1)

Problemă

Se dau autocorelațiile eșantion ale randamentelor zilnice ale unui activ, cu $T = 1000$ observații:

k	1	2	3	4	5
$\hat{\rho}_k$	0,08	-0,03	0,05	-0,01	0,04

1. Calculați statistica Ljung–Box $Q(5)$
2. La nivelul de semnificație $\alpha = 5\%$, testați dacă randamentele prezintă autocorelație semnificativă ($\chi^2_{0,05}(5) = 11,07$)
3. Ce implicație are rezultatul pentru eficiența în formă slabă (weak-form)?

 SFM_ch4_af_sp500

Exercițiu 1: Rezolvare

Rezolvare

Pasul 1: $Q(5) = T(T+2) \sum_{k=1}^5 \frac{\hat{\rho}_k^2}{T-k}$

$$\begin{aligned} Q(5) &= 1000 \times 1002 \times \left[\frac{0,08^2}{999} + \frac{0,03^2}{998} + \frac{0,05^2}{997} + \frac{0,01^2}{996} + \frac{0,04^2}{995} \right] \\ &= 1002000 \times [6,407 \times 10^{-6} + 9,018 \times 10^{-7} + 2,508 \times 10^{-6} + 1,004 \times 10^{-7} + 1,608 \times 10^{-6}] \\ &= 1002000 \times 1,152 \times 10^{-5} = 11,54 \end{aligned}$$

Pasul 2: $Q(5) = 11,54 > \chi_{0,05}^2(5) = 11,07 \Rightarrow$ **Se respinge H_0** la 5% (marginal)

Pasul 3: Autocorelația este statistic semnificativă, dar dominată de $\hat{\rho}_1 = 0,08$. Economic: un trader ar obține profit brut $\approx 0,08\%$ pe zi din exploatarea acestei autocorelații — sub costurile de tranzacționare tipice ($\sim 0,1\%$). Eficiența slabă este aproximativ validă.

Exercițiu 2: Variance Ratio (Exercise 2)

Problemă

Un cercetător calculează varianța randamentelor zilnice și săptămânale ale unui indice bursier:

- ▣ Varianța randamentelor zilnice: $\hat{\sigma}_1^2 = 0,0001$ ($= 0,01\%$)
- ▣ Varianța randamentelor pe 5 zile (săptămânale): $\hat{\sigma}_5^2 = 0,00065$

1. Calculați $VR(5)$
2. Interpretați rezultatul: autocorelație pozitivă sau negativă?
3. Dacă $T = 2000$ și $\phi(5) = 0,0027$ (varianța asimptotică), calculați $Z(5)$ și testați H_0 : mers aleator la nivelul 5% ($z_{0,025} = 1,96$)

Exercițiu 2: Rezolvare

Rezolvare

$$1. VR(5) = \frac{\hat{\sigma}_5^2}{5 \times \hat{\sigma}_1^2} = \frac{0,00065}{5 \times 0,0001} = \frac{0,00065}{0,0005} = 1,30$$

$$2. VR(5) = 1,30 > 1 \Rightarrow \text{autocorelație pozitivă (impuls/momentum)}$$

Varianța pe 5 zile este mai mare decât 5 ori varianța zilnică, ceea ce înseamnă că randamentele pozitive tind să fie urmate de randamente pozitive (și negativ de negativ).

$$3. Z(5) = \frac{VR(5)-1}{\sqrt{\phi(5)}} = \frac{1,30-1}{\sqrt{0,0027}} = \frac{0,30}{0,052} = 5,77$$

$$|Z(5)| = 5,77 > 1,96 \Rightarrow \text{Se respinge } H_0 \text{ (mersul aleator) la nivelul 5\%}.$$

Concluzie: piața prezintă un efect de impuls semnificativ pe orizontul săptămânal.

Exercițiu 3: Event Study (Exercise 3: AR and CAR)

Problemă

O companie anunță câștiguri peste așteptări în ziua $t = 0$. Modelul de piață estimat este $\hat{R}_{i,t} = 0,001 + 1,2 \cdot R_{m,t}$. Randamentele observate sunt:

Ziua t	-2	-1	0	+1	+2	+3
$R_{i,t}$ (%)	0,5	0,3	3,8	1,2	0,4	0,1
$R_{m,t}$ (%)	0,2	0,1	0,5	0,3	0,2	0,0

1. Calculați $AR_{i,t}$ pentru fiecare zi
2. Calculați $CAR_i(-2, +3)$
3. Piața este eficient semi-tare? Argumentați.

Exercițiu 3: Rezolvare

Rezolvare

$$1. AR_{i,t} = R_{i,t} - (0,001 + 1,2 \cdot R_{m,t})$$

t	-2	-1	0	+1	+2	+3
$\hat{R}_{i,t} (\%)$	0,34	0,22	0,70	0,46	0,34	0,10
$AR_{i,t} (\%)$	0,16	0,08	3,10	0,74	0,06	0,00

$$2. CAR_i(-2, +3) = 0,16 + 0,08 + 3,10 + 0,74 + 0,06 + 0,00 = 4,14\%$$

3. Dacă piața ar fi eficient semi-tare, **tot** AR-ul s-ar concentra în ziua 0. Observăm $AR_{+1} = 0,74\%$ — derivă post-anunț. Aceasta sugerează subreacție (PEAD), inconsistentă cu EMH semi-tare. Totuși, pentru o concluzie robustă, este necesar un eșantion de N evenimente.

Exercițiu AI: Testarea EMH (AI Exercise: Testing EMH)

Prompt de testat în ChatGPT / Claude / Copilot

“Descarcă datele zilnice pentru indicele BET (România) și S&P 500 din 2010 până în 2025 folosind Python (yfinance). Calculează log-randamentele. Testează eficiența în formă slabă (weak-form) folosind: (1) autocorelație + Ljung-Box, (2) testul variance ratio Lo-MacKinlay pentru $q = 2, 5, 10, 20$, (3) exponentul Hurst prin analiza R/S. Compară cele două piețe. Calculează variance ratio mobil pe o fereastră mobilă de 500 de zile.”

Verificări ale output-ului:

1. AI-ul folosește log-randamente $r_t = \ln(P_t/P_{t-1})$, nu randamente simple?
2. Statistica Q Ljung-Box este calculată corect cu factorul $(T + 2)$?
3. Variance ratio-ul folosește formula $VR(q) = \hat{\sigma}_q^2 / (q \cdot \hat{\sigma}_1^2)$?
4. Exponentul Hurst estimat este plauzibil ($H \in [0,4, 0,7]$)?
5. Variance ratio mobil folosește fereastră mobilă, nu fereastră fixă?
6. Interpretarea este corectă ($VR > 1 = \text{impuls}$, $VR < 1 = \text{reversie}$)?

☐ **Atenție:** AI-ul confundă adesea variance ratio cu *ratio of variances* (raport simplu de varianțe). Verificați dacă se normalizează cu q . De asemenea, poate folosi ticker-ul greșit pentru BET (corect: ^BETI sau date din surse alternative).

Exercițiul 4: Testul ADF (Exercise 4: ADF Test)

Problemă

Un cercetător aplică testul ADF pe prețurile de închidere și log-randamentele unui indice bursier ($T = 2000$, lag selectat cu BIC: $p = 3$). Rezultatele sunt:

Serie	ADF stat	Val. critică 5%	p -value
Prețuri (cu trend)	-2,15	-3,41	0,52
Prețuri (fără trend)	-1,87	-2,86	0,34
Log-randamente	-42,3	-2,86	< 0,001

1. Pentru fiecare serie, stabiliți dacă se respinge H_0 (rădăcină unitară) la 5%.
2. Ce semnifică rezultatul pentru modelul de mers aleator?
3. De ce testăm prețurile cu și fără trend? Când este adecvat fiecare?

Exercițiul 4: Rezolvare

Rezolvare

1. Comparăm statistica ADF cu valoarea critică la 5%:

Serie	ADF	Val. critică	ADF < Crit?	Decizie
Prețuri (cu trend)	-2,15	-3,41	Nu	Non-respingere H_0
Prețuri (fără trend)	-1,87	-2,86	Nu	Non-respingere H_0
Log-randamente	-42,3	-2,86	Da	Respingere H_0

2. Prețurile au rădăcină unitară $I(1)$ — consistent cu mersul aleator. Randamentele sunt staționare $I(0)$ — diferențierea elimină rădăcina unitară. Aceasta confirmă modelul: $P_t = P_{t-1} + \varepsilon_t$.

3. Modelul cu trend include βt și testează trend deterministic + rădăcină unitară. Se folosește când seria pare să aibă un trend vizual. Modelul fără trend este adecvat pentru serii fără trend aparent. Pentru prețuri financiare cu trend ascendent pe termen lung, se preferă modelul cu trend.

Exercițiul 5: Profitabilitatea regulii de filtrare (Filter Rule)

Problemă

Se dau randamentele zilnice ale unei acțiuni pe 10 zile consecutive (%):

Ziua	1	2	3	4	5	6	7	8	9	10
r_t (%)	0,5	0,8	-0,3	-1,2	-0,5	0,3	1,1	0,6	-0,4	0,2

1. Aplicați o **regulă de filtrare de 1%**: cumpărați când randamentul cumulat de la un minim depășește 1%, vindeți când randamentul cumulat de la un maxim scade sub -1%. Care este profitul strategiei (ignorând costurile)?
2. Calculați randamentul **buy-and-hold** pe aceleași 10 zile.
3. Dacă costurile de tranzacționare sunt 0,2% per tranzacție (cumpărare + vânzare), este strategia de filtrare profitabilă?

Exercițiul 5: Rezolvare

Rezolvare

1. Randamentele cumulate: $c_1 = 0,5$; $c_2 = 1,3$; $c_3 = 1,0$; $c_4 = -0,2$; $c_5 = -0,7$; $c_6 = -0,4$; $c_7 = 0,7$; $c_8 = 1,3$; $c_9 = 0,9$; $c_{10} = 1,1$

Regula filtrului 1%: pornim din afara pieței. Randamentul cumulat depășește 1% la ziua 2 ($c_2 = 1,3\%$) $\Rightarrow$ **cumpărare** la sfârșitul zilei 2. Minimul local ulterior la ziua 5 ($c_5 = -0,7\%$). De la maxim ($c_2 = 1,3$), scăderea $= 1,3 - (-0,7) = 2,0\% > 1\% \Rightarrow$ **vânzare** la ziua 5. Randamentul tranzacției: $c_5 - c_2 = -0,7 - 1,3 = -2,0\%$. Apoi cumpărare la ziua 8 ($c_8 = 1,3$, crește cu $> 1\%$ de la minim). Profitul strategiei $\approx -2,0 + (1,1 - 1,3) = -2,2\%$ (simplificat).

2. Buy-and-hold: $\sum r_t = 0,5 + 0,8 - 0,3 - 1,2 - 0,5 + 0,3 + 1,1 + 0,6 - 0,4 + 0,2 = 1,1\%$

3. Cu 3 tranzacții (cump.+vânz.), costul $= 3 \times 2 \times 0,2\% = 1,2\%$. Profitul net strategiei $\approx -2,2 - 1,2 = -3,4\%$ vs. buy-and-hold 1,1%. Strategia de filtrare este **neprofitabilă** — consistent cu EMH.

Exercițiul 6: Exponentul Hurst (Exercise 6: Hurst)

Problemă

Un analist estimează exponentul Hurst prin analiza R/S pentru patru piețe financiare:

Piață	Exponent Hurst H	Interval de încredere 95%
S&P 500	0,52	[0,49; 0,55]
BET (România)	0,58	[0,54; 0,62]
BTC-USD	0,55	[0,51; 0,59]
EUR/USD	0,50	[0,47; 0,53]

1. Clasificați fiecare piață: mers aleator, persistentă, sau anti-persistentă.
2. Realizați clasamentul de la cea mai eficientă la cea mai puțin eficientă piață.
3. Pentru care piețe intervalul de încredere include $H = 0,5$? Ce implică acest lucru?
4. Ce factori pot explica diferențele între piețe?

Exercițiul 6: Rezolvare

Rezolvare

1. Clasificare:

- ▣ S&P 500: $H = 0,52 > 0,5 \Rightarrow$ **ușor persistentă** (impuls slab)
- ▣ BET: $H = 0,58 > 0,5 \Rightarrow$ **persistentă** (trend/momentum semnificativ)
- ▣ BTC-USD: $H = 0,55 > 0,5 \Rightarrow$ **moderaat persistentă**
- ▣ EUR/USD: $H = 0,50 \Rightarrow$ **mers aleator** (eficient)

2. Clasament eficiență: EUR/USD ($H = 0,50$) > S&P 500 (0,52) > BTC (0,55) > BET (0,58)

3. EUR/USD: $[0,47; 0,53]$ include 0,5 $\Rightarrow$ **nu se poate respinge** $H = 0,5$ (eficient). S&P 500: $[0,49; 0,55]$ include 0,5 $\Rightarrow$ marginal eficient. BET: $[0,54; 0,62]$ **nu include** 0,5 $\Rightarrow$ semnificativ ineficient.

4. Factori: lichiditate (FX > acțiuni > piețe emergente), număr de participanți, costuri de tranzacționare, maturitatea pieței, calitatea reglementării.

Exercițiul 7: Interpretarea studiului de eveniment (Event Study)

Problemă

Se efectuează un studiu de eveniment pe $N = 30$ anunțuri de fuziuni. Rezultatele CAR sunt:

Fereastră	$\overline{CAR}$ (%)	$\hat{\sigma}_{CAR}$ (%)	t -stat
$(-1, +1)$	5,2	8,4	3,39
$(+2, +10)$	1,8	6,1	1,62
$(+2, +30)$	3,1	9,5	1,79

1. La nivelul 5% ($t_{crit} = 2,045$ pentru 29 grade de libertate), care CAR sunt semnificativ diferite de zero?
2. Interpretați: piața reacționează **imediat și complet**?
3. Ce formă de EMH este contestată dacă $CAR(+2, +30)$ este semnificativ pozitiv? De ce?

Exercițiul 7: Rezolvare

Rezolvare

1. Comparăm $|t|$ cu $t_{crit} = 2,045$:

Fereastră	t -stat	$ t > 2,045?$	Decizie
$(-1, +1)$	3,39	Da	Semnificativ ($p < 0,01$)
$(+2, +10)$	1,62	Nu	Non-semnificativ
$(+2, +30)$	1,79	Nu	Non-semnificativ (marginal la 10%)

2. Doar $CAR(-1, +1) = 5,2\%$ este semnificativ — piața reacționează puternic la anunțul de fuziune. $CAR(+2, +10)$ și $CAR(+2, +30)$ nu sunt semnificative la 5%, ceea ce sugerează o ajustare aproximativ completă. Totuși, $CAR(+2, +30) = 3,1\%$ cu $t = 1,79$ este marginal — indiciu de derivă post-eveniment.

3. Dacă $CAR(+2, +30)$ ar fi semnificativ, ar contesta **EMH semi-tare**: informația publică (anunțul de fuziune) nu este absorbită complet în ziua evenimentului, prețul continuă să derive $\Rightarrow$ subreacție.

Exercițiu AI 2: Finanțe comportamentale (Behavioral Finance)

Prompt de testat în ChatGPT / Claude / Copilot

“Folosind Python, descarcă prețurile zilnice pentru 50 de acțiuni din S&P 500 pe perioada 2015–2024. Simulează un portofoliu care implementează **efectul de dispoziție**: vinde automat orice acțiune cu câștig $> 10\%$ și păstrează acțiunile cu pierdere. Compară randamentul acestui portofoliu cu o strategie buy-and-hold. Calculează Proportion of Gains Realized (PGR) și Proportion of Losses Realized (PLR). Testează dacă $PGR > PLR$ semnificativ (test t).”

Verificări ale output-ului:

1. AI-ul simulează corect regulile de vânzare/păstrare pe baza punctului de referință (prețul de cumpărare)?
2. PGR și PLR sunt calculate corect ca fracțiuni (nu valori absolute)?
3. Costurile de tranzacționare sunt incluse la fiecare vânzare?
4. Rezultatul arată că portofoliul cu efect de dispoziție subperformează buy-and-hold?
5. Testul t este aplicat corect (eșantioane pereche sau nepereche)?

Quiz comprehensiv EMH (Comprehensive EMH Quiz)

6 întrebări — toate formele EMH

1. Ce formă de EMH respinge analiza tehnică (medii mobile, tipare grafice)?

R: Forma slabă (Weak-Form) — dacă prețurile istorice sunt reflectate, analiza tehnică nu generează alpha.

2. Un insider corporativ cumpără acțiuni și obține 8% peste piață. Ce formă contestă?

R: Forma tare (Strong-Form) — informația privată nu este reflectată complet în preț.

3. PEAD (deriva post-anunț) contestă ce formă de EMH?

R: Forma semi-tare (Semi-Strong) — informația publică (câștiguri) nu este absorbită imediat.

4. $VR(5) = 1,25$. Ce semnifică?

R: Autocorelație pozitivă (momentum/impuls). Varianța pe 5 zile este 25% mai mare decât $5 \times$ varianța zilnică.

5. Care este diferența fundamentală între EMH și AMH?

R: EMH: eficiența este constantă. AMH: eficiența variază în timp, condusă de forțe evoluționiste.

6. Ce este paradoxul Grossman–Stiglitz?

R: Piețele perfect eficiente sunt imposibile: dacă nu există profit din analiza informației, nimeni nu va investi în cercetare, dar atunci prețurile nu pot fi informative.

Rezumat: starea actuală (Current State of EMH)

Ce susțin evidențele

- ▣ Majoritatea fondurilor gestionate activ **subperformează** indicii pasivi
- ▣ Multe anomalii **scad** după publicare
- ▣ Predicția prețurilor pe termen scurt este extrem de dificilă
- ▣ Costurile de tranzacționare elimină majoritatea profiturilor din trading

Ce contestă EMH

- ▣ Efectele de momentum și valoare persistă
- ▣ PEAD este robustă pe diverse piețe
- ▣ Insider trading-ul este profitabil
- ▣ Bulele și prăbușirile apar periodic
- ▣ Eficiența pieței variază în timp

Concluzie practică

- ▣ Piețele sunt „eficient ineficiente” (Pedersen, 2015)
 - ▶ Suficient de eficiente încât majoritatea nu le pot bate
 - ▶ Cu suficiente fricțiuni pentru a recompensa investitorii sofisticati

Sinteza testelor empirice (Synthesis of Empirical Tests)

Forma EMH	Test	Rezultat tipic	Verdict
Slabă	Autocorelație	$\hat{\rho}_1 \approx 0,02-0,05$	Marginal
	Ljung-Box	Respingere ușoară	Statistic da, economic nu
	Variance ratio	$VR(2) \approx 1,05$	Impuls slab
	Hurst	$H \approx 0,52$	Aproape eficient
Semi-tare	PEAD Anomalii calend.	$CAR \neq 0$ post-eveniment Slăbite post-publicare	Subreacție sistematică Consistent cu EMH
Tare	Insider trading Fonduri mutuale	Profituri anormale 5-8% 92% subperformează	Respinsă Consistentă

Mesaj principal

- EMH nu e totul-sau-nimic, ci un **spectru**
 - ▶ Piețele dezvoltate: mai aproape de eficiență
 - ▶ Piețele emergente: deviații mai mari

Implicații practice (Practical Implications)

Dacă credeți în EMH

- ▣ Investiți pasiv (fonduri index, ETF-uri)
- ▣ Minimizați costurile (comisioane, taxe)
- ▣ Diversificați global
- ▣ Nu încercați să temporizați piața
- ▣ Rebalansați periodic


Dacă credeți în AMH

- ▣ Adaptați strategia la regimul pieței
- ▣ Fiți pasivi în perioade normale
- ▣ Căutați oportunități în crize (dislocări)
- ▣ Folosiți factori (valoare, momentum) cu prudență
- ▣ Monitorizați indicatorii de eficiență (VR mobil, Hurst)

Regula de aur

- ▣ **Costurile contează** — indiferent de poziția pe EMH
 - ▶ Majoritatea investitorilor obțin randamente mai bune
 - ▶ Prin reducerea comisioanelor decât prin strategii sofisticate

Harta conceptuală EMH (Conceptual Map)



■ Verde: dovezi care susțin EMH Roșu: provocări la adresa EMH Galben: sinteze moderne

Ghid practic (Practical Guide: Choosing a Test)

Situație	Test recomandat	Pachet Python	Avantaje
Dependență liniară	Ljung-Box Q	<code>statsmodels</code>	Simplu, standard
Dependență neliniară	BDS test	<code>statsmodels</code>	Detectează dependențe ascunse
Rădăcină unitară	ADF + KPSS	<code>statsmodels</code>	Strategie de confirmare
Autocorelație la scale	Variance ratio	Implementare proprie	Detectează momentum/reversie
Memorie lungă	Hurst (R/S, DFA)	Implementare proprie	Abordare non-parametrică
Reacția la știri	Event study	<code>eventstudy</code>	Standard academic
Dependențe periodice	Analiză spectrală	<code>scipy.signal</code>	Detectează cicluri ascunse
Eficiență variabilă	VR/Hurst mobil	Implementare proprie	Capturează dinamica AMH

Recomandare practică

- ☐ Nu vă bazați pe un singur test
 - ▶ Folosiți o **baterie** (Ljung-Box + VR + ADF/KPSS + Hurst)
 - ▶ Rezultatele divergente sunt informative

Lecții cheie din Capitolul 4 (Key Takeaways)

1. EMH este un **spectru**, nu o dihotomie — piețele variază de la aproape eficiente (S&P 500) la semnificativ ineficiente (BET)
2. Eficiența slabă (weak-form) este **aproximativ validă** pe piețe dezvoltate: autocorelația există dar este economic nesemnificativă
3. Eficiența semi-tare (semi-strong) este contestată de **PEAD** și alte anomalii, dar multe scad post-publicare
4. Eficiența tare (strong-form) este **respinsă** — insider trading-ul este profitabil
5. Finanțele comportamentale oferă **explicații** pentru anomalii, dar nu strategii de arbitraj ușor implementabile
6. **AMH** oferă cadrul cel mai complet: eficiența variază în timp, condusă de ecologia pieței
7. **Costurile de tranzacționare** sunt factorul determinant: majoritatea ineficiențelor detectate statistic nu sunt exploatabile economic
8. Pentru practicienii din piață: **adaptați** strategia la regimul de eficiență curent, nu aplicați reguli fixe

Direcții de cercetare (Current Research Directions)

Machine Learning și EMH

- ▣ Rețele neuronale (LSTM, Transformers) pot prezice randamente?
- ▣ Gu, Kelly & Xiu (2020): ML (*Machine Learning*) explică ~40% din variația transversală a randamentelor
- ▣ Dar: overfitting, data snooping, costuri implementare
- ▣ Dacă ML prezice randamente, piața este ineficientă?
- ▣ Contra: ML captează **prime de risc**, nu ineficiențe

Piețe crypto și DeFi

- ▣ Piețe 24/7, fără circuit breakers
- ▣ Eficiența crește rapid cu instituționalizarea
- ▣ Arbitraj cross-exchange: profitabil dar riscant (latență, contrapartidă)
- ▣ DeFi: AMM-urile (Uniswap) creează noi forme de descoperire a prețului
- ▣ MEV (Maximal Extractable Value): arbitraj de microstructură blockchain

Întrebare deschisă

- ▣ Dacă toți participanții folosesc aceiași algoritmi ML
 - ▶ Piața devine mai eficientă (prețuri corecte)?
 - ▶ Sau mai instabilă (comportament de turmă algoritmic)?

Bibliografie I

- ▣ Bachelier, L. (1900). *Théorie de la spéculation*. Annales Scientifiques de l'École Normale Supérieure.
- ▣ Ball, R., Brown, P. (1968). „An empirical evaluation of accounting income numbers.” *Journal of Accounting Research*, 6(2).
- ▣ Carhart, M.M. (1997). „On persistence in mutual fund performance.” *Journal of Finance*, 52(1).
- ▣ De Bondt, W., Thaler, R. (1985). „Does the stock market overreact?” *Journal of Finance*, 40(3).
- ▣ Fama, E.F. (1970). „Efficient capital markets: A review of theory and empirical work.” *Journal of Finance*, 25(2).
- ▣ Fama, E.F. (1991). „Efficient capital markets: II.” *Journal of Finance*, 46(5).
- ▣ Fama, E.F., French, K.R. (1993). „Common risk factors in the returns on stocks and bonds.” *Journal of Financial Economics*, 33(1).
- ▣ Grossman, S., Stiglitz, J. (1980). „On the impossibility of informationally efficient markets.” *American Economic Review*, 70(3).

Bibliografie II

- ▣ Harvey, C.R., Liu, Y., Zhu, H. (2016). „... and the cross-section of expected returns.” *Review of Financial Studies*, 29(1).
- ▣ Hou, K., Xue, C., Zhang, L. (2020). „Replicating anomalies.” *Review of Financial Studies*, 33(5).
- ▣ Jegadeesh, N., Titman, S. (1993). „Returns to buying winners and selling losers.” *Journal of Finance*, 48(1).
- ▣ Lo, A.W. (2004). „The Adaptive Markets Hypothesis.” *Journal of Portfolio Management*, 30(5).
- ▣ Lo, A.W., MacKinlay, A.C. (1988). „Stock market prices do not follow random walks.” *Review of Financial Studies*, 1(1).
- ▣ Malkiel, B.G. (2003). „The efficient market hypothesis and its critics.” *Journal of Economic Perspectives*, 17(1).
- ▣ McLean, R.D., Pontiff, J. (2016). „Does academic research destroy stock return predictability?” *Journal of Finance*, 71(1).
- ▣ Pedersen, L.H. (2015). *Efficiently Inefficient*. Princeton University Press.
- ▣ Shiller, R.J. (1981). „Do stock prices move too much...” *American Economic Review*, 71(3).
- ▣ Shleifer, A., Vishny, R.W. (1997). „The limits of arbitrage.” *Journal of Finance*, 52(1).

Bibliografie III

- ▣ Baker, M., Wurgler, J. (2006). „Investor sentiment and the cross-section of stock returns.” *Journal of Finance*, 61(4).
- ▣ Brock, W., Lakonishok, J., LeBaron, B. (1992). „Simple technical trading rules and the stochastic properties of stock returns.” *Journal of Finance*, 47(5).
- ▣ DeLong, J.B., Shleifer, A., Summers, L.H., Waldmann, R.J. (1990). „Noise trader risk in financial markets.” *Journal of Political Economy*, 98(4).
- ▣ Gu, S., Kelly, B., Xiu, D. (2020). „Empirical asset pricing via machine learning.” *Review of Financial Studies*, 33(5).
- ▣ Kahneman, D., Tversky, A. (1979). „Prospect theory: An analysis of decision under risk.” *Econometrica*, 47(2).
- ▣ Kim, J.H., Shamsuddin, A., Lim, K.P. (2011). „Stock return predictability and the adaptive markets hypothesis.” *Journal of Financial Econometrics*, 9(4).
- ▣ Kwiatkowski, D., Phillips, P.C.B., Schmidt, P., Shin, Y. (1992). „Testing the null hypothesis of stationarity.” *Journal of Econometrics*, 54(1–3).
- ▣ Mandelbrot, B.B. (1963). „The variation of certain speculative prices.” *Journal of Business*, 36(4).
- ▣ Odean, T. (1998). „Are investors reluctant to realize their losses?” *Journal of Finance*, 53(5).

Vă mulțumim! Întrebări? Materialele cursului sunt disponibile la:

<https://danpele.github.io/SFM/>



Quantlet



Quantinar