



Statistica Piețelor Financiare

Capitolul 4: EVT, Comparăție, Copule și Managementul Riscului



Daniel Traian PELE
Antoaneta Amza

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognostic Economică
MSCA Digital Finance

Ghid de studiu — Cum să folosiți materialele

Înainte de curs (*pre-reading*)

- ▣ McNeil et al. (2015), Cap. 2.3–2.4 (15 pag.)
- ▣ Embrechts et al. (1997), Cap. 3.1–3.3 (EVT)
- ▣ Opțional: Nelsen (2006), Cap. 2 (copule)

După curs (*review*)

- ▣ Refaceți exercițiile din slide-uri **fără** a privi rezolvările
- ▣ Rulați cel puțin 3 notebook-uri Quantlet
- ▣ Completați testele grilă din seminar ca auto-evaluare

Resurse digitale

- ▣ **Slide-uri + cod:** <https://danpele.github.io/SFM/>
- ▣ **Quantlet-uri interactive:** https://github.com/QuantLet/Stat_fin_markets/tree/master/Ch_02
- ▣ **Forum de discuții:** Platforma e-learning ASE

Obiective de învățare

La sfârșitul acestui capitol, veți fi capabili să:

1. **Aplicați** Teoria Valorilor Extreme (EVT): GEV, GPD, metoda POT
2. **Comparați** distribuțiile prin AIC, BIC, teste de adecvare și backtesting
3. **Descrieți** copulele (Gaussiană, Student- t , Clayton, Gumbel) și dependența de coadă
4. **Calculați** VaR și ES sub diferite ipoteze distribuționale
5. **Evaluați** modele prin backtesting (Kupiec, Christoffersen)
6. **Aplicați** extensii moderne: GARCH, schimbare de regim, procese Lévy

Cuprins

- ▣ Teoria Valorilor Extreme (EVT)
- ▣ Comparația distribuțiilor
- ▣ Copule și dependența de coadă
- ▣ Managementul riscului (VaR, ES)
- ▣ Extensii moderne (GARCH, regim)
- ▣ Rezumat / Quiz / Exerciții

EVT — Motivație

- ▣ Avem nevoie de modele precise pentru **evenimente extreme** (crize financiare, prăbușiri)
- ▣ În loc să modelăm *întreaga* distribuție, EVT se concentrează doar pe **cozi**
- ▣ **Indicele de coadă** ξ : un singur număr care rezumă grosimea cozii
 - ▶ $\xi > 0$: cozi groase (*heavy tails*, descreștere tip lege putere) — tipic pentru date financiare
 - ▶ $\xi = 0$: cozi exponențiale (similar cu distribuția normală)
 - ▶ $\xi < 0$: cozi mărginite (maximum finit)
- ▣ Date financiare: $\hat{\xi} > 0$ confirmă că evenimentele extreme sunt mai frecvente decât prevede distribuția normală

Idee cheie


- ▣ EVT oferă **extrapolare riguroasă matematic** în cozi, chiar dincolo de datele observate

GPD — Introducere descriptivă


- Depășirile peste un prag ridicat u tind să urmeze o formă specifică:

Distribuția Pareto Generalizată (GPD)

- Gândiți-vă astfel: „dat fiind că s-a întâmplat ceva extrem, cât de extrem a fost?”
- GPD are doi parametri: formă ξ și scală σ
- Pentru date financiare, de regulă $\hat{\xi} \in [0,1; 0,5]$



EVT în practică — Evenimente extreme



SFM_ch2_extreme_value

- Maximele pe blocuri (ex.: cea mai mare pierdere lunară) urmează distribuția GEV
- Teoreme formale la nivel Master; VaR/ES bazate pe EVT în secțiunea de managementul riscului

Teorema Fisher–Tippett–Gnedenko


Teoremă 1 (Fisher–Tippett–Gnedenko)

Dacă $M_n = \max(X_1, \dots, X_n)$ și $\frac{M_n - b_n}{a_n} \xrightarrow{d} H$, atunci H este **GEV**:

$$H(x; \xi, \mu, \sigma) = \exp \left\{ - \left(1 + \xi \frac{x - \mu}{\sigma} \right)^{-1/\xi} \right\}$$

- Trei tipuri în funcție de ξ :
 - ▶ $\xi > 0$: **Fréchet** — cozi groase (date financiare)
 - ▶ $\xi = 0$: **Gumbel** — cozi exponențiale
 - ▶ $\xi < 0$: **Weibull** — cozi mărginite
- Analog TLC dar pentru *maxime* în loc de sume

Densitățile GEV — Cele trei familii



- **Fréchet** ($\xi > 0$): coadă dreaptă grea — tipică pentru maxime financiare
- **Gumbel** ($\xi = 0$): coadă exponențială
- **Weibull** ($\xi < 0$): coadă mărginită (maximum finit)

Pickands–Balkema–de Haan și metoda POT

Teoremă 2 (Pickands–Balkema–de Haan)

Pentru un prag ridicat u , depășirile $Y = X - u \mid X > u$ urmează GPD:

$$G(y; \xi, \sigma) = 1 - \left(1 + \xi \frac{y}{\sigma}\right)^{-1/\xi}, \quad y > 0.$$


▣ **Metoda POT** (Peaks Over Threshold):

1. Alegem pragul u (graficul excesului mediu, stabilitatea parametrilor)
2. Ajustăm GPD pe depășiri prin MLE
3. Raportăm $(\hat{\xi}, \hat{\sigma})$

▣ **Funcția excesului mediu:** $e(u) = \mathbb{E}[X - u \mid X > u] = \frac{\sigma + \xi u}{1 - \xi}$

▣ Liniară în u pentru GPD $\Rightarrow$ instrument diagnostic pentru selectarea pragului

Densitățile GPD — Forme în funcție de ξ




- $\xi > 0$ (**Pareto**): coadă grea — tipică pentru depășiri financiare
- $\xi = 0$ (**Exponențială**): referință; $\xi < 0$ (**Beta**): suport finit
- Cu cât ξ este mai mare, cu atât depășirile extreme sunt **mai probabile**

VaR și ES bazate pe EVT

□ VaR din GPD:


$$\text{VaR}_\alpha = u + \frac{\sigma}{\xi} \left[\left(\frac{n\alpha}{N_u} \right)^{-\xi} - 1 \right]$$

unde N_u = numărul de depășiri, n = observații totale

□ ES din GPD: $\text{ES}_\alpha = \frac{\text{VaR}_\alpha}{1-\xi} + \frac{\sigma - \xi u}{1-\xi}, \quad \xi < 1$ 

Selectarea pragului

- ▣ **Graficul excesului mediu:** $\hat{e}(u)$ vs. u ; linearitatea sugerează că GPD este adecvată deasupra aceluia u
- ▣ **Graficul stabilității parametrilor:** $\hat{\xi}(u)$ și $\hat{\sigma}^*(u)$ vs. u ; regiunea stabilă = prag bun
- ▣ Compromis: u prea mic $\Rightarrow$ eroare sistematică (date non-extreme incluse); u prea mare $\Rightarrow$ varianță mare (puține depășiri)
- ▣ Regulă practică: se folosesc primele 5–10% din observații



Estimatorul Hill

Definiție 1 (Estimatorul Hill)

Pentru statisticile de ordine $X_{(1)} \geq X_{(2)} \geq \dots \geq X_{(n)}$:

$$\hat{\xi}_{\text{Hill}}^{(k)} = \frac{1}{k} \sum_{i=1}^k \ln X_{(i)} - \ln X_{(k+1)}, \quad k = 1, \dots, n-1.$$

Indicele de coadă este $\alpha = 1/\hat{\xi}_{\text{Hill}}$.

- ▣ **Graficul Hill:** $\hat{\xi}_{\text{Hill}}^{(k)}$ vs. k ; regiunea stabilă indică k adecvat
- ▣ **Compromis bias-varianță:** k mic $\Rightarrow$ varianță mare; k mare $\Rightarrow$ eroare sistematică mare
- ▣ Valid doar pentru $\xi > 0$ (cozi groase)

Estimatori alternativi ai indicelui de coadă


▣ Estimatorul Pickands:

$$\hat{\xi} = \frac{1}{\ln 2} \ln \frac{X_{(k)} - X_{(2k)}}{X_{(2k)} - X_{(4k)}}$$

Funcționează pentru orice $\xi \in \mathbb{R}$ (nu doar $\xi > 0$)

- ▣ **Estimatorul de momente** (Dekkers–Einmahl–de Haan): funcționează și el pentru orice ξ
- ▣ **Condiții de ordin secund:** Hall (1982) — parametrul de ordin secund ρ guvernează k optim în estimatorul Hill
- ▣ **Selectare adaptivă a pragului:** minimizarea MSE asimptotică (Danielsson et al., 2001)

Graficul Hill — S&P 500



- Stânga: $\hat{\alpha}_{\text{Hill}}^{(k)}$ vs. k — regiunea stabilă ($k \in [100, 300]$) sugerează $\hat{\alpha} \approx 3,5$
- Dreapta: log-log confirmă legea putere; distribuția normală (punctată) curbează în jos

Conexiunea cu distribuțiile stabile

- Dacă $X \sim S(\alpha, \beta, \gamma, \delta)$ cu $\alpha < 2$, atunci parametrul de formă EVT este:

$$\xi = 1/\alpha$$

- Distribuțiile stabile sunt în domeniul de atracție al GEV Fréchet ($\xi > 0$)
- Estimatorul Hill aplicat pe date stabile: $\hat{\alpha}_{\text{Hill}} = 1/\hat{\xi}_{\text{Hill}}$
- Compararea indicilor de coadă:
 - ▶ Ajustare stabilă: $\hat{\alpha} \approx 1,7 \Rightarrow \hat{\xi} \approx 0,59$
 - ▶ Estimarea Hill: dă de regulă $\hat{\alpha} \in [3, 5]$ (pentru cozi moderate)
 - ▶ Discrepanța apare deoarece Hill măsoară descreșterea *locală* a cozii, iar α stabil guvernează forma *globală*

Exemplu POT — VaR și ES pas cu pas

Exercițiu

$n = 1.000$ randamente zilnice. Pragul $u = 2,5\%$ dă $N_u = 50$ depășiri. MLE pe depășiri: $\hat{\xi} = 0,3$, $\hat{\sigma} = 0,8\%$. Calculați $\text{VaR}_{1\%}$ și $\text{ES}_{1\%}$.

Rezolvare

1. Raportul: $\frac{n\alpha}{N_u} = \frac{1000 \times 0,01}{50} = 0,2$; $0,2^{-0,3} = 1,621$
2. $\text{VaR}_{0,01} = u + \frac{\hat{\sigma}}{\hat{\xi}} [0,2^{-\hat{\xi}} - 1] = 2,5\% + 2,667\% \times 0,621 = 4,16\%$
3. $\text{ES}_{0,01} = \frac{\text{VaR}}{1-\xi} + \frac{\hat{\sigma}-\hat{\xi}u}{1-\xi} = \frac{4,16\%}{0,7} + \frac{0,05\%}{0,7} = 6,01\%$

Observație 1

- ▣ Comparație: $\text{VaR normală} = 3,49\%$, $\text{VaR EVT} = 4,16\%$ (+19%); $\text{ES EVT} = 6,01\%$

Opriți-vă și gândiți-vă

(auto-evaluare)

Verificare rapidă — EVT

1. Teorema Fisher–Tippett–Gnedenko: maximele normalizate converg la una din 3 distribuții. Care sunt și ce le diferențiază?
2. Estimatorul Hill dă $\hat{\xi} = 0,30$. Ce tip de coadă indică? Comparați VaR EVT cu VaR Normal.
3. De ce pragul u este critic în metoda POT? Ce se întâmplă dacă u este prea mic sau prea mare?


Răspunsuri

1. Gumbel ($\xi = 0$, cozi exponențiale), Fréchet ($\xi > 0$, cozi groase/lege putere), Weibull ($\xi < 0$, coadă finită). ξ = indexul de coadă.
2. $\xi > 0 \Rightarrow$ coadă grea (Fréchet). $\text{VaR EVT} > \text{VaR Normal}$ (tipic +15–30%).
3. u prea mic: bias (GPD nu aproximează bine). u prea mare: varianță mare (prea puține observații). Graficul funcției medii a exceselor ajută la alegere.

Cuprins

- ▣ Teoria Valorilor Extreme ✓
- ▣ **Comparația distribuțiilor**
- ▣ Copule și dependența de coadă
- ▣ Managementul riscului
- ▣ Extensii moderne
- ▣ Rezumat / Quiz / Exerciții


Comparație vizuală a distribuțiilor



 SFM_ch2_distribution_comparison

- ▣ Histogramă cu suprapuneri ajustate: Normală, Student- t , Stabilă
- ▣ Care distribuție surprinde cel mai bine centrul, umerii și cozile?

Grafice QQ




- ▣ **Grafic QQ**: cuantile date vs. distribuție teoretică
- ▣ Ajustare perfectă $\Rightarrow$ pe linia de 45° ; **formă de S**: cozi mai groase
- ▣ QQ sub distribuția normală: abateri sistematice; Student-t: mai aproape de 45°

Checklist: Fapt stilizat → Distribuție

Fapt stilizat	Normal	Student- t	Skew- t	Stabilă	EVT
Cozi groase	✗	✓	✓	✓	✓
Asimetrie	✗	✗	✓	✓	✗
Clusterizare vol.	✗	✗	✗	✗	✗
Kurtosis > 3	✗	✓	✓	✓	—
Varianță infinită	✗	*	✗	✓	—

- * Student- t : varianță infinită doar dacă $\nu \leq 2$ (rar în practică)
- **Nicio distribuție statică** nu captează clusterizarea volatilității $\Rightarrow$ necesită modele dinamice (GARCH)
- Tabelul ghidează selecția: dacă datele prezintă asimetrie, eliminăm distribuția normală și Student- t simetrică

Graficul log-log al cozilor



 SFM_ch2_distribution_comparison

- ▣ Reprezentăm $\ln P(|X| > x)$ vs. $\ln x$
- ▣ Coadă tip lege putere: dreaptă cu panta $-\alpha$
- ▣ Normală: se curbează în jos (descreștere exponențială)
- ▣ Student- t și Stabilă: aproximativ liniare (descreștere tip lege putere)

Criterii informaționale

Formulele AIC și BIC

$$\text{AIC} = -2\ell(\hat{\theta}) + 2k, \quad \text{BIC} = -2\ell(\hat{\theta}) + k \ln n$$

$\ell(\hat{\theta})$ = log-verosimilitatea maximizată; k = nr. parametri; n = dimensiune eșantion

Distribuție	k	AIC	BIC
Normală	2	Cel mai mare	Cel mai mare
Student- t	3	Mai mic	Mai mic
Student- t asim.	4	Cel mai mic	Cel mai mic
Stabilă	4	Comparabil	Comparabil

Teste formale de adecvare și raportul de verosimilitate

Teste de adecvare (GoF)

- ▣ **KS**: $H_0: F = F_\theta$ vs. $H_1: F \neq F_\theta$; $D_n = \sup_x |F_n(x) - F_\theta(x)|$
- ▣ **AD**: aceeași ipoteză, dar ponderat pe cozi:

$$A^2 = -n - \frac{1}{n} \sum (2i-1) [\ln F_\theta(x_{(i)}) + \ln(1 - F_\theta(x_{(n+1-i)}))]$$

Test raport de verosimilitate (LR) — modele imbricate

H_0 : modelul restrâns (ex. Normală) vs. H_1 : modelul general (ex. Student- t)

$$LR = -2 [\ell(\hat{\theta}_0) - \ell(\hat{\theta}_1)] \sim \chi^2(k_1 - k_0)$$

Respingem H_0 dacă $LR > \chi^2_{k_1 - k_0; 1-\alpha}$. Ex.: Normal ($k_0=2$) vs. t ($k_1=3$): $\chi^2(1)$.

Comparație cuprinzătoare a modelelor

Risk Measures Comparison (\$1M Portfolio)
VaR and Expected Shortfall under Different Distributions

Level	Normal VaR	Normal ES	Student-t VaR	Student-t ES	Empirical VaR	Empirical ES
95%	\$19,853	\$24,957	\$16,834	\$29,902	\$18,659	\$29,847
99%	\$28,178	\$32,317	\$35,036	\$58,092	\$34,839	\$50,602
99.9%	\$37,508	\$40,890	\$87,603	\$142,040	\$73,903	\$95,179

Data: S&P 500 log returns, 2000-2025 (n=6,537)
Student-t df=2.64 | ES values shown in red (ES ≥ VaR by construction)

 SFM_ch2_risk_management

- Nicio distribuție nu domină pe toate criteriile
- Student- t și Student- t asimetrică: cel mai bun echilibru între ajustare și parsimonie
- Stabilă: cea mai bună ajustare a cozilor dar costisitoare computațional
- EVT: cea mai bună pentru cuantile extreme, dar agnostică față de centru

Testul Vuong și reguli de scor

- ▣ **Testul Vuong (1989)**: compararea modelelor neimbricate (*non-nested* — modele care nu sunt subcazuri unul altuia)

$$V = \frac{\sum_{i=1}^n m_i}{\sqrt{n} \hat{\sigma}_m}, \quad m_i = \ln \frac{f_1(x_i; \hat{\theta}_1)}{f_2(x_i; \hat{\theta}_2)}$$

$V \sim N(0, 1)$ sub H_0 : modelele sunt echivalente

- ▣ **CRPS** (Continuous Ranked Probability Score):

$$\text{CRPS}(F, x) = \int_{-\infty}^{\infty} (F(y) - 1_{y \geq x})^2 dy$$

- ▣ Regulă de scor proprie: încurajează previziuni probabilistice oneste

Evaluarea densităților predictive

- ▣ **Testul Diebold–Mariano (1995):** H_0 : aceeași capacitate predictivă; H_1 : un model este superior

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})/n}} \xrightarrow{d} N(0, 1), \quad d_t = L(e_{1t}) - L(e_{2t})$$

$L(\cdot)$ = funcție de pierdere (ex. pătratică); e_{it} = eroarea de previziune a modelului i

- ▣ **Validare încrucișată:** evaluare k -fold a ajustării distribuționale
- ▣ **Transformata probabilității integrale (PIT):**
 - ▶ Dacă F este CDF-ul adevărat, atunci $U_i = F(X_i) \sim \text{Uniform}(0, 1)$
 - ▶ Testarea uniformității valorilor PIT $\Rightarrow$ testarea adecvării distribuționale
 - ▶ Transformata Rosenblatt (1952) pentru cazul multivariat
- ▣ Ajustarea in-sample $\neq$ capacitatea predictivă out-of-sample
- ▣ Risc de supraajustare: modelele complexe (GH, 5 parametri) pot supraajusta in-sample

Testul de echivalență a cozilor

Definiție 2 (Testul Jansen & de Vries (1991))

H_0 : indicele de coadă este egal pentru două serii financiare: $\alpha_X = \alpha_Y$.

Statistica de test bazată pe estimatorul Hill:

$$T = \frac{\hat{\alpha}_{H,X} - \hat{\alpha}_{H,Y}}{\sqrt{\hat{\alpha}_{H,X}^2/k_X + \hat{\alpha}_{H,Y}^2/k_Y}} \xrightarrow{d} N(0, 1)$$

unde k_X, k_Y sunt numerele de ordine statistice folosite.

Aplicație: S&P 500 vs. DAX

- ▣ $\hat{\alpha}_{H,SP} = 3,2$ ($k = 100$); $\hat{\alpha}_{H,DAX} = 2,9$ ($k = 100$)
- ▣ $T = \frac{3,2-2,9}{\sqrt{3,2^2/100+2,9^2/100}} = \frac{0,3}{0,432} = 0,69$; $|T| < 1,96 \Rightarrow$ **nu respingem H_0**
- ▣ Cozile S&P 500 și DAX au indiciile de coadă **statistic echivalent**

Intervale de încredere pentru estimatorii distribuționali

Observație 2 (Instabilitatea estimatorilor)

- Estimatorii $\hat{\alpha}_{\text{stabil}}$, $\hat{\nu}_t$, $\hat{\xi}_{\text{Hill}}$ sunt sensibili la dimensiunea eșantionului n
- Raportați întotdeauna erori standard, nu doar estimări punctuale!**

Estimator	$n = 500$	$n = 2.500$	$n = 10.000$
$\hat{\alpha}_{\text{stabil}}$	$1,70 \pm 0,12$	$1,70 \pm 0,05$	$1,70 \pm 0,03$
$\hat{\nu}_t$	$5,0 \pm 1,2$	$5,0 \pm 0,5$	$5,0 \pm 0,25$
$\hat{\xi}_{\text{Hill}}$	$0,30 \pm 0,08$	$0,30 \pm 0,04$	$0,30 \pm 0,02$

Implicație practică

- Cu $n = 500$, intervalul de încredere pentru $\hat{\nu}_t$ este $[3,8; 6,2]$ — diferență enormă în VaR!
- Estimările stabile necesită $n > 2.000$ pentru precizie rezonabilă

Exemplu AIC/BIC — Selecția modelului

Exercițiu

Ajustăm 4 distribuții pe $n = 2.500$ randamente zilnice S&P 500. Log-verosimilitatea maximă:

Model	k	$\hat{\ell}$	$AIC = -2\hat{\ell} + 2k$	$BIC = -2\hat{\ell} + k \ln n$	ΔAIC	ΔBIC
Normală	2	7.420	-14.836	-14.824	294	281
Student- t	3	7.555	-15.104	-15.086	26	19
Student- t asim.	4	7.569	-15.130	-15.105	0	0
Stabilă	4	7.563	-15.118	-15.093	12	12

Interpretare

- ▣ $\Delta AIC > 10$: dovadă puternică *contra* modelului (Burnham & Anderson)
- ▣ Normală: $\Delta = 294$ (respinsă masiv); Student- t sim.: $\Delta = 26$ (respinsă)
- ▣ **Student- t asimetrică câștigă** pe AIC și BIC; Stabilă aproape echivalentă ($\Delta = 12$)

De la marginale la dependență

- ▣ Până acum am modelat distribuția **unui singur activ** (marginală)
- ▣ Riscul de portofoliu depinde de **cum se mișcă activele împreună** — structura de dependență
- ▣ Corelația Pearson surprinde doar dependența **liniară**
- ▣ **Dependența de coadă**: activele tind să se prăbușească *simultan* în crize
 - ▶ În 2008: toate clasele de active au scăzut concomitent
 - ▶ Corelația crește exact când diversificarea este cea mai necesară

Marginale corecte + copulă greșită = portofoliu greșit

Două active cu aceleași marginale și aceeași corelație pot avea structuri de dependență extremală **complet diferite**. Alegerea copulei afectează decisiv estimarea riscului de portofoliu.

Capitolul 4 va trata copulele în detaliu: estimare, selecție, vine copulas și aplicații.

Teorema lui Sklar — Intuiție

Definiție 3 (Copulă — Intuitiv)

O **copulă** $C(u, v)$ este o funcție care leagă distribuțiile marginale de distribuția comună. Separă structura de dependență de comportamentul individual al fiecărui activ.

Teoremă 3 (Sklar, 1959)

Orice distribuție bivariată $F(x, y)$ poate fi scrisă ca:

$$F(x, y) = C(F_X(x), F_Y(y))$$

unde F_X, F_Y sunt marginalele, iar C este copula (unică dacă marginalele sunt continue).

- ▣ **Pas 1:** Modelăm fiecare activ separat (marginalele — capitolul actual)
- ▣ **Pas 2:** Modelăm dependența prin copulă (**Capitolul 4**)
- ▣ Aceasta permite combinații flexibile: marginale Student- t + copulă Clayton

Familii de copule și dependența de coadă

Copulă	Param.	λ_L (coadă inf.)	λ_U (coadă sup.)	Utilizare
Gaussiană	ρ	0	0	Benchmark
Student- t	ρ, ν	> 0	> 0	Riscul de coadă simetric
Clayton	θ	> 0	0	Prăbușiri comune
Gumbel	θ	0	> 0	Co-mișcări pozitive
Frank	θ	0	0	Dependență simetrică

- ▣ **Coeficientul de dependență de coadă:** $\lambda_L = \lim_{u \rightarrow 0} P(U \leq u \mid V \leq u)$
- ▣ Copulă Gaussiană: $\lambda_L = \lambda_U = 0$ chiar dacă $\rho = 0,9$ — **subestimează** riscul de prăbușire comună
- ▣ Copulă Student- t : $\lambda_L = \lambda_U = 2 t_{\nu+1} \left(-\sqrt{(\nu+1)(1-\rho)/(1+\rho)} \right) > 0$
- ▣ **Lecție:** Corelația mare $\neq$ dependență de coadă puternică

Implicații pentru managementul riscului de portofoliu

- ▣ **VaR de portofoliu sub diferite copule:**
 - ▶ Copulă Gaussiană $\Rightarrow$ VaR de portofoliu mai mic (subestimează riscul comun)
 - ▶ Copulă Student- $t \Rightarrow$ VaR mai mare (captează prăbușiri simultane)
 - ▶ Diferența crește dramatic pentru cuantile extreme ($< 0,1\%$)
- ▣ **Basel III:** cere modele de dependență de coadă pentru portofolii de tranzacționare
- ▣ **Estimare:** pseudo-MLE (Joe, 1997); inversiunea rangurilor $\hat{u}_i = R_i/(n+1)$
- ▣ **Selecția copulei:** AIC/BIC pe funcția de verosimilitate a copulei
- ▣ **Vine copulae** (Aas et al., 2009): extensie la dimensiuni mari prin descompunere pair-copula

Observație 3

- ▣ Capitolul 4 va trata copulele în detaliu. Aici reținem: **marginale corecte + copulă greșită = risc de portofoliu greșit**

Opriti-vă și gândiți-vă

(auto-evaluare)

Verificare rapidă — Copule și dependența de coadă

1. Copula Gaussiană are dependență de coadă? Ce implicație a avut aceasta în criza din 2008?
2. Copula Clayton captează dependența de coadă inferioară. În ce context financiar este aceasta importantă?
3. Un manager de risc folosește marginale Student- t + copulă Gaussiană. Ce problemă poate apărea?

Răspunsuri

1. **Nu** ($\lambda_U = \lambda_L = 0$). Subestimează co-mișcările extreme — a contribuit la subevaluarea CDO-urilor (Li, 2000).
2. Crize financiare: activele tind să cadă **simultan** (contagiune). Clayton: $\lambda_L > 0$, captează acest fenomen.
3. Marginale cu cozi grele + copulă fără dependență de coadă = **inconsistentă**. Riscul de portofoliu este subestimat în scenarii extreme.

Partea II

Managementul riscului și Extensii moderne

— Secțiunile 4–5 —

Întrebarea de risc

- ▣ O bancă deține un portofoliu în valoare de \$1.000.000
- ▣ Întrebarea fundamentală: „Care este pierderea maximă pe care o putem aștepta într-o zi dată, cu un nivel specificat de încredere?”
- ▣ **Intuiția cuantilei:** cuantila de ordin α q_α satisface:

$$P(r_t \leq q_\alpha) = \alpha$$

- ▣ Pentru $\alpha = 0,01$: $q_{0,01}$ este depășit (la scădere) doar 1% din timp
- ▣ În 100 de zile de tranzacționare, ne așteptăm să pierdem mai mult decât $q_{0,01}$ în ≈ 1 zi

Value-at-Risk — Convenții de semn și proprietăți

Definiția de lucru a fost introdusă în Secțiunea 4. Aici studiem convențiile și limitările.

- ▣ Cu probabilitatea $(1 - \alpha)$, pierderea zilnică **nu va depăși** $\text{VaR}_\alpha = -F^{-1}(\alpha)$
- ▣ **Convenție:** „VaR 1%” înseamnă $\alpha = 0,01$ (pierdere depășită cu probabilitate 1%)
- ▣ Semnul minus convertește cuantila negativă într-o sumă pozitivă de pierdere

Convenție de semn — atenție!

- ▣ **Secțiunile 2–8:** $\text{VaR}_\alpha = -F^{-1}(\alpha)$ — cuantila cu semn schimbat (rezultat pozitiv)
- ▣ **Secțiunea EVT:** u și VaR sunt magnitudini de pierdere (pozitive)
- ▣ Ambele convenții dau **aceeași valoare numerică**

VaR sub ipoteza normală


- Dacă $r_t \sim N(\mu, \sigma^2)$:

$$\text{VaR}_\alpha = -(\mu + \sigma \cdot z_\alpha), \quad z_\alpha = \Phi^{-1}(\alpha)$$

- **Exemplu:** $\mu = 0$, $\sigma = 0,015$, portofoliu = \$1M, $\alpha = 0,01$:

$$\text{VaR}_{0,01} = -0,015 \times (-2,326) \times 1.000.000 = \$34.890$$

- În 99 din 100 de zile de tranzacționare, pierderea nu va depăși \$34.890




De ce contează distribuția pentru VaR

Model	VaR 1% (\$1M)	VaR 0,1% (\$1M)	Raport față de normală
Normală	\$27.000	\$35.900	1,0×
Student- t ($\nu = 5$)	\$33.700	\$58.400	1,6×
Stabilă ($\alpha = 1,7$)	\$41.000	\$90.200	2,5×

- La 1%: diferență moderată ($\sim 25\%$); la 0,1%: **dramatică** (1,6–2,5×
- **Concluzie:** Alegerea distribuției afectează direct capitalul necesar
- Distribuția stabilă necesită capital de 2,5× mai mare decât cea normală la cuantila 0,1%

VaR sub diferite distribuții — Vizualizare



- Divergența cozilor crește dramatic cu nivelul de încredere
- La 0,1%, distribuția normală subestimează riscul cu **peste 60%** (Student- t) și **150%** (stabilă)
- Cerințele de capital Basel depind critic de ipoteza distribuțională



Limitările VaR

- VaR ne spune *pragul* celei mai rele fracțiuni α din zile
- Dar **nu** cât de rău devine lucrurile *dincolo* de acel prag
- VaR nu distinge între „pierderea de \$35k” și „pierderea de \$200k” — ambele sunt „depășiri VaR”
- O măsură mai bună (**Expected Shortfall**) rezolvă această limitare

VaR nu este subaditivă

- Diversificarea poate *crește* VaR: $VaR(X + Y) > VaR(X) + VaR(Y)$ este posibil
- Acest lucru contrazice principiul că diversificarea reduce riscul

VaR vs. ES — Subaditivitate vizuală



- Stânga: VaR a portofoliului poate depăși suma VaR-urilor individuale (non-subaditivă)
- Dreapta: ES a portofoliului este **întotdeauna** $\leq$ suma ES-urilor (subaditivă, coerentă)

Expected Shortfall

Definiție 4 (Expected Shortfall)

Expected Shortfall (CVaR) la nivelul α :

$$ES_{\alpha} = -\frac{1}{\alpha} \int_0^{\alpha} F^{-1}(p) dp \stackrel{F \text{ cont.}}{=} \mathbb{E}[-X \mid X \leq -\text{VaR}_{\alpha}].$$

Egalitatea cu așteptarea condiționată vale pentru distribuții **continue**.

- **Interpretare:** pierderea medie dat fiind că suntem în cele mai rele $\alpha\%$ din zile
- Sub normalitate: $ES_{\alpha} = -\mu + \sigma \frac{\phi(\Phi^{-1}(\alpha))}{\alpha}$
- ES este o măsură **coerentă** de risc (subaditivă):

$$ES(X + Y) \leq ES(X) + ES(Y)$$

- Diversificarea reduce întotdeauna ES (spre deosebire de VaR)

Axiomele coerență — Artzner et al. (1999)

Definiție 5 (Măsură coerentă de risc)

O funcțională $\rho : \mathcal{X} \rightarrow \mathbb{R}$ este o **măsură coerentă de risc** dacă satisface:

- A1. Monotonie:** $X \leq Y \Rightarrow \rho(X) \geq \rho(Y)$
 - Pierderi mai mari $\Rightarrow$ risc mai mare
- A2. Subaditivitate:** $\rho(X + Y) \leq \rho(X) + \rho(Y)$
 - Diversificarea nu crește riscul
- A3. Omogenitate pozitivă:** $\rho(\lambda X) = \lambda \rho(X)$, $\lambda > 0$
 - Dublarea poziției dublează riscul
- A4. Invariantă la translație:** $\rho(X + c) = \rho(X) - c$
 - Adăugarea de numerar reduce riscul cu aceeași sumă

Rezultat cheie

- **ES este coerentă** (satisface A1–A4); **VaR nu este** (eșuează la A2)

Backtesting VaR — Testele Kupiec și Christoffersen

Testul Kupiec (1995) — acoperire necondiționată

H_0 : rata depășirilor = α vs. H_1 : rata depășirilor $\neq \alpha$

$$LR_{uc} = -2 \ln \frac{\alpha^x (1 - \alpha)^{n-x}}{\hat{p}^x (1 - \hat{p})^{n-x}} \sim \chi^2(1), \quad \hat{p} = x/n$$

Testul Christoffersen (1998) — independența depășirilor


H_0 : depășirile sunt independente vs. H_1 : depășirile se clusterizează

$$LR_{ind} = -2 \ln \frac{\hat{p}^{n_{11}} (1 - \hat{p})^{n_{00}}}{\hat{p}_{01}^{n_{01}} (1 - \hat{p}_{01})^{n_{00}} \hat{p}_{11}^{n_{11}} (1 - \hat{p}_{11})^{n_{10}}} \sim \chi^2(1)$$

n_{ij} = tranzițiile de la starea i la j ; $\hat{p}_{ij} = n_{ij} / (n_{i0} + n_{i1})$

Test combinat: $LR_{cc} = LR_{uc} + LR_{ind} \sim \chi^2(2)$. **Basel III/IV:** de la VaR 1% (10 zile) la ES 2,5%.

Backtesting — Vizualizare



- ▣ Semafor Basel: Verde (0–4 depășiri), Galben (5–9), Roșu (10+) per 250 zile
- ▣ Normală: prea multe depășiri $\Rightarrow$ respinsă de Kupiec

Rezultate backtest VaR

Risk Measures Comparison (\$1M Portfolio)
VaR and Expected Shortfall under Different Distributions

Level	Normal VaR	Normal ES	Student-t VaR	Student-t ES	Empirical VaR	Empirical ES
95%	\$19,853	\$24,957	\$16,834	\$29,902	\$18,659	\$29,847
99%	\$28,178	\$32,317	\$35,036	\$58,092	\$34,839	\$50,602
99.9%	\$37,508	\$40,890	\$87,603	\$142,040	\$73,903	\$95,179

Data: S&P 500 log returns, 2000-2025 (n=6,537)
Student-t df=2.64 | ES values shown in red (ES $\geq$ VaR by construction)

 SFM_ch2_risk_management

- ▣ Normală: prea multe depășiri VaR $\Rightarrow$ respinsă de testul Kupiec
- ▣ Student- t : depășiri aproape de rata așteptată
- ▣ Bazat pe EVT: conservator dar robust
- ▣ **Riscul de model**: rezervele de capital depind de modelul ales

Măsurile spectrale de risc și elicitabilitate

▣ Măsurile spectrale de risc:

$$\rho_{\phi}(X) = - \int_0^1 \phi(p) F^{-1}(p) dp$$


cu spectrul de risc $\phi(p) \geq 0$, $\int_0^1 \phi(p) dp = 1$, ϕ nedescrescătoare

▣ VaR: $\phi(p) = \delta(p - \alpha)$; ES: $\phi(p) = \frac{1}{\alpha} 1_{p \leq \alpha}$

▣ Elicitabilitate (Gneiting, 2011):

- ▶ VaR este elicibilă: optimală sub pierderea cuantică $\rho(x, q) = (\alpha - 1_{x < q})(x - q)$
- ▶ ES **nu** este elicibilă singură
- ▶ (VaR, ES) este elicibilă conjunct (Fissler & Ziegel, 2016)

Funcțiile spectrale de risc — Vizualizare



SFM_ch2_risk_management

- VaR: pondere concentrată într-un singur punct (δ la $p = \alpha$) — ignoră ce se întâmplă dincolo
- ES: pondere uniformă pe $[0, \alpha]$ — media tuturor pierderilor din coada de $\alpha\%$
- Spectrul exponențial: penalizează mai mult pierderile cele mai extreme

Alocarea capitalului și riscul de model

- ▣ **Alocarea Euler:** alocăm ES-ul portofoliului pe pozițiile individuale:

$$ES_i = \mathbb{E}[-X_i \mid X_{\text{total}} \leq -\text{VaR}_\alpha]$$

- ▣ Ipotezele distribuționale afectează direct capitalul alocat per departament
- ▣ **Distribuții stabile și riscul extrem:** ES sub distribuții stabile diverge pe măsură ce $\alpha \rightarrow 0$ mai rapid decât sub Student- t
- ▣ **Cuantificarea riscului de model:** calculăm VaR/ES sub mai multe modele; intervalul cuantifică incertitudinea modelului
- ▣ Răspunsul reglementator: VaR stresat, suplimente de risc de model

Backtest out-of-sample — Compararea modelelor

Exercițiu: Fereastră mobilă 250 zile, VaR 1%, S&P 500 (2010–2025)

Model	Depășiri așteptate	Depășiri reale	p -value Kupiec
Normal	37	58	0,001
Student- t ($\nu = 5$)	37	41	0,42
Stabilă ($\alpha = 1,7$)	37	34	0,55
EVT-GPD	37	30	0,18

Interpretare

- ▣ Distribuția normală: respinsă ($p < 0,05$); Student- t și stabilă: acceptate
- ▣ EVT: conservator (mai puține depășiri) — **nu** neapărat cel mai bun
- ▣ Calibrare $\neq$ discriminare: modelul cu cele mai puține depășiri poate supraestima riscul

Exemplu ES — Calcul pas cu pas sub ipoteza normală

Exercițiu

Portofoliu \$1.000.000, randamente zilnice $r_t \sim N(0, 0,015^2)$. Calculați $ES_{1\%}$.

Rezolvare

Formula: $ES_\alpha = \sigma \phi(z_\alpha) / \alpha$ (cu $\mu = 0$). $z_{0,01} = -2,326$, $\phi(-2,326) = 0,02665$

$$ES_{0,01} = 0,015 \times \frac{0,02665}{0,01} = 0,03998 = 4,00\% \Rightarrow \$1M \times 4\% = \$40.000$$

Comparație VaR vs. ES

- ▣ $VaR_{1\%} = 3,49\%$ (\$34.890) vs. $ES_{1\%} = 4,00\%$ (\$40.000) — cu **14,6%** mai mare
- ▣ ES ne spune cât de rău este *în medie* când depășim VaR

Studiu de caz: Crizele 2008 și 2020 — Ce spun modelele?

	15 sept. 2008 (Lehman)		16 mar. 2020 (Covid)	
	r_t	Echivalent σ	r_t	Echivalent σ
S&P 500	-4,71%	$4,7\sigma$	-11,98%	12σ

Model	$P(r < -4,71\%)$	$P(r < -11,98\%)$	Verdict
Normală ($\sigma = 1\%$)	$2,6 \times 10^{-6}$	≈ 0	Imposibil
Student- t ($\nu = 5$)	$6,8 \times 10^{-4}$	$4,1 \times 10^{-6}$	Rar, dar posibil
Stabilă ($\alpha = 1,7$)	$2,1 \times 10^{-3}$	$3,0 \times 10^{-4}$	Previzibil
EVT-GPD ($\xi = 0,3$)	$1,5 \times 10^{-3}$	$1,8 \times 10^{-4}$	Previzibil

Concluzia

- Doar modelele cu cozi groase (Student- t , stabilă, EVT) atribuie probabilități rezonabile evenimentelor extreme observate

Studiu de caz: Backtest VaR în jurul crizelor

Lehman (sept.–oct. 2008)

- ▣ 23 zile de tranzacționare
- ▣ VaR 1% (normală) depășit: **9 zile** (39%!)
- ▣ VaR 1% (Student- t) depășit: **5 zile** (22%)
- ▣ VaR 1% (EVT) depășit: **3 zile** (13%)

Covid (mar. 2020)

- ▣ 22 zile de tranzacționare
- ▣ VaR 1% (normală) depășit: **11 zile** (50%!)
- ▣ VaR 1% (Student- t) depășit: **7 zile** (32%)
- ▣ VaR 1% (EVT) depășit: **4 zile** (18%)

Lecții pentru practică

- ▣ Niciun model static nu funcționează perfect în criză (clusterizarea volatilității!)
- ▣ Modelele cu cozi groase **eșuează mai puțin grav**
- ▣ Soluție: GARCH cu inovații Student- t + recalibrare frecventă (fereastră mobilă)
- ▣ Basel III impune VaR **stresat** calibrat pe cea mai rea perioadă din ultimul an

Formularul VaR / ES — Toate distribuțiile

Model	VaR_α	ES_α
Normală (μ, σ)	$-\mu - \sigma \Phi^{-1}(\alpha)$	$-\mu + \sigma \frac{\phi(\Phi^{-1}(\alpha))}{\alpha}$
Student-t (μ, σ, ν)	$-\mu - \sigma \sqrt{\frac{\nu-2}{\nu}} t_\nu^{-1}(\alpha)$	$-\mu + \sigma \sqrt{\frac{\nu-2}{\nu}} \frac{f_\nu(t_\nu^{-1}(\alpha))}{\alpha} \frac{\nu + (t_\nu^{-1}(\alpha))^2}{\nu-1}$
Stabilă $(\alpha_s, \beta, \gamma, \delta)$	$-\delta - \gamma S_{\alpha_s, \beta}^{-1}(\alpha)$ (num.)	$-\delta + \gamma \frac{1}{\alpha} \int_0^\alpha S_{\alpha_s, \beta}^{-1}(p) dp$ (num.)
EVT-GPD (u, ξ, σ)	$u + \frac{\sigma}{\xi} \left[\left(\frac{n\alpha}{N_u} \right)^{-\xi} - 1 \right]$	$\frac{\text{VaR}_\alpha}{1-\xi} + \frac{\sigma - \xi u}{1-\xi}$

Notății: Φ, ϕ = CDF/PDF normală; t_ν^{-1}, f_ν = cuantila/PDF Student-t; S^{-1} = cuantila stabilă; N_u = nr. depășiri, n = obs. totale.

GARCH — Intuiție


- ▣ Randamentele sunt necorelate dar **nu independente**: volatilitatea se schimbă în timp
- ▣ **GARCH(1,1)**: varianța depinde de șocurile trecute și varianța trecută:

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

- ▣ α : reacția la șocuri; β : persistență; $\alpha + \beta < 1$: staționaritate
- ▣ După filtrarea GARCH, reziduurile standardizate $z_t = \epsilon_t / \sigma_t$ sunt aproximativ i.i.d.
- ▣ Dar z_t arată încă **exces de kurtosis** $\Rightarrow$ se folosesc inovații Student- t sau Student- t asimetrică

GARCH cu inovații non-Gaussiene

- ▣ **GARCH- t :** $r_t = \mu + \sigma_t z_t$, $z_t \sim t_\nu$
- ▣ Surprinde simultan clusterizarea volatilității și cozile groase
- ▣ **GARCH asimetric:**
 - ▶ GJR-GARCH: $\sigma_t^2 = \omega + (\alpha + \gamma 1_{\epsilon_{t-1} < 0})\epsilon_{t-1}^2 + \beta\sigma_{t-1}^2$
 - ▶ EGARCH: $\ln \sigma_t^2 = \omega + \alpha|z_{t-1}| + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$
- ▣ $\gamma > 0$ în GJR sau $\gamma < 0$ în EGARCH surprinde **efectul de levier**



Mixturi Gaussiene și schimbarea de regim


Mixturi Gaussiene

$$f(x) = \sum_{k=1}^K \pi_k \phi(x; \mu_k, \sigma_k^2)$$

- $K = 2$: regim calm (σ_1 mic) + criză (σ_2 mare); EM


Schimbarea de regim Hamilton (1989)

- Lanț Markov latent $s_t \in \{1, 2\}$; $r_t | s_t \sim N(\mu_{s_t}, \sigma_{s_t}^2)$
- Probabilitățile de tranziție estimate prin MLE



 SFM_ch2_modern_extensions

Clasificarea regimurilor



 SFM_ch2_modern_extensions

- ▣ Probabilitatea netedă de a fi în regimul de „criză” (2001, 2008–2009, 2020)
- ▣ Schimbarea de regim surprinde riscul de coadă variabil în timp

Volatilitate stochastică și difuzii cu salturi

- ▣ **Volatilitate stochastică:**

$$d \ln \sigma_t^2 = \kappa(\theta - \ln \sigma_t^2) dt + \sigma_v dW_t^\nu$$

cu $\text{Corr}(dW_t, dW_t^\nu) = \rho$ (levier)

- ▣ **Difuzie cu salturi** (Merton, 1976):

$$dS/S = \mu dt + \sigma dW + J dN_t$$

unde N_t este un proces Poisson, $J \sim N(\mu_J, \sigma_J^2)$

- ▣ Kou (2002): salturi dublu-exponențiale pentru tratabilitate analitică
- ▣ Aceste modele generează simultan cozi groase și clusterizarea volatilității

Modele conduse de procese Lévy

- ▣ **Modelul BNS** (Barndorff-Nielsen & Shephard, 2001):

$$dX_t = (\mu + \beta\sigma_t^2) dt + \sigma_t dW_t, \quad d\sigma_t^2 = -\lambda\sigma_t^2 dt + dL_{\lambda t}$$

unde L_t este un subordonator (proces Lévy crescător)

- ▣ **GARCH cu inovații stabile:** Mittnik & Rachev (1993)
- ▣ **Volatilitate realizată:** $RV_t = \sum_{i=1}^M r_{t,i}^2$ (frecvență înaltă)
- ▣ GARCH integrat fracționar (FIGARCH) pentru memoria lungă în volatilitate

Măsuri realizate și microstructură

- ▣ **Varianța realizată:** $RV_t = \sum_{i=1}^M r_{t,i}^2 \xrightarrow{P} \int_0^1 \sigma_s^2 ds$ când $M \rightarrow \infty$
- ▣ **Zgomot de microstructură:** la frecvențe foarte înalte, săritura bid-ask distorsionează RV
- ▣ **Corecții:** subeșantionare, estimatori kernel (Barndorff-Nielsen et al., 2008)
- ▣ **Detectarea salturilor:** variația bipower separă componentele continuă și de salt
- ▣ Distribuția randamentelor *condiționată de volatilitatea realizată* este mai aproape de Gaussiană (deformarea timpului)

Exemplu GARCH(1,1) — Calcul pas cu pas

Exercițiu

Un model GARCH(1,1) estimat pe randamentele zilnice S&P 500 dă: $\omega = 0,00001$, $\alpha = 0,09$, $\beta = 0,90$. Calculați varianța necondiționată, persistența și timpul de înjumătățire.

Rezolvare

1. **Persistență:** $\alpha + \beta = 0,99 < 1$ ✓ (staționaritate)
2. **Varianța necondiționată:** $\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta} = \frac{0,00001}{0,01} = 0,001 \Rightarrow \bar{\sigma} = 3,16\%$
3. **Half-life:** $h = \frac{\ln 2}{\ln(1/0,99)} = \frac{0,693}{0,01005} \approx 69$ zile (≈ 3 luni)

Observație 4

- Un șoc de volatilitate se reduce la jumătate abia după ≈ 69 zile de tranzacționare

Concluzii cheie

Rezumat

- ▣ **Randamentele financiare nu sunt normale:** cozi groase (*heavy tails*), asimetrie, clusterizarea volatilității
- ▣ **Student-*t*:** cel mai simplu model cu cozi groase, surprinde excesul de kurtosis
- ▣ **Distribuții stabile:** motivate teoretic (TLCG), varianță infinită posibilă
- ▣ **EVT:** cadru riguros pentru modelarea cozilor extreme
- ▣ **VaR și ES:** alegerea distribuției afectează direct măsurarea riscului
 - ▶ $\text{VaR } 1\% \text{ sub Normală} \ll \text{VaR } 1\% \text{ sub Student-}t \ll \text{VaR } 1\% \text{ sub Stabilă}$
- ▣ **Nu există un singur model cel mai bun:** alegerea depinde de aplicație

Formule importante

Distribuții cheie

- ▣ **Normală:** $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$
- ▣ **Student-t:** $\kappa_e = 6/(\nu - 4)$ pentru $\nu > 4$
- ▣ **Stabilă:** $\varphi(t) = \exp\{i\delta t - \gamma|t|^\alpha[1 + i\beta\text{sgn}(t)\omega]\}$

Măsurile de risc

- ▣ **VaR:** $P(X \leq -\text{VaR}_\alpha) = \alpha$
- ▣ **ES:** $\mathbb{E}[-X \mid X \leq -\text{VaR}_\alpha]$
- ▣ **GPD:** $G_{\xi,\sigma}(y) = 1 - (1 + \xi y/\sigma)^{-1/\xi}$

Criterii de selecție

- ▣ **AIC:** $-2\ell + 2k$
- ▣ **BIC:** $-2\ell + k \ln n$
- ▣ **QQ:** grafic cuantilă-cuantilă

Fapte stilizate

- ▣ Exces de kurtosis > 0
- ▣ Asimetrie negativă
- ▣ Clusterizarea volatilității
- ▣ $|r_t|$ autocorelat

Teme pentru acasă

Anul 3

1. Descărcați 5 ani de prețuri zilnice pentru o acțiune. Calculați log-randamentele, momentele eșantionului și testați normalitatea (Jarque–Bera).
2. Ajustați distribuțiile normală și Student- t prin MLE. Comparați prin AIC/BIC și grafice QQ.
3. Calculați VaR 1% și VaR 0,1% sub ambele modele pentru un portofoliu de \$1M.

Master

4. Ajustați Student- t asimetrică Hansen și calculați ES la nivelul de 1%.
5. Efectuați un backtest VaR cu fereastră mobilă (250 zile) și aplicați testul Kupiec.

Teme avansate

6. Ajustați o distribuție stabilă pe datele voastre folosind MLE. Raportați $(\hat{\alpha}, \hat{\beta}, \hat{\gamma}, \hat{\delta})$.
7. Aplicați metoda POT: selectați pragul, ajustați GPD, calculați VaR 1% și ES bazate pe EVT.
8. Comparați toate modelele (normală, Student- t , Student- t asim., stabilă, EVT) într-un tabel rezumativ.

Master:

9. Implementați estimatorul Hill. Creați un grafic Hill și discutați compromisul bias-varianță.
10. Ajustați un model GARCH(1,1)- t . Comparați distribuția reziduurilor standardizate cu distribuția necondiționată a randamentelor.

Direcții de cercetare

■ Întrebări deschise:

- ▶ Indicele real de coadă al randamentelor financiare este mai aproape de $\alpha \approx 3$ (varianță finită) sau $\alpha \approx 1,7$ (varianță infinită)?
- ▶ Cum ar trebui să agregăm riscul când distribuțiile au varianță infinită?
- ▶ Poate învățarea automată să îmbunătățească previziunea distribuțională?

■ Lecturi recomandate:

- ▶ Cont (2001): „Empirical properties of asset returns: stylized facts and statistical issues”
- ▶ McNeil, Frey & Embrechts (2015): *Quantitative Risk Management*
- ▶ Nolan (2020): *Stable Distributions — Models for Heavy Tailed Data*
- ▶ Rachev (2003): *Handbook of Heavy Tailed Distributions in Finance*

Întrebarea 1

Întrebare

- ▣ Evenimentul din 19 octombrie 1987 (S&P 500 $-20,5\%$) corespunde unui eveniment de $\sim 20\sigma$ sub ipoteza normală ($\sigma \approx 1\%$). Care este probabilitatea unui astfel de eveniment?

Variante de răspuns

- (A) $\approx 10^{-2}$ (1 la 100)
- (B) $\approx 10^{-30}$ (practic imposibil pe orizontul uman)
- (C) $\approx 10^{-89}$ (imposibil în durata de viață a universului)
- (D) $\approx 10^{-6}$ (o dată la un milion de zile)

Întrebarea 1: Răspuns

Răspuns: (C)

- ▣ Sub distribuția normală ($\sigma \approx 1\%$), un eveniment de $\sim 20\sigma$ are probabilitatea $\approx 10^{-89}$.
- ▣ Și totuși s-a întâmplat — aceasta demonstrează **inadecvarea distribuției normale** pentru evenimente extreme.
- ▣ Sub distribuții cu cozi groase (Student- t , stabilă), astfel de evenimente au probabilități mult mai mari.
- ▣ Aceasta este motivația principală pentru studierea distribuțiilor alternative.

Întrebarea 2

Întrebare

☐ O distribuție Student- t cu $\nu = 4$ grade de libertate are:

Variante de răspuns

- (A) Medie finită, varianță finită, kurtosis finită
- (B) Medie finită, varianță finită, kurtosis infinită
- (C) Medie finită, varianță infinită, kurtosis infinită
- (D) Medie infinită, varianță infinită, kurtosis infinită

Întrebarea 2: Răspuns

Răspuns: (B)

- ▣ Pentru Student- t : media există dacă $\nu > 1$, varianța dacă $\nu > 2$, kurtosis dacă $\nu > 4$.
- ▣ Cu $\nu = 4$: media finită (✓), varianță finită ($= \nu/(\nu - 2) = 2$, ✓), dar kurtosis-ul **nu există** (momentul de ordin 4 diverge: $6/(\nu - 4)$ cu $\nu = 4$).
- ▣ (A) este greșit: momentul de ordin 4 nu există la $\nu = 4$ exact.
- ▣ Aceasta arată că și distribuțiile cu varianță finită pot avea cozi **foarte groase**.

Întrebarea 3

Întrebare

- ☐ Un portofoliu de \$10M are VaR zilnic la 1% de: \$230k (normală), \$380k (Student- t , $\nu = 5$), \$520k (stabilă, $\alpha = 1,7$). Ce concluzie trageți?

Variante de răspuns

- (A) Distribuția normală este cea mai conservatoare
- (B) Alegerea distribuției nu afectează semnificativ VaR
- (C) Subestimarea riscului de coadă sub ipoteza normală poate fi de $2\times$ sau mai mult
- (D) Distribuția stabilă subestimează întotdeauna riscul

Întrebarea 3: Răspuns

Răspuns: (C)

- ▣ VaR normală = \$230k, VaR stabilă = \$520k $\Rightarrow$ raportul este $520/230 \approx 2,3\times$.
- ▣ Distribuția normală **subestimează** riscul, nu este conservatoare (elimină A).
- ▣ Diferența de \$290k ($= 520 - 230$) este **foarte semnificativă** din perspectiva capitalului (elimină B).
- ▣ Aceasta demonstrează de ce Basel III impune modele cu cozi groase.

Întrebarea 4

Întrebare

□ În metoda Peaks-Over-Threshold (POT), ce distribuție se ajustează pe excesele peste prag?

Variante de răspuns

- (A) Distribuția normală
- (B) Distribuția Pareto generalizată (GPD)
- (C) Distribuția exponențială
- (D) Distribuția GEV (Generalized Extreme Value)

Întrebarea 4: Răspuns

Răspuns: (B)

- ☐ Teorema Pickands–Balkema–de Haan arată că excesele peste un prag u suficient de mare converg la GPD.
- ☐ (A) este inadecvată: distribuția normală nu modelează cozile extreme.
- ☐ (C) este un caz particular: GPD cu $\xi = 0$ este exponențială, dar este prea restrictivă.
- ☐ (D) este pentru metoda Block Maxima, nu POT. GEV se ajustează pe maximele pe blocuri.

Întrebarea 5

Întrebare

- ☐ Modelul A are $AIC = 5200$ și modelul B are $AIC = 5180$ pe aceleași date. Ce concluzie este corectă?

Variante de răspuns

- (A) Modelul A este mai bun (AIC mai mare)
- (B) Modelul B este mai bun (AIC mai mic = mai bun)
- (C) Nu putem compara fără BIC
- (D) Diferența nu este semnificativă

Întrebarea 5: Răspuns

Răspuns: (B)

- ▣ $AIC = -2\ell + 2k$: valori mai mici indică un echilibru mai bun între ajustare și complexitate.
- ▣ $\Delta AIC = 5200 - 5180 = 20 > 10$, ceea ce indică o preferință **puternică** pentru modelul B.
- ▣ (A) confundă direcția: AIC mai mic este mai bun.
- ▣ (C) este greșit: AIC singur este suficient pentru comparare, BIC oferă o perspectivă complementară.

Exercițiul 1: Log-randamente și momente

Enunț

Se dau prețurile zilnice de închidere:

t	0	1	2	3	4
P_t	100	103	98	95	102

1. Calculați log-randamentele $r_t = \ln(P_t/P_{t-1})$ pentru $t = 1, \dots, 4$.
2. Calculați media, varianța, asimetria și kurtosis eșantionului.
3. Aplicați testul Jarque-Bera: $JB = \frac{n}{6} \left(S^2 + \frac{(K-3)^2}{4} \right)$. Se respinge normalitatea la 5%?
4. Calculați log-randamentul total pe 4 perioade. Verificați aditivitatea temporală.

Exercițiul 2: Distribuția normală și VaR

Enunț

Un portofoliu de \$5M are randamente zilnice $\sim N(\mu, \sigma^2)$ cu $\hat{\mu} = 0,04\%$ și $\hat{\sigma} = 1,2\%$.

1. Calculați VaR zilnic la nivelurile 5%, 1% și 0,1%.
2. Calculați Expected Shortfall la nivelul 1%.
3. Un eveniment de -4% a avut loc. Ce probabilitate are sub ipoteza normală?
4. Argumentați de ce VaR normal poate subestima riscul real.

Indiciu

$\text{VaR}_\alpha = -(\mu + z_\alpha \cdot \sigma)$, unde $z_{0,05} = -1,645$, $z_{0,01} = -2,326$, $z_{0,001} = -3,090$.

Exercițiul 3: Student- t — Ajustare și comparație

Enunț

Pe datele de la Exercițiul 1, presupuneți că MLE produce: distribuția normală $\ell = 12,5$, Student- t ($\nu = 5$) $\ell = 14,8$.

1. Calculați AIC și BIC pentru ambele modele ($k_N = 2$, $k_t = 3$, $n = 4$).
2. Care model este preferat de AIC? Dar de BIC?
3. Calculați excesul de kurtosis al distribuției Student- t cu $\nu = 5$.
4. Explicați de ce Student- t captează mai bine cozile groase decât distribuția normală.

Formule

$$\text{AIC} = -2\ell + 2k, \quad \text{BIC} = -2\ell + k \ln n, \quad \kappa = 6/(\nu - 4) \text{ pentru } \nu > 4.$$

Exercițiul 4: EVT — Metoda POT

Enunț

Dintr-un eșantion de 1000 de randamente zilnice, 50 depășesc pragul $u = 2,5\%$ în valoare absolută. GPD ajustată: $\hat{\xi} = 0,3$, $\hat{\sigma} = 0,8\%$.

1. Calculați VaR la nivelul 1% folosind formula POT:

$$\text{VaR}_{\alpha} = u + \frac{\hat{\sigma}}{\hat{\xi}} \left[\left(\frac{n}{N_u} \cdot \alpha \right)^{-\hat{\xi}} - 1 \right]$$

2. Calculați Expected Shortfall: $\text{ES}_{\alpha} = \frac{\text{VaR}_{\alpha}}{1-\hat{\xi}} + \frac{\hat{\sigma}-\hat{\xi} \cdot u}{1-\hat{\xi}}$
3. Ce semnifică $\hat{\xi} > 0$? Ce clasă de distribuții implică?
4. Cum influențează alegerea pragului u calitatea estimării?

Exercițiul 5: Comparația distribuțiilor

Enunț

Se dau rezultatele ajustării pe randamente S&P 500 (10 ani, zilnice, $n = 2516$):

Model	k	ℓ	AIC	BIC
Normal	2	7890	-15,776	-15,764
Student- t	3	8120	-16,234	-16,216
Skew- t	4	8135	-16,262	-16,239
Stabilă	4	8095	-16,182	-16,159

1. Verificați formulele AIC și BIC pentru modelul normal.
2. Care model este preferat de AIC? Dar de BIC?
3. De ce Skew- t câștigă deși are mai mulți parametri?
4. Stabilă are AIC mai slab decât Student- t . Înseamnă că este un model inferior? Discutați.

Exercițiul 6: VaR sub diferite distribuții

Enunț

Un portofoliu de \$1M. Randamente zilnice cu $\hat{\mu} = 0,03\%$, $\hat{\sigma} = 1,5\%$.

1. Calculați VaR 1% sub ipoteza **normală**.
2. Sub Student- t ($\nu = 5$): $\text{VaR}_{1\%}^t = -\mu + \hat{\sigma} \sqrt{(\nu - 2)/\nu} \cdot t_{0,01;\nu}$.
► Folosiți $t_{0,01;5} = -3,365$.
3. Calculați raportul $\text{VaR}^t/\text{VaR}^N$. Interpretați.
4. Un backtest pe 1000 de zile arată 18 depășiri VaR sub distribuția normală. Este acceptabil la nivelul 1%? (Testul Kupiec: se așteaptă ~ 10 depășiri.)

Exercițiul 7: Expected Shortfall

Enunț

Continuare de la Exercițiul 6. Sub ipoteza normală cu $\mu = 0$ și $\sigma = 1,5\%$:

1. Calculați ES la nivelul 1%: $ES_{0,01} = \sigma \cdot \frac{\phi(z_{0,01})}{0,01}$ unde ϕ este densitatea normală standard și $z_{0,01} = -2,326$.
2. Calculați raportul ES/VaR. Interpretați.
3. De ce ES este considerată o măsură de risc **superioară** VaR? (Menționați subaditivitatea și coerența.)
4. Sub ce cadru regulamentar (Basel II.5 sau Basel III) este ES măsura principală?

Exercițiul 8: Backtesting VaR

Enunț

Un model VaR 1% produce următoarele rezultate pe 500 de zile de tranzacționare:

Model	Depășiri observate	Depășiri așteptate
Normal	12	5
Student- t	6	5
EVT (POT)	4	5

1. Aplicați testul Kupiec (LR) pentru fiecare model: $LR = -2 \ln \frac{\alpha^x (1-\alpha)^{n-x}}{\hat{p}^x (1-\hat{p})^{n-x}}$ cu $\hat{p} = x/n$.
2. Care model(e) trec testul la nivelul de semnificație 5%? ($\chi^2_{1; 0,05} = 3,84$)
3. Ce indică 12 depășiri sub modelul normal?

Exercițiul 9: Interpretare integrată

Enunț

Un activ financiar prezintă următorul profil distributional:

Indicator	Valoare
Asimetrie	-1,3
Exces de kurtosis	8,5
$\hat{\alpha}$ (stabilă)	1,75
$\hat{\nu}$ (Student- t)	4,2
Test JB (p -value)	$< 10^{-10}$

1. Descrieți profilul distributional al activului în 3–4 propoziții.
2. Ce implicații are $\hat{\alpha} = 1,75$ pentru existența varianței?
3. Ce model distributional ați recomanda pentru calculul VaR? Justificați.
4. Un regulator cere capital bazat pe VaR sub distribuția normală. De ce este aceasta o problemă?

Laborator Python — Exerciții interactive

Lab 1: Ajustarea distribuțiilor (Y3)

Deschideți `SFM_ch2_normal_distribution.ipynb`:

1. Descărcați date S&P 500 (2015–2025); calculați log-randamentele
2. Histogramă + suprapunere normală; testul Jarque–Bera
3. Ajustați Student- t (MLE). Comparați AIC cu modelul normal

 `SFM_ch2_normal_distribution`

Laborator Python — Exerciții avansate

Lab 2: EVT și backtesting (MSc)

Folosind `SFM_ch2_extreme_value.ipynb`:

1. Grafic Mean Excess; selectați prag u ; ajustați GPD $\Rightarrow (\hat{\xi}, \hat{\sigma})$
2. Calculați VaR 1% și ES 1% bazate pe EVT
3. Backtest VaR cu fereastră mobilă de 250 zile; testul Kupiec

 `SFM_ch2_extreme_value`

Lab 3: GARCH cu inovații non-Gaussiene (MSc)

Folosind `SFM_ch2_modern_extensions.ipynb`:

1. GARCH(1,1) cu inovații normale și Student- t ; comparați AIC
2. Reziduuri standardizate: sunt i.i.d.? VaR 1% condiționat pe 250 zile

 `SFM_ch2_modern_extensions`

Exercițiul 1: Rezolvare

Rezolvare

1. Log-randamente: $r_1 = \ln(103/100) = 0,0296$, $r_2 = \ln(98/103) = -0,0498$, $r_3 = \ln(95/98) = -0,0311$, $r_4 = \ln(102/95) = 0,0713$.

2. $\bar{r} = (0,0296 - 0,0498 - 0,0311 + 0,0713)/4 = 0,0050$; $s^2 = \frac{1}{3} \sum (r_i - \bar{r})^2 = 0,00253$; $s = 0,0503$.

Asimetrie: $S = \frac{n}{(n-1)(n-2)} \sum \left(\frac{r_i - \bar{r}}{s}\right)^3 \approx 0,56$; Kurtosis: $K \approx 1,72$.

3. $JB = \frac{4}{6}(0,56^2 + (1,72 - 3)^2/4) = 0,21 + 0,27 = 0,48$. Cu $\chi^2_2(0,05) = 5,99$: $0,48 < 5,99 \Rightarrow$ **nu respingem** normalitatea (eșantion prea mic!).

4. $r_{0:4} = \ln(102/100) = 0,0198 = r_1 + r_2 + r_3 + r_4 = 0,0198 \checkmark$

Exercițiul 2: Rezolvare

Rezolvare

Date: $\mu = 0,0004$, $\sigma = 0,012$, portofoliu \$5M.

1. $\text{VaR}_\alpha = -(\mu + z_\alpha \sigma) \times W$

▣ VaR 5%: $-(0,0004 + (-1,645)(0,012)) \times 5\text{M} = 0,01934 \times 5\text{M} = \96.680

▣ VaR 1%: $-(0,0004 + (-2,326)(0,012)) \times 5\text{M} = 0,02751 \times 5\text{M} = \137.560

▣ VaR 0,1%: $-(0,0004 + (-3,090)(0,012)) \times 5\text{M} = 0,03668 \times 5\text{M} = \183.400

2. $\text{ES}_{1\%} = \sigma \cdot \phi(-2,326)/0,01 = 0,012 \times 0,02665/0,01 = 0,03198 \Rightarrow \159.900

3. $P(r < -0,04) = \Phi\left(\frac{-0,04 - 0,0004}{0,012}\right) = \Phi(-3,37) \approx 0,038\%$ (1 zi în ~ 2.600)

4. Empiric, evenimentele $> 3\sigma$ apar mult mai frecvent $\Rightarrow$ VaR sub distribuția normală subestimează riscul.

Exercițiul 3: Rezolvare

Rezolvare

Date: $\ell_N = 12,5$, $\ell_t = 14,8$, $k_N = 2$, $k_t = 3$, $n = 4$.

1.

▣ Distribuția normală: $AIC = -2(12,5) + 2(2) = -21,0$; $BIC = -25 + 2 \ln 4 = -25 + 2,77 = -22,23$

▣ Student- t : $AIC = -2(14,8) + 2(3) = -23,6$; $BIC = -29,6 + 3 \ln 4 = -29,6 + 4,16 = -25,44$

2. Student- t câștigă pe ambele criterii ($AIC: -23,6 < -21,0$; $BIC: -25,44 < -22,23$).

3. Exces de kurtosis: $\kappa = 6/(\nu - 4) = 6/(5 - 4) = 6$. Kurtosis totală: $3 + 6 = 9$.

4. PDF-ul Student- t scade ca $|x|^{-(\nu+1)}$ (lege putere) vs. $e^{-x^2/2}$ pentru distribuția normală. Decăderea mai lentă alocă mai multă probabilitate în cozi.

Exercițiul 4: Rezolvare

Rezolvare

Date: $n = 1000$, $N_u = 50$, $u = 0,025$, $\hat{\xi} = 0,3$, $\hat{\sigma} = 0,008$, $\alpha = 0,01$.

1. VaR POT:

$$\text{VaR}_{0,01} = 0,025 + \frac{0,008}{0,3} \left[\left(\frac{1000}{50} \cdot 0,01 \right)^{-0,3} - 1 \right] = 0,025 + 0,02667 [0,2^{-0,3} - 1]$$

$$0,2^{-0,3} = e^{0,3 \times 1,6094} = e^{0,4828} = 1,6202; \text{ VaR} = 0,025 + 0,02667 \times 0,6202 = 0,0415 = 4,15\%$$

$$2. \text{ ES: } \text{ES}_{0,01} = \frac{0,0415}{1-0,3} + \frac{0,008-0,3 \times 0,025}{1-0,3} = 0,0593 + 0,0007 = 6,00\%$$

3. $\hat{\xi} > 0 \Rightarrow$ domeniul Fréchet: cozi tip lege putere (cozi groase). Distribuția GPD are suport infinit.

4. Prag prea jos: bias (multe date non-extreme); prag prea sus: varianță mare (puține date). Se alege u prin graficul Mean Excess.

Exercițiul 5: Rezolvare

Rezolvare

1. Distribuția normală: $AIC = -2(7890) + 2(2) = -15.776 \checkmark$; $BIC = -2(7890) + 2 \ln(2516) = -15.780 + 2(7,83) = -15.764 \checkmark$
2. AIC minim: Skew- t (-16.262). BIC minim: Skew- t (-16.239). Skew- t câștigă pe ambele.
3. Deși Skew- t are 4 parametri (vs. 3 pentru Student- t), $\Delta AIC = -16.262 - (-16.234) = 28$, dovadă puternică (> 10) că parametrul suplimentar de asimetrie îmbunătățește semnificativ ajustarea.
4. Stabilă ($\Delta AIC = 52$ față de Skew- t) este mai slabă pe AIC/BIC, dar aceasta nu o face inferioară per se:
 - ▣ Stabilă are fundament teoretic superior (închisă la sumă, TLC generalizat)
 - ▣ Poate fi superioară pentru cuantile extreme ($< 0,1\%$) unde AIC/BIC nu discriminează
 - ▣ AIC/BIC evaluează ajustarea globală, nu calitatea cozilor

Exercițiul 6: Rezolvare

Rezolvare

Date: $W = \$1M$, $\mu = 0,0003$, $\sigma = 0,015$.

1. VaR sub distribuția normală 1%: $-(\mu + z_{0,01}\sigma) = -(0,0003 + (-2,326)(0,015)) = 0,0346 \Rightarrow \34.590

2. VaR Student- t 1%: $-\mu + \sigma\sqrt{(\nu-2)/\nu} \cdot |t_{0,01;5}| = -0,0003 + 0,015\sqrt{3/5} \cdot 3,365$
 $= -0,0003 + 0,015 \times 0,7746 \times 3,365 = 0,0388 \Rightarrow \38.810

3. Raport: $38.810/34.590 = 1,12$ (Student- t produce VaR cu 12% mai mare).

4. 18 depășiri pe 1000 zile $\Rightarrow \hat{p} = 1,8\%$ vs. așteptat 1%. Testul Kupiec:

$LR = -2 \ln \frac{0,01^{18} \cdot 0,99^{982}}{0,018^{18} \cdot 0,982^{982}} = 7,35 > 3,84 \Rightarrow \text{respins: modelul normal subestimează riscul.}$

Exercițiul 7: Rezolvare

Rezolvare

Date: $\mu = 0$, $\sigma = 0,015$, $z_{0,01} = -2,326$, $\phi(-2,326) = 0,02665$.

1. $ES_{0,01} = 0,015 \times \frac{0,02665}{0,01} = 0,03998 \approx 4,00\% \Rightarrow \39.975

2. $VaR_{1\%} = 0,015 \times 2,326 = 0,03489 = 3,49\%$. Raport: $ES/VaR = 4,00/3,49 = 1,146$. ES este cu 14,6% mai mare decât VaR.

3. ES este **superioară** deoarece:

- ▣ Este **subaditivă**: $ES(X + Y) \leq ES(X) + ES(Y)$ (diversificarea reduce riscul)
- ▣ Este măsură **coerentă** de risc (Artzner et al., 1999)
- ▣ Informează despre gravitatea pierderilor dincolo de VaR

4. Basel III (FRTB, 2019) adoptă ES la 97,5% ca măsură principală, înlocuind VaR 99%.

Exercițiul 8: Rezolvare

Rezolvare

Date: VaR 1%, $n = 500$, depășiri așteptate: $500 \times 0,01 = 5$.

1. Testul Kupiec: $LR = -2 \ln \frac{0,01^x (0,99)^{500-x}}{(x/500)^x (1-x/500)^{500-x}}$

□ Distribuția normală ($x = 12$): $\hat{p} = 0,024$. $LR = -2 \ln \frac{0,01^{12} \cdot 0,99^{488}}{0,024^{12} \cdot 0,976^{488}} = 7,96$

□ Student- t ($x = 6$): $\hat{p} = 0,012$. $LR = -2 \ln \frac{0,01^6 \cdot 0,99^{494}}{0,012^6 \cdot 0,988^{494}} = 0,30$

□ EVT ($x = 4$): $\hat{p} = 0,008$. $LR = -2 \ln \frac{0,01^4 \cdot 0,99^{496}}{0,008^4 \cdot 0,992^{496}} = 0,23$

2. $\chi^2_{1;0,05} = 3,84$. Distribuția normală: $7,96 > 3,84 \Rightarrow$ **respins**. Student- t : $0,30 \checkmark$. EVT: $0,23 \checkmark$.

3. 12 depășiri (vs. 5 așteptate) = rata empirică de 2,4% (de $2,4 \times$ mai mare). Modelul normal subestimează sistematic riscul de coadă.

Exercițiul 9: Rezolvare

Rezolvare

1. Profilul distributional: Activul prezintă cozi groase (kurtosis = $8,5 \gg 3$), asimetrie negativă ($S = -1,3$, coada stângă mai grea), și deviație extremă de la normalitate ($JB \ p < 10^{-10}$). Randamentele nu pot fi modelate adecvat de distribuția normală.
2. $\hat{\alpha} = 1,75 < 2 \Rightarrow$ sub modelul stabil, varianța este **infinită**. Doar momentele de ordin $p < 1,75$ există. Volatilitatea eșantionului nu converge la o valoare fixă.
3. Recomandare: **Student- t asimetrică (Hansen)** deoarece:
 - ▣ Captează atât cozile groase ($\hat{\nu} = 4,2$) cât și asimetria ($S < 0$)
 - ▣ Varianță finită ($\nu > 2$) — permite calculul VaR/ES standard
 - ▣ Ușor de integrat cu modele GARCH
4. VaR sub distribuția normală subestimează drastic: la 1%, diferența poate fi de 25–40%, iar la 0,1% poate ajunge la 100–150%. Regulatorul impune capital insuficient $\Rightarrow$ risc sistemic.

Cuprins

- ▣ Teoria Valorilor Extreme ✓
- ▣ Comparația distribuțiilor ✓
- ▣ Copule și dependența de coadă ✓
- ▣ Managementul riscului ✓
- ▣ Extensii moderne ✓
- ▣ Rezumat / Quiz / Exerciții ✓

Criterii de evaluare — Exerciții și proiect

Grila de notare (aplicabilă la examen și proiect)

Nivel	Calcul	Interpretare
9–10	Formule + calcule corecte, complete	Leagă de decizia de business
7–8	Formule corecte, erori minore	Interpretare corectă, superficială
5–6	Formula corectă, greșeli de aplicare	Repetă definiția fără context
<5	Formula greșită sau lipsă	Fără interpretare

Pondere evaluare

▣ Examen scris: 70% Proiect individual: 20% Participare activă: 10%

Lectură recomandată pe nivele

Y3 — Lectură minimă

- ▣ McNeil et al. (2015), Cap. 2.3–2.4; Cont (2001), §4–6; exercițiile 1–4 din curs

— Lectură suplimentară

- ▣ + Embrechts et al. (1997), Cap. 3–7 (EVT); Nelsen (2006), Cap. 2–3 (copule); exercițiile 5–7 și studiul de caz

PhD — Lectură avansată

- ▣ + de Haan & Ferreira (2006); McNeil et al. (2015), Cap. 7 (copule); slide-urile Anexă și exercițiile 8–9

Bilet de ieșire (*Exit Ticket*)*(1 minut)*

Completați înainte de a pleca (anonim, pe hârtie sau online)

1. **Un lucru clar:** Ce concept din cursul de azi ați înțeles cel mai bine?
2. **Un lucru neclar:** Ce concept necesită mai multă clarificare?
3. **O întrebare:** Ce întrebare ați dori să explorați mai departe?

De ce facem acest exercițiu?

- ☐ Răspunsurile anonime ajustează conținutul **următorului curs**
- ☐ Cercetările arată că reflecția imediat după curs crește retenția cu 20–40% (Roediger & Butler, 2011)

Bibliografie I

Manuale de referință

- ▣ McNeil, A., Frey, R. & Embrechts, P. (2015). *Quantitative Risk Management*. Princeton University Press.
- ▣ Nolan, J. P. (2020). *Stable Distributions — Models for Heavy Tailed Data*. Birkhäuser.
- ▣ Rachev, S. T. (2003). *Handbook of Heavy Tailed Distributions in Finance*. Elsevier.

Articole fundamentale

- ▣ Mandelbrot, B. (1963). The Variation of Certain Speculative Prices. *Journal of Business*, 36(4), 394–419.
- ▣ Fama, E. (1965). The Behavior of Stock-Market Prices. *Journal of Business*, 38(1), 34–105.
- ▣ Cont, R. (2001). Empirical Properties of Asset Returns. *Quantitative Finance*, 1(2), 223–236.

Bibliografie II

Distribuții și estimare

- Hansen, B. (1994). Autoregressive Conditional Density Estimation. *International Economic Review*, 35(3), 705–730.
- Nolan, J. P. (1997). Numerical Calculation of Stable Densities and Distribution Functions. *Stochastic Models*, 13(4), 759–774.
- Barndorff-Nielsen, O. (1977). Exponentially Decreasing Distributions for the Logarithm of Particle Size. *Proc. Royal Society A*, 353, 401–419.

Modele dinamice

- Hamilton, J. D. (1989). A New Approach to the Economic Analysis of Nonstationary Time Series. *Econometrica*, 57(2), 357–384.
- Merton, R. (1976). Option Pricing When Underlying Stock Returns Are Discontinuous. *J. of Financial Economics*, 3, 125–144.
- Barndorff-Nielsen, O. & Shephard, N. (2001). Non-Gaussian Ornstein–Uhlenbeck-Based Models. *JRSS B*, 63(2), 167–241.

Bibliografie III

Testare și selecție de modele

- ▣ Vuong, Q. H. (1989). Likelihood Ratio Tests for Model Selection and Non-Nested Hypotheses. *Econometrica*, 57(2), 307–333.
- ▣ Fissler, T. & Ziegel, J. F. (2016). Higher Order Elicitability and Osband's Principle. *Annals of Statistics*, 44(4), 1680–1707.

Resurse online și cod

- ▣ **Quantlet:** <https://quantlet.com> > Platformă de cod pentru metode cantitative
- ▣ **Quantinar:** <https://quantinar.com> > Platformă de învățare pentru metode cantitative
- ▣ **GitHub SFM:** https://github.com/QuantLet/Stat_fin_markets/tree/master/Ch_02 > Cod Python capitol 2

Bibliografie IV

Referințe recente (2020–2025)

- Kelly, B., Jiang, H. & Pruitt, S. (2022). Tail Risk and Asset Prices. *Review of Financial Studies*, 35(5), 2254–2295.
- Bollerslev, T. & Todorov, V. (2023). The Jump Tails of Asset Returns. *Econometrica* (forthcoming).
- Aas, K., Czado, C., Frigessi, A. & Bakken, H. (2009). Pair-Copula Constructions of Multiple Dependence. *Insurance: Mathematics and Economics*, 44(2), 182–198.

Evenimente recente relevante

- **Covid-19 (mar. 2020)**: S&P 500 –12% într-o zi; al 3-lea cel mai rău eveniment din istorie
- **FTX/crypto (nov. 2022)**: Prăbușire de –65% în 48h; cozi groase extreme
- **SVB (mar. 2023)**: Contagiune bancară; risc de coadă în sectorul financiar
- **Lecția**: Modelele cu cozi groase sunt **esențiale**, nu opționale

Vă Mulțumim!

Întrebări?

Materialele cursului sunt disponibile la: <https://danpele.github.io/SFM/>



Quantlet



Quantinar