Statistică pe Piețe Financiare

Distribuții Stabile

Daniel Traian PELE
Antoaneta Amza

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

De ce studiem distribuțiile stabile?

- **Datele reale $\neq$ Gaussian**
  - Randamentele financiare, daunele din asigurări, datele de mediu prezintă cozi groase și asimetrie.
  - Încalcă ipotezele de varianță finită și de normalitate.
- **Motivație teoretică**
  - Apar ca legi limită în cadrul Teoremei Limită Centrale Generalizate (TLCG).
  - Păstrează forma distribuțională sub adunare și scalare.
- **Importanță practică**
  - Modelarea riscului, Teoria Valorilor Extreme (TVE), procesarea robustă a semnalelor.
  - Cadru unificator dincolo de distribuția Gaussiană.

De ce studiem distribuțiile stabile?

- **Structură matematică bogată**
  - Formulare elegantă prin funcții caracteristice.
  - Legături profunde cu analiza Fourier, procesele stochastice, geometria fractală.
- **Aplicații în diverse discipline**
  - *Finanțe*: Randamente cu cozi groase, VaR, testarea stresului.
  - *Fizică*: Zboruri Lévy, difuzie anormală.
  - *Procesarea semnalelor*: Zgomot impulsiv, modelarea clutter-ului.

Cuprins

1. Motivație ✓
2. Introducere
3. Definiție
4. Proprietăți
5. Exemple
6. Parametrizare
7. Estimare
8. Simulare
9. Concluzii și teme
10. Bibliografie

Distribuții stabile

- O clasă de distribuții de probabilitate închise sub convoluție (adică, sumarea variabilelor i.i.d.).
- Include distribuția Gaussiană ca un caz special ($\alpha = 2$).
- Permite asimetrie ($\beta \neq 0$) și cozi groase ($\alpha < 2$).
- Definite prin funcția caracteristică, deoarece cele mai multe nu au densități în formă închisă.
- Aplicații în modelarea:
  - Evenimentelor rare/extreme.
  - Fenomenelor auto-similare și fractale.
  - Sistemelor fără varianță finită sau momente de ordin superior.

Dezvoltare istorică

Anul	Contributor
1925	Paul Lévy
1938	A. Khintchine
1954	Gnedenko & Kolmogorov
1960s	B. Mandelbrot
1971	William Feller
1997–	John Nolan

Ce sunt distribuțiile stabile?

- O generalizare a familiei distribuției normale.
- Permit:
  - Cozi groase (variantă infinită).
  - Asimetrie.
- Definite prin stabilitate sub adunare:

$$aX_1 + bX_2 \stackrel{d}{=} cX + d$$

- Utilizate când modelele Gaussiene subestimează riscul de coadă.

Definirea stabilității

- O variabilă aleatoare X este **stabilă** dacă:

$$aX_1 + bX_2 \stackrel{d}{=} cX + d$$

  pentru orice $a, b > 0$, unde $X_1, X_2 \stackrel{\text{iid}}{\sim} X$.
- $c = (a^\alpha + b^\alpha)^{1/\alpha}$.
- Pentru distribuții α-stabile:
  - Această proprietate definește închiderea sub combinații liniare, fundamentală pentru stabilitatea distribuțională.
  - Deosebit de importantă în modelarea sumelor multor șocuri sau inovații mici și independente.

Teorema Limită Centrală Generalizată (TLCG)

- Fie X_i, $i = 1, \ldots, n$ variabile aleatoare i.i.d. cu o distribuție comună ce are cozi groase (adică, varianță infinită sau cozi cu descreștere lentă).
- Atunci, există șiruri de constante $c_n > 0$ și $d_n \in \mathbb{R}$ astfel încât:

$$\frac{\sum_{i=1}^{n} X_i - d_n}{c_n} \xrightarrow{d} X \sim S(\alpha, \beta, \gamma, \delta)$$

- **TLC clasică**: Converge la distribuția Gaussiană când varianța este finită ($\alpha = 2$).
- **TLCG**: Converge la o lege α-stabilă când varianța este infinită ($\alpha < 2$).
- **Implicație**:
  - Distribuțiile stabile generalizează comportamentul limită central al sumelor.
  - Fundament pentru modelarea sumelor de observații extreme sau cu cozi groase.
  - Baza modelelor stabile în risc și fenomene cu cozi groase.

Prezentarea generală a parametrizării

- O distribuție stabilă se notează:

$$S(\alpha, \beta, \gamma, \delta)$$

- α, $(0 < \alpha \leq 2)$: indicele de stabilitate sau exponentul de coadă.
- β, $(-1 \leq \beta \leq 1)$: parametrul de asimetrie.
- γ, $(\gamma > 0)$: parametrul de scală.
- δ, $(\delta \in \mathbb{R})$: parametrul de localizare.
- **Interpretare**:
  - $\alpha = 2$: distribuția normală.
  - $\beta = 0$: distribuție simetrică.
  - Un α mai mic implică cozi mai groase și existența momentelor de ordin inferior.

Efectele parametrilor

- α: Controlează grosimea cozilor; pe măsură ce $\alpha \to 0$, cozile devin extrem de groase.
- β: Ajustează asimetria; $\beta = -1$: coadă stângă grea; $\beta = 1$: coadă dreaptă grea.
- γ: Analog abaterii standard; scalează distribuția.
- δ: Controlează localizarea centrală; se comportă ca media când $\alpha > 1$.

Funcția de densitate de probabilitate (FDP)

- În general, distribuțiile stabile **nu** au densități în formă închisă, cu excepția cazurilor specifice (Gaussiană, Cauchy, Lévy).
- Densitatea poate fi calculată prin transformata Fourier inversă:

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \phi(t)\, dt$$

- **Tehnici numerice**:
  - Inversarea funcției caracteristice.
  - Transformata Fourier rapidă (FFT).
  - Dezvoltări în serie (de ex., formula lui Zolotarev).
- **Instrumente de calcul**: `pystable`, `levy_stable`, `libstable4u`, software-ul lui John Nolan.

Caz special – Distribuția Gaussiană

- Când $\alpha = 2$, distribuția stabilă devine normală:

$$X \sim N(\delta, 2\gamma^2)$$

- Funcția caracteristică:

$$\phi(t) = \exp(-\gamma^2 t^2 + i\delta t)$$

- Densitatea:

$$f(x) = \frac{1}{\sqrt{4\pi\gamma^2}} \exp\left(-\frac{(x-\delta)^2}{4\gamma^2}\right)$$

- Proprietăți:
  - Simetrică, cu cozi ușoare.
  - Toate momentele există.
  - Singura distribuție stabilă cu varianță finită.

Distribuții stabile: Gaussiană

SFM_ch2_stable_distributions

ch2_stable_distributions.png

Caz special – Distribuția Cauchy

- Când $\alpha = 1$, $\beta = 0$, obținem distribuția Cauchy:

$$X \sim \text{Cauchy}(\delta, \gamma)$$

- Densitatea:

$$f(x) = \frac{1}{\pi\gamma\left[1 + \left(\frac{x-\delta}{\gamma}\right)^2\right]}$$

- Proprietăți:
  - Simetrică, cu cozi groase.
  - Nu are medie, varianță sau momente de ordin superior.
  - Raportul a două variabile normale standard are distribuție Cauchy.

Distribuții stabile: Cauchy

SFM_ch2_stable_distributions

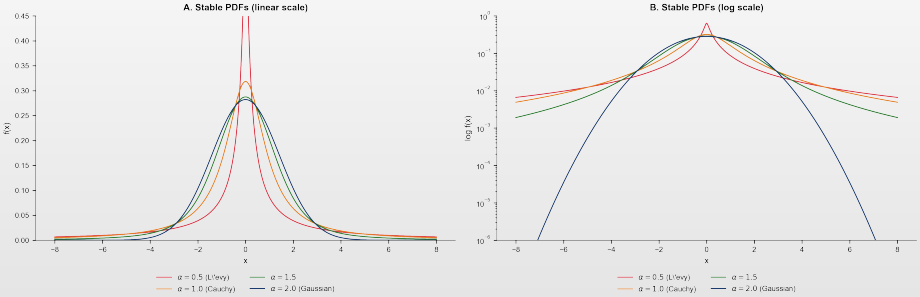

Comparație PDFs: Cauchy ($\alpha = 1.0$) prezintă cozi semnificativ mai grele decât Gaussiana ($\alpha = 2.0$).

Caz special – Distribuția Lévy

- Când $\alpha = 0.5$, $\beta = 1$, obținem distribuția Lévy:

$$X \sim S(0.5, 1, \gamma, \delta), \quad X > \delta$$

- Densitatea:

$$f(x) = \sqrt{\frac{\gamma}{2\pi}} \cdot \frac{e^{-\gamma/(2(x-\delta))}}{(x-\delta)^{3/2}}, \quad x > \delta$$

- Aplicații:
  - Timpii de primă trecere ai mișcării Browniene.
  - Teoria valorilor extreme.

Distribuții stabile: Lévy

SFM_ch2_stable_distributions

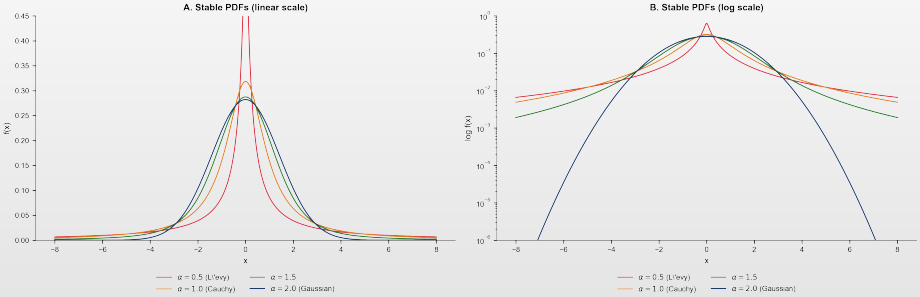

Lévy ($\alpha = 0.5$): cele mai grele cozi. Pe scară logaritmică (panoul B), diferența este evidentă.

Comportamentul cozilor distribuțiilor stabile

- Pentru $0 < \alpha < 2$, distribuțiile stabile prezintă cozi de tip lege de putere:

$$P(X > x) \sim C_\alpha(1+\beta)\,x^{-\alpha}, \qquad P(X < -x) \sim C_\alpha(1-\beta)\,x^{-\alpha}$$

- $C_\alpha = \dfrac{1-\alpha}{\Gamma(2-\alpha)\cos(\pi\alpha/2)}$.
- Cu cât α este mai mic, cu atât cozile sunt mai groase.
- β asimetrizează distribuția: masă mai mare pe coada stângă sau dreaptă.
- Descreșterea cozilor este polinomială, nu exponențială (spre deosebire de distribuția Gaussiană).
- Evenimentele cu impact mare și probabilitate mică sunt mai probabile.

Momentele și existența lor

- Existența momentelor depinde de α:

$$\mathbb{E}[|X|^p] < \infty \quad \text{pentru } 0 < p < \alpha; \qquad \mathbb{E}[|X|^p] = \infty \quad \text{pentru } p \geq \alpha$$

- Media există doar dacă $\alpha > 1$.
- Varianța există doar dacă $\alpha = 2$ (cazul Gaussian).
- Pentru Cauchy ($\alpha = 1$): fără medie, fără varianță.
- Pentru Lévy ($\alpha = 0.5$): chiar $\mathbb{E}[X]$ nu există.
- Această proprietate face distribuțiile stabile potrivite pentru modelarea extremelor, dar ridică provocări pentru inferență.

Distribuții stabile: Exemple financiare

SFM_ch2_stable_fit

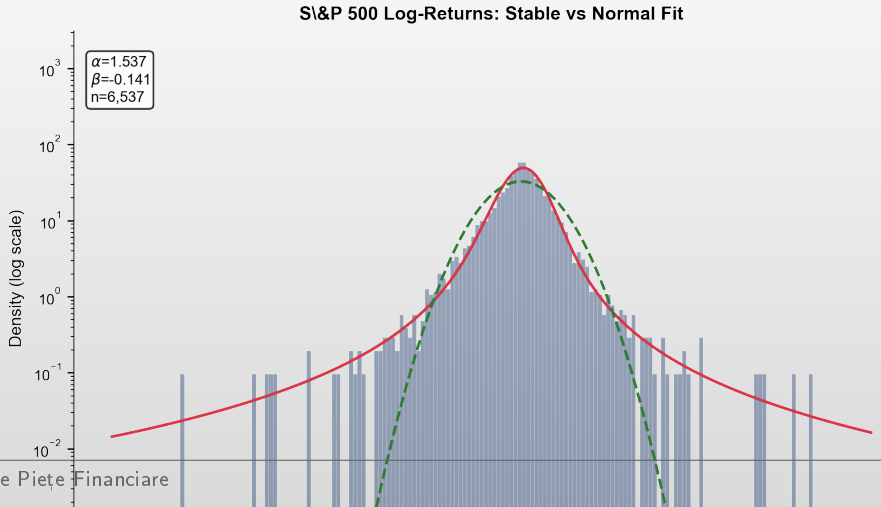

Comparația indicelui de stabilitate α pe clase de active

SFM_ch2_stable_fit

Nicio clasă de active nu este perfect Gaussiană ($\alpha < 2$). Bitcoin are cele mai grele cozi.

Funcția caracteristică (Parametrizarea A)

- Fie $X \sim S_A(\alpha, \beta, \gamma, \delta)$. Funcția caracteristică (FC) $\phi(t) = \mathbb{E}[e^{itX}]$.
- Dacă $\alpha \neq 1$:
$$\phi(t) = \exp\left\{-\gamma^\alpha |t|^\alpha \left[1 - i\beta \cdot \text{sign}(t) \cdot \tan\left(\frac{\pi\alpha}{2}\right)\right] + i\delta t\right\}$$
- Dacă $\alpha = 1$:
$$\phi(t) = \exp\left\{-\gamma|t| \left[1 + i\beta \cdot \frac{2}{\pi} \cdot \text{sign}(t) \cdot \ln|t|\right] + i\delta t\right\}$$
- FC definește în mod unic o distribuție de probabilitate.
- Pentru distribuțiile stabile, densitatea este adesea necunoscută sau intratabilă, astfel încât se folosește FC.
- Parametrii controlează comportamentul. Utilă pentru simulare (metode de transformare inversă), estimare și derivarea proprietăților.

Funcția caracteristică (Parametrizarea B)

- Fie $X \sim S_B(\alpha, \beta, c, \mu)$. FC $\phi(t) = \mathbb{E}[e^{itX}]$.
- Dacă $\alpha \neq 1$:

$$\phi(t) = \exp\left\{-|ct|^\alpha \left[1 - i\beta \cdot \text{sign}(t) \cdot \tan\left(\frac{\pi\alpha}{2}\right)\right] + i\mu t\right\}$$

- Dacă $\alpha = 1$:

$$\phi(t) = \exp\left\{-|ct| \left[1 + i\beta \cdot \frac{2}{\pi} \cdot \text{sign}(t) \cdot \ln|ct|\right] + i\mu t\right\}$$

- Parametrii c, μ sunt parametri alternativi de scală și localizare.
- Frecvent utilizată în demonstrații matematice și simulări bazate pe reprezentarea lui Zolotarev.

Corespondența între parametrizări

- Distribuțiile stabile pot fi exprimate în două parametrizări:
  - Standard (A): $S_A(\alpha, \beta, \gamma, \delta)$.
  - Alternativă (B): $S_B(\alpha, \beta, c, \mu)$.
- **Corespondența de la A la B**:
  - Dacă $\alpha \neq 1$: $c = \gamma, \quad \mu = \delta$.
  - Dacă $\alpha = 1$: $c = \gamma, \quad \mu = \delta - \frac{2}{\pi}\beta\gamma \ln(\gamma)$.
- **Corespondența de la B la A**:
  - Dacă $\alpha \neq 1$: $\gamma = c, \quad \delta = \mu$.
  - Dacă $\alpha = 1$: $\gamma = c, \quad \delta = \mu + \frac{2}{\pi}\beta c \ln(c)$.
- **Notă**: În continuare folosim parametrizarea standard $S_A(\alpha, \beta, \gamma, \delta)$.

Tehnici de estimare a parametrilor

- Nu există densitate în formă închisă pentru distribuțiile stabile generale.
- **Estimarea prin verosimilitate maximă (MLE)**:
  - Utilizează inversarea numerică a FC prin FFT.
  - Log-verosimilitatea: $\ell(\theta) = \sum_{i=1}^{n} \log f(x_i; \theta)$, unde $f(x)$ se calculează prin inversare FFT.
  - Necesită estimări inițiale bune și tehnici de regularizare.
- **Estimarea prin potrivirea cuantilelor (QME)**:
  - Minimizează diferențele pătratice între cuantilele empirice și cele teoretice:

$$\min_{\theta} \sum_{k=1}^{K} \left(Q_k^{\text{empiric}} - Q_k^{\text{teoretic}}(\theta) \right)^2$$

  - Robustă pentru eșantioane mici și cozi groase.

Tehnici de estimare a parametrilor

- **Estimare bazată pe funcția caracteristică (FC)**:
  - Se definește un obiectiv:

$$J(\theta) = \int |\hat{\phi}(t) - \phi(t;\theta)|^2 w(t)\, dt$$

  - Minimizat prin integrare numerică și optimizare neliniară.
  - Avantaj: nu necesită evaluarea densității.
- **Metoda de estimare a cuantilelor a lui McCulloch**:
  - Utilizează cinci cuantile selectate pentru a estima α, β, γ, δ.
  - Bazată pe valori pre-tabulate din simulări.
  - Foarte rapidă și ușor de implementat, potrivită pentru seturi mari de date.

Tehnici de estimare a parametrilor

- **Metoda de regresie Koutrouvelis**:
  - Bazată pe funcția caracteristică empirică (FCE):

$$\hat{\phi}(t) = \frac{1}{n}\sum_{j=1}^{n} e^{itX_j}$$

  - **Etapa 1**: Regresie liniară pentru α și γ:

$$\log(-\log|\hat{\phi}(t)|) = \alpha \log|t| + \alpha \log\gamma + \epsilon_1(t)$$

  - **Etapa 2**: Regresie pentru β și δ prin fază:

$$\frac{\arg(\hat{\phi}(t))}{t} = -\beta\gamma^{\alpha}\tan\left(\frac{\pi\alpha}{2}\right)|t|^{\alpha-1} + \delta + \epsilon_2(t)$$

  - Rapidă, utilizată pe scară largă, eficientă pentru eșantioane moderate și mari.

Metoda Chambers-Mallows-Stuck (CMS)

- Simulează $X \sim S(\alpha, \beta, \gamma, \delta)$ folosind Parametrizarea A:

$$X = \gamma \cdot \frac{\sin(\alpha(U+\zeta))}{\cos(U)^{1/\alpha}} \left[\frac{\cos(U - \alpha(U+\zeta))}{W}\right]^{(1-\alpha)/\alpha} + \delta$$

- $U \sim \text{Uniform}(-\pi/2, \pi/2)$.
- $W \sim \text{Exp}(1)$.
- $\zeta = \frac{1}{\alpha} \arctan\left(\beta \tan\left(\frac{\pi\alpha}{2}\right)\right)$.
- Atenție specială pentru $\alpha = 1$ din cauza singularității în $\tan(\pi\alpha/2)$.
- Eficientă, metodă standard în biblioteci (de ex., `levy_stable.rvs` din SciPy).

Reprezentarea prin serii LePage

- Simulează $X = \sum_{j=1}^{\infty} \gamma_j \epsilon_j$.
- $\Gamma_j = E_1 + E_2 + \cdots + E_j$, cu $E_j \sim \text{Exp}(1)$.
- T_j sunt i.i.d. Uniform$(0,1)$ sau deterministice ($T_j = j$).
- $\gamma_j = \left(\frac{\Gamma_j}{T_j}\right)^{-1/\alpha}$.
- Pentru distribuții stabile simetrice: $\epsilon_j \sim \text{Uniform}(-1,+1)$.
- Pentru distribuții stabile generale:

$$\epsilon_j = \frac{\sin(\alpha V_j)}{\cos(V_j)^{1/\alpha}}, \quad V_j \sim \text{Uniform}(-\pi/2, \pi/2)$$

- Lentă, dar construcție cu valoare teoretică din procese punctuale Poisson.

Inversarea FC bazată pe FFT

- Se alege o grilă simetrică de valori t: $t_k = \frac{2\pi k}{T}$ pentru $k = -N/2, \ldots, N/2 - 1$.
- Se calculează $\phi(t_k)$ din funcția caracteristică cunoscută a legii stabile (Param A).
- Se aplică FFT inversă pentru a obține densitatea aproximată:

$$f(x) \approx \mathrm{Re}\left(\frac{1}{2\pi}\sum_k \phi(t_k)\, e^{-it_k x}\, \Delta t\right)$$

- Se integrează densitatea pentru a obține funcția de repartiție aproximată numeric.
- Se utilizează eșantionarea prin transformare inversă: se extrage $U \sim \mathrm{Uniform}(0,1)$, se inversează $F(x)$.
- Potrivită pentru generarea unor loturi mari de eșantioane pentru parametri arbitrari $(\alpha, \beta, \gamma, \delta)$.
- Precizie ridicată, dar costisitoare computațional (mai ales la rezoluții înalte).

Aplicații practice ale distribuțiilor stabile

- **Finanțe și managementul riscului**:
  - Modelarea randamentelor activelor financiare cu cozi groase și asimetrie.
  - Înlocuirea ipotezelor Gaussiene în modelele de risc de portofoliu cu alternative α-stabile.
  - Potrivire mai bună la datele empirice pentru calculul VaR și Expected Shortfall (ES).
- **Trafic de rețea și telecomunicații**:
  - Dimensiunile pachetelor de internet și timpii între sosiri prezintă comportament cu cozi groase.
  - Modelele stabile captează explozivitatea traficului mai precis decât ipotezele Gaussiene.
  - Aplicate în modelarea fluxurilor de rețea auto-similare și cu dependență pe termen lung.
- **Procesarea semnalelor și imaginilor**:
  - Modele de zgomot impulsiv (de ex., radar, sonar, imagistică medicală).
- **Fizică și științe ale mediului**:
  - Zboruri Lévy în difuzia anormală și mecanica statistică.
  - Distribuția forțelor gravitaționale (Holtsmark) în astrofizică.
  - Legi stabile utilizate pentru descrierea precipitațiilor abundente, magnitudinilor seismelor.

S&P 500 VaR: Stabilă vs Gaussiană vs Empirică

SFM_ch2_stable_fit

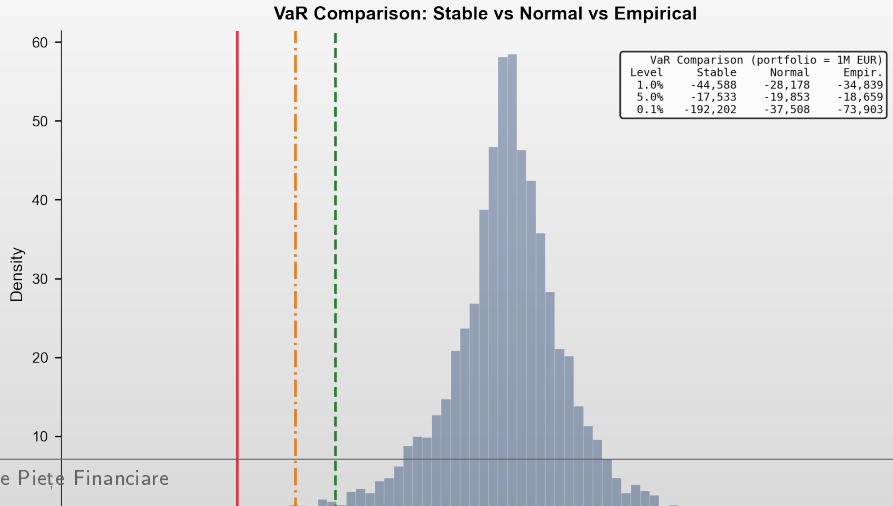

Funcția de supraviețuire: Stabilă vs Normală

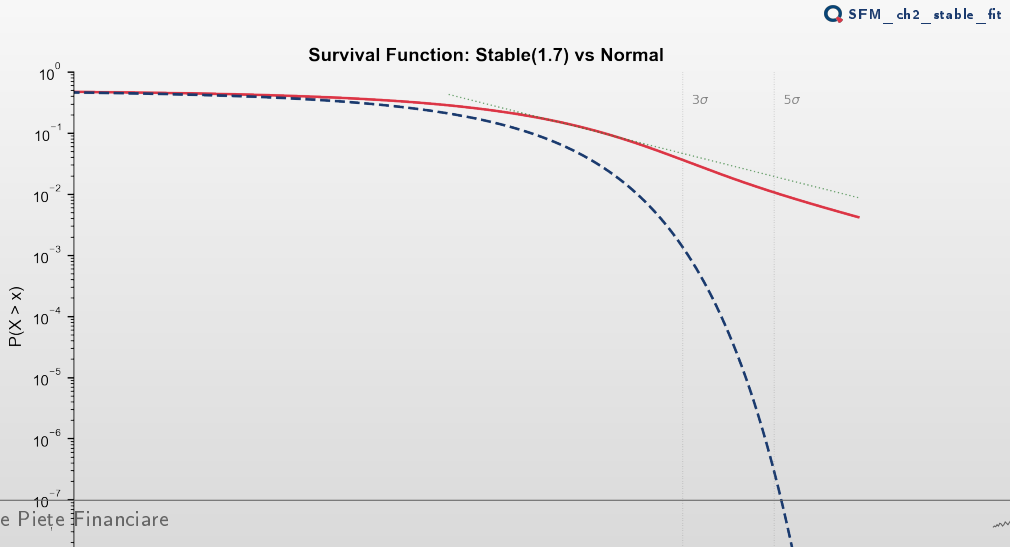

Teme

Cerințe

1. Alegeți o acțiune listată la BVB (ex: TLV, SNP, BRD, FP)
2. Fit-ați o distribuție stabilă pe log-randamentele zilnice
3. Comparați VaR la 1% și 5%: stabil vs normal vs empiric
4. Interpretați: este piața românească "mai Gaussiană" decât S&P 500?

Bibliografie I

- Nolan, J.P. (2020). *Stable Distributions: Models for Heavy Tailed Data*. Birkhäuser.
- Samorodnitsky, G., Taqqu, M.S. (1994). *Stable Non-Gaussian Random Processes*. Chapman & Hall.
- Mandelbrot, B. (1963). The Variation of Certain Speculative Prices. *Journal of Business*, 36(4), 394–419.
- Fama, E.F. (1965). The Behavior of Stock-Market Prices. *Journal of Business*, 38(1), 34–105.
- Rachev, S.T., Mittnik, S. (2000). *Stable Paretian Models in Finance*. Wiley.
- Chambers, J.M., Mallows, C.L., Stuck, B.W. (1976). A Method for Simulating Stable Random Variables. *JASA*, 71(354), 340–344.
- Koutrouvelis, I.A. (1980). Regression-Type Estimation of the Parameters of Stable Laws. *JASA*, 75(372), 918–928.

Bibliografie II

McCulloch, J.H. (1986). Simple Consistent Estimators of Stable Distribution Parameters. *Communications in Statistics*, 15(4), 1109–1136.