



Statistica piețelor financiare

Capitolul 6: Selecția modelului și managementul riscului



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AD: Anderson–Darling (test) (testul Anderson–Darling)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ BET: Bucharest Exchange Trading (index) (indicele de referință al Bursei de Valori București)
- ▣ BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- ▣ BVB: Bursa de Valori București
- ▣ COVID-19: COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- ▣ EDF: Empirical Distribution Function (funcția de repartiție empirică)
- ▣ EM: Expectation–Maximisation (algorithm) (algoritmul de așteptare–maximizare)
- ▣ EMA: Exponential Moving Average (medie mobilă exponențială)
- ▣ EODHD: EOD Historical Data (market-data provider) (furnizor de date de piață)
- ▣ ES: Expected Shortfall (pierderea așteptată în coadă)
- ▣ FFT: Fast Fourier Transform (transformata Fourier rapidă)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GED: Generalised Error Distribution (distribuția erorii generalizate)
- ▣ KS: Kolmogorov–Smirnov (test) (testul Kolmogorov–Smirnov)
- ▣ LR: Likelihood Ratio (raportul de verosimilitate)
- ▣ ML: Maximum Likelihood (verosimilitate maximă)
- ▣ NIG: Normal Inverse Gaussian (distribution) (distribuția Normală invers Gaussiană)
- ▣ PP: Probability–Probability (plot) (graficul probabilitate–probabilitate)
- ▣ QQ: Quantile–Quantile (plot) (graficul cuantilă–cuantilă)
- ▣ RMA: Rectangular Moving Average (medie mobilă simplă (dreptunghiulară))

Întrebarea de azi și traseul

- ▣ **Întrebarea:** avem șapte distribuții candidate pentru randamentele zilnice; pe care să o folosească un manager de risc și cât de siguri putem fi?
 - ▶ **Capitolele 2, 3 și 5:** distribuția Normală eșuează; Student-t, legile stabile și teoria valorilor extreme descriu fiecare o parte a imaginii
- ▣ **Traseul** capitolului
 - ▶ candidații și ce trebuie să reproducă; verosimilitatea maximă, recapitulată
 - ▶ compararea modelelor: teste ale raportului de verosimilitate, AIC și BIC
 - ▶ verificarea unui model: teste de concordanță, grafice PP și QQ
 - ▶ scopul decide: care model nimereste VaR 1%, în eșantion și în afara lui
 - ▶ supraajustarea și incertitudinea de model

Rezultatele învățării


- ▣ Scrieți log-verosimilitatea unui model candidat și explicați cum se obțin estimările de verosimilitate maximă
- ▣ Testați un model restrîns față de unul mai larg cu testul raportului de verosimilitate și știți cînd testul nu se aplică
- ▣ Calculați AIC, BIC, Δ AIC și ponderile Akaike și interpretați-le
- ▣ Aplicați și interpretați testele KS, Cramér–von Mises și Anderson–Darling, graficele PP și QQ, și explicați de ce KS este slab în cozi
- ▣ Judecați un model după VaR 1% în afara eșantionului, recunoașteți supraajustarea și raportați incertitudinea de model

Bibliografie și instrumente

- Manual: [Franke, Härdle & Hafner \(2019\)](#), cap. 16 (Value at Risk și backtesting) și cap. 18 (statistica riscurilor extreme); exerciții: [Borak, Härdle & López-Cabrera \(2013\)](#)
 - ▶ proprietățile distribuției randamentelor: [Tsay \(2010\)](#), cap. 1
- Selecția modelului: [Burnham & Anderson \(2002\)](#); versiunea scurtă [Burnham & Anderson \(2004\)](#)
- Concordanța: [Stephens \(1974\)](#); lucrările originale [Anderson & Darling \(1952\)](#), [Lilliefors \(1967\)](#)
- Quantlet-urile Python ale capitolului: [Quantlets/Ch_06](#)
 - ▶ portate din Quantlet-urile SFESumm și SFEVaRqqplot; fiecare grafic are legătură către Quantlet-ul care îl desenează
- Notebook-ul cursului: [deschideți în Google Colab](#)
- Curs video:  [Measuring Statistical Risk](#)

„Toate modelele sînt greșite”

- George Box: un statistician caută un model util, nu unul adevărat
Box (1976)
 - ▶ „toate modelele sînt greșite, dar unele sînt utile” este forma scurtă a argumentului său
- Pentru randamente, „util” depinde de scop
 - ▶ evaluare și alegerea portofoliului: corpul distribuției (zilele obișnuite)
 - ▶ managementul riscului: coada stîngă (cele mai proaste 1% dintre zile)
- Acest capitol: o trusă de instrumente pentru compararea modelelor și obiceiul de a întreba „util pentru ce?”



George E. P. Box (1919–2013)


Foto: DavidMCEddy (2011); CC BY-SA 3.0;
Wikimedia Commons

Șapte distribuții candidate

Model	k	Cozi	Asimetrie	Referință
Normală	2	subțiri, $e^{-x^2/2}$	nu	Capitolul 2
Student-t	3	putere, $x^{-\nu}$	nu	Capitolul 2
skewed-t	4	putere, $x^{-\nu}$	da (λ)	Hansen (1994)
GED	3	$e^{- x ^\beta}$, groase dacă $\beta < 2$	nu	Nelson (1991)
amestec Normal	5	subțiri, dar o componentă largă	da	Kon (1984)
NIG	4	semigroase, $ x ^{-3/2}e^{-c x }$	da	Barndorff-Nielsen (1997)
stabilă	4	putere, $x^{-\alpha}$, $\alpha < 2$	da (β)	Capitolul 3

- k : numărul de parametri; GED: generalised error distribution (distribuția erorii generalizate); NIG: normal inverse Gaussian (Normală invers Gaussiană), din familia hiperbolică generalizată [Eberlein & Keller \(1995\)](#)
- Amestecul Normal: cu probabilitatea w , o zi calmă $N(\mu_1, \sigma_1^2)$, altfel o zi agitată $N(\mu_2, \sigma_2^2)$

Candidații alături




- Toate cu media 0 și varianța 1 (stabila: același interval intercuartilic ca legea Normală); panoul din dreapta pe scară logaritmică
- În jurul centrului arată la fel; în cozi diferă prin ordine de mărime

Aceeași varianță, cozi foarte diferite

- ▣ $P(X < -4)$, o mișcare de patru abateri standard, pentru fiecare candidat din grafic:
 - ▶ Normală $3,2 \times 10^{-5}$; GED $9,5 \times 10^{-4}$; Student-t $2,4 \times 10^{-3}$; amestec Normal $2,5 \times 10^{-3}$
 - ▶ NIG $3,2 \times 10^{-3}$; skewed-t $4,5 \times 10^{-3}$; stabilă $8,1 \times 10^{-3}$
- ▣ Student-t dă acestei pierderi o probabilitate de circa 76 de ori mai mare decât legea Normală
- ▣ O măsură de risc precum VaR 1% stă exact acolo unde candidații nu sînt de acord
- ▣ **Întrebare pentru sală:** dacă toate se potrivesc bine în centru, de ce nu îl păstrăm pe cel mai simplu?
- ▣ **Răspuns**
 - ▶ cel mai simplu (Normal) greșește exact în zona care determină cerințele de capital și de marjă

Statisticile SFESumm: reperele oricărui model



- Quantlet-ul SFESumm: randamentele logaritmice lunare DAX între primele zile de tranzacționare, iulie 2004 – mai 2014 ($n = 119$), extinse aici până la 1 sep. 2026
- Chiar și randamentele lunare sînt asimetrice și cu cozi groase: slide-ul următor dă cifrele

Statistici descriptive: DAX lunar și randamente zilnice

	n	min	max	ab. std.	vol. anuală	asim.	aplatizare
DAX 2004–2014	119	−19,35	17,12	5,80	20,08	−0,83	4,60
DAX 2004–2026	267	−21,70	17,12	5,39	18,66	−0,72	5,06

- Lunar, în %; aplatizarea (kurtosis) $= E(X - \mu)^4 / \sigma^4$, egală cu 3 pentru distribuția Normală; valoarea p Jarque–Bera (Capitolul 2) $< 0,001$
- Randamente logaritmice zilnice din 2000 (Bitcoin din 2014, acțiunile BVB din 2010): aplatizarea
 - ▶ BET 14,1, S&P 500 13,7, DAX 9,1, Bitcoin 15,0, TLV 16,5, SNP 11,9, BRD 10,3
 - ▶ asimetria: S&P 500 −0,35, BET −0,65, Bitcoin −0,70

Datele înaintea modelelor: două zile greșite

- ▣ Banca Transilvania (TLV), prețul ajustat de la EODHD: randamente logaritmice de $-15,0\%$ pe 30 mai 2016 și $20,5\%$ pe 31 mai 2016
 - ▶ ajustarea pentru acțiunile gratuite este aplicată cu o zi întârziere ([Capitolul 2](#)): un crah fals urmat de o creștere falsă
- ▣ Efectul celor două zile asupra modelului ajustat
 - ▶ aplatizarea 20,5 cu ele, 16,5 fără; $\hat{\nu}$ Student-t: 3,33 vs 3,44
 - ▶ clasamentul AIC nu se schimbă aici (cel mai bun: Student-t), dar momentele se schimbă
- ▣ Regula: verificați cele mai mari randamente față de prețul de închidere și de știri înainte de orice selecție de model; cele două zile sînt eliminate în restul capitolului

Recapitulare: Candidații

- ▣ Șapte candidați cu 2 pînă la 5 parametri; sînt de acord în centru și diferă în cozi
- ▣ Orice model trebuie să reproducă asimetria și aplatizarea mult peste 3, chiar și pentru randamentele lunare
- ▣ Curățați întîi datele: două prețuri greșite au crescut aplatizarea TLV cu circa 19% din valoarea ei

Verosimilitate și log-verosimilitate

- Datele $r_1, \dots, r_n$, presupuse i.i.d. (independente și identic distribuite), cu densitatea $f(r; \theta)$
 - ▶ **verosimilitatea**: $L(\theta) = \prod_{t=1}^n f(r_t; \theta)$, densitatea eșantionului observat, ca funcție de θ
 - ▶ **log-verosimilitatea**: $\ell(\theta) = \sum_{t=1}^n \ln f(r_t; \theta)$; sumele sînt mai ușoare decît produsele
- **Estimarea de verosimilitate maximă (ML, maximum likelihood)**: $\hat{\theta} = \arg \max_{\theta} \ell(\theta)$
 - ▶ $\ell(\hat{\theta})$, log-verosimilitatea maximizată, este materia primă a fiecărei comparații din acest capitol
- n mare: $\hat{\theta}$ este aproximativ Normal în jurul lui θ adevărat, cu covarianța $\approx [-\partial^2 \ell / \partial \theta \partial \theta^\top]^{-1}$ (inversa informației observate)

Exemplu lucrat: modelul Normal, pas cu pas

$$\square \ell(\mu, \sigma) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_t (r_t - \mu)^2$$

► anulînd derivatele: $\hat{\mu} = \bar{r}$, $\hat{\sigma}^2 = \frac{1}{n} \sum_t (r_t - \bar{r})^2$ (împărțitor n , nu $n - 1$)

► înlocuind: $\ell(\hat{\theta}) = -\frac{n}{2} [\ln(2\pi\hat{\sigma}^2) + 1]$

□ S&P 500, randamente logaritmice zilnice în %, 2000–2026: $n = 6\,714$, $\hat{\mu} = 0,025$, $\hat{\sigma} = 1,213$

► $\ln(2\pi\hat{\sigma}^2) = 2,2240$, deci $\ell(\hat{\theta}) = -\frac{6\,714}{2} (2,2240 + 1) = -10\,823$

□ Doar modelul Normal are o formă închisă; celelalte se maximizează numeric

ML numerică pentru ceilalți candidați (S&P 500)


Model	Estimări	$\ell(\hat{\theta})$
Normală	$\hat{\mu} = 0,025, \hat{\sigma} = 1,213$	-10 823
Student-t	$\hat{\nu} = 2,67$, locație 0,068, scală 0,703	-9 848
skewed-t	$\hat{\nu} = 2,69, \hat{\lambda} = -0,067, \hat{\mu} = 0,024, \hat{\sigma} = 1,39$	-9 838
GED	$\hat{\beta} = 0,88$, locație 0,068, scală 0,653	-9 854
amestec Normal	$\hat{w} = 79\%$: $N(0,089; 0,71^2)$; 21% : $N(-0,223; 2,26^2)$	-9 925
NIG	$\hat{a} = 0,403, \hat{b} = -0,048$, locație 0,115, scală 0,755	-9 824
stabilă	$\hat{\alpha} = 1,540, \hat{\beta} = -0,181, \hat{\gamma} = 0,582, \hat{\delta}_0 = 0,093$	-9 893

- Optimizator: Nelder–Mead pe parametri transformați (de exemplu $\ln \sigma, \ln(\nu - 2)$); amestecul Normal prin algoritmul EM (expectation–maximisation); densitatea stabilă prin FFT ([Capitolul 3](#))
- Skewed-t: μ și σ sînt media și abaterea standard (parametrizarea lui Hansen)

Cum citim estimările

- ▣ Student-t $\hat{\nu} = 2,67$: cozi ca $x^{-2,67}$; varianța există ($\nu > 2$), aplatizarea nu ($\nu < 4$)
 - ▶ aplatizarea de selecție 13,7 estimează o mărime pe care modelul ajustat o declară infinită
- ▣ Skewed-t $\hat{\lambda} = -0,067 < 0$: o coadă stîngă puțin mai lungă (crahuri)
- ▣ GED $\hat{\beta} = 0,88$: sub 2 (Normală) și chiar sub 1 (Laplace): un vîrf ascuțit
- ▣ Amestecul Normal: 79% zile calme cu abaterea standard 0,71%, 21% zile agitate cu 2,26% și medie negativă
- ▣ Stabila $\hat{\alpha} = 1,540$ ([Capitolul 3](#)): cozi mai groase decît orice alt candidat

Cît de precis este $\hat{\nu}$? Log-verosimilitatea profil



- Pentru fiecare ν , maximizăm ℓ după locație și scală; curba scade cu -92 la $\nu = 5$
- Intervalul de 95%: toți ν cu $2[\ell(\hat{\nu}) - \ell(\nu)] \leq 3,84$, aici $[2,5; 2,8]$ în jurul lui $\hat{\nu} = 2,67$: cozile sînt bine determinate

Capcanele ML numerice

- ▣ **Maxime locale:** optimizatorul se poate opri pe un deal care nu este cel mai înalt
 - ▶ remediu: mai multe valori de start (amestecurile din acest capitol folosesc 4 până la 12 starturi)
- ▣ **Frontiere:** $\nu \rightarrow 2$, o pondere a amestecului $\rightarrow 0$, $|\lambda| \rightarrow 1$
 - ▶ erorile standard și testele obișnuite nu sînt valide la frontieră (secțiunea următoare)
- ▣ **Parametrizarea:** aceeași lege, parametri diferiți
 - ▶ scala Student-t din scipy nu este abaterea standard: $sd = scale \sqrt{\nu/(\nu - 2)}$
- ▣ **Verificare:** comparați $\ell(\hat{\theta})$ al modelelor imbricate; un model mai larg nu poate avea un maxim mai mic

Recapitulare: Verosimilitatea maximă

- ▣ $\ell(\theta) = \sum_t \ln f(r_t; \theta)$; estimarea ML o maximizează
- ▣ Normală: formă închisă, $\ell(\hat{\theta}) = -\frac{n}{2}[\ln(2\pi\hat{\sigma}^2) + 1]$; celelalte: numeric
- ▣ Precizia din curbura lui ℓ sau din log-verosimilitatea profil
- ▣ Atenție la maxime locale, frontiere și parametrizări

Modele imbricate

- Modelul 0 este **imbricat** în modelul 1 dacă modelul 0 este modelul 1 cu unii parametri fixați
 - ▶ Normală în GED: $\beta = 2$
 - ▶ Student-t în skewed-t: $\lambda = 0$
 - ▶ Normală în Student-t: $\nu = \infty$, adică $1/\nu = 0$, la **marginea** spațiului parametrilor
- Neimbricate: Student-t și GED, Student-t și stabilă, skewed-t și NIG
 - ▶ niciunul nu este caz particular al celuilalt: au nevoie de alte instrumente (testul Vuong, AIC)
- Imbricate: întotdeauna $\ell_1(\hat{\theta}_1) \geq \ell_0(\hat{\theta}_0)$; întrebarea este dacă câștigul depășește hazardul

Testul raportului de verosimilitate

- H_0 : modelul 0 (restrîns) este adevărat; H_1 : modelul 1 (mai larg)
 - ▶ $LR = 2 [\ell_1(\hat{\theta}_1) - \ell_0(\hat{\theta}_0)] \geq 0$
 - ▶ **Teorema lui Wilks** (Wilks (1938)): sub H_0 , $LR \approx \chi^2(d)$, cu $d = k_1 - k_0$ restricții, dacă valorile restrînse sînt în interiorul spațiului parametrilor
- Decizia la 5%: respingem H_0 dacă $LR > \chi_{0,95}^2(d)$
 - ▶ $\chi_{0,95}^2(1) = 3,84$, $\chi_{0,95}^2(2) = 5,99$
- Intuiția: de două ori logaritmul raportului dintre verosimilitățile datelor sub cele două modele

Exemplu lucrat: este necesar parametrul de asimetrie?

- S&P 500: $\ell(\text{Student-t}) = -9\,848$, $\ell(\text{skewed-t}) = -9\,838$
 - ▶ $LR = 2(-9\,838 - (-9\,848)) = 19,63 > 3,84$; $p < 0,001$: respingem $\lambda = 0$
- Același test în alte serii
 - ▶ DAX: $LR = 20,92$, $p < 0,001$: asimetria este necesară
 - ▶ BET: $LR = 0,35$, $p = 0,555$; Bitcoin: $LR = 0,42$, $p = 0,515$: nicio dovadă de asimetrie
- Normală în GED ($\beta = 2$): LR între 1 431 (Bitcoin) și 2 298 (BET); modelul Normal este respins peste tot
- Interpretare: cei doi indici dezvoltați au o coadă stîngă mai lungă; BET și Bitcoin nu

Un caz de frontieră: Normală în Student-t

- ▣ $H_0: 1/\nu = 0$ este pe marginea spațiului $1/\nu \geq 0$: teorema lui Wilks nu se aplică
 - ▶ Self & Liang (1987): legea sub H_0 este un amestec 50:50 de $\chi^2(0)$ (o masă punctuală în 0) și $\chi^2(1)$
 - ▶ valoarea critică la 5%: $\chi^2_{0,90}(1) = 2,71$ în loc de 3,84; valoarea p naivă este dublul celei corecte
- ▣ Date reale: $LR = 1\,949$ (S&P 500), $1\,337$ (Bitcoin): modelul Normal este respins cu oricare valoare critică
- ▣ Aceeași problemă apare pentru o pondere a amestecului $w = 0$ și pentru parametri de varianță egali cu 0
- ▣ **Ce credeți?** Contează frontiera când LR este de ordinul miilor?
- ▣ **Răspuns**
 - ▶ nu pentru decizie; da pentru eșantioane mici și valori LR la limită, unde înjumătățește valoarea p

Modele neimbricate: testul Vuong

	Student-t vs GED	Student-t vs stabilă	skewed-t vs NIG
BET	3,70 ($< 0,001$)	9,33 ($< 0,001$)	-1,34 (0,179)
S&P 500	0,40 (0,686)	6,52 ($< 0,001$)	-2,20 (0,028)
DAX	-0,23 (0,817)	7,66 ($< 0,001$)	-2,97 (0,003)
Bitcoin	-3,80 ($< 0,001$)	16,47 ($< 0,001$)	-6,76 ($< 0,001$)

- **Vuong (1989):** $m_t = \ln f_1(r_t) - \ln f_2(r_t)$, $V = \sqrt{n} \bar{m}/s_m \approx N(0, 1)$ dacă ambele modele sînt la fel de aproape de adevăr
- $V > 1,96$: primul model este mai aproape; $V < -1,96$: al doilea; (valoarea p) în paranteză
- Student-t bate legea stabilă peste tot; NIG bate skewed-t pe S&P 500 și DAX; Student-t vs GED diferă de la o piață la alta

Recapitulare: Testele raportului de verosimilitate și Vuong

- ▣ Modele imbricate: $LR = 2(\ell_1 - \ell_0) \approx \chi^2(k_1 - k_0)$ (Wilks)
- ▣ La frontieră (Normală în Student-t): amestec 50:50, valoarea critică 2,71
- ▣ Modele neimbricate: testul Vuong pe diferențele punctuale de log-verosimilitate
- ▣ Asimetria contează pentru S&P 500 și DAX, nu pentru BET și Bitcoin

Ideea lui Akaike

- ▣ Hirotugu Akaike a întrebat: care model va prezice cel mai bine date noi?
 - ▶ distanța de la adevărul g la un model f : divergența Kullback–Leibler [Kullback & Leibler \(1951\)](#)
 - ▶ $KL(g, f) = E_g[\ln g(R) - \ln f(R)] \geq 0$, zero doar dacă $f = g$
- ▣ $\ell(\hat{\theta})$ este prea optimistă: aceleași date aleg $\hat{\theta}$ și îl judecă
 - ▶ optimismul este de circa k , numărul de parametri [Akaike \(1974\)](#)
- ▣ Rezultatul: $AIC = -2\ell(\hat{\theta}) + 2k$, o estimare a potrivirii așteptate în afara eșantionului (mai mic este mai bine)



Hirotugu Akaike (1927–2009)

Foto: The Institute of Statistical Mathematics;

CC BY-SA 4.0; Wikimedia Commons

AIC și BIC

- ▣ **AIC** (Akaike information criterion, criteriul informațional Akaike): $AIC = -2\ell(\hat{\theta}) + 2k$
 - ▶ scopul: cel mai bun model predictiv; asimptotic echivalent cu validarea încrucișată leave-one-out [Stone \(1977\)](#)
 - ▶ eșantioane mici: $AIC_c = AIC + 2k(k+1)/(n-k-1)$ [Hurvich & Tsai \(1989\)](#)
- ▣ **BIC** (Bayesian information criterion, criteriul informațional bayesian) [Schwarz \(1978\)](#): $BIC = -2\ell(\hat{\theta}) + k \ln n$
 - ▶ scopul: modelul adevărat, dacă este printre candidați (consistență)
 - ▶ penalizarea pe parametru $\ln n$: 8,81 pentru $n = 6\,714$, de peste patru ori penalizarea AIC de 2
- ▣ Ambele: mai mic este mai bine; doar diferențele dintre modele pe **aceleași date** au sens

Δ AIC și ponderile Akaike


- $\Delta_i = \text{AIC}_i - \min_j \text{AIC}_j$; regulile practice din Burnham & Anderson (2004):
 - ▶ $\Delta \leq 2$: sprijin substanțial; $4 \leq \Delta \leq 7$: considerabil mai puțin; $\Delta > 10$: practic niciunul
- **Ponderea Akaike:** $w_i = \frac{e^{-\Delta_i/2}}{\sum_j e^{-\Delta_j/2}}$
 - ▶ ponderea dovezilor pentru modelul i între candidați; ponderile însumează 1
 - ▶ două modele cu $\Delta = 0$ și $\Delta = 2$: $w = 1/(1 + e^{-1}) \approx 0,73$ și $0,27$
- **Ce credeți?** Este $\Delta = 2$ o diferență „semnificativă”?
- **Răspuns**
 - ▶ nu: AIC nu este un test; o diferență de 2 înseamnă că ambele modele rămân plauzibile (circa 73% vs 27%)

Exemplu lucrat: șapte modele pentru S&P 500

	k	$\ell(\hat{\theta})$	AIC	BIC	ΔAIC	ΔBIC	w
Normală	2	-10 823	21 650	21 663	1993,2	1979,6	0,000
Student-t	3	-9 848	19 702	19 723	45,7	38,9	0,000
skewed-t	4	-9 838	19 685	19 712	28,1	28,1	0,000
GED	3	-9 854	19 714	19 735	57,9	51,1	0,000
amestec Normal	5	-9 925	19 859	19 893	202,5	209,3	0,000
NIG	4	-9 824	19 657	19 684	0,0	0,0	1,000
stabilă	4	-9 893	19 794	19 821	137,3	137,3	0,000

- Exemplu: NIG, $\text{AIC} = -2(-9\,824) + 2 \cdot 4 = 19\,657$
- NIG câștigă pe ambele criterii; următorul model, skewed-t, are $\Delta = 28,1$, deci $e^{-\Delta/2} \approx 8,1 \times 10^{-7}$: ponderea $w \approx 1$ pentru NIG
- Normală: ΔAIC de 1993; legea stabilă: 137

ΔAIC pe șapte serii



□ Fiecare rând: o serie; 0 marchează cel mai bun model; celule mai închise: modele mai slabe (scară logaritmică a culorii)

Cum citim harta ΔAIC


- ▣ Niciun câștigător unic: cel mai bun model depinde de piață
 - ▶ indicii (BET, S&P 500, DAX): NIG; Bitcoin: GED; acțiunile BVB: Student-t (TLV, SNP) și skewed-t (BRD)
- ▣ Concluzii robuste
 - ▶ modelul Normal este ultimul peste tot, la 479 (BRD) pînă la 2 425 (BET) de puncte
 - ▶ legea stabilă (Δ de la 23 la 197) și amestecul Normal nu sînt niciodată competitive
- ▣ **Întrebare pentru sală:** pentru BRD, AIC preferă skewed-t (Δ al Student-t: 1,0); ce model preferă BIC?
- ▣ **Răspuns**
 - ▶ Student-t: un parametru în minus economisește $\ln n \approx 8,2$ puncte BIC, mai mult decît câștigul de potrivire; cu $\Delta \approx 1$, cele două sînt practic la egalitate

Recapitulare: Criteriile informaționale

- ▣ $AIC = -2\ell + 2k$ (predicție); $BIC = -2\ell + k \ln n$ (modelul adevărat, penalizare mai mare)
- ▣ Citiți ΔAIC și ponderile Akaike, nu nivelul AIC; $\Delta \leq 2$ înseamnă egalitate
- ▣ Indici: NIG; Bitcoin: GED; acțiuni BVB: Student-t; Normală și stabilă: niciodată
- ▣ AIC ordonează candidații; nu spune dacă cel mai bun este suficient de bun

De la Pearson la funcția de repartiție empirică

- ▣ **Pearson (1900):** primul test de concordanță, testul χ^2
 - ▶ grupăm datele în clase și comparăm frecvențele observate cu cele așteptate
 - ▶ rezultatul depinde de clase, iar cozile conțin puține observații
- ▣ **Funcția de repartiție empirică** (EDF, empirical distribution function):
$$F_n(x) = \frac{1}{n} \# \{t : r_t \leq x\}$$
 - ▶ fără clase: comparăm F_n cu funcția de repartiție a modelului F
- ▣ Trei teste EDF: Kolmogorov–Smirnov, Cramér–von Mises, Anderson–Darling **Stephens (1974)**



Karl Pearson (1857–1936)

Fotogravură (1910); domeniu public; Wikimedia

[Commons](#)

Testul Kolmogorov–Smirnov

- $D_n = \sup_x |F_n(x) - F(x)|$, cea mai mare distanță pe verticală
 - ▶ cu datele ordonate $u_{(i)} = F(r_{(i)})$:
$$D_n = \max_i \max\{i/n - u_{(i)}, u_{(i)} - (i-1)/n\}$$
- F complet cunoscută: legea lui D_n nu depinde de F (Kolmogorov, 1933)
 - ▶ n mare: respingem la 5% dacă $D_n > 1,358/\sqrt{n}$; tabele pentru n mic: [Smirnov \(1948\)](#)
 - ▶ $n = 6714$: valoarea critică 0,017
- Andrei Kolmogorov a dat și axiomele probabilității ([Capitolul 4](#))



Andrei Kolmogorov (1903–1987) la curs, 1963

Foto: [Vsevolod Tarasevich \(1963–1964\)](#); CC BY 4.0;
[Wikimedia Commons](#)

Exemplu lucrat: KS pe cinci randamente

- ▣ Randamente (%): $-2,1; -0,4; 0,3; 0,9; 1,6$; $H_0: N(0, 1)$, complet specificată
 - ▶ $u_{(i)} = \Phi(r_{(i)})$: $0,018; 0,345; 0,618; 0,816; 0,945$ (Φ : funcția de repartiție Normală standard)
 - ▶ i/n : $0,2; 0,4; 0,6; 0,8; 1,0$; cea mai mare distanță este $u_{(3)} - 2/5 = 0,218$
- ▣ $D_5 = 0,218 < 0,563$, valoarea critică exactă de 5% pentru $n = 5$: nu respingem
- ▣ Cu cinci observații, aproape orice lege trece: testul are putere mică în eșantioane mici

Parametri estimați: problema Lilliefors

- În practică, F are parametri estimați: $F(x; \hat{\theta})$ este ajustată pe aceleași date
 - ▶ ajustarea apropie F de F_n : D_n este mai mic decât pentru o F cunoscută
 - ▶ valorile critice obișnuite sînt prea mari: testul aproape că nu mai respinge
- Lilliefors (1967): valori critice prin simulare pentru legea Normală cu $\hat{\mu}$, $\hat{\sigma}$ (nivelul 5%)
 - ▶ $n = 5$: 0,351 în loc de 0,563; $n = 1000$: 0,029 în loc de 0,043
- Orice model: **bootstrap parametric** Stute et al. (1993)
 - ▶ simulăm n extrageri din $F(\cdot; \hat{\theta})$, reajustăm, recalculăm statistica; repetăm de B ori
 - ▶ valoarea $p = (1 + \#\{\text{statistici bootstrap} \geq \text{cea observată}\}) / (B + 1)$

Cramér-von Mises și Anderson-Darling

- Ambele integrează pătratul distanței $[F_n(x) - F(x)]^2$ pe toate valorile x în loc să ia maximumul

- **Cramér-von Mises:**

$$W^2 = n \int [F_n - F]^2 dF = \frac{1}{12n} + \sum_i \left(u_{(i)} - \frac{2i-1}{2n} \right)^2 \text{ Cramér (1928)}$$

- **Anderson-Darling:** $A^2 = n \int \frac{[F_n - F]^2}{F(1-F)} dF$ Anderson & Darling (1952)

- Formula de calcul Anderson & Darling (1954):

$$A^2 = -n - \frac{1}{n} \sum_i (2i-1) [\ln u_{(i)} + \ln(1 - u_{(n+1-i)})]$$


- ponderea $1/[F(1-F)]$ este uriașă unde F este aproape de 0 sau 1: în cozi



Harald Cramér (1893–1985)


Foto: fotograf necunoscut (1951); domeniu public; Wikimedia Commons

De ce este KS slab în cozi



- S&P 500 față de ajustarea Normală. Stînga: distanța KS are maximul la $x = -0,41\%$, aproape de centru ($F = 36\%$), cu $D_n = 0,093$
- În cozi, F_n și F sînt amîndouă aproape de 0 sau 1, deci distanța brută este mică chiar dacă modelul greșește mult; ponderea Anderson-Darling (dreapta) pune cea mai mare distanță la $x = -6,9\%$

Puterea celor trei teste



- Proportia din 1000 de eșantioane simulate în care normalitatea (parametri estimați) este respinsă la 5%; puterea = probabilitatea de a respinge un H_0 fals
- Date Student-t, $n = 250$: KS 62%, Cramér-von Mises 77%, Anderson-Darling 81%; abateri doar în cozi ($n = 250$): 38%, 50%, 57%

Teste EDF pe S&P 500

	KS	CvM	AD
Normală	0,093	22,84	127,35
Student-t	0,018	0,57	4,69
skewed-t	0,017	0,41	2,25
GED	0,019	0,38	3,94
amestec Normal	0,025	1,09	5,80
NIG	0,010	0,13	0,88
stabilă	0,022	0,81	4,61

- Bootstrap parametric, $B = 199$, valori critice de 95%
 - ▶ Student-t: KS 0,009, AD 0,71
 - ▶ skewed-t: KS 0,008, AD 0,35
- Normală, Student-t, skewed-t: p bootstrap = 0,005, cel mai mic posibil: toate respinse
- Student-t, valoarea p KS naivă (ca și cum θ ar fi cunoscut): 0,021

- KS: Kolmogorov–Smirnov; CvM: Cramér–von Mises; AD: Anderson–Darling; mai mic este mai bine

 SFM_ch6_gof_tests

Semnificație statistică vs semnificație practică

- ▣ Cu $n = 6714$, fiecare model este respins: testele detectează abateri minuscule
 - ▶ iar randamentele reale nu sînt i.i.d. (gruparea volatilității), deci nicio lege i.i.d. nu poate trece
- ▣ Folosiți statisticile pentru a **ordona** modelele
 - ▶ AD: Normală 127,35, Student-t 4,69, skewed-t 2,25, NIG 0,88
 - ▶ ca la AIC: NIG primul, modelul Normal mult în urmă
- ▣ **Întrebare pentru sală:** un test KS pe 50 de randamente zilnice nu respinge legea Normală; este atunci legea Normală potrivită pentru VaR 1%?
- ▣ **Răspuns**
 - ▶ nu: cu $n = 50$, testul respinge rar chiar și date Student-t (în 30% din cazuri la $n = 100$), iar KS abia se uită la coadă


Recapitulare: Testele de concordanță

- ▣ KS: cea mai mare distanță; CvM: pătratul distanței integrat; AD: același, ponderat spre cozi
- ▣ Parametri estimați: tabelele Lilliefors sau un bootstrap parametric; niciodată tabelul KS clasic
- ▣ Puterea: $AD > CvM > KS$ pentru alternative cu cozi groase
- ▣ Eșantioanele mari resping totul: ordonați după statistică și priviți graficele

Două moduri de a privi o ajustare


- ▣ **Grafic PP** (probabilitate–probabilitate): punctele $(p_i, F(r_{(i)}))$ cu $p_i = (i - 0,5)/n$
 - ▶ ambele axe în $[0, 1]$: se văd diferențele din centru; cozile sînt înghesuite în colțuri
 - ▶ geamănul vizual al KS: cea mai mare distanță pe verticală față de diagonală este apropiată de D_n
- ▣ **Grafic QQ** (cuantilă–cuantilă): punctele $(F^{-1}(p_i), r_{(i)})$
 - ▶ în unități de randament: cozile sînt întinse, fiecare zi extremă se vede
 - ▶ capete deasupra/sub dreaptă: cozile modelului sînt prea scurte; capete aplatizate: cozile modelului sînt prea lungi
- ▣ Managementul riscului citește grafice QQ; graficele PP și KS au același unghi mort

Grafice PP: S&P 500




- Normală: o formă de S în centru (prea puține randamente mici, prea multe medii), cea mai mare distanță 0,093
- Student-t, skewed-t, stabilă: pe diagonală; într-un grafic PP nu se pot deosebi

Grafice QQ: S&P 500



- Cea mai proastă zi a fost $-12,8\%$; cuantila modelului la aceeași probabilitate: Normală $-4,6\%$, Student-t $-22,9\%$, skewed-t $-24,5\%$, stabilă $-116,1\%$
- Modelele care păreau identice în graficul PP sînt foarte departe unele de altele în coada îndepărtată

Grafice QQ pentru BET, Bitcoin și Banca Transilvania



- Normală (roșu): capetele abrupte la toate cele trei serii; Student-t și skewed-t urmează datele pînă departe în cozi
- Ultimele cîteva puncte sînt zile izolate (cele mai mari crahuri): acolo cozile ajustate diferă cel mai mult, iar incertitudinea este cea mai mare

Recapitulare: Graficele PP și QQ

- ▣ PP: probabilități, bun pentru centru; QQ: cuantile, bun pentru cozi
- ▣ Modelele cu cozi groase care arată la fel în graficele PP diferă mult în graficele QQ
- ▣ Arătați întotdeauna graficul QQ al modelului ales lângă AIC-ul lui

VaR și ES

- Randamentul X , nivelul α (aici $\alpha = 1\%$ sau $2,5\%$, probabilitatea cozii)
 - ▶ **VaR** (Value at Risk, valoarea la risc): $\text{VaR}_\alpha = -q_\alpha(X)$, pierderea depășită cu probabilitatea α
 - ▶ **ES** (expected shortfall, pierderea așteptată în coadă): $\text{ES}_\alpha = -\frac{1}{\alpha} \int_0^\alpha q_u du = -E[X \mid X \leq q_\alpha]$, pierderea medie din coadă
- Modelul Normal: $\text{VaR}_\alpha = -(\mu + \sigma z_\alpha)$, $z_{0,01} = -2,326$
 - ▶ S&P 500: $-(0,025 - 2,326 \times 1,213) = 2,80\%$, față de VaR 1% empiric de 3,45%
- Regulile Basel: ES 2,5% pentru riscul de piață, VaR 1% pentru backtesting (Capitolul 10)

VaR 1% și ES 2,5% în fiecare model (în eșantion)


VaR 1% (%)

	date	Normală	Student-t	skewed-t	GED	NIG	stabilă
BET	4,13	3,19	4,06	4,10	3,74	4,11	4,94
S&P 500	3,45	2,80	3,46	3,71	3,27	3,72	4,54
DAX	4,16	3,25	3,96	4,24	3,77	4,24	5,01
Bitcoin	10,51	7,99	11,06	10,91	9,85	10,52	14,26
TLV	5,10	4,01	4,63	4,61	4,49	4,76	4,92
SNP	4,29	3,70	4,26	4,22	4,16	4,32	4,43
BRD	4,50	3,81	4,24	4,39	4,18	4,43	4,51

ES 2,5% (%)


	date	Normală	Student-t	skewed-t	GED	NIG	stabilă
BET	4,57	3,21	4,76	4,81	3,85	4,31	7,58
S&P 500	3,76	2,81	3,95	4,23	3,36	3,89	6,70
Bitcoin	10,84	8,03	13,37	13,18	10,17	11,06	22,87

VaR 1% al modelelor raportat la date



- Normală: cu 14–24% prea mic peste tot; stabilă: pînă la 36% prea mare
- Student-t, skewed-t și NIG rămîn la cel mult 10% de VaR 1% empiric; GED este puțin prea jos

Coada stîngă pe axe log-log (S&P 500)



- Punctele: proporția zilelor cu o pierdere peste x ; liniile: aceeași probabilitate în fiecare model ajustat
- La 1%, toate modelele cu cozi groase sînt apropiate; dincolo de pierderi de 5%, dreapta stabilă este mult prea sus, iar cea Normală se prăbușește

Numărarea depășirilor: testul Kupiec

	așteptat	Normală	Student-t	skewed-t	GED	NIG	stabilă
BET	67	138	71	69	91	68	43
S&P 500	67	131	67	52	80	52	30
DAX	68	145	78	66	91	65	39
Bitcoin	44	86	34	36	56	44	16

- Depășire: o zi cu $r_t < -\text{VaR}_{1\%}$; pentru un model corect, numărul lor este Binomial($n; 0,01$)
- Kupiec (1995): $LR_{uc} = -2 \ln \frac{(1 - \alpha)^{n-x} \alpha^x}{(1 - x/n)^{n-x} (x/n)^x} \approx \chi^2(1)$, x = numărul de depășiri
- S&P 500: Student-t 67 depășiri la 67 așteptate ($p = 0,986$); NIG, câștigătorul AIC, 52 ($p = 0,053$)
- Cel mai bun model pentru întreaga densitate nu este întotdeauna cel mai bun pentru o cuantilă; există scoruri axate pe coadă Diks, Panchenko & van Dijk (2011)


Recapitulare: VaR 1% în eșantion

- ▣ $\text{VaR } 1\% = -q_{1\%}$, $\text{ES } 2,5\% = \text{pierderea medie dincolo de } q_{2,5\%}$
- ▣ Normală: VaR 1% cu 14–24% prea mic; stabilă: mult prea mare; Student-t, skewed-t, NIG: apropiate
- ▣ Judecați un model de risc după depășirile lui (Kupiec), nu doar după AIC

De ce în afara eşantionului?

- În eşantion, un model mai larg se potrivește cel puțin la fel de bine: ℓ nu scade niciodată când adăugăm parametri
 - ▶ **supraajustare** (overfitting): parametri în plus potrivesc zgomotul eşantionului de estimare, nu trăsături ale randamentelor viitoare
- Verificarea cinstită: estimăm până la 31 decembrie 2019, evaluăm pe 2020–2026 (crahul COVID-19, șocul inflației din 2022, tarifele din 2025)
 - ▶ **scorul logaritm**: media lui $\ln f(r_t; \hat{\theta})$ pe zilele de test; mai mare este mai bine, o regulă de scor proprie Gneiting & Raftery (2007)
 - ▶ **depășirile VaR 1%** (Kupiec) și **pierderea pinball** $\frac{1}{n} \sum_t (\alpha - 1\{r_t < q\})(r_t - q)$ a cuantilei de 1% q
- Un scor este **propriu** dacă distribuția adevărată obține cel mai bun scor așteptat: cine prognozează nu câștigă distorsionînd

Rezultate în afara eșantionului, 2020–2026





- Stînga: fiecare model cu cozi groase bate scorul logaritmice al modelului Normal cu 0,13 pînă la 0,21 pe zi; diferențele dintre ele sînt mici
- Dreapta: ratele de depășire ale VaR 1%; ținta este linia punctată de la 1%

Cum citim tabelul din afara eșantionului

	aștept.	Normală	t	skew-t	NIG	stabilă	ist.	cel mai bun AIC	cel mai bun scor
BET	16,7	17	5	5	5	3	5	NIG	Student-t
S&P 500	16,9	38	19	14	14	8	23	NIG	skewed-t
DAX	17,1	27	11	8	8	4	8	NIG	NIG
Bitcoin	24,5	23	7	7	7	1	10	GED	NIG

- Depășiri ale VaR 1% pe zilele de test; aștept.: numărul așteptat; ist.: simularea istorică (cuantila de 1% a eșantionului de estimare)
- Câștigătorul AIC din 2000–2019 are cel mai bun scor logaritmic doar pentru DAX; în rest, cel mai bun scor aparține unui vecin apropiat
- BET: modelul Normal are 17 depășiri la 16,7 așteptate, modelele cu cozi groase doar 5: perioada 2020–2026 a fost mai calmă pentru BET decât 2000–2019
- Numărul corect din motivul greșit: un model static nu poate urmări schimbările de volatilitate

Supraajustare: amestecuri Normale cu 1 pînă la 6 componente




- S&P 500, estimare 2017–2018 ($n = 501$), test 2019–2026 ($n = 1\,939$); c componente au $3c - 1$ parametri
- În eșantion (albastru), potrivirea crește cu fiecare componentă; în afara eșantionului (roșu) atinge maximumul la $c = 3$ și apoi scade

Care criteriu ne-a avertizat?

- Log-verosimilitatea medie pe zi, în eșantion $\rightarrow$ în afara eșantionului
 - ▶ $c = 1$ (Normală): $-1,219 \rightarrow -1,841$; $c = 3$: $-0,999 \rightarrow -1,608$; $c = 6$ (17 parametri): $-0,971 \rightarrow -1,698$
- BIC a ales $c = 3$, cel mai bun model în afara eșantionului; AIC a ales $c = 5$
 - ▶ cu $n = 501$, penalizarea AIC de 2 pe parametru este prea slabă pentru a opri componentele în plus
- Diferența dintre potrivirea în eșantion și cea din afara lui crește cu numărul de parametri: această diferență este supraajustarea
- Regula: eșantioane scurte, mulți parametri $\Rightarrow$ preferați BIC sau AICc și păstrați întotdeauna o perioadă de test

 SFM_ch6_out_of_sample

VaR 1% mobil: reajustare lunară




- S&P 500: fiecare model reajustat la fiecare 20 de zile de tranzacționare pe cele 1000 de zile anterioare; linia VaR 1% este desenată ca prag de pierdere $-VaR$
- Triunghiurile negre: depășiri ale VaR Student-t; vin în grupuri (martie 2020)

Backtesting mobil: rezultatele

	Normală	Student-t	skewed-t	istorică
S&P 500, rata (%)	2,35	1,56	1,47	1,58
S&P 500, Kupiec p	< 0,001	< 0,001	< 0,001	< 0,001
S&P 500, maximum într-un an	36	31	28	29
BET, rata (%)	1,98	1,52	1,38	1,25
BET, Kupiec p	< 0,001	< 0,001	0,007	0,066

- Backtesting 2003–2026, $n = 5\,714$ zile pentru S&P 500; rata țintă 1%; cel mai prost an este 2008 pentru fiecare model și ambele serii
- Cozile groase înjumătățesc excesul de depășiri, dar niciun model necondiționat nu ajunge la 1%: volatilitatea se schimbă mai repede decât o fereastră de 1000 de zile
- Remediul este un model pentru volatilitatea însăși: GARCH, Capitolele 8 și 9

Graficul de fiabilitate VaR (SFEVaRqqplot)




- DAX din 2000: VaR 1% Normal cu volatilitatea ultimelor 250 de zile, RMA (rectangular moving average, medie mobilă simplă) sau EMA (exponențială, $\lambda = 0.96$); graficul QQ al lui L/VaR față de cuantilele Normale
- O dreaptă ar însemna un VaR fiabil; ambele se curbează în sus la capătul drept: pierderile dincolo de VaR sînt prea mari și prea dese (2,13% și 2,07% depășiri)

Recapitulare: În afara eşantionului

- ▣ Judecați modelele pe date pe care nu le-au văzut: scor logaritmic, depășiri, pierdere pinball
- ▣ Supraajustarea: potrivirea în eşantion crește cu parametrii, cea din afara lui nu; BIC ne-a protejat, AIC nu
- ▣ Cozile groase ajută, dar modelele statice eșuează în crize: volatilitatea trebuie modelată (GARCH)

Cît de siguri sîntem de cîştigător?



- S&P 500, 200 de reeșantionări bootstrap pe blocuri mobile (blocurile de 20 de zile păstrează grupurile de volatilitate); în fiecare, șase modele reajustate
- Stînga: NiG are cel mai mic AIC în 94% din reeșantionări; dreapta: dispersia bootstrap a VaR 1% în fiecare model

Două surse de incertitudine

- ▣ **Incertitudinea parametrilor:** același model, reestimat pe date reeșantionate
 - ▶ VaR 1% Student-t: banda bootstrap de 90% [3,14; 3,87]%; NIG: [3,34; 4,18]%
- ▣ **Incertitudinea de model:** modele diferite pe aceleași date
 - ▶ VaR 1% median: GED 3,27%, Student-t 3,47%, NIG 3,71%, amestec Normal 3,92%
 - ▶ dispersia dintre modele este comparabilă cu dispersia din interiorul unui model
- ▣ Chiar când câștigătorul AIC este clar, cifra care contează pentru risc nu este
- ▣ Măsurile de coadă bazate pe entropie sînt o altă cale de a rezuma această incertitudine: [Pele, Lazar & Dufour \(2017\)](#), [Pele, Lazar & Mazurencu-Marinescu-Pele \(2019\)](#)

Medierea modelelor și riscul de model

	date	Normală	interval cozi groase	mediat	interval (%)
BET	4,13	3,19	[3,74; 4,94]	4,11	32
S&P 500	3,45	2,80	[3,27; 4,54]	3,72	39
DAX	4,16	3,25	[3,77; 5,01]	4,24	33
Bitcoin	10,51	7,99	[9,85; 14,26]	9,85	45
TLV	5,10	4,01	[4,49; 5,41]	4,62	21
SNP	4,29	3,70	[4,16; 4,70]	4,25	13
BRD	4,50	3,81	[4,18; 4,74]	4,33	14

- VaR 1% în %; intervalul cozilor groase: cel mai mic și cel mai mare VaR 1% dintre cele șase modele nenormale; intervalul (%): max/min – 1
- Mediat: $\sum_i w_i \text{VaR}_i$ cu ponderile Akaike; o rudă frecventistă a medierii bayesiene a modelelor [Hoeting et al. \(1999\)](#)
- **Riscul de model**: intervalul dintre modelele plauzibile; autoritățile cer băncilor să îl măsoare [Kerkhof, Melenberg & Schumacher \(2010\)](#), [Danielsson et al. \(2016\)](#)

Un flux de lucru pentru selecția modelului

- ▣ 1. **Datele:** verificați cele mai mari randamente față de prețuri și știri; eliminați doar erorile dovedite
- ▣ 2. **Candidații:** alegeți-i după faptele stilizate (cozi, asimetrie), nu după comoditate
- ▣ 3. **Ajustare și clasament:** ML, apoi AIC și BIC; teste LR pentru perechile imbricate, Vuong pentru celelalte
- ▣ 4. **Verificare:** statistica AD și graficul QQ ale frunțașilor; zona care vă interesează trebuie să se potrivească
- ▣ 5. **Validare:** în afara eșantionului, cu funcția de pierdere potrivită scopului (depășiri pentru VaR)
- ▣ 6. **Raportare:** câștigătorul, urmăritorii și intervalul cifrei de risc între ei

Recapitulare: Incertitudinea de model

- ▣ Cîştigătorul AIC poate fi stabil între reeșantionări, în timp ce VaR nu este
- ▣ Raportați intervalul dintre modelele plauzibile sau mediați cu ponderile Akaike
- ▣ Riscul de model face parte din risc: o singură cifră îl ascunde

O întrebare deschisă

- ▣ **Mai câștigă NIG după ce eliminăm gruparea volatilității?**
 - ▶ o parte din cozile groase ale randamentelor zilnice vine din volatilitatea variabilă ([Capitolul 2](#))
 - ▶ randamentele împărțite la o prognoză de volatilitate (de exemplu EMA, $\lambda = 0,96$) au cozi mai subțiri; care candidat li se potrivește cel mai bine?
- ▣ De ce este deschisă: răspunsul diferă de la o piață la alta, iar modelul de volatilitate este el însuși o alegere
- ▣ Randamentele zilnice brute: NIG câștigă pentru cei trei indici, GED pentru Bitcoin, Student-t pentru acțiunile BVB (acest capitol)
- ▣ Instrumentele AI pot accelera un astfel de studiu; nu înlocuiesc verificarea lui [Wang et al. \(2023\)](#)

Cum ar putea ajuta AI

- ▣ **Literatura:** lista studiilor care compară distribuțiile randamentelor după filtrarea GARCH, cu eşantioanele și criteriile lor
- ▣ **Cod:** o primă versiune a buclei „standardizează, ajustează șapte modele, ordonează după AIC și BIC, testează în afara eşantionului”
- ▣ **Robustețe:** alte filtre de volatilitate, alte ferestre și alte piețe
- ▣ **Explicație:** o primă versiune a motivului pentru care se schimbă clasamentul după filtrare
- ▣ Exemplu de prompt
 - ▶ Write Python code that divides daily log returns by an EMA volatility ($\lambda = 0.96$), fits Normal, Student-t, skewed-t, GED and NIG by maximum likelihood, and reports AIC, BIC and Akaike weights.

Verificări necesare

- ▣ Informația din viitor: volatilitatea zilei t trebuie să folosească doar randamentele până la $t - 1$
- ▣ Numărul de parametri: k din AIC trebuie să includă fiecare parametru estimat, inclusiv pe cei ai filtrului de volatilitate, dacă au fost estimați
- ▣ Aceleași date pentru toate modelele: valorile AIC calculate pe eșantioane diferite nu se pot compara
- ▣ Parametrizările: scală vs abatere standard la Student-t; S_0 vs S_1 la legea stabilă
- ▣ Referințele: fiecare lucrare citată trebuie să existe; verificați DOI-ul

Sămînță de proiect

- ▣ **Întrebarea:** diferă cea mai bună distribuție pentru randamentele standardizate de cea pentru randamentele brute?
 - ▶ date: BET, S&P 500, DAX, Bitcoin și acțiunile BVB din datele cursului (EODHD)
- ▣ Pași
 - ▶ standardizați cu volatilitatea EMA; ajustați cei șapte candidați; tabel cu ΔAIC și ponderile Akaike
 - ▶ repetați backtesting-ul VaR 1% în afara eșantionului din acest capitol cu modelul standardizat
 - ▶ comparați grupurile de depășiri din 2008 și 2020 cu cele ale modelelor necondiționate
- ▣ Rezultat: un tabel, un grafic și un paragraf despre ce se schimbă și de ce
- ▣ Declarați orice folosire a AI și listați erorile AI pe care le-ați corectat

Idei principale

- ▣ Alegerea modelului începe cu date curate și un scop: corpul sau coada?
- ▣ ML ajustează; testele LR compară modele imbricate (atenție la frontiere); Vuong le compară pe cele neimbricate
- ▣ AIC și BIC ordonează toți candidații; citiți Δ și ponderile Akaike
- ▣ Testele EDF: AD se uită la cozi, KS nu; cu n mare toate sînt respinse, deci ordonați și desenați
- ▣ Randamentele reale: cîștigă NIG, GED și Student-t; legile Normală și stabilă pierd peste tot
- ▣ Validați în afara eșantionului și raportați intervalul VaR între modelele plauzibile

Formule de reținut

Mărimea	Formula
Log-verosimilitatea	$\ell(\theta) = \sum_t \ln f(r_t; \theta)$
Raportul de verosimilitate	$LR = 2(\ell_1 - \ell_0) \approx \chi^2(k_1 - k_0)$
AIC, BIC	$-2\ell(\hat{\theta}) + 2k, \quad -2\ell(\hat{\theta}) + k \ln n$
Ponderele Akaike	$w_i = e^{-\Delta_i/2} / \sum_j e^{-\Delta_j/2}$
Vuong	$V = \sqrt{n} \bar{m} / s_m, \quad m_t = \ln f_1(r_t) - \ln f_2(r_t)$
KS	$D_n = \sup_x F_n(x) - F(x) $
Anderson–Darling	$A^2 = n \int [F_n - F]^2 / [F(1 - F)] dF$
Kupiec	$LR_{uc} = -2 \ln \frac{(1-\alpha)^{n-x} \alpha^x}{(1-x/n)^{n-x} (x/n)^x}$
Pierdere pinball	$\frac{1}{n} \sum_t (\alpha - 1\{r_t < q\})(r_t - q)$

Verificați-vă

- **Întrebare:** modelul A are $\ell = -1000$ cu $k = 3$, modelul B are $\ell = -998$ cu $k = 5$; care are AIC mai mic?
▶ **Răspuns:** A: 2006; B: 2006; egalitate ($\Delta = 0$): cei doi parametri în plus câștigă exact cât penalizarea lor
- **Întrebare:** A este imbricat în B; este B semnificativ mai bun la 5%?
▶ **Răspuns:** $LR = 2 \cdot 2 = 4 < \chi_{0,95}^2(2) = 5,99$: nu
- **Întrebare:** de ce nu poate un test KS cu parametri estimați să folosească tabelul KS clasic?
▶ **Răspuns:** ajustarea apropiere F de date, deci D_n este prea mic; folosiți Lilliefors sau un bootstrap parametric
- Urmează: [Capitolul 7](#), piețele eficiente, mersul aleator și testele variance ratio

Bibliografie (1/3)

- ▣ Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723.
- ▣ Amisano, G., Giacomini, R. (2007). Comparing density forecasts via weighted likelihood ratio tests. *Journal of Business & Economic Statistics*, 25(2), 177–190.
- ▣ Anderson, T.W., Darling, D.A. (1952). Asymptotic theory of certain “goodness of fit” criteria based on stochastic processes. *Annals of Mathematical Statistics*, 23(2), 193–212.
- ▣ Anderson, T.W., Darling, D.A. (1954). A test of goodness of fit. *Journal of the American Statistical Association*, 49(268), 765–769.
- ▣ Barndorff-Nielsen, O.E. (1997). Normal inverse Gaussian distributions and stochastic volatility modelling. *Scandinavian Journal of Statistics*, 24(1), 1–13.
- ▣ Borak, S., Härdle, W.K., López-Cabrera, B. (2013). *Statistics of Financial Markets: Exercises and Solutions*, 2nd ed. Springer.
- ▣ Box, G.E.P. (1976). Science and statistics. *Journal of the American Statistical Association*, 71(356), 791–799.
- ▣ Burnham, K.P., Anderson, D.R. (2002). *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach*, 2nd ed. Springer.
- ▣ Burnham, K.P., Anderson, D.R. (2004). Multimodel inference: understanding AIC and BIC in model selection. *Sociological Methods & Research*, 33(2), 261–304.
- ▣ Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- ▣ Cramér, H. (1928). On the composition of elementary errors. *Scandinavian Actuarial Journal*, 1928(1), 13–74.
- ▣ Danielsson, J., James, K.R., Valenzuela, M., Zer, I. (2016). Model risk of risk models. *Journal of Financial Stability*, 23, 79–91.
- ▣ Diks, C., Panchenko, V., van Dijk, D. (2011). Likelihood-based scoring rules for comparing density forecasts in tails. *Journal of Econometrics*, 163(2), 215–230.
- ▣ Eberlein, E., Keller, U. (1995). Hyperbolic distributions in finance. *Bernoulli*, 1(3), 281–299.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Gneiting, T., Raftery, A.E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378.

Bibliografie (2/3)

- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- ▣ Hoeting, J.A., Madigan, D., Raftery, A.E., Volinsky, C.T. (1999). Bayesian model averaging: a tutorial. *Statistical Science*, 14(4), 382–417.
- ▣ Hurvich, C.M., Tsai, C.-L. (1989). Regression and time series model selection in small samples. *Biometrika*, 76(2), 297–307.
- ▣ Kerkhof, J., Melenberg, B., Schumacher, H. (2010). Model risk and capital reserves. *Journal of Banking & Finance*, 34(1), 267–279.
- ▣ Kon, S.J. (1984). Models of stock returns – a comparison. *Journal of Finance*, 39(1), 147–165.
- ▣ Kullback, S., Leibler, R.A. (1951). On information and sufficiency. *Annals of Mathematical Statistics*, 22(1), 79–86.
- ▣ Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- ▣ Lilliefors, H.W. (1967). On the Kolmogorov–Smirnov test for normality with mean and variance unknown. *Journal of the American Statistical Association*, 62(318), 399–402.
- ▣ Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, 59(2), 347–370.
- ▣ Pearson, K. (1900). On the criterion that a given system of deviations from the probable in the case of a correlated system of variables is such that it can be reasonably supposed to have arisen from random sampling. *Philosophical Magazine*, 50(302), 157–175.
- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Lazar, E., Mazurencu-Marinescu-Pele, M. (2019). Modeling expected shortfall using tail entropy. *Entropy*, 21(12), 1204.
- ▣ Schwarz, G. (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2), 461–464.
- ▣ Self, S.G., Liang, K.-Y. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, 82(398), 605–610.
- ▣ Smirnov, N. (1948). Table for estimating the goodness of fit of empirical distributions. *Annals of Mathematical Statistics*, 19(2), 279–281.
- ▣ Stephens, M.A. (1974). EDF statistics for goodness of fit and some comparisons. *Journal of the American Statistical Association*, 69(347), 730–737.

Bibliografie (3/3)

- ▣ Stone, M. (1977). An asymptotic equivalence of choice of model by cross-validation and Akaike's criterion. *Journal of the Royal Statistical Society, Series B*, 39(1), 44–47.
- ▣ Stute, W., González Manteiga, W., Presedo Quindimil, M. (1993). Bootstrap based goodness-of-fit-tests. *Metrika*, 40(1), 243–256.
- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed. Wiley.
- ▣ Vuong, Q.H. (1989). Likelihood ratio tests for model selection and non-nested hypotheses. *Econometrica*, 57(2), 307–333.
- ▣ Wang, H., Fu, T., Du, Y., Gao, W., et al. (2023). Scientific discovery in the age of artificial intelligence. *Nature*, 620, 47–60.
- ▣ Wilks, S.S. (1938). The large-sample distribution of the likelihood ratio for testing composite hypotheses. *Annals of Mathematical Statistics*, 9(1), 60–62.