



Statistica piețelor financiare

Capitolul 8: Estimatori de volatilitate



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ ACF: Autocorrelation Function (funcția de autocorelație)
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AR: AutoRegressive (model); in event studies: Abnormal Return (model autoregresiv; în studiile de eveniment: randament anormal)
- ▣ ARCH: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ ARCH-LM: ARCH Lagrange Multiplier (test) — testul multiplicatorului Lagrange pentru efecte ARCH
- ▣ BET: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ BVB: Bursa de Valori București
- ▣ CBOE: Chicago Board Options Exchange (bursa de opțiuni din Chicago)
- ▣ DM: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ EODHD: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ ES: Expected Shortfall (pierdere așteptată în coadă)
- ▣ EWMA: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ GARCH: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- ▣ GK: Garman–Klass (volatility estimator) — estimatorul de volatilitate Garman–Klass
- ▣ HAR: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- ▣ IGARCH: Integrated GARCH (GARCH integrat)
- ▣ LM: Lagrange Multiplier (multiplicatorul Lagrange)
- ▣ MSE: Mean Squared Error (eroarea pătratică medie)
- ▣ MZ: Mincer–Zarnowitz (regression) — regresia Mincer–Zarnowitz
- ▣ OHLC: Open, High, Low, Close (deschidere, maxim, minim, închidere)
- ▣ QLIKE: Quasi-LIKelihood (loss function) — funcția de pierdere de tip cvasi-verosimilitate
- ▣ RV: Realised Variance (varianța realizată)
- ▣ SE: Standard Error (eroare standard)
- ▣ SFE: Statistics of Financial Markets, Exercises (Quantlet collection of the textbook) — colecția de Quantlet-uri a manualului Statistics of Financial Markets
- ▣ VIX: CBOE Volatility Index (indicele de volatilitate CBOE)
- ▣ YZ: Yang–Zhang (volatility estimator) — estimatorul de volatilitate Yang–Zhang

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cât de mare este riscul unui activ azi, dacă nu îl putem observa niciodată direct?
 - ▶ **Capitolul 7:** randamentele sînt aproape imprevizibile, dar mărimea lor nu este; aici măsurăm această mărime
 - ▶ **Capitolul 9** transformă măsurătorile într-un model (ARCH și GARCH)
- ▣ **Traseul** capitolului
 - ▶ ce este volatilitatea și de ce este latentă; volatilitatea istorică și alegerea ferestrei
 - ▶ EWMA (RiskMetrics); estimatorii de amplitudine, care folosesc prețurile de deschidere, maxim, minim și închidere
 - ▶ volatilitatea realizată; volatility clustering și testele lui
 - ▶ comportamentul pe termen lung, indicele VIX, efectul de levier; compararea prognozelor de volatilitate

Rezultatele învățării

- ▣ Definiți volatilitatea, anualizați-o cu frecvența reală de tranzacționare și explicați de ce este o mărime latentă
- ▣ Calculați volatilitatea istorică și volatilitatea EWMA și alegeți o fereastră sau un factor de atenuare
- ▣ Calculați estimatorii Parkinson, Garman–Klass, Rogers–Satchell și Yang–Zhang și enunțați ipotezele lor
- ▣ Detectați volatility clustering cu ACF-ul randamentelor la pătrat, testul Ljung–Box și testul ARCH-LM
- ▣ Comparați volatilitatea implicită cu cea realizată și evaluați prognozele de volatilitate cu MSE și QLIKE

Bibliografie și instrumente

- Manual: [Franke, Härdle & Hafner \(2019\)](#), cap. 13 (introducerea: volatilitatea și heteroscedasticitatea condiționată)
 - ▶ exerciții rezolvate: [Borak, Härdle & López-Cabrera \(2013\)](#), cap. 13
- Volatilitatea și faptele ei stilizate: [Tsay \(2010\)](#), cap. 3.1; o sinteză despre prognoza volatilității: [Poon & Granger \(2003\)](#)
- Quantlet-urile Python ale capitolului: [Quantlets/Ch_08](#)
 - ▶ portate din Quantlet-urile SFE SFEkurgarch (boltirea unui proces GARCH) și SFEvolnonparest (volatilitate neparametrică)
- Notebook-ul cursului: [deschideți în Google Colab](#)
- Curs video: [📺 Applied Time Series Analysis with Python](#)

Volatilitatea vine în rafale

- „Variațiile mari tind să fie urmate de variații mari, de orice semn, iar variațiile mici, de variații mici”
Mandelbrot (1963)
 - ▶ după crahul din 19 octombrie 1987, piețele au rămas agitate săptămîni la rînd
- Volatilitatea intră în aproape orice cifră din finanțe
 - ▶ măsurile de risc: VaR și ES (Capitolul 10), raportul Sharpe (Capitolul 1)
 - ▶ prețurile opțiunilor, marjele burselor, mărimea pozițiilor
- Acest capitol: cum o **măsurăm** din prețuri și cum verificăm dacă formează clustere




Bursa din Amsterdam, 21 octombrie 1987, la două zile după crah

Foto: Bart Molendijk / Anefo (1987); CC0; Wikimedia Commons

Volatilitatea: definiție și unități de măsură

- ▣ Randamentul logaritmic zilnic în %: $r_t = 100 (\ln P_t - \ln P_{t-1})$ ([Capitolul 1](#))
 - ▶ **volatilitatea** = abaterea standard a randamentelor, $\sigma = \sqrt{\text{Var}(r_t)}$
 - ▶ are unitatea de măsură a randamentului (% pe zi); varianța σ^2 se măsoară în %²
- ▣ **Anualizarea**: cu a observații pe an și randamente necorelate, $\sigma_{\text{an}} = \sigma_{\text{zi}} \sqrt{a}$
 - ▶ a = frecvența reală: circa 252 pentru S&P 500, 250 pentru BET, 365 pentru Bitcoin (tranzacționat în fiecare zi)
 - ▶ regula $\sqrt{a}$ este regula rădăcinii pătrate a timpului din [Capitolul 7](#): cere randamente necorelate
- ▣ Volatilitatea măsoară dispersia în ambele sensuri: un câștig mare contează la fel de mult ca o pierdere mare
 - ▶ există și alte măsuri ale incertitudinii, de exemplu entropia informațională a randamentelor [Pele, Lazar & Dufour \(2017\)](#)

Patru piețe, același tipar



- Randamente logaritmice zilnice în %: S&P 500 și DAX din 1990, BET din 1997, Bitcoin din 2014; ultima zi: 18 septembrie 2026
- Anii liniștiți alternează cu luni agitate în toate cele patru serii

Interpretarea volatilității pe patru piețe

	Volatilitate anuală	Cea mai mare variație zilnică	Data	Excesul de boltire
S&P 500	18,0%	−12,8%	16 martie 2020	10,9
DAX	21,8%	−13,1%	12 martie 2020	6,0
BET	23,4%	−13,1%	7 ianuarie 2009	9,9
Bitcoin	66,6%	−46,5%	12 martie 2020	12,0

- Bitcoin este cu circa 20% mai volatil pe an decât ar rezulta dacă s-ar folosi greșit $\sqrt{252}$: se tranzacționează 365 de zile pe an
- Cele mai mari variații reprezintă 8–13 abateri standard: valori practic imposibile în cazul distribuției Normale ([Capitolul 2](#))
- Excesul de boltire este mult peste 0 (valoarea pentru distribuția Normală): cozi groase; secțiunea 6 arată că volatility clustering este una dintre cauze

Volatilitatea este latentă

- Model: $r_t = \mu + \sigma_t z_t$, cu z_t i.i.d., de medie 0 și varianță 1
 - ▶ σ_t este **volatilitatea condiționată**: $\sigma_t^2 = \text{Var}(r_t \mid \mathcal{F}_{t-1})$, cu $\mathcal{F}_{t-1}$ informația de la închiderea zilei $t - 1$
 - ▶ **volatilitatea necondiționată** $\sigma = \sqrt{\text{Var}(r_t)}$ este nivelul ei mediu pe termen lung
- **Latentă**: nu observăm niciodată σ_t , ci doar un randament pe zi
 - ▶ r_t^2 este o măsură nedeplasată, dar foarte zgomotoasă, a lui σ_t^2 (cu $\mu = 0$): $E[r_t^2 \mid \mathcal{F}_{t-1}] = \sigma_t^2$
 - ▶ o zi liniștită poate apărea într-o perioadă agitată, și invers
- Trei moduri de a obține mai multă informație despre σ_t
 - ▶ calculăm media pe multe zile (volatilitatea istorică, EWMA); folosim întreaga traiectorie a zilei (prețurile maxim și minim); folosim prețurile din timpul zilei (volatilitatea realizată)

Exemplu rezolvat: anualizarea volatilității

- ▣ S&P 500 din 1990: abaterea standard zilnică $\hat{\sigma} = 1,13\%$, $a = 252$ de observații pe an
 - ▶ $\hat{\sigma}_{\text{an}} = 1,13 \times \sqrt{252} = 1,13 \times 15,87 = 18,0\%$
- ▣ Bitcoin din 2014: $\hat{\sigma} = 3,49\%$ pe zi, 7 zile pe săptămână
 - ▶ corect: $3,49 \times \sqrt{365} = 3,49 \times 19,11 = 66,6\%$
 - ▶ greșit, cu convenția de la acțiuni: $3,49 \times \sqrt{252} = 55,3\%$
- ▣ Pentru a compara active: anualizați fiecare serie cu propriul calendar, apoi comparați

Recapitulare: volatilitatea: definiție și caracter latent

- ▣ Volatilitatea = abaterea standard a randamentelor; se anualizează cu $\sqrt{a}$, unde a este numărul real de observații pe an
- ▣ Volatilitatea condiționată σ_t variază în timp și nu este observată niciodată: o putem doar estima
- ▣ Toate piețele au perioade liniștite și perioade agitate

Volatilitatea istorică (pe fereastră mobilă)

- ▣ **Volatilitatea istorică** pe o fereastră cu ultimele n zile:

- ▶ $\hat{\sigma}_t = \sqrt{\frac{1}{n-1} \sum_{j=0}^{n-1} (r_{t-j} - \bar{r}_t)^2}$, cu $\bar{r}_t$ media aceluiași n randamente

- ▶ **fereastră mobilă**: în fiecare zi intră cel mai nou randament și iese cel mai vechi


- ▣ Varianta cu media zero: $\hat{\sigma}_t^2 = \frac{1}{n} \sum_{j=0}^{n-1} r_{t-j}^2$

- ▶ pentru datele zilnice media este foarte mică în raport cu σ (0,03% față de 1,13% la S&P 500); dacă o fixăm la 0, eliminăm o estimare zgomotoasă

- ▣ Ferestre uzuale: $n = 21$ (o lună), 63 (un trimestru), 252 (un an) de zile de tranzacționare

- ▶ fiecare $\hat{\sigma}_t$ se anualizează cu $\sqrt{a}$ și se reprezintă în ultima zi a ferestrei

S&P 500: trei ferestre, trei răspunsuri



- Volatilitatea S&P 500 pe ferestre mobile, anualizată; linia punctată: volatilitatea pe întregul eșantion, 18,0%
- Întrebare pentru sală: în ce fereastră ați avea încredere în ziua de după un crash?

Interpretarea compromisului dintre ferestre

- ▣ Fereastra scurtă ($n = 21$): reacționează repede, dar este zgomotoasă
 - ▶ maximul 97,5% pe 6 aprilie 2020; variația zilnică tipică a lui $\ln \hat{\sigma}_t$ este 6,7%
- ▣ Fereastra lungă ($n = 252$): netedă, dar lentă
 - ▶ maximul doar 45,6%, atins pe 15 iulie 2009, la câteva luni după vârful crizei din 2008; variația zilnică 0,8%
- ▣ **Răspuns:** o fereastră scurtă sau EWMA (secțiunea următoare), deoarece media pe o fereastră lungă include încă zilele liniștite dinaintea crahului
 - ▶ pentru planificarea capitalului se preferă o fereastră lungă: se schimbă lent
- ▣ La sfârșitul eșantionului: 9,6% (21 de zile), 11,1% (63 de zile), 12,9% (252 de zile)

Precizia unei volatilități de selecție

- ▣ Cu n randamente Normale i.i.d., eroarea standard relativă a lui $\hat{\sigma}$ este $SE(\hat{\sigma})/\sigma \approx 1/\sqrt{2n}$
 - ▶ $n = 21$: 15%; $n = 63$: 9%; $n = 252$: 4%
- ▣ Cu cozi groase (coeficient de boltire κ): $SE(\hat{\sigma})/\sigma \approx \sqrt{(\kappa - 1)/(4n)}$ (metoda delta)
 - ▶ S&P 500: $\kappa = 13,9$, deci $n = 21$: 39%; $n = 252$: 11%
 - ▶ pentru $\kappa = 3$ (distribuția Normală) cele două formule coincid
- ▣ **Exemplu rezolvat:** ultima volatilitate pe 21 de zile a S&P 500 este 9,6%
 - ▶ interval aproximativ de 95%, randamente Normale: [6,7%; 12,5%]; cu boltirea observată: [2,2%; 17,0%]

Recapitulare: volatilitatea istorică

- ▣ Abaterea standard pe o fereastră mobilă de n zile; pentru date zilnice media poate fi fixată la zero
- ▣ Ferestrele scurte reacționează repede, dar sînt zgomotoase; cele lungi sînt netede, dar lente
- ▣ O volatilitate pe 21 de zile are o incertitudine de $\pm 15\%$ sau mai mult: o zecimală înseamnă deja prea multă precizie

1994: RiskMetrics face din volatilitate o cifră zilnică

- J.P. Morgan a lansat RiskMetrics în octombrie 1994 și a publicat gratuit metodele și datele [J.P. Morgan/Reuters \(1996\)](#)
 - ▶ scopul: un etalon comun pentru riscul de piață, valabil pentru toate băncile
 - ▶ volatilitățile și corelațiile a peste 480 de serii, actualizate zilnic
- Metoda: o medie mobilă ponderată exponențial (EWMA) a randamentelor la pătrat
 - ▶ un singur parametru, **factorul de atenuare** λ : 0,94 pentru prognozele zilnice, 0,97 pentru cele lunare
 - ▶ pentru fiecare serie, λ minimizează rădăcina erorii pătratice medii a prognozelor de varianță; 0,94 este media ponderată pe toate seriile



Clădirea J.P. Morgan de la 23 Wall Street, New York


Foto: [Beyond My Ken \(2012\)](#); CC BY-SA 4.0; [Wikimedia](#)

[Commons](#)

Estimatorul EWMA

- ▣ Recurența **EWMA** (media zero): $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, $0 < \lambda < 1$
 - ▶ σ_t^2 folosește randamentele pînă în ziua $t - 1$: este prognoza pentru ziua t
 - ▶ valoarea inițială: $\sigma_1^2 =$ media primelor randamente la pătrat; efectul ei dispare după cîteva luni
- ▣ Prin dezvoltarea recurenței: $\sigma_t^2 = (1 - \lambda) \sum_{j \geq 1} \lambda^{j-1} r_{t-j}^2$
 - ▶ ponderile $(1 - \lambda) \lambda^{j-1}$ scad geometric și au suma 1
 - ▶ **timpul de înjumătățire**: decalajul la care ponderea se înjumătățește, $\ln 0,5 / \ln \lambda$
- ▣ O fereastră mobilă dă ponderea $1/n$ fiecăreia dintre ultimele n zile și 0 tuturor zilelor mai vechi

Ponderile EWMA față de ponderile unei ferestre mobile




- $\lambda = 0,94$: timp de înjumătățire 11,2 zile, decalaj mediu $1/(1 - \lambda) = 16,7$ zile, 99% din pondere în ultimele 74 de zile
- $\lambda = 0,97$: timp de înjumătățire 22,8 zile, 99% din pondere în ultimele 151 de zile

Exemplu rezolvat: o actualizare EWMA

- ▣ Varianța EWMA de ieri: $\sigma_{t-1}^2 = 1,00$ (%²), adică o volatilitate zilnică de 1%; randamentul de ieri: $r_{t-1} = -3\%$
 - ▶ pasul 1: $\lambda\sigma_{t-1}^2 = 0,94 \times 1,00 = 0,94$
 - ▶ pasul 2: $(1 - \lambda)r_{t-1}^2 = 0,06 \times 9 = 0,54$
 - ▶ pasul 3: $\sigma_t^2 = 0,94 + 0,54 = 1,48$, deci $\sigma_t = 1,22\%$ pe zi, $1,22 \times \sqrt{252} = 19,3\%$ pe an
- ▣ Dacă ziua de azi este liniștită ($r_t = 0$): $\sigma_{t+1}^2 = 0,94 \times 1,48 = 1,39$
 - ▶ șocul se atenuează cu 6% pe zi; nu dispăre niciodată brusc
- ▣ O fereastră de 63 de zile ar adăuga azi $9/63 = 0,14$ la varianță și ar elimina dintr-odată această contribuție după 63 de zile

Ghost effect: martie–iunie 2020



- S&P 500: volatilitatea pe fereastra mobilă de 63 de zile și volatilitatea EWMA ($\lambda = 0,94$), anualizate; barele: $|r_t|$ pe aceeași scală anuală
- **Întrebare pentru sală:** de ce scade brusc linia albastră la mijlocul lui iunie 2020, într-o zi liniștită?

Interpretarea ghost effect

- ▣ **Răspuns:** pe 15 iunie 2020, randamentul din 16 martie 2020 ($-12,8\%$) a ieșit din fereastra de 63 de zile
 - ▶ volatilitatea pe fereastra mobilă a scăzut de la $50,4\%$ la $43,0\%$ într-o singură zi, fără nicio știre
 - ▶ acest artefact este **ghost effect**: un șoc vechi iese brusc din fereastră
- ▣ EWMA reacționează mai repede și uită treptat
 - ▶ vârful EWMA: $84,8\%$ pe 24 martie 2020; vârful pe 63 de zile: $62,6\%$ abia pe 20 mai 2020
 - ▶ în ziua ghost effect, EWMA s-a modificat cu doar $-0,9$ puncte procentuale
- ▣ Prețul vitezei: EWMA este mai zgomotos decât o fereastră lungă și nu are un nivel de lungă durată spre care să revină

EWMA și GARCH: trimitere la Capitolul 9

- ▣ **ARCH Engle (1982)** și **GARCH Bollerslev (1986)**: $\sigma_t^2 = \omega + \alpha r_{t-1}^2 + \beta \sigma_{t-1}^2$
 - ▶ EWMA este cazul particular $\omega = 0$, $\alpha = 1 - \lambda$, $\beta = \lambda$, deci $\alpha + \beta = 1$ (GARCH „integrat”, **IGARCH**)
- ▣ Consecințe pentru prognozele făcute în ziua t pentru ziua $t + h$
 - ▶ EWMA: constantă, $E_t[\sigma_{t+h}^2] = \sigma_{t+1}^2$ pentru orice h : nivelul de azi persistă la nesfârșit
 - ▶ GARCH cu $\alpha + \beta < 1$: atrasă spre varianța de lungă durată $\omega/(1 - \alpha - \beta)$
- ▣ **Capitolul 9** estimează ω , α , β prin verosimilitate maximă; aici λ este fixat sau ales după un criteriu de prognoză (secțiunea 8)


Recapitulare: EWMA și RiskMetrics

- ▣ $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$; RiskMetrics: $\lambda = 0,94$ pentru date zilnice
- ▣ Ponderi geometrice: timp de înjumătățire 11,2 zile pentru $\lambda = 0,94$; fără ghost effect
- ▣ EWMA = IGARCH(1,1) fără constantă: prognoze constante, fără revenire la medie

Prețurile de deschidere, maxim, minim și închidere

- ▣ Datele **OHLC**: pentru fiecare zi t , deschiderea O_t , maximul H_t , minimul L_t și închiderea C_t
 - ▶ randamentul închidere–închidere folosește 2 prețuri pe zi; H_t și L_t conțin informație despre întreaga traiectorie a zilei
- ▣ Notății (diferențe logaritmice în %), fiecare față de deschiderea zilei t :
 - ▶ $u_t = \ln(H_t/O_t)$, $d_t = \ln(L_t/O_t)$, $c_t = \ln(C_t/O_t)$; deci $d_t \leq 0 \leq u_t$ și $d_t \leq c_t \leq u_t$
 - ▶ randamentul **overnight** $o_t = \ln(O_t/C_{t-1})$; randamentul zilnic este $r_t = o_t + c_t$
 - ▶ **amplitudinea** (range) $u_t - d_t = \ln(H_t/L_t)$
- ▣ Date: S&P 500 din 2008, DAX din 2006, Bitcoin din 2014, acțiuni BVB din 2010; fișierul BET conține doar închideri

O zi de tranzacționare: ce înregistrează OHLC



- Preț logaritmic simulat (mișcare browniană, 390 de pași de un minut) după un salt overnight de 0,35%: închiderea păstrează doar punctul final; maximum și minimum rezumă traiectoria
- Două zile cu aceeași închidere pot avea amplitudini foarte diferite, deci riscuri foarte diferite

Estimatorul Parkinson (1980)

- ▣ Pentru o mișcare browniană fără tendință (drift), cu varianța σ^2 pe zi: $E[(u_t - d_t)^2] = 4 \ln 2 \sigma^2$ Parkinson (1980)
 - ▶ o zi: $\hat{\sigma}_{P,t}^2 = \frac{(u_t - d_t)^2}{4 \ln 2}$; pe n zile: media acestor valori
 - ▶ $4 \ln 2 \approx 2,77$: amplitudinea este, în medie, mai mare decât σ
- ▣ Ipoteze
 - ▶ tranzacționare continuă în timpul zilei, deci maximul și minimul observate sînt extremele reale
 - ▶ fără tendință și fără salt overnight: amplitudinea vede doar ședința de tranzacționare
- ▣ Mult mai precis decât r_t^2 : o simulare din această secțiune măsoară cu cît
 - ▶ logaritmul amplitudinii se folosește și la estimarea modelelor de volatilitate stochastică Alizadeh, Brandt & Diebold (2002)

Garman–Klass (1980) și Rogers–Satchell (1991)

- ▣ **Garman–Klass** Garman & Klass (1980): adaugă randamentul deschidere–închidere
 - ▶ $\hat{\sigma}_{GK,t}^2 = 0,5 (u_t - d_t)^2 - (2 \ln 2 - 1) c_t^2$
 - ▶ ponderile fac estimatorul nedeplasat și aproape de varianță minimă printre astfel de forme pătratice, în absența tendinței
- ▣ **Rogers–Satchell** Rogers & Satchell (1991): nedeplasat pentru orice tendință μ
 - ▶ $\hat{\sigma}_{RS,t}^2 = u_t(u_t - c_t) + d_t(d_t - c_t)$
 - ▶ util pentru active cu o tendință puternică pe fereastră (de exemplu, Bitcoin într-o perioadă de creștere puternică)
- ▣ Ambele ignoră totuși randamentul overnight o_t : măsoară doar varianța ședinței de tranzacționare

Yang–Zhang (2000): adăugarea nopții

- Pe o fereastră de n zile Yang & Zhang (2000):

$$\hat{\sigma}_{YZ}^2 = \hat{\sigma}_O^2 + k \hat{\sigma}_C^2 + (1 - k) \hat{\sigma}_{RS}^2, \quad k = \frac{0,34}{1,34 + (n + 1)/(n - 1)}$$

- $\hat{\sigma}_O^2, \hat{\sigma}_C^2$: varianțele de selecție ale randamentelor overnight o_t și ale randamentelor deschidere–închidere c_t ;
 $\hat{\sigma}_{RS}^2$: media termenului Rogers–Satchell

- Proprietăți


- nedeplasat cu tendință și cu salturi la deschidere; k minimizează varianța estimatorului
- $n = 21$: $k = 0,34/(1,34 + 22/20) = 0,34/2,44 = 0,14$

- Cere o fereastră de $n \geq 2$ zile (varianțe de selecție); Parkinson, Garman–Klass și Rogers–Satchell funcționează și pentru o singură zi

Exemplu rezolvat: S&P 500 pe 16 martie 2020

- ▣ Închiderea precedentă 2711; deschiderea 2509, maximul 2563, minimul 2381, închiderea 2386
 - ▶ $o = -7,76$, $u = 2,14$, $d = -5,22$, $c = -5,00$ (în %); închidere–închidere $r = o + c = -12,77$
- ▣ Estimări ale varianței pentru o zi ($\%^2$)
 - ▶ închidere–închidere: $r^2 = 163,0$
 - ▶ Parkinson: $(7,37)^2/2,773 = 19,6$; Garman–Klass: 17,5; Rogers–Satchell: 16,5
 - ▶ partea overnight $o^2 = 60,2$; overnight plus Rogers–Satchell: 76,7
- ▣ Cea mai mare parte a scăderii s-a produs overnight, înainte de deschidere: estimatorii care ignoră o_t ratează cea mai mare parte a riscului din această zi

Eficiența estimatorilor prin simulare



- 1000 de ferestre de 21 de zile; volatilitatea reală 1% pe zi (15,9% pe an); mișcare browniană intrazilnică pe 4680 de pași (unul la 5 secunde)
- Eficiența** unui estimator: $\text{Var}(\hat{\sigma}_{CC}^2)/\text{Var}(\hat{\sigma}^2)$, CC fiind estimatorul închidere–închidere; panoul din dreapta: 20% din varianța zilnică apare overnight

Interpretarea simulării: precizie și deplasare

	CC	Parkinson	GK	RS	YZ
Eficiența, tranzacționare continuă	1,0	5,4	9,3	7,6	8,5
Deplasarea (%), tranzacționare continuă	0	−2	−3	−3	−2
Deplasarea (%), salt overnight	1	−22	−22	−22	−2
Raportul MSE, salt overnight	1,0	1,8	1,8	1,8	9,0
Deplasarea (%), 26 de prețuri pe zi	0	−23	−32	−32	−28

- Cu tranzacționare continuă, estimatorii de amplitudine sînt de 5–9 ori mai eficienți: o lună de amplitudini conține tot atîta informație cît 5–9 luni de închideri
- Cu salt overnight, Parkinson, GK și RS ratează noaptea (deplasare de circa −22%); doar YZ rămîne nedeplasat; raportul **MSE** (mean squared error, eroarea pătratică medie) = $\text{MSE}(\text{CC})/\text{MSE}$
- Cu puține tranzacții amplitudinea observată este prea mică: toți estimatorii de amplitudine subestimează (piețe puțin lichide) [Molnár \(2012\)](#)

Date reale: cinci estimatori, cinci active

	Din	CC	P	GK	RS	YZ	Ponderea nopții	$\text{corr}(o, c)$
S&P 500	2008	19,9	15,4	14,6	14,4	16,3	13%	0,22
DAX	2006	20,9	16,7	16,6	16,6	20,3	31%	0,02
Bitcoin	2014	66,6	63,5	62,4	62,5	63,2	0%	0,02
TLV	2010	26,6	21,5	20,6	21,0	25,6	26%	-0,08
SNP	2010	24,5	21,4	20,8	21,4	25,8	27%	-0,20


- Volatilitatea anualizată (%) pe întregul eșantion OHLC; $P = \text{Parkinson}$; ponderea nopții = $\hat{\sigma}_O^2 / (\hat{\sigma}_O^2 + \hat{\sigma}_C^2)$
- Acțiuni: deschiderea, maximul și minimul ajustate cu același factor ca închiderea; zilele fără tranzacții sînt eliminate

 SFM_ch8_range_estimators

Interpretarea diferențelor dintre estimatori

- ▣ Bitcoin se tranzacționează 24 de ore din 24: ponderea nopții este aproape 0, iar toți cei cinci estimatori sînt apropiați
 - ▶ diferența rămasă: traiectoria zilei este observată prin tranzacții discrete, nu continuu
- ▣ DAX și acțiunile BVB: între un sfert și o treime din varianță apare overnight
 - ▶ Parkinson, GK și RS sînt mult sub CC; YZ, care adaugă noaptea, este apropiat de CC
- ▣ S&P 500: chiar și YZ (16,3%) rămîne sub CC (19,9%)
 - ▶ randamentele overnight și cele deschidere–închidere sînt corelate pozitiv (0,22); o explicație probabilă: deschiderea indicelui folosește prețuri vechi ale acțiunilor care încă nu s-au tranzacționat
 - ▶ $\text{Var}(r) = \text{Var}(o) + \text{Var}(c) + 2 \text{Cov}(o, c)$: niciun estimator de amplitudine nu vede termenul de covarianță
- ▣ Lecția: verificați ipotezele pe date înainte de a avea încredere într-un câștig de eficiență

S&P 500: estimări pe 21 de zile din 2019



- Volatilitatea pe 21 de zile, anualizată, calculată cu cei cinci estimatori; medii din 2019: CC 16,3%, Parkinson 12,5%, YZ 14,7%
- Liniile estimatorilor de amplitudine sînt mai netede: variația zilnică tipică a estimării logaritmice este 4,3% pentru Parkinson și 4,2% pentru YZ, față de 7,1% pentru CC


Recapitulare: estimatori de amplitudine

- ▣ Parkinson folosește amplitudinea, Garman–Klass adaugă randamentul deschidere–închidere, Rogers–Satchell permite o tendință, Yang–Zhang adaugă noaptea
- ▣ În teorie de 5–9 ori mai eficienți decât estimatorul închidere–închidere; în practică deplasați în jos de salturile overnight și de tranzacționarea discretă
- ▣ Alegeți Yang–Zhang pentru piețele care se închid noaptea; orice estimator de amplitudine pentru piețele deschise 24 de ore

Varianța realizată din randamentele intrazilnice


- Împărțim ziua t în M intervale (de exemplu $M = 78$ de randamente de cinci minute $r_{t,i}$ într-o ședință de 6,5 ore)
 - ▶ **varianța realizată** $RV_t = \sum_{i=1}^M r_{t,i}^2$; **volatilitatea realizată** $= \sqrt{RV_t}$
 - ▶ când $M \rightarrow \infty$, RV_t converge către **varianța integrată** a zilei t , adică varianța reală a zilei Andersen, Bollerslev, Diebold & Labys (2003), Barndorff-Nielsen & Shephard (2002)
- Volatilitatea devine aproape observabilă: o măsură aproape fără eroare pentru fiecare zi
 - ▶ se folosește la evaluarea prognozelor (secțiunea 8) și la prognoza directă a volatilității, de exemplu cu modelul HAR Corsi (2009)
 - ▶ prețuri Bitcoin de înaltă frecvență și riscul zilnic: Pele & Mazurencu-Marinescu-Pele (2019)
- Datele cursului sînt zilnice; următoarele două slide-uri folosesc prețuri simulate la un minut pentru a arăta comportamentul RV

Exemplu simulat: RV urmărește volatilitatea reală



- 60 de zile simulate, fiecare cu 390 de randamente de un minut; logaritmul volatilității zilnice urmează un proces AR(1) (persistența 0,9)
- Eroarea relativă absolută medie: RV la 5 minute 6%, Parkinson 23%, $|r_t|$ 58%; corelația cu valoarea reală: 0,995; 0,94 și 0,59

Zgomotul de microstructură și signature plot




- Prețurile observate = prețurile reale + **zgomot de microstructură** (oscilația între bid și ask, pasul de cotare), aici cu abaterea standard 0,025%; fiecare randament la pătrat crește atunci, în medie, cu dublul varianței zgomotului
- Cu zgomot, RV la un minut supraestimează varianța de 1,79 ori; la 5 minute: 1,15; **signature plot** arată RV în funcție de intervalul de eșantionare
- În practică, RV la 5 minute este greu de depășit [Liu, Patton & Sheppard \(2015\)](#)

Recapitulare: volatilitatea realizată

- ▣ $RV_t = \sum_i r_{t,i}^2$; estimează varianța unei zile aproape fără eroare
- ▣ Eșantionarea prea deasă preia zgomotul de microstructură; 5 minute este compromisul uzual
- ▣ Ordinea după precizie a măsurilor zilnice: $RV > \text{estimatorii de amplitudine} > \text{randamentul zilnic la pătrat}$

1982: Engle și modelul ARCH

- **Volatility clustering**: perioadele cu randamente mari în valoare absolută alternează cu perioade cu randamente mici [Mandelbrot \(1963\)](#), [Cont \(2001\)](#)
 - ▶ randamentele sînt aproape necorelate ([Capitolul 7](#)), dar $|r_t|$ și r_t^2 sînt puternic autocorelate
- Robert F. Engle [Engle \(1982\)](#): varianța de azi depinde de șocurile la pătrat de ieri: **ARCH**
 - ▶ primul model în care σ_t variază în timp într-un mod previzibil
 - ▶ Premiul Nobel pentru economie (2003), împărțit cu Clive Granger [Nobel Prize \(2003\)](#); prelegerea Nobel a lui Engle: [Engle \(2004\)](#)
- Această secțiune: testele pentru volatility clustering; [Capitolul 9](#): modelele




Robert F. Engle (n. 1942), Santiago, 2017

Foto: [Econterms \(2017\)](#); CC BY-SA 4.0; [Wikimedia](#)

[Commons](#)

Semnul este imprevizibil, mărimea nu




- ACF de selecție (funcția de autocorelație, [Capitolul 7](#)) pentru r_t , r_t^2 și $|r_t|$, decalajele 1–100, cu banda de 95% $\pm 1,96/\sqrt{T}$ pentru date i.i.d.
- S&P 500: toate cele 100 de autocorelații ale lui r_t^2 și $|r_t|$ sînt deasupra benzii; la decalajul 100, $|r_t|$ are încă 0,09

Interpretarea volatility clustering pe trei piețe

	$\hat{\rho}_1(r)$	$\hat{\rho}_{10}(r)$	$\hat{\rho}_{100}(r)$	$\hat{\rho}_1(r^2)$	$\hat{\rho}_{10}(r^2)$	Decalaje în afara benzii, $ r $
S&P 500	0,27	0,28	0,09	0,31	0,24	100/100
BET	0,41	0,23	0,11	0,33	0,18	100/100
Bitcoin	0,21	0,12	0,02	0,14	0,04	92/100

- Scădere lentă: un șoc de volatilitate se vede încă după luni de zile; Capitolul 11 numește acest fenomen memorie lungă
- Efectul Taylor:** $|r_t|$ este mai autocorelat decât r_t^2 (96% dintre decalaje la S&P 500, toate decalajele la BET și Bitcoin) [Ding, Granger & Engle \(1993\)](#)
- Bitcoin: volatility clustering mai slab în r_t^2 (26 din 100 de decalaje în afara benzii): câteva zile foarte mari domină pătratele

Este volatility clustering real? Amestecați zilele



- Aceleași randamente S&P 500 într-o ordine aleatoare: aceeași distribuție și aceeași boltire (excesul de boltire 10,9), dar fără volatility clustering
- $\hat{\rho}_1(|r|)$: 0,27 în ordinea reală, -0,02 după amestecare; Ljung–Box $Q(10)$ pentru r_t^2 : 8 015 față de 6,3
- Volatility clustering este o proprietate a **ordinii** randamentelor, nu a distribuției lor

Testarea volatility clustering: Ljung–Box pe randamentele la pătrat

- H_0 : fără volatility clustering, $\text{Var}(r_t | \mathcal{F}_{t-1})$ constantă, deci r_t^2 este necorelat
 - ▶ **Testul McLeod–Li** [McLeod & Li \(1983\)](#): statistica Ljung–Box [Ljung & Box \(1978\)](#) aplicată lui r_t^2
 - ▶ $Q(m) = T(T+2) \sum_{k=1}^m \hat{\rho}_k(r^2)^2 / (T-k) \sim \chi^2(m)$ în ipoteza H_0 ; respingem dacă $Q(m)$ depășește cuantila de 95%
- **Exemplu rezolvat**: S&P 500, $T = 9\,240$, $m = 3$
 - ▶ $\hat{\rho}_1, \hat{\rho}_2, \hat{\rho}_3$ pentru r_t^2 : 0,311; 0,408; 0,250
 - ▶ termenii $T(T+2)\hat{\rho}_k^2/(T-k)$: 892; 1540; 579; $Q(3) = 3\,012 \gg \chi_{0,95}^2(3) = 7,81$: respingem H_0
- Același test aplicat lui r_t ([Capitolul 7](#)) pune o altă întrebare: este **media** previzibilă?

Testul ARCH-LM (Engle, 1982)


- Regresia auxiliară a randamentelor centrate la pătrat e_t^2 , $e_t = r_t - \bar{r}$, pe q dintre propriile lor decalaje [Engle \(1982\)](#):
 - ▶ $e_t^2 = c_0 + c_1 e_{t-1}^2 + \dots + c_q e_{t-q}^2 + u_t$; $H_0: c_1 = \dots = c_q = 0$
 - ▶ statistica **LM** (Lagrange multiplier, multiplicatorul Lagrange): $LM = nR^2 \sim \chi^2(q)$, n = numărul de observații din regresie
- S&P 500, $q = 5$: $R^2 = 0,241$, $n = 9\,235$
 - ▶ $LM = 9\,235 \times 0,241 = 2\,227 \gg \chi_{0,95}^2(5) = 11,07$: efecte ARCH puternice
- Interpretarea lui R^2 : circa un sfert din variația de la o zi la alta a lui e_t^2 poate fi anticipată din ultimele cinci zile
- Ambele teste sînt diagnostice: arată că volatility clustering există, nu cum îl modelăm ([Capitolul 9](#))

Testele de volatility clustering pe șase serii

	T	$\hat{\rho}_1(r)$	$Q(10), r$	$\hat{\rho}_1(r^2)$	$Q(10), r^2$	$Q(10), r $	ARCH-LM(5)	Exc. boltire
S&P 500	9 240	-0,079	90,8	0,311	8 015	8 323	2 227	10,9
DAX	9 288	-0,009	21,8	0,155	3 747	5 794	1 209	6,0
BET	7 243	0,156	198,3	0,333	2 500	5 184	1 057	9,9
Bitcoin	4 384	-0,022	20,2	0,137	213	1 086	115	12,0
TLV	3 788	0,010	29,1	0,122	481	1 179	253	13,5
SNP	3 815	-0,015	20,7	0,195	505	944	234	8,9

- Valori critice de 5%: $\chi_{0,95}^2(10) = 18,31$ pentru $Q(10)$, $\chi_{0,95}^2(5) = 11,07$ pentru ARCH-LM(5); toate statisticile pentru r^2 și $|r|$ resping, cu $p < 0,001$
- $Q(10)$ pentru r este mult mai mic: previzibilitatea mediei este slabă (Capitolul 7), cea a mărimii este puternică peste tot
- Bitcoin și cele două acțiuni BVB au cele mai mici valori ARCH-LM, deși au cozi groase: câteva zile extreme diluează regresia

Volatility clustering produce cozi groase




- Stînga: zile liniștite cu abaterea standard 1, zile agitate cu abaterea standard 2 (ponderea $p = 0,2$): $E[\sigma^2] = 1,6$, $E[\sigma^4] = 4,0$, coeficientul de boltire $3E[\sigma^4]/E[\sigma^2]^2 = 4,69$, deși fiecare zi este Normală
- Dreapta: coeficientul de boltire al unui GARCH(1,1), $3 + 6\alpha^2/(1 - \beta^2 - 2\alpha\beta - 3\alpha^2)$, ca în SFekurgarch; $\alpha = 0,10$, $\beta = 0,85$: 3,77 (Capitolul 9)

Recapitulare: volatility clustering

- ▣ r_t aproape necorelat, $|r_t|$ și r_t^2 corelate puternic și persistent: volatility clustering
- ▣ Testele: Ljung–Box pe r_t^2 (McLeod–Li) și ARCH-LM = nR^2 ; ambele resping pe toate piețele
- ▣ Volatility clustering ține de ordinea randamentelor și este una dintre sursele cozilor groase

Volatilitatea în trei decenii



- Stînga: volatilitatea fiecărui an calendaristic (anualizată, %); dreapta: logaritmul volatilității realizate lunare a S&P 500 (din randamente zilnice) față de luna precedentă
- S&P 500: de la 7% (2017) la 41% (2008); BET: de la 10% (2017) la 43% (2008); Bitcoin: de la 42% (2025) la 94% (2017)

Interpretarea persistenței și a revenirii la medie

- Volatilitatea se schimbă în timp, dar nu se îndepărtează la nesfârșit: revine la un nivel normal [Schwert \(1989\)](#)
 - ▶ AR(1) pentru logaritmul volatilității realizate lunare a S&P 500 (441 de luni): $\hat{\phi} = 0,67$ (SE 0,04)
 - ▶ timpul de înjumătățire al unui șoc de volatilitate: $\ln 0,5 / \ln \hat{\phi} = 1,7$ luni; nivelul de lungă durată circa 13,5%
- Volatilitatea lunară are asimetrie la dreapta (coeficientul de asimetrie 3,3), logaritmul ei mult mai puțin (0,6) [Andersen, Bollerslev, Diebold & Ebens \(2001\)](#)
 - ▶ media 15,3% este peste mediana 12,9%: câteva luni de criză trag media în sus
 - ▶ de aceea modelele volatilității sînt adesea scrise pentru $\ln \sigma_t$
- Revenirea la medie este exact ce îi lipsește modelului EWMA și ce are GARCH cu $\alpha + \beta < 1$ ([Capitolul 9](#))

 SFM_ch8_long_term_vix

VIX: volatilitatea implicită


- Opțiunile se tranzacționează la bursă din 1973, când membrii bursei Chicago Board of Trade au înființat **CBOE** (Chicago Board Options Exchange)
 - ▶ prețul unei opțiuni depinde de volatilitatea pe care piața o așteaptă până la scadență
 - ▶ **volatilitatea implicită**: volatilitatea care, introdusă într-o formulă de evaluare a opțiunilor, dă prețul observat
- **VIX**, introdus în 1993 [Whaley \(1993\)](#): volatilitatea așteptată a S&P 500 pentru următoarele 30 de zile calendaristice, din prețurile opțiunilor pe S&P 500 [Cboe \(2026\)](#)
 - ▶ exprimat în procente anualizate: $VIX = 20$ înseamnă circa $20/\sqrt{12} \approx 5,8\%$ pe o lună
 - ▶ numit „indicele fricii”: crește brusc când acțiunile scad [Whaley \(2009\)](#)



Agenți de bursă la Chicago Board of Trade, 31 mai 1973

Foto: [U.S. Department of Agriculture \(1973\)](#); domeniu public; [Wikimedia Commons](#)

VIX față de volatilitatea care a urmat



- VIX și volatilitatea realizată a S&P 500 în următoarele 21 de zile de tranzacționare, $\sqrt{(a/21) \sum_{j=1}^{21} r_{t+j}^2}$; maximul VIX: 82,7 pe 16 martie 2020
- Întrebare pentru sală: linia roșie este de obicei deasupra sau sub cea albastră?

Interpretarea relației dintre volatilitatea implicită și cea realizată


- **Răspuns:** deasupra; VIX a depășit volatilitatea realizată din următoarele 21 de zile în 86% din cele 9 199 de zile
 - ▶ media VIX 19,4% față de media volatilității realizate 15,3%: o diferență de 4,1 puncte
 - ▶ **prima de risc a varianței:** investitorii plătesc pentru a fi asigurați împotriva salturilor de volatilitate Carr & Wu (2009), Bollerslev, Tauchen & Zhou (2009)
- Ca prognoză, VIX este informativ, dar deplasat
 - ▶ regresia volatilității realizate viitoare pe VIX: realizată = $-1,72 + 0,88 \text{ VIX}$, $R^2 = 0,52$
 - ▶ volatilitatea realizată din ultimele 21 de zile explică mai puțin: $R^2 = 0,44$
- Variațiile zilnice ale logaritmului VIX și randamentele S&P 500: corelație $-0,71$: frica crește când prețurile scad

 SFM_ch8_long_term_vix

Efectul de levier


- ▣ **Efectul de levier:** randamentele negative sînt urmate de o volatilitate mai mare decît randamentele pozitive de aceeași mărime [Christie \(1982\)](#)
 - ▶ explicația prin levier: scăderea prețului acțiunii crește raportul datorii/capital propriu, deci acțiunea devine mai riscantă
 - ▶ explicația prin feedback de volatilitate: o volatilitate așteptată mai mare crește randamentul cerut, deci prețul scade azi [French, Schwert & Stambaugh \(1987\)](#), [Bekaert & Wu \(2000\)](#)
- ▣ O măsură simplă: $\text{corr}(r_t, |r_{t+j}|)$ pentru $j = 1, 2, \dots$
 - ▶ negativă: căderea de azi anunță agitația de mâine; zero într-un model simetric
- ▣ [Capitolul 2](#) a arătat asimetria distribuției; aici asimetria apare în **dinamica** volatilității

Veștile proaste cresc volatilitatea viitoare



- $\text{corr}(r_t, |r_{t+j}|)$, $j = 1, \dots, 10$; S&P 500: $-0,122$ la $j = 1$; în sens invers, $\text{corr}(|r_{t-1}|, r_t) = 0,025$
- Media lui r_{t+1}^2 după o zi de scădere împărțită la cea după o zi de creștere: S&P 500 1,51, DAX 1,46, BET 1,41, Bitcoin 1,06

Volatilitatea neparametrică în funcție de randamentul de ieri



- $\hat{\sigma}(x) = \sqrt{\hat{m}_2(x) - \hat{m}_1(x)^2}$, $\hat{m}_1$, $\hat{m}_2$: regresii liniare locale ale lui r_t și r_t^2 pe $r_{t-1} = x$ (nucleu cvartic, lățimea de bandă 0,04 pe randamente zecimale, ca în SFEvolnonparest)
- S&P 500: $\hat{\sigma}(-2\%) = 1,61\%$ față de $\hat{\sigma}(+2\%) = 1,16\%$; minimumul este la $x \approx 0,7\%$, nu la 0: un impact asimetric al știrilor

Recapitulare: comportamentul pe termen lung, VIX și efectul de levier

- ▣ Volatilitatea este persistentă, dar revine la medie: timp de înjumătățire de circa 1,7 luni la S&P 500
- ▣ VIX (volatilitatea implicită) este peste volatilitatea realizată în 86% din zile: o primă de risc a varianței
- ▣ Efectul de levier: scăderile cresc volatilitatea viitoare la indicii bursieri; mai slab și de mai scurtă durată la Bitcoin

Problema variabilei proxy

- O prognoză h_t a lui σ_t^2 se face la închiderea zilei $t - 1$; valoarea reală σ_t^2 nu este observată niciodată
 - ▶ comparăm h_t cu o variabilă **proxy** $\hat{\sigma}_t^2$: o mărime măsurabilă cu $E[\hat{\sigma}_t^2 | \mathcal{F}_{t-1}] = \sigma_t^2$
- Variabile proxy, de la zgomotoase la precise: r_t^2 , un estimator de amplitudine, varianța realizată
 - ▶ cu r_t^2 chiar și o prognoză perfectă pare slabă: [Andersen & Bollerslev \(1998\)](#) au arătat că un R^2 mic nu înseamnă un model prost
- **Regresia Mincer–Zarnowitz** [Mincer & Zarnowitz \(1969\)](#): $\hat{\sigma}_t^2 = a + b h_t + u_t$
 - ▶ o prognoză bună are $a \approx 0$, $b \approx 1$; R^2 măsoară ce parte din variația variabilei proxy este explicată de prognoză

Funcții de pierdere: MSE și QLIKE


- Pierderea medie pe zilele de evaluare; o valoare mai mică este mai bună [Patton \(2011\)](#)
 - ▶ MSE: $L = (\hat{\sigma}_t^2 - h_t)^2$
 - ▶ **QLIKE** (quasi-likelihood, cvasi-verosimilitate): $L = \hat{\sigma}_t^2/h_t + \ln h_t$, adică, pînă la constante, opusul log-verosimilității Normale
- Ambele sînt **robuste**: cu o variabilă proxy zgomotoasă, dar nedeplasată, ordonează prognozele la fel ca varianța reală
 - ▶ pierderile calculate pe $\sqrt{h_t}$ sau pe $\ln h_t$ nu sînt robuste și pot prefera prognoza greșită
- **Exemplu rezolvat**: varianța reală și variabila proxy egale cu 1; două prognoze, $h = 0,5$ și $h = 2$
 - ▶ MSE: $(1 - 0,5)^2 = 0,25$ față de $(1 - 2)^2 = 1$: MSE penalizează mai mult supraestimarea
 - ▶ QLIKE: $1/0,5 + (-0,693) = 1,307$ față de $1/2 + 0,693 = 1,193$: QLIKE penalizează mai mult subestimarea, eroarea costisitoare în managementul riscului

S&P 500: care prognoză este cea mai bună?

	21 de zile	63 de zile	252 de zile	EWMA 0,94	EWMA 0,97	VIX
MSE	18,99	20,77	21,43	17,77	19,02	16,70
QLIKE	0,876	0,914	1,099	0,808	0,844	0,799
MZ R^2 , proxy r^2	0,14	0,05	0,01	0,17	0,11	0,25
MZ R^2 , proxy de amplitudine	0,24	0,09	0,02	0,29	0,19	0,42


- Prognoze ale varianței pentru ziua următoare, pentru 4 202 de zile, începînd din 2010; proxy r_t^2 ; prognoza VIX: VIX^2/a ; proxy de amplitudine: o_t^2 plus termenul Garman–Klass
- Testul DM (Diebold–Mariano) al egalității QLIKE Diebold & Mariano (1995): EWMA 0,94 față de 21 de zile $t = -4,50$ ($p < 0,001$); VIX față de EWMA 0,94 $t = -0,32$ ($p = 0,751$)
- EWMA este semnificativ mai bun decît fereastra de 21 de zile; VIX și EWMA nu diferă semnificativ; fereastra lungă este cea mai slabă; o variabilă proxy precisă crește fiecare R^2 , dar nu schimbă ordinea

Prognozele din 2020



- Prognozele volatilității S&P 500 pentru ziua următoare în 2020 (anualizate): fereastra de 252 de zile, EWMA ($\lambda = 0,94$) și VIX; barele: $|r_t|$
- VIX a început să crească cu o zi de tranzacționare înaintea primei scăderi mari din februarie 2020; EWMA a crescut imediat după ea; fereastra de 252 de zile s-a mișcat lent și a rămas aproape de vîrf pînă la sfîrșitul anului

Alegerea lui λ după QLIKE



- QLIKE mediu al prognozelor EWMA pentru ziua următoare (proxy r_t^2 , din 2010; Bitcoin din 2016) minus minimul lui, pentru λ între 0,80 și 0,995
- Cel mai bun λ : S&P 500 0,925, BET 0,885, Bitcoin 0,970; valoarea RiskMetrics 0,94 pierde doar 0,002 la S&P 500
- Un singur λ pentru toate activele este un compromis comod, nu un optim

Recapitulare: evaluarea prognozelor de volatilitate

- ▣ Comparăm prognozele cu o variabilă proxy; r_t^2 este nedeplasat, dar zgomotos, deci valorile R^2 sînt mici chiar și pentru prognoze bune
- ▣ Folosiți pierderi robuste (MSE, QLIKE) și testați diferențele (Diebold–Mariano); o comparație amplă a modelelor de volatilitate: [Hansen & Lunde \(2005\)](#)
- ▣ S&P 500: EWMA și VIX sînt cele mai bune prognoze simple; ferestrele lungi sînt cele mai slabe

O întrebare deschisă

- ▣ **Ajută estimatorii de amplitudine la Bursa de Valori București, unde multe acțiuni se tranzacționează rar?**
 - ▶ teoria: amplitudinile sînt de 5–9 ori mai eficiente; dar tranzacționarea rară micșorează amplitudinea observată (secțiunea 4)
 - ▶ zile cu tranzacții, dar cu închiderea neschimbată, din 2010: TLV 9%, SNP 8%, BRD 10%, TGN 10%
 - ▶ raportul volatilităților Parkinson / închidere–închidere: TLV 0,81, SNP 0,87, BRD 0,90, TGN 0,87 (S&P 500: 0,78)
 - ▶ QLIKE al prognozelor pentru ziua următoare, cu fereastra de 21 de zile, CC față de YZ: TLV 2,022 față de 2,039; TGN 1,750 față de 1,636
- ▣ Întrebarea rămîne deschisă: răspunsul diferă de la o acțiune la alta; contează lichiditatea, licitația de deschidere sau mărimea mișcării overnight?
- ▣ Instrumentele AI pot accelera un astfel de studiu; nu înlocuiesc verificarea lui [Wang et al. \(2023\)](#)

Contribuția posibilă a AI

- ▣ **Literatura:** o listă a studiilor despre volatilitatea de amplitudine și cea realizată pe piețe emergente și puțin lichide, cu datele și estimatorii folosiți
- ▣ **Cod:** o primă versiune a celor cinci estimatori, a prognozelor pe ferestre mobile și a comparațiilor QLIKE pentru toate acțiunile din BET
- ▣ **Robustețe:** grupe de lichiditate după volum, alte ferestre, cele două jumătăți 2016–2020 și 2021–2026
- ▣ Exemplu de prompt
 - Write a Python function that computes the Parkinson, Garman-Klass, Rogers-Satchell and Yang-Zhang variance on rolling 21-day windows from daily open, high, low and close prices, and compares their next-day forecasts with QLIKE against squared close-to-close returns.

Verificări necesare

- ▣ Constantele: $4 \ln 2$ la Parkinson, $2 \ln 2 - 1$ la Garman–Klass, k la Yang–Zhang; o ciornă cu $\ln 2$ sau cu $k = 0,34$ este greșită
- ▣ Prețurile acțiunilor: deschiderea, maximul și minimul trebuie ajustate pentru dividende și splituri cu același factor ca închiderea
- ▣ Anualizarea cu frecvența reală: 365 pentru cripto, circa 250 pentru acțiunile BVB
- ▣ Fără informație din viitor: prognoza pentru ziua t folosește doar datele pînă în ziua $t - 1$
- ▣ Referințele: fiecare lucrare citată trebuie să existe; verificați DOI-ul

Idee de proiect

- ▣ **Întrebarea:** ce estimator zilnic de volatilitate ar trebui să folosească un manager de risc din România?
 - ▶ date: acțiuni BVB din 2010 (TLV, SNP, BRD, TGN și altele cu date OHLC), S&P 500 și DAX ca termeni de comparație (EODHD)
- ▣ Pași
 - ▶ cei cinci estimatori pe ferestre de 21 de zile; variantele EWMA ale fiecăruia; prognoze pentru ziua următoare
 - ▶ QLIKE și MSE cu proxy-ul r_t^2 ; teste Diebold–Mariano; rezultate pe grupe de lichiditate
 - ▶ legați câștigul YZ față de CC de ponderea zilelor fără volum și de ponderea nopții
- ▣ Livrabile: un tabel, un grafic și un paragraf despre ce pot și ce nu pot arăta datele
- ▣ Declarați orice utilizare a instrumentelor AI și enumerați erorile acestora pe care le-ați corectat

Idei de reținut

- ▣ Volatilitatea este abaterea standard a randamentelor; este latentă și variază în timp; se anualizează cu frecvența reală
- ▣ La ferestrele istorice, viteza de reacție se plătește cu zgomot; EWMA ($\lambda = 0,94$) reacționează repede și evită ghost effect
- ▣ Estimatorii de amplitudine folosesc traiectoria zilei: mult mai eficienți, dar deplasați de salturile overnight și de tranzacționarea rară; Yang–Zhang adaugă noaptea
- ▣ Volatility clustering: $|r_t|$ și r_t^2 sînt autocorelate; se detectează cu Ljung–Box pe r_t^2 și cu ARCH-LM
- ▣ Volatilitatea revine la medie; VIX depășește de obicei volatilitatea realizată; scăderile cresc volatilitatea viitoare
- ▣ Comparați prognozele cu pierderi robuste (QLIKE) și o variabilă proxy; testați diferențele

Formule de reținut

Mărimea	Formula
Volatilitatea anualizată	$\sigma_{\text{an}} = \sigma_{\text{zi}} \sqrt{a}$
EWMA	$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, timp de înjumătățire $\ln 0,5 / \ln \lambda$
Parkinson	$(u_t - d_t)^2 / (4 \ln 2)$
Garman–Klass	$0,5(u_t - d_t)^2 - (2 \ln 2 - 1) c_t^2$
Rogers–Satchell	$u_t(u_t - c_t) + d_t(d_t - c_t)$
Yang–Zhang	$\hat{\sigma}_O^2 + k \hat{\sigma}_C^2 + (1 - k) \hat{\sigma}_{RS}^2$, $k = 0,34 / (1,34 + (n + 1) / (n - 1))$
Varianța realizată	$RV_t = \sum_i r_{t,i}^2$
McLeod–Li	$Q(m) = T(T + 2) \sum_{k=1}^m \hat{\rho}_k(r^2)^2 / (T - k) \sim \chi^2(m)$
ARCH-LM	$LM = nR^2 \sim \chi^2(q)$
MSE, QLIKE	$(\hat{\sigma}_t^2 - h_t)^2$, $\hat{\sigma}_t^2 / h_t + \ln h_t$

Autoevaluare

- ▣ **Întrebare:** o acțiune are $H = 102$, $L = 98$ într-o zi; care este volatilitatea zilnică Parkinson?
 - ▶ **Răspuns:** $\ln(102/98) = 4,00\%$; $\sqrt{4,00^2/2,77} = 2,40\%$
- ▣ **Întrebare:** testul Ljung–Box pe randamente nu respinge, iar pe randamentele la pătrat respinge puternic; ce concluzie trageți?
 - ▶ **Răspuns:** media este imprevizibilă, varianța este previzibilă: volatility clustering fără autocorelația randamentelor
- ▣ **Întrebare:** de ce nu poate EWMA cu $\lambda = 0,94$ să anticipeze revenirea volatilității la nivelul normal?
 - ▶ **Răspuns:** $\alpha + \beta = 1$ și $\omega = 0$: prognozele lui sînt constante la orice orizont
- ▣ Urmează: [Capitolul 9](#), modelele ARCH și GARCH

Bibliografie (1/3)

- ▣ Alizadeh, S., Brandt, M.W., Diebold, F.X. (2002). Range-based estimation of stochastic volatility models. *Journal of Finance*, 57(3), 1047–1091.
- ▣ Andersen, T.G., Bollerslev, T. (1998). Answering the skeptics: yes, standard volatility models do provide accurate forecasts. *International Economic Review*, 39(4), 885–905.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Ebens, H. (2001). The distribution of realized stock return volatility. *Journal of Financial Economics*, 61(1), 43–76.
- ▣ Andersen, T.G., Bollerslev, T., Diebold, F.X., Labys, P. (2003). Modeling and forecasting realized volatility. *Econometrica*, 71(2), 579–625.
- ▣ Barndorff-Nielsen, O.E., Shephard, N. (2002). Econometric analysis of realized volatility and its use in estimating stochastic volatility models. *Journal of the Royal Statistical Society, Series B*, 64(2), 253–280.
- ▣ Bekaert, G., Wu, G. (2000). Asymmetric volatility and risk in equity markets. *Review of Financial Studies*, 13(1), 1–42.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T., Tauchen, G., Zhou, H. (2009). Expected stock returns and variance risk premia. *Review of Financial Studies*, 22(11), 4463–4492.
- ▣ Borak, S., Härdle, W.K., López-Cabrera, B. (2013). *Statistics of Financial Markets: Exercises and Solutions*, 2nd ed. Springer.
- ▣ Carr, P., Wu, L. (2009). Variance risk premiums. *Review of Financial Studies*, 22(3), 1311–1341.
- ▣ Cboe Global Markets (2026). Cboe Volatility Index (VIX). Product page and methodology.
- ▣ Christie, A.A. (1982). The stochastic behavior of common stock variances: value, leverage and interest rate effects. *Journal of Financial Economics*, 10(4), 407–432.
- ▣ Cont, R. (2001). Empirical properties of asset returns: stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Ding, Z., Granger, C.W.J., Engle, R.F. (1993). A long memory property of stock market returns and a new model. *Journal of Empirical Finance*, 1(1), 83–106.

Bibliografie (2/3)

- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Engle, R.F. (2004). Risk and volatility: econometric models and financial practice. *American Economic Review*, 94(3), 405–420.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ French, K.R., Schwert, G.W., Stambaugh, R.F. (1987). Expected stock returns and volatility. *Journal of Financial Economics*, 19(1), 3–29.
- ▣ Garman, M.B., Klass, M.J. (1980). On the estimation of security price volatilities from historical data. *Journal of Business*, 53(1), 67–78.
- ▣ Hansen, P.R., Lunde, A. (2005). A forecast comparison of volatility models: does anything beat a GARCH(1,1)? *Journal of Applied Econometrics*, 20(7), 873–889.
- ▣ J.P. Morgan/Reuters (1996). *RiskMetrics – Technical Document*, 4th ed. New York: Morgan Guaranty Trust Company.
- ▣ Liu, L.Y., Patton, A.J., Sheppard, K. (2015). Does anything beat 5-minute RV? A comparison of realized measures across multiple asset classes. *Journal of Econometrics*, 187(1), 293–311.
- ▣ Ljung, G.M., Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- ▣ Mandelbrot, B. (1963). The variation of certain speculative prices. *Journal of Business*, 36(4), 394–419.
- ▣ McLeod, A.I., Li, W.K. (1983). Diagnostic checking ARMA time series models using squared-residual autocorrelations. *Journal of Time Series Analysis*, 4(4), 269–273.
- ▣ Mincer, J.A., Zarnowitz, V. (1969). The evaluation of economic forecasts. In J.A. Mincer (ed.), *Economic Forecasts and Expectations*, 3–46. NBER.
- ▣ Molnár, P. (2012). Properties of range-based volatility estimators. *International Review of Financial Analysis*, 23, 20–29.
- ▣ Nobel Prize Outreach (2003). The Sveriges Riksbank Prize in Economic Sciences in Memory of Alfred Nobel 2003: Robert F. Engle III and Clive W.J. Granger. nobelprize.org.
- ▣ Parkinson, M. (1980). The extreme value method for estimating the variance of the rate of return. *Journal of Business*, 53(1), 61–65.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.

Bibliografie (3/3)

- ▣ Pele, D.T., Lazar, E., Dufour, A. (2017). Information entropy and measures of market risk. *Entropy*, 19(5), 226.
- ▣ Pele, D.T., Mazurencu-Marinescu-Pele, M. (2019). Using high-frequency entropy to forecast Bitcoin's daily Value at Risk. *Entropy*, 21(2), 102.
- ▣ Poon, S.-H., Granger, C.W.J. (2003). Forecasting volatility in financial markets: a review. *Journal of Economic Literature*, 41(2), 478–539.
- ▣ Rogers, L.C.G., Satchell, S.E. (1991). Estimating variance from high, low and closing prices. *Annals of Applied Probability*, 1(4), 504–512.
- ▣ Schwert, G.W. (1989). Why does stock market volatility change over time? *Journal of Finance*, 44(5), 1115–1153.
- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed. Wiley.
- ▣ Wang, H., Fu, T., Du, Y., Gao, W., et al. (2023). Scientific discovery in the age of artificial intelligence. *Nature*, 620, 47–60.
- ▣ Whaley, R.E. (1993). Derivatives on market volatility. *Journal of Derivatives*, 1(1), 71–84.
- ▣ Whaley, R.E. (2009). Understanding the VIX. *Journal of Portfolio Management*, 35(3), 98–105.
- ▣ Yang, D., Zhang, Q. (2000). Drift-independent volatility estimation based on high, low, open, and close prices. *Journal of Business*, 73(3), 477–492.