



Statistica piețelor financiare

Seminarul 6: Selecția modelului și managementul riscului



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material

- ▣ AD: Anderson–Darling (test) — testul Anderson–Darling
- ▣ AI: Artificial Intelligence (inteligență artificială)
- ▣ AIC: Akaike Information Criterion (criteriul informațional Akaike)
- ▣ BET: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ BIC: Bayesian Information Criterion (criteriul informațional bayesian)
- ▣ EDF: Empirical Distribution Function (funcția de repartiție empirică)
- ▣ EODHD: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ ES: Expected Shortfall (pierderea așteptată în coadă)
- ▣ GED: Generalised Error Distribution (distribuția erorii generalizate)
- ▣ KS: Kolmogorov–Smirnov (test) — testul Kolmogorov–Smirnov
- ▣ LR: Likelihood Ratio (raportul de verosimilitate)
- ▣ ML: Maximum Likelihood (verosimilitate maximă)
- ▣ NIG: Normal Inverse Gaussian (distribution) — distribuția Normală invers Gaussiană
- ▣ QQ: Quantile–Quantile (plot) — graficul cuantilă–cuantilă

Întrebarea de azi și traseul

- ▣ **Întrebarea:** dintre mai multe distribuții candidate pentru randamentele zilnice, pe care o alegem și de unde știm că este suficient de bună pentru VaR 1%?
 - ▶ seminarul are loc **înaintea** Cursului 6; noțiunile necesare sînt recapitulate în secțiunea „Noțiuni necesare azi”
- ▣ Traseul
 - ▶ Partea A: AIC, BIC, ponderi Akaike, teste ale raportului de verosimilitate, un test KS și depășiri VaR, pe hîrtie
 - ▶ Partea B: alegerea modelului pe BET, S&P 500, DAX, Bitcoin și Banca Transilvania, fiecare cu o întrebare de interpretare
 - ▶ Partea C: o întrebare deschisă pentru proiect și un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook
- ▣ Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	ce model are cel mai mic AIC și BIC și cât de puternice sînt dovezile?	Rezolvat, Propus	A1
A3, A4	este modelul mai general dintre două modele imbricate semnificativ mai bun?	Rezolvat, Propus	A3
A5, A6	trece un eșantion mic un test KS, cu parametri cunoscuți și cu parametri estimați?	Rezolvat, Propus	A5
A7, A8	VaR 1% pentru două modele; sînt depășirile prea multe sau prea puține?	Rezolvat, Propus	A7
B1, B2	care distribuție se potrivește cel mai bine randamentelor BET, DAX și Bitcoin?	Rezolvat, Propus	B1
B3, B4	trec cele mai bune modele testele de concordanță? sînt două zile din seria TLV erori de date?	Rezolvat, Propus	B3
B5, B6	ce model estimează corect VaR 1% în afara eșantionului?	Rezolvat, Propus	B5
C1, C2	se schimbă în timp cel mai bun model? ce este greșit într-un răspuns AI?	Propus	B1, A3

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați voi, după model

Datele folosite

Seria	Sursa	Prețul folosit	Perioada
BET, S&P 500, DAX	EODHD	închidere	2000–2026
Bitcoin	EODHD	închidere, 7 zile pe săptămână	2014–2026
Banca Transilvania (TLV)	EODHD	închidere ajustată	2010–2026

- Randamente logaritmice zilnice în %: $r_t = 100 (\ln P_t - \ln P_{t-1})$; weekendurile și închiderile repetate din zilele libere se elimină (cu excepția Bitcoin)
- Șase modele candidate: Normală, Student-t, skewed-t, GED, amestec Normal cu două componente, NIG
- În notebook: `returns('bet')`, `fit_model('NIG', x)`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/8): log-verosimilitatea

- Randamentele $r_1, \dots, r_n$ i.i.d. (independente și identic distribuite), cu densitatea $f(r; \theta)$
 - ▶ θ : parametrii modelului (de exemplu μ, σ); f : densitatea modelului
- **Log-verosimilitatea:** $\ell(\theta) = \sum_t \ln f(r_t; \theta)$
 - ▶ cât de plauzibile sînt randamentele observate pentru parametrii θ ; valoarea mai mare este preferată
 - ▶ estimarea ML (maximum likelihood, verosimilitate maximă) $\hat{\theta}$ o maximizează; $\ell(\hat{\theta})$: valoarea maximă
- Modelul Normal: $\ell(\hat{\theta}) = -\frac{n}{2} [\ln(2\pi\hat{\sigma}^2) + 1]$
 - ▶ cu $\hat{\sigma}^2 = \frac{1}{n} \sum_t (r_t - \bar{r})^2$ și $\bar{r}$ media de selecție

Noțiuni necesare azi (2/8): candidații

- Candidații și numărul lor de parametri k
 - ▶ Normală (2); Student-t (3: gradele de libertate ν , locație, scală)
 - ▶ skewed-t (4: adaugă asimetria λ ; $\lambda = 0$ dă Student-t)
 - ▶ GED, generalised error distribution (distribuția erorii generalizate) (3: forma β ; $\beta = 2$ dă distribuția Normală)
 - ▶ amestec Normal cu două componente (5); NIG, normal inverse Gaussian (4)
- Rolul parametrilor de formă
 - ▶ un ν mic sau un β mic: cozi mai groase; $\lambda < 0$: o coadă stîngă mai lungă
- Cu cît cozile datelor sînt mai groase, cu atît modelul Normal pierde mai mult în ℓ

Noțiuni necesare azi (3/8): AIC și BIC

- $AIC = -2\ell(\hat{\theta}) + 2k$ (Akaike information criterion, criteriul informațional Akaike)
 - ▶ ajustarea (-2ℓ) plus o penalizare de 2 pentru fiecare parametru
- $BIC = -2\ell(\hat{\theta}) + k \ln n$ (Bayesian information criterion, criteriul informațional bayesian)
 - ▶ penalizarea $\ln n$ pe parametru; mai mare decât 2 când $\ln n > 2$, adică $n > 7$
- Interpretarea
 - ▶ valoarea mai mică este preferată; contează doar diferențele calculate pe aceleași date
 - ▶ AIC nu este un test: nu există p-value și nici „semnificație”

Noțiuni necesare azi (4/8): ΔAIC și ponderile Akaike

- $\Delta_i = AIC_i - \min_j AIC_j$
 - ▶ distanța modelului i față de cel mai bun model; $\Delta = 0$ pentru câștigător
 - ▶ reguli practice [Burnham & Anderson \(2004\)](#): $\Delta \leq 2$ sprijin substanțial; 4–7 considerabil mai puțin; > 10 practic niciunul
- Pondere Akaike: $w_i = e^{-\Delta_i/2} / \sum_j e^{-\Delta_j/2}$
 - ▶ ponderea dovezilor în favoarea modelului i ; ponderile însumează 1
 - ▶ exemplu: $\Delta = 0$ și $\Delta = 2$ dau $w \approx 0,73$ și $0,27$
- VaR mediat: $\sum_i w_i \text{VaR}_i$
 - ▶ VaR-ul fiecărui model, ponderat cu ponderea lui Akaike

Noțiuni necesare azi (5/8): testul raportului de verosimilitate

- Modelul 0 este **imbricat** în modelul 1 dacă este modelul 1 cu unii parametri fixați
 - ▶ exemplu: Student-t = skewed-t cu $\lambda = 0$
- $LR = 2[\ell_1(\hat{\theta}_1) - \ell_0(\hat{\theta}_0)] \approx \chi^2(k_1 - k_0)$ sub H_0 (Wilks)
 - ▶ H_0 : modelul mai mic, 0, este adevărat; $k_1 - k_0$: numărul parametrilor fixați
 - ▶ valori critice la 5%: $\chi^2_{0,95}(1) = 3,84$; $\chi^2_{0,95}(2) = 5,99$; respingem H_0 peste ele
- **Frontiera**: distribuția Normală ca submodel al Student-t înseamnă $1/\nu = 0$, marginea spațiului parametrilor
 - ▶ LR urmează atunci un amestec 50:50 de 0 și $\chi^2(1)$ [Self & Liang \(1987\)](#): valoarea critică la 5% 2,71
 - ▶ p-value-ul este jumătate din cel calculat cu $\chi^2(1)$
- Perechi neimbricate (Student-t și GED): testul LR nu se aplică; folosiți AIC sau testul Vuong
 - ▶ Vuong: $V = \sqrt{n} \bar{m} / s_m$, $m_t = \ln f_1(r_t) - \ln f_2(r_t)$, cu $\bar{m}$, s_m media și abaterea standard a lui m_t ; $|V| > 1,96$: un model este mai aproape

Noțiuni necesare azi (6/8): teste de concordanță

- EDF (empirical distribution function, funcția de repartiție empirică): $F_n(x) = \frac{1}{n} \# \{t : r_t \leq x\}$
 - ▶ proporția randamentelor cel mult egale cu x ; se compară cu funcția de repartiție a modelului, F
- KS (Kolmogorov–Smirnov): $D_n =$ cea mai mare distanță pe verticală dintre F_n și F
 - ▶ $D_n = \max_i \max\{i/n - u_{(i)}, u_{(i)} - (i-1)/n\}$, cu $u_{(i)} = F(r_{(i)})$ și $r_{(i)}$ al i -lea cel mai mic randament
- CvM (Cramér–von Mises) și AD (Anderson–Darling) integrează pătratul distanței
 - ▶ AD îl ponderează cu $1/[F(1-F)]$, mare acolo unde F este aproape de 0 sau 1: pune accentul pe cozi

Noțiuni necesare azi (7/8): valori critice și grafice QQ

- Valori critice KS la 5%
 - ▶ F complet cunoscută: $n = 5$: 0,563; $n = 6$: 0,519; n mare: $1,358/\sqrt{n}$
 - ▶ media și varianța estimate din aceleași date (Lilliefors): $n = 5$: 0,354; $n = 6$: 0,333
 - ▶ alte modele: bootstrap parametric (simulăm din modelul estimat, reestimăm, recalculăm statistica)
- Un **grafic QQ** reprezintă datele ordonate în funcție de cuantilele modelului $F^{-1}((i - 0,5)/n)$
 - ▶ puncte pe dreaptă: o ajustare bună; capete care se îndepărtează de dreaptă: modelul greșește în cozi

Noțiuni necesare azi (8/8): VaR, depășiri, în afara eșantionului

- $\text{VaR}_{1\%} = -q_{1\%}$: pierderea zilnică depășită cu probabilitatea 1%
 - ▶ Normală: $\text{VaR}_{1\%} = -(\mu - 2,326\sigma)$; ES 2,5% (expected shortfall): pierderea medie dincolo de $q_{2,5\%}$
 - ▶ ES 2,5% Normal: $-\mu + \sigma\varphi(z_{0,025})/0,025$, cu φ densitatea $N(0, 1)$
- **Depășire**: o zi cu $r_t < -\text{VaR}$; model corect: $x \sim \text{Binomial}(n; 0,01)$
 - ▶ testul Kupiec: $LR_{uc} = -2[\ell_0 - \ell_1]$, comparat cu $\chi^2(1)$
 - ▶ $\ell_0 = (n - x) \ln 0,99 + x \ln 0,01$ (rata 1%); $\ell_1 = (n - x) \ln(1 - \hat{p}) + x \ln \hat{p}$ (rata observată $\hat{p} = x/n$)
- **În afara eșantionului**: estimăm pe datele de pînă la un moment dat și evaluăm pe datele ulterioare
 - ▶ scorul logaritm: media lui $\ln f(r_t; \hat{\theta})$ pe zilele de test (valoarea mai mare este preferată)
 - ▶ pierderea pinball a cuantilei de 1% q : media lui $(0,01 - 1\{r_t < q\})(r_t - q)$, cu $1\{\cdot\} = 1$ dacă este adevărat, 0 altfel (valoarea mai mică este preferată)

A1: patru modele pentru S&P 500 [Rezolvat]

Cerință

- ▣ S&P 500, ultimele $n = 1000$ de zile de tranzacționare (2022–2026); log-verosimilitățile maximizate:
- ▣ Normală: $\ell = -1400,9$, $k = 2$
- ▣ Student-t: $\ell = -1314,7$, $k = 3$
- ▣ skewed-t: $\ell = -1313,8$, $k = 4$
- ▣ GED: $\ell = -1322,6$, $k = 3$
- ▣ 1. Calculați AIC și BIC ($\ln 1000 = 6,908$) pentru fiecare model.
- ▣ 2. Calculați ΔAIC și ponderile Akaike.
- ▣ 3. Precizați ce model alege fiecare criteriu și cît de puternice sînt dovezile.
- ▣ Raportați: un tabel cu patru rînduri și două fraze.

Rezolvare

- ▣ 1. AIC: Normală 2805,8; Student-t 2635,4; skewed-t 2635,6; GED 2651,2. BIC, în aceeași ordine: 2815,6; 2650,1; 2655,2; 2665,9
- ▣ 2. ΔAIC : 170,4; 0,0; 0,2; 15,8. $e^{-\Delta/2}$: 0,000; 1,000; 0,905; 0,000. Ponderi: 0,000; 0,525; 0,475; 0,000
- ▣ 3. AIC: Student-t și skewed-t la egalitate ($\Delta = 0,2$); BIC: Student-t, cu un avans de 5,1 puncte; modelul Normal și GED nu au niciun sprijin.

A2: patru modele pentru Bitcoin [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Bitcoin, ultimele $n = 1000$ de zile (2023–2026); log-verosimilitățile maximizate: Model: A1.
- ▣ Normală: $\ell = -2328,0$, $k = 2$
- ▣ Student-t: $\ell = -2262,0$, $k = 3$
- ▣ NIG: $\ell = -2258,4$, $k = 4$
- ▣ amestec Normal: $\ell = -2262,3$, $k = 5$
- ▣ 1. Calculați AIC, BIC, ΔAIC și ponderile Akaike.
- ▣ 2. Precizați dacă AIC și BIC aleg același model.
- ▣ 3. Explicați de ce amestecul Normal, cu cei mai mulți parametri, nu câștigă.
- ▣ Raportați: un tabel cu patru rînduri și două fraze.

A3: este necesară asimetria? Este suficientă distribuția Normală? [Rezolvat]

Cerință

- ▣ Folosiți log-verosimilitățile din A1 (S&P 500, $n = 1000$).
- ▣ 1. Testați Student-t ($H_0: \lambda = 0$) față de skewed-t cu un test al raportului de verosimilitate la 5%.
- ▣ 2. Testați distribuția Normală ($H_0: \beta = 2$) față de GED.
- ▣ 3. Comparați decizia LR de la pasul 1 cu verdictul AIC din A1.
- ▣ Raportați: două valori LR , două decizii și o frază.

Rezolvare

- ▣ 1. $LR = 2(-1313,8 - (-1314,7)) = 1,8 < 3,84$, $p = 0,18$: nu respingem $\lambda = 0$
- ▣ 2. $LR = 2(-1322,6 - (-1400,9)) = 156,6$, $p < 0,001$: respingem distribuția Normală
- ▣ 3. Rezultatele sînt concordante: după AIC, cele două modele t sînt la egalitate, iar testul LR nu arată un câștig semnificativ adus de λ . Pentru perechi imbricate, AIC preferă modelul mai general exact atunci cînd $LR > 2$ pentru fiecare parametru în plus.

A4: un test la frontieră [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Folosiți log-verosimilitățile din A2 (Bitcoin, $n = 1000$). Model: A3.
- ▣ 1. Calculați LR pentru distribuția Normală ca submodel al Student-t.
- ▣ 2. Explicați de ce distribuția statisticii sub H_0 nu este $\chi^2(1)$ și dați valoarea critică corectă la 5%.
- ▣ 3. Spuneți dacă un test LR poate compara Student-t cu NIG.
- ▣ Raportați: o valoare LR , o valoare critică și două fraze.

A5: KS pe cinci randamente [Rezolvat]

Cerință

- ▣ Randamente zilnice (%): $-2,1; -0,4; 0,3; 0,9; 1,6$.
- ▣ 1. Calculați D_5 față de $N(0, 1)$ și comparați-l cu valoarea critică la 5% 0,563.
- ▣ 2. Estimați $\hat{\mu}$ și $\hat{\sigma}$ (numitorul n), calculați D_5 față de $N(\hat{\mu}, \hat{\sigma}^2)$ și comparați-l cu valoarea Lilliefors 0,354.
- ▣ 3. Explicați de ce valoarea critică Lilliefors este mai mică.
- ▣ Raportați: două valori D_5 , două decizii, o frază.

Rezolvare

- ▣ 1. $u_{(i)} = \Phi(r_{(i)})$: 0,018; 0,345; 0,618; 0,816; 0,945; cea mai mare distanță $D_5 = 0,218 < 0,563$: nu respingem
- ▣ 2. $\hat{\mu} = 0,060$, $\hat{\sigma} = 1,266$; $z_{(i)}$: $-1,71; -0,36; 0,19; 0,66; 1,22$; $u_{(i)}$: 0,044; 0,358; 0,575; 0,747; 0,888; $D_5 = 0,175 < 0,354$: nu respingem
- ▣ 3. F estimată este apropiată de date, deci D_n este mai mic sub H_0 ; prin urmare, și valoarea critică trebuie să fie mai mică.

A6: KS cu o pierdere mare [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Randamente zilnice (%): $-3,0; -0,6; -0,2; 0,1; 0,5; 1,0$. Model: A5.
- ▣ 1. Calculați D_6 față de $N(0, 1)$; valoarea critică la 5% este 0,519.
- ▣ 2. Calculați D_6 față de $N(\hat{\mu}, \hat{\sigma}^2)$; valoarea Lilliefors este 0,333.
- ▣ 3. Ziua de -3% are $\Phi(-3) = 0,001$; explicați de ce KS aproape nu reacționează la ea, în timp ce AD reacționează puternic.
- ▣ Raportați: două valori D_6 , două decizii, o frază.

A7: VaR 1% pentru două modele [Rezolvat]

Cerință

- ▣ Randamente zilnice (%): Normală cu $\mu = 0,05$, $\sigma = 1,2$; Student-t cu $\nu = 4$, locația 0,06, scala 0,8; $t_{0,01}(4) = -3,747$.
- ▣ 1. Calculați VaR 1% pentru fiecare model.
- ▣ 2. O bancă folosește VaR Normal și observă 20 de depășiri în 1000 de zile; calculați statistica Kupiec.
- ▣ 3. Decideți la 5% și interpretați.
- ▣ Raportați: două valori VaR, o statistică, o decizie.

Rezolvare

- ▣ 1. Normală: $-(0,05 - 2,326 \times 1,2) = 2,742\%$; Student-t: $-(0,06 - 3,747 \times 0,8) = 2,938\%$
- ▣ 2. $\ell_0 = 980 \ln 0,99 + 20 \ln 0,01 = -101,95$;
 $\ell_1 = 980 \ln 0,98 + 20 \ln 0,02 = -98,04$;
 $LR_{uc} = -2(\ell_0 - \ell_1) = 7,83$
- ▣ 3. $7,83 > 3,84$ ($p = 0,0051$): respingem; numărul observat este dublul celor 10 depășiri așteptate: VaR Normal este prea mic, așa cum era de așteptat pentru o coadă subțire.

A8: prea puține depășiri și ES [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ O altă bancă observă 4 depășiri ale VaR 1% în 1000 de zile. Model: A7.
- ▣ 1. Calculați statistica Kupiec și decideți la 5%.
- ▣ 2. Explicați de ce și prea puține depășiri înseamnă un eșec.
- ▣ 3. Calculați ES 2,5% al modelului Normal din A7 ($z_{0,025} = -1,960$, $\varphi(1,960) = 0,0584$).
- ▣ Raportați: o statistică, o decizie, o valoare ES și o frază.

B1: ce distribuție pentru BET? [Rezolvat]

- ▣ **Întrebarea:** care dintre cei șase candidați se potrivește cel mai bine randamentelor zilnice BET și este necesar parametrul de asimetrie?
- ▣ **Date:** închiderile BET, 2000–2026, randamente logaritmice zilnice în % ($n = 6\,670$)
- ▣ **Cerințe**
 1. Estimați cei șase candidați prin metoda verosimilității maxime și raportați $\ell(\hat{\theta})$ pentru fiecare.
 2. Calculați AIC, BIC, ΔAIC și ponderile Akaike.
 3. Testați Student-t față de skewed-t cu un test al raportului de verosimilitate.
 4. Interpretare: ce spun câștigătorul și testul LR despre cozile și asimetria BET?
- ▣ **Raportați:** un tabel cu șase rînduri, un test LR și două fraze
- ▣ **Notebook:** secțiunea B1

B1: rezolvare (1/2) [Rezolvat]



□ Câștigător: NIG pe ambele criterii; Student-t $\hat{\nu} = 2,43$; skewed-t $\hat{\lambda} = -0,009$

► $LR = 0,35$, $p = 0,555$: asimetria nu este necesară

B1: rezolvare (2/2) [Rezolvat]

	$\ell(\hat{\theta})$	AIC	BIC	ΔAIC	ΔBIC	w
Normală	-11 702	23 407	23 421	2425,2	2411,6	0,000
Student-t	-10 495	20 996	21 017	14,4	7,6	0,001
skewed-t	-10 495	20 998	21 025	16,0	16,0	0,000
GED	-10 553	21 111	21 132	129,1	122,3	0,000
amestec Normal	-10 564	21 138	21 172	155,8	162,7	0,000
NIG	-10 487	20 982	21 009	0,0	0,0	0,999

□ Interpretare: cozi foarte groase (ν aproape de 2) și nicio asimetrie semnificativă; distribuția Normală este în urmă cu mii de puncte AIC


B2: DAX și Bitcoin [Propus]

- ▣ **Întrebarea:** aleg DAX și Bitcoin aceeași distribuție ca BET? Model: B1.
- ▣ **Date:** DAX din 2000, Bitcoin din 2014 (7 zile pe săptămână), randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Repetați pașii 1–3 din B1 pentru fiecare serie.
 2. Precizați dacă AIC și BIC aleg același model pentru fiecare serie.
 3. Interpretare: de ce ar putea diferi cel mai bun model între un indice bursier și un activ crypto?
- ▣ **Raportați:** două tabele și trei fraze
- ▣ Notebook: secțiunea B2

B3: trec cele mai bune modele testele? [Rezolvat]

- ▣ **Întrebarea:** trec modelele Normal și Student-t estimate pe S&P 500 testele KS, Cramér–von Mises și Anderson–Darling?
- ▣ **Date:** randamentele logaritmice zilnice S&P 500 din 2000 ($n = 6\,714$)
- ▣ **Cerințe**
 1. Estimați ambele modele și calculați cele trei statistici.
 2. Calculați p-value-ul KS naiv, care tratează parametrii ca fiind cunoscuți.
 3. Calculați p-value-uri prin bootstrap parametric cu $B = 99$ (simulare, reestimare, recalculare).
 4. Desenați graficul QQ al datelor față de ambele modele estimate.
 5. Interpretare: dacă ambele modele sînt respinse, la ce mai folosește testul?
- ▣ **Raportați:** un tabel cu șase statistici și p-value-urile lor, graficul QQ și două fraze
- ▣ **Notebook:** secțiunea B3

B3: rezolvare (1/2) [Rezolvat]



- Graficele QQ ale randamentelor S&P 500 față de ajustările Normală și Student-t: distribuția Normală eșuează în ambele cozi

B3: rezolvare (2/2) [Rezolvat]

	KS	CvM	AD	p-value KS naiv
Normală	0,093	22,84	127,35	< 0,001
valoare critică bootstrap 95%	0,011	0,12	0,75	
Student-t	0,018	0,57	4,69	0,021
valoare critică bootstrap 95%	0,009	0,08	0,65	

- p-value-ul bootstrap = 0,01 pentru fiecare statistică și ambele modele (cel mai mic posibil cu $B = 99$): ambele respinse
 - ▶ p-value-ul KS naiv al Student-t este mult prea mare
- Interpretare: cu $n = 6\,714$, orice model i.i.d. este respins
 - ▶ statisticile permit totuși ordonarea modelelor (AD Student-t 4,69 față de 127,35)
 - ▶ graficul QQ arată unde eșuează fiecare model


B4: crah sau eroare de date? Banca Transilvania [Propus]

- ▣ **Întrebarea:** care dintre cele mai mari randamente TLV sînt reale și schimbă eliminarea celor eronate modelul ales? Model: B1.
- ▣ **Date:** prețul ajustat TLV din 2010, randamente logaritmice zilnice în %; prețul de închidere (neajustat) pentru comparație; BET în aceleași zile
- ▣ **Cerințe**
 1. Identificați cele mai mari trei randamente în valoare absolută și datele lor.
 2. Pentru fiecare, comparați prețul de închidere și prețul ajustat în jurul datei, precum și randamentul BET din aceeași zi.
 3. Decideți care zile sînt erori de date și eliminați doar acele zile.
 4. Reestimați cinci candidați; comparați boltirea, $\hat{D}$ Student-t, statistica AD și câștigătorul AIC înainte și după.
 5. Interpretare: ce s-ar fi întîmplat dacă ați fi eliminat toate cele trei zile?
- ▣ **Raportați:** un tabel cu trei zile și verdictul vostru, un tabel înainte/după și două fraze
- ▣ **Notebook:** secțiunea B4

B5: VaR 1% în afara eșantionului pentru DAX [Rezolvat]

- ▣ Întrebarea: dă modelul ales de AIC pe 2000–2019 și cel mai bun VaR 1% pe 2020–2026?
- ▣ Date: randamentele logaritmice zilnice DAX: estimare 2000–2019 ($n = 5\,075$), test 2020–2026 ($n = 1\,710$)
- ▣ Cerințe
 1. Estimați cei șase candidați pe zilele de estimare și ordonați-i după AIC.
 2. Calculați scorul logaritmico mediu al fiecărui model pe zilele de test.
 3. Calculați VaR 1% al fiecărui model, numărați depășirile pe zilele de test și aplicați testul Kupiec.
 4. Adăugați simularea istorică (cuantila de 1% a zilelor de estimare) și VaR mediat cu ponderile Akaike.
 5. Interpretare: ce model ați alege pentru VaR 1% și de ce?
- ▣ Raportați: un tabel, graficul și două fraze
- ▣ Notebook: secțiunea B5

B5: rezolvare (1/2) [Rezolvat]



- Stînga: scorul logaritmic de test minus cel al modelului Normal; dreapta: ratele de depășire ale VaR 1% pe zilele de test (ținta 1%)

B5: rezolvare (2/2) [Rezolvat]

	scor log.	VaR 1%	depășiri	p Kupiec	pinball $\times 100$
Normală	−1,668	3,37	27	0,027	5,37
Student-t	−1,533	4,09	11	0,113	5,23
skewed-t	−1,532	4,38	8	0,014	5,36
GED	−1,539	3,91	18	0,828	5,21
amestec Normal	−1,542	4,39	8	0,014	5,37
NIG	−1,530	4,38	8	0,014	5,36
istorică	—	4,33	8	0,014	5,33
mediată	—	4,37	8	0,014	5,36

- AIC pe 2000–2019: NIG; cel mai bun scor logaritmic de test: NIG; depășiri așteptate 17,1; cea mai mică pierdere pinball: GED
- Interpretare: câștigătorul AIC dă cea mai bună densitate, dar prea puține depășiri (prea prudent)
 - dacă scopul este doar VaR 1%, GED și Student-t au rate de depășire mai apropiate de 1%

B6: VaR 1% în afara eșantionului pentru Bitcoin [Propus]

- **Întrebarea:** se menține concluzia din B5 pentru Bitcoin? Model: B5.
- **Date:** Bitcoin: estimare 2014–2019 ($n = 1\,931$), test 2020–2026 ($n = 2\,453$)
- **Cerințe**
 1. Repetați pașii 1–4 din B5.
 2. Comparați VaR 1% empiric al zilelor de test cu cel al zilelor de estimare.
 3. Interpretare: de ce eșuează aici toate modelele cu cozi groase testul Kupiec și în ce direcție?
- **Raportați:** un tabel și două fraze
- **Notebook:** secțiunea B6

C1: se schimbă în timp cel mai bun model? [Propus]

- ▣ **Întrebarea:** este câștigătorul AIC pentru S&P 500 și BET același în fiecare fereastră de doi ani?
- ▣ **Date:** randamente logaritmice zilnice din 2000, ferestre de doi ani care nu se suprapun (2000–2001, 2002–2003, ...);
candidați: Normală, Student-t, skewed-t, GED, NIG; modele: B1, A1
- ▣ **Cerințe**
 1. În fiecare fereastră, găsiți câștigătorul AIC, ponderea lui Akaike și ΔAIC al celui de-al doilea.
 2. Numărați de câte ori câștigă fiecare model, pentru fiecare indice.
 3. Propuneți o explicație a schimbărilor și o cale de a o testa.
 4. Interpretare: ar trebui ca modelul de risc să fie ales din nou la fiecare doi ani?
- ▣ **Raportați:** un tabel, numărul de ferestre câștigate de fiecare model și un plan de proiect
- ▣ **Notebook:** secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI să aleagă o distribuție pentru randamentele logaritmice zilnice S&P 500 (%) din 2000 ($n = 6\,714$). Răspunsul:
 - (a) Skewed-t are cel mai mic AIC, deci este semnificativ mai bun decât Student-t (Delta AIC = 17,6).
 - (b) Testul KS al ajustării Student-t dă $p = 0,021$ cu `scipy.stats.kstest`, deci Student-t se potrivește la nivelul de 1%.
 - (c) Testul LR al distribuției Normale față de Student-t folosește valoarea critică $\chi^2(1) = 3,84$.
 - (d) BIC penalizează parametrii în plus mai puțin decât AIC, pentru că $\ln(n)$ este doar 8,81.
 - (e) Testul Anderson-Darling este mai sensibil decât KS la calitatea ajustării în cozi.
 - (f) Pentru că skewed-t are cea mai bună ajustare, VaR 1% calculat cu el este cel mai precis.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, unde se poate, cifra corectă din notebook (secțiunea C2).
 - ▶ 2. Raportați: o listă de șase verdicte, fiecare cu un rând de justificare.

Idei de reținut

- ▣ AIC și BIC ordonează modelele; $\Delta \leq 2$ înseamnă egalitate; ponderile Akaike transformă Δ în dovezi
- ▣ Testele LR cer modele imbricate și o valoare a parametrului din interiorul spațiului parametrilor; la frontieră folosiți amestecul 50:50
- ▣ KS cu parametri estimați cere tabelele Lilliefors sau bootstrap; AD pune accentul pe cozi, KS nu
- ▣ Verificați cele mai mari randamente înainte de modelare: eliminați erorile, păstrați crahurile
- ▣ Cea mai bună densitate nu dă întotdeauna cel mai bun VaR: validați în afara eșantionului

După seminar

- ▣ Cursul 6 dezvoltă fiecare temă de azi: verosimilitatea, testele LR și Vuong, AIC și BIC, testele EDF, graficele QQ, VaR în afara eșantionului, incertitudinea de model
- ▣ Încercați cerințele [Propus] în notebook; rezolvările se discută la seminar
- ▣ C1 poate deveni un proiect de echipă: randamente standardizate, mai multe piețe, ferestre mobile
- ▣ Lectură: [Burnham & Anderson \(2004\)](#); [Stephens \(1974\)](#); [Kupiec \(1995\)](#)

Bibliografie

- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723.
- Burnham, K.P., Anderson, D.R. (2004). Multimodel inference: understanding AIC and BIC in model selection. *Sociological Methods & Research*, 33(2), 261–304.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- Lilliefors, H.W. (1967). On the Kolmogorov–Smirnov test for normality with mean and variance unknown. *Journal of the American Statistical Association*, 62(318), 399–402.
- Schwarz, G. (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2), 461–464.
- Self, S.G., Liang, K.-Y. (1987). Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, 82(398), 605–610.
- Stephens, M.A. (1974). EDF statistics for goodness of fit and some comparisons. *Journal of the American Statistical Association*, 69(347), 730–737.
- Wilks, S.S. (1938). The large-sample distribution of the likelihood ratio for testing composite hypotheses. *Annals of Mathematical Statistics*, 9(1), 60–62.