



Statistica piețelor financiare

Seminarul 8: Estimatori de volatilitate



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **ARCH**: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **ARCH-LM**: ARCH Lagrange Multiplier (test) — testul multiplicatorului Lagrange pentru efecte ARCH
- ▣ **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BVB**: Bursa de Valori București
- ▣ **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **EWMA**: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- ▣ **GK**: Garman–Klass (volatility estimator) — estimatorul de volatilitate Garman–Klass

Acronime folosite în acest material (2/2)

- **HAC:** Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- **LB:** Ljung–Box (test) — testul de autocorelație Ljung–Box
- **LM:** Lagrange Multiplier (multiplicatorul Lagrange)
- **MSE:** Mean Squared Error (eroarea pătratică medie)
- **OHLC:** Open, High, Low, Close (deschidere, maxim, minim, închidere)
- **OMV:** Österreichische Mineralölverwaltung (Administrația austriacă a uleiurilor minerale, grupul OMV)
- **QLIKE:** Quasi-LIKelihood (loss function) — funcția de pierdere de tip cvasi-verosimilitate
- **VIX:** CBOE Volatility Index (indicele de volatilitate CBOE)
- **YZ:** Yang–Zhang (volatility estimator) — estimatorul de volatilitate Yang–Zhang

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum putem măsura, din prețuri, o volatilitate pe care nu o observăm niciodată?
 - ▶ seminarul are loc **înaintea** Cursului 8: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: volatilitatea istorică și EWMA, estimatorii de amplitudine, testele de volatility clustering și pierderile prognozelor, pe hîrtie
 - ▶ Partea B: S&P 500, BET, DAX, Bitcoin și acțiuni BVB, fiecare cerință cu o întrebare de interpretare
 - ▶ Partea C: o întrebare deschisă pentru proiect și un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook
- ▣ Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	volatilitatea istorică, anualizarea și eroarea ei standard	Rezolvat, Propus	A1
A3, A4	EWMA pas cu pas; timpul de înjumătățire	Rezolvat, Propus	A3
A5, A6	Parkinson, Garman–Klass, Rogers–Satchell și Yang–Zhang din prețurile OHLC	Rezolvat, Propus	A5
A7, A8	Ljung–Box pe randamentele la pătrat și testul ARCH-LM	Rezolvat, Propus	A7
A9, A10	pierderile MSE și QLIKE ale prognozelor de volatilitate	Rezolvat, Propus	A9
B1, B2	volatilitatea pe ferestre mobile și EWMA: S&P 500; BET, Bitcoin	Rezolvat, Propus	B1
B3, B4	estimatori de amplitudine: S&P 500; DAX, Bitcoin, TLV	Rezolvat, Propus	B3
B5, B6	teste de volatility clustering: S&P 500; BET, Bitcoin, TLV, SNP	Rezolvat, Propus	B5
B7, B8	evaluarea prognozelor cu VIX; cel mai bun λ	Rezolvat, Propus	B7
C1, C2	alegerea estimatorului pentru acțiunile BVB; erorile unui răspuns AI	Propus	B3, B7

- ▣ **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați voi, după model

Datele folosite

Seria	Sursa	Prețurile folosite	Perioada
S&P 500	EODHD	închidere; OHLC din 2008	1990–2026
DAX	EODHD	închidere; OHLC din 2006	1990–2026
BET	EODHD	doar închidere	1997–2026
Bitcoin	EODHD	OHLC, 7 zile pe săptămână	2014–2026
Banca Transilvania (TLV), OMV Petrom (SNP)	EODHD	OHLC ajustat	2010–2026
VIX	EODHD	închidere	1990–2026

- Randamente logaritmice zilnice în %: $r_t = 100 (\ln P_t - \ln P_{t-1})$; weekendurile și închiderile repetate din zilele libere se elimină (cu excepția Bitcoin); ultima zi este 18 septembrie 2026
- Acțiuni: deschiderea, maximul și minimul se înmulțesc cu același factor de ajustare ca închiderea (dividende, splituri); TLV fără 30–31 mai 2016 ([Capitolul 2](#))
- În notebook: `returns('sp500')`, `ohlcv('btc')`; nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/21): volatilitatea

- ▣ **Volatilitatea:** abaterea standard a randamentelor, mărimea tipică a unei variații zilnice

$$\hat{\sigma} = \sqrt{\frac{1}{n-1} \sum_{t=1}^n (r_t - \bar{r})^2}, \quad \bar{r} = \frac{1}{n} \sum_{t=1}^n r_t$$

- ▶ $r_t = 100 (\ln P_t - \ln P_{t-1})$: randamentul logaritmic zilnic, în %; P_t : prețul de închidere din ziua t
- ▶ n : numărul de randamente; $\bar{r}$: media lor; notația $\hat{}$ indică o valoare estimată din date
- ▶ numitorul $n - 1$ în locul lui n corectează faptul că media $\bar{r}$ este ea însăși estimată

- ▣ **Volatilitatea cu media zero**, uzuală pentru date zilnice

$$\hat{\sigma}_0 = \sqrt{\frac{1}{n} \sum_{t=1}^n r_t^2}$$

- ▶ media zilnică (cîteva sutimi de procent) este neglijabilă față de abaterea standard zilnică (circa 1%)
- ▣ **Volatilitatea istorică:** aceeași formulă pe o **fereastră mobilă** cu ultimele n zile
 - ▶ $n = 21$ (o lună), 63 (un trimestru) sau 252 (un an de zile de tranzacționare); fereastra avansează cîte o zi

Noțiuni necesare azi (2/21): anualizarea

- **Regula rădăcinii pătrate a timpului:** de la volatilitatea zilnică la cea anuală

$$\sigma_{\text{an}} = \sigma_{\text{zi}} \sqrt{A}$$

- ▶ A : numărul de randamente pe an; circa 252 de zile de tranzacționare pentru piețele de acțiuni, 365 pentru Bitcoin (tranzacționat 7 zile pe săptămână)
- ▶ exemplu: 1% pe zi înseamnă $1 \times \sqrt{252} = 15,9\%$ pe an

- Justificarea: randamentul logaritmic anual este suma a A randamente logaritmice zilnice

- ▶ dacă randamentele zilnice sînt necorelate și au aceeași varianță, varianțele se adună:


$$\text{Var}\left(\sum_{t=1}^A r_t\right) = A \sigma_{\text{zi}}^2 \Rightarrow \sigma_{\text{an}} = \sqrt{A} \sigma_{\text{zi}}$$

- ▶ cu randamente corelate, regula este doar o aproximare

- **Frecvența reală A** , numărată din date

$$A = \frac{\text{numărul de randamente din eșantion}}{\text{numărul de ani acoperiți de eșantion}}$$

Noțiuni necesare azi (3/21): precizia unei estimări a volatilității



- **Eroarea standard** $SE(\hat{\sigma})$: abaterea standard a lui $\hat{\sigma}$ în eșantioane repetate

► pentru n randamente Normale i.i.d. (independente și identic distribuite):

$$\frac{SE(\hat{\sigma})}{\sigma} \approx \frac{1}{\sqrt{2n}}$$

► $n = 21$: circa 15% din σ ; $n = 252$: circa 4,5%

- **Intervalul aproximativ de 95%**

$$\hat{\sigma} \left(1 \pm \frac{1,96}{\sqrt{2n}} \right)$$

► 1,96: cuantila de 97,5% a distribuției Normale standard
► graficul: 20 000 de eșantioane simulate cu $\sigma = 20\%$;
barele: intervalele de 95%

Noțiuni necesare azi (4/21): EWMA


- Varianța **EWMA** (exponentially weighted moving average, medie mobilă ponderată exponențial), RiskMetrics J.P. Morgan/Reuters (1996)

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2, \quad 0 < \lambda < 1$$

- ▶ în cuvinte: varianța de azi este o medie ponderată a varianței de ieri și a randamentului de ieri la pătrat
- ▶ λ : **factorul de atenuare**; $\lambda = 0,94$ pentru date zilnice (RiskMetrics)
- ▶ un λ mare: o estimare netedă, cu memorie lungă; un λ mic: o reacție rapidă la randamentele noi
- ▶ σ_t^2 folosește doar randamentele pînă în ziua $t - 1$: este prognoza varianței din ziua t
- Fereastra mobilă, pentru comparație: ponderea $1/n$ pentru fiecare dintre ultimele n zile, 0 înainte

$$\hat{\sigma}_t^2 = \frac{1}{n} \sum_{j=1}^n r_{t-j}^2$$

Noțiuni necesare azi (5/21): ponderile EWMA și timpul de înjumătățire



- Înlocuind recursia de mai multe ori:

$$\sigma_t^2 = (1 - \lambda) \sum_{j \geq 1} \lambda^{j-1} r_{t-j}^2$$

- ▶ j : vechimea randamentului, în zile; ponderea lui, $(1 - \lambda)\lambda^{j-1}$, scade geometric; ponderile au suma 1



- **Timpul de înjumătățire $h_{1/2}$** : vechimea la care ponderea este jumătate din cea mai nouă

$$\lambda^{h_{1/2}} = 0,5 \quad \Rightarrow \quad h_{1/2} = \frac{\ln 0,5}{\ln \lambda}$$

- **Zilele care cumulează 99% din pondere**: ultimele m zile cumulează $1 - \lambda^m$

$$1 - \lambda^m = 0,99 \quad \Rightarrow \quad m = \frac{\ln 0,01}{\ln \lambda}$$

Noțiuni necesare azi (6/21): fereastra mobilă, EWMA și ghost effect



■ daily return r_t (%) ■ one large day (-8%) — 63-day window — EWMA, $\lambda = 0.94$ true volatility (15.9%)

- Randamente simulate cu o volatilitate constantă de 1% pe zi și o singură zi cu -8%
- **Ghost effect:** estimarea pe 63 de zile rămâne ridicată exact 63 de zile, apoi scade brusc când ziua mare iese din fereastră; scăderea este cauzată de calendar, nu de o știre
- EWMA crește brusc în ziua următoare, apoi scade treptat, cu viteza fixată de λ

Noțiuni necesare azi (7/21): prețurile de deschidere, maxim, minim și închidere



- Prețurile **OHLC** ale zilei t : deschiderea O_t , maximum H_t , minimum L_t , închiderea C_t
 - ▶ ședința: de la O_t la C_t ; noaptea: de la C_{t-1} la O_t , fără tranzacții
- Diferențe logaritmice în % (toate înmulțite cu 100):
 - ▶ **randamentul overnight** $o_t = \ln(O_t/C_{t-1})$
 - ▶ $u_t = \ln(H_t/O_t) \geq 0$: maximum, măsurat față de deschidere
 - ▶ $d_t = \ln(L_t/O_t) \leq 0$: minimum, măsurat față de deschidere
 - ▶ $c_t = \ln(C_t/O_t)$: randamentul ședinței, de la deschidere la închidere
- Două identități
 - ▶ randamentul închidere–închidere (**CC**): $r_t = \ln(C_t/C_{t-1}) = o_t + c_t$
 - ▶ **amplitudinea** logaritmă (range): $u_t - d_t = \ln(H_t/L_t) \geq 0$

Noțiuni necesare azi (8/21): estimatorii Parkinson și Garman–Klass

- Estimatorii de amplitudine: fiecare zi dă o estimare a varianței; pe n zile se calculează media
- **Parkinson** Parkinson (1980): pătratul amplitudinii, rescalat

$$\hat{\sigma}_P^2 = \frac{1}{n} \sum_{t=1}^n \frac{(u_t - d_t)^2}{4 \ln 2}$$

- ▶ pentru un preț care evoluează ca o mișcare browniană fără tendință, $E[(u_t - d_t)^2] = 4 \ln 2 \sigma^2$; împărțirea la $4 \ln 2 = 2,773$ face ca media să fie egală cu varianța σ^2 a ședinței
- ▶ amplitudinea folosește întreaga traiectorie a zilei, nu doar capetele ei: mai multă informație decât r_t^2
- **Garman–Klass** Garman & Klass (1980): amplitudinea plus randamentul ședinței

$$\hat{\sigma}_{GK}^2 = \frac{1}{n} \sum_{t=1}^n \left[0,5 (u_t - d_t)^2 - (2 \ln 2 - 1) c_t^2 \right]$$

- ▶ $2 \ln 2 - 1 = 0,386$: ponderile 0,5 și 0,386 minimizează varianța estimatorului
- ▶ atât Parkinson, cât și Garman–Klass presupun lipsa unei tendințe (drift) în cursul zilei

Noțiuni necesare azi (9/21): estimatorii Rogers–Satchell și Yang–Zhang

- **Rogers–Satchell** Rogers & Satchell (1991): valabil și în prezența unei tendințe (drift)

$$\hat{\sigma}_{RS}^2 = \frac{1}{n} \sum_{t=1}^n \left[u_t (u_t - c_t) + d_t (d_t - c_t) \right]$$

- ▶ fiecare termen este ≥ 0 , deoarece $u_t \geq \max(0, c_t)$ și $d_t \leq \min(0, c_t)$

- **Yang–Zhang** Yang & Zhang (2000) pe $n \geq 2$ zile: noaptea + ședința

$$\hat{\sigma}_{YZ}^2 = \hat{\sigma}_O^2 + k \hat{\sigma}_C^2 + (1 - k) \hat{\sigma}_{RS}^2, \quad k = \frac{0,34}{1,34 + (n + 1)/(n - 1)}$$

- ▶ $\hat{\sigma}_O^2 = \frac{1}{n-1} \sum_t (o_t - \bar{o})^2$, $\hat{\sigma}_C^2 = \frac{1}{n-1} \sum_t (c_t - \bar{c})^2$: varianțele de selecție ale randamentelor nopții și ale ședinței
- ▶ k : ponderea pentru care varianța estimatorului este minimă; de exemplu $k = 0,139$ pentru $n = 21$
- ▶ Yang–Zhang este singurul dintre cei patru estimatori care include varianța nopții

- Volatilitatea anuală, din oricare dintre ei: $\sqrt{A \hat{\sigma}^2}$

Noțiuni necesare azi (10/21): eficiența și deplasarea unui estimator

- ▣ **Deplasarea:** eroarea sistematică a unui estimator

$$\text{deplasarea}(\hat{\sigma}^2) = E(\hat{\sigma}^2) - \sigma^2$$

- ▶ nedeplasat: în medie, pe multe eșantioane, estimarea este egală cu varianța adevărată

- ▣ **Eficiența relativă** a unui estimator X față de estimatorul închidere–închidere


$$\text{Eff}(X) = \frac{\text{Var}(\hat{\sigma}_{CC}^2)}{\text{Var}(\hat{\sigma}_X^2)}$$

- ▶ $\text{Var}(\hat{\sigma}_X^2)$: cât variază estimarea de la un eșantion la altul
- ▶ $\text{Eff}(X) = 5$: X pe n zile este la fel de precis ca estimatorul închidere–închidere pe $5n$ zile
- ▶ pentru o mișcare browniană: Parkinson circa 5, Garman–Klass circa 7

- ▣ Eficiența privește **varianța** unui estimator; deplasarea privește **media** lui

- ▶ un estimator precis poate fi totuși deplasat, de exemplu când ignoră o parte din varianța zilnică

Noțiuni necesare azi (11/21): estimatorii de amplitudine în simulare



- ▣ 3 000 de ferestre simulate de câte 21 de zile, volatilitatea adevărată 20%; fiecare curbă: distribuția unui estimator
- ▣ Stînga: estimatorii de amplitudine sînt mult mai concentrați (mai eficienți) decît estimatorul închidere–închidere
- ▣ Dreapta: cu o noapte, Parkinson și Garman–Klass măsoară doar ședința și sînt deplasați în jos; Yang–Zhang rămîne centrat

Noțiuni necesare azi (12/21): noaptea și ședința în varianța închidere–închidere

- Deoarece $r_t = o_t + c_t$, varianța unei sume dă

$$\text{Var}(r_t) = \text{Var}(o_t) + \text{Var}(c_t) + 2 \text{Cov}(o_t, c_t)$$

- ▶ $\text{Var}(o_t)$: noaptea; $\text{Var}(c_t)$: ședința; $\text{Cov}(o_t, c_t)$: cât de mult se mișcă împreună noaptea și ședința

- Covarianța și corelația de selecție

$$\widehat{\text{Cov}}(o, c) = \frac{1}{n-1} \sum_{t=1}^n (o_t - \bar{o})(c_t - \bar{c}), \quad \text{corr}(o, c) = \frac{\widehat{\text{Cov}}(o, c)}{\hat{\sigma}_o \hat{\sigma}_c} \in [-1, 1]$$

- ▶ $\text{corr}(o, c) < 0$: ședința tinde să inverseze o parte din mișcarea din timpul nopții

- **Ponderea nopții**

$$\text{ponderea nopții} = \frac{\text{Var}(o_t)}{\text{Var}(o_t) + \text{Var}(c_t)}$$

- ▶ o piață deschisă 24 de ore (Bitcoin) nu are noapte: $o_t \approx 0$


Noțiuni necesare azi (13/21): volatility clustering și ACF

- ▣ **Volatility clustering:** variațiile mari sînt urmate de variații mari, iar cele mici de variații mici
 - ▶ semnul lui r_t este aproape imprevizibil, dar mărimea lui (r_t^2 , $|r_t|$) este previzibilă
- ▣ **ACF** (autocorrelation function, funcția de autocorelație) de selecție a unei serii x_t la lagul k

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^T (x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^T (x_t - \bar{x})^2}, \quad k = 1, 2, \dots$$

- ▶ x_t : aici r_t , r_t^2 sau $|r_t|$; T : numărul de observații; $\bar{x}$: media seriei
- ▶ $\hat{\rho}_k \in [-1, 1]$: corelația dintre serie și ea însăși cu k zile în urmă
- ▣ **Banda de 95%** pentru date i.i.d.: $\pm 1,96/\sqrt{T}$
 - ▶ pentru o serie i.i.d., $\hat{\rho}_k$ este aproximativ Normal, cu media 0 și varianța $1/T$; barele din afara benzii sînt semnificative la 5%

Noțiuni necesare azi (14/21): volatility clustering în simulare




- Aceași varianță, altă ordine a zilelor: în dreapta zilele mari apar în grupuri, iar ACF-ul lui r_t^2 rămîne peste bandă

Noțiuni necesare azi (15/21): testul Ljung–Box și distribuția χ^2

- **Ljung–Box** Ljung & Box (1978): sînt nule toate primele m autocorelații?

$$Q(m) = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k}$$

- ▶ m : numărul de laguri; $Q(m)$ însumează pătratele autocorelațiilor, deci este mare cînd ele sînt mari
 - ▶ **McLeod–Li** McLeod & Li (1983): același test pe r_t^2 ; H_0 : fără volatility clustering
- Sub H_0 , $Q(m) \sim \chi^2(m)$
- ▶ $\chi^2(m)$: distribuția sumei a m pătrate de variabile Normale standard independente; media ei este m
 - ▶ respingem H_0 la 5% dacă $Q(m) > \chi_{0,95}^2(m)$, cuantila de 95% (valoarea critică)
 - ▶ **p-value** = $P(\chi^2(m) \geq Q_{\text{obs}})$: respingem la 5% dacă este sub 0,05



Noțiuni necesare azi (16/21): testul ARCH-LM

- ▣ **ARCH-LM Engle (1982):** o regresie auxiliară a lui e_t^2 pe propriul trecut

$$e_t^2 = a_0 + a_1 e_{t-1}^2 + \dots + a_q e_{t-q}^2 + u_t, \quad e_t = r_t - \bar{r}$$

- ▶ q : numărul de laguri; $a_0, \dots, a_q$: coeficienți estimați prin metoda celor mai mici pătrate; u_t : eroarea regresiei

- ▣ **Coeficientul de determinare R^2**

$$R^2 = 1 - \frac{\sum_t \hat{u}_t^2}{\sum_t (e_t^2 - \bar{e}^2)^2} \in [0, 1]$$

- ▶ $\hat{u}_t$: reziduurile; $\bar{e}^2$: media lui e_t^2 ; R^2 : proporția din varianța lui e_t^2 explicată de trecutul ei

- ▣ **Statistica testului și decizia**

$$LM = n R^2 \sim \chi^2(q) \text{ sub } H_0: a_1 = \dots = a_q = 0$$

- ▶ $n = T - q$: observațiile folosite în regresie; H_0 : fără efect ARCH (varianță condiționată constantă)
- ▶ valori critice de 5%: $\chi_{0,95}^2(5) = 11,07$, $\chi_{0,95}^2(10) = 18,31$

Noțiuni necesare azi (17/21): excesul de boltire, amestecarea și eficiența în formă slabă

- **Coeficientul de boltire de selecție:** media puterii a patra a randamentelor standardizate

$$\hat{K} = \frac{1}{T} \sum_{t=1}^T \left(\frac{r_t - \bar{r}}{\hat{\sigma}} \right)^4, \quad \text{excesul de boltire} = \hat{K} - 3$$


- ▶ $K = 3$ pentru distribuția Normală; un exces > 0 : cozi groase, zile extreme mai frecvente decât sub distribuția Normală
- **Amestecarea** (o permutare aleatoare) a unei serii
 - ▶ aceleași T randamente, puse într-o ordine aleatoare; **seed**-ul fixează numerele aleatoare, deci rezultatul poate fi reprodus
 - ▶ o statistică calculată înainte și după amestecare arată dacă ea depinde de ordinea zilelor
- **Eficiența pieței în formă slabă** ([Capitolul 7](#))
 - ▶ randamentele trecute nu pot fi folosite pentru a prognoza randamentele viitoare suficient de bine pentru un profit după costuri

Noțiuni necesare azi (18/21): pierderile prognozelor: MSE și QLIKE

- O prognoză h_t a varianței zilei t , făcută la închiderea zilei $t - 1$, se compară cu o variabilă **proxy** a varianței adevărate
 - ▶ varianța adevărată σ_t^2 nu se observă niciodată; proxy-ul uzual este r_t^2 , cu $E(r_t^2 \mid \text{trecut}) = \sigma_t^2$ când media este zero
 - ▶ r_t^2 este nedeplasat, dar foarte zgomotos (slide-ul următor)
- Două **funcții de pierdere** pe N zile de prognoză

$$\text{MSE} = \frac{1}{N} \sum_t (r_t^2 - h_t)^2, \quad \text{QLIKE} = \frac{1}{N} \sum_t \left(\frac{r_t^2}{h_t} + \ln h_t \right)$$

- ▶ **MSE** (mean squared error, eroarea pătratică medie): media pătratului distanței dintre proxy și prognoză
- ▶ **QLIKE** [Patton \(2011\)](#): log-verosimilitatea Normală cu semn schimbat, pînă la constante; valoarea ei așteptată este minimă pentru $h_t = \sigma_t^2$
- ▶ la ambele pierderi, o valoare mai mică este mai bună; ambele ordonează corect prognozele chiar cu proxy-ul zgomotos r_t^2

Noțiuni necesare azi (19/21): proxy-ul r_t^2 

- Variația adevărată simulată (linia) și proxy-ul r_t^2 (punctele), pe o scală logaritmică
- O singură zi spune puțin: pierderile trebuie mediate pe multe zile, iar diferențele dintre ele trebuie testate

Noțiuni necesare azi (20/21): testul Diebold–Mariano

- Testul **DM** (Diebold–Mariano) [Diebold & Mariano \(1995\)](#): au două prognoze A și B aceeași pierdere așteptată?

$$d_t = L_t^A - L_t^B, \quad \bar{d} = \frac{1}{N} \sum_{t=1}^N d_t, \quad t_{DM} = \frac{\bar{d}}{\widehat{SE}(\bar{d})}$$

- ▶ L_t^A, L_t^B : pierderile lui A și B în ziua t (termenii MSE sau QLIKE); d_t : diferența lor
 - ▶ $\widehat{SE}(\bar{d})$: eroarea standard a diferenței medii, calculată astfel încât să rămână validă când d_t este autocorelat și heteroscedastic (HAC)
- Decizia
- ▶ H_0 : $E(d_t) = 0$; sub H_0 , t_{DM} are aproximativ distribuția Normală standard
 - ▶ $|t_{DM}| > 1,96$: cele două prognoze diferă la 5%; $t_{DM} < 0$: A are pierderile mai mici
 - ▶ prognozele trebuie să folosească doar informația disponibilă la închiderea zilei $t - 1$

Noțiuni necesare azi (21/21): VIX și volatilitatea realizată

- **VIX Cboe (2026)**: volatilitatea S&P 500 așteptată pentru următoarele 30 de zile, implicită în prețurile opțiunilor, în procente anualizate

► ca prognoză a varianței zilnice (în %²), cu $A = 252$:

$$h_t = \frac{\text{VIX}_{t-1}^2}{A}$$

► exemplu: $\text{VIX} = 20$ dă $h_t = 400/252 = 1,59$, o volatilitate zilnică de 1,26%

- **Volatilitatea realizată** în următoarele 21 de zile, anualizată

$$\text{RV}_t = \sqrt{\frac{A}{21} \sum_{j=1}^{21} r_{t+j}^2}$$

► **prima de risc a varianței**: diferența dintre varianța implicită (VIX^2) și varianța realizată ulterior

- Acțiuni puțin lichide

► ponderea zilelor cu închiderea neschimbată: $\frac{1}{T} \sum_t 1\{C_t = C_{t-1}\}$, unde $1\{\cdot\}$ este 1 dacă este îndeplinită condiția și 0 altfel

► **stale open**: un preț de deschidere egal cu închiderea precedentă, deoarece la deschidere nu a avut loc nicio tranzacție

A1: volatilitatea istorică din cinci zile [Rezolvat]

Cerință

- ▣ Randamentele zilnice (%) ale unei acțiuni: 1,2; -0,8; 0,5; -1,5; 0,6.
- ▣ 1. Calculați media și abaterea standard de selecție (împărțiți la $n - 1$).
- ▣ 2. Anualizați abaterea standard cu $A = 252$.
- ▣ 3. Calculați volatilitatea cu media zero, $\sqrt{\frac{1}{n} \sum r_t^2}$.
- ▣ 4. Calculați $1/\sqrt{2n}$ și un interval aproximativ de 95% pentru volatilitatea anuală.
- ▣ Raportați: media, două volatilități zilnice, o volatilitate anuală, un interval și o frază.

Rezolvare

- ▣ 1. Media = $0/5 = 0$; abaterile la pătrat 1,44; 0,64; 0,25; 2,25; 0,36, suma 4,94; $s^2 = 4,94/4 = 1,235$, $s = 1,111\%$
- ▣ 2. $1,111 \times \sqrt{252} = 17,6\%$
- ▣ 3. $\sqrt{4,94/5} = 0,994\%$: cu media zero, se schimbă doar numitorul
- ▣ 4. $1/\sqrt{10} = 31,6\%$; $17,6 \times (1 \pm 1,96 \times 0,316)$: [6,7%; 28,6%]
- ▣ Cinci zile nu spun aproape nimic: volatilitatea anuală poate fi oriunde între 6,7% și 28,6%.

A2: Bitcoin în şase zile [Propus]

Rezolvarea se discută la seminar

Cerinţă

- ▣ Randamente zilnice Bitcoin (%): 3,1; -4,2; 1,0; 5,5; -2,4; -0,9. Model: A1.
- ▣ 1. Calculaţi media şi abaterea standard de selecţie.
- ▣ 2. Anualizaţi-o cu $A = 365$ şi, greşit, cu $A = 252$.
- ▣ 3. Calculaţi intervalul aproximativ de 95% pentru volatilitatea anuală ($A = 365$).
- ▣ Raportaţi: două volatilităţi anuale, un interval şi o frază.

A3: EWMA pas cu pas [Rezolvat]

Cerință

- ▣ $\lambda = 0,94$; varianța EWMA de azi este $\sigma_1^2 = 1,00$ (%²); următoarele trei randamente sînt $r_1 = -2,0\%$, $r_2 = 0,5\%$, $r_3 = 3,0\%$.
- ▣ 1. Calculați σ_2^2 , σ_3^2 și σ_4^2 .
- ▣ 2. Anualizați σ_4 cu $A = 252$.
- ▣ 3. Calculați timpul de înjumătățire și ponderea lui r_3^2 în σ_4^2 .
- ▣ Raportați: trei varianțe, o volatilitate anuală, timpul de înjumătățire și o frază.

Rezolvare

- ▣ 1. $\sigma_2^2 = 0,94 \times 1,00 + 0,06 \times 4,00 = 1,1800$
- ▣ $\sigma_3^2 = 0,94 \times 1,1800 + 0,06 \times 0,25 = 1,1242$;
 $\sigma_4^2 = 0,94 \times 1,1242 + 0,06 \times 9 = 1,5967$
- ▣ 2. $\sigma_4 = 1,264\%$; $1,264 \times \sqrt{252} = 20,1\%$
- ▣ 3. $\ln 0,5 / \ln 0,94 = 11,2$ zile; cel mai nou randament la pătrat primește ponderea $1 - \lambda = 0,06$
- ▣ O zi cu 3% crește varianța cu 42%; o zi liniștită o scade doar cu 6%.

A4: un EWMA mai lent [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Aceleași date ca în A3, cu $\lambda = 0,97$ (valoarea lunară RiskMetrics). Model: A3.
- ▣ 1. Calculați σ_2^2 , σ_3^2 și σ_4^2 și anualizați σ_4 .
- ▣ 2. Calculați timpul de înjumătățire și numărul de zile care cumulează 99% din pondere.
- ▣ 3. Comparați cu A3: care λ reacționează mai repede la ziua cu 3%?
- ▣ Raportați: trei variante, o volatilitate anuală, două numere de zile și o frază.

A5: patru estimatori dintr-o singură zi [Rezolvat]

Cerință

- Închiderea precedentă 100,0; deschiderea 101,0, maximul 103,5, minimul 99,8, închiderea 102,2.
- 1. Calculați o , u , d , c (în %) și $r = o + c$.
- 2. Calculați varianțele pentru o zi CC, Parkinson, Garman–Klass și Rogers–Satchell.
- 3. Anualizați-le cu $A = 252$, ca și cum toate zilele ar arăta ca aceasta.
- 4. Precizați care estimatori includ mișcarea overnight o .
- Raportați: cinci randamente logaritmice, patru varianțe, patru volatilități anuale și o frază.

Rezolvare

- 1. $o = 100 \ln(101/100) = 0,995$, $u = 2,445$, $d = -1,195$, $c = 1,181$, $r = 2,176$
- 2. CC $r^2 = 4,736$; Parkinson $3,640^2/2,773 = 4,780$; GK $0,5 \times 3,640^2 - 0,386 \times 1,181^2 = 6,087$; RS 5,931
- 3. $\sqrt{252} \hat{\sigma}^2$: CC 34,5%, Parkinson 34,7%, GK 39,2%, RS 38,7%
- 4. Doar CC (și Yang–Zhang, pe mai multe zile) includ o ; Parkinson, GK și RS reflectă doar ședința.

A6: trei zile și estimatorul Yang–Zhang [Propus]

Rezolvarea se discută la seminar

Cerință

Ziua	Deschidere	Maxim	Minim	Închidere
1	50,2	51,0	49,6	50,8
2	50,5	51,9	50,3	51,6
3	51,9	52,4	50,9	51,1

- Închiderea precedentă: 50,0. Model: A5.
- 1. Calculați o , u , d , c pentru fiecare zi.
- 2. Calculați termenii Parkinson și Rogers–Satchell ai fiecărei zile și mediile lor.
- 3. Calculați k , $\hat{\sigma}_O^2$, $\hat{\sigma}_C^2$ și varianța Yang–Zhang pentru $n = 3$.
- 4. Comparați cu varianța de selecție CC și anualizați toate trei cu $A = 252$.
- Raportați: un tabel mic, trei varianțe, trei volatilități anuale și o frază.

A7: două teste de volatility clustering [Rezolvat]

Cerință

- $T = 1000$ de randamente zilnice; ACF-ul randamentelor **la pătrat** la lagurile 1–5: 0,20; 0,15; 0,12; 0,10; 0,08; regresia ARCH-LM cu $q = 5$ laguri pe $n = 995$ de observații are $R^2 = 0,08$.
- 1. Calculați statistica Ljung–Box $Q(5)$ a randamentelor la pătrat.
- 2. Calculați $LM = nR^2$.
- 3. Comparați ambele statistici cu $\chi^2_{0,95}(5) = 11,07$ și decideți.
- Raportați: două statistici, două decizii și o frază.

Rezolvare

- 1. Termenii $1000 \cdot 1002 \hat{\rho}_k^2 / (1000 - k)$: 40,12; 22,59; 14,47; 10,06; 6,45; $Q(5) = 93,69$
- 2. $LM = 995 \times 0,08 = 79,60$
- 3. Ambele mult peste 11,07 (ambele cu $p < 0,001$): respingem H_0 ; varianța poate fi anticipată din trecutul recent.

A8: rezultate diferite ale celor două teste [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $T = 500$; ACF-ul randamentelor la pătrat la lagurile 1–5: 0,12; 0,08; 0,06; 0,05; 0,04; ARCH-LM cu $q = 5$ pe $n = 495$ de observații: $R^2 = 0,018$. Model: A7.
- ▣ 1. Calculați $Q(5)$ și decideți la 5%.
- ▣ 2. Calculați LM și decideți la 5%.
- ▣ 3. Indicați un motiv pentru care cele două teste pot da rezultate diferite.
- ▣ Raportați: două statistici, două decizii și o frază.

A9: MSE și QLIKE pas cu pas [Rezolvat]

Cerință

- În patru zile variabila proxy r_t^2 ia valorile 1,0; 4,0; 0,25; 2,25 (%²). Prognoza A este constantă, 1,5; prognoza B este 1,0; 2,5; 0,8; 1,8.
- 1. Calculați MSE pentru fiecare prognoză.
- 2. Calculați termenii QLIKE $r_t^2/h_t + \ln h_t$ și media lor pentru fiecare prognoză.
- 3. Precizați care prognoză este mai bună după fiecare funcție de pierdere.
- Raportați: două valori MSE, două valori QLIKE și o frază.

Rezolvare

- 1. A: $(1 - 1,5)^2 = 0,2500$; 6,2500; 1,5625; 0,5625, MSE 2,156; B: 0,0000; 2,2500; 0,3025; 0,2025, MSE 0,689
- 2. A: $1/1,5 + \ln 1,5 = 1,072$; 3,072; 0,572; 1,905, media 1,655; B: 1,000; 2,516; 0,089; 1,838, media 1,361
- 3. B este mai bună după ambele pierderi: urmărește schimbările varianței, pe care o prognoză constantă nu le poate surprinde.

A10: subestimare și supraestimare [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Varianța reală și variabila proxy sînt ambele egale cu 1. Două prognoze: $h = 0,5$ (jumătate) și $h = 2$ (dublu). Model: A9.
- ▣ 1. Calculați MSE pentru fiecare prognoză.
- ▣ 2. Calculați QLIKE pentru fiecare prognoză.
- ▣ 3. Precizați care funcție de pierdere penalizează mai mult subestimarea.
- ▣ Raportați: patru valori și o frază despre importanța acestui fapt pentru VaR.

B1: volatilitatea istorică și volatilitatea EWMA pentru S&P 500 [Rezolvat]

- **Întrebarea:** cât de diferite sînt volatilitățile S&P 500 pe 21, 63 și 252 de zile și volatilitatea EWMA?
- **Date:** închiderile S&P 500 din 1990, randamente logaritmice zilnice în %
- **Cerințe**
 1. Calculați volatilitatea pe ferestre mobile de 21, 63 și 252 de zile și volatilitatea EWMA ($\lambda = 0,94$), anualizate cu frecvența reală.
 2. Desenați cele patru serii din 2018.
 3. Raportați cele patru valori de la sfîrșitul eșantionului și maximele lor din 2020, cu datele.
 4. Găsiți ziua din iunie 2020 în care volatilitatea pe 63 de zile scade cel mai mult și raportați variația EWMA din acea zi.
 5. Interpretare: ce estimare ați prezenta unui comitet de risc în acea zi?
- **Raportați:** graficul, douăsprezece valori și două fraze
- **Notebook:** secțiunea B1

B1: rezolvare [Rezolvat]



- ▣ $A = 252$; întregul eșantion 18,0%; pe 18 septembrie 2026: 21 de zile 9,6%, 63 de zile 11,1%, 252 de zile 12,9%, EWMA 10,4%
- ▣ Maximele din 2020: 97,5% (6 aprilie 2020), 62,6% (20 mai 2020), 34,7% (28 decembrie 2020), EWMA 84,8% (24 martie 2020)
- ▣ Pe 15 iunie 2020, volatilitatea pe 63 de zile a scăzut de la 50,4% la 43,0% (ziua crahului din 16 martie a ieșit din fereastră); EWMA a trecut de la 35,6% la 34,6%
- ▣ Interpretare: EWMA; scăderea estimării pe 63 de zile este ghost effect, nu o știre; valoarea pe 252 de zile reflectă încă luna martie


B2: BET și Bitcoin [Propus]

- **Întrebarea:** cât de volatile sînt BET și Bitcoin în comparație cu S&P 500, azi și la sfîrșitul lui 2017? Model: B1.
- **Date:** BET din 1997, Bitcoin din 2014, S&P 500 din 1990, randamente logaritmice zilnice în %
- **Cerințe**
 1. Calculați numărul de observații pe an și volatilitatea anuală pe întregul eșantion pentru fiecare serie.
 2. Anualizați Bitcoin și cu 252 și dați eroarea în %.
 3. Raportați volatilitatea pe 252 de zile la sfîrșitul lui 2017 și la sfîrșitul eșantionului, precum și maximul volatilității pe 63 de zile, cu anul lui.
 4. Interpretare: a devenit Bitcoin un activ cu o volatilitate asemănătoare acțiunilor?
- **Raportați:** un tabel și două fraze
- **Notebook:** secțiunea B2

B3: estimatori de amplitudine pentru S&P 500 [Rezolvat]

- ▣ **Întrebarea:** dau estimatorii de amplitudine aceeași volatilitate ca prețurile de închidere pentru S&P 500?
- ▣ **Date:** OHLC S&P 500 din 2008 ($T = 4\,707$ de zile)
- ▣ **Cerințe**
 1. Calculați o_t , u_t , d_t , c_t și cei cinci estimatori pe întregul eșantion, anualizați.
 2. Descompuneți $\text{Var}(r_t) = \text{Var}(o_t) + \text{Var}(c_t) + 2 \text{Cov}(o_t, c_t)$.
 3. Desenați estimările pe ferestre mobile de 21 de zile din 2025.
 4. Interpretare: de ce sînt Parkinson, Garman–Klass și Rogers–Satchell sub estimatorul închidere–închidere?
- ▣ **Raportați:** graficul, cinci volatilități, o descompunere și două fraze
- ▣ **Notebook:** secțiunea B3

B3: rezolvare [Rezolvat]



- Volatilitatea anuală: CC 19,9%, Parkinson 15,4%, GK 14,6%, RS 14,4%, YZ 16,3%
- Varianțe zilnice ($\%^2$): $1,568 = 0,176 + 1,194 + 0,197$; noaptea reprezintă 13% din $\text{Var}(o) + \text{Var}(c)$; $\text{corr}(o, c) = 0,22$
- Interpretare: acești estimatori reflectă doar ședința de tranzacționare, deci omit varianța overnight și termenul de covarianță; YZ adaugă varianța nopții, dar nu și covarianța


B4: DAX, Bitcoin și TLV [Propus]

- **Întrebarea:** pentru care dintre DAX, Bitcoin și Banca Transilvania sînt estimatorii de amplitudine apropiați de estimatorul închidere–închidere? Model: B3.
- **Date:** OHLC DAX din 2006, Bitcoin din 2014, OHLC ajustat TLV din 2010
- **Cerințe**
 1. Calculați cei cinci estimatori anualizați pentru fiecare activ.
 2. Calculați ponderea nopții și $\text{corr}(o_t, c_t)$.
 3. Ordonăți activele după raportul Parkinson / CC.
 4. Interpretare: pentru ce activ ați putea înlocui estimatorul închidere–închidere cu Parkinson?
- **Raportați:** un tabel și două fraze
- Notebook: secțiunea B4

B5: volatility clustering la S&P 500 [Rezolvat]

- ▣ **Întrebarea:** sînt mărimea și semnul randamentelor S&P 500 la fel de previzibile?
- ▣ **Date:** închiderile S&P 500 din 1990, randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Desenați ACF-ul lui r_t , r_t^2 și $|r_t|$ pentru lagurile 1–50, cu banda de 95% pentru date i.i.d.
 2. Raportați $\hat{\rho}_1, \dots, \hat{\rho}_5$ pentru r_t și pentru r_t^2 .
 3. Calculați statistica Ljung–Box $Q(10)$ pentru r_t , r_t^2 și $|r_t|$, precum și statistica ARCH-LM(5) cu R^2 -ul ei.
 4. Interpretare: contrazice volatility clustering eficiența pieței în formă slabă?
- ▣ **Raportați:** graficul, zece autocorelații, patru statistici și două fraze
- ▣ **Notebook:** secțiunea B5

B5: rezolvare [Rezolvat]



- $\hat{\rho}_{1..5}(r)$: $-0,079$; $-0,004$; $-0,006$; $-0,022$; $-0,016$; $\hat{\rho}_{1..5}(r^2)$: $0,311$; $0,408$; $0,250$; $0,298$; $0,308$; $T = 9\,240$
- $Q(10)$: r 90,8 ($p < 0,001$), r^2 8015, $|r|$ 8323 (valoarea critică 18,31); ARCH-LM(5) = $9\,235 \times 0,241 = 2\,227$ (valoarea critică 11,07)
- Interpretare: nu; mărimea este previzibilă, semnul aproape deloc; eficiența privește randamentele previzibile, nu riscul previzibil (Capitolul 7)


B6: încă patru serii [Propus]

- **Întrebarea:** depinde volatility clustering de la BET, Bitcoin, Banca Transilvania și OMV Petrom de ordinea zilelor? Model: B5.
- **Date:** BET din 1997, Bitcoin din 2014, TLV și SNP din 2010
- **Cerințe**
 1. Calculați $\hat{\rho}_1(r^2)$, $Q(10)$ pentru r_t^2 , ARCH-LM(5) și excesul de boltire pentru fiecare serie.
 2. Amestecați aleator randamentele (seed 2026) și calculați din nou $Q(10)$ pentru r_t^2 și ARCH-LM(5).
 3. Interpretare: de ce amestecarea elimină volatility clustering, dar nu și cozile groase?
- **Raportați:** un tabel și două fraze
- **Notebook:** secțiunea B6

B7: cea mai bună prognoză simplă [Rezolvat]

- ▣ **Întrebarea:** ce prognoză simplă a varianței de mâine a S&P 500 are cea mai mică pierdere din 2010?
- ▣ **Date:** randamentele S&P 500 din 1990, închiderile VIX; prognoze pentru 4 202 de zile din 2010
- ▣ **Cerințe**
 1. Construiți prognoze pentru ziua următoare: mediile mobile ale lui r_t^2 pe 21, 63 și 252 de zile, EWMA cu $\lambda = 0,94$ și $0,97$ și VIX^2/A .
 2. Calculați MSE și QLIKE cu variabila proxy r_t^2 .
 3. Aplicați testul Diebold–Mariano pentru EWMA 0,94 față de fereastra de 21 de zile și pentru VIX față de EWMA 0,94.
 4. Desenați QLIKE pentru EWMA, cu λ între 0,80 și 0,995.
 5. Interpretare: este VIX o prognoză mai bună a varianței de mâine decât EWMA?
- ▣ **Raportați:** un tabel cu douăsprezece valori, două teste, graficul și două fraze
- ▣ **Notebook:** secțiunea B7

B7: rezolvare [Rezolvat]



	21	63	252	EWMA 0,94	EWMA 0,97	VIX
MSE	18,99	20,77	21,43	17,77	19,02	16,70
QLIKE	0,876	0,914	1,099	0,808	0,844	0,799

- DM: EWMA 0,94 față de 21 de zile $t = -4,50$ ($p < 0,001$); VIX față de EWMA 0,94 $t = -0,32$ ($p = 0,751$); cel mai bun $\lambda = 0,925$
- Interpretare: nu; VIX are pierderi puțin mai mici, dar diferența nu este semnificativă; ambele sînt mai bune decît ferestrele mobile

B8: cel mai bun λ pentru BET și Bitcoin [Propus]

- ▣ **Întrebarea:** este $\lambda = 0,94$ din RiskMetrics o alegere bună pentru BET și pentru Bitcoin? Model: B7.
- ▣ **Date:** BET din 1997 și Bitcoin din 2014; prognoze din 2010 (BET) și din 2016 (Bitcoin)
- ▣ **Cerințe**
 1. Calculați QLIKE pentru prognozele EWMA ale zilei următoare, cu λ între 0,80 și 0,995, și găsiți cel mai bun λ .
 2. Raportați QLIKE pentru cel mai bun λ , pentru 0,94 și pentru 0,97, precum și timpul de înjumătățire al celui mai bun λ .
 3. Aplicați testul Diebold–Mariano pentru cel mai bun λ față de 0,94.
 4. Interpretare: ați folosi $\lambda = 0,94$ pentru ambele serii?
- ▣ **Raportați:** un tabel și două fraze
- ▣ **Notebook:** secțiunea B8

C1: estimatorul potrivit pentru acțiunile BVB [Propus]

- ▣ **Întrebarea:** Îmbunătățesc estimatorii de amplitudine prognozele de volatilitate pentru acțiunile puțin lichide de la Bursa de Valori București?
- ▣ **Date:** OHLC ajustat pentru TLV, SNP, BRD și TGN din 2010; S&P 500 din 2008 ca termen de comparație; modele: B3, B7
- ▣ **Cerințe**
 1. Calculați ponderea zilelor de tranzacționare cu închiderea neschimbată, precum și rapoartele Parkinson / CC și YZ / CC ale volatilității pe întregul eșantion.
 2. Calculați QLIKE (proxy r_t^2) pentru prognozele zilei următoare date de varianțele CC, Parkinson și YZ pe 21 de zile, din 2010.
 3. Comparați cele patru acțiuni cu S&P 500.
 4. Enumerați două motive pentru care cel mai bun estimator poate diferi de la o acțiune la alta.
 5. Interpretare: de ce date ați avea nevoie pentru a explica diferențele?
- ▣ **Raportați:** un tabel și un plan de proiect
- ▣ **Notebook:** secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI să rezume volatilitatea S&P 500 și a Bitcoin. Răspunsul:
- (a) Din 2008 volatilitatea Parkinson a S&P 500 este 15,4%, iar cea închidere–închidere 19,9%; Parkinson este de circa cinci ori mai eficient, deci volatilitatea reală este 15,4%.
- (b) Statistica Ljung-Box $Q(10)$ a randamentelor S&P 500 este 90,8 ($p < 0,001$), deci S&P 500 prezintă volatility clustering.
- (c) EWMA cu $\lambda = 0,94$ are un timp de înjumătățire de circa 94 de zile.
- (d) Abaterea standard zilnică a Bitcoin este 3,49%, deci volatilitatea anuală este $3,49 \times \sqrt{252} = 55,3\%$.
- (e) Din 1990, VIX a fost peste volatilitatea realizată din următoarele 21 de zile în circa 86% din zile.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook (secțiunea C2).
 - ▶ 2. Raportați: o listă de cinci verdicte, fiecare cu un rând de justificare.

Idei de reținut

- ▣ Anualizați cu frecvența reală: 252 pentru piețele de acțiuni, 365 pentru Bitcoin
- ▣ Ferestrele scurte reacționează repede, cele lungi netezesc estimarea; EWMA reacționează fără ghost effect
- ▣ Estimatorii de amplitudine sînt preciși, dar reflectă doar ședința: folosiți Yang–Zhang cînd piața se închide noaptea
- ▣ Volatility clustering se testează pe r_t^2 (Ljung–Box, ARCH-LM), nu pe r_t
- ▣ Comparați prognozele cu QLIKE și testați diferența; un răspuns AI este o primă versiune, care trebuie verificată

După seminar

- Cursul 8 dezvoltă fiecare temă de azi: volatilitatea istorică și EWMA, volatilitatea de amplitudine și cea realizată, volatility clustering, VIX, evaluarea prognozelor
- Încercați cerințele [Propus] în notebook; rezolvările se discută la seminar
- C1 poate deveni un proiect de echipă: toate acțiunile din BET, grupe de lichiditate, teste Diebold–Mariano
- Lectură: [Franke, Härdle & Hafner \(2019\)](#), cap. 13; exerciții în [Borak, Härdle & López-Cabrera \(2013\)](#), cap. 13; [Tsay \(2010\)](#), cap. 3.1

Bibliografie

- Borak, S., Härdle, W.K., López-Cabrera, B. (2013). *Statistics of Financial Markets: Exercises and Solutions*, 2nd ed. Springer.
- Cboe Global Markets (2026). *Cboe Volatility Index (VIX)*. Product page and methodology.
- Diebold, F.X., Mariano, R.S. (1995). *Comparing predictive accuracy*. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Engle, R.F. (1982). *Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation*. *Econometrica*, 50(4), 987–1007.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- Garman, M.B., Klass, M.J. (1980). *On the estimation of security price volatilities from historical data*. *Journal of Business*, 53(1), 67–78.
- J.P. Morgan/Reuters (1996). *RiskMetrics – Technical Document*, 4th ed. New York: Morgan Guaranty Trust Company.
- Ljung, G.M., Box, G.E.P. (1978). *On a measure of lack of fit in time series models*. *Biometrika*, 65(2), 297–303.
- McLeod, A.I., Li, W.K. (1983). *Diagnostic checking ARMA time series models using squared-residual autocorrelations*. *Journal of Time Series Analysis*, 4(4), 269–273.
- Parkinson, M. (1980). *The extreme value method for estimating the variance of the rate of return*. *Journal of Business*, 53(1), 61–65.
- Patton, A.J. (2011). *Volatility forecast comparison using imperfect volatility proxies*. *Journal of Econometrics*, 160(1), 246–256.
- Rogers, L.C.G., Satchell, S.E. (1991). *Estimating variance from high, low and closing prices*. *Annals of Applied Probability*, 1(4), 504–512.
- Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed. Wiley.
- Yang, D., Zhang, Q. (2000). *Drift-independent volatility estimation based on high, low, open, and close prices*. *Journal of Business*, 73(3), 477–492.