



Statistica piețelor financiare

Seminarul 9: Modele ARCH și GARCH



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **AI:** Artificial Intelligence (inteligență artificială)
- ▣ **AIC:** Akaike Information Criterion (criteriul informațional Akaike)
- ▣ **ARCH:** AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC:** Bayesian Information Criterion (criteriul informațional bayesian)
- ▣ **BVB:** Bursa de Valori București
- ▣ **COVID-19:** COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- ▣ **DM:** Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **EGARCH:** Exponential GARCH (GARCH exponențial)
- ▣ **EODHD:** EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **ETF:** Exchange-Traded Fund (fond tranzacționat la bursă)

Acronime folosite în acest material (2/2)

- **EWMA**: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- **GJR**: Glosten–Jagannathan–Runkle (asymmetric GARCH) — modelul GARCH asimetric Glosten–Jagannathan–Runkle
- **GJR-GARCH**: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- **IGARCH**: Integrated GARCH (GARCH integrat)
- **LR**: Likelihood Ratio (test) — testul raportului de verosimilitate
- **MLE**: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- **QLIKE**: Quasi-LIKelihood (loss function) — funcția de pierdere de tip cvasi-verosimilitate
- **SE**: Standard Error (eroare standard)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum modelăm, estimăm și prognozăm o volatilitate care se schimbă în fiecare zi?
 - ▶ seminarul are loc **înaintea** Cursului 9: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: algebra GARCH, prognoze și VaR, verosimilitatea ARCH, impactul asimetric al știrilor, pe hârtie
 - ▶ Partea B: estimarea GARCH, asimetria și prognozele în afara eșantionului pe S&P 500, DAX, BET, Bitcoin și acțiuni BVB, fiecare cu o întrebare de interpretare
 - ▶ Partea C: o întrebare deschisă pentru proiect și un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook
- ▣ Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	persistența, varianța pe termen lung, timpul de înjumătățire și un pas GARCH(1,1)	Rezolvat, Propus	A1
A3, A4	proгноze pe mai mulți pași, volatilitatea pe 10 zile și VaR 1%	Rezolvat, Propus	A3
A5, A6	verosimilitatea și boltirea ARCH(1); impactul știrilor în GJR-GARCH și EGARCH	Rezolvat, Propus	A5
B1, B2	estimări GARCH(1,1)-t: DAX; BET, Banca Transilvania, Bitcoin	Rezolvat, Propus	B1
B3, B4	asimetria și efectul de levier: S&P 500; BET, Bitcoin, TLV	Rezolvat, Propus	B3
B5, B6	GARCH față de EWMA în afara eșantionului, depășirile VaR 1%: S&P 500; DAX, BET	Rezolvat, Propus	B5
C1, C2	apropierea volatilității Bitcoin de cea a acțiunilor; erorile unui răspuns AI	Propus	B1, B3

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați voi, după model

Datele folosite

Seria	Sursa	Prețul folosit	Perioada
S&P 500, DAX, BET	EODHD	închidere	2000–2026
Bitcoin	EODHD	închidere, 7 zile pe săptămână	2014–2026
Banca Transilvania (TLV)	EODHD	închidere ajustată	2010–2026

- Randamente logaritmice zilnice în %: $r_t = 100 (\ln P_t - \ln P_{t-1})$; weekendurile și închiderile repetate din zilele libere se elimină (cu excepția Bitcoin); ultima zi este 18 septembrie 2026
- TLV: zilele de 30 și 31 mai 2016 se elimină (o ajustare de preț aplicată cu o zi mai târziu, [Capitolul 2](#))
- În notebook: `returns('dax')`, `fit(r, dist='t')` (pachetul `arch`); nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/17): media și varianța condiționată

- **Modelul randamentului:** o medie constantă plus un șoc a cărui mărime se schimbă în timp

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t Z_t$$

- ▶ r_t : randamentul logaritmic zilnic, în %; μ : media lui; ε_t : **șocul** (partea neașteptată a randamentului)
- ▶ z_t : **inovațiile**, i.i.d. (independente și identic distribuite), cu media 0 și varianța 1

- **Varianța condiționată:** varianța randamentului de mîine, dat fiind tot ce se știe azi

$$\sigma_t^2 = \text{Var}(r_t \mid \text{informația pînă în ziua } t - 1)$$

- ▶ σ_t^2 este cunoscută cu o zi înainte: este prognoza varianței pentru ziua t
- ▶ **varianța necondiționată** $\text{Var}(r_t)$ este media pe termen lung a lui σ_t^2
- ▶ șocurile sînt necorelate, dar pătratele lor sînt corelate: volatility clustering ([Capitolul 8](#))

Noțiuni necesare azi (2/17): modelul ARCH(1)

- ▣ **ARCH(1)** Engle (1982) (autoregressive conditional heteroskedasticity, heteroscedasticitate condiționată autoregresivă)

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2, \quad \omega > 0, \quad 0 \leq \alpha < 1$$

- ▶ în cuvinte: varianța de azi este o constantă ω plus o fracțiune α din pătratul șocului de ieri
- ▶ α : reacția la știrile de ieri; $\alpha = 0$ dă o varianță constantă ω

- ▣ **Varianța necondiționată**: aplicăm media, cu $E(\varepsilon_t^2) = E(\varepsilon_{t-1}^2) = \sigma^2$

$$\sigma^2 = \omega + \alpha \sigma^2 \quad \Rightarrow \quad \sigma^2 = \frac{\omega}{1 - \alpha}$$

- ▣ **Coeficientul de boltire** $K = E(\varepsilon_t^4)/\sigma^4$, cu z_t Normale și $3\alpha^2 < 1$

$$K = \frac{3(1 - \alpha^2)}{1 - 3\alpha^2} > 3$$

- ▶ $K = 3$ pentru distribuția Normală: ARCH produce cozi groase chiar cu inovații Normale

Noțiuni necesare azi (3/17): modelul GARCH(1,1)

- **GARCH(1,1)** [Bollerslev \(1986\)](#): ARCH plus varianța de ieri

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad \omega > 0, \quad \alpha, \beta \geq 0$$


- ▶ ω : o constantă care fixează nivelul pe termen lung al varianței
- ▶ α : reacția la știri (pătratul șocului de ieri); un α mare: o volatilitate cu salturi
- ▶ β : memoria (ponderea varianței de ieri); un β mare: o volatilitate netedă, care se schimbă lent
- ▶ $\alpha + \beta < 1$: modelul este staționar (în covarianță), cu o varianță necondiționată finită

- **EWMA** ([Capitolul 8](#)) drept caz particular

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$$

- ▶ un GARCH(1,1) cu $\mu = 0$, $\omega = 0$, $\alpha = 1 - \lambda$, $\beta = \lambda$, deci $\alpha + \beta = 1$: un **IGARCH** (integrated GARCH, GARCH integrat)

Noțiuni necesare azi (4/17): varianța constantă, ARCH și GARCH în simulare



- Aceleași inovații z_t în cele trei panouri; liniile roșii sînt $\pm 2\sigma_t$
- ARCH(1): varianța sare după fiecare șoc mare și revine a doua zi; GARCH(1,1): varianța evoluează în valuri lungi și netede
- Pentru un model corect, circa 95% dintre randamente se află în intervalul $\pm 2\sigma_t$ (inovații Normale)

Noțiuni necesare azi (5/17): persistența, varianța pe termen lung și timpul de înjumătățire

□ Persistența $\alpha + \beta$ și varianța pe termen lung


$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha - \beta}, \quad \sigma_{\text{an}} = \sqrt{252 \bar{\sigma}^2}$$

- ▶ $\bar{\sigma}^2$: nivelul spre care revine varianța (revenirea la medie)
- ▶ când $\alpha + \beta$ este aproape de 1, $\bar{\sigma}^2$ este foarte imprecisă: o mică eroare în $1 - \alpha - \beta$ o schimbă mult

□ În fiecare zi, abaterea față de $\bar{\sigma}^2$ se reduce cu factorul $\alpha + \beta$

$$h_{1/2} = \frac{\ln 0,5}{\ln(\alpha + \beta)}$$

- ▶ $h_{1/2}$: **timpul de înjumătățire**, numărul de zile după care a dispărut jumătate dintr-un șoc de varianță
- ▶ IGARCH ($\alpha + \beta = 1$): nu există varianță pe termen lung și nici timp de înjumătățire; șocurile nu se atenuează



Noțiuni necesare azi (6/17): prognozele varianței

- Prognoze făcute la sfârșitul zilei t ; E_t : media condiționată de datele pînă în ziua t
- **O zi înainte:** cunoscută exact din datele de azi

$$\sigma_{t+1}^2 = \omega + \alpha (r_t - \mu)^2 + \beta \sigma_t^2$$

- **Cu h zile înainte:** abaterea față de $\bar{\sigma}^2$ scade geometric


$$E_t[\sigma_{t+h}^2] = \bar{\sigma}^2 + (\alpha + \beta)^{h-1} (\sigma_{t+1}^2 - \bar{\sigma}^2)$$

- ▶ h : orizontul, în zile; pentru $h = 1$ formula dă σ_{t+1}^2 ; pentru h mare tinde spre $\bar{\sigma}^2$
- **Varianța pe o perioadă de deținere de H zile:** suma prognozelor zilnice (randamente necorelate)

$$\sum_{h=1}^H E_t[\sigma_{t+h}^2] = H \bar{\sigma}^2 + (\sigma_{t+1}^2 - \bar{\sigma}^2) \frac{1 - (\alpha + \beta)^H}{1 - \alpha - \beta}$$

- ▶ al doilea termen este o sumă geometrică: $\sum_{h=1}^H q^{h-1} = (1 - q^H)/(1 - q)$, cu $q = \alpha + \beta$
- ▶ volatilitatea pe H zile este rădăcina pătrată a acestei sume

Noțiuni necesare azi (7/17): riscul pe mai multe zile și regula rădăcinii pătrate a timpului



- **Regula rădăcinii pătrate a timpului:** $\sigma_{t:t+H} = \sqrt{H} \sigma$
 - ▶ exactă doar dacă varianța zilnică rămîne aceeași în cele H zile
- Două versiuni simple, ambele greșite sub GARCH
 - ▶ $\sqrt{H} \sigma_{t+1}$: presupune că nivelul de azi durează H zile
 - ▶ $\sqrt{H} \bar{\sigma}$: presupune că varianța este deja la nivelul ei pe termen lung
- GARCH: rădăcina pătrată a sumei prognozelor zilnice
 - ▶ pornește de la nivelul de azi și se apropie de dreapta pe termen lung
 - ▶ graficul folosește parametri ilustrativi ($\omega = 0,05$, $\alpha = 0,10$, $\beta = 0,85$)

Noțiuni necesare azi (8/17): valoarea expusă la risc și cuantila inovației

- **VaR 1%** (value at risk, valoarea expusă la risc, [Capitolul 6](#)): pierderea depășită doar în 1% dintre zile

$$\text{VaR}_{t+1} = -(\mu + \sigma_{t+1} q_{0,01}(z))$$

- ▶ $q_{0,01}(z)$: cuantila de 1% a inovației z , adică $P(z \leq q_{0,01}) = 0,01$; este negativă, deci VaR este o pierdere pozitivă, în %
- ▶ VaR pe H zile: înlocuim σ_{t+1} cu volatilitatea pe H zile (slide-urile anterioare) și μ cu $H\mu$

- Inovații **Normale**: $q_{0,01} = -2,326$


- Inovații **Student-t standardizate**, cu $\nu > 2$ grade de libertate [Bollerslev \(1987\)](#)

- ▶ o variabilă Student-t t_ν are varianța $\nu/(\nu - 2)$; împărțind la abaterea ei standard obținem varianța 1:

$$z = t_\nu \sqrt{\frac{\nu - 2}{\nu}} \Rightarrow q_{0,01}(z) = t_\nu^{-1}(0,01) \sqrt{\frac{\nu - 2}{\nu}}$$

- ▶ $t_\nu^{-1}(0,01)$: cuantila de 1% a distribuției Student-t cu ν grade de libertate (din tabele sau din software)
- ▶ un ν mic: cozi groase; $\nu \rightarrow \infty$: distribuția Normală

Noțiuni necesare azi (9/17): inovații Normale și Student-t



- Ambele densități au varianța 1; distribuția Student-t are mai multă masă în centru și în cozi
- Cuantila ei de 1% este mai la stînga: cu același σ_{t+1} , VaR 1% este mai mare

Noțiuni necesare azi (10/17): verosimilitatea maximă


Log-verosimilitatea Normală condiționată

$$\ell(\theta) = \sum_{t=2}^T \ell_t, \quad \ell_t = -\frac{1}{2} \left[\ln(2\pi) + \ln \sigma_t^2 + \frac{(r_t - \mu)^2}{\sigma_t^2} \right]$$

- ▶ ℓ_t : logaritmul densității Normale a lui r_t , cu media μ și varianța σ_t^2 ; T : numărul de randamente
- ▶ $\theta = (\mu, \omega, \alpha, \beta)$: parametrii; σ_t^2 se calculează recursiv din θ
- ▶ o zi cu $(r_t - \mu)^2$ mare când σ_t^2 este mică scade mult ℓ_t

MLE (maximum likelihood estimator, estimatorul de verosimilitate maximă) $\hat{\theta}$: valoarea lui θ care maximizează $\ell(\theta)$

- ▶ găsit numeric, cu $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \beta < 1$
- ▶ graficul: cu cît sînt mai multe date, cu atît vîrfurile sînt mai ascuțite, deci $\hat{\alpha}$ este mai precis



Noțiuni necesare azi (11/17): erori standard și inovații cu cozi groase

□ Erorile standard (SE) ale lui $\hat{\theta}$

- ▶ clasice: din curbura lui ℓ în punctul de maxim (un vîrf ascuțit dă SE mici)
- ▶ robuste [Bollerslev & Wooldridge \(1992\)](#): valide și cînd z_t nu este Normal; pachetul `arch` le raportează pe acestea

□ Statistica t a unui parametru

$$t = \frac{\hat{\theta}_j}{\text{SE}(\hat{\theta}_j)}$$

- ▶ $H_0: \theta_j = 0$; aproximativ Normală standard sub H_0 ; $|t| > 1,96$: semnificativ la 5%

□ GARCH-t: aceeași ecuație a varianței, cu inovații Student-t standardizate [Bollerslev \(1987\)](#)

- ▶ ℓ_t folosește densitatea Student-t în locul celei Normale; ν se estimează împreună cu ceilalți parametri
- ▶ t asimetrică [Hansen \(1994\)](#): încă un parametru, pentru inovații asimetrice

Noțiuni necesare azi (12/17): compararea modelelor: testul LR, AIC și BIC

- Testul **LR** (likelihood ratio, raportul de verosimilitate): un model mai mare 1 față de un model mai mic 0, inclus în el

$$\text{LR} = 2(\ell_1 - \ell_0) \sim \chi^2(r) \text{ sub } H_0$$

- ▶ ℓ_1, ℓ_0 : log-verosimilitățile maxime; r : numărul de restricții (de exemplu $\gamma = 0$: $r = 1$)
- ▶ H_0 : restricțiile sînt adevărate (modelul mai mic este suficient); respingem la 5% dacă $\text{LR} > \chi^2_{0,95}(r)$; $\chi^2_{0,95}(1) = 3,84$

- **Criteriile informaționale Akaike (1974), Schwarz (1978)**: potrivirea penalizată cu numărul de parametri k

$$\text{AIC} = -2\ell(\hat{\theta}) + 2k, \quad \text{BIC} = -2\ell(\hat{\theta}) + k \ln T$$

- ▶ se preferă modelul cu valoarea **mai mică**; BIC penalizează mai mult parametrii suplimentari ($\ln T > 2$ pentru $T > 7$)
- ▶ $\Delta\text{BIC} = \text{BIC}_1 - \text{BIC}_0 > 0$: parametrul suplimentar nu se justifică

Noțiuni necesare azi (13/17): asimetria: GJR-GARCH și EGARCH


- ▣ **Efectul de levier** Christie (1982): scăderile cresc volatilitatea mai mult decât creșterile de aceeași mărime
- ▣ **GJR-GARCH** Glosten, Jagannathan & Runkle (1993)

$$\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2, \quad I_{t-1} = \begin{cases} 1 & \varepsilon_{t-1} < 0 \\ 0 & \varepsilon_{t-1} \geq 0 \end{cases}$$

- ▶ γ : reacția suplimentară la știrile proaste; $\gamma > 0$: efect de levier
- ▶ persistența $\alpha + \beta + \gamma/2$ pentru z_t simetric (un șoc negativ apare în jumătate din cazuri)
- ▣ **EGARCH** Nelson (1991): un model pentru $\ln \sigma_t^2$

$$\ln \sigma_t^2 = \omega + \alpha (|z_{t-1}| - E|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$$
 - ▶ $z_{t-1} = \varepsilon_{t-1}/\sigma_{t-1}$: șocul standardizat de ieri; α : efectul mărimii; γ : efectul semnului, levier dacă $\gamma < 0$
 - ▶ $E|z| = \sqrt{2/\pi} = 0,7979$ pentru z Normal; varianța $\sigma_t^2 = e^{\ln \sigma_t^2}$ este mereu pozitivă

Noțiuni necesare azi (14/17): curbele de impact al știrilor



- GARCH: symmetric parabola
- GJR: steeper for $\varepsilon_{t-1} < 0$
- EGARCH: exponential, asymmetric

□ **Curba de impact al știrilor Engle & Ng (1993):** σ_t^2 ca funcție de ε_{t-1} , cu σ_{t-1}^2 fixat

- ▶ GARCH: $\omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$, o parabolă simetrică față de 0
- ▶ GJR: coeficientul $\alpha + \gamma$ în stînga, α în dreapta
- ▶ EGARCH: exponențială în ε_{t-1} ; cu $\gamma < 0$, mai ridicată în stînga

□ Citirea graficului

- ▶ distanța pe verticală dintre cele două ramuri în $\pm x$ măsoară asimetria
- ▶ parametri ilustrativi, nu estimări

Noțiuni necesare azi (15/17): diagnosticul unui model estimat

- ▣ **Reziduurile standardizate:** inovațiile estimate

$$\hat{z}_t = \frac{r_t - \hat{\mu}}{\hat{\sigma}_t}$$

- ▶ dacă modelul este corect, $\hat{z}_t$ este aproape i.i.d., cu media 0 și varianța 1

- ▣ **Ljung-Box** $Q(10)$ **Ljung & Box (1978)** pe $\hat{z}_t^2$ (**Capitolul 8**): $Q(m) = T(T+2) \sum_{k=1}^m \hat{\rho}_k^2 / (T-k) \sim \chi^2(m)$

- ▶ $\hat{\rho}_k$: autocorelația lui $\hat{z}_t^2$ la lagul k ; dacă nu respinge: nu a rămas niciun efect ARCH

- ▣ **Testul de asimetrie (sign bias)** **Engle & Ng (1993)**: a rămas asimetrie în $\hat{z}_t^2$?

$$\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{e}_{t-1} + b_3 S_{t-1}^+ \hat{e}_{t-1} + e_t$$

- ▶ $S_{t-1}^- = 1$ dacă $\hat{e}_{t-1} < 0$, altfel 0; $S_{t-1}^+ = 1 - S_{t-1}^-$; e_t : eroarea regresiei

- ▶ testul comun pentru $b_1 = b_2 = b_3 = 0$: $TR^2 \sim \chi^2(3)$; t -ul de **semm**: statistica t a lui b_1 ; o respingere: lipsește asimetria

Noțiuni necesare azi (16/17): compararea prognozelor în afara eșantionului

- În afara eșantionului: prognoza h_t pentru ziua t folosește doar date pînă în ziua $t - 1$
 - ▶ parametrii se reestimează la intervale regulate (de exemplu la fiecare 250 de zile) pe toate datele disponibile atunci
 - ▶ proxy-ul varianței adevărate: r_t^2 (Capitolul 8)
- Pierderea **QLIKE** Patton (2011) în ziua t și media ei pe N zile

$$L_t = \frac{r_t^2}{h_t} + \ln h_t, \quad \bar{L} = \frac{1}{N} \sum_t L_t$$

- ▶ cu cît $\bar{L}$ este mai mică, cu atît prognozele sînt mai bune
- Testul **DM** (Diebold–Mariano) Diebold & Mariano (1995) pentru prognozele A și B


$$d_t = L_t^A - L_t^B, \quad t_{DM} = \frac{\bar{d}}{\widehat{SE}_{HAC}(\bar{d})}$$

- ▶ $\bar{d}$: diferența medie a pierderilor; HAC (heteroskedasticity and autocorrelation consistent): o eroare standard validă cînd d_t este autocorelat
- ▶ $t_{DM} < -1,96$: A este semnificativ mai bună la 5%
- ▶ diferența cumulată a pierderilor $\sum_{s \leq t} (L_s^B - L_s^A)$: crește în zilele în care A este mai bună

Noțiuni necesare azi (17/17): depășirile VaR

- **Depășire:** o zi cu $r_t < -\text{VaR}_t$; indicatorul $I_t = 1\{r_t < -\text{VaR}_t\}$ (1 dacă este adevărat, 0 altfel)
- Pe N zile, un VaR 1% corect are circa $0,01 N$ depășiri; rata depășirilor $\frac{1}{N} \sum_t I_t$ trebuie să fie apropiată de 1%; testele formale, în [Capitolul 10](#)

Simulated returns with heavy-tailed innovations; VaR computed with a Normal quantile



- Randamente simulate cu cozi groase și un VaR Normal: pierderile dincolo de VaR apar mai des decât în 1% din zile
- Corelația a două serii de volatilitate (folosită în C1): corelația dintre $\ln \hat{\sigma}_t$ ale celor două active, în zilele comune

A1: algebra GARCH(1,1) [Rezolvat]

Cerință

- ▣ Randamente zilnice în %: $\omega = 0,02$, $\alpha = 0,08$, $\beta = 0,90$, $\mu = 0$, 252 de zile de tranzacționare pe an.
- ▣ 1. Calculați persistența și varianța pe termen lung.
- ▣ 2. Calculați volatilitatea pe termen lung anualizată.
- ▣ 3. Calculați timpul de înjumătățire al unui șoc de varianță.
- ▣ 4. Azi $\sigma_t^2 = 1,5$ și $r_t = -3\%$; calculați σ_{t+1}^2 și σ_{t+1} .
- ▣ Raportați: patru valori și o frază.

Rezolvare

- ▣ 1. $\alpha + \beta = 0,98$; $\bar{\sigma}^2 = 0,02/(1 - 0,98) = 1,000$
- ▣ 2. $\sqrt{252 \times 1,000} = 15,87\%$ pe an
- ▣ 3. $\ln 0,5 / \ln 0,98 = -0,69315 / (-0,02020) = 34,3$ zile
- ▣ 4. $0,02 + 0,08 \times 9 + 0,90 \times 1,5 = 2,090$; $\sigma_{t+1} = 1,446\%$
- ▣ O scădere de 3% crește varianța cu 39%; jumătate din excesul de varianță dispăre după 34,3 zile de tranzacționare, circa 7 săptămîni.

A2: o piață mai reactivă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $\omega = 0,05$, $\alpha = 0,12$, $\beta = 0,85$, $\mu = 0$; azi $\sigma_t^2 = 2,0$ și $r_t = +1,5\%$. Model: A1.
- ▣ 1. Calculați persistența, varianța pe termen lung și volatilitatea pe termen lung anualizată.
- ▣ 2. Calculați timpul de înjumătățire.
- ▣ 3. Calculați σ_{t+1}^2 .
- ▣ 4. Scrieți EWMA cu $\lambda = 0,94$ ca un GARCH(1,1) și precizați care dintre mărimile de la 1–2 există pentru el.
- ▣ Raportați: patru valori și două fraze.

A3: prognoze și VaR 1% [Rezolvat]

Cerință

- ▣ Modelul din A1, cu $\sigma_{t+1}^2 = 2,090$ și inovații Normale.
- ▣ 1. Calculați $E_t[\sigma_{t+5}^2]$ și $E_t[\sigma_{t+10}^2]$.
- ▣ 2. Calculați varianța și volatilitatea pe 10 zile.
- ▣ 3. Comparați cu regula rădăcinii pătrate a timpului, $\sqrt{10}\sigma_{t+1}$, și cu $\sqrt{10}\bar{\sigma}^2$.
- ▣ 4. Calculați VaR 1% pe o zi și pe 10 zile.
- ▣ Raportați: șase valori și o frază.

Rezolvare

- ▣ 1. $1 + 0,98^4(2,090 - 1) = 1 + 0,9224 \times 1,09 = 2,005$;
 $1 + 0,98^9 \times 1,09 = 1,909$
- ▣ 2. $10 \times 1 + 1,09 \times (1 - 0,98^{10})/0,02 =$
 $10 + 1,09 \times 9,146 = 19,97$; volatilitatea 4,47%
- ▣ 3. $\sqrt{10 \times 2,090} = 4,57\%$ (prea mare),
 $\sqrt{10 \bar{\sigma}^2} = \sqrt{10 \times 1} = 3,16\%$ (prea mică)
- ▣ 4. $2,326 \times 1,446 = 3,36\%$; $2,326 \times 4,47 = 10,40\%$
- ▣ Varianța ridicată scade lent: riscul pe 10 zile este între cele două reguli simple, mai aproape de prima.

A4: prognoze cu inovații Student-t [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Modelul din A2, cu $\sigma_{t+1}^2 = 2,020$ și inovații Student-t standardizate cu $\nu = 5$ ($t_5^{-1}(0,01) = -3,365$). Model: A3.
- ▣ 1. Calculați $E_t[\sigma_{t+10}^2]$ și varianța pe 10 zile.
- ▣ 2. Calculați cuantila $q_{0,01}$ a distribuției t standardizate.
- ▣ 3. Calculați VaR 1% pe o zi și pe 10 zile, cu inovații t și cu inovații Normale.
- ▣ Raportați: șase valori și o frază.

A5: verosimilitatea ARCH(1), pas cu pas [Rezolvat]

Cerință

- ▣ ARCH(1) cu $\omega = 0,5$, $\alpha = 0,5$, $\mu = 0$, z_t Normale; observat: $r_1, \dots, r_4 = 0,5; -1,2; 2,0; -0,3$.
- ▣ 1. Calculați σ_2^2 , σ_3^2 și σ_4^2 .
- ▣ 2. Calculați ℓ_2 , ℓ_3 , ℓ_4 și log-verosimilitatea condiționată.
- ▣ 3. Calculați varianța necondiționată și coeficientul de boltire pentru acest ARCH(1).
- ▣ Raportați: șapte valori și o frază.

Rezolvare

- ▣ 1. $0,5 + 0,5 \times 0,25 = 0,625$; $0,5 + 0,5 \times 1,44 = 1,220$;
 $0,5 + 0,5 \times 4 = 2,500$
- ▣ 2. $\ell_2 = -\frac{1}{2}[1,8379 + \ln 0,625 + 1,44/0,625] = -1,836$;
 $\ell_3 = -2,658$; $\ell_4 = -1,395$; suma $-5,889$
- ▣ 3. $0,5/(1 - 0,5) = 1,0$; $K = 3 \times 0,75/0,25 = 9,0$
- ▣ Ziua 3 ($r_3 = 2$ după o zi liniștită) contribuie cel mai puțin: un randament mare cînd σ_t^2 este mic este puțin probabil.

A6: știri bune și știri proaste [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ GJR-GARCH: $\omega = 0,02$, $\alpha = 0,03$, $\gamma = 0,12$, $\beta = 0,90$; EGARCH: $\omega = 0$, $\alpha = 0,12$, $\gamma = -0,08$, $\beta = 0,98$; în ambele $\sigma_t^2 = 1$, $\mu = 0$. Model: A1.
- ▣ 1. Calculați σ_{t+1}^2 GJR după $\varepsilon_t = -2$ și după $\varepsilon_t = +2$, precum și raportul lor.
- ▣ 2. Calculați persistența și timpul de înjumătățire GJR.
- ▣ 3. Calculați σ_{t+1}^2 EGARCH pentru aceleași două șocuri (folosiți $E|z| = 0,7979$).
- ▣ Raportați: șase valori și o frază.

B1: GARCH(1,1)-t pentru DAX [Rezolvat]

- ▣ **Întrebarea:** cât de persistentă este volatilitatea DAX și cât de departe este DAX azi de volatilitatea lui pe termen lung?
- ▣ **Date:** închiderile DAX din 2000, randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GARCH(1,1) cu inovații Student-t și raportați parametrii cu erorile standard robuste.
 2. Calculați persistența, timpul de înjumătățire și volatilitatea pe termen lung anualizată și comparați-o cu volatilitatea de selecție.
 3. Raportați vîrfurile volatilității condiționate anualizate din 2008 și din 2020, precum și valoarea ei în ultima zi.
 4. Desenați randamentele din 2018 cu benzile $\pm 2\hat{\sigma}_t$.
 5. Interpretare: ar trebui un manager de risc să folosească pentru ziua de mâine volatilitatea pe termen lung sau pe cea curentă?
- ▣ **Raportați:** un tabel cu cinci parametri, cinci valori, graficul și două fraze
- ▣ **Notebook:** secțiunea B1

B1: rezolvare [Rezolvat]



	μ	ω	α	β	ν
estimare	0,081	0,0206	0,097	0,895	7,08
SE robustă	0,012	0,0049	0,011	0,012	0,62

- $T = 6\,786$; $\alpha + \beta = 0,992$, timpul de înjumătățire $\ln 0,5 / (-0,00784) = 88,5$ zile; volatilitatea pe termen lung 25,9%, față de 22,4% în eșantion
- Vîrfuri: 80% (2008), 82% (2020); ultima zi: 13,0%; 5,2% dintre zile ies din banda $\pm 2\hat{\sigma}_t$
- Interpretare: pe cea curentă: VaR pentru mâine are nevoie de σ_{t+1} ; nivelul pe termen lung contează doar pentru orizonturi lungi și este imprecis, deoarece $1 - \alpha - \beta = 0,0078$ este mic


B2: BET, Banca Transilvania și Bitcoin [Propus]

- ▣ **Întrebarea:** care dintre BET, Banca Transilvania și Bitcoin are volatilitatea cea mai persistentă? Model: B1.
- ▣ **Date:** BET din 2000, TLV din 2010 (fără 30–31 mai 2016), Bitcoin din 2014; randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GARCH(1,1)-t pentru fiecare serie și raportați α , β și ν .
 2. Calculați persistența, timpul de înjumătățire și volatilitatea pe termen lung, acolo unde există.
 3. Comparați volatilitatea pe termen lung cu volatilitatea de selecție (anualizați Bitcoin cu 365 de zile).
 4. Interpretare: ce îi spune unui manager de risc o estimare $\hat{\alpha} + \hat{\beta} = 1$?
- ▣ **Raportați:** un tabel și două fraze
- ▣ **Notebook:** secțiunea B2

B3: efectul de levier la S&P 500 [Rezolvat]

- ▣ **Întrebarea:** cresc scăderile volatilitatea S&P 500 mai mult decât creșterile de aceeași mărime?
- ▣ **Date:** închiderile S&P 500 din 2000, randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GARCH(1,1)-t și GJR-GARCH(1,1)-t; raportați γ cu statistica t robustă.
 2. Calculați statistica LR pentru GJR față de GARCH, p-value-ul ei și cele două valori BIC.
 3. Aplicați testul de asimetrie (sign bias) pe reziduurile standardizate ale GARCH-t.
 4. Desenați ambele curbe de impact ale știrilor și calculați varianța GJR după șocuri de -2% și $+2\%$.
 5. Interpretare: cum schimbă efectul de levier VaR-ul din ziua de după o scădere?
- ▣ **Raportați:** patru statistici cu p-value-uri, două varianțe, graficul și două fraze
- ▣ **Notebook:** secțiunea B3

B3: rezolvare [Rezolvat]



- GJR: $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t = 10,03$), $\hat{\beta} = 0,881$; LR = 235,7 ($p < 0,001$); BIC 18169,0 $\rightarrow$ 17942,2
- Testul de asimetrie pe reziduurile GARCH-t: $\chi^2(3) = 40,7$ ($p < 0,001$), t al semnului = 3,56
- Varianța GJR după -2% : 2,136; după $+2\%$: 1,315; raportul 1,62
- Interpretare: doar scăderile cresc varianța ($\hat{\alpha} = 0$); după o scădere, VaR este de circa $\sqrt{1,62}$ ori VaR-ul de după o creștere egală; un GARCH simetric subestimează riscul după zilele proaste


B4: asimetria la BVB și la Bitcoin [Propus]

- ▣ **Întrebarea:** există un efect de levier la BET, la Banca Transilvania și la Bitcoin? Model: B3.
- ▣ **Date:** BET din 2000, TLV din 2010, Bitcoin din 2014; randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GJR-GARCH(1,1)- t și EGARCH(1,1)- t ; raportați ambele valori γ , cu statisticile t robuste.
 2. Calculați testul LR pentru GJR față de GARCH și modificarea BIC.
 3. Calculați raportul GJR dintre varianțele de după -2% și $+2\%$.
 4. Interpretare: ați folosi un model asimetric pentru fiecare dintre cele trei serii? De ce?
- ▣ **Raportați:** un tabel și două fraze
- ▣ Notebook: secțiunea B4

B5: GARCH față de EWMA pentru S&P 500 [Rezolvat]

- **Întrebarea:** prognozează GARCH(1,1)-t varianța de mâine a S&P 500 mai bine decât EWMA și este VaR 1% al lui depășit în 1% dintre zile?
- **Date:** S&P 500 din 2000; prognoze pentru fiecare zi de la 2 ianuarie 2015
- **Cerințe**
 1. Reestimați GARCH(1,1)-t la fiecare 250 de zile pe toate datele pînă în acea zi și calculați prognozele pe o zi h_t ; calculați EWMA cu $\lambda = 0,94$.
 2. Calculați media QLIKE pentru ambele modele și statistica t Diebold–Mariano.
 3. Numărați depășirile VaR 1% GARCH-t și VaR 1% EWMA-Normal și comparați-le cu numărul așteptat.
 4. Desenați diferența cumulată a pierderilor.
 5. Interpretare: ce model i-ați da unui manager de risc și ce ați mai corecta?
- **Raportați:** patru valori, două numere de depășiri, graficul și două fraze
- **Notebook:** secțiunea B5

B5: rezolvare [Rezolvat]



- 2944 de zile; media QLIKE: GARCH-t 0,761, EWMA 0,819; DM: diferența medie $-0,058$, $t = -3,69$ ($p < 0,001$): GARCH-t este mai bun
- Depășiri VaR 1%: GARCH-t 49 (1,66%), EWMA-Normal 65 (2,21%); așteptat circa 29
- Interpretare: GARCH-t, dar ambele modele VaR sînt depășite prea des; adăugăm efectul de levier (B3) și testăm formal depășirile (Capitolul 10)

B6: GARCH față de EWMA pentru DAX și BET [Propus]

- **Întrebarea:** se păstrează rezultatul din B5 pentru DAX și pentru BET? Model: B5.
- **Date:** DAX și BET din 2000; prognoze pentru fiecare zi începînd din ianuarie 2015
- **Cerințe**
 1. Calculați prognozele GARCH(1,1)-t și EWMA în afara eșantionului, ca în B5.
 2. Calculați media QLIKE pentru ambele modele și testul DM.
 3. Numărați depășirile VaR 1% pentru ambele modele.
 4. Interpretare: pentru care indice ajută cel mai mult GARCH și de ce?
- **Raportați:** un tabel și două fraze
- **Notebook:** secțiunea B6

C1: apropierea volatilității Bitcoin de cea a acțiunilor [Propus]

- ▣ **Întrebarea:** s-a apropiat volatilitatea Bitcoin de volatilitatea S&P 500 după 2021?
- ▣ **Date:** randamentele logaritmice zilnice Bitcoin și S&P 500, 2015–2019 și 2021–2026; modele: B1, B3
- ▣ **Cerințe**
 1. Estimați GJR-GARCH(1,1)-t pentru ambele serii, în ambele perioade, și raportați persistența, γ și ν .
 2. Calculați corelația logaritmilor celor două volatilități GARCH-t în zilele comune, în fiecare perioadă.
 3. Enumerați evenimentele din 2020–2024 care ar putea explica o schimbare.
 4. Interpretare: cum ați deosebi o schimbare durabilă de o schimbare produsă de o singură criză?
- ▣ **Raportați:** un tabel și un plan de proiect
- ▣ **Notebook:** secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI să interpreteze un GARCH(1,1)-t estimat pentru S&P 500 (date zilnice, din 2000): $\hat{\omega} = 0,0157$, $\hat{\alpha} = 0,123$, $\hat{\beta} = 0,872$, $\hat{\nu} = 6,26$. Răspunsul:
 - (a) $\alpha + \beta = 0,995$, deci un șoc de volatilitate dispare în aproximativ o săptămână.
 - (b) Varianța pe termen lung este $\omega/(1 - \alpha) = 0,018$, o volatilitate anuală de 2,1%.
 - (c) Un GJR estimat dă $\gamma = 0,205 > 0$: știrile bune cresc volatilitatea mai mult decât știrile proaste.
 - (d) Ljung-Box Q(10) al pătratelor reziduurilor standardizate = 13,6, $p = 0,19$: modelul GARCH-t este corect.
 - (e) Cu inovații Student-t, VaR 1% pe o zi este de 2,326 ori $\sigma(t+1)$.
 - (f) EWMA cu $\lambda = 0,94$ este un GARCH(1,1) cu $\omega = 0$, $\alpha = 0,06$, $\beta = 0,94$.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook (secțiunea C2).
 - ▶ 2. Raportați: o listă de șase verdicte, fiecare cu un rând de justificare.

Idei de reținut

- ▣ $\alpha + \beta$ decide tot ce ține de termenul lung: timpul de înjumătățire, varianța pe termen lung, forma prognozelor
- ▣ Riscul pe mai multe zile este suma prognozelor zilnice ale varianței, nu $\sqrt{H}$ ori volatilitatea de azi
- ▣ Inovațiile cu cozi groase schimbă cuantila VaR; asimetria schimbă VaR-ul după zilele proaste
- ▣ Comparăm prognozele în afara eșantionului (QLIKE, DM), nu doar în eșantion (AIC, BIC)
- ▣ Un răspuns AI este doar o primă versiune: verificați formula varianței pe termen lung, semnul lui γ și cuantila

După seminar

- ▣ Cursul 9 dezvoltă fiecare temă de azi: ARCH și GARCH, estimarea, inovațiile, asimetria, diagnosticul, prognozele, VaR
- ▣ Încercați cerințele [Propus] în notebook; rezolvările se discută la seminar
- ▣ C1 poate deveni un proiect de echipă: ferestre mobile, Ethereum și aurul ca termeni de comparație
- ▣ Lectură: [Franke, Härdle & Hafner \(2019\)](#), cap. 13; exerciții în [Borak, Härdle & López-Cabrera \(2013\)](#), cap. 13; [Tsay \(2010\)](#), cap. 3

Bibliografie (1/2)

- ▣ Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723.
- ▣ Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- ▣ Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, 69(3), 542–547.
- ▣ Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- ▣ Borak, S., Härdle, W.K., López-Cabrera, B. (2013). *Statistics of Financial Markets: Exercises and Solutions*, 2nd ed. Springer.
- ▣ Christie, A.A. (1982). The stochastic behavior of common stock variances: value, leverage and interest rate effects. *Journal of Financial Economics*, 10(4), 407–432.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- ▣ Engle, R.F., Ng, V.K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778.

Bibliografie (2/2)

- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- ▣ Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- ▣ Ljung, G.M., Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- ▣ Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, 59(2), 347–370.
- ▣ Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- ▣ Schwarz, G. (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2), 461–464.
- ▣ Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed. Wiley.