








# Statistica piețelor financiare

## Seminarul 9: Modele ARCH și GARCH



Daniel Traian PELE

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

# Acronime folosite în acest material (1/2)

- **AI**: Artificial Intelligence (inteligență artificială)
- **AIC**: Akaike Information Criterion (criteriul informațional Akaike)
- **ARCH**: AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- **BIC**: Bayesian Information Criterion (criteriul informațional bayesian)
- **BVB**: Bursa de Valori București
- **COVID-19**: COronaVIrus Disease 2019 (boala provocată de noul coronavirus, identificată în 2019)
- **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- **EGARCH**: Exponential GARCH (GARCH exponențial)
- **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- **ETF**: Exchange-Traded Fund (fond tranzacționat la bursă)

# Acronime folosite în acest material (2/2)

- **EWMA**: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- **GJR**: Glosten–Jagannathan–Runkle (asymmetric GARCH) — modelul GARCH asimetric Glosten–Jagannathan–Runkle
- **GJR-GARCH**: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- **IGARCH**: Integrated GARCH (GARCH integrat)
- **LR**: Likelihood Ratio (test) — testul raportului de verosimilitate
- **MLE**: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- **QLIKE**: Quasi-LIKElihood (loss function) — funcția de pierdere de tip cvasi-verosimilitate
- **SE**: Standard Error (eroare standard)

# Întrebarea de azi și structura seminarului

- Întrebarea seminarului
  - **cum modelăm, estimăm și prognozăm o volatilitate care se schimbă în fiecare zi?**
- Rezultate de obținut
  - răspunsurile la exercițiile A
  - tabelul sau figura cerute la fiecare exercițiu B
  - un răspuns scurt și argumentat la C1; erorile găsite în răspunsul AI din C2 și răspunsul corectat
  - frazele de interpretare cerute la fiecare exercițiu
- Seminarul are rol de exercițiu și nu se notează; rezolvările exercițiilor [Propus] se discută la seminar
- Notebook-ul de azi: deschideți notebook-ul seminarului în Google Colab
  - fiecare cerință indică secțiunea din notebook
- Exercițiile, tipurile și ordinea lor: harta exercițiilor (slide-ul următor)
- Contact: prof. Daniel Traian Pele, danpele@ase.ro

# Harta exercițiilor

| Cerința | Întrebarea | Tipul | Model |
|---|---|---|---|
| A1, A2 | persistența, varianța pe termen lung, timpul de înjumătățire și un pas GARCH(1,1) | Rezolvat, Propus | A1 |
| A3, A4 | prognoze pe mai mulți pași, volatilitatea pe 10 zile și VaR 1% | Rezolvat, Propus | A3 |
| A5, A6 | verosimilitatea și boltirea ARCH(1); impactul știrilor în GJR-GARCH și EGARCH | Rezolvat, Propus | A5 |
| B1, B2 | estimări GARCH(1,1)-t: DAX; BET, Banca Transilvania, Bitcoin | Rezolvat, Propus | B1 |
| B3, B4 | asimetria și efectul de levier: S&P 500; BET, Bitcoin, TLV | Rezolvat, Propus | B3 |
| B5, B6 | GARCH față de EWMA în afara eșantionului, depășirile VaR 1%: S&P 500; DAX, BET | Rezolvat, Propus | B5 |
| C1, C2 | apropierea volatilității Bitcoin de cea a acțiunilor; erorile unui răspuns AI | Propus | B1, B3 |

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați după model; soluția se discută la seminar
- A: calcule pe hîrtie; B: date reale, în notebook, fiecare încheiat cu o întrebare de interpretare; C: întrebări deschise, printre care verificarea unui răspuns AI

# Datele folosite

| Seria | Sursa | Prețul folosit | Perioada |
|---|---|---|---|
| S&P 500, DAX, BET | EODHD | închidere | 2000–2026 |
| Bitcoin | EODHD | închidere, 7 zile pe săptămînă | 2014–2026 |
| Banca Transilvania (TLV) | EODHD | închidere ajustată | 2010–2026 |

- Randamente logaritmice zilnice în %: $r_t = 100\,(\ln P_t - \ln P_{t-1})$; weekendurile și închiderile repetate din zilele libere se elimină (cu excepția Bitcoin); ultima zi este 18 septembrie 2026
- TLV: zilele de 30 și 31 mai 2016 se elimină (o ajustare de preț aplicată cu o zi mai tîrziu, Capitolul 2)
- În notebook: `returns('dax')`, `fit(r, dist='t')` (pachetul `arch`); nu este nevoie de cont sau de cheie

# Noțiuni necesare azi (1/17): media și varianța condiționată

- **Modelul randamentului**: o medie constantă plus un șoc a cărui mărime se schimbă în timp

$$r_t = \mu + \varepsilon_t, \qquad \varepsilon_t = \sigma_t z_t$$

  - $r_t$: randamentul logaritmic zilnic, în %; $\mu$: media lui; $\varepsilon_t$: **șocul** (partea neașteptată a randamentului)
  - $z_t$: **inovațiile**, i.i.d. (independente și identic distribuite), cu media 0 și varianța 1
- **Varianța condiționată**: varianța randamentului de mîine, dat fiind tot ce se știe azi

$$\sigma_t^2 = \mathrm{Var}(r_t \mid \text{informația pînă în ziua } t-1)$$

  - $\sigma_t^2$ este cunoscută cu o zi înainte: este prognoza varianței pentru ziua $t$
  - **varianța necondiționată** $\mathrm{Var}(r_t)$ este media pe termen lung a lui $\sigma_t^2$
  - șocurile sînt necorelate, dar pătratele lor sînt corelate: volatility clustering (Capitolul 8)

# Noțiuni necesare azi (2/17): modelul ARCH(1)

- **ARCH(1)** Engle (1982) (autoregressive conditional heteroskedasticity, heteroscedasticitate condiționată autoregresivă)

$$\sigma_t^2 = \omega + \alpha\, \varepsilon_{t-1}^2, \qquad \omega > 0, \quad 0 \leq \alpha < 1$$

  - în cuvinte: varianța de azi este o constantă $\omega$ plus o fracțiune $\alpha$ din pătratul șocului de ieri
  - $\alpha$: reacția la știrile de ieri; $\alpha = 0$ dă o varianță constantă $\omega$

- **Varianța necondiționată**: aplicăm media, cu $E(\varepsilon_t^2) = E(\varepsilon_{t-1}^2) = \sigma^2$

$$\sigma^2 = \omega + \alpha\sigma^2 \quad \Rightarrow \quad \sigma^2 = \frac{\omega}{1-\alpha}$$

- **Coeficientul de boltire** $K = E(\varepsilon_t^4)/\sigma^4$, cu $z_t$ Normale și $3\alpha^2 < 1$

$$K = \frac{3\,(1-\alpha^2)}{1-3\alpha^2} > 3$$

  - $K = 3$ pentru distribuția Normală: ARCH produce cozi groase chiar cu inovații Normale

# Noțiuni necesare azi (3/17): modelul GARCH(1,1)

- **GARCH(1,1)** Bollerslev (1986): ARCH plus varianța de ieri

$$\sigma_t^2 = \omega + \alpha\,\varepsilon_{t-1}^2 + \beta\,\sigma_{t-1}^2, \qquad \omega > 0, \quad \alpha, \beta \geq 0$$

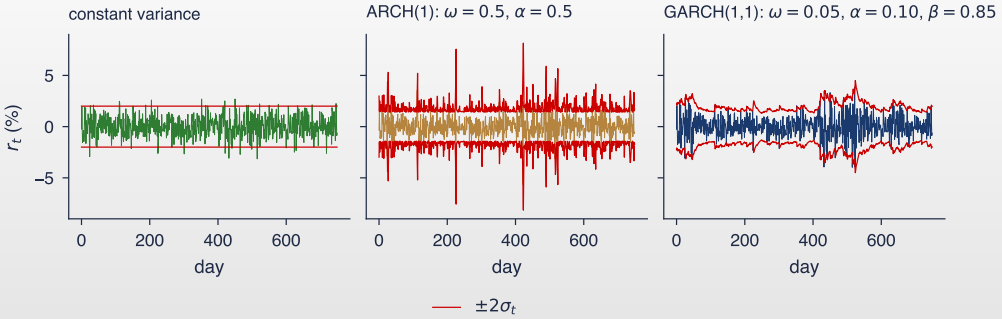
  - $\omega$: o constantă care fixează nivelul pe termen lung al varianței
  - $\alpha$: reacția la știri (pătratul șocului de ieri); un $\alpha$ mare: o volatilitate cu salturi
  - $\beta$: memoria (ponderea varianței de ieri); un $\beta$ mare: o volatilitate netedă, care se schimbă lent
  - $\alpha + \beta < 1$: modelul este staționar (în covarianță), cu o varianță necondiționată finită

- **EWMA** (Capitolul 8) drept caz particular

$$\sigma_t^2 = \lambda\,\sigma_{t-1}^2 + (1-\lambda)\,r_{t-1}^2$$

  - un GARCH(1,1) cu $\mu = 0$, $\omega = 0$, $\alpha = 1 - \lambda$, $\beta = \lambda$, deci $\alpha + \beta = 1$: un **IGARCH** (integrated GARCH, GARCH integrat)

# Noțiuni necesare azi (4/17): varianța constantă, ARCH și GARCH în simulare




- Aceleași inovații $z_t$ în cele trei panouri; liniile roșii sînt $\pm 2\sigma_t$
- ARCH(1): varianța sare după fiecare șoc mare și revine a doua zi; GARCH(1,1): varianța evoluează în valuri lungi și netede
- Pentru un model corect, circa 95% dintre randamente se află în intervalul $\pm 2\sigma_t$ (inovații Normale)

SFM_ch9_seminar

# Noțiuni necesare azi (5/17): persistența, varianța pe termen lung și timpul de înjumătățire

- **Persistența $\alpha+\beta$ și varianța pe termen lung**

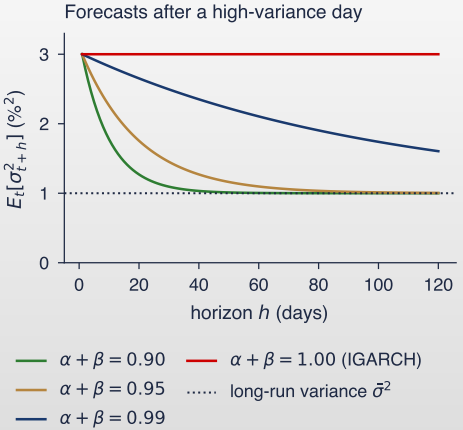
$$\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}, \qquad \sigma_{\text{an}} = \sqrt{252\,\bar{\sigma}^2}$$

  - $\bar{\sigma}^2$: nivelul spre care revine varianța (revenirea la medie)
  - cînd $\alpha+\beta$ este aproape de 1, $\bar{\sigma}^2$ este foarte imprecisă: o mică eroare în $1-\alpha-\beta$ o schimbă mult

- În fiecare zi, abaterea față de $\bar{\sigma}^2$ se reduce cu factorul $\alpha+\beta$

$$h_{1/2} = \frac{\ln 0{,}5}{\ln(\alpha+\beta)}$$

  - $h_{1/2}$: **timpul de înjumătățire**, numărul de zile după care a dispărut jumătate dintr-un șoc de varianță
  - IGARCH ($\alpha+\beta=1$): nu există varianță pe termen lung și nici timp de înjumătățire; șocurile nu se atenuează



# Noțiuni necesare azi (6/17): prognozele variației

- Prognoze făcute la sfîrșitul zilei $t$; $E_t$: media condiționată de datele pînă în ziua $t$
- **O zi înainte**: cunoscută exact din datele de azi

$$\sigma^2_{t+1} = \omega + \alpha\,(r_t - \mu)^2 + \beta\,\sigma^2_t$$

- **Cu $h$ zile înainte**: abaterea față de $\bar\sigma^2$ scade geometric

$$E_t[\sigma^2_{t+h}] = \bar\sigma^2 + (\alpha+\beta)^{h-1}\,(\sigma^2_{t+1} - \bar\sigma^2)$$

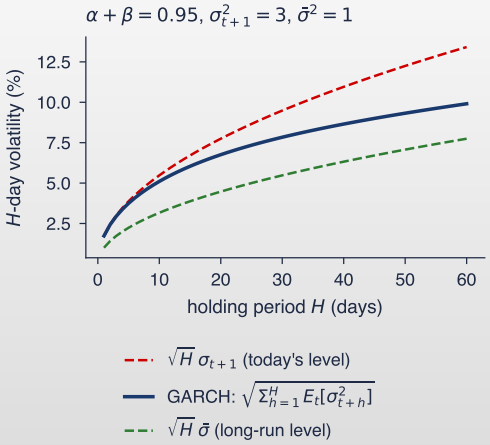
  - $h$: orizontul, în zile; pentru $h = 1$ formula dă $\sigma^2_{t+1}$; pentru $h$ mare tinde spre $\bar\sigma^2$

- **Varianța pe o perioadă de deținere de $H$ zile**: suma prognozelor zilnice (randamente necorelate)

$$\sum_{h=1}^{H} E_t[\sigma^2_{t+h}] = H\,\bar\sigma^2 + (\sigma^2_{t+1} - \bar\sigma^2)\,\frac{1-(\alpha+\beta)^H}{1-\alpha-\beta}$$

  - al doilea termen este o sumă geometrică: $\sum_{h=1}^{H} q^{h-1} = (1-q^H)/(1-q)$, cu $q = \alpha+\beta$
  - volatilitatea pe $H$ zile este rădăcina pătrată a acestei sume

# Noțiuni necesare azi (7/17): riscul pe mai multe zile și regula rădăcinii pătrate a timpului




- **Regula rădăcinii pătrate a timpului**: $\sigma_{t:t+H} = \sqrt{H}\,\sigma$
  - exactă doar dacă varianța zilnică rămîne aceeași în cele $H$ zile
- Două versiuni simple, ambele greșite sub GARCH
  - $\sqrt{H}\,\sigma_{t+1}$: presupune că nivelul de azi durează $H$ zile
  - $\sqrt{H}\,\bar{\sigma}$: presupune că varianța este deja la nivelul ei pe termen lung
- GARCH: rădăcina pătrată a sumei prognozelor zilnice
  - pornește de la nivelul de azi și se apropie de dreapta pe termen lung
  - graficul folosește parametri ilustrativi ($\omega = 0{,}05$, $\alpha = 0{,}10$, $\beta = 0{,}85$)

# Noțiuni necesare azi (8/17): valoarea expusă la risc și cuantila inovației

- **VaR 1%** (value at risk, valoarea expusă la risc, Capitolul 6): pierderea depășită doar în 1% dintre zile

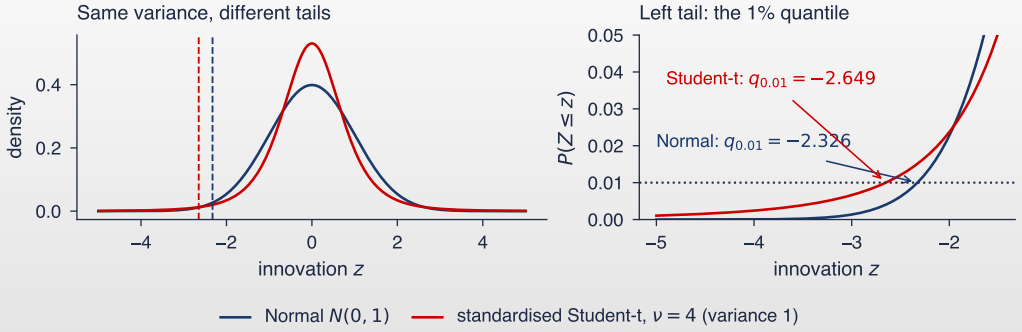
$$\mathrm{VaR}_{t+\mathbf{1}} = -\left(\mu + \sigma_{t+\mathbf{1}}\, q_{\mathbf{0,01}}(z)\right)$$

  - $q_{\mathbf{0,01}}(z)$: cuantila de 1% a inovației $z$, adică $P(z \leq q_{\mathbf{0,01}}) = 0{,}01$; este negativă, deci VaR este o pierdere pozitivă, în %
  - VaR pe $H$ zile: înlocuim $\sigma_{t+\mathbf{1}}$ cu volatilitatea pe $H$ zile (slide-urile anterioare) și $\mu$ cu $H\mu$
- Inovații **Normale**: $q_{\mathbf{0,01}} = -2{,}326$
- Inovații **Student-t standardizate**, cu $\nu > 2$ grade de libertate Bollerslev (1987)
  - o variabilă Student-t $t_\nu$ are varianța $\nu/(\nu-2)$; împărțind la abaterea ei standard obținem varianța 1:

$$z = t_\nu \sqrt{\frac{\nu-2}{\nu}} \quad \Rightarrow \quad q_{\mathbf{0,01}}(z) = t_\nu^{-\mathbf{1}}(0{,}01)\sqrt{\frac{\nu-2}{\nu}}$$

  - $t_\nu^{-\mathbf{1}}(0{,}01)$: cuantila de 1% a distribuției Student-t cu $\nu$ grade de libertate (din tabele sau din software)
  - un $\nu$ mic: cozi groase; $\nu \to \infty$: distribuția Normală

# Noțiuni necesare azi (9/17): inovații Normale și Student-t




- Ambele densități au varianța 1; distribuția Student-t are mai multă masă în centru și în cozi
- Cuantila ei de 1% este mai la stînga: cu același $\sigma_{t+1}$, VaR 1% este mai mare

SFM_ch9_seminar

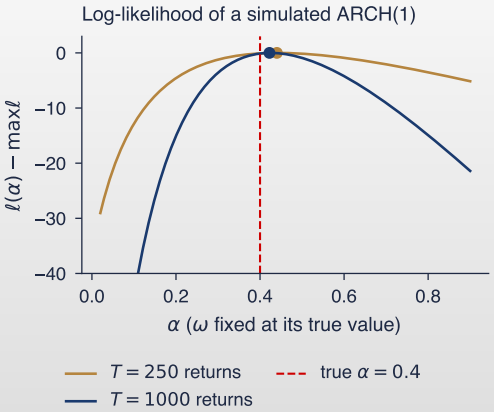
# Noțiuni necesare azi (10/17): verosimilitatea maximă

- **Log-verosimilitatea Normală condiționată**

$$\ell(\theta) = \sum_{t=2}^{T} \ell_t, \qquad \ell_t = -\frac{1}{2}\left[\ln(2\pi) + \ln \sigma_t^2 + \frac{(r_t - \mu)^2}{\sigma_t^2}\right]$$

  - $\ell_t$: logaritmul densității Normale a lui $r_t$, cu media $\mu$ și varianța $\sigma_t^2$; $T$: numărul de randamente
  - $\theta = (\mu, \omega, \alpha, \beta)$: parametrii; $\sigma_t^2$ se calculează recursiv din $\theta$
  - o zi cu $(r_t - \mu)^2$ mare cînd $\sigma_t^2$ este mică scade mult $\ell_t$

- **MLE** (maximum likelihood estimator, estimatorul de verosimilitate maximă) $\hat{\theta}$: valoarea lui $\theta$ care maximizează $\ell(\theta)$
  - găsit numeric, cu $\omega > 0$, $\alpha, \beta \geq 0$, $\alpha + \beta < 1$
  - graficul: cu cît sînt mai multe date, cu atît vîrful este mai ascuțit, deci $\hat{\alpha}$ este mai precis




SFM_ch9_seminar

# Noțiuni necesare azi (11/17): erori standard și inovații cu cozi groase

- **Erorile standard** (SE) ale lui $\hat{\theta}$
  - clasice: din curbura lui $\ell$ în punctul de maxim (un vîrf ascuțit dă SE mici)
  - robuste Bollerslev & Wooldridge (1992): valide și cînd $z_t$ nu este Normal; pachetul `arch` le raportează pe acestea
- **Statistica** $t$ a unui parametru

$$t = \frac{\hat{\theta}_j}{\mathrm{SE}(\hat{\theta}_j)}$$

  - $H_0$: $\theta_j = 0$; aproximativ Normală standard sub $H_0$; $|t| > 1{,}96$: semnificativ la 5%
- **GARCH-t**: aceeași ecuație a variației, cu inovații Student-t standardizate Bollerslev (1987)
  - $\ell_t$ folosește densitatea Student-t în locul celei Normale; $\nu$ se estimează împreună cu ceilalți parametri
  - t asimetrică Hansen (1994): încă un parametru, pentru inovații asimetrice

# Noțiuni necesare azi (12/17): compararea modelelor: testul LR, AIC și BIC

- Testul **LR** (likelihood ratio, raportul de verosimilitate): un model mai mare 1 față de un model mai mic 0, inclus în el

$$\mathrm{LR} = 2\,(\ell_{\mathbf{1}} - \ell_{\mathbf{0}}) \sim \chi^{\mathbf{2}}(r) \text{ sub } H_{\mathbf{0}}$$

  - $\ell_{\mathbf{1}}$, $\ell_{\mathbf{0}}$: log-verosimilitățile maxime; $r$: numărul de restricții (de exemplu $\gamma = 0$: $r = 1$)
  - $H_{\mathbf{0}}$: restricțiile sînt adevărate (modelul mai mic este suficient); respingem la 5% dacă $\mathrm{LR} > \chi^{\mathbf{2}}_{\mathbf{0,95}}(r)$; $\chi^{\mathbf{2}}_{\mathbf{0,95}}(1) = 3{,}84$

- **Criteriile informaționale** Akaike (1974), Schwarz (1978): potrivirea penalizată cu numărul de parametri $k$

$$\mathrm{AIC} = -2\,\ell(\hat{\theta}) + 2k, \qquad \mathrm{BIC} = -2\,\ell(\hat{\theta}) + k \ln T$$

  - se preferă modelul cu valoarea **mai mică**; BIC penalizează mai mult parametrii suplimentari ($\ln T > 2$ pentru $T > 7$)
  - $\Delta\mathrm{BIC} = \mathrm{BIC}_{\mathbf{1}} - \mathrm{BIC}_{\mathbf{0}} > 0$: parametrul suplimentar nu se justifică

# Noțiuni necesare azi (13/17): asimetria: GJR-GARCH și EGARCH

- **Efectul de levier** Christie (1982): scăderile cresc volatilitatea mai mult decît creșterile de aceeași mărime
- **GJR-GARCH** Glosten, Jagannathan & Runkle (1993)

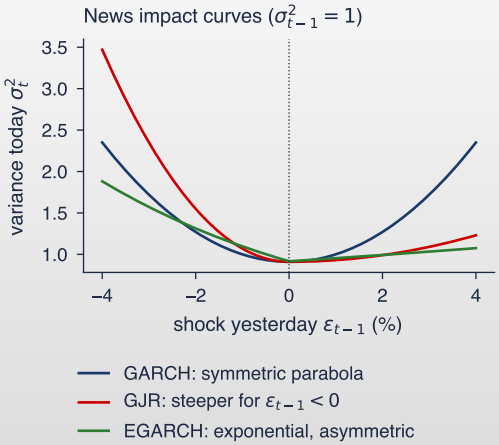
$$\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1})\,\varepsilon_{t-1}^2 + \beta\,\sigma_{t-1}^2, \qquad I_{t-1} = \begin{cases} 1 & \varepsilon_{t-1} < 0 \\ 0 & \varepsilon_{t-1} \geq 0 \end{cases}$$

  - $\gamma$: reacția suplimentară la știrile proaste; $\gamma > 0$: efect de levier
  - persistența $\alpha + \beta + \gamma/2$ pentru $z_t$ simetric (un șoc negativ apare în jumătate din cazuri)
- **EGARCH** Nelson (1991): un model pentru $\ln \sigma_t^2$

$$\ln \sigma_t^2 = \omega + \alpha\left(|z_{t-1}| - E|z_{t-1}|\right) + \gamma\, z_{t-1} + \beta\, \ln \sigma_{t-1}^2$$

  - $z_{t-1} = \varepsilon_{t-1}/\sigma_{t-1}$: șocul standardizat de ieri; $\alpha$: efectul mărimii; $\gamma$: efectul semnului, levier dacă $\gamma < 0$
  - $E|z| = \sqrt{2/\pi} = 0{,}7979$ pentru $z$ Normal; varianța $\sigma_t^2 = e^{\ln \sigma_t^2}$ este mereu pozitivă

# Noțiuni necesare azi (14/17): curbele de impact al știrilor




- **Curba de impact al știrilor** Engle & Ng (1993): $\sigma_t^2$ ca funcție de $\varepsilon_{t-1}$, cu $\sigma^2_{t-1}$ fixat
  - GARCH: $\omega + \alpha\varepsilon^2_{t-1} + \beta\sigma^2_{t-1}$, o parabolă simetrică față de 0
  - GJR: coeficientul $\alpha + \gamma$ în stînga, $\alpha$ în dreapta
  - EGARCH: exponențială în $\varepsilon_{t-1}$; cu $\gamma < 0$, mai ridicată în stînga
- Citirea graficului
  - distanța pe verticală dintre cele două ramuri în $\pm x$ măsoară asimetria
  - parametri ilustrativi, nu estimări

# Noțiuni necesare azi (15/17): diagnosticul unui model estimat

- **Reziduurile standardizate**: inovațiile estimate

$$\hat{z}_t = \frac{r_t - \hat{\mu}}{\hat{\sigma}_t}$$

  - dacă modelul este corect, $\hat{z}_t$ este aproape i.i.d., cu media 0 și varianța 1
- **Ljung–Box** $Q(10)$ Ljung & Box (1978) pe $\hat{z}_t^2$ (Capitolul 8): $Q(m) = T(T+2)\sum_{k=1}^{m} \hat{\rho}_k^2/(T-k) \sim \chi^2(m)$
  - $\hat{\rho}_k$: autocorelația lui $\hat{z}_t^2$ la lagul $k$; dacă nu respinge: nu a rămas niciun efect ARCH
- **Testul de asimetrie (sign bias)** Engle & Ng (1993): a rămas asimetrie în $\hat{z}_t^2$?

$$\hat{z}_t^2 = b_0 + b_1 S_{t-1}^- + b_2 S_{t-1}^- \hat{\varepsilon}_{t-1} + b_3 S_{t-1}^+ \hat{\varepsilon}_{t-1} + e_t$$

  - $S_{t-1}^- = 1$ dacă $\hat{\varepsilon}_{t-1} < 0$, altfel 0; $S_{t-1}^+ = 1 - S_{t-1}^-$; $e_t$: eroarea regresiei
  - testul comun pentru $b_1 = b_2 = b_3 = 0$: $TR^2 \sim \chi^2(3)$; $t$-ul de **semn**: statistica $t$ a lui $b_1$; o respingere: lipsește asimetria

# Noțiuni necesare azi (16/17): compararea prognozelor în afara eșantionului

- **În afara eșantionului**: prognoza $h_t$ pentru ziua $t$ folosește doar date pînă în ziua $t-1$
  - parametrii se reestimează la intervale regulate (de exemplu la fiecare 250 de zile) pe toate datele disponibile atunci
  - proxy-ul variației adevărate: $r_t^2$ (Capitolul 8)
- Pierderea **QLIKE** Patton (2011) în ziua $t$ și media ei pe $N$ zile

$$L_t = \frac{r_t^2}{h_t} + \ln h_t, \qquad \bar{L} = \frac{1}{N}\sum_t L_t$$

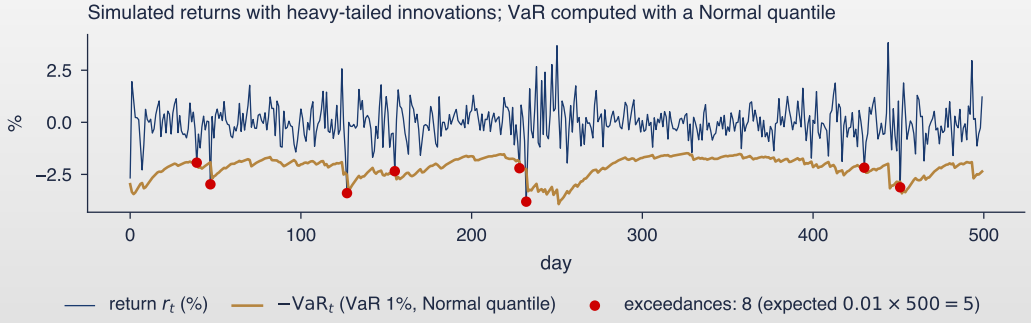
  - cu cît $\bar{L}$ este mai mică, cu atît prognozele sînt mai bune
- Testul **DM** (Diebold–Mariano) Diebold & Mariano (1995) pentru prognozele A și B

$$d_t = L_t^A - L_t^B, \qquad t_{DM} = \frac{\bar{d}}{\widehat{\mathrm{SE}}_{\mathrm{HAC}}(\bar{d})}$$

  - $\bar{d}$: diferența medie a pierderilor; HAC (heteroskedasticity and autocorrelation consistent): o eroare standard validă cînd $d_t$ este autocorelat
  - $t_{DM} < -1{,}96$: A este semnificativ mai bună la 5%
  - **diferența cumulată a pierderilor** $\sum_{s\le t}(L_s^B - L_s^A)$: crește în zilele în care A este mai bună

# Noțiuni necesare azi (17/17): depășirile VaR

- **Depășire**: o zi cu $r_t < -\mathrm{VaR}_t$; indicatorul $I_t = 1\{r_t < -\mathrm{VaR}_t\}$ (1 dacă este adevărat, 0 altfel)
- Pe $N$ zile, un VaR 1% corect are circa 0,01 $N$ depășiri; rata depășirilor $\frac{1}{N}\sum_t I_t$ trebuie să fie apropiată de 1%; testele formale, în Capitolul 10




- Randamente simulate cu cozi groase și un VaR Normal: pierderile dincolo de VaR apar mai des decît în 1% din zile
- Corelația a două serii de volatilitate (folosită în C1): corelația dintre $\ln \hat{\sigma}_t$ ale celor două active, în zilele comune

# A1: algebra GARCH(1,1) [Rezolvat]

## Cerință

- Randamente zilnice în %: $\omega = 0{,}02$, $\alpha = 0{,}08$, $\beta = 0{,}90$, $\mu = 0$, 252 de zile de tranzacționare pe an.
- 1. Calculați persistența și varianța pe termen lung.
- 2. Calculați volatilitatea pe termen lung anualizată.
- 3. Calculați timpul de înjumătățire al unui șoc de varianță.
- 4. Azi $\sigma_t^2 = 1{,}5$ și $r_t = -3\%$; calculați $\sigma_{t+1}^2$ și $\sigma_{t+1}$.
- Raportați: patru valori și o frază.

## Rezolvare

- 1. $\alpha + \beta = 0{,}98$; $\bar{\sigma}^2 = 0{,}02/(1 - 0{,}98) = 1{,}000$
- 2. $\sqrt{252 \times 1{,}000} = 15{,}87\%$ pe an
- 3. $\ln 0{,}5 / \ln 0{,}98 = -0{,}69315/(-0{,}02020) = 34{,}3$ zile
- 4. $0{,}02 + 0{,}08 \times 9 + 0{,}90 \times 1{,}5 = 2{,}090$; $\sigma_{t+1} = 1{,}446\%$
- O scădere de 3% crește varianța cu 39%; jumătate din excesul de varianță dispare după 34,3 zile de tranzacționare, circa 7 săptămîni.

înapoi Lista exercițiilor

# A2: o piață mai reactivă [Propus]

Rezolvarea se discută la seminar

## Cerință

- $\omega = 0{,}05$, $\alpha = 0{,}12$, $\beta = 0{,}85$, $\mu = 0$; azi $\sigma_t^2 = 2{,}0$ și $r_t = +1{,}5\%$. Model: A1.
- 1. Calculați persistența, varianța pe termen lung și volatilitatea pe termen lung anualizată.
- 2. Calculați timpul de înjumătățire.
- 3. Calculați $\sigma_{t+1}^2$.
- 4. Scrieți EWMA cu $\lambda = 0{,}94$ ca un GARCH(1,1) și precizați care dintre mărimile de la 1–2 există pentru el.
- Raportați: patru valori și două fraze.

înapoi Lista exercițiilor

# A3: prognoze și VaR 1% [Rezolvat]

## Cerință

- Modelul din A1, cu $\sigma^2_{t+1} = 2{,}090$ și inovații Normale.
- 1. Calculați $E_t[\sigma^2_{t+5}]$ și $E_t[\sigma^2_{t+10}]$.
- 2. Calculați varianța și volatilitatea pe 10 zile.
- 3. Comparați cu regula rădăcinii pătrate a timpului, $\sqrt{10}\,\sigma_{t+1}$, și cu $\sqrt{10}\,\bar{\sigma}^2$.
- 4. Calculați VaR 1% pe o zi și pe 10 zile.
- Raportați: șase valori și o frază.

## Rezolvare

- 1. $1 + 0{,}98^4(2{,}090 - 1) = 1 + 0{,}9224 \times 1{,}09 = 2{,}005$; $1 + 0{,}98^9 \times 1{,}09 = 1{,}909$
- 2. $10 \times 1 + 1{,}09 \times (1 - 0{,}98^{10})/0{,}02 = 10 + 1{,}09 \times 9{,}146 = 19{,}97$; volatilitatea 4,47%
- 3. $\sqrt{10 \times 2{,}090} = 4{,}57\%$ (prea mare), $\sqrt{10\,\bar{\sigma}^2} = \sqrt{10 \times 1} = 3{,}16\%$ (prea mică)
- 4. $2{,}326 \times 1{,}446 = 3{,}36\%$; $2{,}326 \times 4{,}47 = 10{,}40\%$
- Varianța ridicată scade lent: riscul pe 10 zile este între cele două reguli simple, mai aproape de prima.

Înapoi Lista exercițiilor

# A4: prognoze cu inovații Student-t [Propus]

Rezolvarea se discută la seminar

## Cerință

- Modelul din A2, cu $\sigma^2_{t+1} = 2{,}020$ și inovații Student-t standardizate cu $\nu = 5$ ($t_5^{-1}(0{,}01) = -3{,}365$). Model: A3.
- 1. Calculați $E_t[\sigma^2_{t+10}]$ și varianța pe 10 zile.
- 2. Calculați cuantila $q_{0{,}01}$ a distribuției t standardizate.
- 3. Calculați VaR 1% pe o zi și pe 10 zile, cu inovații t și cu inovații Normale.
- Raportați: șase valori și o frază.

Înapoi Lista exercițiilor

# A5: verosimilitatea ARCH(1), pas cu pas [Rezolvat]

## Cerință

- ARCH(1) cu $\omega = 0{,}5$, $\alpha = 0{,}5$, $\mu = 0$, $z_t$ Normale; observat: $r_1, \ldots, r_4 = 0{,}5;\ -1{,}2;\ 2{,}0;\ -0{,}3$.
- 1. Calculați $\sigma_2^2$, $\sigma_3^2$ și $\sigma_4^2$.
- 2. Calculați $\ell_2$, $\ell_3$, $\ell_4$ și log-verosimilitatea condiționată.
- 3. Calculați varianța necondiționată și coeficientul de boltire pentru acest ARCH(1).
- Raportați: șapte valori și o frază.

## Rezolvare

- 1. $0{,}5 + 0{,}5 \times 0{,}25 = 0{,}625$; $0{,}5 + 0{,}5 \times 1{,}44 = 1{,}220$; $0{,}5 + 0{,}5 \times 4 = 2{,}500$
- 2. $\ell_2 = -\frac{1}{2}[1{,}8379 + \ln 0{,}625 + 1{,}44/0{,}625] = -1{,}836$; $\ell_3 = -2{,}658$; $\ell_4 = -1{,}395$; suma $-5{,}889$
- 3. $0{,}5/(1 - 0{,}5) = 1{,}0$; $K = 3 \times 0{,}75/0{,}25 = 9{,}0$
- Ziua 3 ($r_3 = 2$ după o zi liniștită) contribuie cel mai puțin: un randament mare cînd $\sigma_t^2$ este mic este puțin probabil.

înapoi Lista exercițiilor

# A6: știri bune și știri proaste [Propus]

Rezolvarea se discută la seminar

## Cerință

- GJR-GARCH: $\omega = 0{,}02$, $\alpha = 0{,}03$, $\gamma = 0{,}12$, $\beta = 0{,}90$; EGARCH: $\omega = 0$, $\alpha = 0{,}12$, $\gamma = -0{,}08$, $\beta = 0{,}98$; în ambele $\sigma_t^2 = 1$, $\mu = 0$. Model: A1.
- 1. Calculați $\sigma_{t+1}^2$ GJR după $\varepsilon_t = -2$ și după $\varepsilon_t = +2$, precum și raportul lor.
- 2. Calculați persistența și timpul de înjumătățire GJR.
- 3. Calculați $\sigma_{t+1}^2$ EGARCH pentru aceleași două șocuri (folosiți $E|z| = 0{,}7979$).
- Raportați: șase valori și o frază.

Înapoi Lista exercițiilor

# B1: GARCH(1,1)-t pentru DAX [Rezolvat]

- **Întrebarea**: cît de persistentă este volatilitatea DAX și cît de departe este DAX azi de volatilitatea lui pe termen lung?
- **Date**: închiderile DAX din 2000, randamente logaritmice zilnice în %
- **Cerințe**
  1. Estimați GARCH(1,1) cu inovații Student-t și raportați parametrii cu erorile standard robuste.
  2. Calculați persistența, timpul de înjumătățire și volatilitatea pe termen lung anualizată și comparați-o cu volatilitatea de selecție.
  3. Raportați vîrfurile volatilității condiționate anualizate din 2008 și din 2020, precum și valoarea ei în ultima zi.
  4. Desenați randamentele din 2018 cu benzile $\pm 2\hat{\sigma}_t$.
  5. Interpretare: ar trebui un manager de risc să folosească pentru ziua de mîine volatilitatea pe termen lung sau pe cea curentă?
- **Raportați**: un tabel cu cinci parametri, cinci valori, graficul și două fraze
- Notebook: secțiunea B1

◂ Înapoi ▸ Lista exercițiilor

# B1: rezolvare [Rezolvat]




| | $\mu$ | $\omega$ | $\alpha$ | $\beta$ | $\nu$ |
|---|---|---|---|---|---|
| estimare | 0,081 | 0,0206 | 0,097 | 0,895 | 7,08 |
| SE robustă | 0,012 | 0,0049 | 0,011 | 0,012 | 0,62 |

- $T = 6\,786$; $\alpha + \beta = 0{,}992$, timpul de înjumătățire $\ln 0{,}5/(-0{,}00784) = 88{,}5$ zile; volatilitatea pe termen lung 25,9%, față de 22,4% în eșantion
- Vîrfuri: 80% (2008), 82% (2020); ultima zi: 13,0%; 5,2% dintre zile ies din banda $\pm 2\hat{\sigma}_t$
- Interpretare: pe cea curentă: VaR pentru mîine are nevoie de $\sigma_{t+\mathbf{1}}$; nivelul pe termen lung contează doar pentru orizonturi lungi și este imprecis, deoarece $1 - \alpha - \beta = 0{,}0078$ este mic

SFM_ch9_seminar

# B2: BET, Banca Transilvania și Bitcoin [Propus]

- **Întrebarea**: care dintre BET, Banca Transilvania și Bitcoin are volatilitatea cea mai persistentă? Model: B1.
- **Date**: BET din 2000, TLV din 2010 (fără 30–31 mai 2016), Bitcoin din 2014; randamente logaritmice zilnice în %
- **Cerințe**
  1. Estimați GARCH(1,1)-t pentru fiecare serie și raportați $\alpha$, $\beta$ și $\nu$.
  2. Calculați persistența, timpul de înjumătățire și volatilitatea pe termen lung, acolo unde există.
  3. Comparați volatilitatea pe termen lung cu volatilitatea de selecție (anualizați Bitcoin cu 365 de zile).
  4. Interpretare: ce îi spune unui manager de risc o estimare $\hat{\alpha} + \hat{\beta} = 1$?
- **Raportați**: un tabel și două fraze
- Notebook: secțiunea B2

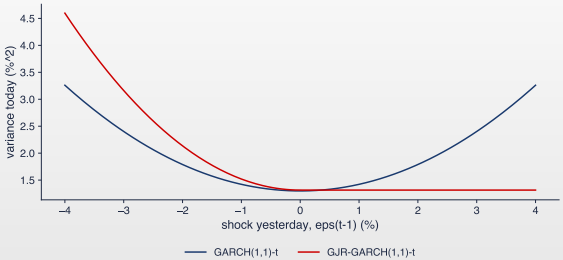
Înapoi Lista exercițiilor

# B3: efectul de levier la S&P 500 [Rezolvat]

- **Întrebarea**: cresc scăderile volatilitatea S&P 500 mai mult decît creșterile de aceeași mărime?
- **Date**: închiderile S&P 500 din 2000, randamente logaritmice zilnice în %
- **Cerințe**
  1. Estimați GARCH(1,1)-t și GJR-GARCH(1,1)-t; raportați $\gamma$ cu statistica $t$ robustă.
  2. Calculați statistica LR pentru GJR față de GARCH, p-value-ul ei și cele două valori BIC.
  3. Aplicați testul de asimetrie (sign bias) pe reziduurile standardizate ale GARCH-t.
  4. Desenați ambele curbe de impact ale știrilor și calculați varianța GJR după șocuri de $-2\%$ și $+2\%$.
  5. Interpretare: cum schimbă efectul de levier VaR-ul din ziua de după o scădere?
- **Raportați**: patru statistici cu p-value-uri, două variațe, graficul și două fraze
- Notebook: secțiunea B3

◂ Înapoi ▸ Lista exercițiilor

# B3: rezolvare [Rezolvat]




- GJR: $\hat{\alpha} = 0{,}000$, $\hat{\gamma} = 0{,}205$ ($t = 10{,}03$), $\hat{\beta} = 0{,}881$; LR $= 235{,}7$ ($p < 0{,}001$); BIC $18169{,}0 \to 17942{,}2$
- Testul de asimetrie pe reziduurile GARCH-t: $\chi^2(3) = 40{,}7$ ($p < 0{,}001$), $t$ al semnului $= 3{,}56$
- Varianța GJR după $-2\%$: 2,136; după $+2\%$: 1,315; raportul 1,62
- Interpretare: doar scăderile cresc varianța ($\hat{\alpha} = 0$); după o scădere, VaR este de circa $\sqrt{1{,}62}$ ori VaR-ul de după o creștere egală; un GARCH simetric subestimează riscul după zilele proaste

SFM_ch9_seminar

# B4: asimetria la BVB și la Bitcoin [Propus]

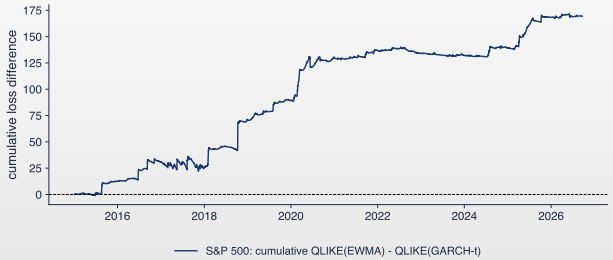
- **Întrebarea**: există un efect de levier la BET, la Banca Transilvania și la Bitcoin? Model: B3.
- **Date**: BET din 2000, TLV din 2010, Bitcoin din 2014; randamente logaritmice zilnice în %
- **Cerințe**
  1. Estimați GJR-GARCH(1,1)-t și EGARCH(1,1)-t; raportați ambele valori $\gamma$, cu statisticile $t$ robuste.
  2. Calculați testul LR pentru GJR față de GARCH și modificarea BIC.
  3. Calculați raportul GJR dintre variațele de după $-2\%$ și $+2\%$.
  4. Interpretare: ați folosi un model asimetric pentru fiecare dintre cele trei serii? De ce?
- **Raportați**: un tabel și două fraze
- Notebook: secțiunea B4

# B5: GARCH față de EWMA pentru S&P 500 [Rezolvat]

- **Întrebarea**: prognozează GARCH(1,1)-t varianța de mîine a S&P 500 mai bine decît EWMA și este VaR 1% al lui depășit în 1% dintre zile?
- **Date**: S&P 500 din 2000; prognoze pentru fiecare zi de la 2 ianuarie 2015
- **Cerințe**
  1. Reestimați GARCH(1,1)-t la fiecare 250 de zile pe toate datele pînă în acea zi și calculați prognozele pe o zi $h_t$; calculați EWMA cu $\lambda = 0{,}94$.
  2. Calculați media QLIKE pentru ambele modele și statistica $t$ Diebold–Mariano.
  3. Numărați depășirile VaR 1% GARCH-t și VaR 1% EWMA-Normal și comparați-le cu numărul așteptat.
  4. Desenați diferența cumulată a pierderilor.
  5. Interpretare: ce model i-ați da unui manager de risc și ce ați mai corecta?
- **Raportați**: patru valori, două numere de depășiri, graficul și două fraze
- Notebook: secțiunea B5

◂ Înapoi ▸ Lista exercițiilor

# B5: rezolvare [Rezolvat]




- 2 944 de zile; media QLIKE: GARCH-t 0,761, EWMA 0,819; DM: diferența medie $-0{,}058$, $t = -3{,}69$ ($p < 0{,}001$): GARCH-t este mai bun
- Depășiri VaR 1%: GARCH-t 49 (1,66%), EWMA-Normal 65 (2,21%); așteptat circa 29
- Interpretare: GARCH-t, dar ambele modele VaR sînt depășite prea des; adăugăm efectul de levier (B3) și testăm formal depășirile (Capitolul 10)

SFM_ch9_seminar

# B6: GARCH față de EWMA pentru DAX și BET [Propus]

- **Întrebarea**: se păstrează rezultatul din B5 pentru DAX și pentru BET? Model: B5.
- **Date**: DAX și BET din 2000; prognoze pentru fiecare zi începînd din ianuarie 2015
- **Cerințe**
  1. Calculați prognozele GARCH(1,1)-t și EWMA în afara eșantionului, ca în B5.
  2. Calculați media QLIKE pentru ambele modele și testul DM.
  3. Numărați depășirile VaR 1% pentru ambele modele.
  4. Interpretare: pentru care indice ajută cel mai mult GARCH și de ce?
- **Raportați**: un tabel și două fraze
- Notebook: secțiunea B6

Înapoi Lista exercițiilor

# C1: apropierea volatilității Bitcoin de cea a acțiunilor [Propus]

- **Întrebarea**: s-a apropiat volatilitatea Bitcoin de volatilitatea S&P 500 după 2021?
- **Date**: randamentele logaritmice zilnice Bitcoin și S&P 500, 2015–2019 și 2021–2026; modele: B1, B3
- **Cerințe**
  1. Estimați GJR-GARCH(1,1)-t pentru ambele serii, în ambele perioade, și raportați persistența, $\gamma$ și $\nu$.
  2. Calculați corelația logaritmilor celor două volatilități GARCH-t în zilele comune, în fiecare perioadă.
  3. Enumerați evenimentele din 2020–2024 care ar putea explica o schimbare.
  4. Interpretare: cum ați deosebi o schimbare durabilă de o schimbare produsă de o singură criză?
- **Raportați**: un tabel și un plan de proiect
- Notebook: secțiunea C1

Înapoi Lista exercițiilor

# C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI să interpreteze un GARCH(1,1)-t estimat pentru S&P 500 (date zilnice, din 2000): $\hat{\omega} = 0{,}0157$, $\hat{\alpha} = 0{,}123$, $\hat{\beta} = 0{,}872$, $\hat{\nu} = 6{,}26$. Răspunsul:
- (a) alpha + beta = 0,995, deci un șoc de volatilitate dispare în aproximativ o săptămînă.
- (b) Varianța pe termen lung este omega/(1 - alpha) = 0,018, o volatilitate anuală de 2,1%.
- (c) Un GJR estimat dă gamma = 0,205 > 0: știrile bune cresc volatilitatea mai mult decît știrile proaste.
- (d) Ljung-Box Q(10) al pătratelor reziduurilor standardizate = 13,6, p = 0,19: modelul GARCH-t este corect.
- (e) Cu inovații Student-t, VaR 1% pe o zi este de 2,326 ori sigma(t+1).
- (f) EWMA cu lambda = 0,94 este un GARCH(1,1) cu omega = 0, alpha = 0,06, beta = 0,94.
- Cerințe
  - 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook (secțiunea C2).
  - 2. Raportați: o listă de șase verdicte, fiecare cu un rînd de justificare.

◂ Înapoi ▸ Lista exercițiilor

## Idei de reținut

- $\alpha + \beta$ decide tot ce ține de termenul lung: timpul de înjumătățire, varianța pe termen lung, forma prognozelor
- Riscul pe mai multe zile este suma prognozelor zilnice ale variației, nu $\sqrt{H}$ ori volatilitatea de azi
- Inovațiile cu cozi groase schimbă cuantila VaR; asimetria schimbă VaR-ul după zilele proaste
- Comparăm prognozele în afara eșantionului (QLIKE, DM), nu doar în eșantion (AIC, BIC)
- Un răspuns AI este doar o primă versiune: verificați formula variației pe termen lung, semnul lui $\gamma$ și cuantila

## După seminar

- Cursul 9 dezvoltă fiecare temă de azi: ARCH și GARCH, estimarea, inovațiile, asimetria, diagnosticul, prognozele, VaR
- C1 poate deveni un proiect de echipă: ferestre mobile, Ethereum și aurul ca termeni de comparație
- Lectură: Franke, Härdle & Hafner (2019), cap. 13; exerciții în Borak, Härdle & López-Cabrera (2013), cap. 13; Tsay (2010), cap. 3

# Bibliografie (1/2)


- **Akaike, H. (1974).** A new look at the statistical model identification. ***IEEE Transactions on Automatic Control*, 19(6), 716–723.**
- **Bollerslev, T. (1986).** Generalized autoregressive conditional heteroskedasticity. ***Journal of Econometrics*, 31(3), 307–327.**
- **Bollerslev, T. (1987).** A conditionally heteroskedastic time series model for speculative prices and rates of return. ***Review of Economics and Statistics*, 69(3), 542–547.**
- **Bollerslev, T., Wooldridge, J.M. (1992).** Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. ***Econometric Reviews*, 11(2), 143–172.**
- **Borak, S., Härdle, W.K., López-Cabrera, B. (2013).** ***Statistics of Financial Markets: Exercises and Solutions*, 2nd ed. Springer.**
- **Christie, A.A. (1982).** The stochastic behavior of common stock variances: value, leverage and interest rate effects. ***Journal of Financial Economics*, 10(4), 407–432.**
- **Diebold, F.X., Mariano, R.S. (1995).** Comparing predictive accuracy. ***Journal of Business & Economic Statistics*, 13(3), 253–263.**
- **Engle, R.F. (1982).** Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. ***Econometrica*, 50(4), 987–1007.**
- **Engle, R.F., Ng, V.K. (1993).** Measuring and testing the impact of news on volatility. ***Journal of Finance*, 48(5), 1749–1778.**

# Bibliografie (2/2)


- Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- Ljung, G.M., Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, 59(2), 347–370.
- Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- Schwarz, G. (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2), 461–464.
- Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed. Wiley.