



Statistica piețelor financiare

Seminarul 9: Modele ARCH și GARCH



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **AI:** Artificial Intelligence (inteligență artificială)
- ▣ **AIC:** Akaike Information Criterion (criteriul informațional Akaike)
- ▣ **ARCH:** AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă)
- ▣ **BET:** Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BIC:** Bayesian Information Criterion (criteriul informațional bayesian)
- ▣ **BVB:** Bursa de Valori București
- ▣ **COVID-19:** COronaVirus Disease 2019 (boala provocată de coronavirus, 2019)
- ▣ **DM:** Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **EGARCH:** Exponential GARCH (GARCH exponențial)
- ▣ **EODHD:** EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **ETF:** Exchange-Traded Fund (fond tranzacționat la bursă)

Acronime folosite în acest material (2/2)

- **EWMA**: Exponentially Weighted Moving Average (medie mobilă ponderată exponențial)
- **GARCH**: Generalised AutoRegressive Conditional Heteroskedasticity (heteroscedasticitate condiționată autoregresivă generalizată)
- **GJR**: Glosten–Jagannathan–Runkle (asymmetric GARCH) — modelul GARCH asimetric Glosten–Jagannathan–Runkle
- **GJR-GARCH**: Glosten–Jagannathan–Runkle GARCH (GARCH asimetric Glosten–Jagannathan–Runkle)
- **HAC**: Heteroskedasticity and Autocorrelation Consistent (standard errors) — erori standard robuste la heteroscedasticitate și autocorelație
- **IGARCH**: Integrated GARCH (GARCH integrat)
- **LR**: Likelihood Ratio (test) — testul raportului de verosimilitate
- **MLE**: Maximum Likelihood Estimation (estimarea prin metoda verosimilității maxime)
- **QLIKE**: Quasi-LIKelihood (loss function) — funcția de pierdere de tip cvasi-verosimilitate
- **SE**: Standard Error (eroare standard)

Întrebarea de azi și traseul

- ▣ **Întrebarea:** cum modelăm, estimăm și prognozăm o volatilitate care se schimbă în fiecare zi?
 - ▶ seminarul are loc **înaintea** Cursului 9: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- ▣ Traseul
 - ▶ Partea A: algebra GARCH, prognoze și VaR, verosimilitatea ARCH, impactul asimetric al știrilor, pe hârtie
 - ▶ Partea B: estimarea GARCH, asimetria și prognozele în afara eșantionului pe S&P 500, DAX, BET, Bitcoin și acțiuni BVB, fiecare cu o întrebare de interpretare
 - ▶ Partea C: o întrebare deschisă pentru proiect și un răspuns AI de verificat
- ▣ Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook
- ▣ Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	persistența, varianța pe termen lung, timpul de înjumătățire și un pas GARCH(1,1)	Rezolvat, Propus	A1
A3, A4	proгноze pe mai mulți pași, volatilitatea pe 10 zile și VaR 1%	Rezolvat, Propus	A3
A5, A6	verosimilitatea și boltirea ARCH(1); impactul știrilor în GJR-GARCH și EGARCH	Rezolvat, Propus	A5
B1, B2	estimări GARCH(1,1)-t: DAX; BET, Banca Transilvania, Bitcoin	Rezolvat, Propus	B1
B3, B4	asimetria și efectul de levier: S&P 500; BET, Bitcoin, TLV	Rezolvat, Propus	B3
B5, B6	GARCH față de EWMA în afara eșantionului, depășirile VaR 1%: S&P 500; DAX, BET	Rezolvat, Propus	B5
C1, C2	apropierea volatilității Bitcoin de cea a acțiunilor; erorile unui răspuns AI	Propus	B1, B3

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați voi, după model

Datele folosite

Seria	Sursa	Prețul folosit	Perioada
S&P 500, DAX, BET	EODHD	închidere	2000–2026
Bitcoin	EODHD	închidere, 7 zile pe săptămână	2014–2026
Banca Transilvania (TLV)	EODHD	închidere ajustată	2010–2026

- Randamente logaritmice zilnice în %: $r_t = 100 (\ln P_t - \ln P_{t-1})$; weekendurile și închiderile repetate din zilele libere se elimină (cu excepția Bitcoin); ultima zi este 18 septembrie 2026
- TLV: zilele de 30 și 31 mai 2016 se elimină (o ajustare de preț aplicată cu o zi mai târziu, [Capitolul 2](#))
- În notebook: `returns('dax')`, `fit(r, dist='t')` (pachetul `arch`); nu este nevoie de cont sau de cheie

Noțiuni necesare azi (1/5): varianța condiționată, ARCH și GARCH

- $r_t = \mu + \varepsilon_t$, $\varepsilon_t = \sigma_t z_t$; z_t i.i.d., media 0, varianța 1 (**inovațiile**)
 - ▶ $\sigma_t^2 = \text{Var}(r_t | \text{trecut})$: **varianța condiționată**, cunoscută cu o zi înainte
 - ▶ șocurile ε_t sînt necorelate, dar pătratele lor sînt corelate (volatility clustering, [Capitolul 8](#))
- **ARCH(1) Engle (1982)**: $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$, $\omega > 0$, $0 \leq \alpha < 1$
 - ▶ în cuvinte: varianța de azi = o constantă ω plus o fracțiune α din pătratul șocului de ieri
 - ▶ varianța necondiționată (medie) $\omega/(1 - \alpha)$
 - ▶ cu z_t Normale și $3\alpha^2 < 1$: coeficientul de boltire $3(1 - \alpha^2)/(1 - 3\alpha^2) > 3$
- **GARCH(1,1) Bollerslev (1986)**: $\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$, $\omega > 0$, $\alpha, \beta \geq 0$
 - ▶ ω : o constantă care fixează nivelul pe termen lung; α : reacția la știri; β : memoria (ponderea varianței de ieri)
 - ▶ $\alpha + \beta < 1$: modelul este staționar
 - ▶ **EWMA** ([Capitolul 8](#)): $\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) r_{t-1}^2$, un GARCH cu $\omega = 0$, $\alpha + \beta = 1$ (**IGARCH**)

Noțiuni necesare azi (2/5): persistență și prognoze

- ▣ **Persistența** $\alpha + \beta$; **varianța pe termen lung** $\bar{\sigma}^2 = \omega / (1 - \alpha - \beta)$; volatilitatea anuală $\sqrt{252 \bar{\sigma}^2}$
 - ▶ **timpul de înjumătățire:** $h_{1/2} = \ln 0,5 / \ln(\alpha + \beta)$ zile, timpul în care dispare jumătate dintr-un șoc de varianță
- ▣ Prognoze făcute la sfârșitul zilei t
 - ▶ E_t : media condiționată de datele până în ziua t ; h : orizontul, în zile; H : lungimea perioadei de deținere
 - ▶ o zi: $\sigma_{t+1}^2 = \omega + \alpha(r_t - \mu)^2 + \beta\sigma_t^2$
 - ▶ h zile: $E_t[\sigma_{t+h}^2] = \bar{\sigma}^2 + (\alpha + \beta)^{h-1}(\sigma_{t+1}^2 - \bar{\sigma}^2)$
 - ▶ varianța pe H zile: $\sum_{h=1}^H E_t[\sigma_{t+h}^2] = H\bar{\sigma}^2 + (\sigma_{t+1}^2 - \bar{\sigma}^2) \frac{1 - (\alpha + \beta)^H}{1 - \alpha - \beta}$
- ▣ **VaR 1%** (value at risk, valoarea expusă la risc, [Capitolul 6](#)): $\text{VaR}_{t+1} = -(\mu + \sigma_{t+1} q_{0,01}(z))$
 - ▶ $q_{0,01}(z)$: cuantila de 1% a inovației z ; VaR este o pierdere pozitivă, în %
 - ▶ Normală: $q_{0,01} = -2,326$; Student-t standardizată: $q_{0,01} = t_\nu^{-1}(0,01) \sqrt{(\nu - 2)/\nu}$
 - ▶ $t_\nu^{-1}(0,01)$: cuantila de 1% a distribuției Student-t cu ν grade de libertate, de exemplu $t_5^{-1}(0,01) = -3,365$

Noțiuni necesare azi (3/5): verosimilitatea maximă

- Log-verosimilitatea Normală condiționată, cu σ_t^2 calculat recursiv:

- ▶ $\ell(\theta) = \sum_{t=2}^T \ell_t, \quad \ell_t = -\frac{1}{2} \left[\ln(2\pi) + \ln \sigma_t^2 + \frac{(r_t - \mu)^2}{\sigma_t^2} \right]$

- ▶ $\theta = (\mu, \omega, \alpha, \beta)$: parametrii; T : numărul de randamente; ℓ_t : contribuția zilei t

- ▶ **MLE**: $\hat{\theta}$ maximizează ℓ ; numeric, cu $\omega > 0, \alpha, \beta \geq 0, \alpha + \beta < 1$

- Erori standard (SE)

- ▶ clasice: din curbura lui ℓ în punctul de maxim

- ▶ robuste [Bollerslev & Wooldridge \(1992\)](#): valide când z_t nu este Normal; arch le raportează pe cele robuste

- Inovații cu cozi groase ([Capitolul 2](#)): Student-t standardizată cu ν grade de libertate [Bollerslev \(1987\)](#); t asimetrică [Hansen \(1994\)](#)

- ▶ comparăm modelele prin testul **LR** (likelihood ratio, raportul de verosimilitate) $2(\ell_1 - \ell_0) \sim \chi^2(r)$ și prin AIC/BIC ([Capitolul 6](#))

- ▶ ℓ_1, ℓ_0 : log-verosimilitățile maxime ale modelului mai mare și ale celui mai mic; r : numărul de restricții; $\chi_{0,95}^2(1) = 3,84$

Noțiuni necesare azi (4/5): asimetria

- ▣ **Efectul de levier**: scăderile cresc volatilitatea mai mult decât creșterile de aceeași mărime [Christie \(1982\)](#)
- ▣ **GJR-GARCH** [Glosten, Jagannathan & Runkle \(1993\)](#): $\sigma_t^2 = \omega + (\alpha + \gamma I_{t-1})\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2$, $I_{t-1} = 1$ dacă $\varepsilon_{t-1} < 0$
 - ▶ I_{t-1} : indicatorul unui șoc negativ ieri; γ : reacția suplimentară la știrile proaste
 - ▶ efect de levier: $\gamma > 0$; persistența $\alpha + \beta + \gamma/2$ pentru z_t simetric
- ▣ **EGARCH** [Nelson \(1991\)](#): $\ln \sigma_t^2 = \omega + \alpha(|z_{t-1}| - E|z_{t-1}|) + \gamma z_{t-1} + \beta \ln \sigma_{t-1}^2$
 - ▶ modelează $\ln \sigma_t^2$, deci varianța este mereu pozitivă; $|z_{t-1}| - E|z_{t-1}|$: mărimea șocului standardizat de ieri peste media ei
 - ▶ $E|z| = \sqrt{2/\pi} = 0,7979$ pentru z Normal; efect de levier: $\gamma < 0$
- ▣ **Curba de impact a știrilor** [Engle & Ng \(1993\)](#): σ_t^2 ca funcție de ε_{t-1} , cu σ_{t-1}^2 fixat
 - ▶ parabolă simetrică pentru GARCH; mai abruptă la stînga pentru GJR și EGARCH cu efect de levier

Noțiuni necesare azi (5/5): verificarea și compararea prognozelor

- ▣ Reziduurile standardizate $\hat{z}_t = (r_t - \hat{\mu})/\hat{\sigma}_t$: aproape i.i.d. dacă modelul este corect
 - ▶ Ljung–Box $Q(10)$ pe $\hat{z}_t^2$ (Capitolul 7) Ljung & Box (1978): nu a rămas niciun efect ARCH dacă nu respinge
 - ▶ testul de asimetrie (sign bias) Engle & Ng (1993): $\chi^2(3)$; o respingere înseamnă că lipsește asimetria
- ▣ În afara eșantionului: prognoza h_t pentru ziua t folosește doar date pînă la $t - 1$; aproximarea varianței adevărate: r_t^2
 - ▶ pierderea **QLIKE** Patton (2011): $L_t = r_t^2/h_t + \ln h_t$; cu cît media este mai mică, cu atît prognozele sînt mai bune
 - ▶ testul **DM** (Diebold–Mariano) Diebold & Mariano (1995): statistica t a mediei lui $L_t^A - L_t^B$, cu erori standard HAC; $t < -1,96$: A este mai bun
- ▣ **Depășire VaR**: o zi cu $r_t < -\text{VaR}_t$; un VaR 1% corect este depășit în circa 1% dintre zile

A1: algebra GARCH(1,1) [Rezolvat]

Cerință

- ▣ Randamente zilnice în %: $\omega = 0,02$, $\alpha = 0,08$, $\beta = 0,90$, $\mu = 0$, 252 de zile de tranzacționare pe an.
- ▣ 1. Calculați persistența și varianța pe termen lung.
- ▣ 2. Calculați volatilitatea pe termen lung anualizată.
- ▣ 3. Calculați timpul de înjumătățire al unui șoc de varianță.
- ▣ 4. Azi $\sigma_t^2 = 1,5$ și $r_t = -3\%$; calculați σ_{t+1}^2 și σ_{t+1} .
- ▣ Raportați: patru valori și o frază.

Rezolvare

- ▣ 1. $\alpha + \beta = 0,98$; $\bar{\sigma}^2 = 0,02/(1 - 0,98) = 1,000$
- ▣ 2. $\sqrt{252 \times 1,000} = 15,87\%$ pe an
- ▣ 3. $\ln 0,5 / \ln 0,98 = -0,69315 / (-0,02020) = 34,3$ zile
- ▣ 4. $0,02 + 0,08 \times 9 + 0,90 \times 1,5 = 2,090$; $\sigma_{t+1} = 1,446\%$
- ▣ O scădere de 3% crește varianța cu 39%; jumătate din excesul de varianță dispare după 34,3 zile de tranzacționare, circa 7 săptămîni.

A2: o piață mai reactivă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ $\omega = 0,05$, $\alpha = 0,12$, $\beta = 0,85$, $\mu = 0$; azi $\sigma_t^2 = 2,0$ și $r_t = +1,5\%$. Model: A1.
- ▣ 1. Calculați persistența, varianța pe termen lung și volatilitatea pe termen lung anualizată.
- ▣ 2. Calculați timpul de înjumătățire.
- ▣ 3. Calculați σ_{t+1}^2 .
- ▣ 4. Scrieți EWMA cu $\lambda = 0,94$ ca un GARCH(1,1) și precizați care dintre mărimile de la 1–2 există pentru el.
- ▣ Raportați: patru valori și două fraze.

A3: prognoze și VaR 1% [Rezolvat]

Cerință

- ▣ Modelul din A1, cu $\sigma_{t+1}^2 = 2,090$ și inovații Normale.
- ▣ 1. Calculați $E_t[\sigma_{t+5}^2]$ și $E_t[\sigma_{t+10}^2]$.
- ▣ 2. Calculați varianța și volatilitatea pe 10 zile.
- ▣ 3. Comparați cu regula rădăcinii pătrate a timpului, $\sqrt{10}\sigma_{t+1}$, și cu $\sqrt{10}\bar{\sigma}^2$.
- ▣ 4. Calculați VaR 1% pe o zi și pe 10 zile.
- ▣ Raportați: șase valori și o frază.

Rezolvare

- ▣ 1. $1 + 0,98^4(2,090 - 1) = 1 + 0,9224 \times 1,09 = 2,005$;
 $1 + 0,98^9 \times 1,09 = 1,909$
- ▣ 2. $10 \times 1 + 1,09 \times (1 - 0,98^{10})/0,02 =$
 $10 + 1,09 \times 9,146 = 19,97$; volatilitatea 4,47%
- ▣ 3. $\sqrt{10 \times 2,090} = 4,57\%$ (prea mare),
 $\sqrt{10 \bar{\sigma}^2} = \sqrt{10 \times 1} = 3,16\%$ (prea mică)
- ▣ 4. $2,326 \times 1,446 = 3,36\%$; $2,326 \times 4,47 = 10,40\%$
- ▣ Varianța ridicată scade lent: riscul pe 10 zile este între cele două reguli simple, mai aproape de prima.

A4: prognoze cu inovații Student-t [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Modelul din A2, cu $\sigma_{t+1}^2 = 2,020$ și inovații Student-t standardizate cu $\nu = 5$ ($t_5^{-1}(0,01) = -3,365$). Model: A3.
- ▣ 1. Calculați $E_t[\sigma_{t+10}^2]$ și varianța pe 10 zile.
- ▣ 2. Calculați cuantila $q_{0,01}$ a distribuției t standardizate.
- ▣ 3. Calculați VaR 1% pe o zi și pe 10 zile, cu inovații t și cu inovații Normale.
- ▣ Raportați: șase valori și o frază.

A5: verosimilitatea ARCH(1), pas cu pas [Rezolvat]

Cerință

- ▣ ARCH(1) cu $\omega = 0,5$, $\alpha = 0,5$, $\mu = 0$, z_t Normale; observat: $r_1, \dots, r_4 = 0,5; -1,2; 2,0; -0,3$.
- ▣ 1. Calculați σ_2^2 , σ_3^2 și σ_4^2 .
- ▣ 2. Calculați ℓ_2 , ℓ_3 , ℓ_4 și log-verosimilitatea condiționată.
- ▣ 3. Calculați varianța necondiționată și coeficientul de boltire pentru acest ARCH(1).
- ▣ Raportați: șapte valori și o frază.

Rezolvare

- ▣ 1. $0,5 + 0,5 \times 0,25 = 0,625$; $0,5 + 0,5 \times 1,44 = 1,220$;
 $0,5 + 0,5 \times 4 = 2,500$
- ▣ 2. $\ell_2 = -\frac{1}{2}[1,8379 + \ln 0,625 + 1,44/0,625] = -1,836$;
 $\ell_3 = -2,658$; $\ell_4 = -1,395$; suma $-5,889$
- ▣ 3. $0,5/(1 - 0,5) = 1,0$; $K = 3 \times 0,75/0,25 = 9,0$
- ▣ Ziua 3 ($r_3 = 2$ după o zi liniștită) contribuie cel mai puțin: un randament mare cînd σ_t^2 este mic este puțin probabil.

A6: știri bune și știri proaste [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ GJR-GARCH: $\omega = 0,02$, $\alpha = 0,03$, $\gamma = 0,12$, $\beta = 0,90$; EGARCH: $\omega = 0$, $\alpha = 0,12$, $\gamma = -0,08$, $\beta = 0,98$; în ambele $\sigma_t^2 = 1$, $\mu = 0$. Model: A1.
- ▣ 1. Calculați σ_{t+1}^2 GJR după $\varepsilon_t = -2$ și după $\varepsilon_t = +2$, precum și raportul lor.
- ▣ 2. Calculați persistența și timpul de înjumătățire GJR.
- ▣ 3. Calculați σ_{t+1}^2 EGARCH pentru aceleași două șocuri (folosiți $E|z| = 0,7979$).
- ▣ Raportați: șase valori și o frază.

B1: GARCH(1,1)-t pentru DAX [Rezolvat]

- ▣ **Întrebarea:** cât de persistentă este volatilitatea DAX și cât de departe este DAX azi de volatilitatea lui pe termen lung?
- ▣ **Date:** închiderile DAX din 2000, randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GARCH(1,1) cu inovații Student-t și raportați parametrii cu erorile standard robuste.
 2. Calculați persistența, timpul de înjumătățire și volatilitatea pe termen lung anualizată și comparați-o cu volatilitatea de selecție.
 3. Raportați vîrfurile volatilității condiționate anualizate din 2008 și din 2020, precum și valoarea ei în ultima zi.
 4. Desenați randamentele din 2018 cu benzile $\pm 2\hat{\sigma}_t$.
 5. Interpretare: ar trebui un manager de risc să folosească pentru ziua de mâine volatilitatea pe termen lung sau pe cea curentă?
- ▣ **Raportați:** un tabel cu cinci parametri, cinci valori, graficul și două fraze
- ▣ **Notebook:** secțiunea B1

B1: rezolvare [Rezolvat]



	μ	ω	α	β	ν
estimare	0,081	0,0206	0,097	0,895	7,08
SE robustă	0,012	0,0049	0,011	0,012	0,62

- $T = 6\,786$; $\alpha + \beta = 0,992$, timpul de înjumătățire $\ln 0,5 / (-0,00784) = 88,5$ zile; volatilitatea pe termen lung 25,9%, față de 22,4% în eșantion
- Vîrfuri: 80% (2008), 82% (2020); ultima zi: 13,0%; 5,2% dintre zile ies din banda $\pm 2\hat{\sigma}_t$
- Interpretare: pe cea curentă: VaR pentru mâine are nevoie de σ_{t+1} ; nivelul pe termen lung contează doar pentru orizonturi lungi și este imprecis, deoarece $1 - \alpha - \beta = 0,0078$ este mic


B2: BET, Banca Transilvania și Bitcoin [Propus]

- ▣ **Întrebarea:** care dintre BET, Banca Transilvania și Bitcoin are volatilitatea cea mai persistentă? Model: B1.
- ▣ **Date:** BET din 2000, TLV din 2010 (fără 30–31 mai 2016), Bitcoin din 2014; randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GARCH(1,1)-t pentru fiecare serie și raportați α , β și ν .
 2. Calculați persistența, timpul de înjumătățire și volatilitatea pe termen lung, acolo unde există.
 3. Comparați volatilitatea pe termen lung cu volatilitatea de selecție (anualizați Bitcoin cu 365 de zile).
 4. Interpretare: ce îi spune unui manager de risc o estimare $\hat{\alpha} + \hat{\beta} = 1$?
- ▣ **Raportați:** un tabel și două fraze
- ▣ **Notebook:** secțiunea B2

B3: efectul de levier la S&P 500 [Rezolvat]

- ▣ **Întrebarea:** cresc scăderile volatilitatea S&P 500 mai mult decât creșterile de aceeași mărime?
- ▣ **Date:** închiderile S&P 500 din 2000, randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GARCH(1,1)-t și GJR-GARCH(1,1)-t; raportați γ cu statistica t robustă.
 2. Calculați statistica LR pentru GJR față de GARCH, p-value-ul ei și cele două valori BIC.
 3. Aplicați testul de asimetrie (sign bias) pe reziduurile standardizate ale GARCH-t.
 4. Desenați ambele curbe de impact ale știrilor și calculați varianța GJR după șocuri de -2% și $+2\%$.
 5. Interpretare: cum schimbă efectul de levier VaR-ul din ziua de după o scădere?
- ▣ **Raportați:** patru statistici cu p-value-uri, două varianțe, graficul și două fraze
- ▣ **Notebook:** secțiunea B3

B3: rezolvare [Rezolvat]



- GJR: $\hat{\alpha} = 0,000$, $\hat{\gamma} = 0,205$ ($t = 10,03$), $\hat{\beta} = 0,881$; LR = 235,7 ($p < 0,001$); BIC 18169,0 $\rightarrow$ 17942,2
- Testul de asimetrie pe reziduurile GARCH-t: $\chi^2(3) = 40,7$ ($p < 0,001$), t al semnului = 3,56
- Varianța GJR după -2% : 2,136; după $+2\%$: 1,315; raportul 1,62
- Interpretare: doar scăderile cresc varianța ($\hat{\alpha} = 0$); după o scădere, VaR este de circa $\sqrt{1,62}$ ori VaR-ul de după o creștere egală; un GARCH simetric subestimează riscul după zilele proaste


B4: asimetria la BVB și la Bitcoin [Propus]

- ▣ **Întrebarea:** există un efect de levier la BET, la Banca Transilvania și la Bitcoin? Model: B3.
- ▣ **Date:** BET din 2000, TLV din 2010, Bitcoin din 2014; randamente logaritmice zilnice în %
- ▣ **Cerințe**
 1. Estimați GJR-GARCH(1,1)- t și EGARCH(1,1)- t ; raportați ambele valori γ , cu statisticile t robuste.
 2. Calculați testul LR pentru GJR față de GARCH și modificarea BIC.
 3. Calculați raportul GJR dintre varianțele de după -2% și $+2\%$.
 4. Interpretare: ați folosi un model asimetric pentru fiecare dintre cele trei serii? De ce?
- ▣ **Raportați:** un tabel și două fraze
- ▣ Notebook: secțiunea B4

B5: GARCH față de EWMA pentru S&P 500 [Rezolvat]

- **Întrebarea:** prognozează GARCH(1,1)-t varianța de mâine a S&P 500 mai bine decât EWMA și este VaR 1% al lui depășit în 1% dintre zile?
- **Date:** S&P 500 din 2000; prognoze pentru fiecare zi de la 2 ianuarie 2015
- **Cerințe**
 1. Reestimați GARCH(1,1)-t la fiecare 250 de zile pe toate datele pînă în acea zi și calculați prognozele pe o zi h_t ; calculați EWMA cu $\lambda = 0,94$.
 2. Calculați media QLIKE pentru ambele modele și statistica t Diebold–Mariano.
 3. Numărați depășirile VaR 1% GARCH-t și VaR 1% EWMA-Normal și comparați-le cu numărul așteptat.
 4. Desenați diferența cumulată a pierderilor.
 5. Interpretare: ce model i-ați da unui manager de risc și ce ați mai corecta?
- **Raportați:** patru valori, două numere de depășiri, graficul și două fraze
- **Notebook:** secțiunea B5

B5: rezolvare [Rezolvat]



- 2944 de zile; media QLIKE: GARCH-t 0,761, EWMA 0,819; DM: diferența medie $-0,058$, $t = -3,69$ ($p < 0,001$): GARCH-t este mai bun
- Depășiri VaR 1%: GARCH-t 49 (1,66%), EWMA-Normal 65 (2,21%); așteptat circa 29
- Interpretare: GARCH-t, dar ambele modele VaR sînt depășite prea des; adăugăm efectul de levier (B3) și testăm formal depășirile (Capitolul 10)

B6: GARCH față de EWMA pentru DAX și BET [Propus]

- **Întrebarea:** se păstrează rezultatul din B5 pentru DAX și pentru BET? Model: B5.
- **Date:** DAX și BET din 2000; prognoze pentru fiecare zi începînd din ianuarie 2015
- **Cerințe**
 1. Calculați prognozele GARCH(1,1)-t și EWMA în afara eșantionului, ca în B5.
 2. Calculați media QLIKE pentru ambele modele și testul DM.
 3. Numărați depășirile VaR 1% pentru ambele modele.
 4. Interpretare: pentru care indice ajută cel mai mult GARCH și de ce?
- **Raportați:** un tabel și două fraze
- **Notebook:** secțiunea B6

C1: apropierea volatilității Bitcoin de cea a acțiunilor [Propus]

- ▣ **Întrebarea:** s-a apropiat volatilitatea Bitcoin de volatilitatea S&P 500 după 2021?
- ▣ **Date:** randamentele logaritmice zilnice Bitcoin și S&P 500, 2015–2019 și 2021–2026; modele: B1, B3
- ▣ **Cerințe**
 1. Estimați GJR-GARCH(1,1)-t pentru ambele serii, în ambele perioade, și raportați persistența, γ și ν .
 2. Calculați corelația logaritmilor celor două volatilități GARCH-t în zilele comune, în fiecare perioadă.
 3. Enumerați evenimentele din 2020–2024 care ar putea explica o schimbare.
 4. Interpretare: cum ați deosebi o schimbare durabilă de o schimbare produsă de o singură criză?
- ▣ **Raportați:** un tabel și un plan de proiect
- ▣ **Notebook:** secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI să interpreteze un GARCH(1,1)-t estimat pentru S&P 500 (date zilnice, din 2000): $\hat{\omega} = 0,0157$, $\hat{\alpha} = 0,123$, $\hat{\beta} = 0,872$, $\hat{\nu} = 6,26$. Răspunsul:
 - (a) $\alpha + \beta = 0,995$, deci un șoc de volatilitate dispare în aproximativ o săptămână.
 - (b) Varianța pe termen lung este $\omega/(1 - \alpha) = 0,018$, o volatilitate anuală de 2,1%.
 - (c) Un GJR estimat dă $\gamma = 0,205 > 0$: știrile bune cresc volatilitatea mai mult decât știrile proaste.
 - (d) Ljung-Box Q(10) al pătratelor reziduurilor standardizate = 13,6, $p = 0,19$: modelul GARCH-t este corect.
 - (e) Cu inovații Student-t, VaR 1% pe o zi este de 2,326 ori $\sigma(t+1)$.
 - (f) EWMA cu $\lambda = 0,94$ este un GARCH(1,1) cu $\omega = 0$, $\alpha = 0,06$, $\beta = 0,94$.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook (secțiunea C2).
 - ▶ 2. Raportați: o listă de șase verdicte, fiecare cu un rând de justificare.

Idei de reținut

- ▣ $\alpha + \beta$ decide tot ce ține de termenul lung: timpul de înjumătățire, varianța pe termen lung, forma prognozelor
- ▣ Riscul pe mai multe zile este suma prognozelor zilnice ale varianței, nu $\sqrt{H}$ ori volatilitatea de azi
- ▣ Inovațiile cu cozi groase schimbă cuantila VaR; asimetria schimbă VaR-ul după zilele proaste
- ▣ Comparăm prognozele în afara eșantionului (QLIKE, DM), nu doar în eșantion (AIC, BIC)
- ▣ Un răspuns AI este doar o primă versiune: verificați formula varianței pe termen lung, semnul lui γ și cuantila

După seminar

- ▣ Cursul 9 dezvoltă fiecare temă de azi: ARCH și GARCH, estimarea, inovațiile, asimetria, diagnosticul, prognozele, VaR
- ▣ Încercați cerințele [Propus] în notebook; rezolvările se discută la seminar
- ▣ C1 poate deveni un proiect de echipă: ferestre mobile, Ethereum și aurul ca termeni de comparație
- ▣ Lectură: [Franke, Härdle & Hafner \(2019\)](#), cap. 13; exerciții în [Borak, Härdle & López-Cabrera \(2013\)](#), cap. 13; [Tsay \(2010\)](#), cap. 3

Bibliografie

- Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- Bollerslev, T. (1987). A conditionally heteroskedastic time series model for speculative prices and rates of return. *Review of Economics and Statistics*, 69(3), 542–547.
- Bollerslev, T., Wooldridge, J.M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- Borak, S., Härdle, W.K., López-Cabrera, B. (2013). *Statistics of Financial Markets: Exercises and Solutions*, 2nd ed. Springer.
- Christie, A.A. (1982). The stochastic behavior of common stock variances: value, leverage and interest rate effects. *Journal of Financial Economics*, 10(4), 407–432.
- Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- Engle, R.F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- Engle, R.F., Ng, V.K. (1993). Measuring and testing the impact of news on volatility. *Journal of Finance*, 48(5), 1749–1778.
- Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- Glosten, L.R., Jagannathan, R., Runkle, D.E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- Hansen, B.E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- Ljung, G.M., Box, G.E.P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- Nelson, D.B. (1991). Conditional heteroskedasticity in asset returns: a new approach. *Econometrica*, 59(2), 347–370.
- Patton, A.J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- Tsay, R.S. (2010). *Analysis of Financial Time Series*, 3rd ed. Wiley.