



Statistica piețelor financiare

Seminarul 13: Învățare automată



Daniel Traian PELE

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognoză Economică

MSCA Digital Finance

Acronime folosite în acest material (1/2)

- ▣ **ACF**: Autocorrelation Function (funcția de autocorelație)
- ▣ **AI**: Artificial Intelligence (inteligență artificială)
- ▣ **AUC**: Area Under the (ROC) Curve (aria de sub curba ROC)
- ▣ **BET**: Bucharest Exchange Trading (index) — indicele de referință al Bursei de Valori București
- ▣ **BVB**: Bursa de Valori București
- ▣ **DM**: Diebold–Mariano (test) — testul Diebold–Mariano de comparare a prognozelor
- ▣ **EODHD**: EOD Historical Data (market-data provider) — furnizor de date de piață
- ▣ **GB**: Gradient Boosting (boosting pe gradient)
- ▣ **HAR**: Heterogeneous AutoRegressive (model) — model autoregresiv heterogen
- ▣ **HS**: Historical Simulation (simularea istorică)
- ▣ **ML**: Machine Learning (învățare automată)
- ▣ **MLP**: MultiLayer Perceptron (perceptron multistrat)
- ▣ **MSE**: Mean Squared Error (eroarea pătratică medie)

Acronime folosite în acest material (2/2)

- ▣ **OLS**: Ordinary Least Squares (metoda celor mai mici pătrate)
- ▣ **OMV**: Österreichische Mineralölverwaltung (Administrația austriacă a uleiurilor minerale, grupul OMV)
- ▣ **QGB**: Quantile Gradient Boosting (gradient boosting cu pierdere cuantică)
- ▣ **QLIKE**: Quasi-LIKelihood (loss function) — funcția de pierdere de tip cvasi-verosimilitate
- ▣ **QR**: Quantile Regression (regresie cuantică)
- ▣ **RF**: Random Forest (pădure aleatoare)
- ▣ **ROC**: Receiver Operating Characteristic (curve) — curba caracteristică de operare
- ▣ **SPX**: S&P 500 index (ticker symbol) — indicele S&P 500 (simbolul de tranzacționare)
- ▣ **SSE**: Sum of Squared Errors (suma pătratelor erorilor)
- ▣ **VIX**: CBOE Volatility Index (indicele de volatilitate CBOE)

Întrebarea de azi și traseul

- **Întrebarea:** cînd este o metodă flexibilă de predicție superioară unui model simplu pe date financiare și cum testăm acest lucru fără a trage concluzii eronate?
 - ▶ seminarul are loc **înaintea** Cursului 13: secțiunea „Noțiuni necesare azi” dă toate definițiile folosite în cerințe
- **Traseul**
 - ▶ Partea A: deplasare și varianță, o împărțire a unui arbore, ridge și lasso într-o dimensiune, scheme walk-forward și cu purging, pe hîrtie
 - ▶ Partea B: prognoze de volatilitate, semnul randamentelor și VaR 1% pe date reale, fiecare cu o întrebare de interpretare
 - ▶ Partea C: o întrebare deschisă pentru proiect și un răspuns AI de verificat
- Notebook-ul de azi: [deschideți notebook-ul seminarului în Google Colab](#); fiecare cerință indică secțiunea din notebook
- Seminarul are rol de exercițiu și nu se notează; rezolvările cerințelor [Propus] se discută la seminar

Harta exercițiilor

Cerința	Întrebarea	Tipul	Model
A1, A2	deplasarea, varianța și eroarea așteptată din cinci eșantioane de antrenare	Rezolvat, Propus	A1
A3, A4	cea mai bună împărțire a unui arbore de regresie, pas cu pas	Rezolvat, Propus	A3
A5, A6	ridge și lasso cu o singură variabilă	Rezolvat, Propus	A5
A7, A8	o schemă walk-forward; un K-fold cu purging și embargo	Rezolvat, Propus	A7
B1, B2	prognoze de volatilitate: S&P 500 (ziua următoare), DAX (săptămîna următoare)	Rezolvat, Propus	B1
B3, B4	semnul randamentelor zilnice: DAX; TLV și SNP	Rezolvat, Propus	B3
B5, B6	VaR 1% pentru DAX prin regresie cuantilică și quantile boosting	Rezolvat, Propus	B5
C1, C2	ajută S&P 500 la prognoza volatilității BET? ce este greșit într-un răspuns AI?	Propus	B2, A7

- **[Rezolvat]**: rezolvarea completă în slide-uri și în notebook, un model de urmat; **[Propus]**: îl rezolvați voi, după model

Datele folosite

Seria	Sursa	Prețurile folosite	Perioada
S&P 500	EODHD	deschidere, maxim, minim, închidere	2008–2026
DAX	EODHD	deschidere, maxim, minim, închidere	2006–2026
BET	EODHD	închidere	2008–2026
Banca Transilvania (TLV), OMV Petrom (SNP)	EODHD	închidere ajustată	2010–2026

- Randamente logaritmice zilnice în %: $r_t = 100 (\ln P_t - \ln P_{t-1})$; variabila proxy zilnică a varianței v_t din deschidere, maxim, minim și închidere ([Capitolul 8](#)); ultima zi este 18 septembrie 2026
- În notebook: `rv_frame('dax')`, `walk_forward(...)`, `rv_metrics(...)`, `sign_walk_forward('dax')`, `var_backtest(...)` (scikit-learn); nu este nevoie de cont sau de cheie


Noțiuni necesare azi (1/20): învățarea din date

- ▣ **Machine learning** (ML, învățare automată): alegem din date o regulă de predicție $\hat{f}$ cu o eroare mică pe date noi
 - ▶ x_t : **variabilele explicative** (features), valorile cunoscute la închiderea zilei t (volatilități și randamente trecute)
 - ▶ y_t : **ținta**, mărimea de prognozat; $\hat{y}_t = \hat{f}(x_t)$: prognoza (accentul circumflex marchează o estimatie)
- ▣ **Pierderea și eroarea pătratică medie** (MSE, mean squared error) pe n zile:

$$\text{MSE} = \frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2$$

- ▣ **Eroarea de antrenare**: MSE pe zilele folosite la estimarea lui $\hat{f}$; **eroarea de test**: MSE pe zile nefolosite
 - ▶ **overfitting**: o eroare de antrenare mică și o eroare de test mare: modelul a învățat zgomotul
 - ▶ un **hyperparametru** (adâncimea arborelui, penalizarea λ) fixează flexibilitatea; se alege pe date nefolosite la estimare

Noțiuni necesare azi (2/20): eroarea de antrenare și eroarea de test



- Simulare: $y = f(x) + \varepsilon$, arbori de adâncime 1–10 estimați pe 200 de eșantioane de antrenare
 - ▶ adâncimea: numărul de împărțiri succesive, flexibilitatea arborelui
- **Eroarea de antrenare** (ocru) scade spre 0 când adâncimea crește
 - ▶ un arbore adânc reproduce fiecare punct de antrenare, inclusiv zgomotul
- **Eroarea de test așteptată** (bleumarin) = deplasare² + varianță + σ^2 : în formă de U
 - ▶ deplasarea² (albastru) scade, varianța (roșu) crește; zgomotul σ^2 (verde) nu poate fi eliminat
 - ▶ adâncimea optimă este acolo unde eroarea de test este minimă, nu eroarea de antrenare


Noțiuni necesare azi (3/20): deplasare și varianță

- Modelul: $y = f(x) + \varepsilon$, cu $E[\varepsilon] = 0$ și $\text{Var}(\varepsilon) = \sigma^2$; $\hat{f}$ este estimat pe un eșantion de antrenare aleator
 - ▶ f : relația adevărată, necunoscută; ε : zgomotul; $E[\cdot]$: media după eșantioanele de antrenare și zgomot
- Eroarea pătratică așteptată într-un punct x_0 , cu $y_0 = f(x_0) + \varepsilon_0$:

$$E[(y_0 - \hat{f}(x_0))^2] = \underbrace{(E\hat{f}(x_0) - f(x_0))^2}_{\text{deplasare}^2} + \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{varianță}} + \underbrace{\sigma^2}_{\text{zgomot}}$$

- Din M eșantioane de antrenare, cu prognozele $\hat{f}_1, \dots, \hat{f}_M$ în x_0 :
 - ▶ $\bar{f} = \frac{1}{M} \sum_{m=1}^M \hat{f}_m$: prognoza medie; deplasarea = $\bar{f} - f(x_0)$: eroarea sistematică
 - ▶ varianța = $\frac{1}{M} \sum_{m=1}^M (\hat{f}_m - \bar{f})^2$: cât se modifică prognoza de la un eșantion la altul

Noțiuni necesare azi (4/20): arbori puțin adânci și adânci pe zece eșantioane




□ Liniile subțiri: estimările pe zece eșantioane de antrenare simulate; linia groasă: media lor $\bar{f}(x)$; linia întreruptă: $f(x)$ adevărată

- ▶ adâncimea 1 (stînga): cele zece estimări aproape coincid (varianță mică), dar $\bar{f}$ nu urmează forma lui f (deplasare mare)
- ▶ adâncimea 8 (dreapta): $\bar{f}$ urmează f (deplasare mică), dar fiecare estimare sare odată cu zgomotul eșantionului ei (varianță mare)

Noțiuni necesare azi (5/20): validarea pentru serii de timp

- **Walk-forward:** antrenăm pe trecut, testăm pe blocul următor (aici: un an calendaristic), reestimăm și avansăm
 - ▶ fereastra extinsă: eșantionul de antrenare păstrează toate zilele anterioare
- **Purging:** ținta y_t folosește zilele $t + 1, \dots, t + h$
 - ▶ h : orizontul țintei, în zile; ultimele h zile de antrenare au ținte în interiorul blocului de test, deci se elimină
 - ▶ **K-fold:** K blocuri în ordine temporală, fiecare fiind o dată bloc de test; **embargo:** eliminăm și câteva zile de antrenare imediat după blocul de test
- **Look-ahead bias:** o variabilă folosește informație încă necunoscută la momentul t (prețuri viitoare, medii pe tot eșantionul)
 - ▶ **leakage:** informația despre țintele de test ajunge în antrenare
 - ▶ **K-fold aleator** (partiții amestecate) îl produce când țintele se suprapun

Noțiuni necesare azi (6/20): walk-forward și K-fold cu purging



- Stînga: fiecare partiție antrenează pe toate zilele anterioare (albastru), elimină ultimele h dintre ele (roșu) și testează pe blocul următor (verde)
- Dreapta: K-fold în ordine temporală; zile de antrenare de ambele părți ale blocului de test
 - înaintea blocului de test: eliminăm h zile; după el: un embargo (ocru); zilele de antrenare = toate — test — eliminate — embargo

Noțiuni necesare azi (7/20): ridge și lasso

- ▣ **Ridge**: minimizăm eroarea pătratică plus o penalizare a pătratelor coeficienților

$$\hat{\beta}^R = \arg \min_{\beta} \sum_t (y_t - x_t^\top \beta)^2 + \lambda \sum_j \beta_j^2$$

- ▣ **Notățiile**

- ▶ $x_t^\top \beta = \sum_j \beta_j x_{tj}$: prognoza liniară; β_j : coeficientul variabilei j ; $\arg \min$: valoarea care minimizează
- ▶ $\lambda \geq 0$: penalizarea; $\lambda = 0$ dă OLS (metoda celor mai mici pătrate), un λ mare împinge coeficienții spre 0

- ▣ **Lasso**: același criteriu, cu valorile absolute ale coeficienților

$$\hat{\beta}^L = \arg \min_{\beta} \sum_t (y_t - x_t^\top \beta)^2 + \lambda \sum_j |\beta_j|$$

- ▣ **Interpretarea**

- ▶ lasso anulează exact unii coeficienți: selectează variabilele
- ▶ ambele acceptă o deplasare mică în schimbul unei varianțe mai mici; întîi standardizăm variabilele cu media și abaterea standard de antrenare

Noțiuni necesare azi (8/20): ridge și lasso cu o singură variabilă

- ▣ **O singură variabilă centrată** (cu media 0), fără termen liber

▶ $S_{xx} = \sum_t x_t^2$: suma pătratelor lui x ; $S_{xy} = \sum_t x_t y_t$: suma produselor încrucișate

- ▣ Cei trei estimatori:

$$\hat{\beta}^{OLS} = \frac{S_{xy}}{S_{xx}}, \quad \hat{\beta}^R = \frac{S_{xy}}{S_{xx} + \lambda}, \quad \hat{\beta}^L = \frac{\text{sign}(S_{xy}) \max(|S_{xy}| - \lambda/2, 0)}{S_{xx}}$$

- ▣ Ridge


▶ coeficientul OLS înmulțit cu **factorul de contracție** $S_{xx}/(S_{xx} + \lambda) < 1$; tinde la 0, dar nu îl atinge

- ▣ Lasso (**soft thresholding**)

▶ $\text{sign}(S_{xy})$: semnul, $+1$ sau -1 ; $\max(a, 0)$: a , dacă este pozitiv, și 0 în rest

▶ lasso scade $\lambda/2$ din $|S_{xy}|$; dacă $|S_{xy}| \leq \lambda/2$, coeficientul este exact 0

Noțiuni necesare azi (9/20): contracție și selecție




☐ Sus: coeficientul în funcție de λ , pentru $S_{xx} = 40$, $S_{xy} = 12$

- ▶ OLS: $12/40 = 0,30$ pentru orice λ
- ▶ ridge (albastru): o scădere lină, mereu peste 0
- ▶ lasso (roșu): o scădere liniară, exact 0 de la $\lambda = 2|S_{xy}| = 24$

☐ Jos: estimația în funcție de coeficientul OLS, pentru $\lambda = 20$ fixat

- ▶ ridge înmulțește orice coeficient cu același factor $40/60$
- ▶ lasso scade $\lambda/(2S_{xx}) = 0,25$ și anulează coeficienții mici

Noțiuni necesare azi (10/20): arborele de regresie



- **Împărțirea:** zilele cu $x_j \leq s$ merg la stînga, celelalte la dreapta; fiecare frunză prezice media valorilor y din ea
 - j : variabila folosită; s : pragul
- Alegem (j, s) cu cea mai mică sumă a pătratelor erorilor (SSE):

$$SSE(s) = \sum_{x_{tj} \leq s} (y_t - \bar{y}_L)^2 + \sum_{x_{tj} > s} (y_t - \bar{y}_R)^2$$

- **Notațiile și interpretarea**
 - $\bar{y}_L, \bar{y}_R$: mediile lui y în frunza din stînga și în cea din dreapta
 - candidații pentru s : mijloacele dintre valorile ordonate consecutive ale lui x_j
 - ponderea din SSE eliminată: $1 - SSE(s^*)/SSE_0$, cu $SSE_0 = \sum_t (y_t - \bar{y})^2$

Noțiuni necesare azi (11/20): random forest și gradient boosting

- **Random forest (RF)**: media a B arbori adânci

$$\hat{f}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B \hat{T}_b(x)$$

- Notațiile și interpretarea

- ▶ $\hat{T}_b$: arborele b , crescut pe un eșantion **bootstrap** (zile extrase aleator, cu întoarcere), cu o submulțime aleatoare de variabile la fiecare împărțire
- ▶ media a B arbori slab corelați reduce varianța; deplasarea rămîne cea a unui arbore adînc (mică)


- **Gradient boosting (GB)**: arbori mici adăugați pe rînd, fiecare estimat pe reziduurile curente

$$F_m(x) = F_{m-1}(x) + \nu \hat{T}_m(x), \quad \hat{T}_m \text{ estimat pe } y_t - F_{m-1}(x_t)$$

- Notațiile și interpretarea


- ▶ F_0 : media lui y ; F_m : modelul după m arbori; M : numărul de arbori
- ▶ $\nu \in (0, 1]$: **rata de învățare**; un ν mic cere mai mulți arbori, dar produce mai puțin overfitting

Noțiuni necesare azi (12/20): media arborilor și boosting



- Stînga: un singur arbore adînc (roșu) urmează fiecare punct simulat; pădurea de 300 de arbori (albastru) este netedă și aproape de f
- Dreapta: cu $\nu = 0,1$, boosting după $M = 1$ arbore este aproape media; după 10 arbori are forma generală; după 100 urmează și detaliile

Noțiuni necesare azi (13/20): rețele neuronale



- MLP (multilayer perceptron, perceptron multistrat) cu un strat ascuns de K neuroni:

$$\hat{y} = c + \sum_{k=1}^K v_k g(b_k + w_k^\top x)$$

- Notățiile

- w_k, b_k : ponderile și constanta neuronului k
- v_k, c : ponderile și constanta ieșirii
- $g(z) = \max(0, z)$ (ReLU): funcția de activare (sus)

- Interpretarea (jos)

- fiecare neuron adaugă o frângere în $x = -b_k/w_k$
- suma celor K neuroni este o funcție liniară pe porțiuni: o prognoză neliniară
- ponderile se estimează prin minimizarea MSE pe zilele de antrenare

Noțiuni necesare azi (14/20): variabila proxy a varianței zilnice

- ▣ **Variabila proxy a varianței zilnice** v_t (**Capitolul 8**), din deschiderea O_t , maximul H_t , minimul L_t și închiderea C_t :

$$v_t = o_t^2 + \frac{1}{2}(u_t - d_t)^2 - (2 \ln 2 - 1) c_t^2$$

- ▣ Notățiile (prețuri logaritmice, în %)

- ▶ $o_t = 100 \ln(O_t/C_{t-1})$: variația peste noapte; $u_t = 100 \ln(H_t/O_t)$, $d_t = 100 \ln(L_t/O_t)$: maximul și minimul față de deschidere
- ▶ $c_t = 100 \ln(C_t/O_t)$; ultimii doi termeni sînt estimatorul Garman–Klass al varianței din timpul ședinței



- ▣ **Ținta** pentru orizontul h (B1: $h = 1$; B2, C1: $h = 5$) și **prognoza varianței**:

$$y_t = \ln \left(\frac{1}{h} \sum_{j=1}^h v_{t+j} \right), \quad \hat{h}_t = \exp(\hat{y}_t + s^2/2)$$

- ▣ Interpretarea

- ▶ logaritmul face ținta aproape Normală; s^2 : varianța reziduurilor de antrenare ale lui y , care corectează deplasarea lui $\exp(\hat{y}_t)$

Noțiuni necesare azi (15/20): reperul HAR



— $\ln v_t$ (day) — $\ln v_t^{(w)}$ (5 days) — $\ln v_t^{(m)}$ (22 days) - - - $\pm 1.96/\sqrt{n}$

- Modelul **HAR** (heterogeneous autoregressive, autoregresiv heterogen), estimat prin OLS:

$$y_t = \beta_0 + \beta_d \ln v_t + \beta_w \ln v_t^{(w)} + \beta_m \ln v_t^{(m)} + u_t$$

- $v_t^{(w)} = \frac{1}{5} \sum_{j=0}^4 v_{t-j}$, $v_t^{(m)} = \frac{1}{22} \sum_{j=0}^{21} v_{t-j}$: mediile pe ultima săptămînă și ultima lună; u_t : eroarea

► $\beta_d, \beta_w, \beta_m$: ponderile zilei, săptămînii și lunii; trei medii reproduc scăderea lentă a ACF (funcția de autocorelație, dreapta)

Noțiuni necesare azi (16/20): evaluarea prognozelor

- ▣ R^2 în afara eșantionului față de o prognoză de referință $\tilde{y}_t$ (media de antrenare sau HAR):

$$R_{OOS}^2 = 1 - \frac{\sum_t (y_t - \hat{y}_t)^2}{\sum_t (y_t - \tilde{y}_t)^2}$$

- ▣ Interpretarea

► sumele parcurg doar zilele de test; $R_{OOS}^2 > 0$: mai bun decât reperul; < 0 : mai slab; se raportează în %

- ▣ Pierderea QLIKE a unei prognoze a varianței $\hat{h}_t$ pentru varianța realizată RV_t :

$$L_t = \frac{RV_t}{\hat{h}_t} + \ln \hat{h}_t$$

- ▣ Interpretarea

► $RV_t = \frac{1}{h} \sum_{j=1}^h v_{t+j}$: varianța care a urmat; L_t este minimă la $\hat{h}_t = RV_t$

► comparăm modelele prin QLIKE mediu pe zilele de test: mai mic este mai bun


Noțiuni necesare azi (17/20): testul Diebold–Mariano

- ▣ Testul **DM** (Diebold–Mariano) al acurateței egale a modelelor A și B pe n zile de test
 - ▶ diferența pierderilor $d_t = L_t^A - L_t^B$; $H_0: E[d_t] = 0$ (acuratețe egală)
- ▣ Statistica, cu o varianță pe termen lung Newey–West a lui d_t :

$$DM = \frac{\bar{d}}{\sqrt{\hat{\sigma}_{LR}^2/n}}, \quad \hat{\sigma}_{LR}^2 = \hat{\gamma}_0 + 2 \sum_{j=1}^{\ell} \left(1 - \frac{j}{\ell+1}\right) \hat{\gamma}_j$$

- ▣ Notățiile
 - ▶ $\bar{d}$: diferența medie a pierderilor; $\hat{\gamma}_j$: autocovarianța de selecție a lui d_t la lagul j
 - ▶ ℓ : numărul de laguri, aici orizontul h : țintele suprapuse fac d_t autocorelat
- ▣ Distribuția de referință și interpretarea
 - ▶ sub H_0 , $DM \approx N(0, 1)$; $|DM| > 1,96$: acuratețile diferă la 5%
 - ▶ $DM < 0$: modelul A are pierderea mai mică; $DM > 0$: modelul B

Noțiuni necesare azi (18/20): clasificarea



- **Logit:** probabilitatea ca mâine să fie o zi de creștere

$$\hat{p}_t = \frac{1}{1 + e^{-(\beta \mathbf{o} + x_t^\top \beta)}}$$


- prognoză „creștere” dacă $\hat{p}_t \geq 0,5$; acuratețea: ponderea semnelor corecte
 - reperul acc_0 : acuratețea prognozei constante a clasei mai frecvente

- Testul unui avantaj față de reper:

$$z = \frac{\widehat{\text{acc}} - \text{acc}_0}{\sqrt{\text{acc}_0(1 - \text{acc}_0)/n}}$$

- n : zilele de test; $z \approx N(0, 1)$ fără un avantaj real (jos);
 $z > 1,96$: semnificativ mai bun
 - **AUC:** aria de sub curba ROC (sus) = probabilitatea ca o zi de creștere aleasă aleator să primească un $\hat{p}$ mai mare decât o zi de scădere; 0,5: nicio abilitate

Noțiuni necesare azi (19/20): regresia cuantilică



- $\hat{q}_\alpha(x) = x^\top \hat{\beta}_\alpha$, cuantila condiționată de ordin α , minimizează $\sum_t \rho_\alpha(y_t - x_t^\top \beta)$, cu $\rho_\alpha(u) = u(\alpha - 1\{u < 0\})$ (stînga)
- $1\{u < 0\}$: 1 dacă $u < 0$, 0 în rest; o eroare sub cuantilă costă $(1 - \alpha)|u|$, deasupra ei $\alpha|u|$
 - în dreapta: linia de 1% coboară odată cu volatilitatea, deci VaR crește în zilele volatile; $\text{VaR } 1\% = -\hat{q}_{0.01}$

Noțiuni necesare azi (20/20): VaR prin simulare istorică și backtesting

- **Simularea istorică (HS):** $\text{VaR } 1\% = -\hat{q}_{0,01}$ din ultimele 500 de randamente (cuantila empirică)

▶ **depășire:** o zi cu $r_{t+1} < -\text{VaR}_t$; x : numărul depășirilor în n zile; $\hat{\pi} = x/n$

- **Testul Kupiec** al ratei, $H_0: \pi = \alpha$:

$$LR_{uc} = -2[(n-x)\ln(1-\alpha) + x\ln\alpha - (n-x)\ln(1-\hat{\pi}) - x\ln\hat{\pi}] \sim \chi^2(1)$$

- **Testul Christoffersen** al independenței, H_0 : o depășire azi nu schimbă șansa unei depășiri mâine:

$$LR_{ind} = -2[\ln L(\hat{\pi}) - \ln L(\hat{\pi}_{01}, \hat{\pi}_{11})] \sim \chi^2(1)$$

- **Notațiile și interpretarea**

▶ $\hat{\pi}_{01}, \hat{\pi}_{11}$: ponderile depășirilor după o zi fără și cu depășire; L : verosimilitatea secvenței 0-1

▶ respingem la 5% dacă $LR > 3,84$; pierderea cuantilică medie $\frac{1}{n} \sum_t \rho_\alpha(r_{t+1} + \text{VaR}_t)$: mai mică este mai bună

A1: deplasarea și varianța unui arbore puțin adînc [Rezolvat]

Cerință

- Într-un punct x_0 , valoarea reală este $f(x_0) = 2,0$ și $\sigma^2 = 0,25$. Un arbore de adîncime 1 estimat pe cinci eșantioane de antrenare prognozează 1,6; 1,7; 1,5; 1,8; 1,6.
- 1. Calculați prognoza medie și deplasarea.
- 2. Calculați varianța celor cinci prognoze (împărțiți la 5).
- 3. Calculați eroarea pătratică așteptată în x_0 .
- Raportați: patru valori și o frază.

Rezolvare

- 1. $\bar{f} = 8,2/5 = 1,640$; deplasarea = $1,640 - 2 = -0,360$
- 2.
 $[(-0,04)^2 + 0,06^2 + (-0,14)^2 + 0,16^2 + (-0,04)^2]/5 = 0,0104$
- 3. $0,1296 + 0,0104 + 0,25 = 0,390$
- Arborele puțin adînc este stabil, dar subestimează sistematic: eroarea lui provine în principal din deplasarea la pătrat.

A2: deplasarea și varianța unui arbore adînc [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Același punct și același zgomot ca în A1. Un arbore de adîncime 10, pe aceleași cinci eșantioane, prognozează 2,6; 1,4; 2,3; 1,7; 2,2. Model: A1.
- ▣ 1. Calculați prognoza medie, deplasarea și varianța.
- ▣ 2. Calculați eroarea pătratică așteptată.
- ▣ 3. Decideți ce arbore ați folosi în x_0 .
- ▣ Raportați: patru valori și o frază.

A3: o împărțire a unui arbore de regresie [Rezolvat]

Cerință

- Opt zile: x = randamentul absolut de ieri (%), y = variabila proxy a varianței de azi:
- x : 0,2; 0,4; 0,5; 0,9; 1,1; 1,6; 2,0; 2,8; y : 0,5; 0,7; 0,6; 1,0; 1,4; 2,2; 2,6; 3,4
- 1. Calculați media lui y și SSE fără împărțire.
- 2. Pentru fiecare împărțire candidată, calculați mediile celor două frunze și SSE total.
- 3. Alegeți cea mai bună împărțire și ponderea din SSE pe care o elimină.
- Raportați: tabelul, împărțirea și o frază.

Rezolvare

s	$\bar{y}_L$	$\bar{y}_R$	SSE
0,30	0,500	1,700	6,740
0,45	0,600	1,867	5,593
0,70	0,600	2,120	3,668
1,00	0,700	2,400	2,220
1,35	0,840	2,733	1,279
1,80	1,067	3,000	2,393
2,40	1,286	3,400	4,089

- $\bar{y} = 1,550$, $SSE = 8,000$; cea mai bună $s = 1,35$: frunzele 0,840 și 2,733, $SSE = 0,532 + 0,747 = 1,279$
- împărțirea elimină $1 - 1,279/8,000 = 0,840$ din SSE: mișcări mari ieri, varianță mare azi

A4: o împărțire după indicele de volatilitate [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Opt luni: x = nivelul VIX (indicele volatilității implicite a S&P 500, în % anual) la sfîrșitul lunii, y = volatilitatea realizată din luna următoare (% pe zi). Model: A3.
- ▣ x : 12, 14, 15, 17, 21, 24, 30, 38; y : 0,8; 0,9; 0,7; 1,1; 1,5; 1,4; 2,6; 3,0
- ▣ 1. Calculați SSE fără împărțire și pentru fiecare împărțire candidată.
- ▣ 2. Alegeți cea mai bună împărțire și precizați prognozele celor două frunze.
- ▣ 3. Calculați ponderea din SSE eliminată de împărțire.
- ▣ Raportați: tabelul, trei valori și o frază.

A5: ridge cu o singură variabilă [Rezolvat]

Cerință

- ▣ O singură variabilă centrată, cu $S_{xx} = 50$ și $S_{xy} = 20$; fără termen liber.
- ▣ 1. Calculați coeficientul OLS.
- ▣ 2. Calculați coeficientul ridge și factorul de contracție $S_{xx}/(S_{xx} + \lambda)$ pentru $\lambda = 10$ și $\lambda = 50$.
- ▣ 3. Explicați ce se întîmplă cînd $\lambda \rightarrow \infty$.
- ▣ Raportați: cinci valori și o frază.

Rezolvare

- ▣ 1. $\hat{\beta}^{OLS} = 20/50 = 0,40$
- ▣ 2. $\lambda = 10$: $20/60 = 0,333$, factorul 0,833; $\lambda = 50$: $20/100 = 0,20$, factorul 0,50
- ▣ 3. Coeficientul tinde la 0, dar nu devine niciodată 0.
- ▣ Ridge înmulțește coeficientul OLS cu un factor sub 1: contractă, nu selectează.

A6: lasso cu o singură variabilă [Propus]

Rezolvarea se discută la seminar

Cerință

- ▣ Aceleași date ca în A5: $S_{xx} = 50$, $S_{xy} = 20$. Model: A5.
- ▣ 1. Calculați coeficientul lasso pentru $\lambda = 10, 30$ și 50 .
- ▣ 2. Găsiți cel mai mic λ pentru care coeficientul este exact zero.
- ▣ 3. Comparați lasso cu rezultatele ridge din A5 pentru $\lambda = 50$.
- ▣ Raportați: patru valori și o frază.

A7: o schemă walk-forward [Rezolvat]

Cerință

- ▣ Variabile zilnice S&P 500 de la 8 aprilie 2008 la 18 septembrie 2026; ținta: varianța medie din următoarele 5 zile; reestimare în fiecare ianuarie din 2013.
- ▣ 1. Numărați partițiile evaluării walk-forward.
- ▣ 2. Pentru partiția din 2013, precizați ce zile de antrenare trebuie eliminate (purging) și de ce.
- ▣ 3. Explicați de ce nu este nevoie de embargo.
- ▣ 4. Explicați ce problemă ar apărea dacă hiperparametrii modelului pentru 2013 ar fi aleși prin 5-fold aleator pe 2008–2012.
- ▣ Raportați: două valori și trei fraze.

Rezolvare

- ▣ 1. O partiție pentru fiecare an 2013–2026: 14 partiții.
- ▣ 2. Ultimele 5 zile de antrenare (de la 24 decembrie 2012): țintele lor folosesc ianuarie 2013; partiția antrenează pe 1 188 de zile, ultima fiind 21 decembrie 2012, și testează pe 252.
- ▣ 3. Toate zilele de antrenare sînt înaintea anului de test: nicio variabilă de antrenare nu folosește informație de test.
- ▣ 4. Partițiile aleatoare pun zile vecine, cu ținte suprapuse, în antrenare și în validare: hiperparametrii aleși recompensează memorarea, nu prognoza.

A8: K-fold cu purging și embargo [Propus]

Rezolvarea se discută la seminar


Cerință

- ▣ 2500 de zile, $K = 5$ blocuri în ordine temporală, o țintă care folosește următoarele 21 de zile, un embargo de 1% din zile. Model: A7.
- ▣ 1. Calculați mărimea fiecărui bloc de test și a embargoului.
- ▣ 2. Calculați numărul de zile de antrenare cînd blocul de test este la mijloc.
- ▣ 3. Calculați-l cînd blocul de test este primul și cînd este ultimul.
- ▣ Raportați: patru valori și o frază.

B1: volatilitatea S&P 500 pentru ziua următoare [Rezolvat]

- ▣ **Întrebarea:** prognozează un random forest varianța de mâine a S&P 500 mai bine decât HAR?
- ▣ **Date:** deschiderea, maximul, minimul și închiderea S&P 500 din 2008; ținta: $\ln v_{t+1}$; variabilele: cele trei medii HAR
- ▣ **Cerințe**
 1. Estimați HAR (OLS) și un random forest (300 de arbori, cel puțin 20 de zile într-o frunză) walk-forward, reestimînd în fiecare ianuarie din 2013.
 2. Calculați R^2 în afara eșantionului pentru ambele modele față de media de antrenare și pentru random forest față de HAR.
 3. Calculați QLIKE mediu pentru ambele și testul Diebold–Mariano al egalității QLIKE.
 4. Desenați diferența QLIKE pe ani.
 5. Interpretare: merită aici complexitatea random forest?
- ▣ **Raportați:** patru valori, un test cu p-value-ul lui, graficul și două fraze
- ▣ **Notebook:** secțiunea B1

B1: rezolvare [Rezolvat]



- 3 448 de zile de la 2 ianuarie 2013; R^2_{OOS} față de medie: HAR 54,8%, random forest 53,4%; random forest față de HAR: -3,2%
- QLIKE: HAR 0,329, random forest 0,339; DM = +2,65 (p 0,008); random forest este mai bun doar în 3 din 14 ani
- Interpretare: nu: cu aceleași trei variabile, random forest este semnificativ mai slab decât HAR liniar; relația este aproape liniară în logaritmi, iar random forest adaugă varianță


B2: volatilitatea săptămînală a DAX [Propus]

- **Întrebarea:** sînt lasso, random forest, gradient boosting sau un MLP superioare modelului HAR pentru varianța DAX din săptămîna următoare? Model: B1.
- **Date:** deschiderea, maximul, minimul și închiderea DAX din 2006; ținta: logaritmul mediei lui v din următoarele 5 zile; 11 variabile (HAR, 4 laguri, media pe 66 de zile, r_t , $\min(r_t, 0)$, $|r_t|$)
- **Cerințe**
 1. Estimați cele cinci modele walk-forward din 2012, eliminînd ultimele 5 zile de antrenare.
 2. Calculați R^2 în afara eșantionului față de HAR și QLIKE mediu pentru fiecare model.
 3. Aplicați testul Diebold–Mariano pentru fiecare model față de HAR.
 4. Interpretare: ce model ați folosi pentru DAX?
- **Raportați:** un tabel și două fraze
- Notebook: secțiunea B2

B3: semnul randamentelor DAX [Rezolvat]

- **Întrebarea:** pot un logit sau un random forest să prezică dacă DAX crește mâine mai bine decât „mereu creștere”?
- **Date:** închiderile DAX din 2000; ținta $1\{r_{t+1} > 0\}$; variabilele: ultimele 5 randamente, sumele pe 5, 21 și 63 de zile, volatilitatea pe 21 și 63 de zile
- **Cerințe**
 1. Estimați ambii clasificatori walk-forward din 2008, reestimînd în fiecare ianuarie.
 2. Calculați acuratețea fiecărui model și a reperului clasei majoritare.
 3. Testați fiecare acuratețe față de reper cu statistica z și calculați AUC.
 4. Desenați acuratețea pe ani.
 5. Interpretare: are vreunul dintre modele o abilitate reală?
- **Raportați:** șase valori, graficul și două fraze
- Notebook: secțiunea B3

B3: rezolvare [Rezolvat]



- $n = 4\,752$ de zile; zile de creștere 53,1% = acuratețea reperului; logit 52,9% ($z = -0,20$, $p\,0,839$, AUC 0,507); random forest 52,0% ($z = -1,45$, $p\,0,146$, AUC 0,508)
- Logit prognozează „creștere” în 90% din zile; random forest depășește reperul în 8 din 19 ani, aproximativ cât s-ar obține din întâmplare
- Interpretare: nu: ambele acurateți sînt la nivelul reperului sau sub el, iar AUC este aproape de 0,5; randamentele zilnice ale DAX sînt aproape imprevizibile (Capitolul 7)


B4: semnul a două acțiuni BVB [Propus]

- **Întrebarea:** este semnul randamentelor Banca Transilvania și OMV Petrom mai ușor de prezis decât cel al DAX? Model: B3.
- **Date:** închiderile ajustate TLV (fără 30–31 mai 2016) și SNP din 2010; variabilele din B3; prognoze din 2014
- **Cerințe**
 1. Estimați logit, random forest și gradient boosting walk-forward din 2014.
 2. Calculați acuratețea, acuratețea reperului, statistica z și AUC pentru fiecare acțiune și model.
 3. Interpretare: există mai multă predictibilitate la BVB decât la DAX?
- **Raportați:** un tabel și două fraze
- Notebook: secțiunea B4

B5: VaR 1% pentru DAX prin regresie cuantilică [Rezolvat]

- ▣ **Întrebarea:** dă o regresie cuantilică liniară pe variabile de volatilitate un VaR 1% mai bun decât simularea istorică?
- ▣ **Date:** DAX din 2006; ținta r_{t+1} ; variabilele: $\sqrt{v_t}$, $\sqrt{v^{(w)}}$ și $\sqrt{v^{(m)}}$ (rădăcinile mediilor lui v pe 5 și 22 de zile), r_t
- ▣ **Cerințe**
 1. Estimați regresia cuantilică de nivel 1% walk-forward din 2012 și luați $\text{VaR } 1\% = -\hat{q}_{0,01}$.
 2. Calculați VaR 1% prin simulare istorică pe ultimele 500 de zile.
 3. Numărați depășirile, aplicați testele Kupiec și Christoffersen și calculați pierderea cuantilică medie.
 4. Desenați ambele prognoze VaR în 2020–2022.
 5. Interpretare: ce VaR ați raporta unui comitet de risc?
- ▣ **Raportați:** un tabel, graficul și două fraze
- ▣ **Notebook:** secțiunea B5

B5: rezolvare (1/2) [Rezolvat]



- 3731 de zile de la 2 ianuarie 2012; ultima estimare: $\hat{q}_{0,01} = -0,472 - 0,434\sqrt{v_t} - 1,814\sqrt{v^{(w)}} - 0,221\sqrt{v^{(m)}} + 0,158r_t$;
 VaR 1% pe 17 septembrie 2026: 2,24%

B5: rezolvare (2/2) [Rezolvat]

Metoda	x	rata (%)	p Kupiec	p ind.	pierdere $\times 100$
QR	39	1,05	0,783	0,364	3,80
HS	49	1,31	0,066	< 0,001	4,75

□ Coloanele

- ▶ x : numărul depășirilor; $\text{rata} = x/n$, ținta 1%; pierdere $\times 100$: pierderea cuantică medie
- ▶ p Kupiec, p ind.: p-value-urile testelor Kupiec (rata) și Christoffersen (independența)

- Interpretare: regresia cuantică: rată corectă, depășiri independente, pierdere mai mică; HS este depășit grupat (de 13 ori în 2020), deoarece o fereastră de 500 de zile reacționează lent

B6: quantile gradient boosting pentru DAX [Propus]

- ▣ **Întrebarea:** îmbunătățește un model cuantic flexibil regresia cuantică liniară din B5? Model: B5.
- ▣ **Date:** ca în B5; gradient boosting cu pierderea cuantică la 1%, 300 de arbori de adâncime 2, rata de învățare 0,05, cel puțin 50 de zile într-o frunză
- ▣ **Cerințe**
 1. Estimați quantile boosting walk-forward din 2012 și calculați VaR 1%.
 2. Numărați depășirile, aplicați testele Kupiec și Christoffersen și calculați pierderea cuantică.
 3. Interpretare: merită modelul flexibil la nivelul de 1%?
- ▣ **Raportați:** un tabel și două fraze
- ▣ Notebook: secțiunea B6

C1: ajută S&P 500 la prognoza volatilității BET? [Propus]

- ▣ **Întrebarea:** BVB se închide înaintea bursei din New York; îmbunătățește volatilitatea S&P 500 de ieri o prognoză HAR a varianței BET din săptămîna următoare?
- ▣ **Date:** închiderile BET și S&P 500 din 2008; proxy: randamentele zilnice la pătrat (BET nu are prețuri maxime și minime în datele noastre); modele: B1, B2
- ▣ **Cerințe**
 1. Construiți variabilele HAR ale BET și variabilele HAR ale S&P 500 de la închiderea precedentă din New York.
 2. Comparați HAR, HAR plus variabilele S&P 500 (OLS) și un random forest pe toate variabilele, walk-forward din 2012.
 3. Calculați R^2 în afara eșantionului, QLIKE și testele Diebold–Mariano față de HAR.
 4. Interpretare: merită adăugată informația din S&P 500?
- ▣ **Raportați:** un tabel și un plan de proiect
- ▣ Notebook: secțiunea C1

C2: verificați un răspuns AI [Propus]

- Un student a cerut unui asistent AI să rezume aplicarea machine learning la S&P 500. Răspunsul:
- (a) Cu validare încrucișată 5-fold aleatoare, un random forest explică 36,9% din randamentul următoarelor 21 de zile: piața este previzibilă.
- (b) Random forest explică logaritmul varianței din săptămîna următoare mai bine decît HAR: R^2 în eșantion 80,2% față de 73,7%.
- (c) Un random forest prezice corect semnul randamentului de mîine în 53,1% din zile, mai mult decît o monedă: are o abilitate reală.
- (d) Pentru VaR 99% folosiți regresia cuantilică cu $\tau = 0,99$ pe randamentul zilei următoare.
- (e) Lasso elimină variabilele ale căror statistici t nu sînt semnificative.
- (f) QLIKE penalizează o subestimare a varianței mai mult decît o supraestimare cu același factor.
- Cerințe
 - ▶ 1. Pentru fiecare afirmație, precizați dacă este corectă; dacă nu este, formulați afirmația corectă și, acolo unde se poate, dați valoarea corectă din notebook (secțiunea C2).
 - ▶ 2. Raportați: o listă de șase verdicte, fiecare cu un rînd de justificare.

Idei de reținut

- ▣ Eroarea așteptată este deplasare² + varianță + zgomot: flexibilitatea are un cost
- ▣ Serii de timp: walk-forward cu purging; nu amestecați niciodată zilele cu ținte suprapuse
- ▣ Volatilitatea: modelele liniare și penalizate sînt greu de depășit; arborii estimați doar pe variabilele HAR sînt inferiori
- ▣ Semnul randamentelor zilnice: comparați cu „mereu creștere”; aici niciun model nu îl depășește
- ▣ VaR 1%: o regresie cuantilică liniară trece testele; un model cuantilic flexibil la 1% nu le trece
- ▣ Un răspuns AI este o ciornă: verificați schema de validare, reperul și convenția VaR

După seminar

- ▣ Cursul 13 dezvoltă fiecare temă de azi: deplasarea și varianța, validarea, ridge și lasso, arborii și ansamblurile, rețelele neuronale, cele trei aplicații și data snooping
- ▣ Încercați cerințele [Propus] în notebook; rezolvările se discută la seminar
- ▣ C1 poate deveni un proiect de echipă: acțiuni BVB, piețe externe, mai multe orizonturi
- ▣ Lectură: [James et al. \(2023\)](#), cap. 2, 5, 6 și 8; [Franke, Härdle & Hafner \(2019\)](#), cap. 19

Bibliografie

- ▣ Christoffersen, P.F. (1998). Evaluating interval forecasts. *International Economic Review*, 39(4), 841–862.
- ▣ Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2), 174–196.
- ▣ Diebold, F.X., Mariano, R.S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets: An Introduction*, 5th ed. Springer.
- ▣ Friedman, J.H. (2001). Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- ▣ Hoerl, A.E., Kennard, R.W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.
- ▣ James, G., Witten, D., Hastie, T., Tibshirani, R., Taylor, J. (2023). *An Introduction to Statistical Learning with Applications in Python*. Springer.
- ▣ Koenker, R., Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50.
- ▣ Kupiec, P.H. (1995). Techniques for verifying the accuracy of risk measurement models. *Journal of Derivatives*, 3(2), 73–84.
- ▣ López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- ▣ Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society, Series B*, 58(1), 267–288.