



Statistica Piețelor Financiare

Seminar 1: Randamente și Staționaritate



Daniel Traian PELE
Antoaneta Amza

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognostic Economică
MSCA Digital Finance


Cuprins Seminar

- ▣ **Obiective** – Competențe vizate în seminar
- ▣ **Partea I: Calcul manual** – Tipuri de randamente și calcule
- ▣ **De la calcul la intuiție** – Sondaj rapid și variance drag intuitiv
- ▣ **Partea II: Variance Drag** – Formulă, exerciții și demonstrații
- ▣ **Partea III: Staționaritate** – Random walk, ADF, regresie falsă
- ▣ **Partea IV: Implementare Python** – Cod și vizualizări
- ▣ **Studiu de caz: S&P 500** – Analiză pe date reale
- ▣ **Rezumat** – Concluzii și competențe dobândite

Obiective de învățare — Seminar 1

La sfârșitul acestui seminar, veți fi capabili să:

1. **Calculați** randamente simple și logaritmice din date de preț
2. **Comparați** agregarea temporală a celor două tipuri de randamente
3. **Explicați** pierderea din varianță (variance drag) și impactul ei
4. **Argumentați** de ce analizăm randamente și nu prețuri (staționaritate)
5. **Implementați** calculul randamentelor în Python



Total: 90 min predare + studiu de caz și quiz ca material suplimentar

Exercițiul 1: Calcul randamente simple și logaritmice

Date de preț

t	0	1	2	3
P_t	100	110	99	120

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}} \text{ (simple)}$$

- ▣ $R_1 = 10/100 = +10.00\%$
- ▣ $R_2 = -11/110 = -10.00\%$
- ▣ $R_3 = 21/99 = +21.21\%$

$$r_t = \ln(P_t/P_{t-1}) \text{ (logaritmice)}$$

- ▣ $r_1 = \ln(1.10) = +9.531\%$
- ▣ $r_2 = \ln(0.90) = -10.536\%$
- ▣ $r_3 = \ln(1.2121) = +19.237\%$

Observație cheie

- ▣ $R_1 + R_2 = 0\%$, dar prețul a scăzut la 99! Randamentele simple **nu sunt aditive** — se compun multiplicativ: $\prod(1 + R_t)$.

Exercițiul 1: Aditivitate și comparație

Verificare: aditivitate log

- ▣ $r_1 + r_2 + r_3 = +18.232\%$
- ▣ $\ln(P_3/P_0) = \ln(1.20) = +18.232\% \checkmark$

Compunere simplă (multiplicativă)

$$\prod_{t=1}^3 (1 + R_t) = 1.10 \times 0.90 \times 1.2121 = 1.20$$

- ▣ $R_{\text{total}} = 20\%; \quad e^{r_{\text{total}}} - 1 = 20\% \checkmark$

	Per. 1	Per. 2	Per. 3	Total
R_t	+10.00	-10.00	+21.21	+20.00
r_t	+9.53	-10.54	+19.24	+18.23


- ▣ Unitate: %. Ambele metode $\Rightarrow$ aceeași avere finală.

Concluzie

- ▣ Log-randamentele se **adună**, simplele se **înmulțesc**
- ▣ Folosim log-randamente în modelarea statistică pentru aditivitate temporală

Vizualizare: Analiza randamentelor (S&P 500, 2000–2024)

Ch.1: Returns Analysis (S&P 500, 2000–2024)



- Scatter: corelație ≈ 0.9998 între R_t și r_t — aproape identice pentru valori mici
- Histogramă: cozi mai groase decât distribuția normală ($K = 13.4$, $S = -0.39$)

Sondaj rapid — Votați acum!

Întrebare

- Investiți **\$100** într-un activ. Acesta crește cu $+50\%$ într-un an, apoi scade cu -50% în anul următor.
- Cu cât rămâneți?

A)
\$100
(0% net)

B)
\$90
(-10%)

C)
\$75
(-25%)

D)
\$50
(-50%)

Sondaj rapid — Răspuns

Calcul

- ▣ $\$100 \times 1.50 = \150 , apoi $\$150 \times 0.50 = \text{\textcolor{red}{\$75}}$
- ▣ Pierdeți **25%**, nu 0%!

De ce?

- ▣ Creșterea de 50% se aplică pe \$100, dar scăderea de 50% se aplică pe \$150 — o *bază mai mare*
- ▣ Acesta este **variance drag** în acțiune: volatilitatea *distruge* averea
- ▣ Formula: pierdere $\approx \sigma^2/2$ pe an (vom demonstra în Partea II)

Discuție ghidată: De ce +50% și -50% nu se anulează?

Tocmai ați văzut: \$100 $\rightarrow$ \$150 $\rightarrow$ \$75. Dar cum arată cu log-randamente?

Randamente simple (multiplicative)

$$(1.50)(0.50) = 0.75 \neq 1.00$$

- ▣ $R_1 + R_2 = +50\% + (-50\%) = 0\%$
- ▣ Dar averea finală: \$75, nu \$100!
- ▣ Randamentele simple **nu** sunt aditive

Randamente log (aditive)

$$r_{\text{up}} = \ln(1.50) = +40.55\%$$

$$r_{\text{down}} = \ln(0.50) = -69.31\%$$

- ▣ Suma: $-28.77\% = \ln(0.75)$ ✓
- ▣ Log-randamentele reflectă **corect** pierderea

Mesaj cheie

- ▣ Asimetria este dramatică: trebuie +100% ca să recuperezi -50%
- ▣ Cu cât volatilitatea e mai mare, cu atât pierderea e mai severă

Variance Drag: Formulă și intuiție

Definiție 1 (Pierdere din varianță)

- Relația dintre randamentul aritmetic așteptat și cel geometric:

$$\mathbb{E}[r] \approx \mathbb{E}[R] - \frac{1}{2}\sigma^2$$

- $\mathbb{E}[R]$ — randamentul simplu așteptat
- $\mathbb{E}[r]$ — randamentul logaritmic așteptat
- σ^2 — varianța randamentelor simple

- Pierdere din varianță crește **cvadratic** cu volatilitatea: dublarea $\sigma \Rightarrow$ cvadruplarea pierderii
- Aceasta este o consecință a **inegalității lui Jensen**: $\mathbb{E}[\ln(1 + R)] < \ln(1 + \mathbb{E}[R])$ deoarece $\ln$ este concavă.
- Implicație**: volatilitatea *distruge* averea pe termen lung, chiar dacă randamentul aritmetic este pozitiv.

Exercițiul 2: Două active, aceeași medie, volatilitate diferită

Enunț

Activ	$\mathbb{E}[R]$	σ	$\mathbb{E}[r] \approx \mathbb{E}[R] - \sigma^2/2$
A	12%	10%	?
B	12%	30%	?

Rezolvare

- **Activ A:** $\mathbb{E}[r]_A \approx 0.12 - 0.5 \times (0.10)^2 = 0.12 - 0.005 = \mathbf{11.50\%}$
- **Activ B:** $\mathbb{E}[r]_B \approx 0.12 - 0.5 \times (0.30)^2 = 0.12 - 0.045 = \mathbf{7.50\%}$

Întrebare pentru studenți


- Care activ produce mai multă avere pe termen lung?
- Calculați W_{10} pentru ambele ($W_0 = 1$)

Exercițiul 2: Rezolvare — Avera pe termen lung

$$W_T = W_0 \cdot e^{T \times \mathbb{E}[r]}$$

- ▣ **A:** $W_{10} = e^{10 \times 0.115} = 3.16$ (triplare)
- ▣ **B:** $W_{10} = e^{10 \times 0.075} = 2.12$ (dublare)

Activ	$\mathbb{E}[R]$	σ	$\mathbb{E}[r]$	W_{10}
A	12%	10%	11.50%	3.16
B	12%	30%	7.50%	2.12



Concluzie cheie

- ▣ **Volatilitatea mare distruge averea!** Activul B are drag de 4.5%/an — pe 10 ani, costă $\approx 33\%$ din avere
- ▣ *“Volatility is the cost of uncertainty.”*

Exercițiile 3–5

Exercițiul 3: Aditivitatea log-randamentelor — Arătați că $r_{0,T} = \ln(P_T/P_0) = \sum_{t=1}^T r_t$

- ▣ *Indiciu:* scrieți $\frac{P_T}{P_0} = \frac{P_1}{P_0} \cdot \frac{P_2}{P_1} \cdots \frac{P_T}{P_{T-1}}$ și aplicați $\ln$ pe produs.

Exercițiul 4: Variance drag — Arătați că $\mathbb{E}[r] \approx \mathbb{E}[R] - \frac{1}{2}\sigma^2$

- ▣ Folosind dezvoltarea Taylor: $\ln(1+R) \approx R - R^2/2$, aplicați $\mathbb{E}[\cdot]$ pe ambii membri.
▣ *Indiciu:* $\mathbb{E}[R^2] = \text{Var}(R) + (\mathbb{E}[R])^2 \approx \sigma^2$ pentru $\mathbb{E}[R] \approx 0$.

Exercițiul 5: Inegalitatea lui Jensen — Deduceți că $\mathbb{E}[\ln(1+R)] \leq \ln(1+\mathbb{E}[R])$

- ▣ Funcția $f(x) = \ln(x)$ este concavă. Enunțați inegalitatea lui Jensen și interpretați: ce implică aceasta pentru relația dintre randamentul geometric și cel aritmetic?

Exercițiile 3–5: Soluții

Soluție Ex. 3 — Aditivitate

$$\square \quad \frac{P_T}{P_0} = \prod_{t=1}^T \frac{P_t}{P_{t-1}} \Rightarrow \ln\left(\frac{P_T}{P_0}\right) = \sum_{t=1}^T \underbrace{\ln\left(\frac{P_t}{P_{t-1}}\right)}_{=r_t} \quad \square$$

Soluție Ex. 4 — Variance drag

- $r = \ln(1 + R) \approx R - \frac{R^2}{2}$. Aplicăm $\mathbb{E}[\cdot]$:
- $\mathbb{E}[r] \approx \mathbb{E}[R] - \frac{1}{2}\mathbb{E}[R^2] = \mathbb{E}[R] - \frac{1}{2}(\sigma^2 + \mu^2) \approx \mathbb{E}[R] - \frac{1}{2}\sigma^2$ (deoarece $\mu^2 \ll \sigma^2$) □

Soluție Ex. 5 — Jensen

- Inegalitatea lui Jensen: dacă f concavă, atunci $\mathbb{E}[f(X)] \leq f(\mathbb{E}[X])$
- Cu $f = \ln$, $X = 1 + R$: $\mathbb{E}[\ln(1 + R)] \leq \ln(1 + \mathbb{E}[R])$
- Interpretare: randamentul geometric < randamentul aritmetic; diferența crește cu σ □

De ce lucrăm cu randamente, nu cu prețuri?

Prețuri: $P_t \sim I(1)$

- ▣ $\mathbb{E}[P_t]$, $\text{Var}(P_t)$ **nu** sunt constante
- ▣ Regresia pe prețuri $\Rightarrow$ **regresie falsă** (Granger & Newbold, 1974)

Randamente: $r_t \sim I(0)$

- ▣ Aproximativ staționare (medie ≈ 0 , varianță $\approx$ ct.)
- ▣ Metodele statistice sunt **valide**

Definiție 2 (Staționaritate slabă (covariance stationarity))

- ▣ Un proces $\{X_t\}$ este slab staționar dacă, $\forall t, h$:

$$\mathbb{E}[X_t] = \mu, \quad \text{Var}(X_t) = \sigma^2 < \infty, \quad \text{Cov}(X_t, X_{t+h}) = \gamma(h).$$

Consecință

- ▣ $P_t \sim I(1)$: nestaționară (rădăcină unitară)
- ▣ $r_t = \Delta \ln P_t \sim I(0)$: staționară
- ▣ Metodele clasice (OLS, teste t , F) **cer staționaritate**; pe serii $I(1)$ produc rezultate false

Random walk și non-staționaritate

Random walk: $P_t = P_{t-1} + \varepsilon_t$, $\varepsilon_t \stackrel{iid}{\sim} (0, \sigma^2)$

De ce P_t nu e staționară?

- ▣ Iterând: $P_t = P_0 + \sum_{s=1}^t \varepsilon_s$
- ▣ $\text{Var}(P_t) = t\sigma^2 \xrightarrow{t \rightarrow \infty} \infty$
- ▣ Variația **crește liniar** cu t




Dar $r_t = \Delta \ln P_t$ e staționară

- ▣ $\mathbb{E}[r_t] = \mu$ (constantă)
- ▣ $\text{Var}(r_t) = \sigma^2$ (constantă)
- ▣ $\text{Cov}(r_t, r_{t+h}) = \gamma(h)$ — doar de h

Strictă vs. slabă

- ▣ **Strictă**: distribuția conjunctă $(X_{t_1}, \dots, X_{t_k})$ invariantă la translații în timp
- ▣ **Slabă**: doar primele două momente invariante (suficient pentru OLS, ACF)
- ▣ Strictă $\Rightarrow$ slabă (dacă $\mathbb{E}[X_t^2] < \infty$), dar **nu** reciproc

Regresie falsă: Prețul Amazon vs. Abonații Netflix (2010–2020)



Pe niveluri (preț vs. abonați)

R^2	0.94
$\hat{\beta}$	0.63
t-stat	42.3
Concluzie	Falsă!

Pe diferențe (ΔP_t vs. ΔS_t)

R^2	0.06
$\hat{\beta}$	1.10
t-stat	2.7
Concluzie	Nicio relație

■ **Lecție:** Un preț de acțiune și un număr de abonați — variabile **complet diferite**, dar ambele cu trend $\Rightarrow$

Implementare Python: Descărcare și calcul

Descărcare date + randamente + statistici descriptive

```
import yfinance as yf
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.stattools import adfuller
from scipy.stats import jarque_bera

ticker = "AAPL"
data = yf.download(ticker, start="2020-01-01", end="2024-01-01")
data['log_ret'] = np.log(data['Close'] / data['Close'].shift(1))
data['simple_ret'] = data['Close'].pct_change()
r = data['log_ret'].dropna()

print(f"Media zilnica: {r.mean():.6f}")
print(f"Vol anualizata: {r.std() * np.sqrt(252):.4f}")
print(f"Skewness: {r.skew():.4f}")
print(f"Kurtosis: {r.kurtosis() + 3:.4f}") # scipy: excess
```

Implementare Python: Teste statistice

Testul ADF (staționaritate) și Jarque-Bera (normalitate)

```
# Testul ADF pe log-preturi vs. randamente
adf_price = adfuller(np.log(data['Close'].dropna()))
adf_ret    = adfuller(r)
print(f"ADF log-pret:    stat={adf_price[0]:.3f}, p={adf_price[1]:.4f}")
print(f"ADF randamente: stat={adf_ret[0]:.3f},    p={adf_ret[1]:.4f}")

# Testul Jarque-Bera
jb_stat, jb_p = jarque_bera(r)
print(f"\nJarque-Bera: JB={jb_stat:.1f}, p-value={jb_p:.2e}")

# ACF pe r_t si r_t^2
from statsmodels.tsa.stattools import acf
acf_r    = acf(r, nlags=30)
acf_r2   = acf(r**2, nlags=30)
```

▣ `adfuller` returnează: (statistic, p-value, lags, nobs, critical values)

▣ $p < 0.05 \Rightarrow$ respingem H_0 de rădăcină unitară

Exercițiu AI (I): Prompt Engineering

Cerință

- Formulați un prompt către un LLM (ChatGPT, Claude etc.) care să rezolve **complet** Exercițiul 1 din acest seminar
- Promptul trebuie să conțină: datele de intrare, formulele cerute, formatul de output dorit

Exemplu de prompt bun

- *“Am prețurile de închidere $P_0 = 100$, $P_1 = 110$, $P_2 = 99$, $P_3 = 120$. Calculează randamentele simple R_t și logaritmice r_t pentru fiecare perioadă. Verifică aditivitatea log-randamentelor. Prezintă rezultatele într-un tabel.”*

Întrebări de reflecție

- Răspunsul AI este corect matematic? Verificați cu calculul manual
- Ce se întâmplă dacă schimbați formularea? Obțineți alt rezultat?
- AI-ul a explicat **de ce** log-randamentele sunt aditive?

Exercițiu AI (II): Generare și Verificare Cod Python

Cerință

- ▣ Cereți unui LLM: *“Scrie cod Python care descarcă date AAPL pe 2020–2024, calculează randamente log, verifică staționaritatea cu testul ADF și afișează un grafic preț vs. randamente.”*
- ▣ Rulați codul generat — funcționează *as-is*?

Checklist de verificare

- ▣ Importurile sunt corecte? (yfinance, numpy, statsmodels)
- ▣ Formula randamentelor: `np.log(P/P.shift(1))` sau `pct_change()`?
 - ▶ Atenție: `pct_change()` = randamente **simple**, nu log!
- ▣ Testul ADF: interpretarea corectă a *p*-value?
- ▣ Graficul are titluri, axe etichetate, legendă?

Obiectiv pedagogic

- ▣ AI-ul este un **instrument**, nu un înlocuitor — codul generat trebuie **întotdeauna verificat**
- ▣ Eroarea tipică: confuzia între randamente simple și logaritmice

Discuție pe baza graficelor


Întrebări pentru studenți — analizând graficele generate

1. Care serie pare **staționară**? Care nu? De ce?
2. Unde observați **volatility clustering** (gruparea volatilității)?
 - ▶ Indiciu: priviți perioada martie 2020 (COVID-19).
3. Sunt randamentele mari urmate de randamente mari (de orice semn)?
4. Există perioade vizibil “calme” alternând cu cele “agitate”?

Fapte stilizate observabile vizual

- **Clustering**: perioadele volatile vin în grupuri
- **Cozi groase**: câteva randamente extreme (departe de medie)
- **Medie** ≈ 0 : randamentele fluctuează în jurul zero-ului
- Acestea sunt **faptele stilizate** ale randamentelor financiare (Cont, 2001)

Studiu de caz: S&P 500 — Preț vs. Randamente




Date utilizate

- Indicele S&P 500
- Perioada: 2000–2024
- Frecvență: zilnică

Ce observăm?

- Prețul: trend ascendent, crizele 2008 și 2020 vizibile
- Randamentele: oscilează în jurul lui zero
- Volatility clustering evident în perioadele de criză

Studiu de caz: S&P 500 — Testul ADF




Log-prețuri

- H_0 nu se respinge ($p = 0.98$)
- Serie nestaționară, $I(1)$
- Rădăcină unitară confirmată

Log-randamente

- H_0 se respinge la 1% ($p \approx 0$)
- Serie staționară, $I(0)$
- Metodele statistice sunt valide

Studiu de caz: ACF — Randamente vs. Randamente pătratic




$$ACF(r_t) \approx 0$$

- Randamentele **nu** sunt autocorelate
- Consistent cu ipoteza de piață eficientă (EMH)
- Nu putem prezice r_{t+1} din r_t

$$ACF(r_t^2) \neq 0 \text{ — declin lent}$$


- **Volatility clustering:** perioadele volatile persistă
- Faptul stilizat #1 (Cont, 2001)
- Motivația modelelor GARCH: σ_t^2 depinde de r_{t-1}^2

Studiu de caz: Variance Drag — Impact pe active reale



- **S&P 500** ($\sigma \approx 16\%$): pierdere din varianță $\approx 1.3\%/an$ — neglijabilă
- **Acțiuni individuale** ($\sigma \approx 30\text{--}40\%$): pierdere 4–8%/an — semnificativă
- **Bitcoin** ($\sigma \approx 75\%$): pierdere $\approx 28\%/an$ — devastatoare pe termen lung
- **Concluzie:** diversificarea reduce σ și astfel reduce variance drag

Studiu de caz: S&P 500 — Distribuția empirică vs. distribuția normală




Date reale: S&P 500 (2000–2024)

- $N = 6\,287$ randamente zilnice logaritmice
- Histograma empirică vs. curba Normală vs. Student- t

Ce observăm?

- Vârful central **mai ascuțit** decât distribuția normală
- Cozile **mai groase** — crahuri mult mai frecvente
- $S = -0.39$, $K = 13.4$ (Normal: $S = 0$, $K = 3$)
- Student- t cu $\nu \approx 3$ aproximează mai bine

Studiu de caz: QQ-Plot — Verificare vizuală a normalității



Cum citim un QQ-plot?

- Cuantilele eșantionului vs. cuantilele distribuției Normale
- Dacă datele sunt Normale $\Rightarrow$ punctele cad pe linia de 45°

Ce observăm?

- **Formă de S:** cozile deviază de la linie
 - Coada stângă: pierderi mai extreme decât prevede distribuția normală
 - Coada dreaptă: câștiguri mai extreme
- Testul Jarque-Bera confirmă formal:
 - $JB = \frac{n}{6} \left(S^2 + \frac{\kappa^2}{4} \right) \sim \chi^2_2$

Studiu de caz: Testul Jarque-Bera — Respingerea formală a normalității

Definiție 3 (Statistica Jarque-Bera)

- ▣ $H_0: r_t \sim \mathcal{N}(\mu, \sigma^2)$
- ▣ $JB = \frac{n}{6} \left(S^2 + \frac{(K-3)^2}{4} \right) \xrightarrow{d} \chi^2_2$
- ▣ $S = \text{skewness}$, $K = \text{kurtosis}$, $n = \text{dimensiune eșantion}$

Calcul pe S&P 500 (2000–2024, $n = 6\,287$)

$$\square JB = \frac{6287}{6} \left((-0.39)^2 + (13.4 - 3)^2 / 4 \right) = 1047.8 \times 27.19 = \mathbf{28\,488}$$

Activ	n	S	K	JB	$p\text{-value}$
S&P 500	6 287	−0.39	13.4	28 488	$< 10^{-16}$
AAPL	2 516	−0.31	8.6	3 168	$< 10^{-16}$
Bitcoin	3 287	−0.15	7.4	2 675	$< 10^{-16}$

- ▣ Valoare critică: $\chi^2_{2,0.01} = 9.21$
- ▣ Toate $JB \gg 9.21 \Rightarrow$ respingem H_0 la **orice** nivel de semnificație

Studiu de caz: Probabilitatea valorilor extreme

Cât de probabile sunt crahurile sub ipoteza de normalitate?

- Sub $\mathcal{N}(\mu, \sigma^2)$, un eveniment de 5σ are prob. $\approx 2.87 \times 10^{-7}$
- Black Monday** (19 oct. 1987): S&P 500 -22.6% într-o zi ($> 20\sigma$)

Magnitudine	Prob. Normală	Frecvență observată
Mișcare $> 3\sigma$	0.27% (1 la 370 zile)	~ 1 la 50–100 zile
Mișcare $> 4\sigma$	0.006% (1 la 16 000 zile)	~ 1 la 500–1000 zile
Mișcare $> 5\sigma$	1 la 3.5 mil. zile	~ 1 la 5000–10 000 zile

Concluzie

- Randamentele sunt **leptokurtice**
- Distribuția Normală subestimează dramatic riscul de coadă

Implicație practică

- VaR sub normalitate **subestimează** pierderile extreme
- Empiric $\approx$ Student- t cu $\nu \in [4, 8]$

Studiu de caz: Momente empirice — Comparație între active

- Statistici eșantion pentru randamente logaritmice zilnice, S&P 500 (2000–2024), restul (2015–2024):

Activ	Medie	Std	Skewness	Kurtosis	Min	Max
S&P 500	+0.040%	1.00%	−0.39	13.4	−12.8%	+9.4%
AAPL	+0.058%	1.80%	−0.31	8.6	−13.0%	+11.9%
Bitcoin	+0.195%	3.90%	−0.15	7.4	−46.5%	+22.5%
EUR/USD	+0.000%	0.45%	+0.08	5.2	−2.7%	+3.1%

- Toate activele: excess kurtosis $\gg 0 \Rightarrow$ cozi groase (fat tails) confirmate
- Acțiuni și indici: skewness negativ $\Rightarrow$ riscul de crah domină
- Bitcoin: volatilitate maximă ($\sigma = 3.9\%$ zilnic $\approx 62\%$ anual)
- EUR/USD: medie ≈ 0 , aproape simetrică, dar cozi groase

Temă pentru acasă: Seminar 1

Analiza unei acțiuni românești (BVB)

- ▣ Alegeți o acțiune listată la Bursa de Valori București (ex.: TLV, SNP, BRD, FP, SNG). Perioadă: min. 3 ani.

Cerințe de calcul

1. Randamente log zilnice (grafic)
2. Statistici descriptive: $\hat{\mu}$, $\hat{\sigma}$, S , K
3. Volatilitatea anualizată ($\times \sqrt{252}$)
4. **Testul ADF** pe log-prețuri și pe randamente (raportați statistica, p -value, concluzie)
5. **Testul Jarque-Bera**: calculați JB , raportați p -value, interpretați

Cerințe de interpretare

- ▣ Sunt randamentele staționare? (ADF)
- ▣ Sunt normal distribuite? (JB)
- ▣ Comparați σ cu S&P 500 ($\approx 16\%$ anual)
- ▣ Calculați variance drag-ul — e semnificativ?

Termen

- ▣ Următorul seminar
- ▣ Cod Python + grafice + 1 pagină interpretare

Ce trebuie să știți la finalul Seminarului 1

Checklist de competențe

- ✓ **Diferența simplu vs. log:** simple sunt multiplicative, log sunt aditive temporal
- ✓ **Compunerea randamentelor:** $1 + R_{\text{total}} = \prod (1 + R_t)$ vs. $r_{\text{total}} = \sum r_t$
- ✓ **Variance drag:** $\mathbb{E}[r] \approx \mathbb{E}[R] - \sigma^2/2$; volatilitatea distruge averea
- ✓ **Motivul staționarității:** $P_t \sim I(1)$, $r_t \sim I(0)$; metodele statistice cer staționaritate
- ✓ **Implementare Python:** descărcare date, calcul r_t , grafice preț vs. randamente

Nivel cognitiv atins

- | | |
|--|--|
| ☐ Calcul operațional (manual + cod) | ☐ Legătura matematică-finanțe |
| ☐ Interpretare economică | ☐ Început de gândire critică |

Structura seminarelor — Capitolul 1 (4 săptămâni)

Sem.	Tema	Conținut	Temă
1	Randamente și staționaritate (acest seminar)	Calcul R_t , r_t ; variance drag; $I(1)$ vs $I(0)$; Python intro	Analiză acțiune BVB: randamente
2	Volatilitate	CC, rolling vol, $\sqrt{T}$; EWMA; comparație 20 vs 60z	Volatilitate 30z pentru acțiune BVB
3	Fapte stilizate	Skew, kurtosis, QQ-plot; $ACF(r_t)$; normalitate	Jarque-Bera test; verificare normalitate
4	Performanță și risc	Sharpe, MDD, Sortino; mini-proiect complet	Mini-proiect: analiză completă

Test rapid — Seminar 1 (15 minute)

Răspundeți pe foaie (fără note)

1. Scrieți cele **3 condiții** ale staționarității slabe (covariance stationarity).
2. De ce $ACF(r_t) \approx 0$ dar $ACF(r_t^2) \neq 0$? Ce model motivează acest fapt?
3. Un activ are $\mathbb{E}[R] = 10\%$, $\sigma = 40\%$. Calculați variance drag-ul și averea după 20 de ani ($W_0 = 1$). Interpretați.
4. Un $R^2 = 0.92$ între prețul acțiunii A și prețul acțiunii B indică neapărat o relație reală? Argumentați.
5. Pentru un eșantion cu $n = 1000$, $S = -0.5$, $K = 8$, calculați statistica Jarque-Bera și concluzionați.

Test rapid — Răspunsuri

Răspunsuri

1. $\mathbb{E}[X_t] = \mu$; $\text{Var}(X_t) = \sigma^2 < \infty$; $\text{Cov}(X_t, X_{t+h}) = \gamma(h)$ — primele două momente constante, autocovarianța depinde doar de lag-ul h .
2. Randamentele sunt necorelate (EMH) dar **nu independente**: magnitudinea lor este autocorelată. $\text{ACF}(r_t^2)$ captează **volatility clustering** $\Rightarrow$ motivație GARCH.
3. $\text{Drag} = \sigma^2/2 = 0.40^2/2 = 8\%/an$. $\mathbb{E}[r] = 10\% - 8\% = 2\%/an$. $W_{20} = e^{20 \times 0.02} = 1.49$. Randamentul aritmetic de 10% se “topește” la doar 2% geometric — volatilitatea extremă distruge averea.
4. **Nu**. Ambele prețuri pot fi $I(1)$ cu trenduri comune (spurious regression, Granger & Newbold 1974). Trebuie testat pe randamente (R^2 scade dramatic) sau testat cointegrarea.
5. $JB = \frac{1000}{6}((-0.5)^2 + (8 - 3)^2/4) = 166.7 \times (0.25 + 6.25) = \mathbf{1083.3}$. $\chi_{2,0.01}^2 = 9.21$. $1083.3 \gg 9.21 \Rightarrow$ respingem H_0 de normalitate.

Bibliografie și resurse

Referințe cheie

- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets*. 4th Ed., Springer.
- ▣ Cont, R. (2001). Empirical Properties of Asset Returns. *Quantitative Finance*, 1(2), 223–236.
- ▣ Dickey, D.A., Fuller, W.A. (1979). Distribution of the Estimators for AR Time Series with a Unit Root. *JASA*, 74, 427–431.
- ▣ Granger, C.W.J., Newbold, P. (1974). Spurious Regressions in Econometrics. *J. of Econometrics*, 2(2), 111–120.
- ▣ Mandelbrot, B. (1963). The Variation of Certain Speculative Prices. *J. of Business*, 36(4), 394–419.

Resurse online

- ▣ **GitHub:** https://github.com/QuantLet/Stat_fin_markets — cod Python complet
- ▣ **Quantlet:** <https://quantlet.com> **Quantinar:** <https://quantinar.com>

Vă mulțumesc! Întrebări? Materialele seminarului sunt disponibile la:

<https://danpele.github.io/SFM/>



Quantlet



Quantinar