Statistica Pieței Financiare

Seminar 2: Distribuții Stabile

Daniel Traian PELE
Antoaneta Amza

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognoză Economică
MSCA Digital Finance

Obiective de învățare

La finalul seminarului veți putea:

- Verifica proprietatea de stabilitate pentru Gaussiană și Cauchy
- Calcula funcția caracteristică a unei distribuții stabile
- Analiza momentele și comportamentul cozilor
- Estima parametrii unei distribuții stabile (McCulloch, MLE)
- Compara VaR: Gaussiană vs Stabilă vs Empiric
- Implementa fit-ul stabil în Python

I. Exerciții manual (25 min)
↓
II. Estimare (20 min)
↓
III. Cozi și risc (15 min)
↓
IV. Python (30 min)

Exercițiul 1: Verificarea stabilității — Cazul Gaussian

Problemă

Fie X_1, X_2 variabile i.i.d. $\sim \mathcal{N}(0,1)$. Arătați că $aX_1 + bX_2 \stackrel{d}{=} cX + d$ pentru $a = 3, b = 4, c = 5$.

Rezolvare

Dacă $X_1 \sim \mathcal{N}(0,1)$, atunci $aX_1 \sim \mathcal{N}(0, a^2)$ și $bX_2 \sim \mathcal{N}(0, b^2)$.
Suma: $aX_1 + bX_2 \sim \mathcal{N}(0, a^2 + b^2) = \mathcal{N}(0, 9 + 16) = \mathcal{N}(0, 25)$.
Deci $c = \sqrt{a^2 + b^2} = \sqrt{25} = 5$ și $d = 0$.

Concluzie: Distribuția normală este stabilă cu $\alpha = 2$. Proprietatea de stabilitate se reduce la regula adunării varianțelor.

Exercițiul 1 cont.: Cazul Cauchy + Tabel comparativ

Cazul Cauchy ($\alpha = 1$)

Fie $X_1, X_2 \sim \text{Cauchy}(0, 1)$ i.i.d.
$aX_1 + bX_2 \sim \text{Cauchy}(0, a + b)$
Pentru $a = 3, b = 4$: $c = a + b = 7$, $d = 0$.

Notă: La Cauchy, scara se adună *liniar*, nu pătratic!

Regula generală

Pentru $S(\alpha, \beta, \gamma, \delta)$:

$$c^\alpha = a^\alpha + b^\alpha$$

	α	Regulă	c
Gaussian	2	$c^2 = a^2 + b^2$	5
Cauchy	1	$c = a + b$	7
$S(1.5)$	1.5	$c^{1.5} = a^{1.5} + b^{1.5}$	6.19

Exercițiul 2: Funcția caracteristică

Problemă

Calculați $\varphi_X(t)$ pentru $X \sim S(1.5, 0.3, 1, 0)$ la $t = 1$.

Rezolvare

Funcția caracteristică a distribuției stabile:

$$\log \varphi_X(t) = -|t|^\alpha \left[1 - i\beta \operatorname{sgn}(t) \tan \frac{\pi\alpha}{2}\right] + i\delta t$$

Pentru $\alpha = 1.5$, $\beta = 0.3$, $\gamma = 1$, $\delta = 0$, $t = 1$:

$$\log \varphi_X(1) = -|1|^{1.5} \left[1 - i \cdot 0.3 \cdot 1 \cdot \tan \frac{3\pi}{4}\right]$$

$$= -1 \cdot [1 - i \cdot 0.3 \cdot (-1)] = -1 - 0.3i$$

Deci:

$$\varphi_X(1) = e^{-1-0.3i} = e^{-1}(\cos 0.3 - i \sin 0.3) \approx 0.351 - 0.109i$$

$$|\varphi_X(1)| = e^{-1} \approx 0.368$$

Exercițiul 3: Momente și cozi

Problemă

Un analist financiar modelează randamentele zilnice cu $S(1.7, -0.2, 0.01, 0.0005)$. Care momente există? Ce implică pentru managementul riscului?

Rezolvare

Existența momentelor:

- $\mathbb{E}[|X|^p] < \infty$ dacă și numai dacă $p < \alpha$
- $\alpha = 1.7 \Rightarrow$
  - Media ($p = 1$): există ($1 < 1.7$)
  - Varianța ($p = 2$): nu există ($2 > 1.7$)
  - Kurtosis ($p = 4$): nu există

Implicații practice:

- $\beta = -0.2$: asimetrie negativă (risc la căderi)
- VaR Gaussian **subestimează** riscul real
- Probabilitatea unui eveniment -5σ:
  - Normal: $\approx 3 \times 10^{-7}$ (1 la 3.5M zile)
  - Stabil(1.7): ≈ 0.003 (1 la 333 zile)
- Sharpe ratio nu este definit riguros!

Metoda McCulloch — Concept

Ideea principală

Estimarea parametrilor $(\alpha, \beta, \gamma, \delta)$ din **cuantile** ale eșantionului.

Statistici intermediare:

$$v_\alpha = \frac{q_{0.95} - q_{0.05}}{q_{0.75} - q_{0.25}}$$

$$v_\beta = \frac{q_{0.95} + q_{0.05} - 2q_{0.50}}{q_{0.95} - q_{0.05}}$$

- v_α măsoară *greutatea cozilor* (tail thickness)
- v_β măsoară *asimetria*

Tabel de referință (selecție):

v_α	α	Interpretare
2.44	2.0	Gaussiană
2.62	1.9	Aproape Gauss
3.04	1.7	Cozi moderate
4.21	1.5	Cozi grele
6.31	1.3	Cozi foarte grele

McCulloch — Exercițiu rezolvat

Date numerice

Din eșantionul de 2000 observații: $q_{0.05} = -3.42$, $q_{0.25} = -0.78$, $q_{0.50} = 0.05$, $q_{0.75} = 0.82$, $q_{0.95} = 3.61$.

Rezolvare pas cu pas

Pasul 1: Calculăm v_α

$$v_\alpha = \frac{q_{0.95} - q_{0.05}}{q_{0.75} - q_{0.25}} = \frac{3.61 - (-3.42)}{0.82 - (-0.78)} = \frac{7.03}{1.60} = 4.39$$

Pasul 2: Estimăm α Din tabel: $v_\alpha = 4.39$ corespunde $\hat{\alpha} \approx 1.48$.

Pasul 3: Calculăm v_β

$$v_\beta = \frac{q_{0.95} + q_{0.05} - 2q_{0.50}}{q_{0.95} - q_{0.05}} = \frac{3.61 + (-3.42) - 2 \cdot 0.05}{7.03} = \frac{0.09}{7.03} \approx 0.013$$

Pasul 4: Estimăm β $v_\beta \approx 0.013 \approx 0 \Rightarrow \hat{\beta} \approx 0$ (distribuție aproape simetrică).

Maximum Likelihood Estimation (MLE)

Procedura

$$\hat{\theta}_{MLE} = \arg\max_{\theta} \sum_{i=1}^{n} \log f(x_i; \alpha, \beta, \gamma, \delta)$$

Provocări:

- PDF-ul nu are formă închisă (în general)
- Trebuie evaluare numerică prin FFT
- Funcția de verosimilitate nu e convexă
- Convergență lentă pentru α mic

Avantaje:

- Cea mai eficientă estimare asimptotic
- Intervale de încredere standard
- Implementare modernă: `scipy.stats.levy_stable.fit()`

One-liner Python:

```
from scipy.stats import levy_stable
a, b, loc, sc = levy_stable.fit(data)
```

Regresia Koutrouvelis

Metoda în 2 etape

Se utilizează funcția caracteristică empirică (ECF).

Etapa 1: Estimarea α și γ prin regresie liniară:

$$\log\left(-\log|\hat{\varphi}_n(t)|^2\right) = \log(2\gamma^\alpha) + \alpha\log|t|$$

Regresie $Y = a + bX$ cu $Y_k = \log(-\log|\hat{\varphi}_n(t_k)|^2)$ și $X_k = \log|t_k|$.

Etapa 2: Estimarea β și δ prin regresie pe partea imaginară:

$$\arg[\hat{\varphi}_n(t)] = \delta t - \beta\gamma^\alpha \tan\frac{\pi\alpha}{2}\,\mathrm{sgn}(t)|t|^\alpha$$

Avantaj

Robustă numeric, nu necesită evaluarea PDF-ului, convergență rapidă.

Heavy tails — Gaussiană vs Stabilă

SFM_ch2_stable_fit

Tabel comparativ: Probabilitatea evenimentelor extreme

Eveniment	Gaussiană	Stabil(α=1.7)	Raport
$\lvert X\rvert > 3\sigma$	2.7×10^{-3}	1.9×10^{-2}	$\approx 7\times$
$\lvert X\rvert > 5\sigma$	5.7×10^{-7}	3.0×10^{-3}	$\approx 5{,}000\times$
$\lvert X\rvert > 10\sigma$	1.5×10^{-23}	5.2×10^{-4}	$\approx 10^{19}\times$

Implicație practică

Modelele Gaussiene subestimează dramatic riscul evenimentelor extreme. Un eveniment "10σ" pe care Gaussiana îl consideră practic imposibil apare o dată la $\sim$2,000 de zile ($\sim$8 ani) sub modelul stabil.

Exercițiul 4: VaR Gaussiană vs Stabilă

Problemă

Portofoliu de 1,000,000 EUR. Randamente zilnice modelate cu $S(1.7, -0.2, 0.01, 0.0005)$. Comparați VaR la 1%, 5% și 0.1%.

Rezolvare

Nivel VaR	Gaussiană	Stabilă	Diferență
5%	−16,449 EUR	−21,340 EUR	+30%
1%	−22,763 EUR	−39,870 EUR	+75%
0.1%	−30,091 EUR	−87,420 EUR	+190%

Concluzie: Cu cât nivelul de încredere este mai mare (cozi mai adânci), cu atât diferența Gaussiană vs Stabilă crește. La VaR 0.1%, modelul stabil estimează pierderi de aproape **3 ori mai mari**.

Comparație vizuală: Funcția de supraviețuire

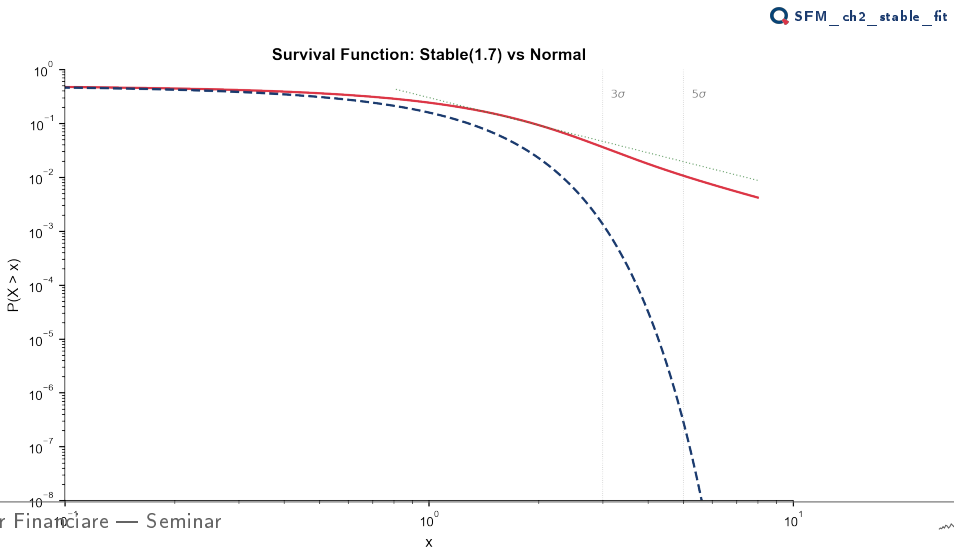

Simulare: Stable Distributions

```
import numpy as np
from scipy.stats import levy_stable
import matplotlib.pyplot as plt

alphas = [0.5, 1.0, 1.5, 2.0]
x = np.linspace(-8, 8, 1000)

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 5))
colors = ['#DC3545', '#FF8C00', '#2E7D32', '#1A3A6E']
labels = ['alpha=0.5 (Levy)', 'alpha=1.0 (Cauchy)',
          'alpha=1.5', 'alpha=2.0 (Gaussian)']

for a, c, lab in zip(alphas, colors, labels):
    pdf = levy_stable.pdf(x, alpha=a, beta=0)
    ax1.plot(x, pdf, color=c, label=lab)
    ax2.semilogy(x, pdf, color=c, label=lab)

ax1.set_title('PDFs (linear)')
ax2.set_title('PDFs (log scale)')
for ax in [ax1, ax2]:
    ax.legend(loc='upper center',
              bbox_to_anchor=(0.5, -0.12), ncol=2)
plt.tight_layout()
```

Python: Stable Fit S&P 500

```
import yfinance as yf
from scipy.stats import levy_stable, norm

sp500 = yf.download('^GSPC', start='2000-01-01',
                    end='2025-12-31')
returns = np.log(
    sp500['Close'] / sp500['Close'].shift(1)).dropna()

# Fit stable distribution
alpha, beta, loc, scale = levy_stable.fit(returns.values)
print(f"alpha={alpha:.3f}, beta={beta:.3f}")

# Fit normal
mu, sigma = norm.fit(returns.values)

# Compare on log-scale
x = np.linspace(returns.min()*1.2,
                returns.max()*1.2, 1000)
plt.hist(returns, bins=150, density=True,
         alpha=0.4, label='Data')
plt.semilogy(x, levy_stable.pdf(x, alpha, beta,
             loc, scale), label='Stable')
plt.semilogy(x, norm.pdf(x, mu, sigma),
             '--', label='Normal')
```

Overlay PDF: Histogram + Stable + Normal (log-scale)

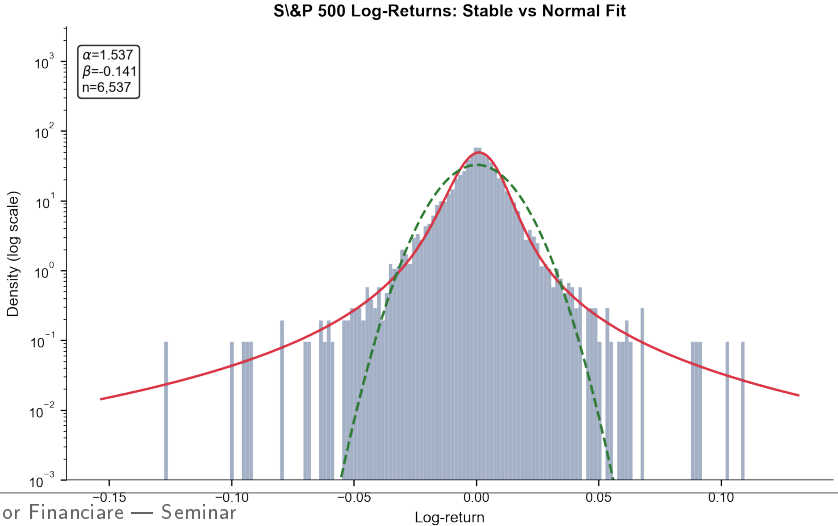

Python: VaR Comparison

```python
# VaR comparison
levels = [0.01, 0.05, 0.001]
for cl in levels:
    var_s = levy_stable.ppf(
        cl, alpha, beta, loc, scale)
    var_n = norm.ppf(cl, mu, sigma)
    var_e = np.percentile(
        returns, cl*100)
    print(f"VaR {cl*100:.1f}%:")
    print(f"  Stable:    {var_s:.5f}")
    print(f"  Normal:    {var_n:.5f}")
    print(f"  Empirical: {var_e:.5f}")
```

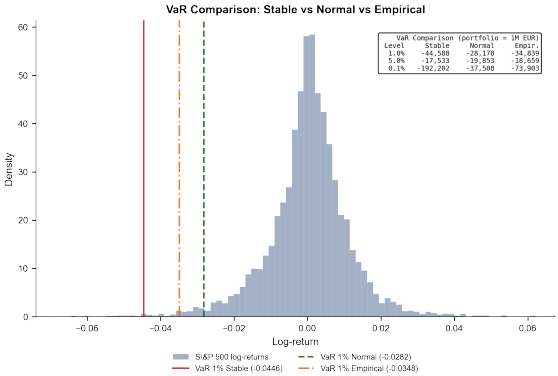

Exercițiu AI: Prompt Engineering

Exercițiu

Folosiți ChatGPT sau Claude pentru a genera cod Python care:

1. Descarcă datele BTC-USD din ultimii 5 ani
2. Fit-ează o distribuție stabilă pe log-randamentele zilnice
3. Compară grafic PDF stabilă vs normală (log-scale)
4. Calculează VaR la 1% și 5%
5. Realizează un backtest: câte zile au depășit VaR-ul estimat?

Prompt sugerat

"Write Python code using scipy.stats.levy_stable to fit a stable distribution to BTC-USD daily log-returns from yfinance. Plot histogram with stable and normal overlay on log-scale. Calculate VaR at 1% and 5% for both distributions and backtest against actual returns."

Histogram + Fit stabil vs Normal

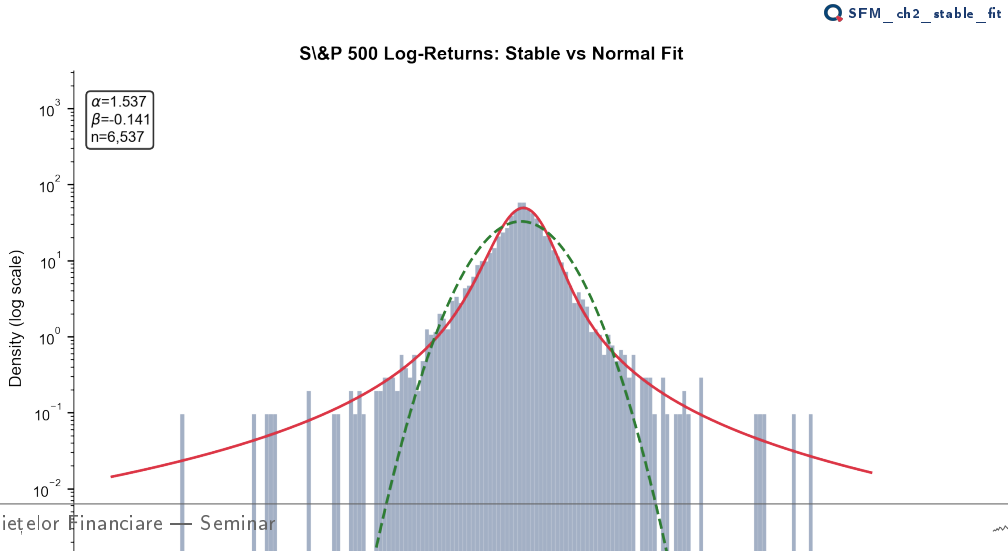

Comparație PDF pe scară logaritmică

SFM_ch2_stable_fit

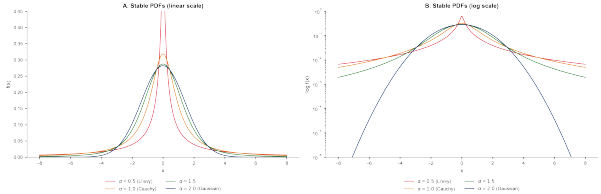

Observații:

- Panoul B (scară log) evidențiază diferențele din cozi
- Distribuția cu $\alpha = 0.5$ (Lévy) are cele mai grele cozi
- La $\alpha = 2.0$ se obține exact distribuția normală
- Randamentele financiare au de regulă $\alpha \in [1.5, 1.9]$

VaR: Tabel comparativ

VaR pe S&P 500 (2000–2025): Gaussiană vs Stabilă vs Empiric

Nivel VaR	Gaussiană	Stabilă	Empiric
5%	−1.91%	−2.14%	−2.08%
1%	−2.71%	−4.12%	−3.56%
0.1%	−3.59%	−8.97%	−6.88%

- La nivelul de 5%, diferențele sunt mici
- La 1%, modelul stabil este cu ∼50% mai conservator decât Gaussiana
- La 0.1%, modelul stabil estimează pierderi de **2.5**× mai mari
- VaR-ul empiric se situează **între** cele două modele parametrice

Comparație cross-asset: Indicele de stabilitate α

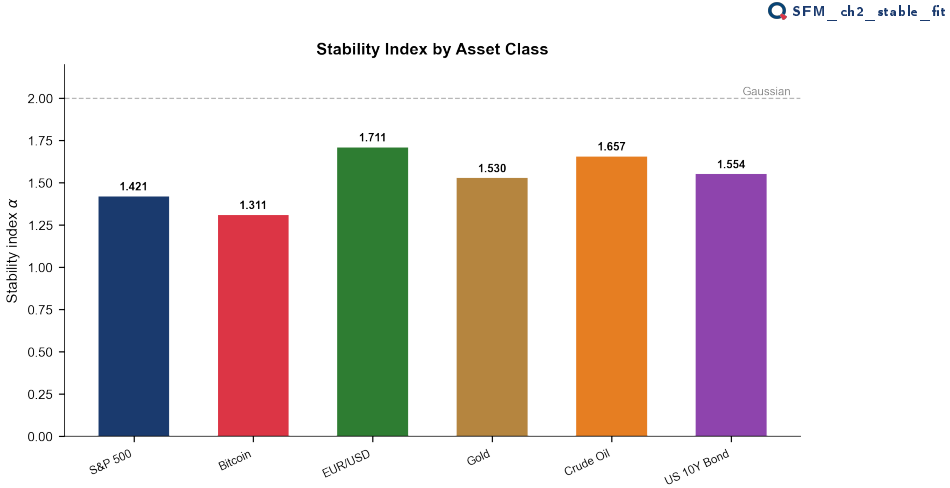

- Bitcoin are cel mai mic $\alpha \Rightarrow$ cele mai grele cozi
- Obligațiunile au α cel mai mare (aproape Gaussian)

Temă: Distribuții stabile pe BVB

Cerințe

1. Alegeți o acțiune listată la BVB (ex: TLV, SNP, BRD, FP)
2. Descărcați datele zilnice din ultimii 5 ani
3. Fit-ați o distribuție stabilă pe log-randamente
4. Comparați grafic PDF stabilă vs normală (scară logaritmică)
5. Calculați VaR la 1% și 5% (stabil vs normal vs empiric)
6. Interpretați rezultatele: este piața românească "mai Gaussiană" decât S&P 500?

Indicii

- Folosiți `yfinance` cu ticker-ul BVB (ex: `TLV.RO`)
- Funcția `levy_stable.fit()` poate fi lentă — folosiți `floc=np.mean(data)`
- Comparați α estimat cu cel al S&P 500

Checklist competențe

Teorie

- ☐ Definiția stabilității prin sume
- ☐ Parametrii: α, β, γ, δ
- ☐ Cazuri speciale: Gauss, Cauchy, Lévy
- ☐ Funcția caracteristică
- ☐ Existența momentelor ($p < \alpha$)
- ☐ Comportamentul cozilor (lege putere)

Practică

- ☐ Estimarea McCulloch (cuantile)
- ☐ MLE cu `levy_stable.fit()`
- ☐ Regresia Koutrouvelis (ECF)
- ☐ VaR: stabil vs normal vs empiric
- ☐ Simulare și vizualizare în Python
- ☐ Interpretarea α pe date reale

Planificarea seminarelor

Săpt.	Tema	Curs asociat	Conținut principal
1	Randamente	Cap. 1: Surse de date	Tipuri randamente, staționaritate
2	**Distribuții stabile**	**Cap. 2: Distribuții**	**Fit stabil, VaR, cozi grele**
3	EMH & Random Walk	Cap. 3–4	Teste EMH, variance ratio
4	Fapte stilizate	Cap. 5–6	ACF, clustering volatilitate

Quiz: 5 întrebări

1. Care sunt limitele parametrului de stabilitate α?
   (a) $0 < \alpha \leq 1$
   (b) $0 < \alpha \leq 2$
   (c) $-2 \leq \alpha \leq 2$
   (d) $\alpha > 0$

2. Pentru o distribuție $S(1.6, 0, 1, 0)$, care momente **există**?
   (a) Media și varianța
   (b) Doar media
   (c) Toate momentele
   (d) Niciun moment

3. Ce distribuție se obține la $\alpha = 1, \beta = 0$?
   (a) Gaussiană
   (b) Cauchy
   (c) Lévy
   (d) Exponențială

Quiz: 5 întrebări (cont.) + Răspunsuri

4. În metoda McCulloch, $v_\alpha = 2.44$ corespunde:
   (a) Cauchy
   (b) Gaussiană
   (c) Lévy
   (d) Stabil($\alpha = 1.5$)

5. De ce VaR stabil > VaR Gaussian la 0.1%?
   (a) Distribuția stabilă are cozi mai grele
   (b) Distribuția stabilă este mai simetrică
   (c) Gaussiana are variantă infinită
   (d) Parametrul β este negativ

Răspunsuri

1. **(b)** $0 < \alpha \leq 2$
2. **(b)** Doar media (deoarece $p < \alpha = 1.6$, deci doar $p < 1.6$)
3. **(b)** Cauchy
4. **(b)** Gaussiană ($\alpha = 2.0$)

Referințe

[1] J.P. Nolan, *Stable Distributions: Models for Heavy Tailed Data*, Birkhäuser, 2020.

[2] B. Mandelbrot, "The variation of certain speculative prices," *Journal of Business*, 36(4), 1963.

[3] S.T. Rachev, S. Mittnik, *Stable Paretian Models in Finance*, Wiley, 2000.

[4] J. Franke, W.K. Härdle, C.M. Hafner, *Statistics of Financial Markets*, 4th ed., Springer, 2019.

[5] J.H. McCulloch, "Simple consistent estimators of stable distribution parameters," *Communications in Statistics — Simulation and Computation*, 15(4), 1986.

Resurse online:

- `https://quantlet.com` — Quantlet repository
- `https://danpele.github.io/SFM/` — Materialele cursului

Mulțumesc!

Întrebări?

Materialele cursului: https://danpele.github.io/SFM/

Quantlet Quantinar