



Statistica Piețelor Financiare

Seminar 3: Distribuții Stabile



Daniel Traian PELE

Antoaneta Amza

Academia de Studii Economice din București

IDA Institute Digital Assets

Blockchain Research Center

AI4EFin Artificial Intelligence for Energy Finance

Academia Română, Institutul de Prognostic Economică

MSCA Digital Finance


Cuprins Seminar

- ▣ **Obiective** – Competențe vizate, parametri, cazuri speciale
- ▣ **Partea I: Exerciții manual** – Stabilitate, funcția caracteristică, momente, densitate
- ▣ **Partea II: Estimare** – McCulloch, MLE, Koutrouvelis, comparație metode
- ▣ **Partea III: Cozi și risc** – Heavy tails, VaR, ES, backtesting, adevărat/fals
- ▣ **Partea IV: Python** – Simulare, fit, comparații VaR, cross-asset, backtest
- ▣ **Discuții și AI** – Scenarii practice, verificarea codului AI
- ▣ **Studiu de caz: S&P 500** – Fit stabil pe date reale, analiză cross-asset
- ▣ **Test rapid** – 8+ întrebări cu răspunsuri detaliate
- ▣ **Rezumat și Bibliografie** – Checklist, referințe, tema pentru acasă

Obiective de învățare

La finalul seminarului veți putea:

- ▣ Verifica proprietatea de stabilitate pentru Gaussiană și Cauchy
- ▣ Calcula funcția caracteristică a unei distribuții stabile
- ▣ Analiza momentele și comportamentul cozilor
- ▣ Estima parametrii unei distribuții stabile (McCulloch, MLE)
- ▣ Compara VaR: Gaussiană vs Stabilă vs Empiric
- ▣ Implementa fit-ul stabil în Python



Parametrii Distribuției Stabile: $\alpha, \beta, \gamma, \delta$


Parametru	Nume	Interval	Controlează
α	Indice de stabilitate	$(0, 2]$	Greutatea cozilor
β	Parametru de asimetrie	$[-1, 1]$	Direcția asimetriei
γ	Parametru de scară	$(0, \infty)$	Dispersia (analogul σ)
δ	Parametru de locație	$(-\infty, \infty)$	Centrul (analogul μ)

- ▣ α mic $\Rightarrow$ cozi **foarte grele** (evenimente extreme frecvente)
- ▣ $\beta = 0$: simetrică; $\beta < 0$: coada stângă mai grea
- ▣ $\alpha = 2$: Normal (β devine irelevant)
- ▣ **Notăție:** $X \sim S(\alpha, \beta, \gamma, \delta)$

Cazuri Speciale: De la Normal la Lévy


Distribuție	α	β	Momente
Gaussiană	2	0	Toate
Cauchy	1	0	Niciunul
Lévy	0.5	1	Niciunul

- ▣ **Gaussiană:** singura stabilă cu varianță finită
- ▣ **Cauchy:** densitate $f(x) = \frac{1}{\pi(1+x^2)}$; fără medie!
- ▣ **Lévy:** distribuție asimetrică pe $[0, \infty)$
- ▣ Doar aceste 3 au PDF cu formă închisă



Familii stabile: de la Lévy la Gaussiană

Spectrul Distribuțiilor Stabile: α de la 0 la 2



- ▣ $\alpha \rightarrow 0$: cozi din ce în ce mai grele, toate momentele divergente
- ▣ $\alpha = 2$: distribuția normală (cozi exponențiale, toate momentele finite)
- ▣ **Randamente financiare**: $\hat{\alpha} \in [1.5, 1.9]$ — între Cauchy și Normal
- ▣ α mai mic $\Rightarrow$ evenimente "lebedă neagră" mai frecvente

Exercițiul 1: Verificarea stabilității — Cazul Gaussian

Problemă

- ▣ Fie X_1, X_2 variabile i.i.d. $\sim \mathcal{N}(0, 1)$. Arătați că $aX_1 + bX_2 \stackrel{d}{=} cX + d$ pentru $a = 3, b = 4, c = 5$.

Rezolvare

- ▣ Dacă $X_1 \sim \mathcal{N}(0, 1)$, atunci $aX_1 \sim \mathcal{N}(0, a^2)$ și $bX_2 \sim \mathcal{N}(0, b^2)$.
- ▣ Suma: $aX_1 + bX_2 \sim \mathcal{N}(0, a^2 + b^2) = \mathcal{N}(0, 9 + 16) = \mathcal{N}(0, 25)$.
- ▣ Deci $c = \sqrt{a^2 + b^2} = \sqrt{25} = 5$ și $d = 0$.
- ▣ **Concluzie:** Distribuția normală este stabilă cu $\alpha = 2$. Proprietatea de stabilitate se reduce la regula adunării varianțelor.

Exercițiul 1 cont.: Cazul Cauchy + Tabel comparativ

Cazul Cauchy ($\alpha = 1$)

- ▣ Fie $X_1, X_2 \sim \text{Cauchy}(0, 1)$ i.i.d.
- ▣ $aX_1 + bX_2 \sim \text{Cauchy}(0, a + b)$
- ▣ Pentru $a = 3, b = 4$: $c = a + b = 7, d = 0$.
- ▣ **Notă:** La Cauchy, scara se adună *liniar*, nu pătratic!

Regula generală

- ▣ Pentru $S(\alpha, \beta, \gamma, \delta)$:

$$c^\alpha = a^\alpha + b^\alpha$$

	α	Regulă	c
Gaussian	2	$c^2 = a^2 + b^2$	5
Cauchy	1	$c = a + b$	7
$S(1.5)$	1.5	$c^{1.5} = a^{1.5} + b^{1.5}$	5.58

Exercițiul 2: Funcția caracteristică

Problemă

- Calculați $\varphi_X(t)$ pentru $X \sim S(1.5, 0.3, 1, 0)$ la $t = 1$.

Rezolvare

- Funcția caracteristică a distribuției stabile: $\log \varphi_X(t) = -|t|^\alpha \left[1 - i\beta \operatorname{sgn}(t) \tan \frac{\pi\alpha}{2} \right] + i\delta t$
- Pentru $\alpha = 1.5$, $\beta = 0.3$, $\gamma = 1$, $\delta = 0$, $t = 1$:
 $\log \varphi_X(1) = -|1|^{1.5} \left[1 - i \cdot 0.3 \cdot 1 \cdot \tan \frac{3\pi}{4} \right] = -1 \cdot [1 - i \cdot 0.3 \cdot (-1)] = -1 - 0.3i$
- Deci: $\varphi_X(1) = e^{-1-0.3i} = e^{-1}(\cos 0.3 - i \sin 0.3) \approx 0.351 - 0.109i$, $|\varphi_X(1)| = e^{-1} \approx 0.368$

Exercițiul 3: Momente și cozi

Problemă

- Un analist financiar modelează randamentele zilnice cu $S(1.7, -0.2, 0.01, 0.0005)$. Care momente există? Ce implică pentru managementul riscului?

Rezolvare

- **Existența momentelor:**
- $\mathbb{E}[|X|^p] < \infty$ dacă și numai dacă $p < \alpha$
- $\alpha = 1.7 \Rightarrow$
 - ▶ Media ($p = 1$): **există** ($1 < 1.7$)
 - ▶ Varianța ($p = 2$): **nu există** ($2 > 1.7$)
 - ▶ Kurtosis ($p = 4$): **nu există**
- **Implicații practice:**
- $\beta = -0.2$: asimetrie negativă (risc la căderi)
- VaR Gaussian **subestimează** riscul real
- Probabilitatea unui eveniment -5σ :
 - ▶ Normal: $\approx 3 \times 10^{-7}$ (1 la 3.5M zile)
 - ▶ Stabil(1.7): ≈ 0.003 (1 la 333 zile)
- Sharpe ratio nu este definit riguros!

Exercițiul 3b: Verificarea stabilității pentru $\alpha = 1.5$

Problemă

- Fie $X_1, X_2 \sim S(1.5, 0, 1, 0)$ i.i.d. Calculați constanta c astfel încât $X_1 + X_2 \sim S(1.5, 0, c, 0)$, pentru $a = b = 1$.

Rezolvare

- **Formula:** $c^\alpha = a^\alpha + b^\alpha$
- $c^{1.5} = 1^{1.5} + 1^{1.5} = 2$
- $c = 2^{1/1.5} = 2^{2/3} \approx 1.587$

- **Comparație cu Normal ($\alpha = 2$):**
- Normal: $c = 2^{1/2} = \sqrt{2} \approx 1.414$
- Stabil(1.5): $c = 2^{2/3} \approx 1.587$
- $\Rightarrow$ Suma a două variabile stabile crește scara **mai repede** decât sub Normal
- Implicație: diversificarea reduce riscul **mai puțin eficient** sub distribuții stabile

Exercițiul 3c: Densitatea stabilă vs normală în puncte cheie

Problemă

- Comparați $P(|X| > k)$ pentru Normal vs $S(1.7, 0, 1, 0)$, pentru $k = 2, 3, 5$.

Rezolvare

k	$P_{\text{Normal}}(X > k)$	$P_{\text{Stabil}}(X > k)$	Raport	Frecvență stabil
2	4.56%	8.2%	$1.8\times$	1 la 12 zile
3	0.27%	2.1%	$7.8\times$	1 la 48 zile
5	0.000057%	0.35%	$6,100\times$	1 la 286 zile

- Diferența crește **dramatic** cu k
- La $k = 5$: evenimentul este de $6,100\times$ mai probabil sub modelul stabil
- $\Rightarrow$ Modelul normal **subestimează** frecvența evenimentelor extreme

Metoda McCulloch — Concept

Ideea principală

- Estimarea parametrilor $(\alpha, \beta, \gamma, \delta)$ din **cuantile** ale eșantionului.

Statistici intermediare:

$$v_{\alpha} = \frac{q_{0.95} - q_{0.05}}{q_{0.75} - q_{0.25}}$$

$$v_{\beta} = \frac{q_{0.95} + q_{0.05} - 2q_{0.50}}{q_{0.95} - q_{0.05}}$$

- v_{α} măsoară *greutatea cozilor* (tail thickness)
- v_{β} măsoară *asimetria*

Tabel de referință (selecție):

v_{α}	α	Interpretare
2.44	2.0	Gaussiană
2.62	1.9	Aproape Gauss
3.04	1.7	Cozi moderate
4.21	1.5	Cozi grele
6.31	1.3	Cozi foarte grele

McCulloch — Exercițiu rezolvat

Date numerice

- Din eșantionul de 2000 observații: $q_{0.05} = -3.42$, $q_{0.25} = -0.78$, $q_{0.50} = 0.05$, $q_{0.75} = 0.82$, $q_{0.95} = 3.61$.

Rezolvare pas cu pas

- **Pasul 1:** $v_{\alpha} = \frac{q_{0.95} - q_{0.05}}{q_{0.75} - q_{0.25}} = \frac{3.61 - (-3.42)}{0.82 - (-0.78)} = \frac{7.03}{1.60} = 4.39$
- **Pasul 2:** Din tabel: $v_{\alpha} = 4.39$ corespunde $\hat{\alpha} \approx 1.48$
- **Pasul 3:** $v_{\beta} = \frac{q_{0.95} + q_{0.05} - 2q_{0.50}}{q_{0.95} - q_{0.05}} = \frac{3.61 + (-3.42) - 2 \cdot 0.05}{7.03} = \frac{0.09}{7.03} \approx 0.013$
- **Pasul 4:** $v_{\beta} \approx 0.013 \approx 0 \Rightarrow \hat{\beta} \approx 0$ (distribuție aproape simetrică)

Maximum Likelihood Estimation (MLE)

Procedura

$$\hat{\theta}_{MLE} = \arg \max_{\theta} \sum_{i=1}^n \log f(x_i; \alpha, \beta, \gamma, \delta)$$

□ Provocări:

- PDF-ul nu are formă închisă (în general)
- Trebuie evaluare numerică prin FFT
- Funcția de verosimilitate nu e convexă
- Convergență lentă pentru α mic

□ Avantaje:

- Cea mai eficientă estimare asimptotic
- Intervale de încredere standard
- Implementare:
`scipy.stats.levy_stable.fit()`

□ One-liner Python:

```
from scipy.stats import levy_stable  
a, b, loc, sc = levy_stable.fit(data)
```

Regresia Koutrouvelis

Metoda în 2 etape

- Se utilizează funcția caracteristică empirică (ECF).

- Etapa 1:** Estimarea α și γ prin regresie liniară:

$$\log(-\log|\hat{\varphi}_n(t)|^2) = \log(2\gamma^\alpha) + \alpha \log|t|$$

- Regresie $Y = a + bX$ cu $Y_k = \log(-\log|\hat{\varphi}_n(t_k)|^2)$ și $X_k = \log|t_k|$.

- Etapa 2:** Estimarea β și δ prin regresie pe partea imaginară:

$$\arg[\hat{\varphi}_n(t)] = \delta t - \beta\gamma^\alpha \tan \frac{\pi\alpha}{2} \operatorname{sgn}(t)|t|^\alpha$$

Avantaj

- Robustă numeric, nu necesită evaluarea PDF-ului, convergență rapidă.

Comparație: McCulloch vs MLE vs Koutrouvelis

- ▣ **Problemă:** Pe $n = 5000$ randamente zilnice S&P 500, cele 3 metode dau:

Metodă	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\gamma}$	Timp calcul
McCulloch	1.72	-0.15	0.0083	< 0.01s
Koutrouvelis	1.69	-0.19	0.0081	~ 0.1s
MLE	1.71	-0.18	0.0082	~ 30s

- ▣ **Observații:**
- ▣ Toate metodele dau $\hat{\alpha} \approx 1.7$ — consistent
- ▣ McCulloch: cel mai rapid, dar mai puțin precis (bazat pe doar 5 cuantile)
- ▣ MLE: cel mai precis asimptotic, dar **foarte lent**
- ▣ Koutrouvelis: compromis bun viteză/precizie
- ▣ **Recomandare:** McCulloch pentru explorare rapidă, MLE pentru rapoarte finale

Heavy tails — Gaussiană vs Stabilă

Q SFM_ch2_stable_fit

Tabel comparativ: Probabilitatea evenimentelor extreme

Eveniment	Gaussiană	Stabil($\alpha=1.7$)	Raport
$ X > 3\sigma$	2.7×10^{-3}	1.9×10^{-2}	$\approx 7 \times$
$ X > 5\sigma$	5.7×10^{-7}	3.0×10^{-3}	$\approx 5,000 \times$
$ X > 10\sigma$	1.5×10^{-23}	5.2×10^{-4}	$\approx 10^{19} \times$

Implicație practică

- ▣ Modelele Gaussiene subestimează dramatic riscul evenimentelor extreme. Un eveniment “ 10σ ” pe care Gaussiană îl consideră practic imposibil apare o dată la $\sim 2,000$ de zile (~ 8 ani) sub modelul stabil.

Exercițiul 4: VaR Gaussiană vs Stabilă

Problemă

- ▣ Portofoliu de 1M EUR. Randamente zilnice $\sim S(1.7, -0.2, 0.01, 0.0005)$. Comparați VaR la 1%, 5%, 0.1%.


Rezolvare

Nivel VaR	Gaussiană	Stabilă	Diferență
5%	-16,449 EUR	-21,340 EUR	+30%
1%	-22,763 EUR	-39,870 EUR	+75%
0.1%	-30,091 EUR	-87,420 EUR	+190%

- ▣ **Concluzie:** Cu cât nivelul de încredere este mai mare, cu atât diferența crește. La VaR 0.1%, modelul stabil estimează pierderi de aproape $3 \times$ mai mari.

Comparație vizuală: Funcția de supraviețuire

SFM_ch2_stable_fit



- ▣ Grafic log-log: funcția de supraviețuire $P(X > x)$
- ▣ Stabilă: scade ca o **lege putere** $P(X > x) \sim C_\alpha x^{-\alpha}$; Normală: scade **exponențial**

Exercițiul 5: Expected Shortfall sub Distribuție Stabilă

Problemă

- Portofoliu de 1,000,000 EUR. Randamente $\sim S(1.7, -0.2, 0.01, 0)$.
- Calculați raportul ES/VaR la 1% și comparați cu cazul Normal.

Rezolvare

- | | |
|----------------------------|--|
| □ Normal: | □ Stabil ($\alpha = 1.7$): |
| □ $VaR_{1\%} = 22,763$ EUR | □ $VaR_{1\%} = 39,870$ EUR |
| □ $ES_{1\%} = 26,152$ EUR | □ $ES_{1\%} = 67,779$ EUR |
| □ $ES/VaR = 1.149$ | □ $ES/VaR = 1.700$ |
-
- $\Rightarrow$ Sub distribuția stabilă, ES este cu **70%** mai mare decât VaR (vs 15% sub Normal)
 - Motiv: cozile grele contribuie enorm la media pierderilor condiționate
 - **Regulă practică:** ES/VaR crește cu scăderea lui α

Exercițiul 6: Backtesting VaR — Câte depășiri?

Problemă

- Pe 2500 de zile de tranzacționare (≈ 10 ani), VaR la 1% a fost depășit de:

Model	Depășiri așteptate	Depășiri observate	Verdict
Normal	25 (1%)	58	Subestimează
Stabil($\alpha = 1.7$)	25 (1%)	29	Bun
Empiric	25 (1%)	25	Exact

- Normalul: 58 depășiri vs 25 așteptate $\Rightarrow 2.3\times$ mai multe
- Modelul stabil: aproape de numărul așteptat
- Testul Kupiec (LR):** compară proporția observată cu cea așteptată
- $LR = 2 \left[v \ln \frac{v/n}{\alpha} + (n - v) \ln \frac{1-v/n}{1-\alpha} \right] \sim \chi^2(1)$

Adevărat sau Fals? — Distribuții Stabile

Răspundeți cu A sau F:

1. Normala este un caz special al distribuțiilor stabile ($\alpha = 2$).
2. Cauchy ($\alpha = 1$) are medie finită.
3. Dacă $\alpha = 1.8$, s^2 converge la o constantă finită când $n \rightarrow \infty$.
4. Funcția caracteristică stabilă are formă închisă.
5. McCulloch este mai eficientă asimptotic decât MLE.
6. Cozile distribuției stabile scad ca $x^{-\alpha}$.
7. VaR stabil $>$ VaR Gaussian întotdeauna.

Răspunsuri

1. **A**: Normal $\equiv S(2, 0, \sigma/\sqrt{2}, \mu)$
2. **F**: Cauchy nu are niciun moment finit
3. **F**: $\alpha = 1.8 < 2 \Rightarrow \text{varianța} = \infty$; s^2 diverge
4. **A**: $\log \varphi(t)$ parametrică; PDF-ul nu
5. **F**: MLE cea mai eficientă
6. **A**: $P(X > x) \sim C_{\alpha} x^{-\alpha}$
7. **F**: La 5% diferența e mică

Simulare: Stable Distributions

```
import numpy as np
from scipy.stats import levy_stable
import matplotlib.pyplot as plt

alphas = [0.5, 1.0, 1.5, 2.0]
x = np.linspace(-8, 8, 1000)

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(14, 5))
colors = ['#DC3545', '#FF8C00', '#2E7D32', '#1A3A6E']
labels = ['alpha=0.5 (Levy)', 'alpha=1.0 (Cauchy)',
          'alpha=1.5', 'alpha=2.0 (Gaussian)']

for a, c, lab in zip(alphas, colors, labels):
    pdf = levy_stable.pdf(x, alpha=a, beta=0)
    ax1.plot(x, pdf, color=c, label=lab)
    ax2.semilogy(x, pdf, color=c, label=lab)

ax1.set_title('PDFs (linear)')
ax2.set_title('PDFs (log scale)')
for ax in [ax1, ax2]:
    ax.legend(loc='upper center',
             bbox_to_anchor=(0.5, -0.12), ncol=2)
plt.tight_layout()
```


Python: Stable Fit S&P 500

```
import yfinance as yf
from scipy.stats import levy_stable, norm


sp500 = yf.download('^GSPC', start='2000-01-01',
                    end='2025-12-31')
returns = np.log(
    sp500['Close'] / sp500['Close'].shift(1)).dropna()

# Fit stable distribution
alpha, beta, loc, scale = levy_stable.fit(returns.values)
print(f"alpha={alpha:.3f}, beta={beta:.3f}")

# Fit normal
mu, sigma = norm.fit(returns.values)

# Compare on log-scale
x = np.linspace(returns.min()*1.2,
                returns.max()*1.2, 1000)
plt.hist(returns, bins=150, density=True,
        alpha=0.4, label='Data')
plt.semilogy(x, levy_stable.pdf(x, alpha, beta,
                                loc, scale), label='Stable')
plt.semilogy(x, norm.pdf(x, mu, sigma),
            '--', label='Normal')
```


Overlay PDF: Histogram + Stable + Normal (log-scale)



- Pe scară logaritmică, diferența în cozi este evidentă
- Stabilă: captează **leptokurtosis**; Normală: subestimează cozile

Python: VaR Comparison

```
# VaR comparison
levels = [0.01, 0.05, 0.001]
for cl in levels:
    var_s = levy_stable.ppf(
        cl, alpha, beta, loc, scale)
    var_n = norm.ppf(cl, mu, sigma)
    var_e = np.percentile(
        returns, cl*100)
    print(f"VaR {cl*100:.1f}%:")
    print(f"  Stable:      {var_s:.5f}")
    print(f"  Normal:       {var_n:.5f}")
    print(f"  Empirical:    {var_e:.5f}")
```



Exercițiu Python 5: Comparație Cross-Asset α

Sarcină:

1. Descărcați randamente zilnice pentru S&P 500, Bitcoin și Gold (ultimii 5 ani)
2. Ajustați o distribuție stabilă pe fiecare activ
3. Comparați $\hat{\alpha}$ — care activ are cele mai grele cozi?
4. Vizualizați PDF-urile estimate pe același grafic (log-scale)

Cod cheie:

```
tickers = ['^GSPC', 'BTC-USD', 'GC=F']
for t in tickers:
    data = yf.download(t, start='2020-01-01')
    ret = np.log(data['Close']/data['Close'].shift(1)).dropna()
    a, b, loc, sc = levy_stable.fit(ret.values)
    print(f"{t}: alpha={a:.3f}, beta={b:.3f}")
```

 SFM_ch2_stable_fit

Exercițiu Python 6: Backtesting VaR Stabil vs Normal

Sarcină:

1. Estimați VaR la 1% pe o fereastră de 500 zile (rolling window)
2. Comparați numărul de depășiri VaR: Normal vs Stabil vs Empiric
3. Vizualizați randamentele cu liniile VaR suprapuse

Cod cheie:

```
window = 500
for i in range(window, len(returns)):
    train = returns[i-window:i]
    a, b, loc, sc = levy_stable.fit(train)
    var_stable[i] = levy_stable.ppf(0.01, a, b, loc, sc)
    var_normal[i] = norm.ppf(0.01, train.mean(), train.std())
violations_s = (returns>window:] < var_stable>window:]).sum()
```

 SFM_ch2_stable_fit

Exercițiu AI: Prompt Engineering

Exercițiu

☐ Folosiți ChatGPT sau Claude pentru a genera cod Python care:

1. Descarcă datele BTC-USD din ultimii 5 ani
2. Ajustează o distribuție stabilă pe log-randamentele zilnice
3. Compară grafic PDF stabilă vs normală (log-scale)
4. Calculează VaR la 1% și 5%
5. Realizează un backtest: câte zile au depășit VaR-ul estimat?

Prompt sugerat

☐ *“Write Python code using `scipy.stats.levy_stable` to fit a stable distribution to BTC-USD daily log-returns from `yfinance`. Plot histogram with stable and normal overlay on log-scale. Calculate VaR at 1% and 5% for both distributions and backtest against actual returns.”*

Discuție 1: Normal vs Stabil în Practică

- ▣ **Scenariu:** Un fond de investiții folosește distribuția normală pentru calculul VaR zilnic. Auditorii recomandă trecerea la distribuția stabilă.
- ▣ **Întrebări:**
 1. Care sunt **avantajele** practice ale modelului normal? (simplitate, CLT, formulă închisă)
 2. Ce probleme specifice apar cu distribuția stabilă? (varianță infinită, estimare lentă, PDF fără formă închisă)
 3. La ce **nivel** de VaR (5%, 1%, 0.1%) diferența contează cel mai mult?
 4. Cum justificați costul computațional suplimentar al modelului stabil?

Recomandare

Raportați ambele modele. Diferența este un **indicator** al riscului de model.

Discuție 2: Limitările Distribuțiilor Stabile

- ▣ **Scenariu:** Estimați $\alpha = 1.6$ pe randamente zilnice BTC-USD. Managerul de risc întreabă: “Sharpe ratio-ul portofoliului este 1.2. Este fiabil?”
- ▣ **Întrebări:**
 1. Cu $\alpha = 1.6$, ce momente **nu** există? Cum afectează aceasta Sharpe ratio-ul?
 2. Dacă varianța este infinită, cum comparați riscul între active?
 3. Ce **alternative** la Sharpe ratio funcționează cu distribuții stabile? (Rachev ratio, Stable Tail Adjusted Return)
 4. Distribuția stabilă presupune independență. Este realist pe piețele financiare?
- ▣ **Indiciu:** Cu $\alpha = 1.6$, $\mathbb{E}[X^p] < \infty$ doar pentru $p < 1.6$. Varianța ($p = 2$) este infinită.

Exercițiu AI 2: Verificarea codului generat

Prompt de testat

“Scrie cod Python care: (1) generează 10000 observații dintr-o distribuție stabilă cu $\alpha=1.5$, $\beta=0.3$, (2) estimează parametrii din eșantion folosind McCulloch și MLE, (3) compară estimările cu valorile reale, (4) vizualizează histograma cu PDF-ul estimat overlay.”


☐ Verificați:

1. LLM-ul folosește `levy_stable.rvs()` corect (4 parametri: α , β , `loc`, `scale`)?
2. Implementarea McCulloch este corectă? (cuantile, nu momente!)
3. MLE cu `levy_stable.fit()` — convergează? Rezultatele sunt rezonabile?
4. Estimările sunt aproape de $\alpha = 1.5$, $\beta = 0.3$?
5. Overlay-ul PDF folosește parametrii **estimați**, nu cei reali?

Atenție: `levy_stable.fit()` poate fi foarte lent. Verificați dacă LLM-ul menționează această limitare.

Histogram + Fit stabil vs Normal


SFM_ch2_stable_fit



- Stabilă: se potrivește mai bine în **centru** și în **cozi**
- Normală: supraestimează la $\pm 1\sigma$, subestimează în cozi

Comparație PDF pe scară logaritmică

SFM_ch2_stable_fit



- **Observații:**
- Panoul B (scară log) evidențiază diferențele din cozi
- $\alpha = 0.5$ (Lévy): cele mai grele cozi
- La $\alpha = 2.0$: exact distribuția normală
- Randamente financiare: $\alpha \in [1.5, 1.9]$

VaR: Tabel comparativ


VaR pe S&P 500 (2000–2025): Gaussiană vs Stabilă vs Empiric

Nivel VaR	Gaussiană	Stabilă	Empiric
5%	−1.91%	−2.14%	−2.08%
1%	−2.71%	−4.12%	−3.56%
0.1%	−3.59%	−8.97%	−6.88%

- La nivelul de 5%, diferențele sunt mici
- La 1%, modelul stabil este cu $\sim 50\%$ mai conservator decât Gaussiană
- La 0.1%, modelul stabil estimează pierderi de $2.5\times$ mai mari
- VaR-ul empiric se situează **între** cele două modele parametrice

Comparație cross-asset: Indicele de stabilitate α

SFM_ch2_stable_fit



- Bitcoin are cel mai mic $\alpha \Rightarrow$ cele mai grele cozi
- Obligațiunile au α cel mai mare (aproape Gaussian)
- **Nicio** clasă de active nu este perfect Gaussiană ($\alpha < 2$)

Temă: Distribuții stabile pe BVB

Cerințe

1. Alegeți o acțiune listată la BVB (ex: TLV, SNP, BRD, FP)
2. Descărcați datele zilnice din ultimii 5 ani
3. Ajustați o distribuție stabilă pe log-randamente
4. Comparați grafic PDF stabilă vs normală (scară logaritmică)
5. Calculați VaR la 1% și 5% (stabil vs normal vs empiric)
6. Interpretați rezultatele: este piața românească “mai Gaussiană” decât S&P 500?

Indicii

- ▣ Folosiți `yfinance` cu ticker-ul BVB (ex: TLV.R0)
- ▣ Funcția `levy_stable.fit()` poate fi lentă — folosiți `floc=np.mean(data)`
- ▣ Comparați α estimat cu cel al S&P 500

Checklist competențe

Teorie

- ☐ Definiția stabilității prin sume
- ☐ Parametrii: α , β , γ , δ
- ☐ Cazuri speciale: Gauss, Cauchy, Lévy
- ☐ Funcția caracteristică
- ☐ Existența momentelor ($p < \alpha$)
- ☐ Comportamentul cozilor (lege putere)

Practică

- ☐ Estimarea McCulloch (cuantile)
- ☐ MLE cu `levy_stable.fit()`
- ☐ Regresia Koutrouvelis (ECF)
- ☐ VaR: stabil vs normal vs empiric
- ☐ Simulare și vizualizare în Python
- ☐ Interpretarea α pe date reale

Următorul Seminar

Cozi Grele — Skew- t , GED și EVT

Planificarea seminarelor

Săpt.	Tema	Curs asociat	Conținut principal
1	Randamente	Cap. 1: Surse de date	Tipuri randamente, staționaritate
2	Distribuții clasice	Cap. 2: Distribuții	Normal, Student- t , Pareto, VaR
3	Distribuții stabile	Cap. 2: Distribuții	Fit stabil, VaR, cozi grele
4	EVT, Copule, Risc	Cap. 4: EVT & Copule	GEV, GPD, copule, VaR/ES
5	Selecția modelului	Cap. 5: Selecția modelului	AIC/BIC, backtesting VaR

Quiz: 5 întrebări

1. Care sunt limitele parametrului de stabilitate α ?
 - (a) $0 < \alpha \leq 1$
 - (b) $0 < \alpha \leq 2$
 - (c) $-2 \leq \alpha \leq 2$
 - (d) $\alpha > 0$
2. Pentru o distribuție $S(1.6, 0, 1, 0)$, care momente **există**?
 - (a) Media și varianța
 - (b) Doar media
 - (c) Toate momentele
 - (d) Niciun moment
3. Ce distribuție se obține la $\alpha = 1, \beta = 0$?
 - (a) Gaussiană
 - (b) Cauchy
 - (c) Lévy
 - (d) Exponențială

Quiz: 5 întrebări (cont.) + Răspunsuri

4. În metoda McCulloch, $v_\alpha = 2.44$ corespunde:
(a) Cauchy (b) Gaussiană (c) Lévy (d) Stabil($\alpha = 1.5$)
5. De ce VaR stabil $>$ VaR Gaussian la 0.1%?
(a) Distribuția stabilă are cozi mai grele (b) Este mai simetrică
(c) Gaussiană are varianță infinită (d) β este negativ

Răspunsuri

1. **(b)** $0 < \alpha \leq 2$
2. **(b)** Doar media ($p < \alpha = 1.6$)
3. **(b)** Cauchy
4. **(b)** Gaussiană ($\alpha = 2.0$)
5. **(a)** Cozile mai grele ale distribuției stabile

Test 6: Proprietatea de stabilitate

Întrebare

Dacă $X_1, X_2 \sim S(\alpha, \beta, \gamma, \delta)$ i.i.d., atunci $X_1 + X_2$ este:

Variante de răspuns

- (A) $S(\alpha, \beta, 2\gamma, 2\delta)$
- (B) $S(2\alpha, \beta, \gamma, \delta)$
- (C) $S(\alpha, \beta, 2^{1/\alpha}\gamma, 2\delta)$
- (D) $S(\alpha, 2\beta, \gamma, \delta)$

Test 6: Răspuns

Răspuns: C

$$X_1 + X_2 \sim S(\alpha, \beta, 2^{1/\alpha}\gamma, 2\delta)$$

▣ **Regula generală de stabilitate:**

▣ Dacă $X_1, \dots, X_n$ sunt i.i.d. $S(\alpha, \beta, \gamma, \delta)$:

$$X_1 + \dots + X_n \sim S(\alpha, \beta, n^{1/\alpha}\gamma, n\delta)$$

▣ α și β se **păstrează** (forma și asimetria)

▣ γ (scara) crește cu factorul $n^{1/\alpha}$

▣ δ (locația) se adună liniar

▣ **Verificare:** $\alpha = 2$ (Normal): $n^{1/2}\gamma = \sqrt{n}\sigma$ ✓

▣ $\alpha = 1$ (Cauchy): $n^{1/1}\gamma = n\gamma$ — scara crește **liniar**!

Test 7: Convergența la distribuție stabilă

Întrebare

Fie $X_1, \dots, X_n$ i.i.d. cu $\alpha = 1.7$. Ce se întâmplă cu media $\bar{X}_n$ când $n \rightarrow \infty$?

Variante de răspuns

- (A) Converge la Normal (CLT clasic funcționează)
- (B) Converge la distribuție stabilă cu același α
- (C) Converge la Cauchy
- (D) Nu converge la nimic

Test 7: Răspuns

Răspuns: B

Media converge la o distribuție stabilă cu același $\alpha = 1.7$

- ▣ **CLT generalizat (Gnedenko–Kolmogorov):**
- ▣ Dacă $\text{Var}(X) = \infty$ ($\alpha < 2$), CLT clasic **nu se aplică**
- ▣ Media normalizată converge la o distribuție **stabilă**:

$$\frac{X_1 + \dots + X_n - n\delta}{n^{1/\alpha}\gamma} \xrightarrow{d} S(\alpha, \beta, 1, 0)$$

- ▣ Normalizarea este $n^{1/\alpha}$, nu $\sqrt{n}$
- ▣ $\alpha = 1.7$: viteza de convergență este $n^{1/1.7} \approx n^{0.59}$
- ▣ $\Rightarrow$ Distribuțiile stabile sunt singurele **atractori** posibili pentru sume normalizate

Test 8: Estimatorul McCulloch

Întrebare

Statisticile McCulloch v_α și v_β se calculează din:

Variante de răspuns

- (A) Momentele eșantionului (medie, varianță, skewness)
- (B) Cuantilele eșantionului ($q_{0.05}$, $q_{0.25}$, $q_{0.50}$, $q_{0.75}$, $q_{0.95}$)
- (C) Funcția caracteristică empirică
- (D) Log-verosimilitatea maximă

Test 8: Răspuns

Răspuns: B

McCulloch folosește 5 cuantile ale eșantionului

- ▣ **De ce cuantile și nu momente?**
- ▣ Momentele de ordin $\geq \alpha$ sunt **infinite** $\Rightarrow$ inutilizabile
- ▣ Cuantilele există **întotdeauna**, indiferent de α
- ▣ **Cele 5 cuantile:** $q_{0.05}$, $q_{0.25}$, $q_{0.50}$, $q_{0.75}$, $q_{0.95}$

$$v_{\alpha} = \frac{q_{0.95} - q_{0.05}}{q_{0.75} - q_{0.25}}, \quad v_{\beta} = \frac{q_{0.95} + q_{0.05} - 2q_{0.50}}{q_{0.95} - q_{0.05}}$$

- ▣ A: Momentele nu funcționează (pot fi infinite) ✗
- ▣ C: Metoda Koutrouvelis, nu McCulloch ✗
- ▣ D: MLE, nu McCulloch ✗

Bibliografie I

Distribuții Stabile

- ▣ Nolan, J.P. (2020). *Stable Distributions: Models for Heavy Tailed Data*, Birkhäuser.
- ▣ Mandelbrot, B. (1963). "The variation of certain speculative prices," *Journal of Business*, 36(4).
- ▣ Rachev, S.T., Mitnik, S. (2000). *Stable Paretian Models in Finance*, Wiley.
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets*, 4th ed., Springer.
- ▣ McCulloch, J.H. (1986). "Simple consistent estimators of stable distribution parameters," *Communications in Statistics — Simulation and Computation*, 15(4).

Resurse online

- ▣ <https://quantlet.com> — Quantlet repository
- ▣ <https://danpele.github.io/SFM/> — Materialele cursului

Vă mulțumesc! Întrebări? Materialele seminarului sunt disponibile la:

<https://danpele.github.io/SFM/>



Quantlet



Quantinar