



Statistica Piețelor Financiare

Seminar 4: EVT, Copule și Managementul Riscului



Daniel Traian PELE
Antoaneta Amza

Academia de Studii Economice din București
IDA Institute Digital Assets
Blockchain Research Center
AI4EFin Artificial Intelligence for Energy Finance
Academia Română, Institutul de Prognostic Economică
MSCA Digital Finance


Cuprins Seminar

- ▣ **Obiective** – Competențe vizate, recapitulare formule cheie
- ▣ **Partea I: EVT manual** – GEV, GPD, POT, estimatorul Hill, Mean Excess
- ▣ **Partea II: Compararea distribuțiilor** – AIC, BIC, QQ-plot, backtesting VaR
- ▣ **Partea III: Copule** – Gaussiană, Student- t , Clayton, Gumbel, dependența de coadă
- ▣ **Partea IV: Managementul riscului** – VaR, ES, subaditivitate, Kupiec, Basel III
- ▣ **Partea V: Python** – EVT fit, backtesting, copule, GARCH
- ▣ **Discuții și AI** – Scenarii practice, verificarea codului AI
- ▣ **Test rapid** – 8 întrebări cu răspunsuri detaliate
- ▣ **Rezumat și Bibliografie** – Checklist, referințe, tema pentru acasă

Obiective de învățare

La finalul seminarului veți putea:

- ▣ Aplica metoda POT: alege pragul u , ajusta GPD, calcula VaR/ES
- ▣ Utiliza estimatorul Hill pentru indicele de coadă
- ▣ Compara distribuții prin AIC, BIC, teste KS și grafice QQ
- ▣ Descrie copulele principale și dependența de coadă
- ▣ Calcula VaR și ES sub diferite ipoteze distribuționale
- ▣ Efectua backtesting VaR cu testul Kupiec



Recapitulare: Formule cheie din curs

EVT — Extreme Value Theory

- ▣ **GEV:** $H_{\xi}(x) = \exp\{-(1 + \xi x)^{-1/\xi}\}$
- ▣ **GPD:** $G_{\xi, \sigma}(y) = 1 - (1 + \xi y/\sigma)^{-1/\xi}$
- ▣ **VaR POT:**

$$\text{VaR}_{\alpha} = u + \frac{\hat{\sigma}}{\hat{\xi}} \left[\left(\frac{n}{N_u} \alpha \right)^{-\hat{\xi}} - 1 \right]$$

- ▣ **ES POT:**

$$\text{ES}_{\alpha} = \frac{\text{VaR}_{\alpha}}{1 - \hat{\xi}} + \frac{\hat{\sigma} - \hat{\xi}u}{1 - \hat{\xi}}$$

Selecția modelului

- ▣ **AIC:** $-2\ell + 2k$
- ▣ **BIC:** $-2\ell + k \ln n$
- ▣ **Hill:** $\hat{\alpha}_H = \left[\frac{1}{k} \sum_{i=1}^k \ln \frac{X_{(i)}}{X_{(k+1)}} \right]^{-1}$

Măsurile de risc

- ▣ **VaR:** $P(X \leq -\text{VaR}_{\alpha}) = \alpha$
- ▣ **ES:** $\mathbb{E}[-X \mid X \leq -\text{VaR}_{\alpha}]$
- ▣ **Kupiec:** $LR \sim \chi^2(1)$

Exercițiul 1: Parametrul de formă GEV — Interpretare

Problemă

- ▣ Maximele lunare ale pierderilor zilnice pe S&P 500 (20 ani, $n = 240$ blocuri) sunt ajustate cu GEV. Rezultat: $\hat{\xi} = 0,28$, $\hat{\mu} = 1,8\%$, $\hat{\sigma} = 0,9\%$.
- ▣ (a) Ce tip de GEV este? (b) Ce implică $\xi > 0$ pentru cozi? (c) Calculați cuantila 99%.

Rezolvare

- ▣ (a) $\xi > 0 \Rightarrow$ **Fréchet** (cozi groase, lege putere). Celelalte: Gumbel ($\xi = 0$), Weibull ($\xi < 0$).
- ▣ (b) Coada superioară scade ca $x^{-1/\xi} = x^{-3,57}$. Momente de ordin $\geq 1/\xi \approx 3,6$ nu există.
- ▣ (c) Cuantila 99%: $x_{0,99} = \hat{\mu} + \frac{\hat{\sigma}}{\hat{\xi}} \left[(-\ln 0,99)^{-\hat{\xi}} - 1 \right]$
 $= 1,8\% + \frac{0,9\%}{0,28} \left[(0,01005)^{-0,28} - 1 \right] = 1,8\% + 3,214\% \times (3,72 - 1) = 10,5\%$

Exercițiul 2: Metoda POT — Pas cu pas

Problemă


- ▣ Din $n = 1.000$ randamente zilnice, $N_u = 50$ depășesc pragul $u = 2,5\%$ (în valoare absolută). GPD ajustată pe excese: $\hat{\xi} = 0,3$, $\hat{\sigma} = 0,8\%$. Calculați VaR și ES la 1%.

Rezolvare

1. Raportul: $\frac{n\alpha}{N_u} = \frac{1000 \times 0,01}{50} = 0,2$; $0,2^{-0,3} = 1,621$
2. $\text{VaR}_{1\%} = u + \frac{\hat{\sigma}}{\hat{\xi}} [0,2^{-\hat{\xi}} - 1] = 2,5\% + \frac{0,8\%}{0,3} \times 0,621 = 2,5\% + 1,66\% = 4,16\%$
3. $\text{ES}_{1\%} = \frac{\text{VaR}}{1-\hat{\xi}} + \frac{\hat{\sigma}-\hat{\xi}u}{1-\hat{\xi}} = \frac{4,16\%}{0,7} + \frac{0,8\%-0,75\%}{0,7} = 5,94\% + 0,07\% = 6,01\%$
4. **Interpretare:** Pierdere medie *dincolo* de VaR este 6,01%, cu 44% mai mare decât VaR!

Graficul Mean Excess — Alegerea pragului u

SFM_ch2_extreme_value



Funcția Mean Excess

$$e(u) = \mathbb{E}[X - u \mid X > u] = \frac{\hat{\sigma} + \hat{\xi}u}{1 - \hat{\xi}}$$

- ▣ Graficul $e(u)$ vs u : **linie dreaptă** dacă GPD este corectă
- ▣ Pantă pozitivă ($\hat{\xi} > 0$): cozi groase
- ▣ Pantă zero ($\hat{\xi} = 0$): cozi exponențiale
- ▣ **Prag optim**: zona unde graficul devine linear
- ▣ Prag prea jos $\Rightarrow$ bias; prea sus $\Rightarrow$ varianță mare

Exercițiul 3: Estimatorul Hill

Problemă


- ▣ Cele mai mari 6 pierderi zilnice (ordonate descrescător): $X_{(1)} = 8,2\%$, $X_{(2)} = 6,5\%$, $X_{(3)} = 5,1\%$, $X_{(4)} = 4,3\%$, $X_{(5)} = 3,8\%$, $X_{(6)} = 3,2\%$. Calculați $\hat{\alpha}_{\text{Hill}}$ pentru $k = 5$.

Rezolvare

- ▣ $\hat{\xi}_{\text{Hill}} = \frac{1}{k} \sum_{i=1}^k \ln \frac{X_{(i)}}{X_{(k+1)}} = \frac{1}{5} \left[\ln \frac{8,2}{3,2} + \ln \frac{6,5}{3,2} + \ln \frac{5,1}{3,2} + \ln \frac{4,3}{3,2} + \ln \frac{3,8}{3,2} \right]$
- ▣ $= \frac{1}{5} [0,941 + 0,709 + 0,466 + 0,296 + 0,172] = \frac{2,584}{5} = 0,517$
- ▣ $\hat{\alpha}_{\text{Hill}} = 1/\hat{\xi}_{\text{Hill}} = 1/0,517 = 1,93$
- ▣ **Interpretare:** Indicele de coadă ≈ 2 sugerează cozi foarte groase (varianță la limită). Consistent cu randamente financiare tipice ($\hat{\alpha} \in [2, 5]$).

Graficul Hill — Stabilitatea estimării

SFM_ch2_extreme_value



- ▣ $\hat{\alpha}_{Hill}^{(k)}$ vs. k : regiunea **stabilă** (platou) indică alegerea optimă a lui k
- ▣ k mic: varianță mare (puține observații); k mare: bias (include date non-extreme)
- ▣ **Regulă practică:** $k \in [50, 300]$ pentru $n \approx 2.500$ zile

Exercițiul 4: AIC și BIC — Selecția modelului

Problemă

- Pe $n = 2.516$ randamente zilnice S&P 500, MLE produce:


Model	Parametri (k)	ℓ (log-lik)	AIC
Normal	2	7,890	?
Student- t	3	8,117	?
Skew- t	4	8,131	?

Rezolvare

- Normal: $-15,776$; Student- t : $-16,228$; Skew- t : $-16,254$ (cel mai bun)
- $\Delta AIC_{\text{Normal vs Skew-}t} = 478 \Rightarrow$ dovadă covârșitoare ($> 10 =$ puternic, $> 100 =$ indiscutabil)


Comparație vizuală: Overlay și QQ-plot

SFM_ch2_dist_comparison



Overlay: N vs t vs Empiric

- Overlay: exces de kurtosis (vârf ascuțit + cozi groase)
- QQ-plot: curbura la capete $\Rightarrow$ cozi mai groase decât modelul
- **Diagnostic rapid:** QQ-plot este mai sensibil în cozi decât histograma



QQ-plot: devierea = inadecvare

Exercițiul 5: Backtesting VaR — Testul Kupiec

Problemă

- Un model VaR 1% produce $v = 18$ depășiri pe $n = 1,000$ de zile. Testați validitatea modelului.

Rezolvare


- Proporția observată: $\hat{p} = 18/1000 = 1,8\%$ vs așteptat $\alpha = 1\%$
- Testul Kupiec (Likelihood Ratio):

$$LR = -2 \ln \frac{\alpha^v (1 - \alpha)^{n-v}}{\hat{p}^v (1 - \hat{p})^{n-v}} = -2 \ln \frac{0,01^{18} \cdot 0,99^{982}}{0,018^{18} \cdot 0,982^{982}}$$

- $LR = 7,35$; $\chi_{1;0,05}^2 = 3,84$
- $7,35 > 3,84 \Rightarrow$ **Respins**: modelul subestimează sistematic riscul de coadă
- Concluzie**: 18 depășiri vs 10 așteptate — modelul normal este inadecvat

Backtesting vizual: VaR pe date reale

SFM_ch2_risk_measures



- Punctele **roșii**: depășiri ale VaR (pierderi > VaR estimat)
- Modelul normal (linia albastră) produce mai multe depășiri decât Student- t sau EVT
- **Interpretare**: Un model bun produce $\sim \alpha\%$ depășiri, distribuite uniform

Teorema lui Sklar — Fundament

Teoremă (Sklar, 1959)

- Orice distribuție multivariată $F(x_1, \dots, x_d)$ cu marginale $F_1, \dots, F_d$:
 $F(x_1, \dots, x_d) = C(F_1(x_1), \dots, F_d(x_d))$ unde $C : [0, 1]^d \rightarrow [0, 1]$ este **copula**. Dacă marginalele sunt continue, C este **unică**.

De ce copule?

- Separă structura marginală de structura de dependență
- Corelația Pearson ρ captează doar dependența *liniară*
- Copulele captează dependența *de coadă* (crize!)

Familii principale

- Gaussiană**: $\lambda_U = \lambda_L = 0$ (fără dep. de coadă)
- Student- t** : $\lambda_U = \lambda_L > 0$ (simetrică)
- Clayton**: $\lambda_L > 0, \lambda_U = 0$ (coadă inferioară)
- Gumbel**: $\lambda_U > 0, \lambda_L = 0$ (coadă superioară)

Exercițiul 6: Dependența de coadă — Calcul

Problemă


- Copula Student- t bivariată cu $\rho = 0,5$ și $\nu = 4$ grade de libertate. Calculați coeficientul de dependență de coadă λ_U .

Rezolvare

- Formula: $\lambda_U = 2 t_{\nu+1} \left(-\sqrt{\frac{(\nu+1)(1-\rho)}{1+\rho}} \right)$
- $\lambda_U = 2 t_5 \left(-\sqrt{\frac{5 \times 0,5}{1,5}} \right) = 2 t_5 \left(-\sqrt{1,667} \right) = 2 t_5(-1,291)$
- $t_5(-1,291) \approx 0,127 \Rightarrow \lambda_U = 2 \times 0,127 = 0,254$
- **Interpretare:** Dacă un activ suferă o pierdere extremă, probabilitatea ca celălalt activ să sufere simultan este $\sim 25\%$. Sub copula Gaussiană, această probabilitate ar fi 0!

Vizualizare: Copule pe date financiare

SFM_ch2_case_study_2c



- Scatter-plot pe marginale uniforme ($U_1 = F_1(X_1)$, $U_2 = F_2(X_2)$)
- Concentrarea în colțurile (0, 0) și (1, 1): dependență de coadă
- Copula Gaussiană: concentrare centrală; Student- t : concentrare în colțuri

Exercițiul 7: Alegerea copulei — Tabel comparativ

Problemă

- Date bivariate (S&P 500, DAX). Ajustați 4 copule:

Copulă	$\hat{\theta}$	ℓ	AIC	$\hat{\lambda}_L$
Gaussiană	$\rho = 0,62$	312	-622	0
Student- t	$\rho = 0,63, \nu = 6$	338	-672	0,18
Clayton	$\theta = 1,1$	305	-608	0,22
Gumbel	$\theta = 1,6$	295	-588	0

Rezolvare

- **Cel mai bun AIC:** Student- t (-672). $\Delta\text{AIC} = 50$ față de Gaussiană $\Rightarrow$ puternic
- Student- t : dep. de coadă simetrică ($\lambda_L = \lambda_U = 0,18$); Clayton: doar λ_L
- **Concluzie:** Copula Student- t este preferabilă pentru portofolii diversificate

Exercițiul 8: VaR și ES sub diferite distribuții

Problemă

- ▣ Portofoliu de \$1M, $\mu = 0,03\%/zi$, $\sigma = 1,5\%/zi$. Calculați VaR și ES la 1% sub: (a) distribuția normală; (b) Student- t cu $\nu = 5$.


Rezolvare

	Normal	Student- t ($\nu = 5$)
VaR _{1%}	3,52% $\Rightarrow$ \$35,190	3,93% $\Rightarrow$ \$39,330
ES _{1%}	\$39,975	\$52,100
ES/VaR	1,14	1,32

- ▣ Student- t : factor $\sqrt{(\nu - 2)/\nu} = 0,7746$ pe σ ; cuantila $|t_{0,01;5}| = 3,365$ vs $z = 2,326$
- ▣ Cozile grele cresc ES relativ mai mult decât VaR
- ▣ **Basel III**: ES (nu VaR) este măsura oficială de risc de piață

VaR: Subaditivitate și coerență

SFM_ch2_risk_measures



VaR nu este subaditivă!

- Există cazuri unde:

$$VaR(X + Y) > VaR(X) + VaR(Y)$$

- Diversificarea “crește” riscul?! $\Rightarrow$ Absurd
- VaR nu este măsură **coerentă** de risc

ES este subaditivă

- $ES(X + Y) \leq ES(X) + ES(Y)$
- ES satisface toate 4 axiomele Artzner (1999)
- De aceea Basel III a trecut de la VaR la ES

Adevărat sau Fals? — EVT, Copule și Risc

1. $\hat{\xi} > 0$ în GEV indică cozi groase de tip Fréchet.
2. Metoda POT necesită împărțirea datelor în blocuri.
3. Copula Gaussiană captează dependența de coadă.
4. ES este întotdeauna $\geq$ VaR la același nivel de încredere.
5. BIC penalizează mai puternic decât AIC pentru $n > 8$.
6. Estimatorul Hill funcționează doar pentru cozi de tip lege putere.
7. Testul Kupiec evaluează dacă numărul de depășiri VaR este consistent cu α .

Răspunsuri

1. ✓ **A:** Fréchet = lege putere; Gumbel ($\xi = 0$); Weibull ($\xi < 0$)
2. ✗ **F:** POT = depășiri peste prag, nu blocuri. Block Maxima = blocuri
3. ✗ **F:** Gaussiană: $\lambda_U = \lambda_L = 0$. Trebuie Student- t sau Arhimediană
4. ✓ **A:** ES = media pierderilor | pierdere $>$ VaR $\Rightarrow$ ES $\geq$ VaR
5. ✓ **A:** BIC: $k \ln n$; AIC: $2k$. $\ln n > 2$ pentru $n > 8$
6. ✓ **A:** Hill presupune $P(X > x) \sim Cx^{-\alpha}$
7. ✓ **A:** Kupiec: $H_0 : p = \alpha$ cu LR $\sim \chi^2(1)$

Lab 1: EVT și backtesting VaR

 SFM_ch2_extreme_value

Exercițiu Python (30 min)

Deschideți `SFM_ch2_extreme_value.ipynb`:

1. Descărcați randamente S&P 500 (2015–2025); grafic Mean Excess $\Rightarrow$ alegeți u
2. Ajustați GPD pe excese $\Rightarrow (\hat{\xi}, \hat{\sigma})$; calculați VaR/ES la 1%
3. Comparați cu VaR/ES sub normală și Student- t
4. Backtest VaR cu fereastră mobilă 250 zile; testul Kupiec

```
from scipy.stats import genpareto
# Fit GPD on exceedances
excess = losses[losses > u] - u
xi, loc, sigma = genpareto.fit(excess, floc=0)
print(f"xi = {xi:.3f}, sigma = {sigma:.4f}")
# VaR POT
VaR = u + (sigma/xi) * ((n*alpha/Nu)**(-xi) - 1)
```

Lab 2: Copule în Python

Exercițiu Python (20 min)

Analizați dependența S&P 500 – DAX:

1. Randamente zilnice $\Rightarrow$ marginale uniforme (PIT)
2. Ajustați copule: Gaussiană, Student- t , Clayton, Gumbel
3. Comparați AIC; estimați λ_L , λ_U ; scatter-plot $[0, 1]^2$

```
from copulas.bivariate import Clayton, Gumbel
from scipy.stats import kendalltau
# Kendall's tau -> theta
tau, _ = kendalltau(u1, u2)
# Clayton: theta = 2*tau/(1-tau)
theta_c = 2 * tau / (1 - tau)
lambda_L = 2**(-1/theta_c) # lower tail dependence
print(f"Clayton: theta={theta_c:.2f}, lambda_L={lambda_L:.3f}")
```

Lab 3: GARCH cu inovații non-Gaussiene

 SFM_ch2_modern_extensions

Exercițiu Python (15 min)

Comparați GARCH(1,1) cu diferite inovații:

1. Ajustați GARCH(1,1) cu inovații normale și Student- t
2. Comparați AIC/BIC
3. Extrageți reziduurile standardizate: sunt i.i.d.?
4. Calculați VaR 1% **condiționat** pe volatilitatea curentă

```
from arch import arch_model
# GARCH(1,1) with Student-t innovations
model = arch_model(returns, vol='Garch', p=1, q=1, dist='t')
res = model.fit(dispen='off')
# Conditional VaR
cond_vol = res.conditional_volatility
VaR_t = res.params['mu'] + cond_vol * t.ppf(0.01, res.params['nu'])
```

Scenarii practice: Ce model alegeți?

Scenariul 1: Fond de investiții — raportare zilnică

- ▣ Portofoliu diversificat (acțiuni, obligațiuni, FX). Trebuie VaR zilnic la 1%.
- ▣ **Recomandare:** GARCH(1,1) cu inovații Student- t — captează clusterizarea volatilității și cozile groase

Scenariul 2: Bancă — cerințe de capital Basel III

- ▣ Regulatorul cere ES la 2,5% pe orizont de 10 zile.
- ▣ **Recomandare:** EVT (POT) pe reziduurile GARCH — cel mai robust pentru cozi extreme

Scenariul 3: Asigurări — modelarea pierderilor catastrofale

- ▣ Pierderi rare dar extreme (cutremure, inundații). Dependență spațială.
- ▣ **Recomandare:** EVT + copule Clayton/Gumbel pentru dependența de coadă

Exercițiu AI: Verificați codul generat

Prompt pentru AI

“Scrie cod Python care ajustează GPD pe excesele peste pragul $u = 2,5\%$ din randamentele S&P 500 și calculează VaR la 1%.”

Ce trebuie verificat:

1. **Semnul randamentelor:** AI-ul a folosit pierderi ($-r_t$) sau randamente (r_t)?
 2. **Parametrul `floc=0`:** GPD trebuie ajustat cu locație fixă la 0 (excesele sunt deja centrate)
 3. **Formula VaR POT:** verificați dacă folosește n/N_u corect, nu N_u/n
 4. **Pragul u :** este selectat prin Mean Excess plot sau arbitrar?
 5. **Interpretare:** VaR-ul returnat este zilnic sau anual? Procent sau valoare absolută?
- ☐ **Regulă:** Codul AI poate fi un punct de *plecare*, nu un produs finit. Verificați **întotdeauna** convențiile de semn și formulele!

Test 1: GPD și POT

Întrebare

□ În metoda POT, ce distribuție se ajustează pe excesele peste prag?

Variante de răspuns

- (A) Distribuția normală
- (B) Distribuția Pareto generalizată (GPD)
- (C) Distribuția exponențială
- (D) Distribuția GEV

Test 1: Răspuns

Răspuns: B

Teorema Pickands–Balkema–de Haan: excesele peste un prag u suficient de mare converg la GPD.

- ☐ **A** — Normala nu modelează cozi extreme ✗
- ☐ **C** — Exponențiala este GPD cu $\xi = 0$ (caz particular, prea restrictiv) ✗
- ☐ **D** — GEV este pentru Block Maxima, nu POT ✗

Test 2: Estimatorul Hill

Întrebare

- ☐ Ce presupunere fundamentală face estimatorul Hill despre coada distribuției?

Variante de răspuns

- (A) Coada scade exponențial
- (B) Coada urmează o lege putere: $P(X > x) \sim Cx^{-\alpha}$
- (C) Distribuția este simetrică
- (D) Distribuția are varianță finită

Test 2: Răspuns

Răspuns: B

Hill este un estimator **semi-parametric** care presupune variație regulată (lege putere) în coada dreaptă.

- ☐ **A** — Cozi exponențiale: Hill nu este aplicabil (dă $\hat{\alpha} \rightarrow \infty$) ✗
- ☐ **C** — Nu necesită simetrie, funcționează pe o singură coadă ✗
- ☐ **D** — Funcționează chiar și cu varianță infinită ($\alpha < 2$) ✗

Test 3: Copula și dependența de coadă

Întrebare

□ Care copulă are dependență de coadă **simetrică** ($\lambda_L = \lambda_U > 0$)?

Variante de răspuns

- (A) Gaussiană
- (B) Clayton
- (C) Student- t
- (D) Gumbel

Test 3: Răspuns

Răspuns: C

Copula Student- t are $\lambda_L = \lambda_U > 0$. Dependența de coadă crește cu scăderea lui ν .

- ☐ **A** — Gaussiană: $\lambda_L = \lambda_U = 0$ (nicio dependență de coadă) ✗
- ☐ **B** — Clayton: doar $\lambda_L > 0$ (asimetrică, coada inferioară) ✗
- ☐ **D** — Gumbel: doar $\lambda_U > 0$ (asimetrică, coada superioară) ✗

Test 4: VaR vs ES

Întrebare

□ De ce Basel III a înlocuit VaR cu ES ca măsură principală de risc de piață?

Variante de răspuns

- (A) ES este mai ușor de calculat
- (B) ES este subaditivă (coerentă) și captează gravitatea cozii
- (C) VaR subestimează întotdeauna riscul
- (D) ES este mai stabilă la alegerea nivelului de încredere

Test 4: Răspuns

Răspuns: B

ES satisface subaditivitatea: diversificarea reduce riscul. VaR poate penaliza diversificarea.

- ☐ A — ES este de fapt *mai greu* de calculat (necesită integrale) ✗
- ☐ C — VaR nu subestimează *întotdeauna*; problema este non-coerența ✗
- ☐ D — Stabilitatea nu este motivul principal al schimbării regulamentare ✗

Test 5: Testul Kupiec

Întrebare

□ Un model VaR 1% produce 35 depășiri pe 2,000 de zile. Așteptarea: 20. Ce concluzie trageți?

Variante de răspuns

- (A) Modelul este acceptabil ($35 \approx 20$)
- (B) Modelul subestimează riscul semnificativ
- (C) Modelul supraestimează riscul
- (D) Nu putem concluziona fără BIC

Test 5: Răspuns

Răspuns: B

$\hat{p} = 35/2000 = 1,75\%$ vs $\alpha = 1\%$. Modelul produce $1,75\times$ mai multe depășiri.

- ▣ Kupiec: $LR = -2 \ln \frac{0,01^{35} \cdot 0,99^{1965}}{0,0175^{35} \cdot 0,9825^{1965}} = 9,12 > 3,84$
- ▣ $\Rightarrow$ **Respins** la 5%: modelul subestimează sistematic riscul
- ▣ **A** — 35 vs 20 nu este “aproape” ✗
- ▣ **C** — Mai multe depășiri = model prea optimist, nu prea conservator ✗
- ▣ **D** — BIC este pentru selecția modelului, nu backtesting ✗

Test 6: AIC vs BIC

Întrebare

- ▣ Modelul A: $AIC = 5,200$. Modelul B: $AIC = 5,180$. Care este mai bun și cât de puternică este dovada?

Variante de răspuns

- (A) A este mai bun (AIC mai mare)
- (B) B este mai bun, dovadă puternică ($\Delta > 10$)
- (C) B este mai bun, dar diferența nu este semnificativă
- (D) Nu putem compara modele diferite cu AIC

Test 6: Răspuns

Răspuns: B

$\Delta AIC = 5,200 - 5,180 = 20 > 10 \Rightarrow$ dovadă puternică pentru modelul B.

- ▣ Scala Burnham–Anderson: $\Delta < 2$ slab; 4–7 moderat; > 10 puternic
- ▣ **A** — Confundă direcția: AIC *mai mic* = mai bun ✗
- ▣ **C** — $\Delta = 20$ este deasupra pragului de semnificație ✗
- ▣ **D** — AIC poate compara orice modele pe aceleași date ✗

Test 7: Mean Excess plot

Întrebare

□ Graficul Mean Excess $e(u)$ vs u are pantă pozitivă. Ce implică aceasta?

Variante de răspuns

- (A) Distribuția are cozi exponențiale
- (B) Distribuția are cozi groase ($\xi > 0$)
- (C) Distribuția este simetrică
- (D) Pragul ales este prea mare

Test 7: Răspuns

Răspuns: B

$e(u) = (\hat{\sigma} + \hat{\xi}u)/(1 - \hat{\xi})$. Pantă pozitivă $\Leftrightarrow \hat{\xi} > 0 \Leftrightarrow$ cozi groase (Fréchet).

- ☐ **A** — Cozi exponențiale: $e(u) = \text{const}$ (pantă zero, $\xi = 0$) ✗
- ☐ **C** — Mean Excess nu informează despre simetrie ✗
- ☐ **D** — Pragul nu afectează *panta*, doar volatilitatea estimării ✗

Test 8: Teorema lui Sklar

Întrebare

▣ Ce garantează Teorema lui Sklar despre unicitatea copulei?

Variante de răspuns

- (A) Copula este unică pentru orice distribuție multivariată
- (B) Copula este unică dacă marginalele sunt continue
- (C) Copula este unică doar pentru distribuții eliptice
- (D) Copula nu este niciodată unică

Test 8: Răspuns

Răspuns: B

Sklar (1959): dacă $F_1, \dots, F_d$ sunt continue, copula C este **unică**. Pentru marginale discrete, copula nu este neapărat unică.

- ☐ A — Nu “orice”: necesită continuitate ✗
- ☐ C — Nu doar eliptice: funcționează pentru orice marginale continue ✗
- ☐ D — Este unică sub continuitate ✗

Checklist: Ce trebuie să știți

EVT

- ☐ GEV: Fréchet ($\xi > 0$), Gumbel ($\xi = 0$), Weibull ($\xi < 0$)
- ☐ GPD: ajustare pe excese peste prag u
- ☐ Formulele VaR POT și ES POT
- ☐ Mean Excess plot: alegerea pragului
- ☐ Hill: indicele de coadă, graficul Hill

Copule

- ☐ Teorema lui Sklar
- ☐ Gaussiană vs Student- t : λ_U
- ☐ Clayton (λ_L) vs Gumbel (λ_U)
- ☐ AIC pentru selecția copulei

Selecția modelului

- ☐ AIC: $-2\ell + 2k$
- ☐ BIC: $-2\ell + k \ln n$
- ☐ QQ-plot: interpretare
- ☐ Scala ΔAIC : 2/4-7/10+

Managementul riscului

- ☐ VaR: definiție, calcul
- ☐ ES: subaditivitate, coerență
- ☐ Kupiec: LR, $\chi^2(1)$
- ☐ Basel III: ES $>$ VaR
- ☐ GARCH + inovații non-Gaussiene

Tema pentru acasă

Exercițiu individual (deadline: următorul seminar)

1. Alegeți un activ financiar (acțiune, criptomonedă, FX) cu minim 5 ani de date zilnice
2. Aplicați metoda POT: grafic Mean Excess $\Rightarrow$ alegeți $u \Rightarrow$ ajustați GPD
3. Calculați VaR 1% și ES 1% sub 3 modele: Normal, Student- t , EVT
4. Efectuați backtesting VaR pe ultimii 2 ani (fereastră mobilă 250 zile)
5. Raportați: tabel comparativ, graficul Hill, Mean Excess, testul Kupiec
6. **Bonus:** ajustați o copulă Student- t pe perechea activ ales + S&P 500

Resurse

- Quantlet: https://github.com/QuantLet/Stat_fin_markets/tree/master/Ch_02
- Curs: <https://danpele.github.io/SFM/>

Bibliografie

Referințe principale

- ▣ Embrechts, P., Klüppelberg, C., Mikosch, T. (1997). *Modelling Extremal Events for Insurance and Finance*, Springer.
- ▣ McNeil, A.J., Frey, R., Embrechts, P. (2015). *Quantitative Risk Management*, 2nd ed., Princeton.
- ▣ Nelsen, R.B. (2006). *An Introduction to Copulas*, 2nd ed., Springer.
- ▣ de Haan, L., Ferreira, A. (2006). *Extreme Value Theory: An Introduction*, Springer.
- ▣ Artzner, P. et al. (1999). "Coherent measures of risk," *Mathematical Finance*, 9(3).
- ▣ Franke, J., Härdle, W.K., Hafner, C.M. (2019). *Statistics of Financial Markets*, 4th ed., Springer.

Resurse online

- ▣ <https://quantlet.com> — Quantlet repository
- ▣ <https://danpele.github.io/SFM/> — Materialele cursului

Vă mulțumesc!

Întrebări?

Materialele seminarului sunt disponibile la: <https://danpele.github.io/SFM/>



Quantlet



Quantinar